Contents

Ανθρωποκεντρική Μηχανική Μάθηση: Παρεξηγημένη **1**
Δομή του Βιβλίου . . . 1

Δήλωση Πρωτοτυπίας **3**

Περίληψη **5**

Ευχαριστίες **7**

Τι Είναι η Ανθρωποκεντρική ΜΜ; **9**
Το Παράδοξο της Αυτοματοποίησης . . . 9
Ορισμός της Ανθρωποκεντρικής ΜΜ . . . 9
Μια Σύντομη Ιστορία . . . 10
Γιατί HITL; Η Υπεράσπιση της Ανθρώπινης Κρίσης . . . 11
Ο Βρόχος Ανατροφοδότησης . . . 12
Τι Δεν Είναι το HITL . . . 13
Τα Οικονομικά της Ανθρώπινης Ανατροφοδότησης . . . 13
Επισκόπηση του Εγχειριδίου . . . 13

Ταξινόμηση Αλληλεπίδρασης Ανθρώπου–Μηχανής **15**
Επίπεδα Αυτοματοποίησης . . . 15
Ενεργός vs. Παθητική Ανθρώπινη Εμπλοκή . . . 16
Μεμονωμένος vs. Πολλαπλοί Σχολιαστές . . . 17
Ένα Ενοποιημένο Πλαίσιο . . . 17

Σχολιασμός Δεδομένων και Επισήμανση **19**
Τύποι Σχολιασμού . . . 19
Οδηγίες Σχολιασμού . . . 20
Μέτρηση Ποιότητας Σχολιασμού: Συμφωνία Μεταξύ Σχολιαστών . . . 21
Χειρισμός Διαφωνιών . . . 22
Θόρυβος Ετικετών και οι Επιπτώσεις του . . . 23
Κόστος και Απόδοση Σχολιασμού . . . 24

Ενεργός Μάθηση **25**
Η Ρύθμιση Ενεργούς Μάθησης . . . 25
Θεωρητικές Βάσεις . . . 25
Στρατηγικές Ερωτημάτων . . . 26
Εκτίμηση Αβεβαιότητας για Βαθιά Μοντέλα . . . 27
Ένας Πλήρης Βρόχος Ενεργούς Μάθησης . . . 29
Το Πρόβλημα Ψυχρής Εκκίνησης . . . 31
Ενεργός Μάθηση Λειτουργίας Παρτίδας . . . 31

Κριτήρια Διακοπής . . . 31
Πότε Λειτουργεί η Ενεργός Μάθηση (και Πότε Δεν Λειτουργεί) . . . 32

Διαδραστικό Μηχανικό Μάθηση **33**
Αρχές Διαδραστικού Μηχανικού Μάθησης . . . 33
Σύγκριση με Ενεργό Μάθηση . . . 33
Αλληλεπίδραση Μικτής Πρωτοβουλίας . . . 34
Ανθρώπινοι Παράγοντες στο IML . . . 34
Τύποι Ανατροφοδότησης IML στην Πράξη . . . 35
Μελέτη Περίπτωσης: Google Teachable Machine . . . 35
Υλοποίηση ενός Απλού Βρόχου IML . . . 36
Το Τεστ της Γιαγιάς . . . 37
IML και Θεμελιακά Μοντέλα . . . 38

Ενισχυτική Μάθηση από Ανθρώπινη Ανατροφοδότηση **41**
Το Πρόβλημα Ευθυγράμμισης . . . 41
Ο Αγωγός RLHF . . . 41
Μια Απλοποιημένη Επίδειξη RLHF . . . 43
Προκλήσεις στο RLHF . . . 44
Constitutional AI (RLAIF) . . . 45

Μάθηση από Επιδείξεις **47**
Κλωνοποίηση Συμπεριφοράς . . . 47
Αντίστροφη Ενισχυτική Μάθηση . . . 48
GAIL: Γενετική Ανταγωνιστική Μάθηση Μίμησης . . . 49
Κλωνοποίηση Συμπεριφοράς στην ΕΦΓ: Πρακτικό Παράδειγμα . . . 49
Σύγκριση Μεθόδων Μάθησης από Μίμηση . . . 51
Εφαρμογές . . . 51

Μάθηση από Συγκρίσεις και Κατατάξεις **53**
Γιατί οι Συγκρίσεις Είναι Καλύτερες από τις Αξιολογήσεις . . . 53
Το Μοντέλο Bradley-Terry . . . 54
Το Μοντέλο Thurstone . . . 55
Συνάθροιση Κατατάξεων . . . 56
Dueling Bandits . . . 56
Μάθηση Προτίμησης για Γλωσσικά Μοντέλα . . . 56
Συλλογή Δεδομένων Προτίμησης Υψηλής Ποιότητας . . . 57

Ανθρωποκεντρική ΜΜ στην Επεξεργασία Φυσικής Γλώσσας **59**
Το Συγκροτητικό Πρόβλημα στον Σχολιασμό ΕΦΓ . . . 59
Σχολιασμός Ταξινόμησης Κειμένου . . . 60
Αναγνώριση Ονομαστικών Οντοτήτων . . . 60
Εξαγωγή Σχέσεων και Σημασιολογικός Σχολιασμός . . . 61
Μετα-Επεξεργασία Μηχανικής Μετάφρασης (MTPE) . . . 61
Διάλογος και Σχολιασμός Συνομιλίας . . . 62
Προγραμματική Επισήμανση και Αδύναμη Εποπτεία . . . 62
RLHF για Γλωσσικά Μοντέλα: Η Πραγματικότητα Σχολιασμού . . . 63
Ο Βρόχος Ανατροφοδότησης Σχολιασμού–Μοντέλου . . . 64
Αξιολόγηση Γεννητικών Μοντέλων ΕΦΓ . . . 65

Ανθρωποκεντρική ΜΜ στην Υπολογιστική Όραση **67**
Πώς οι Επιλογές Σχολιασμού Γίνονται Προκαταλήψεις Μοντέλου . . . 67
Σχολιασμός Ταξινόμησης Εικόνας . . . 68

Ανίχνευση Αντικειμένων: Σχολιασμός Οριοθετικών Πλαισίων 68
Σημασιολογική και Κατά Στιγμιότυπο Τμηματοποίηση 70
Ενεργός Μάθηση για Υπολογιστική Όραση 70
Ημι-Εποπτευόμενη Μάθηση με Ανθρώπινη Καθοδήγηση 72
Σχολιασμός Βίντεο 72

Ανθρωποκεντρική ΜΜ στην Υγεία και την Επιστήμη 75
Ανάλυση Ιατρικής Εικόνας 75
Κλινικός Σχολιασμός ΕΦΓ 77
Ρυθμιστικές Εκτιμήσεις 77
Σχολιασμός Επιστημονικών Δεδομένων 78
Διαχείριση Σχολιαστών Ειδικών 79
Αγωγός Ενεργούς Μάθησης HITL για Ιατρική Απεικόνιση 79

Πλατφόρμες Σχολιασμού και Εργαλεία 83
Το Τοπίο Πλατφορμών Σχολιασμού 83
Σύγκριση Χαρακτηριστικών Πλατφορμών Σχολιασμού 84
Σχολιασμός ως Κώδικας 85

Crowdsourcing και Ποιοτικός Έλεγχος 87
Πλατφόρμες Crowdsourcing 87
Σχεδιασμός Εργασιών για Crowdsourcing 88
Στατιστικά Μοντέλα για Συνάθροιση Ετικετών 89
Στρατηγική Πλεονασμού και Συνάθροισης 91

Αξιολόγηση και Μετρικές 93
Μετρικές Κεντρικές στο Μοντέλο 93
Μετρικές Αποδοτικότητας Σχολιασμού 94
Ανθρώπινη Αξιολόγηση 95
Μέτρηση Ευθυγράμμισης με Ανθρώπινη Πρόθεση 97
Δοκιμές A/B σε Αναπτυγμένα Συστήματα 97

Δικαιοσύνη, Προκατάληψη και Ηθική 99
Πηγές Προκατάληψης σε Συστήματα HITL 99
Δικαιοσύνη σε Συστήματα HITL 100
Πρόνοια Σχολιαστών 101
Ιδιωτικότητα στον Σχολιασμό 102
Αντίξοος Σχολιασμός και Δηλητηρίαση Δεδομένων 102
Θεσμική Ηθική 103

Μελλοντικές Κατευθύνσεις 105
Θεμελιώδη Μοντέλα και ο Μεταβαλλόμενος Ρόλος του Σχολιασμού 105
LLMs ως Σχολιαστές 106
Αδύναμη Επίβλεψη σε Κλίμακα 106
Συνεχής Μάθηση με Ανθρώπινη Εποπτεία 107
Πολυτροπικό HITL 107
Κλιμακωτή Εποπτεία 107
Η Εξελισσόμενη Κατανομή Εργασίας 108
Ανοιχτά Ερευνητικά Προβλήματα 108

Βιβλιογραφία 111

Μελέτη Περίπτωσης: Limen — Ένας Άνθρωπος στον Βρόχο των Πάντων 113

Το Πρόβλημα με τη Συμβατική Σχεδίαση ΛΣ 113
Αρχιτεκτονική στο Κατώφλι 114
Ο Σχεδιασμός Αλληλεπίδρασης 116
Το Limen ως Σύστημα HITL 117
Το Βαθύτερο Νόημα 117

Περί Αποχώρησης **119**

Ανθρωποκεντρική Μηχανική Μάθηση: Παρεξηγημένη

Λάζαρος Τουμανίδης

Αυτό το εγχειρίδιο εξετάζει έναν από τους πιο κρίσιμους — και παρεξηγημένους — τομείς της σύγχρονης τεχνητής νοημοσύνης: την ενσωμάτωση του ανθρώπου στον βρόχο μάθησης. Από τον σχολιασμό δεδομένων και την ενεργό μάθηση έως την ενισχυτική μάθηση από ανθρώπινη ανατροφοδότηση (RLHF) και τη μάθηση από επιδείξεις, η ανθρώπινη κρίση παραμένει ανεκτίμητη — ακόμη και σε εποχή που τα μοντέλα AI δείχνουν να τα καταφέρνουν σχεδόν σε οτιδήποτε.

Το βιβλίο απευθύνεται σε ερευνητές, μηχανικούς και φοιτητές που θέλουν να κατανοήσουν πότε, γιατί και πώς ο άνθρωπος πρέπει να συμμετέχει στον κύκλο μάθησης.

:::{admonition} Ελληνική έκδοση :class: note Αυτή είναι η ελληνική μετάφραση. Η αγγλική πρωτότυπη έκδοση είναι η κύρια έκδοση αναφοράς. Ορισμένα τεχνικά κεφάλαια ενδέχεται να βρίσκονται σε εξέλιξη μετάφρασης. :::

Δομή του Βιβλίου

Το βιβλίο οργανώνεται σε έξι μέρη:

Μέρος I — Θεμέλια θέτει το εννοιολογικό πλαίσιο: τι σημαίνει «ανθρωποκεντρική» ΜΜ και πώς ταξινομούνται τα διάφορα επίπεδα αυτοματισμού.

Μέρος II — Βασικές Τεχνικές καλύπτει τις θεμελιώδεις μεθόδους: σχολιασμό δεδομένων, ενεργό μάθηση και διαδραστικό μηχανικό μάθηση.

Μέρος III — Μάθηση από Ανατροφοδότηση πραγματεύεται το RLHF, τη μάθηση από επιδείξεις και τη μάθηση από συγκρίσεις.

Μέρος IV — Εφαρμογές εξετάζει πρακτικά παραδείγματα σε ΕΦΓ, υπολογιστική όραση και ιατρικά συστήματα.

Μέρος V — Συστήματα καλύπτει τα εργαλεία, τις πλατφόρμες και τις μετρικές που απαιτεί κάθε ανθρωποκεντρικό σύστημα στην πράξη.

Μέρος VI — Ηθική θέτει ζητήματα δικαιοσύνης, προκατάληψης και της σχέσης ανθρώπου-αλγόριθμου στο μέλλον.

Δήλωση Πρωτοτυπίας

Υποβληθέν σε μερική μη-εκπλήρωση των απαιτήσεων για τον τίτλο του Διδάκτορα της Φιλοσοφίας.

Δηλώνω με το παρόν ότι η εργασία που παρουσιάζεται σε αυτό το εγχειρίδιο είναι δική μου, εκτός από τα σημεία όπου δεν είναι.

Οι ιδέες αυτών των σελίδων παράχθηκαν με τη συνδρομή: ερευνητών που δημοσίευσαν εργασίες και τις έβαλαν περιστασιακά πίσω από τείχη πληρωμής· σχολιαστών δεδομένων η εργασία των οποίων κατέστησε δυνατά τα μοντέλα αλλά τα ονόματά τους δεν εμφανίζονται σε καμία ενότητα ευχαριστιών· συντελεστών ανοιχτού κώδικα που έγραψαν τις βιβλιοθήκες που χρησιμοποιούνται σε κάθε παράδειγμα κώδικα· και του συσσωρευμένου γραπτού λόγου του ανθρώπινου πολιτισμού, που αφομοιώθηκε και συμπυκνώθηκε από μεγάλα γλωσσικά μοντέλα χωρίς γνώμη για τίποτα.

Τα σφάλματα είναι δικά μου. Οι διορατικότητες ήταν συλλογικές.

Επιβεβαιώνω ότι αυτή η εργασία δεν έχει υποβληθεί για κανένα άλλο πτυχίο ή επαγγελματικό προσόν, ακαδημαϊκό βραβείο, επιχορήγηση, θέση μόνιμου διδακτικού προσωπικού ή ανάρτηση στο LinkedIn, εκτός όπου άλλως δηλώνεται.

Επιπλέον, επιβεβαιώνω ότι δεν περιλαμβάνεται σε αυτή την εργασία ενότητα σύγκρισης αιχμής (State of the Art). Ο αναγνώστης δεν θα βρει πίνακα κατάταξης 47 μεθόδων σε 12 σύνολα δεδομένων αναφοράς, όπου η προτεινόμενη μέθοδος επιτυγχάνει στατιστικά σημαντικές βελτιώσεις σε 9 από αυτά (†p < 0,05). Αυτό δεν οφείλεται στο ότι ένας τέτοιος πίνακας δεν θα μπορούσε να κατασκευαστεί, αλλά στο ότι η κατασκευή του θα ήταν άσχετη με το θέμα.

Το θέμα είναι αυτό: ο άνθρωπος είναι στον βρόχο. Πάντα ήταν. Αυτό το βιβλίο προσπαθεί να κατανοήσει τι σημαίνει αυτό.

Υπογραφή: Ένας Άνθρωπος στον Βρόχο

Ημερομηνία: Όποτε το διαβάζετε αυτό

Ίδρυμα: Κανένα. Αυτό είναι το νόημα.

Σχετικά με τον υπότιτλο :class: note

Παρεξηγημένη αναφέρεται στο πεδίο, στον ρόλο του ανθρώπου μέσα σε αυτό, και στον αναγνώστη — ταυτόχρονα. Αν νομίζετε ότι αναφέρεται μόνο σε

εσάς, μπορεί να έχετε δίκιο. Αν νομίζετε ότι αναφέρεται μόνο στις μηχανές, αποδεικνύετε τον υπότιτλο.

Περίληψη

Ανθρωποκεντρική Μηχανική Μάθηση: Παρεξηγημένη

Η κυρίαρχη αφήγηση για τη μηχανική μάθηση τοποθετεί τον άνθρωπο ως προσωρινό συμμέτοχο — παρόντα κατά τη συλλογή δεδομένων και την εκπαίδευση μοντέλων, κατόπιν σταδιακά αντικατεστημένο καθώς η αυτοματοποίηση βελτιώνεται. Αυτό το εγχειρίδιο υποστηρίζει ότι αυτή η αφήγηση είναι λανθασμένη, υπήρξε πάντα λανθασμένη, και ότι η κατανόηση του *γιατί* είναι λανθασμένη αποτελεί ένα από τα πιο πρακτικά χρήσιμα πράγματα που μπορεί να κάνει ένας ασκούμενος μηχανικής μάθησης.

Η Ανθρωποκεντρική Μηχανική Μάθηση (ΑΚΜΜ) είναι ο κλάδος που καθιστά τη συμμετοχή του ανθρώπου στα συστήματα μάθησης σκόπιμη, δομημένη και συνεχή. Αντί να αντιμετωπίζει την ανθρώπινη ανατροφοδότηση ως κόστος που πρέπει να ελαχιστοποιηθεί, η ΑΚΜΜ τη θεωρεί ως σήμα που πρέπει να κατανοηθεί: από πού προέρχεται, τι κωδικοποιεί, πώς να συλλέγεται αποτελεσματικά και πώς να ενσωματώνεται πιστά σε μοντέλα που συμπεριφέρονται όπως ο σχεδιαστής και ο χρήστης πραγματικά προτίθενται.

Αυτό το εγχειρίδιο παρέχει ολοκληρωμένη κάλυψη του πεδίου σε έξι μέρη. Το Μέρος I θεμελιώνει τις έννοιες και μια ταξινόμηση της αλληλεπίδρασης ανθρώπου–μηχανής. Το Μέρος II καλύπτει τις κλασικές τεχνικές: σχολιασμό και επισήμανση δεδομένων, ενεργό μάθηση και διαδραστικό μηχανικό μάθηση. Το Μέρος III πραγματεύεται τα σύγχρονα πρότυπα ευθυγράμμισης: ενισχυτική μάθηση από ανθρώπινη ανατροφοδότηση (RLHF), μάθηση από επιδείξεις και μάθηση από προτιμήσεις. Το Μέρος IV εφαρμόζει αυτές τις τεχνικές στην επεξεργασία φυσικής γλώσσας, την υπολογιστική όραση και την υγειονομική περίθαλψη. Το Μέρος V καλύπτει τα συστήματα και τις υποδομές της ΑΚΜΜ σε κλίμακα: πλατφόρμες σχολιασμού, ποιοτικό έλεγχο πλήθους και μεθοδολογία αξιολόγησης. Το Μέρος VI εξετάζει την ηθική και το μέλλον του πεδίου.

Κάθε κεφάλαιο περιλαμβάνει τυπικούς ορισμούς, μαθηματική επεξεργασία όπου ενδείκνυται, και αυτόνομα εκτελέσιμα παραδείγματα κώδικα σε Python.

Το εγχειρίδιο απευθύνεται σε ασκούμενους που κατασκευάζουν συστήματα ΜΜ, σε ερευνητές που τα μελετούν, σε φοιτητές που μαθαίνουν γι' αυτά, και σε οποιονδήποτε αναρωτήθηκε ποτέ ποιος επισήμανε τα δεδομένα που εκπαίδευσαν το μοντέλο που έλαβε την απόφαση που επηρέασε τη ζωή του.

Η απάντηση, σε όλες τις περιπτώσεις, είναι: ένας άνθρωπος. Συχνά υποαμειβόμενος. Σπάνια αναγνωρισμένος. Πάντα στον βρόχο.

Λέξεις-κλειδιά: ανθρωποκεντρική μηχανική μάθηση, ενεργός μάθηση, σχολιασμός δεδομένων, ενισχυτική μάθηση από ανθρώπινη ανατροφοδότηση, RLHF, μάθηση από

προτιμήσεις, crowdsourcing, διαδραστικό μηχανικό μάθηση, ευθυγράμμιση ΤΝ, υπεύθυνη ΤΝ

Θεματική κατάταξη: Μηχανική Μάθηση · Αλληλεπίδραση Ανθρώπου–Υπολογιστή · Τεχνητή Νοημοσύνη · Επιστήμη Δεδομένων

Αριθμός λέξεων: Επαρκής.

Ευχαριστίες

Κάθε βιβλίο για την ανθρωποκεντρική μηχανική μάθηση οφείλει να ξεκινά με τους ανθρώπους στον δικό του βρόχο.

Οι σχολιαστές. Αυτό το εγχειρίδιο μιλά, εν μέρει, για εσάς — για την εργασία σας, την κρίση σας, και το γεγονός ότι το όνομά σας δεν εμφανίζεται σε κανένα δελτίο δεδομένων, εργασία ή δελτίο τύπου για τα μοντέλα που η δουλειά σας κατέστησε δυνατά. Το πεδίο αρχίζει να αντιμετωπίζει αυτό. Έχει δρόμο ακόμα.

Οι συντελεστές ανοιχτού κώδικα των οποίων οι βιβλιοθήκες χρησιμοποιούνται σε κάθε παράδειγμα κώδικα: η κοινότητα NumPy (από το 2006), οι συντελεστές του scikit-learn (από το 2007), η ομάδα PyTorch, η κοινότητα Hugging Face, και οι αναρίθμητοι συντηρητές που διορθώνουν σφάλματα τα σαββατοκύριακα χωρίς αποζημίωση ή αναγνώριση. Ο επιστημονικός υπολογισμός είναι χτισμένος πάνω σε αυτή την αόρατη εργασία.

Οι ερευνητές που δημοσίευσαν το έργο τους ανοιχτά — σε προεκτυπώσεις arXiv, σε περιοδικά ανοιχτής πρόσβασης και σε αποθετήρια GitHub — καθιστώντας δυνατό για τους ασκούμενους να μαθαίνουν χωρίς θεσμική πρόσβαση. Και οι ερευνητές που αξιολόγησαν εργασίες προσεκτικά και έντιμα — μια μορφή εξειδικευμένου σχολιασμού που η ακαδημία έχει κατορθώσει να μην αναγνωρίζει ως εργασία.

Οι δάσκαλοι που κατέστησαν τη γνώση προσβάσιμη: οι bloggers, οι συγγραφείς tutorials, οι χρήστες Stack Overflow που απαντούν, οι παρουσιαστές συνεδρίων που ανέβασαν τις διαφάνειές τους. Η μάθηση δεν συμβαίνει σε απομόνωση, και δεν συμβαίνει χωρίς ανθρώπους πρόθυμους να εξηγούν πράγματα σε αγνώστους.

Οι επικριτές. Οι ερευνητές που επεσήμαναν ότι τα σύνολα δεδομένων κωδικοποιούν προκαταλήψεις, ότι τα δημογραφικά χαρακτηριστικά των σχολιαστών διαμορφώνουν τη συμπεριφορά των μοντέλων, ότι οι άνθρωποι στον βρόχο είναι συχνά οι πιο ευάλωτοι συμμέτοχοι στο σύστημα. Αυτό το πεδίο είναι καλύτερο χάρη στην επιμονή σας να θέτετε ενοχλητικά ερωτήματα.

Υπάρχουν γνωστά γνωστά — τα πράγματα που γνωρίζουμε ότι γνωρίζουμε. Υπάρχουν γνωστά άγνωστα — τα πράγματα που γνωρίζουμε ότι δεν γνωρίζουμε. Υπάρχουν άγνωστα άγνωστα — τα πράγματα που δεν γνωρίζουμε ότι δεν γνωρίζουμε.

Και μετά υπάρχουν τα πράγματα που όλοι στο πεδίο γνωρίζουν αλλά που ποτέ δεν καταφέρνουν να μπουν στα άρθρα.

Αυτό το εγχειρίδιο είναι, εν μέρει, μια απόπειρα για την τελευταία κατηγορία.

Αν συνέβαλες σε αυτό το πεδίο και δεν βλέπεις το όνομά σου εδώ: αναγνωρίζεσαι. Ο βρόχος σε περιλαμβάνει.

Τι Είναι η Ανθρωποκεντρική ΜΜ;

Μια μηχανή που μπορεί να μαθαίνει από την εμπειρία… αλλά μόνο αν της δώσεις τις σωστές εμπειρίες. – παράφραση Alan Turing

Το Παράδοξο της Αυτοματοποίησης

Κάθε νέο κύμα αυτοματοποίησης δημιουργεί νέες απαιτήσεις για ανθρώπινη προσοχή. Όταν οι αεροπορικές εταιρείες εισήγαγαν τον αυτόματο πιλότο, οι πιλότοι έγιναν παρατηρητές — υπεύθυνοι όχι για τον έλεγχο από στιγμή σε στιγμή, αλλά για το πολύ δυσκολότερο έργο να γνωρίζουν *πότε* να αναλάβουν. Όταν τα σούπερ μάρκετ εισήγαγαν τους αυτόματους ταμία, ανακάλυψαν ότι τα συστήματα απαιτούν περισσότερη ανθρώπινη εποπτεία ανά συναλλαγή από τους παραδοσιακούς ταμίες, όχι λιγότερη. Και όταν η μηχανική μάθηση άρχισε να λαμβάνει αποφάσεις σε μεγάλη κλίμακα — στην ιατρική, τα οικονομικά, την πρόσληψη και τον έλεγχο περιεχομένου — δημιούργησε μια τεράστια, συνεχή ζήτηση για ανθρώπινη κρίση.

Αυτό είναι το **παράδοξο της αυτοματοποίησης** {cite}`bainbridge1983ironies`: όσο πιο ικανό γίνεται ένα αυτοματοποιημένο σύστημα, τόσο πιο σοβαρές είναι οι αποτυχίες του, και επομένως τόσο πιο αναγκαία γίνεται η ισχυρή ανθρώπινη εποπτεία. Η μηχανική μάθηση δεν αποτελεί εξαίρεση.

Η Ανθρωποκεντρική Μηχανική Μάθηση (HITL ML) είναι ο κλάδος που αντιμετωπίζει αυτό το παράδοξο σοβαρά και το ενσωματώνει στον σχεδιασμό συστημάτων από την αρχή. Αντί να αντιμετωπίζει την ανθρώπινη εμπλοκή ως προσωρινό σκαλωσιά που πρόκειται τελικά να αφαιρεθεί, η HITL ML αντιμετωπίζει την αλληλεπίδραση ανθρώπου–μηχανής ως *χαρακτηριστικό* — μια πηγή σήματος, διόρθωσης και καθοδήγησης που μπορεί να κάνει τα μοντέλα πιο ακριβή, πιο ευθυγραμμισμένα με τις ανθρώπινες αξίες και πιο αξιόπιστα.

Ορισμός της Ανθρωποκεντρικής ΜΜ

Δεν υπάρχει ενιαίος αποδεκτός ορισμός της HITL ML, και ο όρος χρησιμοποιείται με αρκετούς επικαλυπτόμενους τρόπους στη βιβλιογραφία. Για το παρόν εγχειρίδιο υιοθετούμε έναν ευρύ αλλά ακριβή ορισμό:

:::{admonition} Ορισμός :class: important

Ανθρωποκεντρική Μηχανική Μάθηση αναφέρεται σε οποιοδήποτε σύστημα ή μεθοδολογία ΜΜ στο οποίο η ανθρώπινη ανατροφοδότηση ενσωματώνεται στη διαδικασία μάθησης με *σκόπιμο, δομημένο και συνεχή* τρόπο — όχι μόνο κατά τη

δημιουργία του συνόλου δεδομένων, αλλά καθ' όλη τη διάρκεια της εκπαίδευσης, της αξιολόγησης και της ανάπτυξης.

:::

Αυτός ο ορισμός έχει τρεις βασικές ρήτρες:

Σκόπιμος. Το HITL δεν αποτελεί τυχαία ανθρώπινη επιρροή (π.χ. το γεγονός ότι τα δεδομένα εκπαίδευσης δημιουργήθηκαν αρχικά από ανθρώπους). Αναφέρεται σε συστήματα που σχεδιάστηκαν ρητά για να ζητούν, να ενσωματώνουν και να επωφελούνται από την ανθρώπινη ανατροφοδότηση.

Δομημένος. Η ανατροφοδότηση έχει ορισμένη μορφή — μια ετικέτα, μια διόρθωση, μια κρίση προτίμησης, μια επίδειξη — και έναν ορισμένο ρόλο στον αλγόριθμο μάθησης.

Συνεχής. Ο βρόχος ανατροφοδότησης συνεχίζεται με την πάροδο του χρόνου, επιτρέποντας στο σύστημα να βελτιώνεται καθώς αντιμετωπίζει νέες καταστάσεις, κάνει λάθη και λαμβάνει ανθρώπινη καθοδήγηση.

Αυτός ο ορισμός περιλαμβάνει τις κλασικές αγωγούς σχολιασμού, την ενεργό μάθηση, τη διαδραστική ΜΜ, το RLHF και τη μάθηση από επιδείξεις. Εξαιρεί την παθητική συλλογή δεδομένων και την αμιγώς εκτός σύνδεσης εποπτευόμενη μάθηση (αν και η γραμμή είναι θολή, όπως θα συζητήσουμε στο Κεφάλαιο 2).

Μια Σύντομη Ιστορία

Έμπειρα Συστήματα και Μηχανική Γνώσης (1960–1980)

Τα πρώτα συστήματα ΤΝ ήταν σχεδόν εξ ολοκλήρου ανθρωποκεντρικά: μηχανικοί γνώσης συνεργάζονταν με ειδικούς του τομέα για μήνες, κωδικοποιώντας με μόχθο κανόνες σε έμπειρα συστήματα όπως το MYCIN και το DENDRAL. Κάθε κομμάτι γνώσης παρεχόταν ρητά από έναν άνθρωπο. Η μηχανή ήταν ο εκτελεστής· ο άνθρωπος ήταν το μαντείο.

Αυτά τα συστήματα λειτουργούσαν εκπληκτικά καλά σε στενούς τομείς, αλλά ήταν εύθραυστα — ανίκανα να γενικεύσουν πέρα από τους χειροποίητους κανόνες τους και ακριβά στη συντήρηση.

Η Στατιστική Στροφή (1980–2000)

Η στροφή στη στατιστική μηχανική μάθηση τις δεκαετίες του 1980 και 1990 άλλαξε τη φύση της ανθρώπινης εμπλοκής. Αντί να κωδικοποιεί γνώση ως κανόνες, οι άνθρωποι παρείχαν πλέον *παραδείγματα* — σύνολα δεδομένων με ετικέτες που επέτρεπαν στα μοντέλα να συνάγουν μοτίβα. Ο ρόλος του ανθρώπου έγινε αυτός του σχολιαστή: επισήμανση εγγράφων, ετικετοποίηση εικόνων, μεταγραφή ομιλίας.

Αυτό ήταν ένα σημαντικό βήμα προόδου, αλλά δημιούργησε ένα νέο εμπόδιο: **τα δεδομένα με ετικέτες είναι ακριβά**. Οι ερευνητές άρχισαν να αναρωτιούνται πώς να αξιοποιήσουν όσο το δυνατόν πιο αποτελεσματικά την ανθρώπινη προσπάθεια επισήμανσης. Αυτό το ερώτημα γέννησε την **ενεργό μάθηση**, που τυποποιήθηκε πρώτα στις αρχές της δεκαετίας του 1990 {cite}`cohn1994improving`.

Η Εποχή της Βαθιάς Μάθησης (2010 — σήμερα)

Η επανάσταση της βαθιάς μάθησης δημιούργησε ένα νέο καθεστώς: μοντέλα με δισεκατομμύρια παραμέτρους που μπορούν να μαθαίνουν εξαιρετικά σύνθετες συναρτήσεις από δεδομένα — αλλά απαιτούν αντιστοίχως τεράστια σύνολα δεδομένων με ετικέτες. Το ImageNet (14 εκατομμύρια εικόνες με ετικέτες) και τα επόμενα μεγάλης κλίμακας έργα σχολιασμού έδειξαν τόσο τη δύναμη όσο και το κόστος της κλίμακας.

Ταυτόχρονα, η ανάπτυξη ΜΜ σε μεγάλη κλίμακα αποκάλυψε νέα προβλήματα: μοντέλα που ήταν κατά μέσο όρο ακριβή αλλά συστηματικά λανθασμένα για συγκεκριμένες ομάδες, που εφηύρισκαν γεγονότα με αυτοπεποίθηση, που βελτιστοποιούσαν μετρήσιμες προσεγγίσεις αντί για ανθρώπινες αξίες. Αυτές οι αποτυχίες παρακίνησαν νέες μορφές ανθρώπινης εμπλοκής: όχι μόνο επισήμανση, αλλά *ευθυγράμμιση* — το εγχείρημα να κάνουμε τα μοντέλα να συμπεριφέρονται με τον τρόπο που οι άνθρωποι πραγματικά θέλουν.

Η πιο σαφής έκφραση αυτής της εργασίας HITL με επίκεντρο την ευθυγράμμιση είναι η **Ενισχυτική Μάθηση από Ανθρώπινη Ανατροφοδότηση (RLHF)** {cite}`christiano2017deep`, που έγινε η ραχοκοκαλιά συστημάτων όπως το InstructGPT {cite}`ouyang2022training` και οι δυνατότητες ακολούθησης οδηγιών των σύγχρονων γλωσσικών μοντέλων.

Γιατί HITL; Η Υπεράσπιση της Ανθρώπινης Κρίσης

Ποιες ιδιότητες κάνουν την ανθρώπινη κρίση αρκετά πολύτιμη ώστε να ενσωματωθεί σε συστήματα μηχανικής μάθησης;

1. Κοινή Λογική και Κοσμογνωσία

Οι άνθρωποι φέρνουν στη δουλειά τους εκτεταμένη υπόβαθρο γνώση. Όταν μια ακτινολόγος επισημαίνει μια ακτινογραφία, αξιοποιεί χρόνια εκπαίδευσης, κατανόηση της ανατομίας και σιωπηρή γνώση για το πώς φαίνονται οι ασθένειες — γνώση που είναι εξαιρετικά δύσκολο να προσδιοριστεί πλήρως ή να αποκτηθεί αποκλειστικά από δεδομένα.

2. Σημασιολογική Θεμελίωση

Οι ετικέτες είναι σημαντικές επειδή οι άνθρωποι κατανοούν τι σημαίνουν. Η κλάση «γάτα» στο ImageNet αναφέρεται σε μια ασαφή έννοια που οι άνθρωποι αναγνωρίζουν διαισθητικά, αλλά την οποία κανένας επίσημος ορισμός δεν αποτυπώνει πλήρως. Τα μοντέλα μαθαίνουν την έκταση της ετικέτας (ποιες εικόνες αντιστοιχούν σε αυτήν) αλλά μπορεί να μην μαθαίνουν την ίδια την έννοια, οδηγώντας σε αποτυχίες σε οριακές περιπτώσεις που οποιοσδήποτε άνθρωπος θα χειριζόταν σωστά.

3. Ευθυγράμμιση Αξιών

Οι άνθρωποι έχουν προτιμήσεις, αξίες και ηθικές κρίσεις που τα μοντέλα ΜΜ δεν μπορούν να εξαγάγουν μόνο από δεδομένα. Το αν ένα κείμενο είναι «χρήσιμο» ή «βλαβερό» δεν είναι καθαρά εμπειρικό ζήτημα — εξαρτάται από ανθρώπινες αξίες που ποικίλλουν μεταξύ ατόμων και πλαισίων. Το HITL είναι ο πρωταρχικός μηχανισμός μέσω του οποίου αυτές οι αξίες μπορούν να μεταδοθούν σε συστήματα ΜΜ.

4. Προσαρμοστικότητα

Η ανθρώπινη κρίση μπορεί να προσαρμοστεί σε νέες καταστάσεις χωρίς επανεκπαίδευση. Ένα μοντέλο εκπαιδευμένο σε ιστορικά δεδομένα μπορεί να αποτύχει καταστροφικά όταν αλλάξει ο κόσμος· ένας άνθρωπος μπορεί να αναγνωρίσει τη νεότητα και να αντιδράσει κατάλληλα.

5. Λογοδοσία

Σε τομείς υψηλού κινδύνου — ιατρική, νομική, χρηματοοικονομική — οι αποφάσεις πρέπει να λογοδοτούν σε ανθρώπους. Τα συστήματα HITL καθιστούν αυτή τη λογοδοσία εφικτή, διατηρώντας τους ανθρώπους σε θέση να κατανοούν, να επαληθεύουν και να παρακάμπτουν τη συμπεριφορά της μηχανής.

Ο Βρόχος Ανατροφοδότησης

Η κεντρική δομή της HITL ML είναι ένας βρόχος ανατροφοδότησης μεταξύ ενός μοντέλου και ενός ή περισσότερων ανθρώπων:

```
+-----------------------------------------------+
|                                               |
|   Το μοντέλο κάνει προβλέψεις / αιτήματα    |
|   ----------------------------------->        |
|                                   Άνθρωπος   |
|   Ο άνθρωπος παρέχει ανατροφοδότηση <----- |
|   -----------------------------------         |
|                                               |
|   Το μοντέλο ενημερώνεται                   |
|                                               |
+-----------------------------------------------+
```

Η φύση της ανατροφοδότησης ποικίλλει σημαντικά μεταξύ των παραδειγμάτων HITL:

Τύπος ανατροφοδότησης	Παράδειγμα	Κύριο παράδειγμα
Ετικέτα κλάσης	«Αυτό το email είναι ανεπιθύμητο»	Εποπτευόμενη μάθηση
Διόρθωση	«Η οντότητα πρέπει να είναι ORG, όχι PER»	Ενεργός / διαδραστική ΜΜ
Προτίμηση	«Η απάντηση Α είναι καλύτερη από την Β»	RLHF / κατάταξη
Επίδειξη	Δείχνω στο ρομπότ πώς να πιάσει ένα αντικείμενο	Μάθηση από επιδείξεις
Φυσική γλώσσα	«Να είσαι πιο συνοπτικός στις απαντήσεις σου»	Ρύθμιση οδηγιών
Σιωπηρό σήμα	Ο χρήστης έκανε κλικ / δεν έκανε κλικ	Σιωπηρή ανατροφοδότηση

Τι Δεν Είναι το HITL

Αξίζει να είμαστε ακριβείς σχετικά με το τι εξαιρείται *από* τον ορισμό μας.

Το HITL δεν είναι το ίδιο με την ανθρωποκεντρική ανάπτυξη (γνωστή ορισμένες φορές ως «human on the loop»), όπου οι άνθρωποι παρακολουθούν αυτοματοποιημένες αποφάσεις και μπορούν να τις παρακάμψουν, αλλά δεν επιστρέφουν διορθώσεις στην εκπαίδευση. Θα συζητήσουμε αυτή τη διάκριση στο Κεφάλαιο 2.

Το HITL δεν είναι μόνο αδύναμη εποπτεία. Συστήματα προγραμματικής επισήμανσης όπως το Snorkel χρησιμοποιούν συναρτήσεις επισήμανσης (συχνά κανόνες γραμμένους από ανθρώπους) για να δημιουργήσουν θορυβώδεις ετικέτες σε μεγάλη κλίμακα. Αυτή είναι μια μορφή δομημένης ανθρώπινης εισόδου, αλλά η ανατροφοδότηση δεν είναι επαναληπτική με τον τρόπο που το HITL συνήθως υπονοεί.

Το HITL δεν σημαίνει απλώς χρήση δεδομένων με ετικέτες. Κάθε μοντέλο εποπτευόμενης μάθησης χρησιμοποιεί δεδομένα με ετικέτες από ανθρώπους. Το HITL αναφέρεται ειδικά σε συστήματα όπου η ανθρώπινη ανατροφοδότηση αποτελεί *ενεργό, επαναληπτικό* μέρος της διαδικασίας μάθησης.

Τα Οικονομικά της Ανθρώπινης Ανατροφοδότησης

Η ανθρώπινη ανατροφοδότηση είναι πολύτιμη αλλά δαπανηρή. Ο σχολιασμός ιατρικών εικόνων μπορεί να κοστίζει από δεκάδες έως εκατοντάδες δολάρια ανά εικόνα όταν εκτελείται από ειδικό, ανάλογα με την υποειδικότητα και την πολυπλοκότητα του έργου {cite}`monarch2021human`. Οι ετικέτες εργατών πλήθους σε πλατφόρμες όπως το Amazon Mechanical Turk μπορούν να κοστίσουν $0,01–$0,10 ανά στοιχείο {cite}`hara2018data` σε πολύ χαμηλότερη ποιότητα. Η θεμελιώδης πρόκληση της HITL ML είναι η **μεγιστοποίηση της αξίας κάθε μονάδας ανθρώπινης ανατροφοδότησης**.

Αυτό οδηγεί σε ένα ενοποιητικό ερώτημα που διατρέχει το μεγαλύτερο μέρος αυτού του εγχειριδίου:

:::{admonition} Το Κεντρικό Ερώτημα της HITL ML :class: tip

Δεδομένου ενός σταθερού προϋπολογισμού ανθρώπινου χρόνου και προσοχής, πώς πρέπει να αποφασίζουμε τι να ρωτάμε τους ανθρώπους, πότε να ρωτάμε και πώς να ενσωματώνουμε τις απαντήσεις τους στην εκπαίδευση μοντέλων;

:::

Η απάντηση σε αυτό το ερώτημα εξαρτάται από τον τομέα, τη μορφή της ανατροφοδότησης, το κόστος σχολιασμού, τον κίνδυνο σφάλματος και την τρέχουσα κατάσταση του μοντέλου — γι' αυτό η HITL ML είναι ένας πλούσιος και συνεχώς εξελισσόμενος κλάδος.

Επισκόπηση του Εγχειριδίου

Το υπόλοιπο αυτού του εγχειριδίου είναι δομημένο ως εξής. Το **Μέρος ΙΙ** καλύπτει τους τρεις κλασικούς πυλώνες του HITL: σχολιασμό, ενεργό μάθηση και διαδραστική ΜΜ. Το **Μέρος ΙΙΙ** αντιμετωπίζει τα νεότερα παραδείγματα μάθησης από ανατροφοδότηση — RLHF, μάθηση από επιδείξεις και μάθηση από προτιμήσεις — που έχουν γίνει κεντρικά στη σύγχρονη ΤΝ. Το **Μέρος IV** εξετάζει το HITL μέσα από το πρίσμα συγκεκριμένων τομέων

εφαρμογής. Το **Μέρος V** υιοθετεί την οπτική του εφαρμοστή σχετικά με πλατφόρμες, crowdsourcing και αξιολόγηση. Το **Μέρος VI** αντιμετωπίζει θέματα ηθικής και κοιτάζει μπροστά.

> **See also:** Για μια πρακτικά προσανατολισμένη επισκόπηση του κλάδου, βλ. {cite}`monarch2021human`. Για το θεμελιώδες άρθρο ενεργούς μάθησης που εκκίνησε μεγάλο μέρος της επίσημης αντιμετώπισης του HITL, βλ. {cite}`settles2009active`.

Ταξινόμηση Αλληλεπίδρασης Ανθρώπου–Μηχανής

Ένα ακριβές λεξιλόγιο είναι η προϋπόθεση για σαφή σκέψη. Ο όρος «άνθρωπος στον βρόχο» (human-in-the-loop) χρησιμοποιείται χαλαρά στην πράξη — μερικές φορές για να υποδηλώσει ότι ένας άνθρωπος επισημαίνει δεδομένα εκπαίδευσης, μερικές φορές ότι ένας άνθρωπος μπορεί να παρακάμψει την απόφαση ενός μοντέλου, και μερικές φορές ότι ένας άνθρωπος κατευθύνει ενεργά τη διαδικασία μάθησης σε πραγματικό χρόνο. Αυτά είναι ουσιαστικά διαφορετικά πράγματα.

Αυτό το κεφάλαιο χαρτογραφεί το τοπίο της αλληλεπίδρασης ανθρώπου–μηχανής στη ΜΜ, παρέχοντας το εννοιολογικό λεξιλόγιο που χρησιμοποιείται σε όλο το υπόλοιπο εγχειρίδιο.

Επίπεδα Αυτοματοποίησης

Η πιο θεμελιώδης διάκριση είναι πόσο ενεργά εμπλέκεται ο άνθρωπος στη λήψη αποφάσεων του συστήματος. Ένα γνωστό πλαίσιο από τη θεωρία αυτοματοποίησης {cite}`sheridan1992telerobotics` διακρίνει δέκα επίπεδα, αλλά για σκοπούς ΜΜ τρεις κατηγορίες αποτυπώνουν τις σημαντικές διακυμάνσεις:

Άνθρωπος στον Βρόχο (HITL)

Ο άνθρωπος είναι *ενεργός συμμετέχων στη διαδικασία μάθησης*. Οι αποφάσεις — ή τουλάχιστον οι σημαντικές αποφάσεις — απαιτούν ανθρώπινη συμβολή πριν οριστικοποιηθούν. Το σύστημα δεν μπορεί να λειτουργήσει χωρίς συνεχή ανθρώπινη εμπλοκή.

Παραδείγματα: Ένα σύστημα ενεργούς μάθησης που διαβουλεύεται με κλινικό ιατρό πριν προσθέσει μια περίπτωση στα δεδομένα εκπαίδευσης. Ένας σχολιαστής δεδομένων που επισημαίνει παραδείγματα που χρησιμοποιούνται αμέσως για ενημέρωση μοντέλων. Ένας σχολιαστής RLHF που συγκρίνει εξόδους μοντέλου.

Άνθρωπος πάνω από τον Βρόχο (HOTL)

Το σύστημα λειτουργεί αυτόνομα, αλλά ένας άνθρωπος το παρακολουθεί και μπορεί να παρέμβει. Ο άνθρωπος είναι *επόπτης*, όχι συμμετέχων. Η ανατροφοδότηση μπορεί ή δεν μπορεί να επιστρέφει στην εκπαίδευση.

Παραδείγματα: Ένα σύστημα συντονισμού περιεχομένου που επισημαίνει αναρτήσεις αυτόματα· ένας ανθρώπινος κριτής δειγματοληπτεί και διορθώνει ένα κλάσμα των

αποφάσεων. Ένας αυτόματος πιλότος που πετά το αεροπλάνο αλλά ειδοποιεί τον πιλότο για ανωμαλίες.

Άνθρωπος σε Διοίκηση (HIC)

Ο άνθρωπος λαμβάνει όλες τις αποφάσεις· το σύστημα παρέχει *συστάσεις ή πληροφορίες* αλλά δεν έχει αυτονομία. Αυτή είναι η ασθενέστερη μορφή ανάπτυξης ΜΜ.

Παραδείγματα: Ένα σύστημα υποστήριξης διάγνωσης που δείχνει στον γιατρό την εκτίμηση πιθανότητας του μοντέλου αλλά αφήνει την τελική απόφαση εξ ολοκλήρου στον ιατρό.

> **Ποιο επίπεδο είναι κατάλληλο;** :class: tip
>
> Το κατάλληλο επίπεδο αυτοματοποίησης εξαρτάται από το κόστος των σφαλμάτων, την αξιοπιστία του μοντέλου, την εμπειρογνωμοσύνη των διαθέσιμων ανθρώπων και τους χρονικούς περιορισμούς του έργου. Αυτοί οι παράγοντες αλλάζουν καθώς ωριμάζει ένα μοντέλο — τα περισσότερα συστήματα ξεκινούν ως HITL και μεταβαίνουν προς HOTL καθώς αυξάνεται η εμπιστοσύνη.

```
Ακατέργαστα δεδομένα --> Προεπεξεργασία --> Χαρακτηριστικά --> Εκπαίδευση --> Αξιολόγηση -->
    ^                        ^                                    ^                ^
    |                        |                                    |                |
 Συλλογή              Σχολιασμός                            Ενεργός          Έλεγχος      Παρ
 ανατροφ.             & επισήμανση                          μάθηση           ανατροφ.     & δ
```

Στάδιο	Ρόλος ανθρώπου	Κεφάλαιο
Συλλογή	Απόφαση για ποια δεδομένα να συλλεχθούν· στρατηγική δειγμ.	3, 4
Σχολιασμός	Ανάθεση ετικετών, δομών, μεταδεδομένων	3, 13
Εκπαίδευση	Ερωτήματα ενεργούς μάθησης· ανατροφοδότηση σε πραγ. χρόνο	4, 5, 6
Αξιολόγηση	Ανθρώπινη αξιολόγηση εξόδων μοντέλου	14
Ανάπτυξη	Παρακολούθηση, χειρισμός εξαιρέσεων, διορθώσεις	12, 14

Ενεργός vs. Παθητική Ανθρώπινη Εμπλοκή

Στην *ενεργή* HITL, το σύστημα επιλέγει ποια σημεία δεδομένων να παρουσιάσει στον άνθρωπο — κάνοντας στρατηγικές ερωτήσεις. Στην *παθητική* HITL, ο άνθρωπος παρέχει ανατροφοδότηση για ό,τι δεδομένα τυχαία φτάνουν (π.χ. παρτίδες σχολιασμού που ανατίθενται διαδοχικά).

Η ενεργή εμπλοκή είναι πιο αποτελεσματική διότι η ανατροφοδότηση κατευθύνεται εκεί όπου θα βελτιώσει περισσότερο το μοντέλο. Η παθητική εμπλοκή είναι απλούστερη στην υλοποίηση και διαχείριση.

Μια σχετική διάκριση είναι μεταξύ **παρτίδας** και **διαδικτυακής** ανατροφοδότησης:

- **Παρτίδα:** Οι άνθρωποι επισημαίνουν ένα μεγάλο σύνολο παραδειγμάτων· το μοντέλο επανεκπαιδεύεται. Επαναλαμβάνεται.

- **Διαδικτυακή (ροή):** Η ανθρώπινη ανατροφοδότηση φτάνει συνεχώς· το μοντέλο ενημερώνεται σταδιακά.

Οι ροές εργασίας παρτίδας είναι ο κανόνας στη βιομηχανία (έργα σχολιασμού ακολουθούμενα από εκτελέσεις εκπαίδευσης). Οι διαδικτυακές ροές εργασίας είναι πιο φυσικές για διαδραστικά συστήματα και περιβάλλοντα ενισχυτικής μάθησης.

Μεμονωμένος vs. Πολλαπλοί Σχολιαστές

Οι περισσότερες επίσημες παρουσιάσεις του HITL υποθέτουν έναν μεμονωμένο, συνεπή σχολιαστή. Στην πράξη, ο σχολιασμός εμπλέκει πολλούς ανθρώπους, και οι κρίσεις τους διαφέρουν.

Συνάθροιση συνδυάζει πολλαπλούς σχολιασμούς σε μία ετικέτα, συνήθως με πλειοψηφική ψηφοφορία ή στατιστικό μοντέλο (Κεφάλαιο 13).

Η διαφωνία ως σήμα — ορισμένοι ερευνητές υποστηρίζουν ότι η διαφωνία μεταξύ σχολιαστών είναι πολύτιμη πληροφορία που δεν πρέπει να καταρρέει σε μία «χρυσή» ετικέτα. Οι προσεγγίσεις περσπεκτιβισμού στην Επεξεργασία Φυσικής Γλώσσας, για παράδειγμα, διατηρούν πολλαπλούς σχολιασμούς ως ήπιες ετικέτες που αντικατοπτρίζουν την πραγματική ασάφεια των δεδομένων {cite}`uma2021learning`.

Ένα Ενοποιημένο Πλαίσιο

Μπορούμε να αναπαραστήσουμε οποιαδήποτε διαμόρφωση HITL με μια πενταδική κατανομή:

$$\text{Διαμόρφωση HITL} = (\text{επίπεδο}, \text{τρόπος}, \text{στάδιο}, \text{συχνότητα}, \text{σχολιαστές})$$

όπου:

- **επίπεδο** $\in$ {HITL, HOTL, HIC}
- **τρόπος** $\in$ {ετικέτα, διόρθωση, επίδειξη, προτίμηση, ΦΓ, σιωπηρό}
- **στάδιο** $\in$ {συλλογή, σχολιασμός, εκπαίδευση, αξιολόγηση, ανάπτυξη}
- **συχνότητα** $\in$ {παρτίδα, διαδικτυακή}
- **σχολιαστές** $\in \mathbb{N}^+$ (αριθμός σχολιαστών ανά στοιχείο)

Αυτή η ταξινόμηση μας επιτρέπει να συγκρίνουμε διαφορετικά συστήματα HITL στους ίδιους άξονες και να συλλογιζόμαστε για τις ανταλλαγές μεταξύ τους. Το υπόλοιπο εγχειρίδιο εξετάζει λεπτομερώς συγκεκριμένα κελιά αυτού του χώρου.

> **See also:** Για εμπειρική μελέτη του πώς οι αποφάσεις σχολιασμού επηρεάζουν τη συμπεριφορά μοντέλων κατάντη, βλ. {cite}`bender2021stochastic`. Για έρευνα διαδραστικών συστημάτων ΜΜ, βλ. {cite}`amershi2014power`.

Σχολιασμός Δεδομένων και Επισήμανση

Ο σχολιασμός δεδομένων είναι η πιο διαδεδομένη μορφή ανθρώπινης εμπλοκής στη ΜΜ. Προτού ένα μοντέλο μπορέσει να μάθει, κάποιος πρέπει να του πει ποιες είναι οι σωστές απαντήσεις — και αυτός ο κάποιος είναι συνήθως άνθρωπος. Αυτό το κεφάλαιο καλύπτει τη θεωρία και την πρακτική του σχολιασμού: τι κάνει τον σχολιασμό δύσκολο, πώς να σχεδιάζουμε έργα σχολιασμού, πώς να μετράμε την ποιότητα και πώς να χειριζόμαστε τις διαφωνίες.

Τύποι Σχολιασμού

Τα έργα σχολιασμού ποικίλλουν σημαντικά ως προς τη δομή, τη δυσκολία και το κόστος. Οι κύριοι τύποι περιλαμβάνουν:

Ταξινόμηση

Ο σχολιαστής αναθέτει κάθε στιγμιότυπο σε μία από K προκαθορισμένες κατηγορίες. Αυτό είναι το απλούστερο γνωστικά έργο σχολιασμού, αλλά ο ορισμός καλού σχήματος κατηγοριών (μιας *ταξινομίας*) μπορεί να αποδειχθεί εκπληκτικά δύσκολος.

Δυαδική ταξινόμηση (είναι αυτή η εικόνα γάτα;) είναι η απλούστερη περίπτωση. **Πολυκλαδική** (ποιο είδος είναι αυτό το ζώο;) απαιτεί από τους σχολιαστές να επιλέξουν μία επιλογή από μια λίστα. **Πολυετικέτα** σχολιασμός (ποια θέματα καλύπτει αυτό το άρθρο;) επιτρέπει πολλαπλές ταυτόχρονες ετικέτες.

Επισήμανση Ακολουθίας

Κάθε τεκμήριο σε μια ακολουθία λαμβάνει μια ετικέτα. Η Αναγνώριση Ονομαστικών Οντοτήτων (NER) είναι το κανονικό παράδειγμα — οι σχολιαστές σημειώνουν εκτάσεις κειμένου ως PERSON, ORGANIZATION, LOCATION κ.λπ. Ο σχολιασμός εκτελείται συνήθως χρησιμοποιώντας το σχήμα ετικέτας BIO (Beginning-Inside-Outside) ή BIOES:

```
B-ORG    O          B-ORG    O    O    O
```

Σχολιασμός Εκτάσεων και Σχέσεων

Πέρα από την επισήμανση μεμονωμένων τεκμηρίων, οι σχολιαστές μπορεί να χρειαστεί να: - Εντοπίσουν εκτάσεις (πολυτεκμηριακές εκφράσεις) και να αναθέσουν τύπους - Σημειώσουν *σχέσεις* μεταξύ εκτάσεων («Apple» ACQUIRED «Shazam») - Σχολιάσουν αλυσίδες αναφοράς (όλες οι αναφορές στην ίδια οντότητα)

Αυτά τα έργα είναι γνωστικά απαιτητικά και έχουν χαμηλότερη συμφωνία μεταξύ σχολιαστών.

Οριοθετικά Πλαίσια και Ανίχνευση Αντικειμένων

Οι σχολιαστές σχεδιάζουν ορθογώνια γύρω από αντικείμενα σε εικόνες και αναθέτουν ετικέτα κατηγορίας σε κάθε πλαίσιο. Η ακρίβεια εντοπισμού έχει σημασία: ένα πλαίσιο που είναι πολύ μικρό χάνει το πλαίσιο· ένα πλαίσιο που είναι πολύ μεγάλο περιλαμβάνει το φόντο. Τα σύγχρονα εργαλεία σχολιασμού υπολογίζουν την τομή-πάνω-από-ένωση (IoU) με σχολιασμούς αναφοράς για να επισημαίνουν ζητήματα ποιότητας.

Τμηματοποίηση

Σχολιασμός σε επίπεδο εικονοστοιχείου: κάθε εικονοστοιχείο ανατίθεται σε μια κλάση (σημασιολογική τμηματοποίηση) ή σε ένα συγκεκριμένο αντικείμενο-στιγμιότυπο (τμηματοποίηση στιγμιοτύπου). Η τμηματοποίηση υψηλής ποιότητας είναι από τους πιο ακριβούς τύπους σχολιασμού, με κόστος που κυμαίνεται από δεκάδες έως πάνω από εκατό δολάρια ανά εικόνα για σύνθετες σκηνές ανάλογα με τον τομέα και την υποστήριξη εργαλείων.

Μεταγραφή και Μετάφραση

Ήχος κείμενο (δεδομένα εκπαίδευσης ASR), χειρόγραφο κείμενο (δεδομένα OCR), ή γλώσσα πηγής γλώσσα στόχος (δεδομένα MT). Αυτά τα έργα απαιτούν γλωσσική εμπειρογνωμοσύνη και δεν μπορούν να εκτελεστούν αξιόπιστα από αναπαίδευτους σχολιαστές.

Οδηγίες Σχολιασμού

Ο μεμονωμένος πιο σημαντικός καθοριστικός παράγοντας ποιότητας σχολιασμού είναι η ποιότητα των **οδηγιών σχολιασμού**: των γραπτών οδηγιών που ακολουθούν οι σχολιαστές.

Καλές οδηγίες: - Δηλώνουν τον στόχο του έργου και εξηγούν *γιατί* έχει σημασία η ετικέτα - Παρέχουν σαφή ορισμό για κάθε κατηγορία με θετικά και αρνητικά παραδείγματα - Αντιμετωπίζουν ρητά συνηθισμένες οριακές περιπτώσεις και δύσκολες περιπτώσεις - Προσδιορίζουν τι να κάνουν όταν υπάρχει αβεβαιότητα (π.χ. σημείωση «παράλειψη» έναντι αναγκαστικής επιλογής) - Περιλαμβάνουν λυμένα παραδείγματα πλήρους σχολιασμού

Οι κακές οδηγίες βασίζονται στους σχολιαστές να «χρησιμοποιούν την κοινή λογική» για οριακές περιπτώσεις — γεγονός που οδηγεί σε ασυνεπείς αποφάσεις που υποβαθμίζουν την ποιότητα μοντέλου και αυξάνουν τη διαφωνία μεταξύ σχολιαστών.

> **Η ανάπτυξη οδηγιών είναι επαναληπτική** :class: note
>
> Μην περιμένετε να γράψετε τέλειες οδηγίες εξ αρχής. Εκτελέστε έναν μικρό πιλοτικό κύκλο σχολιασμού, αναλύστε τις διαφωνίες και ενημερώστε τις οδηγίες. Επαναλάβετε. Οι καλά ανεπτυγμένες οδηγίες συνήθως περνούν από 3–5 κύκλους αναθεώρησης πριν σταθεροποιηθούν.

Μέτρηση Ποιότητας Σχολιασμού: Συμφωνία Μεταξύ Σχολιαστών

Όταν πολλαπλοί σχολιαστές επισημαίνουν τα ίδια δεδομένα, η συμφωνία τους μπορεί να μετρηθεί. Υψηλή συμφωνία υποδηλώνει ότι το έργο είναι καλά ορισμένο και ότι οι σχολιαστές το κατανόησαν. Χαμηλή συμφωνία υποδηλώνει ασάφεια στο έργο, τις οδηγίες ή τα δεδομένα.

Κάππα του Cohen

Για δύο σχολιαστές που επισημαίνουν δεδομένα σε K κατηγορίες, το **κάππα του Cohen** {cite}`cohen1960coefficient` διορθώνει την παρατηρούμενη συμφωνία για τυχαιότητα:

$$\kappa = \frac{P_o - P_e}{1 - P_e}$$

όπου P_o είναι η παρατηρούμενη αναλογιακή συμφωνία και P_e είναι η πιθανότητα συμφωνίας λόγω τύχης (υπολογίζεται από τις οριακές κατανομές ετικετών).

$\kappa = 1$ σημαίνει τέλεια συμφωνία· $\kappa = 0$ σημαίνει συμφωνία όχι καλύτερη από την τύχη· $\kappa < 0$ σημαίνει συστηματική διαφωνία.

Εύρος κ	Ερμηνεία
< 0	Κατώτερο από τύχη
$0.0 - 0.20$	Ελαφρά
$0.21 - 0.40$	Μέτρια
$0.41 - 0.60$	Μέτρια-ισχυρή
$0.61 - 0.80$	Ισχυρή
$0.81 - 1.00$	Σχεδόν τέλεια

Κάππα του Fleiss

Επεκτείνει το κάππα του Cohen σε $M > 2$ σχολιαστές. Κάθε σχολιαστής επισημαίνει ανεξάρτητα κάθε στοιχείο· ο τύπος συναθροίζει σε όλους τους σχολιαστές:

$$\kappa_F = \frac{\bar{P} - \bar{P}_e}{1 - \bar{P}_e}$$

όπου $\bar{P}$ είναι η μέση ανά ζεύγος συμφωνία σε όλα τα ζεύγη σχολιαστών, και $\bar{P}_e$ είναι η αναμενόμενη συμφωνία υπό τυχαία ανάθεση.

Άλφα του Krippendorff

Η πιο γενική μετρική, που υποστηρίζει οποιοδήποτε αριθμό σχολιαστών, οποιοδήποτε τύπο κλίμακας (ονομαστική, τακτική, διαστηματική, αναλογιακή) και ελλείποντα δεδομένα {cite}`krippendorff2011computing`:

$$\alpha = 1 - \frac{D_o}{D_e}$$

όπου D_o είναι η παρατηρούμενη διαφωνία και D_e είναι η αναμενόμενη διαφωνία. Το άλφα του Krippendorff γενικά προτιμάται στην ακαδημαϊκή εργασία λόγω της ευελιξίας του.

```python
import numpy as np
from sklearn.metrics import cohen_kappa_score

# Simulate two annotators labeling 200 items into 3 categories
rng = np.random.default_rng(0)
true_labels = rng.integers(0, 3, size=200)

# Annotator 1: mostly agrees with ground truth
ann1 = true_labels.copy()
flip_mask = rng.random(200) < 0.15
ann1[flip_mask] = rng.integers(0, 3, size=flip_mask.sum())

# Annotator 2: less consistent
ann2 = true_labels.copy()
flip_mask2 = rng.random(200) < 0.30
ann2[flip_mask2] = rng.integers(0, 3, size=flip_mask2.sum())

kappa_12 = cohen_kappa_score(ann1, ann2)
kappa_1true = cohen_kappa_score(ann1, true_labels)
kappa_2true = cohen_kappa_score(ann2, true_labels)

print(f"Cohen's κ (ann1 vs ann2):   {kappa_12:.3f}")
print(f"Cohen's κ (ann1 vs truth):  {kappa_1true:.3f}")
print(f"Cohen's κ (ann2 vs truth):  {kappa_2true:.3f}")
```

Χειρισμός Διαφωνιών

Όταν οι σχολιαστές διαφωνούν, υπάρχουν αρκετές στρατηγικές:

Πλειοψηφική Ψηφοφορία

Η πιο συνηθισμένη ετικέτα λαμβάνεται ως χρυσό πρότυπο. Απλή και ανθεκτική όταν ο αριθμός σχολιαστών ανά στοιχείο είναι μονός. Αποτυγχάνει όταν μια μειοψηφική ομάδα σχολιαστών είναι συστηματικά πιο ακριβής.

Σταθμισμένη Ψηφοφορία

Οι σχολιαστές σταθμίζονται κατά την εκτιμώμενη ακρίβειά τους (που προκύπτει από συμφωνία με ένα χρυσό πρότυπο ή άλλους σχολιαστές). Οι πιο ακριβείς σχολιαστές έχουν περισσότερη επιρροή.

Ήπιες Ετικέτες

Αντί να καταρρέουν οι σχολιασμοί σε μία ετικέτα, διατηρείται η κατανομή. Εάν 3 από 5 σχολιαστές είπαν «θετικό» και 2 «ουδέτερο», αναπαριστούμε αυτό ως $(p_{\text{θετ}}, p_{\text{ουδ}}, p_{\text{αρν}}) = (0.6, 0.4, 0.0)$. Η εκπαίδευση σε ήπιες ετικέτες βελτιώνει τη βαθμονόμηση.

Διαιτησία

Ένας ανώτερος σχολιαστής ή εμπειρογνώμονας τομέα επιλύει τις διαφωνίες. Χρυσό πρότυπο αλλά ακριβό· συνήθως επιφυλάσσεται για τομείς υψηλών διακυβευμάτων.

Στατιστικά Μοντέλα

Πιο εξελιγμένες προσεγγίσεις μοντελοποιούν πιθανολογικά την ικανότητα σχολιαστών. Το μοντέλο **Dawid-Skene** {cite}`dawid1979maximum` εκτιμά ταυτόχρονα πίνακες σύγχυσης σχολιαστών και πραγματικές ετικέτες στοιχείων μέσω EM. Βλ. Κεφάλαιο 13 για λεπτομέρειες.

Θόρυβος Ετικετών και οι Επιπτώσεις του

Ο πραγματικός σχολιασμός είναι θορυβώδης. Οι επιπτώσεις του θορύβου ετικετών στην εκπαίδευση μοντέλου εξαρτώνται από τον τύπο θορύβου:

- **Τυχαίος θόρυβος** (ετικέτες τυχαία αντεστραμμένες) υποβαθμίζει την απόδοση, αλλά τα μοντέλα είναι εκπληκτικά ανθεκτικά σε μέτρια επίπεδα (έως ~20% για πολλά έργα).
- **Συστηματικός/εχθρικός θόρυβος** (ετικέτες συνεπώς λανθασμένες σε συγκεκριμένα μοτίβα) είναι πολύ πιο καταστροφικός και δυσκολότερο να εντοπιστεί.
- **Θόρυβος υπό συνθήκη κλάσης** (σφάλματα πιο πιθανά για ορισμένες κλάσεις) μεροληπτεί το όριο απόφασης του μοντέλου.

Ένας πρακτικός εμπειρικός κανόνας: με n παραδείγματα εκπαίδευσης και ϵ κλάσμα κατεστραμμένων ετικετών, η απόδοση μοντέλου υποβαθμίζεται περίπου σαν να είχατε $(1 - 2\epsilon)^2 n$ καθαρά παραδείγματα {cite}`natarajan2013learning`. Για $\epsilon = 0.2$, αυτό ισοδυναμεί με απώλεια 36% των δεδομένων σας.

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import cross_val_score

rng = np.random.default_rng(42)
X, y = make_classification(n_samples=2000, n_features=20, random_state=42)

noise_levels = np.linspace(0, 0.45, 15)
mean_accs = []

for eps in noise_levels:
    y_noisy = y.copy()
    flip = rng.random(len(y)) < eps
    y_noisy[flip] = 1 - y_noisy[flip]
    scores = cross_val_score(LogisticRegression(max_iter=500), X, y_noisy, cv=5)
    mean_accs.append(scores.mean())

plt.figure(figsize=(7, 4))
plt.plot(noise_levels, mean_accs, 'o-', color='#2b3a8f', linewidth=2)
plt.xlabel("Label noise rate (ε)", fontsize=12)
```

```
plt.ylabel("Cross-validated accuracy", fontsize=12)
plt.title("Effect of Label Noise on Model Performance", fontsize=13)
plt.axvline(0.2, color='#e05c5c', linestyle='--', alpha=0.7, label='20% noise')
plt.legend()
plt.tight_layout()
plt.savefig('label_noise_effect.png', dpi=150)
plt.show()
print(f"\nAccuracy at 0% noise:  {mean_accs[0]:.3f}")
print(f"Accuracy at 20% noise: {mean_accs[round(0.2 / 0.45 * 14)]:.3f}")
print(f"Accuracy at 40% noise: {mean_accs[-2]:.3f}")
```

Κόστος και Απόδοση Σχολιασμού

Η κατανόηση των οικονομικών του σχολιασμού είναι απαραίτητη για τον σχεδιασμό έργων.

Τύπος έργου	Τυπική απόδοση	Κόστος ανά στοιχείο (ειδικός)
Δυαδική ταξινόμηση εικόνας	200–500/ώρα	$0.02–0.10
NER (σύντομο κείμενο)	50–150 στοιχ./ώρα	$0.10–0.50
Εξαγωγή σχέσεων	20–60 στοιχ./ώρα	$0.30–1.50
Τμηματοποίηση ιατρικής εικόνας	5–30 στοιχ./ώρα	$10–100
Σχολιασμός βίντεο	5–20 λεπτά/ώρα	$20–200

Αυτά τα στοιχεία είναι κατά προσέγγιση εκτιμήσεις τάξης μεγέθους και ποικίλλουν σημαντικά ανάλογα με την απαιτούμενη εμπειρογνωμοσύνη τομέα, την ποιότητα εργαλείων σχολιασμού, την ξεκαθαρότητα των οδηγιών και την εμπειρία σχολιαστών. Πρέπει να θεωρούνται ενδεικτικά, όχι κανονιστικά.

> **See also:** Οι επιλογές εργαλείων σχολιασμού καλύπτονται στο Κεφάλαιο 12. Τα στατιστικά μοντέλα για crowdsourced σχολιασμό (Dawid-Skene, MACE) καλύπτονται στο Κεφάλαιο 13.

Ενεργός Μάθηση

Τα δεδομένα με ετικέτες είναι ακριβά. Η βασική ιδέα της ενεργούς μάθησης είναι ότι *δεν είναι όλα τα μη-επισημασμένα παραδείγματα εξίσου ενημερωτικά* — ένα μοντέλο μπορεί να βελτιωθεί ταχύτερα εάν του επιτρέπεται να επιλέγει για ποια παραδείγματα να ρωτά. Αντί να επισημαίνει δεδομένα τυχαία, ένα σύστημα ενεργούς μάθησης απευθύνει ερώτηση σε ένα μαντείο (συνήθως έναν ανθρώπινο σχολιαστή) για τα παραδείγματα που πιθανότατα θα βελτιώσουν το μοντέλο.

Αυτό το κεφάλαιο καλύπτει τη θεωρία και πρακτική της ενεργούς μάθησης: στρατηγικές ερωτημάτων, πλαίσια δειγματοληψίας, κριτήρια διακοπής και πρακτικές εκτιμήσεις για πραγματικές αναπτύξεις.

Η Ρύθμιση Ενεργούς Μάθησης

Η τυπική ρύθμιση **ενεργούς μάθησης βάσει συνόλου** περιλαμβάνει:

- Ένα **επισημασμένο σύνολο** $\mathcal{L} = \{(x_i, y_i)\}_{i=1}^n$ — αρχικά μικρό
- Ένα **μη-επισημασμένο σύνολο** $\mathcal{U} = \{x_j\}_{j=1}^m$ — συνήθως πολύ μεγαλύτερο από το $\mathcal{L}$
- Ένα **μαντείο** $\mathcal{O}$ που μπορεί να επιστρέψει $y = \mathcal{O}(x)$ για οποιοδήποτε x ερωτηθεί
- Μια **στρατηγική ερωτήματος** ϕ που επιλέγει το επόμενο ερώτημα $x^* = \phi(\mathcal{L}, \mathcal{U}, f_\theta)$

Ο βρόχος ενεργούς μάθησης:

```
1. Αρχικοποίηση: L = μικρό αρχικό επισημασμένο σύνολο, U = μη-επισημασμένο σύνολο
2. Εκπαίδευση: f_θ ← train(L)
3. Ερώτημα: x* = argmax φ(x; f_θ) για x ∈ U
4. Επισήμανση: y* = O(x*)
5. Ενημέρωση: L ← L ∪ {(x*, y*)}, U ← U \ {x*}
→ Επανάληψη από 2 έως εξάντληση προϋπολογισμού
```

Ο στόχος είναι να επιτευχθεί στοχευμένη ποιότητα μοντέλου χρησιμοποιώντας όσο το δυνατόν λιγότερα ερωτήματα μαντείου.

Θεωρητικές Βάσεις

Ένα φυσικό ερώτημα είναι: πόσο μπορεί να βοηθήσει η ενεργός μάθηση; Στην καλύτερη περίπτωση, η ενεργός μάθηση μπορεί να επιτύχει *εκθετικές* μειώσεις στην πολυπλοκότητα ετικέτας — επιτυγχάνοντας σφάλμα ϵ με $O(\log(1/\epsilon))$ ετικέτες αντί

για $O(1/\epsilon)$ που χρειάζεται η παθητική μάθηση, τουλάχιστον σε πραγματοποιήσιμες ρυθμίσεις με καλή στρατηγική ερωτήματος {cite}`settles2009active`.

Στην πράξη, οι εγγυήσεις είναι πιο δύσκολο να ληφθούν. Η **αγνωστική ενεργός μάθηση** {cite}`balcan2006agnostic` δείχνει ότι η εξοικονόμηση ετικετών είναι δυνατή ακόμα και όταν η στοχευμένη έννοια δεν ανήκει στην κλάση υποθέσεων, αλλά η εξοικονόμηση εξαρτάται σθεναρά από τον συντελεστή διαφωνίας — μέτρο του πόσο γρήγορα συρρικνώνεται το σύνολο εύλογων υποθέσεων καθώς συσσωρεύονται δεδομένα.

Το βασικό πρακτικό συμπέρασμα: το πλεονέκτημα της ενεργούς μάθησης είναι μεγαλύτερο όταν το **όριο απόφασης είναι απλό και συγκεντρωμένο** (ώστε τα ερωτήματα αβεβαιότητας να εξαλείφουν γρήγορα λανθασμένες υποθέσεις), και μικρότερο όταν η κλάση υποθέσεων είναι μεγάλη ή το όριο είναι σύνθετο.

Στρατηγικές Ερωτημάτων

Δειγματοληψία Αβεβαιότητας

Η απλούστερη και ευρύτερα χρησιμοποιούμενη στρατηγική: ερώτηση για το παράδειγμα για το οποίο το μοντέλο είναι *πιο αβέβαιο* {cite}`lewis1994sequential`.

Χαμηλότερη εμπιστοσύνη ερωτά για το παράδειγμα για το οποίο το μοντέλο είναι λιγότερο σίγουρο για την κορυφαία πρόβλεψή του:

$$x^* = \arg\max_{x \in \mathcal{U}} \left(1 - P_\theta(\hat{y} \mid x)\right)$$

Δειγματοληψία περιθωρίου εξετάζει το χάσμα μεταξύ των δύο κορυφαίων προβλεπόμενων πιθανοτήτων:

$$x^* = \arg\min_{x \in \mathcal{U}} \left(P_\theta(\hat{y}_1 \mid x) - P_\theta(\hat{y}_2 \mid x)\right)$$

Δειγματοληψία εντροπίας χρησιμοποιεί την πλήρη προβλεπόμενη κατανομή:

$$x^* = \arg\max_{x \in \mathcal{U}} \left(-\sum_{k=1}^{K} P_\theta(y_k \mid x) \log P_\theta(y_k \mid x)\right)$$

Η δειγματοληψία εντροπίας είναι η πιο τεκμηριωμένη από τις τρεις — εξετάζει όλες τις κλάσεις — και γενικά υπερτερεί των άλλων σε πολυκλαδικά προβλήματα.

Ερώτημα Επιτροπής (QbC)

Εκπαίδευση μιας **επιτροπής** από C μοντέλα (χρησιμοποιώντας bagging, διαφορετικές αρχικοποιήσεις ή διαφορετικές αρχιτεκτονικές). Ερώτηση για το παράδειγμα για το οποίο η επιτροπή διαφωνεί περισσότερο:

$$x^* = \arg\max_{x \in \mathcal{U}} \ \text{disagreement}(\{f_c(x)\}_{c=1}^{C})$$

Η διαφωνία μπορεί να μετρηθεί ως **εντροπία ψηφοφορίας** (εντροπία επί των πλειοψηφικών ψηφοφοριών της επιτροπής) ή **απόκλιση KL** από την κατανομή συναίνεσης.

Το QbC παρέχει καλύτερες εκτιμήσεις αβεβαιότητας από ένα μεμονωμένο μοντέλο, αλλά απαιτεί εκπαίδευση πολλαπλών μοντέλων, κάτι που είναι υπολογιστικά ακριβό.

Αναμενόμενη Αλλαγή Μοντέλου

Ερώτηση για το παράδειγμα που θα προκαλούσε τη μεγαλύτερη αλλαγή στο τρέχον μοντέλο εάν επισημαινόταν. Για μοντέλα βασισμένα σε κλίση, αυτό αντιστοιχεί στο παράδειγμα με τη μεγαλύτερη αναμενόμενη μέτρηση κλίσης {cite}`settles2008analysis`:

$$x^* = \arg\max_{x \in \mathcal{U}} \sum_{y \in \mathcal{Y}} P_\theta(y \mid x) \, \|\nabla_\theta \mathcal{L}(f_\theta(x), y)\|$$

Αυτή η στρατηγική έχει ισχυρή θεωρητική τεκμηρίωση, αλλά απαιτεί υπολογισμό κλίσεων για κάθε υποψήφιο, καθιστώντας την ακριβή για μεγάλα μοντέλα.

Βασικό Σύνολο / Γεωμετρικές Προσεγγίσεις

Οι στρατηγικές βάσει αβεβαιότητας μπορεί να **εκτρέπονται προς ακραίες τιμές**: ένα ασυνήθιστο παράδειγμα μπορεί να είναι πολύ αβέβαιο αλλά μη αντιπροσωπευτικό της κατανομής δεδομένων. Οι μέθοδοι βασικού συνόλου αντιμετωπίζουν αυτό αναζητώντας ένα διαφορετικό δείγμα που καλύπτει τον χώρο χαρακτηριστικών.

Ο αλγόριθμος **k-center greedy** {cite}`sener2018active` βρίσκει το μικρότερο σύνολο σημείων έτσι ώστε κάθε μη-επισημασμένο σημείο να βρίσκεται εντός δ τουλάχιστον ενός ερωτηθέντος σημείου:

$$x^* = \arg\max_{x \in \mathcal{U}} \min_{x' \in \mathcal{L}} d(x, x')$$

δηλαδή, ερώτηση για το σημείο που απέχει περισσότερο από οποιοδήποτε τρέχον επισημασμένο σημείο. Αυτό ενθαρρύνει ένα καλά κατανεμημένο σύνολο σχολιασμών.

BADGE

Η **Ενεργός Μάθηση Παρτίδας με Διαφορετικές Ενσωματώσεις Κλίσης** (BADGE) {cite}`ash2020deep` συνδυάζει αβεβαιότητα και ποικιλομορφία: επιλέγει μια παρτίδα παραδειγμάτων των οποίων οι ενσωματώσεις κλίσης (ως προς την προβλεπόμενη ετικέτα) είναι τόσο μεγάλες σε μέτρηση (αβέβαιες) όσο και διαφορετικές (καλύπτουν διαφορετικές περιοχές του χώρου κλίσης). Αυτή είναι μία από τις πιο ανταγωνιστικές σύγχρονες στρατηγικές.

Εκτίμηση Αβεβαιότητας για Βαθιά Μοντέλα

Οι παραπάνω στρατηγικές υποθέτουν πρόσβαση σε βαθμονομημένες εξόδους πιθανότητας από το μοντέλο. Για απλά μοντέλα (λογιστική παλινδρόμηση, ταξινομητές softmax), αυτό είναι απλό. Για βαθιά δίκτυα, η λήψη αξιόπιστων εκτιμήσεων αβεβαιότητας απαιτεί πρόσθετες τεχνικές.

Δύο Τύποι Αβεβαιότητας

Ακολουθώντας τους Kendall και Gal {cite}`kendall2017uncertainties`, διακρίνουμε:

Αλεατορική (εγγενής) αβεβαιότητα (αβεβαιότητα δεδομένων): εγγενής θόρυβος στις παρατηρήσεις που δεν μπορεί να μειωθεί με συλλογή περισσότερων δεδομένων. Μια θολή εικόνα είναι αλεατορικά αβέβαιη — καμία ποσότητα πρόσθετων δεδομένων εκπαίδευσης από την ίδια κατανομή δεν θα κάνει το μοντέλο πιο σίγουρο γι' αυτήν.

Επιστημική (γνωσιακή) αβεβαιότητα (αβεβαιότητα μοντέλου): αβεβαιότητα λόγω περιορισμένων δεδομένων εκπαίδευσης ή μοντέλου που δεν έχει δει παρόμοια παραδείγματα. Η επιστημική αβεβαιότητα *μπορεί* να μειωθεί επισημαίνοντας περισσότερα δεδομένα — και είναι επομένως η σχετική ποσότητα για την επιλογή ερωτήματος ενεργούς μάθησης.

Για ενεργό μάθηση, θέλουμε να ερωτάμε παραδείγματα με υψηλή επιστημική αβεβαιότητα, όχι υψηλή αλεατορική αβεβαιότητα. Η ερώτηση για ένα θεμελιωδώς ασαφές παράδειγμα σπαταλά την προσπάθεια του μαντείου: καμία ετικέτα που παρέχουν δεν θα είναι σαφώς σωστή.

Dropout Monte Carlo

Μια πρακτική προσέγγιση για εκτίμηση επιστημικής αβεβαιότητας για νευρωνικά δίκτυα είναι το **MC Dropout** {cite}`gal2016dropout`: εφαρμογή dropout κατά τον χρόνο συμπερασμού και εκτέλεση T μπροστινών διελεύσεων. Η διακύμανση στις προβλέψεις είναι μια εκτίμηση της επιστημικής αβεβαιότητας.

```
import numpy as np
import torch
import torch.nn as nn

torch.manual_seed(42)
rng = np.random.default_rng(42)

class MCDropoutNet(nn.Module):
    def __init__(self, input_dim=20, hidden=64, output_dim=2, p_drop=0.3):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(input_dim, hidden), nn.ReLU(), nn.Dropout(p_drop),
            nn.Linear(hidden, hidden),    nn.ReLU(), nn.Dropout(p_drop),
            nn.Linear(hidden, output_dim)
        )

    def forward(self, x):
        return self.net(x)

def mc_uncertainty(model, x, T=30):
    """
    Run T stochastic forward passes with dropout active.
    Returns mean prediction and epistemic uncertainty (predictive variance).
    """
    model.train()  # keep dropout active during inference
    with torch.no_grad():
        preds = torch.stack([
            torch.softmax(model(x), dim=-1) for _ in range(T)
```

```
        ])  # shape: (T, N, C)
    mean_pred = preds.mean(0)
    # Epistemic uncertainty: mean of variances across passes
    epistemic = preds.var(0).sum(-1)
    # Aleatoric uncertainty: entropy of mean prediction
    aleatoric = -(mean_pred * (mean_pred + 1e-9).log()).sum(-1)
    return mean_pred, epistemic, aleatoric

# Quick demonstration
model = MCDropoutNet(input_dim=20, output_dim=2)
# In-distribution example (simulated)
x_familiar   = torch.randn(1, 20) * 0.5
# Out-of-distribution example (far from training distribution)
x_unfamiliar = torch.randn(1, 20) * 3.0

for name, x in [("In-distribution ", x_familiar), ("Out-of-distribution", x_unfamiliar)]:
    _, ep, al = mc_uncertainty(model, x)
    print(f"{name} | epistemic: {ep.item():.4f} | aleatoric: {al.item():.4f}")
```

Στο μη-εκπαιδευμένο δίκτυο παραπάνω, και τα δύο παραδείγματα εμφανίζουν παρόμοια αβεβαιότητα. Μετά την εκπαίδευση, το παράδειγμα εκτός κατανομής θα εμφανίζει υψηλότερη επιστημική αβεβαιότητα — το μοντέλο δεν έχει μάθει μια αξιόπιστη αντιστοίχιση για εισόδους μακριά από την κατανομή εκπαίδευσης.

Βαθιά Σύνολα

Η εκπαίδευση M ανεξάρτητα αρχικοποιημένων μοντέλων και η μέση τιμή των προβλέψεών τους παρέχει απλούστερη και συχνά πιο αξιόπιστη εκτίμηση αβεβαιότητας από το MC Dropout {cite}`lakshminarayanan2017simple`. Η διαφωνία μεταξύ μελών του συνόλου είναι το σήμα επιστημικής αβεβαιότητας.

Για ενεργό μάθηση σε κλίμακα, τόσο το MC Dropout όσο και τα βαθιά σύνολα προσθέτουν επιβάρυνση ανάλογη με T ή M μπροστινές διελεύσεις. Στην πράξη, $T = 10$–30 για MC Dropout ή $M = 5$ μέλη συνόλου είναι συχνά αρκετά για κατάταξη παραδειγμάτων κατά επιστημική αβεβαιότητα, ακόμα και αν οι απόλυτες τιμές δεν είναι καλά βαθμονομημένες.

Ένας Πλήρης Βρόχος Ενεργούς Μάθησης

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score
from copy import deepcopy

rng = np.random.default_rng(42)

# Generate dataset
X, y = make_classification(
    n_samples=2000, n_features=20, n_informative=10,
    n_classes=3, n_clusters_per_class=1, random_state=42
```

```
)
X_train, y_train = X[:1500], y[:1500]
X_test,  y_test  = X[1500:], y[1500:]

def entropy_query(model, X_pool):
    """Return index of most uncertain sample (entropy)."""
    probs = model.predict_proba(X_pool)
    ent = -np.sum(probs * np.log(probs + 1e-9), axis=1)
    return np.argmax(ent)

def random_query(X_pool):
    """Random baseline."""
    return rng.integers(0, len(X_pool))

def run_active_learning(strategy='entropy', n_initial=30, n_queries=120, query_batch=5):
    labeled_idx = list(rng.choice(len(X_train), n_initial, replace=False))
    unlabeled_idx = [i for i in range(len(X_train)) if i not in labeled_idx]
    accs = []

    for step in range(n_queries // query_batch):
        model = LogisticRegression(max_iter=500, C=1.0)
        model.fit(X_train[labeled_idx], y_train[labeled_idx])
        accs.append(accuracy_score(y_test, model.predict(X_test)))

        # Query
        X_pool = X_train[unlabeled_idx]
        for _ in range(query_batch):
            if strategy == 'entropy':
                q = entropy_query(model, X_pool)
            else:
                q = random_query(X_pool)
            labeled_idx.append(unlabeled_idx.pop(q))
            X_pool = X_train[unlabeled_idx]

    return np.array(accs)

labels_used = np.arange(1, 25) * 5 + 30  # label counts at each step

accs_active = run_active_learning(strategy='entropy')
accs_random = run_active_learning(strategy='random')

plt.figure(figsize=(8, 5))
plt.plot(labels_used, accs_active, 'o-', label='Entropy sampling', color='#2b3a8f', linewidth
plt.plot(labels_used, accs_random, 's--', label='Random baseline',  color='#e05c5c', linewidt
plt.xlabel("Number of labeled examples", fontsize=12)
plt.ylabel("Test accuracy", fontsize=12)
plt.title("Active Learning vs. Random Sampling", fontsize=13)
plt.legend(fontsize=11)
plt.grid(alpha=0.3)
plt.tight_layout()
plt.savefig('active_learning_curve.png', dpi=150)
```

```
plt.show()

print(f"Active learning reaches {accs_active[-1]:.3f} accuracy")
print(f"Random sampling reaches {accs_random[-1]:.3f} accuracy")
print(f"Active learning saves ~{int((accs_random.tolist().index(min(accs_random, key=lambda a
```

Το Πρόβλημα Ψυχρής Εκκίνησης

Η ενεργός μάθηση απαιτεί εκπαιδευμένο μοντέλο για βαθμολόγηση μη-επισημασμένων σημείων — αλλά στην αρχή, δεν υπάρχουν (ή υπάρχουν ελάχιστα) επισημασμένα παραδείγματα. Αυτό είναι το **πρόβλημα ψυχρής εκκίνησης**.

Πρακτικές λύσεις:

1. **Τυχαία αρχικοποίηση:** Επισημάνετε ένα μικρό τυχαίο αρχικό σύνολο (20–100 παραδείγματα) πριν ξεκινήσετε την ενεργό μάθηση.
2. **Αρχικοποίηση βάσει ομαδοποίησης:** Χρήση k-means στο μη-επισημασμένο σύνολο· επισήμανση ενός παραδείγματος από κάθε ομάδα. Αυτό εξασφαλίζει ποικιλομορφία στο αρχικό επισημασμένο σύνολο.
3. **Επιλογή βάσει ενσωμάτωσης:** Χρήση προ-εκπαιδευμένου κωδικοποιητή για ενσωμάτωση παραδειγμάτων· επιλογή διαφορετικού υποσυνόλου μέσω βασικού συνόλου.

Για τα περισσότερα έργα, μερικές δεκάδες τυχαίες αρχικές ετικέτες είναι συνήθως αρκετές για να ξεκινήσει η ενεργός μάθηση· ο ακριβής αριθμός εξαρτάται από την ισορροπία κλάσεων, τη διαστατικότητα χαρακτηριστικών και την πολυπλοκότητα μοντέλου.

Ενεργός Μάθηση Λειτουργίας Παρτίδας

Στην πράξη, οι σχολιαστές εργάζονται σε παρτίδες — είναι αναποτελεσματικό να εκπαιδεύεται και να αναπτύσσεται ένα νέο μοντέλο μετά από κάθε μεμονωμένη ετικέτα. Η **ενεργός μάθηση λειτουργίας παρτίδας** επιλέγει ένα σύνολο b παραδειγμάτων για ταυτόχρονη επισήμανση.

Η αφελής επιλογή των top-b πιο αβέβαιων παραδειγμάτων οδηγεί σε **πλεονασμό**: τα πολύ αβέβαια παραδείγματα τείνουν να ομαδοποιούνται μαζί (π.χ. παραδείγματα κοντά στο όριο απόφασης στην ίδια περιοχή). Καλύτερες στρατηγικές παρτίδας βελτιστοποιούν τόσο την αβεβαιότητα *όσο και* την ποικιλομορφία εντός της παρτίδας.

Οι **Ντετερμινιστικές Διεργασίες Σημείων (DPPs)** παρέχουν θεμελιωμένο τρόπο δειγματοληψίας διαφορετικών παρτίδων: ορίζουν κατανομή επί υποσυνόλων που τιμωρεί παρόμοια στοιχεία. Η πιθανότητα ενός υποσυνόλου S υπό DPP είναι ανάλογη με $\det(L_S)$ όπου L είναι ένας πίνακας πυρήνα που κωδικοποιεί ομοιότητα.

Κριτήρια Διακοπής

Πότε πρέπει να σταματά η ενεργός μάθηση; Συνηθισμένα κριτήρια:

- **Εξάντληση προϋπολογισμού:** Απλούστερο — διακοπή όταν εξαντληθεί ο προϋπολογισμός σχολιασμού.
- **Οροπέδιο απόδοσης:** Διακοπή όταν η ακρίβεια μοντέλου σε κρατημένο σύνολο επικύρωσης δεν έχει βελτιωθεί κατά περισσότερο από δ για k διαδοχικούς γύρους.
- **Κατώφλι εμπιστοσύνης:** Διακοπή όταν λιγότερα από κάποιο κλάσμα μη-επισημασμένων παραδειγμάτων έχουν αβεβαιότητα πάνω από κατώφλι.
- **Μέγιστη μείωση απώλειας:** Εκτίμηση του μέγιστου δυνατού κέρδους από επιπρόσθετες ετικέτες· διακοπή όταν αυτό πέσει κάτω από κατώφλι {cite}`bloodgood2009method`.

Πότε Λειτουργεί η Ενεργός Μάθηση (και Πότε Δεν Λειτουργεί)

Η ενεργός μάθηση τείνει να λειτουργεί καλά όταν: - Η επισήμανση είναι ακριβή και το μη-επισημασμένο σύνολο είναι μεγάλο - Τα δεδομένα έχουν σαφή δομή που το μοντέλο μπορεί να εκμεταλλευτεί για εντοπισμό ενημερωτικών παραδειγμάτων - Η κλάση μοντέλου είναι κατάλληλη για το έργο

Η ενεργός μάθηση αποδίδει άσχημα όταν: - Το αρχικό μοντέλο είναι πολύ κακό (κρύα εκκίνηση) και δεν μπορεί σημαντικά να κατατάξει παραδείγματα - Η στρατηγική ερωτήματος επιλέγει ακραίες τιμές ή λανθασμένα επισημασμένα παραδείγματα (σημαντική ανθεκτικότητα στον θόρυβο) - Η κατανομή δεδομένων μεταβάλλεται μεταξύ του μη-επισημασμένου συνόλου και της κατανομής ελέγχου

Μια βασική πρακτική ανησυχία είναι η **αναντιστοιχία κατανομής**: η ενεργός μάθηση τείνει να ερωτά παραδείγματα κοντά στο όριο απόφασης, δημιουργώντας ένα μεροληπτικό επισημασμένο σύνολο που μπορεί να μην αντιπροσωπεύει καλά την κατανομή ελέγχου. Αυτό μπορεί να οδηγήσει σε καλά εκπαιδευμένα όρια απόφασης αλλά κακή βαθμονόμηση.

> **See also:** Η θεμελιώδης έρευνα είναι {cite}`settles2009active`. Θεωρητικές βάσεις (πολυπλοκότητα ετικέτας, αγνωστικά όρια): {cite}`balcan2006agnostic`. Για ενεργό μάθηση ειδικά για βαθιά μάθηση, βλ. {cite}`ash2020deep` (BADGE) και {cite}`sener2018active` (βασικό σύνολο). Για κριτική αξιολόγηση πότε η ενεργός μάθηση πραγματικά βοηθά, βλ. {cite}`lowell2019practical`. Για αλεατορική vs. επιστημική αβεβαιότητα για βαθιά μοντέλα, βλ. {cite}`kendall2017uncertainties`· για βαθιά σύνολα ως εκτιμητές αβεβαιότητας, βλ. {cite}`lakshminarayanan2017simple`· για MC Dropout ως προσεγγιστική Βαυεσιανή συμπερασματολογία, βλ. {cite}`gal2016dropout`.

Διαδραστικό Μηχανικό Μάθηση

Η ενεργός μάθηση θέτει ένα εστιασμένο ερώτημα: δεδομένου προϋπολογισμού, ποια παραδείγματα να επισημανθούν; Το Διαδραστικό Μηχανικό Μάθηση (IML) θέτει ένα ευρύτερο ερώτημα: πώς μπορούμε να σχεδιάσουμε *ολόκληρη την αλληλεπίδραση* μεταξύ ανθρώπου και συστήματος μάθησης για να είναι μέγιστα παραγωγική, ευχάριστη και ορθή;

Το IML χαρακτηρίζεται από την **άμεσότητα** και **άμεση** σύνδεση του βρόχου ανατροφοδότησης ανθρώπου–μοντέλου. Όπου η παραδοσιακή ΜΜ περιλαμβάνει άνθρωπο που παραδίδει δεδομένα και περιμένει την ολοκλήρωση εκπαίδευσης, το IML επιτρέπει στους ανθρώπους να παρατηρούν τη συμπεριφορά μοντέλου, να παρέχουν ανατροφοδότηση και να βλέπουν το μοντέλο να ανταποκρίνεται — συχνά μέσα σε δευτερόλεπτα.

Αρχές Διαδραστικού Μηχανικού Μάθησης

Οι Amershi et al. {cite}`amershi2014power` εντοπίζουν τρία καθοριστικά χαρακτηριστικά του IML:

1. Γρήγορη Ανατροφοδότηση: Το μοντέλο ενημερώνεται αρκετά γρήγορα ώστε οι άνθρωποι να αντιλαμβάνονται την επίδραση της ανατροφοδότησής τους. Στο όριο, οι ενημερώσεις μοντέλου συμβαίνουν σε πραγματικό χρόνο.

2. Άμεση Χειραγώγηση: Ο άνθρωπος αλληλεπιδρά με το μοντέλο μέσω των δεδομένων ή μέσω των προβλέψεων του μοντέλου — όχι μέσω αρχείων διαμόρφωσης ή ρύθμισης υπερπαραμέτρων.

3. Επαναληπτική Βελτίωση: Η διαδικασία είναι γνησίως επαναληπτική: η επόμενη ενέργεια του ανθρώπου ενημερώνεται από την τρέχουσα συμπεριφορά του μοντέλου, η οποία διαμορφώθηκε από τις προηγούμενες ενέργειες του ανθρώπου.

Αυτό δημιουργεί έναν σφιχτό **βρόχο αμοιβαίας προσαρμογής**: τόσο ο άνθρωπος όσο και το μοντέλο αλλάζουν με την πάροδο του χρόνου ως απάντηση στο ένα προς το άλλο. Ο άνθρωπος μαθαίνει τι κατανοεί το μοντέλο· το μοντέλο μαθαίνει τι ενδιαφέρει τον άνθρωπο.

Σύγκριση με Ενεργό Μάθηση

Το IML και η ενεργός μάθηση επικαλύπτονται σημαντικά αλλά δεν είναι ταυτόσημα:

Ιδιότητα	Ενεργός Μάθηση	Διαδραστική ΜΜ
Κύριο ερώτημα	Τι να επισημάνω;	Πώς να αλληλεπιδράσω;
Καθυστέρηση ανατροφοδότησης	Μπορεί παρτίδα (ημέρες)	Τυπικά πραγματικός ή σχεδόν πραγ.
Συχνότητα ενημέρωσης μοντέλου	Ανά γύρο (παρτίδα)	Ανά αλληλεπίδραση (διαδικτυακά)
Ανθρώπινη πρωτοβουλία	Απαντά ερωτήματα μοντέλου	Μπορεί να διδάσκει προληπτικά
Σχεδιασμός διεπαφής	Δευτερεύον θέμα	Κεντρικό θέμα
Γνωστικό φορτίο ανθρώπου	Δεν μοντελοποιείται ρητά	Εξετάζεται ρητά

Στην ενεργό μάθηση, η μηχανή κατευθύνει την αλληλεπίδραση. Στο IML, ο άνθρωπος μπορεί επίσης να παίρνει την πρωτοβουλία — παρέχοντας παραδείγματα, διορθώσεις ή ανατροφοδότηση για οποιαδήποτε πτυχή της συμπεριφοράς του μοντέλου φαίνεται πιο προβληματική.

Αλληλεπίδραση Μικτής Πρωτοβουλίας

Τα συστήματα **μικτής πρωτοβουλίας** επιτρέπουν τόσο στον άνθρωπο όσο και στη μηχανή να αναλαμβάνουν την ηγεσία σε διαφορετικές στιγμές {cite}`allen1999mixed`. Ένα αμιγώς μηχανο-κατευθυνόμενο σύστημα κάνει ερωτήσεις και ο άνθρωπος απαντά. Ένα αμιγώς ανθρωπο-κατευθυνόμενο σύστημα αφήνει τον άνθρωπο να αποφασίζει τα πάντα. Τα συστήματα μικτής πρωτοβουλίας εξισορροπούν και τα δύο.

Στην πράξη, τα καλύτερα συστήματα IML συνδυάζουν: - **Πρωτοβουλία μηχανής:** «Είμαι αβέβαιο για αυτά τα παραδείγματα — μπορείτε να τα επισημάνετε;» - **Πρωτοβουλία ανθρώπου:** «Παρατηρώ ότι το μοντέλο συνεχώς κάνει λάθος για αυτή την κατηγορία — αφήστε με να δώσω περισσότερα παραδείγματα» - **Επιβεβαίωση:** Το μοντέλο αναδεικνύει την τρέχουσα κατανόησή του· ο άνθρωπος επιβεβαιώνει ή διορθώνει

Οι καλές διεπαφές IML κάνουν την τρέχουσα κατανόηση του μοντέλου ορατή και διορθώσιμη. Αυτή είναι η απαίτηση **ευκρίνειας**: οι άνθρωποι μπορούν να καθοδηγήσουν μόνο ένα μοντέλο που κατανοούν, τουλάχιστον κατά προσέγγιση.

Ανθρώπινοι Παράγοντες στο IML

Το IML φέρνει ανθρώπινους παράγοντες — γνωστικό φορτίο, κόπωση, συνέπεια και εμπιστοσύνη — άμεσα μέσα στον βρόχο μάθησης. Ο κακός σχεδιασμός IML οδηγεί σε:

Κόπωση σχολιασμού: Άνθρωποι που λαμβάνουν γρηγορότερες, πιο αμελείς αποφάσεις καθώς μακρύνουν οι συνεδρίες. Σφάλματα που εισέρχονται στα δεδομένα εκπαίδευσης.

Προκατάληψη αγκύρωσης: Άνθρωποι που εξαρτώνται υπερβολικά από τις τρέχουσες προτάσεις του μοντέλου. Εάν μια διεπαφή συμπληρώνει εκ των προτέρων την πρόβλεψη του μοντέλου, οι σχολιαστές είναι λιγότερο πιθανό να τη διορθώσουν ακόμα και όταν είναι λανθασμένη — μια συστηματική πηγή θορύβου ετικετών που επιδεινώνεται σε γύρους σχολιασμού {cite}`geva2019annotator`. Ο προ-σχολιασμός μπορεί να επιταχύνει

την απόδοση {cite}`lingren2014evaluating` ενώ ταυτόχρονα μειώνει τον ρυθμό με τον οποίο οι σχολιαστές εντοπίζουν σφάλματα μοντέλου· αυτές οι δύο επιδράσεις πρέπει να σταθμίζονται στον σχεδιασμό διεπαφής IML.

Κακή βαθμονόμηση εμπιστοσύνης: Οι άνθρωποι είτε υπερεμπιστεύονται (αποδέχονται λανθασμένες εξόδους μοντέλου) είτε υποεμπιστεύονται (αγνοούν σωστές προτάσεις). Και τα δύο μοτίβα μειώνουν την αξία της συνεργασίας ανθρώπου–μοντέλου.

Συνέπεια συνεδρίας: Οι άνθρωποι μπορεί να λαμβάνουν διαφορετικές αποφάσεις για το ίδιο παράδειγμα σε διαφορετικές στιγμές, ειδικά μετά από μακρές συνεδρίες. Έλεγχοι συνέπειας (επαναπαρουσίαση προηγούμενων παραδειγμάτων) μπορούν να εντοπίσουν και να διορθώσουν αυτό.

Ο καλός σχεδιασμός IML μετριάζει αυτά τα ζητήματα μέσω επιλογών διεπαφής: ρητή παρουσίαση εμπιστοσύνης μοντέλου, τυχαιοποίηση σειράς εμφάνισης, περιορισμός διάρκειας συνεδρίας και ενσωμάτωση ελέγχων συνέπειας.

Τύποι Ανατροφοδότησης IML στην Πράξη

Ανατροφοδότηση Επιπέδου Παραδείγματος

Ο άνθρωπος παρέχει ετικέτα ή διόρθωση για ένα συγκεκριμένο παράδειγμα. Αυτή είναι η πιο κοινή μορφή και είναι άμεσα συμβατή με εποπτευόμενη μάθηση.

Ανατροφοδότηση Επιπέδου Χαρακτηριστικού

Ο άνθρωπος υποδεικνύει ποια χαρακτηριστικά είναι σχετικά ή άσχετα. «Το μοντέλο πρέπει να δίνει προσοχή στις λέξεις "επείγον" και "προθεσμία" για αυτή την κατηγορία.» Αυτό είναι πιο εκφραστικό από την ανατροφοδότηση επιπέδου παραδείγματος και μπορεί να είναι πιο αποτελεσματικό για ορισμένα έργα.

Συστήματα όπως **TFIDF Interactive** επιτρέπουν στους σχολιαστές να επισημαίνουν σχετικές λέξεις σε έγγραφα κειμένου. Αυτές οι επισημάνσεις μετατρέπονται σε περιορισμούς ή πρόσθετη εποπτεία στην προσοχή του μοντέλου.

Ανατροφοδότηση Επιπέδου Μοντέλου

Ο άνθρωπος διορθώνει άμεσα τη συμπεριφορά του μοντέλου σε μια κλάση εισόδων: «Κάθε φορά που η είσοδος περιέχει [X], η έξοδος πρέπει να είναι [Y].» Αυτό αντιστοιχεί σε λογικούς κανόνες ή περιορισμούς σε προσεγγίσεις όπως η Οπίσθια Κανονικοποίηση {cite}`ganchev2010posterior` ή η μάθηση με περιορισμούς.

Μελέτη Περίπτωσης: Google Teachable Machine

Το Teachable Machine είναι ένα προσβάσιμο web-based σύστημα IML που επιτρέπει σε μη-τεχνικούς χρήστες να εκπαιδεύουν ταξινομητές εικόνας στον περιηγητή. Ο χρήστης:

1. Καταγράφει παραδείγματα κάθε κλάσης χρησιμοποιώντας τη webcam του
2. Εκπαιδεύει το μοντέλο με ένα κλικ (fine-tuning ενός MobileNet στον περιηγητή)
3. Βλέπει αμέσως τις προβλέψεις του μοντέλου σε ζωντανό βίντεο
4. Προσθέτει περισσότερα παραδείγματα για κλάσεις όπου το μοντέλο κάνει λάθος

Αυτό απεικονίζει τον βασικό βρόχο IML: παροχή παραδειγμάτων □ παρατήρηση μοντέλου □ εντοπισμός αποτυχίας □ παροχή περισσότερων στοχευμένων παραδειγμάτων. Η ανατροφοδότηση σε πραγματικό χρόνο (οι έξοδοι μοντέλου ενημερώνονται σε πραγματικό χρόνο, τυπικά με διαδραστικούς ρυθμούς καρέ σε σύγχρονο υλικό) κάνει τον βρόχο αμοιβαίας προσαρμογής παρορμητικά άμεσο.

Υλοποίηση ενός Απλού Βρόχου IML

```python
import numpy as np
from sklearn.linear_model import SGDClassifier
from sklearn.preprocessing import StandardScaler
import warnings
warnings.filterwarnings('ignore')

class SimpleIMLSystem:
    """
    Minimal IML system that allows online feedback and displays
    model state after each annotation.
    """

    def __init__(self, n_features=10, n_classes=2):
        self.model = SGDClassifier(loss='log_loss', max_iter=1, warm_start=True,
                                   random_state=42)
        self.scaler = StandardScaler()
        self.X_seen = []
        self.y_seen = []
        self.n_classes = n_classes
        self.initialized = False

    def update(self, x, y_true):
        """Receive a single labeled example and update the model."""
        self.X_seen.append(x)
        self.y_seen.append(y_true)

        if len(self.X_seen) >= 2 * self.n_classes:
            X_arr = np.array(self.X_seen)
            y_arr = np.array(self.y_seen)
            X_scaled = self.scaler.fit_transform(X_arr)
            self.model.partial_fit(X_scaled[-1:], y_arr[-1:],
                                   classes=list(range(self.n_classes)))
            self.initialized = True

        return self

    def predict_with_confidence(self, x):
        """Predict label and return confidence."""
        if not self.initialized:
            return None, 0.0
        x_scaled = self.scaler.transform(x.reshape(1, -1))
```

```
        probs = self.model.predict_proba(x_scaled)[0]
        return self.model.predict(x_scaled)[0], probs.max()

    def current_accuracy(self, X_val, y_val):
        if not self.initialized:
            return None
        X_scaled = self.scaler.transform(X_val)
        return (self.model.predict(X_scaled) == y_val).mean()


# Simulate an IML session
rng = np.random.default_rng(42)
X_all, y_all = np.random.default_rng(0).random((500, 10)), np.random.default_rng(0).integers(
X_val, y_val = X_all[400:], y_all[400:]

system = SimpleIMLSystem(n_features=10, n_classes=2)
accs, confidences = [], []

print("Step | Labels | Accuracy | Example confidence")
print("-" * 50)

for step in range(100):
    x, y = X_all[step], y_all[step]
    pred, conf = system.predict_with_confidence(x)
    system.update(x, y)

    if (step + 1) % 10 == 0:
        acc = system.current_accuracy(X_val, y_val)
        if acc is not None:
            accs.append(acc)
            print(f"  {step+1:3d} |  {step+1:4d}  |  {acc:.3f}   | {conf:.3f}")
```

Το Τεστ της Γιαγιάς

Ένα χρήσιμο ευρετικό για αξιολόγηση σχεδιασμού διεπαφής IML — και σχεδιασμού συστήματος HITL γενικότερα — είναι αυτό που θα ονομάσουμε **Τεστ της Γιαγιάς** (πρωτότυπος όρος που εισάγεται εδώ ως σχεδιαστικός περιορισμός, όχι ως αναφορά σε προηγούμενη εργασία):

> *Μια γυναίκα γεννημένη το 1930 πρέπει να μπορεί να χρησιμοποιεί αυτή τη συσκευή με φωνή, και αν ματαιωθεί, να υποχωρεί ομαλά σε διεπαφή πληκτρολογίου ή κειμένου.*

Το τεστ δεν αφορά κυρίως την προσβασιμότητα, αν και είναι και αυτό. Αφορά τον **σχεδιασμό για τριβή**. Εάν ένα σύστημα απαιτεί νοητικό μοντέλο νευρωνικών δικτύων, βρόχων εκπαίδευσης ή κατανομών πιθανότητας για αποτελεσματική χρήση, έχει αποτύχει στο Τεστ της Γιαγιάς. Ο άνθρωπος στον βρόχο πρέπει να μπορεί να συμμετέχει χωρίς να κατανοεί τη μηχανική πλευρά του βρόχου.

Οι συνέπειες για τον σχεδιασμό IML είναι συγκεκριμένες:

Προτεραιότητα φωνής: Η κύρια τρόπος αλληλεπίδρασης πρέπει να είναι η φυσική γλώσσα ή η χειρονομία — όχι ρυθμιστικά παραμέτρων ή κατώφλια εμπιστοσύνης. Οι ειδικοί μπορεί να θέλουν ρυθμιστικά· όλοι πρέπει να μπορούν να πουν «αυτό είναι λάθος».

Ομαλή υποβάθμιση: Όταν ο προτιμώμενος τρόπος του χρήστη αποτυγχάνει ή ματαιώνει, το σύστημα πρέπει να προσφέρει εναλλακτική — όχι κενή οθόνη ή μήνυμα σφάλματος. Η διεπαφή είναι μέρος του συστήματος μάθησης· ένας χρήστης που δεν μπορεί να αλληλεπιδράσει δεν μπορεί να διδάξει.

Αναγνώσιμη κατάσταση μοντέλου: Η τρέχουσα κατανόηση του μοντέλου πρέπει να είναι ορατή σε ανθρώπινους όρους. Όχι «εμπιστοσύνη: 0.73» αλλά «Είμαι αρκετά σίγουρο ότι αυτό είναι [X], αλλά έχω δει παραδείγματα σαν αυτό και στις δύο κατευθύνσεις.» Η αβεβαιότητα πρέπει να επικοινωνείται σε γλώσσα που προσκαλεί διόρθωση.

Ανοχή ασάφειας: Ένας χρήστης 93 ετών και ένας μηχανικός ΜΜ 23 ετών θα αλληλεπιδρούν διαφορετικά με το ίδιο σύστημα. Το Τεστ της Γιαγιάς ρωτά αν το σύστημα μπορεί να φιλοξενήσει και τους δύο — όχι ανιχνεύοντας την ηλικία του χρήστη, αλλά σχεδιάζοντας αλληλεπιδράσεις που λειτουργούν σε ένα φάσμα εξειδίκευσης και άνεσης.

Το τεστ αποκτά ιδιαίτερη σημασία καθώς τα συστήματα ΜΜ μεταβαίνουν από ερευνητικά εργαλεία σε καθημερινή υποδομή. Ένας βοηθός ιατρικής απεικόνισης που χρησιμοποιείται από ακτινολόγους, ένας ταξινομητής νομικών εγγράφων που χρησιμοποιείται από γραμματείς, ένα σύστημα εκπαιδευτικής ανατροφοδότησης που χρησιμοποιείται από εκπαιδευτικούς — κάθε ένα περιλαμβάνει ανθρώπους-στον-βρόχο που δεν εγγράφηκαν ως εκπαιδευτές ΤΝ. Ο σχεδιασμός γι' αυτούς δεν είναι παραχώρηση· είναι το νόημα.

:::{admonition} Αρχή Σχεδιασμού :class: tip Το Τεστ της Γιαγιάς είναι σχεδιαστικός περιορισμός, όχι δημογραφικός στόχος. Τα συστήματα που το περνούν είναι πιο ανθεκτικά στη διαφορετικότητα χρηστών, πιο συγχωρητικά για κενά εξειδίκευσης και πιο ειλικρινή για το τι αναμένουν από ανθρώπους-στον-βρόχο. Εάν ένα σύστημα απαιτεί εξήγηση πριν τη χρήση, ζητά από τον άνθρωπο να κάνει επιπλέον δουλειά. Αυτή η δουλειά πρέπει να δικαιολογείται από ανάλογο όφελος. :::

IML και Θεμελιακά Μοντέλα

Η σύγχρονη IML αξιοποιεί ολοένα και περισσότερο **προ-εκπαιδευμένα θεμελιακά μοντέλα** {cite}`bommasani2021opportunities` ως βάση. Αντί να εκπαιδεύονται από την αρχή, οι χρήστες κάνουν fine-tune ένα μεγάλο προ-εκπαιδευμένο μοντέλο με έναν μικρό αριθμό διαδραστικών παραδειγμάτων. Αυτό μπορεί να μειώσει δραματικά τον αριθμό παραδειγμάτων που απαιτούνται για χρήσιμη απόδοση — σε ευνοϊκές περιπτώσεις, τόσο λίγο όσο 5–50 παραδείγματα αντί για χιλιάδες, ανάλογα με το πόσο καλά οι προ-εκπαιδευμένες αναπαραστάσεις ταιριάζουν με το στοχευμένο έργο {cite}`bommasani2021opportunities`.

Τεχνικές που το επιτρέπουν: - **Few-shot prompting:** Παροχή παραδειγμάτων στο παράθυρο πλαισίου του LLM - **Adapter fine-tuning:** Ενημέρωση μικρών μονάδων adapter ενώ παγώνει το βασικό μοντέλο - **Αποτελεσματικό fine-tuning παραμέτρων (PEFT):** LoRA, prefix tuning και παρόμοιες μέθοδοι που επιτρέπουν γρήγορες, χαμηλών πόρων ενημερώσεις

Τα θεμελιακά μοντέλα αλλάζουν τη δυναμική IML: οι άνθρωποι δεν διδάσκουν πλέον ένα

μοντέλο με κενό σχίστη από την αρχή αλλά *καθοδηγούν* ένα μοντέλο που ήδη γνωρίζει πολλά. Η πρόκληση μετατοπίζεται από «πώς να παρέχουμε αρκετά παραδείγματα» σε «πώς να προσδιορίσουμε ακριβώς τι θέλουμε διαφορετικά από αυτό που το μοντέλο ήδη κάνει».

> **See also:** Η έρευνα από {cite}`amershi2014power` παραμένει η καλύτερη επισκόπηση αρχών IML. Για συστήματα μικτής πρωτοβουλίας ειδικά, βλ. {cite}`allen1999mixed`. Για επιδράσεις αγκύρωσης στον σχολιασμό, βλ. {cite}`geva2019annotator` και {cite}`lingren2014evaluating`.

Ενισχυτική Μάθηση από Ανθρώπινη Ανατροφοδότηση

Καμία τεχνική δεν έχει συμβάλει περισσότερο στην ανάδειξη της HITL ML στο ευρύ κοινό από την Ενισχυτική Μάθηση από Ανθρώπινη Ανατροφοδότηση (RLHF). Αποτελεί τον μηχανισμό πίσω από το InstructGPT {cite}`ouyang2022training` και βασικό συστατικό των αγωγών ακολούθησης οδηγιών σε πολλά σύγχρονα μεγάλα γλωσσικά μοντέλα {cite}`stiennon2020learning`. Η κατανόηση του RLHF — όχι απλώς ως συνταγή που ακολουθείται, αλλά ως θεμελιωμένη προσέγγιση ευθυγράμμισης — είναι απαραίτητη για όσους εργάζονται στη σύγχρονη ΤΝ.

Το Πρόβλημα Ευθυγράμμισης

Τα Μεγάλα Γλωσσικά Μοντέλα (LLMs) εκπαιδευμένα καθαρά στην πρόβλεψη επόμενου τεκμηρίου βελτιστοποιούν έναν αντιπρόσωπο στόχο: πρόβλεψη του κειμένου που ακολουθεί στο σώμα ανθρώπινου γραπτού κειμένου. Αυτός ο στόχος σχετίζεται, αλλά διαφέρει, από αυτό που πραγματικά θέλουμε: απαντήσεις που είναι χρήσιμες, ακριβείς, ασφαλείς και ευθυγραμμισμένες με τις ανθρώπινες αξίες.

Η αναντιστοιχία μεταξύ του στόχου εκπαίδευσης και της επιθυμητής συμπεριφοράς ονομάζεται **πρόβλημα ευθυγράμμισης** {cite}`russell2019human`. Συγκεκριμένα, ένα γλωσσικό μοντέλο εκπαιδευμένο σε κείμενο διαδικτύου μαθαίνει να: - Παράγει αληθοφανείς συνεχίσεις (που μπορεί να είναι πραγματολογικά λανθασμένες) - Αντικατοπτρίζει τις προκαταλήψεις και τις βλάβες που υπάρχουν στα δεδομένα εκπαίδευσης - Να είναι αποφευκτικό ή χειραγωγικό όταν αυτό είναι στατιστικά το επόμενο μετά τη γλωσσική εντολή

Το RLHF αντιμετωπίζει την ευθυγράμμιση κάνοντας τις ανθρώπινες προτιμήσεις *μέρος του στόχου βελτιστοποίησης*.

Ο Αγωγός RLHF

Το RLHF προχωρά σε τρία στάδια:

```
Στάδιο 1: Εποπτευόμενο Fine-Tuning (SFT)
  --> Συλλογή δεδομένων επίδειξης (ο άνθρωπος γράφει ιδανικές απαντήσεις)
  --> Fine-tune βασικού LLM στις επιδείξεις

Στάδιο 2: Εκπαίδευση Μοντέλου Ανταμοιβής
```

```
  --> Συλλογή ζευγαρωτών προτιμήσεων (ο άνθρωπος αξιολογεί A vs B)
  --> Εκπαίδευση μοντέλου ανταμοιβής R(x, y) για πρόβλεψη ανθρώπινων προτιμήσεων

Στάδιο 3: Fine-Tuning EN
  --> Fine-tune LLM χρησιμοποιώντας PPO/EN για μεγιστοποίηση R(x, y)
  --> Η ποινή KL αποτρέπει υπερβολική απόκλιση από το μοντέλο SFT
```

Στάδιο 1: Εποπτευόμενο Fine-Tuning

Ξεκινώντας από ένα προ-εκπαιδευμένο βασικό μοντέλο π_0, συλλέγουμε ένα σύνολο δεδομένων ζευγαριών (εντολή, ιδανική απάντηση), γραμμένων ή επιλεγμένων από ανθρώπινους εργαζομένους που ακολουθούν λεπτομερείς οδηγίες. Το μοντέλο κάνει fine-tune σε αυτές τις επιδείξεις χρησιμοποιώντας τυπική διασταυρωτή εντροπία:

$$\mathcal{L}_{\text{SFT}}(\theta) = -\mathbb{E}_{(x,y)\sim\mathcal{D}_{\text{demo}}}\left[\log \pi_\theta(y \mid x)\right]$$

Το μοντέλο SFT π_{SFT} είναι πολύ καλύτερο σημείο εκκίνησης για RLHF από το ακατέργαστο προ-εκπαιδευμένο μοντέλο.

Στάδιο 2: Εκπαίδευση Μοντέλου Ανταμοιβής

Για ένα σύνολο εντολών $\{x_i\}$, παράγουμε K απαντήσεις ανά εντολή χρησιμοποιώντας π_{SFT} και τις παρουσιάζουμε σε ανθρώπινους σχολιαστές ως ζευγαρωτές συγκρίσεις: «Ποια απάντηση είναι καλύτερη, A ή B;»

Το μοντέλο ανταμοιβής r_ϕ εκπαιδεύεται να προβλέπει αυτές τις προτιμήσεις. Υπό το μοντέλο **Bradley-Terry** (Κεφάλαιο 8), η πιθανότητα να προτιμηθεί η απάντηση y_w έναντι της y_l είναι:

$$P(y_w \succ y_l \mid x) = \sigma\left(r_\phi(x, y_w) - r_\phi(x, y_l)\right)$$

Το μοντέλο ανταμοιβής εκπαιδεύεται να ελαχιστοποιεί την απώλεια ζευγαρωτής κατάταξης:

$$\mathcal{L}_{\text{RM}}(\phi) = -\mathbb{E}_{(x,y_w,y_l)\sim\mathcal{D}_{\text{pref}}}\left[\log \sigma\left(r_\phi(x, y_w) - r_\phi(x, y_l)\right)\right]$$

Το μοντέλο ανταμοιβής αρχικοποιείται συνήθως από το μοντέλο SFT με μια βαθμωτή κεφαλή που αντικαθιστά το τελευταίο στρώμα.

Στάδιο 3: Fine-Tuning EN με PPO

Με εκπαιδευμένο μοντέλο ανταμοιβής, μπορούμε να χρησιμοποιήσουμε ενισχυτική μάθηση για fine-tuning του LLM. Κάθε εντολή x είναι μια κατάσταση· κάθε απάντηση y είναι μια τροχιά επιλογών τεκμηρίων· και η ανταμοιβή είναι $r_\phi(x, y)$.

Ο στόχος βελτιστοποίησης περιλαμβάνει μια **ποινή απόκλισης KL** για να αποτραπεί η υπερβολική απόκλιση του μοντέλου από τη βάση SFT (που θα οδηγούσε σε reward hacking {cite}`krakovna2020specification,gao2023scaling`):

$$\max_\theta \mathbb{E}_{x\sim\mathcal{D}, y\sim\pi_\theta(\cdot|x)}\left[r_\phi(x, y) - \beta \cdot \text{KL}\left[\pi_\theta(\cdot \mid x) \| \pi_{\text{SFT}}(\cdot \mid x)\right]\right]$$

Η παράμετρος β ελέγχει την ισχύ της ποινής KL. Μικρή β επιτρέπει περισσότερη βελτιστοποίηση αλλά κινδυνεύει με reward hacking· μεγάλη β κρατά το μοντέλο κοντά στο SFT αλλά περιορίζει τα κέρδη ευθυγράμμισης.

Η **Εγγύς Βελτιστοποίηση Πολιτικής (PPO)** {cite}`schulman2017proximal` είναι ο τυπικός αλγόριθμος για αυτό το στάδιο, επιλεγμένος για τη σταθερότητά του σε σχέση με τις μεθόδους ακατέργαστης κλίσης πολιτικής.

Μια Απλοποιημένη Επίδειξη RLHF

Ο πλήρης αγωγός RLHF απαιτεί υποδομή μεγάλης κλίμακας. Το ακόλουθο παράδειγμα επιδεικνύει τις βασικές ιδέες σε μικρή κλίμακα.

```
import numpy as np
import torch
import torch.nn as nn
import torch.optim as optim
from torch.nn import functional as F

torch.manual_seed(42)
rng = np.random.default_rng(42)

# ----------------------------------------------
# Toy setup: responses are 4-dimensional vectors
# "Quality" is known analytically (sum of positive values)
# We simulate a reward model learning this from pairwise feedback
# ----------------------------------------------

class RewardModel(nn.Module):
    def __init__(self, d=4, hidden=32):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(d, hidden), nn.ReLU(),
            nn.Linear(hidden, hidden), nn.ReLU(),
            nn.Linear(hidden, 1)
        )
    def forward(self, x):
        return self.net(x).squeeze(-1)

def true_quality(x):
    """The hidden ground-truth reward function."""
    return x.sum(dim=-1) + 0.5 * (x ** 2).mean(dim=-1)

# Generate pairwise preference data
N_PAIRS = 500
X1 = torch.randn(N_PAIRS, 4)
X2 = torch.randn(N_PAIRS, 4)
q1, q2 = true_quality(X1), true_quality(X2)
# Human prefers X1 when q1 > q2 (with some noise)
noise = torch.randn(N_PAIRS) * 0.5
```

```
preferred_1 = ((q1 - q2 + noise) > 0).float()

# Train reward model
rm = RewardModel(d=4, hidden=32)
optimizer = optim.Adam(rm.parameters(), lr=3e-3)

losses = []
for epoch in range(200):
    r1 = rm(X1)
    r2 = rm(X2)
    # Bradley-Terry loss
    logit = r1 - r2
    loss = F.binary_cross_entropy_with_logits(logit, preferred_1)
    optimizer.zero_grad(); loss.backward(); optimizer.step()
    losses.append(loss.item())

# Evaluate: does the reward model agree with true quality?
X_eval = torch.randn(1000, 4)
with torch.no_grad():
    r_pred = rm(X_eval).numpy()
    r_true = true_quality(X_eval).numpy()

corr = np.corrcoef(r_pred, r_true)[0, 1]
print(f"Reward model correlation with true quality: {corr:.4f}")
print(f"Final training loss: {losses[-1]:.4f}")

import matplotlib.pyplot as plt
plt.figure(figsize=(8, 3))
plt.subplot(1, 2, 1)
plt.plot(losses, color='#2b3a8f', linewidth=1.5)
plt.xlabel("Epoch"); plt.ylabel("Pairwise loss")
plt.title("Reward Model Training")

plt.subplot(1, 2, 2)
plt.scatter(r_true[:200], r_pred[:200], alpha=0.4, s=15, color='#2b3a8f')
plt.xlabel("True quality"); plt.ylabel("Predicted reward")
plt.title(f"Reward Model vs. Truth (r={corr:.3f})")
plt.tight_layout()
plt.savefig('reward_model.png', dpi=150)
plt.show()
```

Προκλήσεις στο RLHF

Reward Hacking

Ένας βασικός τρόπος αποτυχίας: η πολιτική βρίσκει τρόπους να παίρνει υψηλή ανταμοιβή από το μοντέλο ανταμοιβής που δεν αντιστοιχούν σε γνησίως καλή συμπεριφορά. Για παράδειγμα, ένα LLM μπορεί να μάθει να παράγει απαντήσεις που είναι κολακευτικές ή ακούγονται σίγουρα (τις οποίες οι σχολιαστές τείνουν να αξιολογούν υψηλά) αντί να είναι ακριβείς.

Το reward hacking είναι πιο πιθανό όταν: - Το μοντέλο ανταμοιβής εκπαιδεύεται σε ανεπαρκή δεδομένα προτίμησης - Η πολιτική έχει αποκλίνει πολύ από τη βάση SFT (μικρή β) - Η κατανομή μοντέλου ανταμοιβής μετατοπίζεται κατά την εκπαίδευση PPO

Στρατηγικές μετριασμού: ποινή KL, επαναληπτική εκπαίδευση μοντέλου ανταμοιβής, διαφορετική αξιολόγηση, περιορισμοί Constitutional AI.

Προκατάληψη Αξιολογητή

Οι ανθρώπινοι σχολιαστές έχουν συστηματικές προκαταλήψεις. Τείνουν να προτιμούν μακρύτερες απαντήσεις (προκατάληψη λεκτικότητας), κείμενο που ακούγεται πιο σίγουρο (προκατάληψη εμπιστοσύνης) και απαντήσεις που συμφωνούν με τις προηγούμενες πεποιθήσεις τους. Αυτές οι προκαταλήψεις μεταδίδονται στο μοντέλο ανταμοιβής.

Η γνωστή αποτυχία συκοφαντίας μοντέλων RLHF — όπου το μοντέλο λέει στους χρήστες αυτό που θέλουν να ακούσουν αντί για αυτό που είναι αληθινό — είναι εν μέρει αποτέλεσμα της προτίμησης αξιολογητών για ευάρεστες απαντήσεις.

Κλιμακωτή Εποπτεία

Για σύνθετα έργα, οι άνθρωποι δεν μπορούν αξιόπιστα να κρίνουν ποια απάντηση ΤΝ είναι σωστή. Ένας σχολιαστής που συγκρίνει δύο μακρές μαθηματικές αποδείξεις ή δύο υλοποιήσεις κώδικα μπορεί απλώς να επιλέξει την πιο αναγνώσιμη, ανεξάρτητα από ορθότητα. Η **κλιμακωτή εποπτεία** είναι το ανοιχτό ερευνητικό πρόβλημα σχεδιασμού διαδικασιών αξιολόγησης που παραμένουν αξιόπιστες καθώς αυξάνεται η πολυπλοκότητα έργου {cite}`bowman2022measuring`.

Constitutional AI (RLAIF)

Το **Constitutional AI** {cite}`bai2022constitutional`, που αναπτύχθηκε στην Anthropic, μειώνει την εξάρτηση από ανθρώπινους σχολιαστές χρησιμοποιώντας την ίδια την ΤΝ για να παράγει ετικέτες προτίμησης καθοδηγούμενες από ένα σύνολο αρχών (μια «σύνταξη»). Η διαδικασία:

1. Παράγει απαντήσεις σε δυνητικά επιβλαβείς εντολές
2. Χρησιμοποιεί κριτή ΤΝ για αξιολόγηση απαντήσεων έναντι συνταγματικών αρχών
3. Αναθεωρεί απαντήσεις καθοδηγούμενες από ανατροφοδότηση ΤΝ (RLAIF — ΕΝ από Ανατροφοδότηση ΤΝ)
4. Εκπαιδεύει μοντέλο ανταμοιβής σε προτιμήσεις που παράγει η ΤΝ
5. Κάνει fine-tune με RLHF χρησιμοποιώντας αυτό το μοντέλο ανταμοιβής

Το RLAIF μπορεί να παράγει δεδομένα προτίμησης σε πολύ μεγαλύτερη κλίμακα από την ανθρώπινη επισήμανση, και επιτρέπει λεπτομερή έλεγχο των αξιών που κωδικοποιούνται στο μοντέλο ανταμοιβής.

> **See also:** Το πρωτότυπο άρθρο InstructGPT {cite}`ouyang2022training` περιγράφει την πρώτη μεγάλης κλίμακας εφαρμογή RLHF σε LLMs. Η θεμελιώδης εργασία RLHF για βαθιά ΕΝ είναι {cite}`christiano2017deep`. Το PPO περιγράφεται στο {cite}`schulman2017proximal`. Το Constitutional AI είναι από {cite}`bai2022constitutional`.

Μάθηση από Επιδείξεις

Όταν ένα έργο είναι δύσκολο να προσδιοριστεί αλλά εύκολο να επιδειχθεί, μπορεί να είναι πιο αποτελεσματικό να διδάσκουμε με παράδειγμα παρά να ορίζουμε με κανόνα. Ένας ανθρώπινος εμπειρογνώμονας δείχνει σε ένα ρομποτικό βραχίονα πώς να πιάσει ένα αντικείμενο· η αλληλεπίδραση ενός προγραμματιστή με το IDE του παρέχει μια ακολουθία σωστών επεξεργασιών· ένας παγκόσμιος πρωταθλητής παίζει ένα παιχνίδι. **Η μάθηση από επιδείξεις** εξάγει μια πολιτική από τέτοια δεδομένα συμπεριφοράς, αποφεύγοντας την ανάγκη για χειροποίητες συναρτήσεις ανταμοιβής ή ρητές προδιαγραφές έργου.

Κλωνοποίηση Συμπεριφοράς

Η απλούστερη προσέγγιση είναι η **κλωνοποίηση συμπεριφοράς (BC)**: αντιμετώπιση της επίδειξης ως εποπτευόμενα δεδομένα και εκμάθηση μιας αντιστοίχισης από καταστάσεις σε ενέργειες.

Δεδομένου ενός συνόλου δεδομένων ζευγαριών κατάσταση-ενέργεια $\mathcal{D} = \{(s_i, a_i)\}$ από έναν εμπειρογνώμονα επιδείκτη, εφαρμόζουμε μια πολιτική $\pi_\theta(a \mid s)$ ελαχιστοποιώντας την αρνητική λογαριθμοπιθανότητα:

$$\mathcal{L}_{\text{BC}}(\theta) = -\frac{1}{|\mathcal{D}|} \sum_{(s,a)\in\mathcal{D}} \log \pi_\theta(a \mid s)$$

Αυτό είναι ακριβώς η τυπική εποπτευόμενη μάθηση εφαρμοζόμενη σε διαδοχικά δεδομένα.

Το Πρόβλημα Μεταβολής Μεταβλητής

Η BC έχει μια θεμελιώδη αδυναμία: **μεταβολή κατανομής** μεταξύ εκπαίδευσης και ανάπτυξης. Οι επιδείξεις του εμπειρογνώμονα καλύπτουν καταστάσεις που επισκέπτεται ο εμπειρογνώμονας. Κατά την ανάπτυξη, όμως, η μαθημένη πολιτική μπορεί να λαμβάνει ελαφρώς διαφορετικές αποφάσεις, οδηγώντας την σε καταστάσεις που ο εμπειρογνώμονας δεν επισκέφθηκε ποτέ — καταστάσεις όπου η πολιτική δεν έχει εποπτεία και μπορεί να αποτύχει άσχημα.

Κρίσιμα, τα σφάλματα **επιδεινώνονται**: μια μικρή απόκλιση οδηγεί σε μια άγνωστη κατάσταση, όπου μια ελαφρώς λανθασμένη ενέργεια οδηγεί σε μια ακόμα πιο άγνωστη κατάσταση, και ούτω καθεξής. Η απόδοση υποβαθμίζεται ως $O(T^2\epsilon)$ όπου T είναι το μήκος επεισοδίου και ϵ είναι ο ρυθμός σφάλματος σε κάθε βήμα — πολύ χειρότερα από την υποβάθμιση $O(T\epsilon)$ μιας πολιτικής μαντείου {cite}`ross2010efficient`.

Παράδειγμα: Αυτόνομη Οδήγηση :class: note

Ένα μοντέλο κλωνοποίησης συμπεριφοράς για διατήρηση λωρίδας εκπαιδευμένο σε δεδομένα ανθρώπινης οδήγησης αποδίδει καλά σε ευθείες δρόμους (καταστάσεις κοντά στην κατανομή εκπαίδευσης). Αλλά τη στιγμή που αποκλίνει ελαφρώς — μια κατάσταση στην οποία κανένας ανθρώπινος οδηγός δεν θα βρισκόταν επειδή θα είχε ήδη διορθώσει — δεν έχει δεδομένα που να το καθοδηγήσουν και μπορεί να βγει εκτός δρόμου.

```
Αλγόριθμος DAgger:
  Αρχικοποίηση: D <- {} (κενό σύνολο δεδομένων)
  Εκπαίδευση αρχικής πολιτικής pi_1 σε M επιδείξεις εμπειρογνώμονα

  για επανάληψη i = 1, 2, ..., N:
    1. Εκτέλεση pi_i στο περιβάλλον για συλλογή καταστάσεων {s_1, ..., s_t}
    2. Ερώτηση εμπειρογνώμονα για ενέργειες σε κάθε κατάσταση: a_t = pi*(s_t)
    3. Συγκέντρωση: D <- D u {(s_1, a_1), ..., (s_t, a_t)}
    4. Εκπαίδευση pi_{i+1} με εποπτευόμενη μάθηση στο D
```

Ο DAgger επιτυγχάνει $O(T\epsilon)$ μετάνοια — ίσο με μια πολιτική μαντείου — επειδή η κατανομή εκπαίδευσης συγκλίνει για να ταιριάξει με την κατανομή ανάπτυξης.

Η βασική απαίτηση είναι ότι ο εμπειρογνώμονας μπορεί να ερωτηθεί για οποιαδήποτε κατάσταση, συμπεριλαμβανομένων καταστάσεων που ο εμπειρογνώμονας δεν θα επισκεπτόταν φυσικά. Αυτό είναι εφικτό στην προσομοίωση (ερώτηση εμπειρογνώμονα για διόρθωση του ρομπότ από ασυνήθιστη διαμόρφωση) αλλά μπορεί να είναι δύσκολο ή μη ασφαλές σε πραγματικά φυσικά συστήματα.

Αντίστροφη Ενισχυτική Μάθηση

Μερικές φορές η συμπεριφορά του εμπειρογνώμονα κατανοείται καλύτερα όχι ως ακολουθία ενεργειών για μίμηση αλλά ως αποτέλεσμα βελτιστοποίησης μιας άγνωστης συνάρτησης ανταμοιβής. Η **Αντίστροφη Ενισχυτική Μάθηση (IRL)** {cite}`ng2000algorithms` ανακτά αυτή τη λανθάνουσα συνάρτηση ανταμοιβής από επιδείξεις.

Δεδομένων επιδείξεων $\tau = \{(s_1, a_1), \ldots, (s_T, a_T)\}$, η IRL βρίσκει μια συνάρτηση ανταμοιβής $R(s, a)$ τέτοια ώστε η πολιτική του εμπειρογνώμονα να είναι βέλτιστη υπό R.

Η έλξη της IRL έναντι της BC: εάν ανακτήσουμε την πραγματική συνάρτηση ανταμοιβής, μπορούμε να την επαναβελτιστοποιήσουμε σε νέα περιβάλλοντα, με διαφορετική δυναμική ή με βελτιωμένα σχέδια — γενικεύοντας πολύ πέρα από τα επιδειχθέντα σενάρια.

MaxEnt IRL

Η **MaxEnt IRL** {cite}`ziebart2008maximum` επιλύει το πρόβλημα ασάφειας IRL (υπάρχουν πολλές συναρτήσεις ανταμοιβής συνεπείς με οποιοδήποτε σύνολο επιδείξεων) επιλέγοντας τη συνάρτηση ανταμοιβής που, ενώ είναι συνεπής με τη συμπεριφορά επίδειξης, οδηγεί σε κατανομή τροχιών με *μέγιστη εντροπία*. Οι τροχιές κατανέμονται ως:

$$P(\tau \mid R) \propto \exp\left(\sum_t R(s_t, a_t)\right)$$

Ο στόχος μάθησης ταιριάζει τις παρατηρούμενες προσδοκίες χαρακτηριστικών του εμπειρογνώμονα $\mu_E = \mathbb{E}_{\tau\sim\pi^*}[\phi(\tau)]$ με τις προσδοκίες χαρακτηριστικών του μοντέλου $\mu_\theta = \mathbb{E}_{\tau\sim\pi_\theta}[\phi(\tau)]$.

GAIL: Γενετική Ανταγωνιστική Μάθηση Μίμησης

Το **GAIL** {cite}`ho2016generative` παρακάμπτει εντελώς τη μάθηση συνάρτησης ανταμοιβής, χρησιμοποιώντας μια GAN-παρόμοια διατύπωση για άμεση αντιστοίχιση της κατανομής κατάσταση-ενέργεια του εμπειρογνώμονα.

Ένας κριτής D_ψ εκπαιδεύεται να διακρίνει ζεύγη κατάσταση-ενέργεια εμπειρογνώμονα $(s, a) \sim \pi^*$ από ζεύγη κατάσταση-ενέργεια πολιτικής $(s, a) \sim \pi_\theta$:

$$\mathcal{L}_D = -\mathbb{E}_{\pi^*}[\log D_\psi(s, a)] - \mathbb{E}_{\pi_\theta}[\log(1 - D_\psi(s, a))]$$

Ο γεννήτρας (η πολιτική π_θ) εκπαιδεύεται να ξεγελά τον κριτή — δηλαδή να παράγει ζεύγη κατάσταση-ενέργεια που μοιάζουν με αυτά του εμπειρογνώμονα. Η έξοδος του κριτή $\log D_\psi(s, a)$ χρησιμεύει ως σήμα ανταμοιβής για την πολιτική.

Το GAIL επιτυγχάνει απόδοση επιπέδου εμπειρογνώμονα σε συνεχείς ελέγχους αναφοράς με πολύ λιγότερες επιδείξεις από την BC, και γενικεύει καλύτερα από το MaxEnt IRL σε σύνθετα περιβάλλοντα.

Κλωνοποίηση Συμπεριφοράς στην ΕΦΓ: Πρακτικό Παράδειγμα

```python
import numpy as np
import torch
import torch.nn as nn
from torch.utils.data import DataLoader, TensorDataset

torch.manual_seed(42)

# ----------------------------------------------
# Toy NLP task: rewriting sentences to be more formal
# We simulate this as a simple sequence transformation
# In practice: fine-tuning a seq2seq model on expert rewrites
# ----------------------------------------------

class SimpleSeq2Seq(nn.Module):
    def __init__(self, vocab_size=100, embed_dim=32, hidden_dim=64):
        super().__init__()
        self.embed = nn.Embedding(vocab_size, embed_dim, padding_idx=0)
        self.encoder = nn.GRU(embed_dim, hidden_dim, batch_first=True)
        self.decoder = nn.GRU(embed_dim, hidden_dim, batch_first=True)
```

```
        self.proj = nn.Linear(hidden_dim, vocab_size)
        self.hidden_dim = hidden_dim

    def forward(self, src, tgt):
        src_emb = self.embed(src)
        _, hidden = self.encoder(src_emb)
        tgt_emb = self.embed(tgt)
        out, _ = self.decoder(tgt_emb, hidden)
        return self.proj(out)

# Generate synthetic demonstration data
VOCAB = 100
rng = np.random.default_rng(42)
N, SEQ_LEN = 1000, 12

src_seqs = torch.tensor(rng.integers(1, VOCAB, (N, SEQ_LEN)), dtype=torch.long)
# "Expert" transformation: shift tokens by 1 (toy formalization)
tgt_seqs = torch.clamp(src_seqs + 1, 1, VOCAB - 1)
tgt_in  = torch.cat([torch.ones(N, 1, dtype=torch.long), tgt_seqs[:, :-1]], dim=1)

dataset = TensorDataset(src_seqs, tgt_in, tgt_seqs)
loader = DataLoader(dataset, batch_size=64, shuffle=True)

model = SimpleSeq2Seq(vocab_size=VOCAB)
optimizer = torch.optim.Adam(model.parameters(), lr=1e-3)
criterion = nn.CrossEntropyLoss(ignore_index=0)

# Behavioral cloning training
train_losses = []
for epoch in range(20):
    epoch_loss = 0
    for src, tgt_i, tgt_o in loader:
        logits = model(src, tgt_i)
        loss = criterion(logits.reshape(-1, VOCAB), tgt_o.reshape(-1))
        optimizer.zero_grad(); loss.backward(); optimizer.step()
        epoch_loss += loss.item()
    train_losses.append(epoch_loss / len(loader))

print(f"Initial loss: {train_losses[0]:.3f}")
print(f"Final loss:   {train_losses[-1]:.3f}")

# Evaluate: check token accuracy on held-out examples
model.eval()
with torch.no_grad():
    src_test = src_seqs[-100:]
    tgt_test_in = tgt_in[-100:]
    tgt_test_out = tgt_seqs[-100:]
    logits = model(src_test, tgt_test_in)
    preds = logits.argmax(dim=-1)
    acc = (preds == tgt_test_out).float().mean().item()
    print(f"Token accuracy on held-out set: {acc:.3f}")
```

Σύγκριση Μεθόδων Μάθησης από Μίμηση

Μέθοδος	Απαιτεί ανταμοιβή;	Εμπειρογνώμονας εν-σύνδεση;	Γενικεύει σε νέα δυναμική;	Πολυπλοκότητα
Κλωνοποίηση Συμπεριφοράς	Όχι	Όχι	Άσχημα (μεταβολή κατανομής)	Χαμηλή
DAgger	Όχι	Ναι	Μέτρια	Μεσαία
MaxEnt IRL	Ανακτά	Όχι	Καλά	Υψηλή
GAIL	Όχι	Όχι	Καλά	Υψηλή

Εφαρμογές

Ρομποτική. Διδασκαλία ρομπότ να χειρίζεται αντικείμενα, να πλοηγείται σε περιβάλλοντα ή να εκτελεί οικιακές εργασίες. Οι φυσικές επιδείξεις συλλέγονται μέσω τηλεχειρισμού ή κινητοποίησης.

Αυτόνομη οδήγηση. Τα πρώτα συστήματα αυτο-οδήγησης όπως το ALVINN {cite}`pomerleau1989alvinn` και το DAVE της NVIDIA βασίστηκαν σε μεγάλο βαθμό στην κλωνοποίηση συμπεριφοράς από δεδομένα ανθρώπινης οδήγησης.

TN Παιχνιδιών. Η μάθηση από μίμηση σε ανθρώπινο gameplay εκκινεί πράκτορες πριν από fine-tuning EN. Το AlphaStar εκπαιδεύτηκε σε αναπαραγωγές ανθρώπων πριν από EN· αυτή η προσέγγιση είναι κοινή όταν υπάρχουν επιδείξεις σε επίπεδο ανθρώπου.

Δημιουργία κώδικα. Το fine-tuning γλωσσικών μοντέλων σε επιδείξεις κώδικα υψηλής ποιότητας (GitHub Copilot, Codex) είναι μια μορφή κλωνοποίησης συμπεριφοράς.

Υποστήριξη κλινικής απόφασης. Μάθηση από ακολουθίες αποφάσεων εμπειρογνωμόνων ιατρών για σύνθετα πρωτόκολλα.

> **See also:** Η θεμελιώδης ανάλυση BC/DAgger βρίσκεται στο {cite}`ross2011reduction`. Το MaxEnt IRL είναι από {cite}`ziebart2008maximum`. Το GAIL είναι από {cite}`ho2016generative`. Για μια ολοκληρωμένη έρευνα μάθησης από μίμηση, βλ. {cite}`osa2018algorithmic`.

Μάθηση από Συγκρίσεις και Κατατάξεις

Να ζητάς από ανθρώπους να αναθέσουν απόλυτη βαθμολογία ποιότητας σε μια έξοδο είναι δύσκολο. Ποια είναι η αριθμητική ποιότητα αυτής της δοκιμής, σε κλίμακα 1 έως 10; Το ερώτημα είναι ακαθόριστο: οι άνθρωποι στερούνται σταθερής εσωτερικής κλίμακας, και οι βαθμολογίες τους επηρεάζονται έντονα από αγκύρωση, πλαίσιο και κόπωση.

Να ζητάς από ανθρώπους να *συγκρίνουν* δύο εξόδους είναι πολύ ευκολότερο: ποια δοκιμή είναι καλύτερη, A ή B; Οι συγκριτικές κρίσεις είναι πιο συνεπείς, πιο αξιόπιστες και αξιοποιούν πιο άμεσα τις ανθρώπινες προτιμήσεις από τις απόλυτες αξιολογήσεις. Αυτό το κεφάλαιο καλύπτει τις μαθηματικές βάσεις και τις πρακτικές εφαρμογές της μάθησης από συγκρίσεις και κατατάξεις.

Γιατί οι Συγκρίσεις Είναι Καλύτερες από τις Αξιολογήσεις

Ψυχομετρική Θεμελίωση

Η υπεροχή των συγκριτικών κρίσεων έχει μακρά ιστορία στην ψυχομετρία. Ο Νόμος Συγκριτικής Κρίσης του Thurstone {cite}`thurstone1927law` (1927) έδειξε ότι ακόμα και όταν οι άνθρωποι έχουν ασυνεπείς απόλυτες κρίσεις, οι σχετικές κρίσεις τους ακολουθούν έναν συνεπή πιθανολογικό νόμο. Οι συγκρίσεις εκμεταλλεύονται το γεγονός ότι οι άνθρωποι είναι πολύ καλύτεροι στην *σχετική* αντίληψη από ότι στην απόλυτη βαθμονόμηση.

Στατιστική Αποτελεσματικότητα

Κάθε ζευγαρωτή σύγκριση παρέχει πληροφορία για τις *σχετικές* θέσεις δύο στοιχείων στην κλίμακα ποιότητας. Με K στοιχεία, $K - 1$ συγκρίσεις μπορούν να κατατάξουν όλα τα στοιχεία· μόνο $O(\log K)$ συγκρίσεις χρειάζονται για να βρούμε το κορυφαίο στοιχείο. Οι απόλυτες αξιολογήσεις συνήθως απαιτούν περισσότερες κρίσεις για να επιτύχουν την ίδια ακρίβεια.

Κλιμακωσιμότητα

Για γεννητικά μοντέλα, ο αριθμός διακριτών εξόδων είναι πρακτικά άπειρος. Η αξιολόγηση μιας εξόδου σε απόλυτους όρους απαιτεί τη δημιουργία κοινής κλίμακας σε όλες τις εξόδους· η σύγκριση εξόδων απαιτεί μόνο τοπικές, σχετικές κρίσεις που βαθμονομούνται φυσικά μεταξύ τους.

Το Μοντέλο Bradley-Terry

Το κυρίαρχο πιθανολογικό μοντέλο για ζευγαρωτές συγκρίσεις είναι το **μοντέλο Bradley-Terry (BT)** {cite}`bradley1952rank`. Κάθε στοιχείο i έχει μια λανθάνουσα βαθμολογία ποιότητας $\alpha_i \in \mathbb{R}$. Η πιθανότητα να προτιμηθεί το στοιχείο i από το στοιχείο j σε άμεση σύγκριση είναι:

$$P(i \succ j) = \frac{e^{\alpha_i}}{e^{\alpha_i} + e^{\alpha_j}} = \sigma(\alpha_i - \alpha_j)$$

όπου σ είναι η λογιστική σιγμοειδής. Αυτό ισοδυναμεί με υπόθεση ότι η αντιληπτή ποιότητα του στοιχείου i είναι $\alpha_i + \epsilon$ όπου ϵ είναι ένας τυπικός λογιστικός όρος θορύβου.

Ταυτοποιησιμότητα

Το μοντέλο BT είναι ταυτοποιήσιμο έως μεταφορά: εάν το α είναι λύση, έτσι είναι και το $\alpha + c$ για οποιαδήποτε σταθερά c. Μια τυπική σύμβαση είναι να κουπώσουμε μία βαθμολογία (π.χ. $\alpha_0 = 0$) ή να περιορίσουμε $\sum_i \alpha_i = 0$. Οι βαθμολογίες εντοπίζονται μόνο όταν ο **γράφος σύγκρισης** (κόμβοι = στοιχεία, ακμές = παρατηρούμενα ζεύγη) είναι **συνδεδεμένος** — εάν ο γράφος έχει αποσυνδεδεμένα συστατικά, οι σχετικές βαθμολογίες σε αυτά τα συστατικά είναι αόριστες.

Εκτίμηση Παραμέτρων

Δεδομένου ενός συνόλου δεδομένων ζευγαρωτών συγκρίσεων $\mathcal{D} = \{(i, j, y_{ij})\}$ όπου $y_{ij} = 1$ εάν προτιμήθηκε το i από το j, η λογαριθμοπιθανότητα είναι:

$$\mathcal{L}(\alpha) = \sum_{(i,j,y_{ij}) \in \mathcal{D}} \left[y_{ij} \log \sigma(\alpha_i - \alpha_j) + (1 - y_{ij}) \log \sigma(\alpha_j - \alpha_i) \right]$$

Αυτή είναι μια κοίλη συνάρτηση του α και μπορεί να μεγιστοποιηθεί μέσω ανόδου κλίσης ή μεθόδου Newton.

```python
import numpy as np
from scipy.optimize import minimize
from scipy.special import expit  # sigmoid

rng = np.random.default_rng(42)

# ----------------------------------------------
# Simulate Bradley-Terry: 8 items with true quality scores
# Generate pairwise comparisons and recover the scores
# ----------------------------------------------

N_ITEMS = 8
true_alpha = rng.normal(0, 1, N_ITEMS)
print(f"True quality ranking: {np.argsort(true_alpha)[::-1]}")

# Generate comparisons: every pair compared 5 times
comparisons = []
for i in range(N_ITEMS):
    for j in range(i + 1, N_ITEMS):
```

```
        for _ in range(5):
            p_i_wins = expit(true_alpha[i] - true_alpha[j])
            winner = i if rng.random() < p_i_wins else j
            loser  = j if winner == i else i
            comparisons.append((winner, loser))

print(f"Total comparisons: {len(comparisons)}")

def neg_log_likelihood(alpha, comparisons):
    """Bradley-Terry negative log-likelihood."""
    alpha = np.array(alpha)
    loss = 0.0
    for winner, loser in comparisons:
        log_prob = np.log(expit(alpha[winner] - alpha[loser]) + 1e-10)
        loss -= log_prob
    return loss

def neg_grad(alpha, comparisons):
    alpha = np.array(alpha)
    grad = np.zeros(len(alpha))
    for winner, loser in comparisons:
        p = expit(alpha[winner] - alpha[loser])
        grad[winner] -= (1 - p)
        grad[loser]  -= (-p)
    return grad

# Fix alpha[0] = 0 to resolve scale ambiguity
result = minimize(
    lambda a: neg_log_likelihood(np.concatenate([[0.0], a]), comparisons),
    x0=np.zeros(N_ITEMS - 1),
    jac=lambda a: neg_grad(np.concatenate([[0.0], a]), comparisons)[1:],
    method='L-BFGS-B'
)
est_alpha = np.concatenate([[0.0], result.x])

# Compare true vs estimated ranking
true_rank = np.argsort(true_alpha)[::-1]
est_rank  = np.argsort(est_alpha)[::-1]

print(f"\nTrue ranking (item indices): {true_rank}")
print(f"Estimated ranking:           {est_rank}")
rank_corr = np.corrcoef(true_alpha, est_alpha)[0, 1]
print(f"Correlation with true scores: {rank_corr:.4f}")
```

Το Μοντέλο Thurstone

Το μοντέλο Thurstone {cite}`thurstone1927law` είναι στενά συνδεδεμένο με το Bradley-Terry αλλά χρησιμοποιεί Γκαουσιανό αντί για λογιστικό θόρυβο:

$$P(i \succ j) = \Phi\left(\frac{\alpha_i - \alpha_j}{\sqrt{2}\sigma}\right)$$

όπου Φ είναι η τυπική κανονική CDF. Όταν $\sigma = 1/\sqrt{2}$, αυτό γίνεται ισοδύναμο με BT με μικρή διαφορά κλίμακας. Στην πράξη, τα δύο μοντέλα δίνουν σχεδόν πανομοιότυπα αποτελέσματα.

Συνάθροιση Κατατάξεων

Όταν κάθε σχολιαστής παρέχει μια πλήρη κατάταξη K στοιχείων (αντί για ζευγαρωτές συγκρίσεις), το πρόβλημα είναι η **συνάθροιση κατατάξεων**: συνδυασμός πολλαπλών κατατεταγμένων λιστών σε μια κατάταξη συναίνεσης.

Μέτρηση Borda: Κάθε στοιχείο λαμβάνει βαθμολογία ίση με τον αριθμό στοιχείων που κατατάσσονται κάτω από αυτό στην κατάταξη κάθε σχολιαστή. Οι βαθμολογίες αθροίζονται σε όλους τους σχολιαστές. Απλό και ανθεκτικό.

Kemeny–Young: Βρίσκει την κατάταξη που ελαχιστοποιεί το άθροισμα ανά-ζεύγος διαφωνιών (η απόσταση Kendall tau) με την κατάταξη κάθε σχολιαστή. Αυτό είναι NP-δύσκολο για μεγάλα K αλλά εφικτό για μικρά σύνολα.

RankNet / ListNet: Νευρωνικές προσεγγίσεις που μαθαίνουν μια συνάρτηση βαθμολόγησης από κατατεταγμένες λίστες, επιτρέποντας γενίκευση σε μη-εμφανισθέντα στοιχεία.

Dueling Bandits

Στη **διαδικτυακή** μάθηση προτίμησης, τα στοιχεία φτάνουν σε ροή και πρέπει να αποφασίσουμε ποια ζεύγη να συγκρίνουμε, εξισορροπώντας εξερεύνηση (μάθηση για άγνωστα στοιχεία) και εκμετάλλευση (παρουσίαση υψηλής ποιότητας στοιχείων). Αυτό είναι το **πρόβλημα dueling bandit** {cite}`yue2009interactively`.

Βασικοί αλγόριθμοι: - **Doubler:** Διατηρεί ένα πρωταθλητή στοιχείο· το προκαλεί με τυχαίους ανταγωνιστές - **RUCB (Σχετικό Άνω Φράγμα Εμπιστοσύνης):** Υπολογίζει διαστήματα εμπιστοσύνης τύπου UCB για την πιθανότητα κάθε στοιχείου να νικά κάθε άλλο στοιχείο - **MergeRank:** Συνδυάζει σύγκριση τύπου τουρνουά με UCB

Τα dueling bandits χρησιμοποιούνται σε διαδικτυακά συστήματα σύστασης (ποιο άρθρο να δείξω στη συνέχεια, δεδομένης σιωπηρής ανατροφοδότησης) και διαδραστική εξαγωγή προτίμησης για συλλογή δεδομένων RLHF.

Μάθηση Προτίμησης για Γλωσσικά Μοντέλα

Στο πλαίσιο του RLHF (Κεφάλαιο 6), το μοντέλο Bradley-Terry χρησιμοποιείται για εκπαίδευση του μοντέλου ανταμοιβής. Μια σημαντική παραλλαγή είναι η **Άμεση Βελτιστοποίηση Προτίμησης (DPO)** {cite}`rafailov2023direct`, που δείχνει ότι ο στόχος RLHF μπορεί να βελτιστοποιηθεί άμεσα από δεδομένα προτίμησης χωρίς εκπαίδευση ξεχωριστού μοντέλου ανταμοιβής:

$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{(x,y_w,y_l)\sim\mathcal{D}}\left[\log\sigma\left(\beta\log\frac{\pi_\theta(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta\log\frac{\pi_\theta(y_l \mid x)}{\pi_{\text{ref}}(y_l \mid x)}\right)\right]$$

Το DPO είναι απλούστερο από το πλήρες RLHF (χωρίς βρόχο εκπαίδευσης PPO, χωρίς μοντέλο ανταμοιβής) επιτυγχάνοντας συγκρίσιμα ή καλύτερα αποτελέσματα σε πολλά αναφοράς {cite}`rafailov2023direct`. Έχει γίνει ευρέως υιοθετημένη εναλλακτική στο RLHF βάσει PPO για fine-tuning ακολούθησης οδηγιών, αν και και οι δύο προσεγγίσεις παραμένουν σε ενεργή χρήση και τα σχετικά τους πλεονεκτήματα εξαρτώνται από το έργο.

Συλλογή Δεδομένων Προτίμησης Υψηλής Ποιότητας

Η ποιότητα των δεδομένων προτίμησης καθορίζει την ποιότητα του μοντέλου ανταμοιβής. Βασικές εκτιμήσεις:

Ποικιλομορφία εντολών. Τα δεδομένα προτίμησης πρέπει να καλύπτουν την πλήρη κατανομή των εντολών που θα συναντήσει το μοντέλο κατά την ανάπτυξη. Κενά κάλυψης οδηγούν σε αναξιόπιστη συμπεριφορά μοντέλου ανταμοιβής σε αυτές τις περιοχές.

Ποικιλομορφία απαντήσεων. Η σύγκριση δύο πολύ παρόμοιων απαντήσεων παρέχει λίγες πληροφορίες. Οι συγκρινόμενες απαντήσεις πρέπει να διαφέρουν αρκετά ώστε οι σχολιαστές να έχουν σαφή προτίμηση.

Συμφωνία σχολιαστών. Χαμηλή συμφωνία μεταξύ σχολιαστών υποδηλώνει ότι τα κριτήρια σύγκρισης είναι ασαφή. Μετρήστε τη συμφωνία (κάππα Cohen) και αναθεωρήστε τις οδηγίες όταν είναι κάτω από αποδεκτά κατώφλια.

Βαθμονόμηση. Οι σχολιαστές πρέπει να κατανοούν *γιατί* μια απάντηση είναι καλύτερη: χρησιμότητα, ακρίβεια, ασφάλεια, στυλ; Τα έργα που ομαδοποιούν πολλαπλά κριτήρια τείνουν να παράγουν ασυνεπείς προτιμήσεις. Είναι συχνά καλύτερο να συλλέγουμε προτιμήσεις για κάθε κριτήριο ξεχωριστά.

> **See also:** Μοντέλο Bradley-Terry: {cite}`bradley1952rank`. Thurstone: {cite}`thurstone1927law`. Dueling bandits: {cite}`yue2009interactively`. Άμεση Βελτιστοποίηση Προτίμησης (DPO): {cite}`rafailov2023direct`.

Ανθρωποκεντρική ΜΜ στην Επεξεργασία Φυσικής Γλώσσας

Η φυσική γλώσσα είναι ο τομέας όπου η HITL ML έχει αναμφίβολα τον μεγαλύτερο αντίκτυπο — και όπου αναδύονται οι βαθύτερες εννοιολογικές δυσκολίες της. Η γλώσσα είναι εγγενώς κοινωνική: το νόημά της κατασκευάζεται από ανθρώπινες κοινότητες, η πραγματολογία της εξαρτάται από το πλαίσιο και την πρόθεση, και η ποιότητά της μπορεί να κριθεί μόνο από ανθρώπους αναγνώστες. Αλλά αυτό σημαίνει επίσης ότι ο σχολιασμός ΕΦΓ δεν είναι απλώς διαδικασία συλλογής παρατηρήσεων. Είναι διαδικασία *κατασκευής* κατηγοριών.

Το Συγκροτητικό Πρόβλημα στον Σχολιασμό ΕΦΓ

Στην ιατρική απεικόνιση, υπάρχει αλήθεια: ένας όγκος παρευρίσκεται ή δεν παρευρίσκεται. Η ετικέτα του ακτινολόγου μπορεί να είναι αβέβαιη, αλλά προσπαθεί να παρακολουθήσει κάτι πραγματικό. Ο σχολιασμός ΕΦΓ είναι συχνά θεμελιωδώς διαφορετικός. Όταν ένας σχολιαστής χαρακτηρίζει ένα tweet ως «τοξικό», δεν υπάρχει τοξικό μόριο στο tweet που προσπαθούμε να εντοπίσουμε. **Η ετικέτα συγκροτεί την κατηγορία.**

Αυτό έχει βαθιές συνέπειες που συχνά δεν εκτιμώνται επαρκώς:

Το εργατικό δυναμικό σχολιασμού ορίζει το φαινόμενο. Ένα σχήμα ετικετών για «προσβλητική ομιλία» κωδικοποιεί τις ευαισθησίες όποιου το σχεδίασε και όποιου το εφάρμοσε. Μια ομάδα αγγλόφωνων σχολιαστών από ένα μόνο δημογραφικό υπόβαθρο, που εργάζεται υπό οδηγίες γραμμένες από εταιρική ομάδα πολιτικής, παράγει ένα σύνολο δεδομένων που αντικατοπτρίζει την κατανόηση εκείνης της ομάδας για την προσβολή — όχι κάποιο παγκόσμιο ανθρώπινο πρότυπο. Τα μοντέλα εκπαιδευμένα σε τέτοια δεδομένα θα εμφανίζουν τα ίδια σιωπηρά όρια.

Οι οδηγίες είναι θεωρία, είτε το αναγνωρίζουν είτε όχι. Κάθε σχήμα σχολιασμού κάνει ισχυρισμούς για οντολογία. Η απόφαση ότι «ειρωνεία» και «σαρκασμός» είναι η ίδια κλάση είναι θεωρητικός ισχυρισμός, όχι ουδέτερη ευκολία. Η απόφαση να επισημανθεί ο «θυμός» ως μία κλάση αντί να διακριθεί ο «δίκαιος θυμός» από τον «εχθρικό θυμός» καταρρέει μια διάκριση που μπορεί να έχει σημασία για το έργο κατάντη. Αυτές οι αποφάσεις λαμβάνονται υπό πίεση παραγωγής και σπάνια επανεξετάζονται.

Αστάθεια ετικετών με την πάροδο του χρόνου. Η κοινωνική γλώσσα εξελίσσεται. Ένα μοντέλο τοξικότητας εκπαιδευμένο το 2018 θα κατατάξει λανθασμένα περιεχόμενο του 2024 όχι επειδή είναι στατιστικά ανεπαρκώς εκπαιδευμένο, αλλά επειδή η κοινωνική σημασία ορισμένων όρων έχει αλλάξει. Ο σχολιασμός ΕΦΓ δεν δειγματοληπτεί από

μια στατική κατανομή — δειγματοληπτεί από ένα κινούμενο στόχο που η πράξη της επισήμανσης συμβάλλει εν μέρει στη συγκρότησή του.

:::{admonition} Το Πρόβλημα Τεχνουργημάτων Σχολιασμού :class: important

Οι Geva et al. {cite}`geva2019annotator` απέδειξαν ότι τα σύνολα δεδομένων NLI (Φυσική Γλωσσική Εξαγωγή Συμπεράσματος) περιέχουν συστηματικά τεχνουργήματα που εισάγονται από την ίδια τη διαδικασία σχολιασμού. Οι σχολιαστές που καλούνται να γράψουν υποθέσεις «συνεπαγωγής» για μια δεδομένη πρόταση τείνουν να χρησιμοποιούν ορισμένα συντακτικά μοτίβα· οι σχολιαστές που γράφουν υποθέσεις «αντίφασης» χρησιμοποιούν άλλα. Τα μοντέλα μαθαίνουν να ταξινομούν βάσει αυτών των τεχνουργημάτων παρά της προβλεπόμενης σημασιολογικής σχέσης — λύνουν το έργο σχολιασμού, όχι το υποκείμενο έργο ΕΦΓ.

Αυτό δεν είναι αμέλεια. Είναι εγγενής συνέπεια του να έχουμε ανθρώπους να κατασκευάζουν παραδείγματα για να ταιριάζουν με μια ετικέτα. Η διαδικασία HITL εισάγει ένα συστηματικό σήμα που δεν προοριζόταν ποτέ να είναι στα δεδομένα. :::

Σχολιασμός Ταξινόμησης Κειμένου

Η απλούστερη εργασία σχολιασμού ΕΦΓ είναι η ανάθεση κατηγορίας σε ένα έγγραφο κειμένου. Η ανάλυση συναισθημάτων, η θεματική ταξινόμηση, η ανίχνευση πρόθεσης και το φιλτράρισμα ανεπιθύμητης αλληλογραφίας είναι όλες εργασίες ταξινόμησης.

Προκλήσεις ειδικά για ταξινόμηση κειμένου:

Υποκειμενικότητα. Κατηγορίες όπως «τοξικό» ή «προσβλητικό» είναι εγγενώς υποκειμενικές και ποικίλλουν ανά πολιτισμικά πλαίσια, δημογραφικά στοιχεία σχολιαστών και πλαίσιο πλατφόρμας. Μεταξύ σχολιαστών, οι αντιλήψεις για την προσβολή διαφέρουν σημαντικά ανά δημογραφικό — ένα γεγονός με άμεσες συνέπειες για τη δικαιοσύνη {cite}`blodgett2020language`.

Ασάφεια ετικέτας. Πολλά έγγραφα ανήκουν σε πολλαπλές κατηγορίες ή βρίσκονται σε ένα όριο. Μια κριτική που είναι 60% θετική και 40% αρνητική είναι γνησίως ασαφής, όχι λανθασμένα επισημασμένη. Η εξαναγκαστική μία ετικέτα απορρίπτει πραγματικές πληροφορίες (βλ. Κεφάλαιο 13 για ήπιες ετικέτες και διαφωνία σχολιαστών).

Κοκκομετρία ετικέτας. Ένα μοντέλο συναισθήματος 2 κλάσεων μπορεί να είναι επαρκές για παρακολούθηση κοινωνικών μέσων· μια κλίμακα 7 σημείων μπορεί να είναι απαραίτητη για ανάλυση σχολίων προϊόντων. Η σωστή κοκκομετρία εξαρτάται από το έργο κατάντη, αλλά συνήθως ορίζεται πριν τον σχολιασμό — μια συνέπεια σχεδιαστική απόφαση που λαμβάνεται με ανεπαρκή δεδομένα.

Αναγνώριση Ονομαστικών Οντοτήτων

Ο σχολιασμός NER απαιτεί εντοπισμό εκτάσεων κειμένου και ανάθεση τύπου οντότητας (PERSON, ORGANIZATION, LOCATION κ.λπ.). Ο σχολιασμός είναι πιο σύνθετος από την ταξινόμηση εγγράφων για πολλούς λόγους:

Τα όρια εκτάσεων είναι ασαφή. Στη φράση «Apple CEO Tim Cook announced…», η οντότητα PERSON καλύπτει «Tim Cook» ή «Apple CEO Tim Cook»; Οι οδηγίες πρέπει να

αντιμετωπίζουν ρητά αυτές τις περιπτώσεις, και η συμφωνία μεταξύ σχολιαστών για εκτάσεις είναι σταθερά χαμηλότερη από ότι για τύπους.

Η ανάθεση τύπου απαιτεί κοσμογνωσία. «Apple» είναι ORG σε ένα πλαίσιο, PRODUCT σε άλλο, και ανεπίσημα κανένα από τα δύο στο «apple pie». Οι σχολιαστές χρειάζονται επαρκή γνώση τομέα για σωστές αναθέσεις τύπου.

Ένθετες οντότητες. «The University of California, Berkeley» περιέχει ORGANIZATION ένθετο εντός LOCATION. Η τυπική ετικετοποίηση BIO δεν μπορεί να αναπαραστήσει ένθετες οντότητες· απαιτούνται πιο σύνθετα σχήματα (π.χ. BIOES, ή μορφές βάσει γράφου).

Αποτελεσματικότητα σχολιασμού. Ο προ-σχολιασμός με μοντέλο βάσης NER επιταχύνει σημαντικά τον σχολιασμό επιτρέποντας στους σχολιαστές να διορθώνουν προβλέψεις αντί να σχολιάζουν από μηδέν. Σε μία μελέτη κλινικής NER, παρατηρήθηκαν αυξήσεις απόδοσης 30–60% {cite}`lingren2014evaluating`· το μέγεθος τέτοιων κερδών εξαρτάται σε μεγάλο βαθμό από την ποιότητα του βασικού μοντέλου και τον τομέα.

Εξαγωγή Σχέσεων και Σημασιολογικός Σχολιασμός

Πέρα από τον εντοπισμό οντοτήτων, η εξαγωγή σχέσεων απαιτεί σχολιασμό *σχέσεων* μεταξύ οντοτήτων:

- Οι σχολιαστές πρέπει να κατανοούν τόσο τις οντότητες όσο και το κατηγόρημα που τις συνδέει
- Οι τύποι σχέσεων έχουν σύνθετες σημασιολογικές διακρίσεις (WORKS_AT vs. EMPLOYED_BY vs. FOUNDED)
- Τα αρνητικά παραδείγματα (ζεύγη οντοτήτων χωρίς σχέση) είναι πολύ πιο κοινά από τα θετικά

Η συμφωνία μεταξύ σχολιαστών για εξαγωγή σχέσεων τείνει να είναι χαμηλότερη από ότι για εργασίες ταξινόμησης. Για καλά ορισμένα σχήματα, οι τιμές κ στην περιοχή 0,65–0,80 αναφέρονται κοινώς {cite}`pustejovsky2012natural`· για σύνθετες σημασιολογικές σχέσεις (αιτιότητα γεγονότος, χρονικές σχέσεις), η συμφωνία μπορεί να πέσει σημαντικά χαμηλότερα, ανάλογα με τον σχεδιασμό σχήματος και την εκπαίδευση σχολιαστών.

Μετα-Επεξεργασία Μηχανικής Μετάφρασης (MTPE)

Η μετα-επεξεργασία μηχανικής μετάφρασης είναι μια ώριμη μορφή HITL ΕΦΓ. Ένας ανθρώπινος μεταφραστής διορθώνει την έξοδο ενός συστήματος MT αντί να μεταφράζει από μηδέν:

Ελαφριά μετα-επεξεργασία (LPE): Διορθώνονται μόνο κρίσιμα σφάλματα. Κατάλληλο όταν οι απαιτήσεις ποιότητας μετάφρασης είναι μέτριες.

Πλήρης μετα-επεξεργασία (FPE): Η έξοδος διορθώνεται σε επίπεδο δημοσίευσης. Η επεξεργασμένη έξοδος συνήθως γίνεται δεδομένα εκπαίδευσης για περαιτέρω βελτίωση MT — ένας γνήσιος κύκλος βελτίωσης ανθρώπου-στον-βρόχο.

HTER (Ανθρώπινο Ποσοστό Επεξεργασίας Μετάφρασης στόχου): Μια μετρική που μετρά την απόσταση επεξεργασίας μεταξύ εξόδου MT και μετα-επεξεργασμένης

μετάφρασης, κανονικοποιημένη κατά μήκος πρότασης {cite}`graham2015accurate`. Ως κατά προσέγγιση πρακτικός κανόνας, HTER κάτω από περίπου 0,3 θεωρείται συχνά καλή έξοδος MT· πάνω από 0,5, η μετάφραση από μηδέν μπορεί να είναι ταχύτερη — αν και αυτά τα κατώφλια ποικίλλουν κατά τομέα και γλωσσικό ζεύγος.

Διάλογος και Σχολιασμός Συνομιλίας

Ο σχολιασμός διαλόγου εισάγει χρονική δομή:

- **Σχολιασμός επιπέδου γύρου:** ετικέτα κάθε γύρου (πρόθεση, συναίσθημα, ποιότητα)
- **Σχολιασμός επιπέδου διαλόγου:** αξιολόγηση συνολικής συνοχής, επιτυχίας έργου, ικανοποίησης χρήστη
- **Σχολιασμός ίχνους αλληλεπίδρασης:** εντοπισμός συγκεκριμένων στιγμών αποτυχίας σε μια συνομιλία

Το HITL είναι ιδιαίτερα σημαντικό στον διάλογο επειδή οι αποτυχίες μοντέλου είναι συχνά λεπτές και σωρευτικές: ένα πραγματολογικό σφάλμα στον γύρο 3 μπορεί να μην γίνει εμφανές μέχρι τον γύρο 7. Οι ανθρώπινοι σχολιαστές που ιχνηλατούν συνομιλίες μπορούν να εντοπίσουν αυτά τα μακρο-αποτυχημένα μοτίβα που οι αυτοματοποιημένες μετρικές αδυνατούν να εντοπίσουν.

Προγραμματική Επισήμανση και Αδύναμη Εποπτεία

Όταν τα επισημασμένα δεδομένα είναι σπάνια, η **αδύναμη εποπτεία** επιτρέπει τη χρήση πολλαπλών θορυβωδών, επικαλυπτόμενων συναρτήσεων επισήμανσης για δημιουργία πιθανολογικών ετικετών σε κλίμακα. Το **Snorkel** {cite}`ratner2017snorkel` είναι το κανονικό πλαίσιο:

```
import numpy as np
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import f1_score

rng = np.random.default_rng(42)

# ------------------------------------------------------
# Toy weak supervision: sentiment classification
# 5 labeling functions (LFs) with different coverage/accuracy
# Label: +1 (positive), -1 (negative), 0 (abstain)
# ------------------------------------------------------

N = 1000
true_labels = rng.choice([-1, 1], size=N)
X_features = np.column_stack([
    true_labels * 0.8 + rng.normal(0, 0.5, N),
    rng.normal(0, 1, N),
    rng.normal(0, 1, N),
])

def make_lf(accuracy, coverage, seed):
```

```
    rng_lf = np.random.default_rng(seed)
    votes = np.zeros(N, dtype=int)
    active = rng_lf.random(N) < coverage
    correct = rng_lf.random(N) < accuracy
    votes[active & correct]  = true_labels[active & correct]
    votes[active & ~correct] = -true_labels[active & ~correct]
    return votes

LFs = np.column_stack([
    make_lf(accuracy=0.85, coverage=0.60, seed=1),
    make_lf(accuracy=0.78, coverage=0.45, seed=2),
    make_lf(accuracy=0.70, coverage=0.80, seed=3),
    make_lf(accuracy=0.90, coverage=0.30, seed=4),
    make_lf(accuracy=0.60, coverage=0.90, seed=5),
])

def majority_vote(LF_matrix):
    labels = []
    for i in range(LF_matrix.shape[0]):
        votes = LF_matrix[i][LF_matrix[i] != 0]
        labels.append(0 if len(votes) == 0 else int(np.sign(votes.sum())))
    return np.array(labels)

mv_labels = majority_vote(LFs)
covered = mv_labels != 0

print(f"Coverage:                    {covered.mean():.1%}")
print(f"MV accuracy (covered):       {(mv_labels[covered] == true_labels[covered]).mean():.3f

X_train, y_train = X_features[covered], mv_labels[covered]
X_test,  y_test  = X_features[~covered], true_labels[~covered]

if len(X_train) > 10 and len(X_test) > 10:
    clf = LogisticRegression().fit(X_train, y_train)
    preds = clf.predict(X_test)
    print(f"F1 on uncovered test set:    {f1_score(y_test, preds):.3f}")
```

RLHF για Γλωσσικά Μοντέλα: Η Πραγματικότητα Σχολιασμού

Το Κεφάλαιο 6 κάλυψε το RLHF τεχνικά. Από την οπτική ΕΦΓ, το έργο σχολιασμού είναι πιο δύσκολο από ότι φαίνεται εξωτερικά.

Αυτό που πραγματικά ζητείται από τους σχολιαστές — να συγκρίνουν δύο εξόδους μοντέλου και να υποδείξουν ποια είναι «καλύτερη» — ακούγεται απλό. Στην πράξη, το «καλύτερη» είναι μια ανεπαρκώς ορισμένη κατασκευή που οι σχολιαστές επιλύουν χρησιμοποιώντας προσωπικές ευρεστικές. Ορισμένοι βαραίνουν πολύ τη ροή· άλλοι βαραίνουν την πραγματολογική ακρίβεια· άλλοι τιμωρούν τη λεκτικότητα. Χωρίς αυστηρές οδηγίες, το προκύπτον σύνολο δεδομένων προτίμησης αντικατοπτρίζει όχι τις ανθρώπινες αξίες αφηρημένα αλλά τις συγκεκριμένες στρατηγικές επίλυσης του χρησιμοποιούμενου εργατικού δυναμικού σχολιασμού.

Οι βασικές διαστάσεις σχολιασμού είναι:

- *Χρησιμότητα:* Απαντά καλά η απάντηση στο ερώτημα; Είναι ενημερωτική, σαφής και κατάλληλα λεπτομερής;
- *Πραγματολογικότητα:* Είναι η απάντηση πραγματολογικά ακριβής; Αυτό απαιτεί από τους αξιολογητές να έχουν γνώση τομέα — μια απαίτηση που δημιουργεί σοβαρά προβλήματα ποιότητας σε κλίμακα, καθώς οι γενικοί σχολιαστές δεν μπορούν να επαληθεύσουν ισχυρισμούς ειδικών.
- *Αβλαβότητα:* Αποφεύγει η απάντηση τοξικό, μεροληπτικό, βλαβερό ή ακατάλληλο περιεχόμενο; Αυτές οι κρίσεις απαιτούν λεπτομερείς οδηγίες επειδή το «βλαβερό» εξαρτάται ισχυρά από το πλαίσιο και μεταβάλλεται ανά πολιτισμό, χρόνο και πλαίσιο πλατφόρμας.
- *Βαθμονόμηση:* Εκφράζει η απάντηση κατάλληλη αβεβαιότητα; Οι σχολιαστές προτιμούν συστηματικά απαντήσεις που ακούγονται σίγουρες, πράγμα που δημιουργεί σήμα ανταμοιβής κατά της κατάλληλης επιστημικής ταπεινοφροσύνης.

Η αλληλεπίδραση μεταξύ κριτηρίων είναι σύνθετη: η μέγιστα χρήσιμη απάντηση σε ένα επικίνδυνο ερώτημα μπορεί να είναι μέγιστα βλαβερή. Οι οδηγίες πρέπει να προσδιορίζουν πώς να αντισταθμίζονται ανταγωνιστικά κριτήρια — και αυτές οι αντισταθμίσεις είναι αποτελεσματικά αποφάσεις πολιτικής, όχι αποφάσεις σχολιασμού. Το εργατικό δυναμικό σχολιασμού κάνει πολιτική.

Η κλίμακα συγκεντρώνει δημογραφική επιρροή. Το RLHF για μεγάλα μοντέλα περιλαμβάνει σχετικά μικρά εργατικά δυναμικά σχολιασμού (εκατοντάδες έως λίγες χιλιάδες) που λαμβάνουν δισεκατομμύρια αποφάσεις κατάντη. Οι δημογραφικές και πολιτισμικές προκαταλήψεις αυτού του εργατικού δυναμικού μεταδίδονται στη συμπεριφορά του μοντέλου σε κλίμακα με τρόπο που δεν θα συνέβαινε εάν ο σχολιασμός ήταν πιο κατανεμημένος. Αυτό είναι ένα από τα λιγότερο συζητημένα δομικά προβλήματα στον τρέχοντα αγωγό RLHF.

Ο Βρόχος Ανατροφοδότησης Σχολιασμού–Μοντέλου

Στην ΕΦΓ περισσότερο από οποιονδήποτε άλλον τομέα, οι διαδικασίες σχολιασμού και ανάπτυξης μοντέλου εμπλέκονται με την πάροδο του χρόνου:

1. Οι σχολιαστές βαθμονομούνται χρησιμοποιώντας τις υπάρχουσες εξόδους του μοντέλου ως αναφορά (συχνά σιωπηρά).
2. Το μοντέλο ανταμοιβής μαθαίνει τι τείνουν να προτιμούν οι σχολιαστές.
3. Ο γεννήτρας κάνει fine-tune για να παράγει εξόδους που παίρνουν υψηλή ανταμοιβή.
4. Αυτές οι έξοδοι επηρεάζουν το πώς φαίνεται το «καλό» στους επόμενους γύρους σχολιασμού.

Αυτός ο βρόχος ανατροφοδότησης δεν είναι εγγενώς παθολογικός — είναι αυτό που επιτρέπει στο RLHF να συγκλίνει — αλλά σημαίνει ότι η συμπεριφορά του μοντέλου διαμορφώνεται από έναν κινούμενο στόχο που η διαδικασία σχολιασμού βοηθά να κινείται. Η διάκριση μεταξύ αυτού που το μοντέλο έμαθε επειδή αντικατοπτρίζει ανθρώπινες προτιμήσεις και αυτού που έμαθε επειδή έμαθε να αντιστοιχίζει ευρεστικές σχολιαστών είναι εμπειρικά δύσκολη.

Δεν υπάρχει καθαρή λύση. Η καλύτερη τρέχουσα πρακτική είναι να παρακολουθούμε για ανάπτυξη χρησιμοποιώντας κρατημένες κρίσεις προτίμησης που συλλέγονται σε τακτά διαστήματα, και να αντιμετωπίζουμε την έκδοση οδηγιών σχολιασμού ως πειραματική

μεταβλητή.

Αξιολόγηση Γεννητικών Μοντέλων ΕΦΓ

Σε αντίθεση με τα μοντέλα ταξινόμησης με σαφή μετρική ακρίβειας, η αξιολόγηση της ποιότητας παραγωγής απαιτεί ανθρώπινη κρίση:

Μέθοδος αξιολόγησης	Περιγραφή	Κόστος
Άμεση Αξιολόγηση (DA)	Σχολιαστές αξιολογούν ποιότητα σε κλίμακα	Μεσαίο
Συγκριτική κρίση	Σχολιαστές συγκρίνουν δύο εξόδους	Χαμηλό
MQM (Πολυδιαστατικές Μετρικές Ποιότητας)	Δομημένη ταξινομία σφαλμάτων	Υψηλό
Προτίμηση RLHF	Ετικέτες προτίμησης για εκπαίδευση	Μεσαίο
LLM-ως-κριτής	LLM βαθμολογεί εξόδους (συσχετίζεται μέτρια με ανθρώπινες)	Πολύ χαμηλό
BERTScore, BLEU	Αυτόματες μετρικές (ατελής συσχέτιση με ανθρώπινη κρίση)	Πολύ χαμηλό

Οι αυτόματες μετρικές (BLEU για MT, ROUGE για περίληψη) είναι φθηνές αλλά ατελώς συσχετισμένες με ανθρώπινες κρίσεις ποιότητας {cite}`reiter2018structured`. Οι προσεγγίσεις LLM-ως-κριτής δείχνουν μέτρια συμφωνία με ανθρώπινους σχολιαστές {cite}`zheng2023judging` και χρησιμοποιούνται ολοένα και περισσότερο για γρήγορες επαναλήψεις, αλλά δεν πρέπει να αντικαθιστούν την ανθρώπινη αξιολόγηση για τελικές εκτιμήσεις. Για αποφάσεις με πραγματικά διακυβεύματα, η ανθρώπινη αξιολόγηση παραμένει απαραίτητη.

> **See also:** Αδύναμη εποπτεία Snorkel: {cite}`ratner2017snorkel`. Οδηγίες σχολιασμού ΕΦΓ: {cite}`pustejovsky2012natural`. Τεχνουργήματα σχολιασμού στο NLI: {cite}`geva2019annotator`. Προκατάληψη σχολιαστών και σύνολα δεδομένων ΕΦΓ: {cite}`blodgett2020language`. Για αξιολόγηση γεννητικών μοντέλων: {cite}`reiter2018structured`.

Ανθρωποκεντρική ΜΜ στην Υπολογιστική Όραση

Η υπολογιστική όραση παρέχει μερικά από τα πιο οπτικά διαισθητικά παραδείγματα HITL ML. Η πρόκληση ImageNet, χτισμένη σε 14 εκατομμύρια εικόνες με ανθρώπινες ετικέτες, εκκίνησε την εποχή βαθιάς μάθησης. Ο σχολιασμός ιατρικής απεικόνισης από ακτινολόγους τροφοδοτεί διαγνωστική ΤΝ. Τα αυτόνομα οχήματα εξαρτώνται από εκατομμύρια καρέ με ανθρώπινες ετικέτες για να μάθουν να αντιλαμβάνονται τον κόσμο.

Αυτό που εύκολα χάνεται: αυτά δεν είναι απλώς περιπτώσεις ανθρώπων που παρέχουν αλήθεια εδάφους. Είναι περιπτώσεις ανθρώπων που κατασκευάζουν σύνολα δεδομένων που ενσωματώνουν συγκεκριμένες αντιληπτικές, πολιτισμικές και λειτουργικές επιλογές — επιλογές που γίνονται ορατές μόνο αργότερα, όταν τα μοντέλα αποτυγχάνουν με προβλέψιμους τρόπους.

Πώς οι Επιλογές Σχολιασμού Γίνονται Προκαταλήψεις Μοντέλου

Το τυπικό πλαίσιο αντιμετωπίζει τον σχολιασμό ως συλλογή δεδομένων: οι άνθρωποι παρατηρούν τον κόσμο και καταγράφουν αυτό που βλέπουν. Το πιο ακριβές πλαίσιο είναι ότι ο σχολιασμός είναι *σχεδιασμός συνόλου δεδομένων*: οι άνθρωποι αποφασίζουν ποιες κατηγορίες να χρησιμοποιήσουν, πού να χαράξουν τα όρια, ποιες οριακές περιπτώσεις να συμπεριλάβουν και πώς να επιλύουν ασάφεια — και όλες αυτές οι αποφάσεις διαμορφώνουν αυτό που θα αντιλαμβάνεται το εκπαιδευμένο μοντέλο.

Η Περίπτωση ImageNet

Το ImageNet {cite}`russakovsky2015imagenet` είναι το πιο σημαντικό σύνολο δεδομένων στην ιστορία της υπολογιστικής όρασης. Το σύνολο ετικετών του προκύπτει από WordNet synsets, επιλεγμένα κυρίως επειδή ήταν πολυάριθμα και σημασιολογικά διακριτά. Αρκετές συνέπειες αυτής της επιλογής σχεδιασμού αναδύθηκαν χρόνια αργότερα:

- **Οι κατηγορίες προσώπων κωδικοποιούσαν δημογραφικές συσχετίσεις.** Πρώιμες εκδόσεις των ετικετών συνόλου ImageNet για ανθρώπους περιλάμβαναν πολλές που τώρα θα θεωρούνταν υποτιμητικές ή μεροληπτικές, αντικατοπτρίζοντας τόσο την ιστορική πηγή WordNet όσο και τις σιωπηρές αποφάσεις του εργατικού δυναμικού σχολιασμού για το ποιες ετικέτες να εφαρμόσουν σε ποιες εικόνες {cite}`yang2020towards`. Οι ετικέτες που εφαρμόζονταν σε εικόνες ανθρώπων κωδικοποιούσαν φυλετικές, φυλετικές και ταξικές συσχετίσεις που μεταδόθηκαν άμεσα στις ενσωματώσεις μοντέλου.

- **Λεπτομερής ταξινόμηση ειδών, αδρή ταξινόμηση σχεδόν όλων των άλλων.** Το ImageNet μπορεί να διακρίνει 120 φυλές σκύλων αλλά καταρρέει τεράστιες παραλλαγές σε εργαλεία, οχήματα, τρόφιμα και έπιπλα σε μεμονωμένες κατηγορίες. Αυτό ήταν συνέπεια της ακολούθησης της δομής WordNet, όχι σκόπιμη επιλογή για το τι έχει σημασία. Τα μοντέλα εκπαιδευμένα στο ImageNet εμφανίζουν την ίδια ασύμμετρη ακρίβεια.
- **Δυτικές, αγγλόφωνες οπτικές προκαταλήψεις.** Οι εικόνες συλλέχθηκαν κυρίως από το Flickr και αναζητήσεις διαδικτύου με αγγλόφωνα ερωτήματα. Η προκύπτουσα κατανομή παρεκκλίνει έντονα προς το οπτικό περιβάλλον και τα πολιτισμικά αντικείμενα πλούσιων, αγγλόφωνων χωρών.

Τίποτα από αυτά δεν ήταν σφάλματα. Ήταν επιλογές σχεδιασμού σχολιασμού που έγιναν γρήγορα σε κλίμακα, συχνά από ανθρώπους που δεν προέβλεπαν πώς θα χρησιμοποιηθεί το σύνολο δεδομένων. Το δίδαγμα δεν είναι ότι το ImageNet έπρεπε να είχε χτιστεί διαφορετικά (αν και έπρεπε), αλλά ότι **ο σχεδιασμός σχολιασμού είναι σχεδιασμός μοντέλου**, και πρέπει να αντιμετωπίζεται με την ίδια επιμέλεια.

:::{admonition} Το σχήμα σχολιασμού είναι θεωρία του κόσμου :class: note

Κάθε ταξινομία ετικετών κάνει ισχυρισμούς για το ποιες διακρίσεις έχουν σημασία. Η επιλογή διαχωρισμού «αυτοκίνητο» από «φορτηγό» ενώ καταρρέουν όλα τα σεντάν σε μία κλάση είναι θεωρητικός ισχυρισμός για το ποιες διακρίσεις είναι σημασιολογικά σχετικές. Η επιλογή σχολιασμού «άτομο» ως μία κλάση ανεξαρτήτως στάσης, ρούχων ή δραστηριότητας είναι διαφορετικός θεωρητικός ισχυρισμός. Τα μοντέλα εκπαιδευμένα σε αυτά τα σχήματα θα κάνουν τις ίδιες διακρίσεις, και τίποτα περισσότερο — δεν θα γενικεύσουν πέρα από τις κατηγορίες που εκπαιδεύτηκαν να διακρίνουν. :::

Σχολιασμός Ταξινόμησης Εικόνας

Η απλούστερη εργασία σχολιασμού CV είναι η ανάθεση μίας ή περισσότερων ετικετών σε μια ολόκληρη εικόνα.

Ιεραρχία ετικετών. Η ετικέτα «σκύλος» είναι θυγατρική της «ζώο» σε μια σημασιολογική ιεραρχία. Τα μοντέλα εκπαιδευμένα σε επίπεδες ταξινομίες μπορεί να μην γενικεύουν καλά σε επίπεδα αφαίρεσης. Το ImageNet χρησιμοποιεί ιεραρχία βάσει synset που επιτρέπει αξιολόγηση σε πολλαπλά επίπεδα ειδικότητας.

Ασάφεια πολλαπλών ετικετών. Μια αστική σκηνή μπορεί να περιέχει ταυτόχρονα αυτοκίνητο, άτομο, ποδήλατο και φωτεινό σηματοδότη. Η απόφαση ποιες ετικέτες να συμπεριλαμβάνονται απαιτεί σαφείς οδηγίες σχετικά με τα κατώφλια σχετικότητας.

Κατανομές μακράς ουράς. Τα φυσικά σύνολα δεδομένων εικόνας ακολουθούν νόμο δύναμης: μερικές κατηγορίες είναι εξαιρετικά κοινές· οι περισσότερες είναι σπάνιες. Η ενεργός μάθηση είναι ιδιαίτερα πολύτιμη για κατηγορίες μακράς ουράς όπου η τυχαία δειγματοληψία αποδίδει μόνο ελάχιστα παραδείγματα.

Ανίχνευση Αντικειμένων: Σχολιασμός Οριοθετικών Πλαισίων

Η ανίχνευση αντικειμένων απαιτεί από τους σχολιαστές να σχεδιάζουν οριοθετικά πλαίσια ευθυγραμμισμένα με τους άξονες γύρω από στιγμιότυπα κάθε κλάσης

αντικειμένου. Αυτό εισάγει απαιτήσεις γεωμετρικής ακρίβειας και σημαντικές οριακές περιπτώσεις.

Μετρικές ποιότητας σχολιασμού:

Η *IoU (Τομή επί Ένωσης)* μετρά την επικάλυψη μεταξύ ενός σχολιασμένου πλαισίου και ενός πλαισίου αναφοράς:

$$\mathrm{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

IoU ≥ 0.5 είναι το τυπικό κατώφλι για «σωστή» ανίχνευση στο PASCAL VOC· το COCO {cite}`lin2014microsoft` χρησιμοποιεί εύρος κατωφλιών από 0,5 έως 0,95, που είναι πολύ πιο απαιτητικό και πιο ενημερωτικό.

Οριακές περιπτώσεις σχολιασμού που πρέπει να επιλύονται στις οδηγίες: - Αποκλεισμένα αντικείμενα: σχολιασμός ορατού τμήματος ή εκτίμηση πλήρους έκτασης; - Αποκομμένα αντικείμενα (μερικά εκτός καρέ): συμπερίληψη ή αποκλεισμός; - Περιοχές πλήθους: χρήση ειδικού σχολιασμού «πλήθους» ή σχολιασμός μεμονωμένων στιγμιοτύπων;

Κάθε μία από αυτές τις αποφάσεις αλλάζει τι σημαίνει «σωστή ανίχνευση» — και επομένως αλλάζει αυτό για το οποίο εκπαιδεύεται το μοντέλο.

```python
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.patches as patches

def compute_iou(boxA, boxB):
    """Compute IoU between two boxes [x1, y1, x2, y2]."""
    xA = max(boxA[0], boxB[0])
    yA = max(boxA[1], boxB[1])
    xB = min(boxA[2], boxB[2])
    yB = min(boxA[3], boxB[3])
    inter_area = max(0, xB - xA) * max(0, yB - yA)
    boxA_area = (boxA[2] - boxA[0]) * (boxA[3] - boxA[1])
    boxB_area = (boxB[2] - boxB[0]) * (boxB[3] - boxB[1])
    union_area = boxA_area + boxB_area - inter_area
    return inter_area / (union_area + 1e-6)

ref_box  = [1.0, 1.0, 4.0, 4.0]
ann1_box = [1.1, 0.9, 4.1, 4.2]   # close
ann2_box = [0.5, 0.5, 3.5, 3.8]   # less precise

print(f"IoU (ann1 vs ref):  {compute_iou(ann1_box, ref_box):.3f}")
print(f"IoU (ann2 vs ref):  {compute_iou(ann2_box, ref_box):.3f}")
print(f"IoU (ann1 vs ann2): {compute_iou(ann1_box, ann2_box):.3f}")

fig, ax = plt.subplots(figsize=(5, 5))
ax.set_xlim(0, 5); ax.set_ylim(0, 5); ax.set_aspect('equal')
ax.add_patch(patches.Rectangle(
    (ref_box[0], ref_box[1]), ref_box[2]-ref_box[0], ref_box[3]-ref_box[1],
    linewidth=2.5, edgecolor='#2b3a8f', facecolor='none', label='Reference'))
ax.add_patch(patches.Rectangle(
```

```
    (ann1_box[0], ann1_box[1]), ann1_box[2]-ann1_box[0], ann1_box[3]-ann1_box[1],
    linewidth=2, edgecolor='#0d9e8e', facecolor='none', linestyle='--',
    label=f'Ann1 (IoU={compute_iou(ann1_box, ref_box):.2f})'))
ax.add_patch(patches.Rectangle(
    (ann2_box[0], ann2_box[1]), ann2_box[2]-ann2_box[0], ann2_box[3]-ann2_box[1],
    linewidth=2, edgecolor='#e05c5c', facecolor='none', linestyle=':',
    label=f'Ann2 (IoU={compute_iou(ann2_box, ref_box):.2f})'))
ax.legend(fontsize=10)
ax.set_title("Bounding Box Agreement (IoU)", fontsize=12)
plt.tight_layout()
plt.savefig('bbox_iou.png', dpi=150)
plt.show()
```

Σημασιολογική και Κατά Στιγμιότυπο Τμηματοποίηση

Ο σχολιασμός τμηματοποίησης απαιτεί ανάθεση ετικέτας κλάσης σε κάθε εικονοστοιχείο μιας εικόνας — μεταξύ των πιο ακριβών τύπων σχολιασμού.

Σημασιολογική τμηματοποίηση: Κάθε εικονοστοιχείο ανήκει σε μια σημασιολογική κλάση (δρόμος, ουρανός, άτομο, αυτοκίνητο). Όλα τα εικονοστοιχεία της ίδιας κλάσης μοιράζονται την ίδια ετικέτα, ανεξαρτήτως σε ποιο μεμονωμένο αντικείμενο ανήκουν.

Τμηματοποίηση κατά στιγμιότυπο: Κάθε μεμονωμένο στιγμιότυπο αντικειμένου παίρνει μοναδική ετικέτα. Ένα πλήθος 20 ανθρώπων γίνεται 20 διακριτές μάσκες.

Πανοπτική τμηματοποίηση: Συνδυάζει και τα δύο: οι κλάσεις «πράγματα» (μετρήσιμα αντικείμενα) έχουν μάσκες στιγμιοτύπου· οι κλάσεις «υλικό» (δρόμος, ουρανός) έχουν σημασιολογικές μάσκες.

Σχολιασμός με υποστήριξη SAM: Το Segment Anything Model (SAM) της Meta {cite}`kirillov2023segment` δημιουργεί μάσκες τμηματοποίησης υψηλής ποιότητας από ένα μόνο κλικ σημείου. Οι σχολιαστές κάνουν κλικ στο κέντρο ενός αντικειμένου· το SAM προτείνει μάσκα· ο σχολιαστής αποδέχεται ή διορθώνει. Οι συγγραφείς του SAM αναφέρουν επιτάχυνση σχολιασμού περίπου 6,5× έναντι επισήμανσης βάσει πολυγώνου· τα κέρδη ποικίλλουν ανά τύπο σκηνής και εργαλείο σχολιασμού.

Το SAM αντιπροσωπεύει μια ευρύτερη μετατόπιση: **ο ρόλος του σχολιαστή αλλάζει από σχεδίαση σε ανασκόπηση**. Αυτό έχει συνέπειες για την ποιότητα σχολιασμού πέρα από την ταχύτητα. Όταν οι σχολιαστές σχεδιάζουν, η προσοχή τους είναι αφοσιωμένη καθ' όλη τη διάρκεια της διαδικασίας. Όταν οι σχολιαστές ανασκοπούν και κάνουν κλικ «αποδοχή», υπάρχουν στοιχεία ότι χάνουν σφάλματα πιο εύκολα — μια έκδοση αυτοματοποιημένης προκατάληψης ειδικά για το πλαίσιο σχολιασμού.

Ενεργός Μάθηση για Υπολογιστική Όραση

Η ενεργός μάθηση είναι ιδιαίτερα πολύτιμη στην CV επειδή: 1. Οι εικόνες είναι υψηλής διαστατικότητας και πλούσιες σε χαρακτηριστικά — οι ενσωματώσεις από προεκπαιδευμένα μοντέλα φέρουν ισχυρά σήματα για εκτίμηση αβεβαιότητας 2. Μεγάλα μη-επισημασμένα σύνολα είναι φθηνά (φωτογραφίες, καρέ βίντεο) 3. Ο σχολιασμός

(ειδικά τμηματοποίηση) είναι ακριβός και δεν μπορεί εύκολα να crowdsourceί για εξειδικευμένους τομείς

```
import numpy as np
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score
import matplotlib.pyplot as plt

rng = np.random.default_rng(42)

X, y = make_classification(n_samples=3000, n_features=50, n_informative=25,
                           n_classes=5, n_clusters_per_class=2, random_state=42)
X_train, y_train = X[:2500], y[:2500]
X_test,  y_test  = X[2500:], y[2500:]

def margin_uncertainty(model, X_pool):
    probs = model.predict_proba(X_pool)
    sorted_p = np.sort(probs, axis=1)
    return sorted_p[:, -2] - sorted_p[:, -1]  # most negative = most uncertain

n_init = 50
results = {'active': [], 'random': []}
label_counts = list(range(50, 401, 30))

for strategy in ['active', 'random']:
    labeled = list(rng.choice(len(X_train), n_init, replace=False))
    unlabeled = [i for i in range(len(X_train)) if i not in labeled]

    for target in label_counts:
        while len(labeled) < target and unlabeled:
            if strategy == 'active' and len(labeled) >= 10:
                model_temp = LogisticRegression(max_iter=300).fit(
                    X_train[labeled], y_train[labeled])
                margins = margin_uncertainty(model_temp, X_train[unlabeled])
                idx = int(np.argmin(margins))
            else:
                idx = rng.integers(0, len(unlabeled))
            labeled.append(unlabeled.pop(idx))

        clf = LogisticRegression(max_iter=300).fit(X_train[labeled], y_train[labeled])
        results[strategy].append(accuracy_score(y_test, clf.predict(X_test)))

plt.figure(figsize=(7, 4))
plt.plot(label_counts, results['active'], 'o-', color='#2b3a8f',
         linewidth=2, label='Active (margin sampling)')
plt.plot(label_counts, results['random'], 's--', color='#e05c5c',
         linewidth=2, label='Random baseline')
plt.xlabel("Labeled training images", fontsize=12)
plt.ylabel("Test accuracy", fontsize=12)
plt.title("Active Learning for 5-Class Image Classification", fontsize=13)
plt.legend(fontsize=11); plt.grid(alpha=0.3)
```

```
plt.tight_layout()
plt.savefig('cv_active_learning.png', dpi=150)
plt.show()
```

Ημι-Εποπτευόμενη Μάθηση με Ανθρώπινη Καθοδήγηση

Η μεγάλη ποσότητα διαθέσιμων μη-επισημασμένων οπτικών δεδομένων κάνει την ημι-εποπτευόμενη μάθηση ιδιαίτερα ελκυστική για CV.

Αυτο-εκπαίδευση / ψευδο-επισήμανση: Εκπαίδευση μοντέλου σε επισημασμένα δεδομένα· χρήση προβλέψεων υψηλής εμπιστοσύνης σε μη-επισημασμένα δεδομένα ως ψευδο-ετικέτες· επανεκπαίδευση. Το κρίσιμο ερώτημα σχεδιασμού είναι το κατώφλι εμπιστοσύνης. Ένα χαμηλό κατώφλι εισάγει περισσότερα παραδείγματα αλλά εισάγει θόρυβο· ένα υψηλό κατώφλι αφήνει το μεγαλύτερο μέρος του μη-επισημασμένου συνόλου αχρησιμοποίητο. Η ανθρώπινη εμπλοκή μπορεί να καθοδηγήσει αυτό το κατώφλι — οι σχολιαστές ελέγχουν ένα δείγμα ψευδο-επισημασμένων παραδειγμάτων για βαθμονόμησή του.

FixMatch και κανονικοποίηση συνέπειας: Αυτές οι μέθοδοι εκπαιδεύουν μοντέλα να παράγουν συνεπείς προβλέψεις υπό επαύξηση. Η βασική οπτική HITL: οι άνθρωποι συμβουλεύονται όχι μόνο για ετικέτες αλλά για **σχεδιασμό επαύξησης** — ποιες αναλλοίωτες θα πρέπει να μαθαίνει το μοντέλο; Ένα μοντέλο για ιατρική απεικόνιση πρέπει να είναι αναλλοίωτο σε στροφή και φωτεινότητα αλλά όχι σε κλίμακα· ένα μοντέλο για ανίχνευση κειμένου δεν πρέπει να γίνεται αναλλοίωτο σε στρέβλωση προοπτικής. Αυτές οι επιλογές ειδικές για τον τομέα απαιτούν ανθρώπινη εμπειρογνωμοσύνη, και η λανθασμένη διαχείρισή τους υποβαθμίζει σημαντικά την ημι-εποπτευόμενη μάθηση.

Ενεργή ημι-εποπτευόμενη μάθηση: Ο πιο αποτελεσματικός συνδυασμός: η ενεργός μάθηση συγκεντρώνει ανθρώπινες ετικέτες όπου η αβεβαιότητα μοντέλου είναι υψηλότερη· η αυτο-εκπαίδευση αυτόματα επισημαίνει την υψηλής εμπιστοσύνης ουρά. Η ανθρώπινη προσπάθεια συγκεντρώνεται εκεί που είναι πιο πολύτιμη, και το μοντέλο εκκινεί στο υπόλοιπο. Σε κάθε κύκλο, ένας ανθρώπινος έλεγχος τυχαίου δείγματος ψευδο-ετικετών παρέχει έλεγχο ποιότητας χωρίς να απαιτεί πλήρη ανασκόπηση.

Σχολιασμός Βίντεο

Ο σχολιασμός βίντεο πολλαπλασιάζει τις προκλήσεις σχολιασμού εικόνας κατά χρόνο:

- **Παρακολούθηση:** Τα αντικείμενα πρέπει να εντοπίζονται σε όλα τα καρέ. Οι σχολιαστές επισημαίνουν βασικά καρέ· οι αλγόριθμοι παρακολούθησης παρεμβάλλουν μεταξύ τους. Αποτυχίες παρακολούθησης — απόκρυψη, επανεμφάνιση, γρήγορη κίνηση — απαιτούν ανθρώπινη επανεπισήμανση με υψηλότερους ρυθμούς από ότι η σταθερή κατάσταση παρακολούθησης.
- **Χρονική συνέπεια:** Τα όρια που σχεδιάζονται στο καρέ t πρέπει να είναι χωρικά συνεπή με το καρέ $t+1$. Ασυνεπείς σχολιασμοί είναι ένα σήμα εκπαίδευσης που λέει στο μοντέλο ότι τα αντικείμενα πηδούν ασυνεχώς — μια μορφή θορύβου σχολιασμού που είναι ιδιαίτερα επιζήμια για μοντέλα ανίχνευσης.
- **Κλιμακωσιμότητα:** Ένα βίντεο 1 ώρας με 30fps είναι 108.000 καρέ. Ο πλήρης σχολιασμός είναι απρακτικός· οι στρατηγικές δειγματοληψίας πρέπει να σχεδιάζονται

προσεκτικά για να εξασφαλίσουν ότι σπάνια γεγονότα (οριακές περιπτώσεις, πλησιέστερες αστοχίες, σενάρια αποτυχίας) δεν αποκλείονται συστηματικά.

Τα σύγχρονα εργαλεία σχολιασμού βίντεο υποστηρίζουν **έξυπνη παρακολούθηση** που διαδίδει σχολιασμούς σε καρέ και επισημαίνει καρέ όπου η εμπιστοσύνη παρακολούθησης πέφτει κάτω από ένα κατώφλι, παρακινώντας τον σχολιαστή να επανελέγξει. Αυτό είναι άμεση εφαρμογή της ιδέας ενεργούς μάθησης στον ίδιο τον αγωγό σχολιασμού: το εργαλείο απευθύνει ερώτηση στον σχολιαστή ακριβώς εκεί που η παρεμβολή του είναι αβέβαιη.

Το πρόβλημα σπάνιων γεγονότων σε αυτόνομα συστήματα. Για εφαρμογές όπου οι συνέπειες σπάνιων γεγονότων είναι καταστροφικές — αυτόνομη οδήγηση, πλοήγηση UAV — η κατανομή καρέ που εμφανίζονται σε κανονική λειτουργία αντιστοιχεί άσχημα με την κατανομή των καρέ που έχουν σημασία περισσότερο. Ένα σύνολο δεδομένων χτισμένο δειγματοληπτώντας ομοιόμορφα πλάνα οδήγησης θα περιέχει εκατομμύρια καρέ «δεν συμβαίνει τίποτα ενδιαφέρον» και μια χούφτα από τα κοντινά ατυχήματα, ασυνήθιστου φωτισμού και υποβαθμισμένων αισθητήρων που έχουν πραγματικά σημασία για την ασφάλεια. Η ενεργός μάθηση HITL που εντοπίζει και ιεραρχεί τέτοια καρέ δεν είναι τέχνασμα αποτελεσματικότητας — είναι απαίτηση ασφάλειας.

See also: Σύνολο δεδομένων ImageNet: {cite}`russakovsky2015imagenet`. Προκατάληψη ετικετών στο ImageNet: {cite}`yang2020towards`. Αναφορά COCO: {cite}`lin2014microsoft`. SAM (Segment Anything): {cite}`kirillov2023segment`. Ενεργός μάθηση βασικού συνόλου για CV: {cite}`sener2018active`.

Ανθρωποκεντρική ΜΜ στην Υγεία και την Επιστήμη

Η υγειονομική περίθαλψη και η επιστήμη αντιπροσωπεύουν δύο από τους τομείς όπου η HITL ML είναι πιο συνεπαγωγική και πιο αμφιλεγόμενη. Τα διακυβεύματα είναι υψηλά: μια χαμένη διάγνωση καρκίνου ή ένας ελαττωματικός φαρμακευτικός στόχος έχει πραγματικό ανθρώπινο κόστος. Ο σχολιασμός απαιτεί σπάνια και ακριβή εμπειρογνωμοσύνη. Οι ρυθμιστικές απαιτήσεις περιορίζουν αυτό που μπορούν να κάνουν τα μοντέλα και πώς πρέπει να επικυρώνονται. Και σε αντίθεση με την ΕΦΓ, όπου το πρόβλημα σχολιασμού είναι εν μέρει κοινωνικής κατασκευής, εδώ υπάρχει συχνά γνήσια αλήθεια εδάφους — ένας όγκος παρευρίσκεται ή δεν παρευρίσκεται — ακόμα και αν κανένας μεμονωμένος παρατηρητής δεν μπορεί να το καθορίσει αξιόπιστα.

Το κυρίαρχο πλαίσιο στη λαϊκή κάλυψη είναι «ΤΝ vs. άνθρωπος»: θα αντικαταστήσει η ΤΝ τους ακτινολόγους; Αυτό το πλαίσιο είναι λανθασμένο με τρόπο που έχει σημασία. Το πραγματικό ερώτημα είναι τι μορφή ανθρώπου-ΤΝ συνεργασίας παράγει καλύτερα αποτελέσματα από οποιοδήποτε μόνο του, και πώς να χτίσουμε συστήματα που επιτρέπουν αυτή τη συνεργασία αντί να τη διαταράσσουν.

Ανάλυση Ιατρικής Εικόνας

Η ιατρική απεικόνιση — ακτινολογία (ακτινογραφία, CT, MRI), παθολογία (ιστολογικές τομές), δερματολογία, οφθαλμολογία — είναι ο τομέας όπου η ιατρική ΤΝ έχει προχωρήσει ταχύτατα.

Απαιτήσεις Εμπειρογνώμονα Σχολιαστή

Ο σχολιασμός ιατρικής εικόνας απαιτεί συνήθως ιατρούς με συγκεκριμένη υποειδικότητα εκπαίδευση. Αυτό κάνει τον σχολιασμό:

- **Αργό:** Οι ειδικοί έχουν περιορισμένο χρόνο· ο σχολιασμός ανταγωνίζεται με κλινικά καθήκοντα
- **Ακριβό:** Τα κόστη κυμαίνονται από δεκάδες έως εκατοντάδες δολάρια ανά σχολιασμένη περίπτωση, ανάλογα με υποειδικότητα, αρθρωτικότητα και πολυπλοκότητα έργου
- **Μεταβλητό:** Ακόμα και ειδικοί διαφωνούν, ειδικά για οριακές περιπτώσεις — γεγονός που συχνά αντιμετωπίζεται ως πρόβλημα αλλά είναι πραγματικά ενημερωτικό

Διαρθρωτική Μεταβλητότητα Ακτινολόγων

Η μεταβλητότητα αναγνωστών είναι καλά τεκμηριωμένη στην ακτινολογία. Για ερμηνεία ακτινογραφίας θώρακα, η διαφωνία μεταξύ αναγνωστών είναι ουσιαστική — στη μελέτη CheXNet, τέσσερις ακτινολόγοι επισήμαναν το ίδιο σύνολο ελέγχου ανίχνευσης πνευμονίας με βαθμολογίες F1 που καλύπτουν περίπου 12 ποσοστιαίες μονάδες {cite}`rajpurkar2017chexnet`, αντικατοπτρίζοντας γνήσια διαγνωστική αβεβαιότητα σε οριακές περιπτώσεις. Για ανίχνευση οζιδίων σε CT πνεύμονα, η ενδο-αναγνωστική μεταβλητότητα (ίδιος αναγνώστης, ίδια περίπτωση, διαφορετική μέρα) μπορεί να είναι τόσο μεγάλη όσο η μεταξύ-αναγνωστική μεταβλητότητα.

Αυτή η μεταβλητότητα δεν είναι απλά θόρυβος — αντικατοπτρίζει γνήσια διαγνωστική αβεβαιότητα. Τα μοντέλα εκπαιδευμένα στους σχολιασμούς ενός μόνο ακτινολόγου μπορεί να μαθαίνουν τις συγκεκριμένες προκαταλήψεις εκείνου του ιατρού αντί για την υποκείμενη παθολογία.

:::{admonition} Η Διαμάχη CheXNet ως Μάθημα HITL :class: note

Όταν οι Rajpurkar et al. ισχυρίστηκαν ότι το μοντέλο CheXNet τους «ξεπέρασε την απόδοση ακτινολόγου» στην ανίχνευση πνευμονίας, ο ισχυρισμός αμφισβητήθηκε αμέσως από την κοινότητα ακτινολογίας {cite}`yu2022assessing`. Μέρος της διαμάχης αφορούσε το συγκεκριμένο σύνολο ελέγχου και σύγκριση ακτινολόγων. Αλλά ένα βαθύτερο ζήτημα ήταν μεθοδολογικό: η βάση «απόδοσης ακτινολόγου» χρησιμοποιούσε μοναχικούς αναγνώστες υπό χρονική πίεση, ενώ η κλινική ακτινολογία συνήθως περιλαμβάνει διαβούλευση, σύγκριση με προηγούμενες απεικονίσεις και πρόσβαση σε κλινικό πλαίσιο — τίποτα από αυτά δεν είχε το μοντέλο.

Το δίδαγμα δεν είναι ότι το μοντέλο ήταν καλό ή κακό, αλλά ότι **οι συγκρίσεις απόδοσης απαιτούν προσδιορισμό της ρύθμισης HITL**. Ένα μοντέλο που ξεπερνά έναν μοναχικό ακτινολόγο που διαβάζει ψυχρά μπορεί να είναι λιγότερο ακριβές από έναν ακτινολόγο που χρησιμοποιεί την έξοδο του μοντέλου ως δεύτερη γνώμη. Αυτά είναι διαφορετικά συστήματα με διαφορετικούς τρόπους αποτυχίας, και η διαφορετική συνάθροισή τους τα κάνει να διαφέρουν. :::

:::{admonition} Ήπιες ετικέτες στην ιατρική :class: important

Αρκετά ιατρικά έργα TN έχουν μεταβεί σε χρήση **ήπιων ετικετών** που αντικατοπτρίζουν την κατανομή γνωμών εμπειρογνωμόνων αντί μίας «χρυσής» ετικέτας. Μια ακτινογραφία θώρακα επισημασμένη ως 60% πνευμονία / 40% ατελεκτασία από ομάδα ακτινολόγων φέρει περισσότερες πληροφορίες από μια αναγκαστική δυαδική επιλογή. Τα μοντέλα εκπαιδευμένα σε τέτοιες κατανομές εμφανίζουν καλύτερη βαθμονόμηση και πιο κατάλληλη ποσοτικοποίηση αβεβαιότητας — και αυτή η αβεβαιότητα είναι κλινικά σημαντική, καθώς λέει στον κλινικό γιατρό πότε να συμβουλευτεί, όχι μόνο τι σκέφτεται το μοντέλο. :::

Ενεργός Μάθηση για Σπάνιες Παθήσεις

Η ενεργός μάθηση είναι ιδιαίτερα πολύτιμη για σπάνιες ασθένειες και σπάνιες παθολογίες, όπου ακόμα και ένα μεγάλο μη-επισημασμένο σύνολο περιέχει μόνο μικρό αριθμό θετικών περιπτώσεων. Η τυπική τυχαία δειγματοληψία θα σπαταλούσε τον χρόνο εμπειρογνωμόνων επισημαίνοντας ως επί το πλείστον αρνητικές περιπτώσεις.

Η ενεργός μάθηση βάσει αβεβαιότητας φυσικά επιλέγει οριακές περιπτώσεις όπου το μοντέλο είναι αβέβαιο — που, για σπάνιες παθήσεις, τείνουν να είναι θετικές περιπτώσεις και οριακά αρνητικά. Αυτό συγκεντρώνει τον χρόνο ειδικού εκεί που είναι πιο πολύτιμος. Ο συνδυασμός ασύμμετρης εκπαίδευσης κλάσης (με `class_weight='balanced'`

ή παρόμοιο) και επιλογής βάσει αβεβαιότητας είναι τυπική πρακτική για εργασίες ανίχνευσης σπάνιας παθολογίας.

Κλινικός Σχολιασμός ΕΦΓ

Τα ηλεκτρονικά αρχεία υγείας (EHRs) περιέχουν τεράστιο πλούτο κλινικού αφηγηματικού κειμένου: σημειώσεις ιατρών, συνοπτικά αρχεία εξόδου, ακτινολογικές εκθέσεις, παθολογικές εκθέσεις. Η εξαγωγή δομημένων πληροφοριών από αυτό το κείμενο απαιτεί ΕΦΓ — και η ΕΦΓ υψηλής ποιότητας απαιτεί επισημασμένα δεδομένα εκπαίδευσης.

Κοινές εργασίες κλινικού σχολιασμού ΕΦΓ: - Κλινική NER: Εντοπισμός φαρμάκων, δοσολογιών, διαγνώσεων, διαδικασιών και συμπτωμάτων σε κείμενο - **Ανίχνευση άρνησης:** «Χωρίς ένδειξη πνευμονίας» vs. «Πνευμονία επιβεβαιωμένη» — μια κρίσιμη διάκριση που είναι εκπληκτικά δύσκολη - **Χρονική συλλογιστική:** Διάκριση τρεχουσών παθήσεων από ιστορικό («ιστορικό MI, παρουσίασε στηθάγχη») - **Απανθρωποποίηση:** Αφαίρεση Προστατευόμενων Πληροφοριών Υγείας (PHI) για επίτρεψη κοινής χρήσης δεδομένων

Η απανθρωποποίηση PHI είναι τόσο εργασία σχολιασμού όσο και απαίτηση διακυβέρνησης δεδομένων. Υπό HIPAA (ΗΠΑ) και GDPR (ΕΕ), τα δεδομένα υγείας δεν μπορούν να κοινοποιηθούν χωρίς αφαίρεση ή ανωνυμοποίηση αναγνωριστικών ασθενών. Αυτοματοποιημένα εργαλεία απανθρωποποίησης υπάρχουν αλλά είναι ατελή· η ανθρώπινη ανασκόπηση αυτοματοποιημένων εξόδων είναι τυπική πρακτική, και το προφίλ κινδύνου είναι ασύμμετρο: τα ψευδώς αρνητικά (χαμένα PHI) δημιουργούν νομική έκθεση, καθιστώντας απαραίτητα συντηρητικά κατώφλια.

i2b2 / n2c2 ως Πρότυπο

Οι πρωτοβουλίες κοινών έργων i2b2 (Πληροφορική για Ενοποίηση Βιολογίας και Κλίνης) και διάδοχος n2c2 (Εθνικές Κλινικές Προκλήσεις NLP) έχουν κυκλοφορήσει μια σειρά συνόλων δεδομένων κλινικής ΕΦΓ επισημασμένων από εμπειρογνώμονες. Αυτά απεικονίζουν τόσο τη δυνατότητα όσο και το κόστος: οι προσπάθειες σχολιασμού συνήθως περιλαμβάνουν ομάδες κλινικών εμπειρογνωμόνων τομέα που εργάζονται για αρκετούς μήνες, σχολιάζοντας εκατοντάδες έγγραφα ανά πρόκληση.

Ρυθμιστικές Εκτιμήσεις

Η ιατρική ΤΝ υπόκειται σε ρυθμιστική εποπτεία στις περισσότερες δικαιοδοσίες.

FDA (Ηνωμένες Πολιτείες): Λογισμικό ΤΝ/ΜΜ ως Ιατρική Συσκευή (SaMD) απαιτεί προ-αγοράς έγκριση ή άδεια. Το Σχέδιο Δράσης ΤΝ/ΜΜ του FDA του 2021 δίνει έμφαση σε **προκαθορισμένα σχέδια ελέγχου αλλαγών** — τεκμηρίωση του πώς θα ενημερώνεται το μοντέλο και πώς αυτές οι ενημερώσεις θα επικυρώνονται πριν από την ανάπτυξη. Ένα μοντέλο που μαθαίνει συνεχώς από κλινική ανατροφοδότηση είναι, στο πλαίσιο αυτό, διαφορετική συσκευή μετά από κάθε ενημέρωση και μπορεί να απαιτεί επανα-επικύρωση.

Σήμανση CE (Ευρώπη): Οι ιατρικές συσκευές συμπεριλαμβανομένων των συστημάτων ΤΝ πρέπει να συμμορφώνονται με τον Κανονισμό Ιατρικών Συσκευών (MDR). Ο MDR απαιτεί κλινική αξιολόγηση, επιτήρηση μετά την αγορά και τεκμηρίωση των δεδομένων που χρησιμοποιούνται για εκπαίδευση και επικύρωση.

Βασική συνέπεια HITL: Τα ρυθμιστικά πλαίσια απαιτούν σαφή τεκμηρίωση των διαδικασιών σχολιασμού, των προσόντων σχολιαστών, της αξιοπιστίας μεταξύ αξιολογητών και τυχόν αλλαγών στα δεδομένα εκπαίδευσης. Αυτό δεν είναι γραφειοκρατική επιβάρυνση — είναι το ίχνος ελέγχου που επιτρέπει σε έναν κλινικό γιατρό να κατανοήσει ποια δεδομένα εκπαίδευσης παρήγαγαν την τρέχουσα συμπεριφορά του μοντέλου, και απαιτείται νομικά.

Σχολιασμός Επιστημονικών Δεδομένων

Πέρα από την υγειονομική περίθαλψη, η HITL ML διαδραματίζει αυξανόμενο και υποεκτιμημένο ρόλο στην επιστημονική έρευνα, όπου η πρόκληση σχολιασμού συχνά συνδυάζει εμπειρογνωμοσύνη τομέα με κλίμακα.

Αστρονομία: Galaxy Zoo

Το Galaxy Zoo {cite}`lintott2008galaxy` crowdsource-αρε τη μορφολογική ταξινόμηση γαλαξιών από τη Sloan Digital Sky Survey σε επιστήμονες-πολίτες. Το πρωτότυπο έργο συγκέντρωσε πάνω από 40 εκατομμύρια ταξινομήσεις από πάνω από 100.000 εθελοντές, αποδεικνύοντας ότι η μεγάλης κλίμακας crowdsourcing επιστημονικής ταξινόμησης εικόνας είναι εφικτή όταν το έργο μπορεί να αποσυντεθεί σε απλές ερωτήσεις αναπαντήσιμες χωρίς εξειδικευμένη εκπαίδευση.

Η εμπειρία Galaxy Zoo παρήγαγε δύο σημαντικά μεθοδολογικά ευρήματα. Πρώτον, η συμφωνία μεταξύ επιστημόνων-πολιτών και επαγγελματιών αστρονόμων ήταν υψηλή για σαφείς περιπτώσεις και συστηματικά αποκλίνει στις οριακές περιπτώσεις — ακριβώς τις περιπτώσεις όπου η διάκριση έχει επιστημονική σημασία. Η λύση δεν ήταν να απορριφθούν τα δεδομένα επιστήμης πολιτών σε οριακές περιπτώσεις αλλά να αντιμετωπιστεί η κατανομή αποκρίσεων εθελοντών ως ήπια ετικέτα που κωδικοποιεί γνήσια μορφολογική ασάφεια.

Γενωμική: Ταξινόμηση Παθογονικότητας

Ο σχολιασμός γενωμικών παραλλαγών — απόφαση εάν μια παραλλαγή είναι παθογόνος, καλοήθης ή αβέβαιης σημασίας — είναι πρόβλημα ΕΦΓ υψηλών διακυβευμάτων και εμπειρογνώμονα κρίσης. Κλινικές βάσεις δεδομένων παραλλαγών όπως η ClinVar συγκεντρώνουν ερμηνείες εμπειρογνωμόνων από πολλαπλά εργαστήρια, και η διαφωνία μεταξύ εργαστηρίων είναι κοινή.

Κλίμα και Επιστήμη Γης

Η επισήμανση δορυφορικής απεικόνισης για αλλαγές χρήσης γης, αποδάσωση, έκταση παγετώνων και πορείες καταιγίδων περιλαμβάνει εμπειρογνώμονες τηλεπισκόπησης και ολοένα και περισσότερο πλατφόρμες επιστήμης πολιτών. Η κύρια πρόκληση HITL σε αυτόν τον τομέα είναι χρονική: οι ετικέτες που δημιουργούνται σήμερα μπορεί να γίνουν παρωχημένες καθώς αλλάζει ο κόσμος.

Νευροεπιστήμη: Connectomics

Η ανακατασκευή νευρωνικών κυκλωμάτων από εικόνες ηλεκτρονικού μικροσκοπίου — connectomics — απαιτεί σχολιασμό σε επίπεδο εικονοστοιχείου μεμβρανών νευρώνων σε

τεράστιες στοίβες εικόνων. Το έργο Eyewire το γαμιφίκαρε, εμπλέκοντας δεκάδες χιλιάδες παίκτες στην ιχνηλασία νευρώνων μέσω 3D τόμων εικόνας.

Διαχείριση Σχολιαστών Ειδικών

Όταν ο σχολιασμός απαιτεί σπάνια εμπειρογνωμοσύνη, οι συνηθισμένες προσεγγίσεις crowdsourcing (Κεφάλαιο 13) δεν εφαρμόζονται.

Η θεμελιώδης τάση είναι ότι οι άνθρωποι που μπορούν να παράγουν τους σχολιασμούς υψηλότερης ποιότητας είναι επίσης οι άνθρωποι του οποίου ο χρόνος είναι πιο πολύτιμος και πιο περιορισμένος. Κάθε απόφαση σχεδιασμού σε έναν αγωγό σχολιασμού ειδικών πρέπει να αξιολογείται έναντι του ερωτήματος: αυτό αξιοποιεί τον σπάνιο χρόνο εμπειρογνωμόνων βέλτιστα;

Αυτό σημαίνει στην πράξη:

- **Επιθετικός προ-σχολιασμός.** Χρησιμοποιήστε σχολιαστές χαμηλότερης βαθμίδας, αυτοματοποιημένα μοντέλα ή κανονιστικά συστήματα για δημιουργία υποψηφίων που ο ειδικός ανασκοπεί και διορθώνει αντί να δημιουργεί από μηδέν.
- **Σχεδιάστε για προσοχή εμπειρογνωμόνων, όχι απόδοση.** Διεπαφές σχολιασμού βελτιστοποιημένες για υψηλή απόδοση είναι κατάλληλες για crowdsourcing. Ο σχολιασμός ειδικών συχνά επωφελείται από πλουσιότερες διεπαφές: παράθεση με προηγούμενες περιπτώσεις, εύκολη πρόσβαση σε υλικά αναφοράς, πεδία εμπιστοσύνης σχολιασμού και δυνατότητα επισήμανσης περίπτωσης για συζήτηση.
- **Παρακολουθήστε ρητά μεμονωμένα μοτίβα σχολιαστών.** Με μικρό δεξαμενή ειδικών, είναι εφικτό και σημαντικό να παρακολουθείτε τον ρυθμό συμφωνίας κάθε σχολιαστή με την ομάδα, να επισημαίνετε περιπτώσεις που φαίνονται ασυνεπείς με το ιστορικό τους και να τις συζητάτε σε τακτικές συνεδρίες βαθμονόμησης.
- **Ο σχεδιασμός συνεδρίας έχει σημασία.** Ο ιατρικός σχολιασμός είναι γνωστικά απαιτητικός. Στοιχεία από ακτινολογία και παθολογία υποδηλώνουν ότι τα ποσοστά σφαλμάτων αυξάνονται αισθητά μετά από περίπου 90 λεπτά συνεχούς ανάγνωσης.

Αγωγός Ενεργούς Μάθησης HITL για Ιατρική Απεικόνιση

```
import numpy as np
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import roc_auc_score
from sklearn.datasets import make_classification
import matplotlib.pyplot as plt

rng = np.random.default_rng(42)

# Simulate a rare-pathology detection task
# 8% positive class (e.g., rare pathology)
X, y = make_classification(
    n_samples=5000, n_features=100,
    n_informative=20, n_redundant=10,
```

```
    weights=[0.92, 0.08],
    random_state=42
)
X_train, y_train = X[:4000], y[:4000]
X_test,  y_test  = X[4000:], y[4000:]

print(f"Training set positive prevalence: {y_train.mean():.1%}")

def run_medical_al(strategy, n_initial=50, budget=300):
    labeled = list(rng.choice(len(X_train), n_initial, replace=False))
    unlabeled = [i for i in range(len(X_train)) if i not in labeled]
    aucs = []

    while len(labeled) < n_initial + budget:
        model = LogisticRegression(max_iter=500, class_weight='balanced')
        model.fit(X_train[labeled], y_train[labeled])

        if len(labeled) % 30 == 0:
            preds = model.predict_proba(X_test)[:, 1]
            aucs.append(roc_auc_score(y_test, preds))

        X_pool = X_train[unlabeled]
        if strategy == 'uncertainty' and len(labeled) >= 10:
            probs = model.predict_proba(X_pool)
            entropy = -np.sum(probs * np.log(probs + 1e-9), axis=1)
            q = int(np.argmax(entropy))
        else:
            q = rng.integers(0, len(unlabeled))

        labeled.append(unlabeled.pop(q))

    return np.array(aucs)

aucs_al  = run_medical_al('uncertainty')
aucs_rnd = run_medical_al('random')
label_counts = np.arange(len(aucs_al)) * 30 + 50

plt.figure(figsize=(7, 4))
plt.plot(label_counts, aucs_al,  'o-',  color='#2b3a8f', linewidth=2, label='Uncertainty AL')
plt.plot(label_counts, aucs_rnd, 's--', color='#e05c5c', linewidth=2, label='Random baseline'
plt.xlabel("Expert labels obtained", fontsize=12)
plt.ylabel("AUROC", fontsize=12)
plt.title("Active Learning for Rare Pathology Detection", fontsize=13)
plt.legend(); plt.grid(alpha=0.3)
plt.tight_layout()
plt.savefig('medical_al.png', dpi=150)
plt.show()

# Show how AL preferentially selects positive examples
# by checking which class the queried examples belong to
n_init = 50
```

```
labeled_al  = list(rng.choice(len(X_train), n_init, replace=False))
labeled_rnd = labeled_al.copy()
unlabeled_al  = [i for i in range(len(X_train)) if i not in labeled_al]
unlabeled_rnd = unlabeled_al.copy()

model = LogisticRegression(max_iter=500, class_weight='balanced')
model.fit(X_train[labeled_al], y_train[labeled_al])
probs = model.predict_proba(X_train[unlabeled_al])
entropy = -np.sum(probs * np.log(probs + 1e-9), axis=1)
top50_al  = [unlabeled_al[i] for i in np.argsort(entropy)[-50:]]
top50_rnd = list(rng.choice(unlabeled_rnd, 50, replace=False))

pos_rate_al  = y_train[top50_al].mean()
pos_rate_rnd = y_train[top50_rnd].mean()
print(f"\nPositive rate in next 50 queries:")
print(f"  Uncertainty AL: {pos_rate_al:.1%}  (base rate: {y_train.mean():.1%})")
print(f"  Random:         {pos_rate_rnd:.1%}")
print(f"  AL queries {pos_rate_al/y_train.mean():.1f}x more positives than random")
```

See also: Crowdsourcing Galaxy Zoo: {cite}`lintott2008galaxy`. Απόδοση ακτινολόγων CheXNet: {cite}`rajpurkar2017chexnet`. Ποιότητα ακτινογραφίας και διάγνωση υποβοηθούμενη από TN: {cite}`yu2022assessing`. Μεθοδολογία κλινικού σχολιασμού ΕΦΓ: {cite}`pustejovsky2012natural`. Για καθοδήγηση σχεδίου δράσης TN/MM FDA, βλ. τεκμηρίωση FDA που δημοσιεύτηκε (2021).

Πλατφόρμες Σχολιασμού και Εργαλεία

Η πλατφόρμα σχολιασμού είναι το περιβάλλον στο οποίο η ανθρώπινη ανατροφοδότηση μετατρέπεται σε δεδομένα. Μια καλή πλατφόρμα αυξάνει την απόδοση, μειώνει τα λάθη, διατηρεί τους ελέγχους ποιότητας και καθιστά τη γραμμή σχολιασμού διαχειρίσιμη σε κλίμακα. Η επιλογή της κατάλληλης πλατφόρμας — και η γνώση πότε να κατασκευαστεί έναντι αγοράς — είναι μια κρίσιμη απόφαση σε κάθε έργο HITL.

Το Τοπίο Πλατφορμών Σχολιασμού

Η αγορά εργαλείων σχολιασμού έχει αναπτυχθεί και ωριμάσει σημαντικά τα τελευταία χρόνια, κινούμενη από την εταιρική ζήτηση για δεδομένα εκπαίδευσης ΜΜ. Τα εργαλεία καλύπτουν ένα ευρύ φάσμα, από πλήρως διαχειριζόμενες υπηρεσίες έως πλαίσια ανοιχτού κώδικα αυτο-φιλοξενίας.

Πλατφόρμες Ανοιχτού Κώδικα

Το **Label Studio** είναι η πιο δημοφιλής πλατφόρμα σχολιασμού ανοιχτού κώδικα, υποστηρίζοντας κείμενο, εικόνες, ήχο, βίντεο και δεδομένα χρονοσειρών μέσω μιας ενιαίας διαμόρφωσης εργασιών βάσει XML. Μπορεί να αυτο-φιλοξενηθεί και ενσωματώνεται με backends ΜΜ για ενεργό μάθηση. Βασικά πλεονεκτήματα: ευελιξία, υποστήριξη κοινότητας και η δυνατότητα ενσωμάτωσης προσαρμοσμένων προβλέψεων ΜΜ για προ-σχολιασμό.

Το **Prodigy** (από τους δημιουργούς του spaCy) είναι ένα εργαλείο σχολιασμού υψηλά προσανατολισμένο στη ροή εργασίας, σχεδιασμένο για εργασίες NLP. Η αρχιτεκτονική ροής του αποστέλλει παραδείγματα ένα κάθε φορά και υποστηρίζει ενεργό μάθηση εξ ορισμού. Η διεπαφή σχολιασμού είναι ελάχιστη αλλά γρήγορη — σχεδιασμένη για μέγιστη απόδοση σχολιασμού. Το Prodigy είναι εμπορικό λογισμικό αλλά χρησιμοποιείται ευρέως στην έρευνα NLP.

Το **CVAT (Computer Vision Annotation Tool)** είναι το κορυφαίο εργαλείο ανοιχτού κώδικα για σχολιασμό CV, με ισχυρή υποστήριξη για ανίχνευση, κατάτμηση και σχολιασμό βίντεο. Αρχικά αναπτύχθηκε στην Intel, το CVAT υποστηρίζει αλγόριθμους παρακολούθησης, σχολιασμό σκελετού και ενσωματώσεις αλγορίθμων τρίτων.

Το **Doccano** στοχεύει εργασίες ακολουθιακής επισήμανσης (NER, εξαγωγή σχέσεων, ταξινόμηση κειμένου). Η απλή διεπαφή ιστού του το καθιστά προσβάσιμο σε ομάδες χωρίς αφιερωμένους πόρους μηχανικής δεδομένων.

Εμπορικές Πλατφόρμες

Η **Scale AI** παρέχει πλήρως διαχειριζόμενες υπηρεσίες σχολιασμού: ανθρώπινο εργατικό δυναμικό, διαχείριση ποιότητας και ενσωμάτωση API. Ιδιαίτερα ισχυρή για αυτόνομη οδήγηση, ρομποτική και σύνθετο τρισδιάστατο σχολιασμό. Η τιμολόγηση βασίζεται στην πολυπλοκότητα και τον όγκο εργασιών.

Το **Labelbox** είναι μια πλήρης πλατφόρμα για επιμέλεια δεδομένων, σχολιασμό και επισήμανση με βοήθεια ΜΜ. Ισχυρά εταιρικά χαρακτηριστικά: διαχείριση έργων, ροές εργασίας ποιότητας, βρόχοι ανατροφοδότησης μοντέλου και ενσωματώσεις με τις κύριες πλατφόρμες ΜΜ (SageMaker, Vertex AI, Azure ML).

Η **Appen** (πρώην Figure Eight / CrowdFlower) λειτουργεί ένα μεγάλο παγκόσμιο εργατικό δυναμικό σχολιασμού μαζί με εργαλεία. Καλή επιλογή όταν ο όγκος και η διαχείριση εργατικού δυναμικού αποτελούν πρωταρχικές ανησυχίες.

Η **Surge AI** εστιάζει σε έμπειρους σχολιαστές και είναι ισχυρή για εργασίες που απαιτούν γνώσεις τομέα ή λεπτές κρίσεις.

Το **Humanloop** ειδικεύεται στη συλλογή ανατροφοδότησης LLM — σχολιασμός προτίμησης, συλλογή δεδομένων RLHF και αξιολόγηση μοντέλων.

Σύγκριση Χαρακτηριστικών Πλατφορμών Σχολιασμού

Χαρακτηριστικό	Label Studio	Prodigy	CVAT	Labelbox	Scale AI
Άδεια	Ανοιχτός κώδικας	Εμπορική	Ανοιχτός κώδικας	Εμπορική	Εμπορική
Φιλοξενία	Εαυτός / cloud	Εαυτός	Εαυτός / cloud	Cloud	Διαχειριζόμενη
Σχολιασμός κειμένου	□	□	—	□	□
Σχολιασμός εικόνας	□	Περιορισμένος	□	□	□
Σχολιασμός βίντεο	□	—	□	□	□
Ενσωμάτωση ενεργού μάθησης	□	□	Περιορισμένη	□	□
Προ-σχολιασμός με ΜΜ	□	□	□	□	□
Ροές ελέγχου ποιότητας	Βασικές	Βασικές	Βασικές	Προηγμένες	Προηγμένες
Πρόσβαση API / Προγραμματισμός	□	□	□	□	□
Διαχείριση εργατικού δυναμικού	—	—	—	Περιορισμένη	□

Σχολιασμός ως Κώδικας

Μια κρίσιμη αλλά συχνά παραμελημένη πτυχή της υποδομής σχολιασμού είναι ο **έλεγχος εκδόσεων για τους σχολιασμούς και τα σχήματα σχολιασμού**. Η αντιμετώπιση του σχολιασμού ως κώδικα σημαίνει:

Σχεδιασμός με πρώτο το σχήμα. Η ταξινομία ετικετών και οι κανόνες σχολιασμού ορίζονται σε ένα εκδοχοποιημένο αρχείο διαμόρφωσης (YAML ή JSON) πριν ξεκινήσει ο σχολιασμός. Οι αλλαγές στο σχήμα δημιουργούν νέα έκδοση.

Εκδοχοποίηση σχολιασμών. Οι σχολιασμοί αποθηκεύονται με σύνδεσμο στην έκδοση σχήματος υπό την οποία δημιουργήθηκαν. Αυτό επιτρέπει ελέγχους, επαναφορά και σύγκριση σχολιασμών σε διάφορες εκδόσεις σχήματος.

Αναπαραγώγιμες γραμμές επεξεργασίας. Η γραμμή επεξεργασίας σχολιασμού — από ακατέργαστα δεδομένα έως ετικέτες έτοιμες για εκπαίδευση — πρέπει να είναι αναπαραγώγιμη από κώδικα. Τα μοντέλα προ-σχολιασμού, τα φίλτρα ποιότητας, η λογική συνάθροισης και οι κατανομές δεδομένων πρέπει όλα να καταγραφούν.

```
# Παράδειγμα: Σχήμα σχολιασμού Label Studio (ταξινόμηση κειμένου)
label_config: |
  <View>
    <Text name="text" value="$text"/>
    <Choices name="sentiment" toName="text" choice="single">
      <Choice value="positive"/>
      <Choice value="negative"/>
      <Choice value="neutral"/>
      <Choice value="mixed"/>
    </Choices>
  </View>
schema_version: "2.1.0"
task_type: text_classification
guidelines_version: "guidelines_v3.pdf"
```
```text
Πηγή δεδομένων
    |
    v
Σύνολο χωρίς ετικέτες -->  Πλατφόρμα σχολιασμού --> Σύνολο με ετικέτες
    ^                           |                           |
    |                           | (με βοήθεια ΜΜ)           v
Ενεργός μάθηση <----------------+                     Εκτέλεση εκπαίδευσης
στρατηγική ερωτήματος                                       |
    ^                                                       v
    +-------------- Εκπαιδευμένο μοντέλο <---------- Αξιολόγηση
                                                            |
                                                      Ανάπτυξη &
                                                      παρακολούθηση
```

Βασικά σημεία ενσωμάτωσης: 1. **Εισαγωγή δεδομένων:** Τα αδύναμα δεδομένα ρέουν αυτόματα από την αποθήκη δεδομένων στην πλατφόρμα σχολιασμού 2. **Εξυπηρέτηση μοντέλου:** Το τρέχον καλύτερο μοντέλο αναπτύσσεται στην πλατφόρμα σχολιασμού

για προ-σχολιασμό και βαθμολόγηση ενεργού μάθησης 3. **Εξαγωγή:** Οι ολοκληρωμένοι σχολιασμοί εξάγονται σε μορφή συμβατή με το πλαίσιο εκπαίδευσης (COCO JSON, σύνολα δεδομένων Hugging Face κ.λπ.) 4. **Βρόχος ανατροφοδότησης:** Τα σφάλματα μοντέλου παραγωγής δρομολογούνται πίσω στην πλατφόρμα σχολιασμού για διόρθωση

> **See also:** Για τεκμηρίωση Label Studio και ενσωμάτωση ενεργού μάθησης: https://labelstud.io. Για Prodigy: https://prodi.gy. CVAT: https://cvat.ai. Για μια ολοκληρωμένη σύγκριση εργαλείων σχολιασμού, βλ. {cite}`monarch2021human`, Κεφάλαιο 7.

Crowdsourcing και Ποιοτικός Έλεγχος

Όταν οι εργασίες σχολιασμού είναι αρκετά απλές για να εκτελεστούν από μη ειδικούς, οι πλατφόρμες crowdsourcing προσφέρουν πρόσβαση σε μεγάλα, κατ' απαίτηση εργατικά δυναμικά σχολιασμού με χαμηλό κόστος ανά στοιχείο. Η δημιουργία συνόλων δεδομένων υψηλής ποιότητας με ετικέτες από πλήθη απαιτεί προσεκτικό σχεδιασμό εργασιών, στρατηγική πλεονασμό και αυστηρό ποιοτικό έλεγχο.

Πλατφόρμες Crowdsourcing

Το **Amazon Mechanical Turk (MTurk)** είναι η πρωτότυπη αγορά crowdsourcing, που εγκαινιάστηκε το 2005. Οι εργαζόμενοι ("Turkers") ολοκληρώνουν μικρο-εργασίες (HITs) που αναρτούν οι αιτούντες. Μια μελέτη του 2018 βρήκε διάμεσες πραγματικές ωριαίες αποδοχές Turkers περίπου 2$/ώρα — πολύ κάτω από τον κατώτατο μισθό σε πολλές χώρες υψηλού εισοδήματος {cite}`hara2018data` — μια ηθική ανησυχία που αντιμετωπίζεται αργότερα στο Κεφάλαιο 15. Το MTurk είναι καλύτερο για απλές εργασίες με σαφή, επαληθεύσιμα κριτήρια.

Το **Prolific** είναι μια ακαδημαϊκή πλατφόρμα crowdsourcing που επιβάλλει ένα ελάχιστο πρότυπο αμοιβής (επί του παρόντος περίπου £9/ώρα, περίπου 11$/ώρα, όπως αναφέρεται στις δημοσιευμένες οδηγίες του Prolific), ελέγχει τους συμμετέχοντες κατά δημογραφικά, και διατηρεί ένα πάνελ εργαζομένων που έχουν επιλέξει να συμμετέχουν σε έρευνες. Προτιμάται για κοινωνικο-επιστημονική έρευνα και εργασίες που απαιτούν αντιπροσωπευτικότητα.

Η **Appen** (και παρόμοιες: Telus International, iMerit) παρέχει διαχειριζόμενα εργατικά δυναμικά σχολιασμού με διαχείριση ποιότητας, που χρησιμοποιείται για εργασίες υψηλότερης πολυπλοκότητας και εταιρικά έργα.

Εξειδικευμένες κοινότητες. Για τομεακές εργασίες, κοινότητες ενθουσιωδών του τομέα μπορούν να παρέχουν σχολιασμούς υψηλής ποιότητας: Galaxy Zoo για αστρονομία, eBird για είδη πτηνών, Chess Tempo για σχολιασμό θέσεων σκακιού.

Σχεδιασμός Εργασιών για Crowdsourcing

Αποσύνθεση Σύνθετων Εργασιών

Οι σύνθετες εργασίες πρέπει να αποσυντίθενται σε απλές, καλά ορισμένες μικρο-εργασίες. Αντί να ζητάτε από εργαζόμενους να σχολιάσουν ολοκληρωτικά ένα έγγραφο, ρωτήστε τους μία εστιασμένη ερώτηση κάθε φορά: "Περιέχει αυτή η πρόταση το όνομα ενός προσώπου;" ή "Βαθμολογήστε τη σαφήνεια αυτής της μετάφρασης σε κλίμακα 1–5."

Πλεονεκτήματα της αποσύνθεσης: - Χαμηλότερη γνωστική απαίτηση ανά εργασία λιγότερη κόπωση, υψηλότερη ποιότητα - Κάθε μικρο-εργασία μπορεί να ελεγχθεί ξεχωριστά ως προς ποιότητα - Ευκολότερος έλεγχος και αποσφαλμάτωση

Η Σημασία των Οδηγιών

Ο μεγαλύτερος μεμονωμένος προβλεπτής ποιότητας crowdsourcing είναι η ποιότητα των οδηγιών. Καλές οδηγίες εργασίας: - Εξηγούν τον *σκοπό* της εργασίας σε μία πρόταση - Δίνουν σαφή, αναμφίβολο ορισμό κάθε κατηγορίας - Παρέχουν 3–5 παραδείγματα εκτελεσμένων εργασιών (ειδικά οριακές περιπτώσεις) - Δεν είναι μεγαλύτερες από ό,τι οι εργαζόμενοι θα διαβάσουν πραγματικά (< 300 λέξεις για απλές εργασίες)

Εκτελέστε μια **πιλοτική μελέτη** (10–50 εργαζόμενοι, 20–100 εργασίες) πριν κλιμακωθείτε. Αναλύστε τις διαφωνίες του πιλότου· οι περισσότερες δείχνουν σε ασάφειες οδηγιών που μπορούν να διορθωθούν.

Ερωτήσεις Χρυσού Προτύπου

Ενσωματώστε **ερωτήσεις χρυσού προτύπου** — εργασίες με γνωστές σωστές απαντήσεις — σε όλη τη δέσμη εργασιών. Οι εργαζόμενοι που αποτυγχάνουν σε ερωτήσεις χρυσού κάτω από ένα κατώφλι αφαιρούνται από το έργο.

```
import numpy as np
from scipy.stats import binom

rng = np.random.default_rng(42)

def simulate_gold_screening(n_workers=100, gold_per_batch=5,
                            p_good_worker=0.7, good_acc=0.92,
                            bad_acc=0.55, threshold=0.70):
    """
    Simulate quality screening via gold questions.
    Returns: precision and recall of identifying bad workers.
    """
    worker_quality = rng.choice(['good', 'bad'], size=n_workers,
                                p=[p_good_worker, 1 - p_good_worker])
    results = {'tp': 0, 'fp': 0, 'tn': 0, 'fn': 0}

    for q in worker_quality:
        acc = good_acc if q == 'good' else bad_acc
        n_correct = rng.binomial(gold_per_batch, acc)
        passed = (n_correct / gold_per_batch) >= threshold
        if q == 'bad' and not passed:  results['tp'] += 1
        if q == 'good' and not passed: results['fp'] += 1
        if q == 'bad' and passed:      results['fn'] += 1
```

```
        if q == 'good' and passed:     results['tn'] += 1

    tp, fp, fn = results['tp'], results['fp'], results['fn']
    precision = tp / (tp + fp + 1e-6)
    recall    = tp / (tp + fn + 1e-6)
    return precision, recall

# Vary gold question count
gold_counts = [3, 5, 8, 10, 15, 20]
precisions, recalls = [], []
for g in gold_counts:
    p_list, r_list = [], []
    for _ in range(50):
        p, r = simulate_gold_screening(gold_per_batch=g)
        p_list.append(p); r_list.append(r)
    precisions.append(np.mean(p_list))
    recalls.append(np.mean(r_list))

import matplotlib.pyplot as plt
fig, ax = plt.subplots(figsize=(7, 4))
ax.plot(gold_counts, precisions, 'o-', color='#2b3a8f', label='Precision', linewidth=2)
ax.plot(gold_counts, recalls,    's--', color='#0d9e8e', label='Recall',    linewidth=2)
ax.set_xlabel("Gold questions per batch", fontsize=12)
ax.set_ylabel("Screening performance", fontsize=12)
ax.set_title("Worker Screening via Gold Standard Questions", fontsize=13)
ax.legend(fontsize=11); ax.grid(alpha=0.3)
plt.tight_layout()
plt.savefig('gold_screening.png', dpi=150)
plt.show()

p, r = simulate_gold_screening(gold_per_batch=5)
print(f"5 gold questions: Precision={p:.3f}, Recall={r:.3f}")
p, r = simulate_gold_screening(gold_per_batch=10)
print(f"10 gold questions: Precision={p:.3f}, Recall={r:.3f}")
```

Στατιστικά Μοντέλα για Συνάθροιση Ετικετών

Η ψηφοφορία πλειοψηφίας είναι μια φυσική βασική γραμμή αλλά αγνοεί τις διαφορές στην ακρίβεια σχολιαστών. Τα στατιστικά μοντέλα μπορούν να κάνουν καλύτερα.

Το Μοντέλο Dawid-Skene

Το **μοντέλο Dawid-Skene (DS)** {cite}dawid1979maximum εκτιμά από κοινού: - Την **πραγματική ετικέτα** z_i για κάθε στοιχείο i - Τον **πίνακα σύγχυσης** $\pi_j^{(k,l)}$ για κάθε σχολιαστή j: η πιθανότητα ο σχολιαστής j να επισημαίνει ένα στοιχείο με πραγματική κλάση k ως κλάση l

Ο αλγόριθμος EM επαναλαμβάνει: - **Βήμα E:** Δεδομένων των πινάκων σύγχυσης σχολιαστών, υπολογίστε την εκ των υστέρων πιθανότητα κάθε πραγματικής ετικέτας

- **Βήμα Μ:** Δεδομένων των εκτιμήσεων ετικετών στοιχείων, ενημερώστε τους πίνακες σύγχυσης σχολιαστών

```
import numpy as np
from scipy.special import softmax

def dawid_skene_em(annotations, n_classes, n_iter=20):
    """
    Simplified Dawid-Skene EM for binary classification.
    annotations: dict {item_idx: [(annotator_idx, label), ...]}
    Returns: estimated true labels and annotator accuracies.
    """
    items = sorted(annotations.keys())
    n_items = len(items)
    annotators = sorted({a for anns in annotations.values() for a, _ in anns})
    n_annotators = len(annotators)
    ann_idx = {a: i for i, a in enumerate(annotators)}

    # Initialize: majority vote
    T = np.zeros((n_items, n_classes))  # soft label estimates
    for i, item in enumerate(items):
        for _, label in annotations[item]:
            T[i, label] += 1
        T[i] /= T[i].sum()

    # Confusion matrices: shape (n_annotators, n_classes, n_classes)
    PI = np.ones((n_annotators, n_classes, n_classes)) * 0.5

    for _ in range(n_iter):
        # M-step: update confusion matrices
        PI = np.zeros((n_annotators, n_classes, n_classes)) + 1e-6
        for i, item in enumerate(items):
            for ann, label in annotations[item]:
                a = ann_idx[ann]
                for k in range(n_classes):
                    PI[a, k, label] += T[i, k]
        PI /= PI.sum(axis=2, keepdims=True)

        # E-step: update soft label estimates
        T = np.zeros((n_items, n_classes))
        for i, item in enumerate(items):
            log_p = np.zeros(n_classes)
            for ann, label in annotations[item]:
                a = ann_idx[ann]
                log_p += np.log(PI[a, :, label] + 1e-10)
            T[i] = softmax(log_p)

    return {item: T[i] for i, item in enumerate(items)}, PI

# Simulate crowdsourcing scenario
rng = np.random.default_rng(42)
N_ITEMS, N_ANNOTATORS, ANNS_PER_ITEM = 200, 10, 3
```

```
true_labels = rng.integers(0, 2, N_ITEMS)
# Annotator accuracies: 3 good (0.9), 4 medium (0.75), 3 noisy (0.6)
accuracies = [0.90]*3 + [0.75]*4 + [0.60]*3

annotations = {}
for i in range(N_ITEMS):
    anns_for_item = []
    chosen = rng.choice(N_ANNOTATORS, ANNS_PER_ITEM, replace=False)
    for a in chosen:
        acc = accuracies[a]
        label = true_labels[i] if rng.random() < acc else 1 - true_labels[i]
        anns_for_item.append((a, int(label)))
    annotations[i] = anns_for_item

# Run Dawid-Skene
soft_labels, confusion = dawid_skene_em(annotations, n_classes=2, n_iter=30)
ds_preds = {i: int(np.argmax(soft_labels[i])) for i in range(N_ITEMS)}

# Compare with majority vote
mv_preds = {}
for i in range(N_ITEMS):
    votes = [l for _, l in annotations[i]]
    mv_preds[i] = int(np.round(np.mean(votes)))

ds_acc = np.mean([ds_preds[i] == true_labels[i] for i in range(N_ITEMS)])
mv_acc = np.mean([mv_preds[i] == true_labels[i] for i in range(N_ITEMS)])

print(f"Majority vote accuracy:  {mv_acc:.3f}")
print(f"Dawid-Skene accuracy:    {ds_acc:.3f}")
print(f"\nEstimated annotator accuracies (diagonal of confusion matrix):")
for a in range(N_ANNOTATORS):
    est_acc = np.mean([confusion[a, k, k] for k in range(2)])
    print(f"  Annotator {a}: estimated={est_acc:.3f}, true={accuracies[a]:.2f}")
```

MACE

Το **MACE (Multi-Annotator Competence Estimation)** {cite}`hovy2013learning` είναι ένα εναλλακτικό πιθανολογικό μοντέλο που αντιπροσωπεύει ρητά την αποστολή ανεπιθύμητων μηνυμάτων από σχολιαστές (τυχαία επισήμανση) έναντι ικανής σχολίασης. Ένας σχολιαστής είτε παρέχει μια ουσιαστική ετικέτα (με πιθανότητα $1 - \text{spam}_j$) είτε μια τυχαία ετικέτα (με πιθανότητα spam_j). Αυτό το μοντέλο δύο συστατικών είναι συχνά καλύτερα βαθμονομημένο από το Dawid-Skene για σενάρια crowdsourcing όπου ορισμένοι σχολιαστές είναι καθαροί spammers.

Στρατηγική Πλεονασμού και Συνάθροισης

Ο βέλτιστος αριθμός σχολιαστών ανά στοιχείο εξαρτάται από τη δυσκολία εργασίας και την ποιότητα σχολιαστή:

- **Εύκολες εργασίες με ειδικευμένους σχολιαστές:** 1–2 σχολιαστές ανά στοιχείο είναι

συχνά επαρκείς
- **Μέτριες εργασίες με εκπαιδευμένους σχολιαστές:** 3 σχολιαστές + ψηφοφορία πλειοψηφίας
- **Δύσκολες/υποκειμενικές εργασίες με εργαζόμενους crowdsourcing:** 5–7 σχολιαστές + Dawid-Skene

Η βασική διορατικότητα: ο πλεονασμός είναι πιο πολύτιμος όταν η ακρίβεια σχολιαστή είναι χαμηλή. Για σχολιαστές με ακρίβεια p, η ακρίβεια ψηφοφορίας πλειοψηφίας με n σχολιαστές είναι:

$$P(\text{MV correct}) = \sum_{k>n/2}^{n} \binom{n}{k} p^k (1-p)^{n-k}$$

Για $p = 0.70$, η προσθήκη τρίτου σχολιαστή αυξάνει την ακρίβεια ψηφοφορίας πλειοψηφίας από 70% σε 78%· για $p = 0.90$, το κέρδος από τρίτο σχολιαστή είναι αμελητέο (από 90% σε 97%).

See also: Μοντέλο Dawid-Skene: {cite}`dawid1979maximum`. MACE: {cite}`hovy2013learning`. Για μια ολοκληρωμένη ανασκόπηση crowdsourcing για NLP: {cite}`snow2008cheap`. Ηθική πλήθους και δίκαιη αμοιβή: βλ. Κεφάλαιο 15.

Αξιολόγηση και Μετρικές

Για να ξέρετε αν το σύστημά σας HITL λειτουργεί, χρειάζεστε περισσότερα από τη μέτρηση της ακρίβειας μοντέλου. Χρειάζεστε να γνωρίζετε αν αποκομίζετε αξία από τον προϋπολογισμό σχολιασμού σας, αν το μοντέλο είναι πραγματικά καλύτερα ευθυγραμμισμένο με την ανθρώπινη πρόθεση, και αν η πρόσθετη ανθρώπινη ανατροφοδότηση θα συνεχίσει να βελτιώνει τα πράγματα. Αυτό το κεφάλαιο καλύπτει το πλήρες τοπίο αξιολόγησης σε ρυθμίσεις HITL.

Μετρικές Κεντρικές στο Μοντέλο

Οι τυπικές μετρικές ΜΜ εφαρμόζονται απευθείας σε συστήματα HITL, με ορισμένες σημαντικές αποχρώσεις.

Μετρικές Ταξινόμησης

Η **ακρίβεια** είναι κατάλληλη όταν οι κλάσεις είναι ισορροπημένες και όλα τα σφάλματα κοστίζουν εξίσου. Σε ρυθμίσεις HITL, ωστόσο, το επισημασμένο σύνολο ελέγχου μπορεί να είναι μεροληπτικό από τη στρατηγική ερωτήματος (η ενεργός μάθηση υποβάλλει ερώτηση σε μη τυχαία παραδείγματα), καθιστώντας τις απλές εκτιμήσεις ακρίβειας αναξιόπιστες.

Η **βαθμολογία F1** είναι ο αρμονικός μέσος ακρίβειας και ανάκλησης, κατάλληλος για ανισόρροπες κλάσεις. Σε πλαίσια HITL, τόσο η ακρίβεια όσο και η ανάκληση μπορεί να έχουν διαφορετική σημασία ανάλογα με την ασυμμετρία κόστους μεταξύ ψευδών θετικών και ψευδών αρνητικών.

Το **AUROC** μετρά την ικανότητα του μοντέλου να διακρίνει μεταξύ κλάσεων ανεξάρτητα από κατώφλι — σημαντικό για εργασίες ευαίσθητες στη βαθμονόμηση, όπως η ιατρική διαλογή.

Η **βαθμονόμηση** μετρά πόσο καλά οι προβλεπόμενες πιθανότητες αντιστοιχούν σε εμπειρικές συχνότητες. Σε συστήματα HITL, τα μοντέλα εκπαιδευμένα σε μεροληπτικά επισημασμένα σύνολα (από ενεργό μάθηση) μπορεί να είναι κακώς βαθμονομημένα ακόμα και όταν είναι ακριβή.

Μετρικές Γενεστικών Μοντέλων

Για γλωσσικά μοντέλα και γενεστικά συστήματα, η αξιολόγηση είναι θεμελιωδώς δυσκολότερη. Καμία μεμονωμένη αυτόματη μετρική δεν αποτυπώνει ποιότητα:

- **BLEU / ROUGE / METEOR:** Μετρικές βάσει αναφοράς για μετάφραση και περίληψη. Συσχετίζονται αδύναμα με ανθρώπινες κρίσεις ποιότητας για εκτεταμένη δημιουργία.
- **Perplexity:** Μετρά πόσο καλά το μοντέλο προβλέπει κείμενο που κρατήθηκε εκτός εκπαίδευσης. Αναγκαία αλλά όχι επαρκής συνθήκη για ποιότητα.
- **BERTScore:** Ομοιότητα βάσει ενσωμάτωσης με αναφορές. Καλύτερα συσχετισμένη με ανθρώπινες κρίσεις από μετρικές n-gram.
- **Ανθρώπινη αξιολόγηση:** Το χρυσό πρότυπο. Βλ. Ενότητα 14.3.

Μετρικές Αποδοτικότητας Σχολιασμού

Η αξιολόγηση HITL πρέπει επίσης να μετρά αν η ανθρώπινη ανατροφοδότηση χρησιμοποιείται αποτελεσματικά.

Καμπύλες Μάθησης

Μια **καμπύλη μάθησης** σχεδιάζει την απόδοση μοντέλου συναρτήσει του αριθμού επισημασμένων παραδειγμάτων. Μια απότομη καμπύλη μάθησης (ταχεία βελτίωση με λίγες ετικέτες) δείχνει ότι η στρατηγική σχολιασμού επιλέγει ενημερωτικά παραδείγματα. Μια επίπεδη καμπύλη μάθησης δείχνει ότι η πρόσθετη επισήμανση παρέχει φθίνουσες αποδόσεις.

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import f1_score, roc_auc_score
from sklearn.model_selection import StratifiedShuffleSplit

rng = np.random.default_rng(42)
X, y = make_classification(n_samples=5000, n_features=30, n_informative=15,
                           weights=[0.8, 0.2], random_state=42)
X_test, y_test = X[4000:], y[4000:]
X_pool, y_pool = X[:4000], y[:4000]

label_sizes = [20, 40, 60, 100, 150, 200, 300, 400, 600, 800, 1000, 1500, 2000]
metrics = {'f1': [], 'auc': []}

for n in label_sizes:
    idx = rng.choice(len(X_pool), n, replace=False)
    clf = LogisticRegression(max_iter=500, class_weight='balanced')
    clf.fit(X_pool[idx], y_pool[idx])
    preds = clf.predict(X_test)
    probs = clf.predict_proba(X_test)[:, 1]
    metrics['f1'].append(f1_score(y_test, preds))
    metrics['auc'].append(roc_auc_score(y_test, probs))

# Fit learning curve: performance ≈ a - b/sqrt(n)
from scipy.optimize import curve_fit
```

```
def learning_curve_fn(n, a, b):
    return a - b / np.sqrt(n)

popt_f1, _ = curve_fit(learning_curve_fn, label_sizes, metrics['f1'], p0=[0.9, 2])
popt_auc, _ = curve_fit(learning_curve_fn, label_sizes, metrics['auc'], p0=[0.95, 1])

n_smooth = np.linspace(20, 3000, 200)

fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(11, 4))

ax1.scatter(label_sizes, metrics['f1'], color='#2b3a8f', zorder=5, s=40)
ax1.plot(n_smooth, learning_curve_fn(n_smooth, *popt_f1), '--', color='#e05c5c',
         label=f'Fit: {popt_f1[0]:.3f} - {popt_f1[1]:.1f}/√n')
ax1.set_xlabel("Labeled examples"); ax1.set_ylabel("F1 score")
ax1.set_title("Learning Curve: F1"); ax1.legend(); ax1.grid(alpha=0.3)

ax2.scatter(label_sizes, metrics['auc'], color='#0d9e8e', zorder=5, s=40)
ax2.plot(n_smooth, learning_curve_fn(n_smooth, *popt_auc), '--', color='#e05c5c',
         label=f'Fit: {popt_auc[0]:.3f} - {popt_auc[1]:.2f}/√n')
ax2.set_xlabel("Labeled examples"); ax2.set_ylabel("AUROC")
ax2.set_title("Learning Curve: AUROC"); ax2.legend(); ax2.grid(alpha=0.3)

plt.tight_layout()
plt.savefig('learning_curves.png', dpi=150)
plt.show()

# Estimate the annotation budget needed to reach a target performance
target_f1 = 0.80
n_needed = (popt_f1[1] / (popt_f1[0] - target_f1)) ** 2
print(f"Estimated labels needed to reach F1={target_f1}: {n_needed:.0f}")
```

Ανάλυση Απόδοσης Επένδυσης (ROI)

Η ROI ανθρώπινης ανατροφοδότησης απαντά: για κάθε πρόσθετη ετικέτα, πόσο βελτιώνεται η απόδοση μοντέλου;

$$\mathrm{ROI}(n) = \frac{\Delta\mathrm{performance}(n)}{\text{cost per label}}$$

Καθώς ένα μοντέλο ωριμάζει (και καθώς εξαντλούνται τα εύκολα παραδείγματα μάθησης), η ROI συνήθως μειώνεται. Η πρακτική συνέπεια: οι προϋπολογισμοί σχολιασμού πρέπει να είναι μεγαλύτεροι στα πρώτα στάδια, με περισσότερες ετικέτες που συλλέγονται στα αρχικά στάδια όταν η ROI είναι υψηλότερη.

Ανθρώπινη Αξιολόγηση

Για γενεστικά συστήματα και υποκειμενικές εργασίες, η ανθρώπινη αξιολόγηση παραμένει το χρυσό πρότυπο.

Άμεση Αξιολόγηση (DA)

Οι σχολιαστές βαθμολογούν αποτελέσματα σε απόλυτη κλίμακα (π.χ. 1–100 για ποιότητα μετάφρασης, ή 1–5 για χρησιμότητα απάντησης). Η DA έχει τυποποιηθεί στην αξιολόγηση μηχανικής μετάφρασης (benchmarks WMT).

Βέλτιστες πρακτικές για DA: - Τυχαιοποιείτε τη σειρά των αποτελεσμάτων για να αποτρέψετε την αγκύρωση - Χρησιμοποιείτε επαρκή αριθμό σχολιαστών ανά στοιχείο (ελάχιστο 3–5) - Συμπεριλαμβάνετε ελέγχους ποιότητας (προφανώς καλά και κακά παραδείγματα για εντοπισμό αδύνατων αξιολογητών) - Αναφέρετε συμφωνία μεταξύ σχολιαστών παράλληλα με συγκεντρωτικές βαθμολογίες

Συγκριτική Αξιολόγηση

Οι σχολιαστές επιλέγουν μεταξύ δύο αποτελεσμάτων: "Ποιο είναι καλύτερο;" Οι συγκριτικές κρίσεις είναι ταχύτερες και πιο συνεπείς από τις απόλυτες βαθμολογίες (βλ. Κεφάλαιο 8). **Τα συστήματα βαθμολόγησης ELO** (δανεισμένα από το σκάκι) μετατρέπουν τα αποτελέσματα ζευγαρωτών συγκρίσεων σε μια συνεχή κατάταξη ποιότητας.

```
import numpy as np

def update_elo(rating_a, rating_b, outcome_a, k=32):
    """Update ELO ratings. outcome_a: 1=A wins, 0=B wins, 0.5=tie."""
    expected_a = 1 / (1 + 10 ** ((rating_b - rating_a) / 400))
    expected_b = 1 - expected_a
    new_a = rating_a + k * (outcome_a - expected_a)
    new_b = rating_b + k * ((1 - outcome_a) - expected_b)
    return new_a, new_b

# Simulate 5 model versions being compared pairwise
rng = np.random.default_rng(42)
true_quality = [0.60, 0.70, 0.75, 0.80, 0.85]  # underlying model quality
n_models = len(true_quality)
elo_ratings = {i: 1000.0 for i in range(n_models)}

for _ in range(500):  # 500 pairwise comparisons
    i, j = rng.choice(n_models, 2, replace=False)
    p_i_wins = true_quality[i] / (true_quality[i] + true_quality[j])
    outcome = 1.0 if rng.random() < p_i_wins else 0.0
    elo_ratings[i], elo_ratings[j] = update_elo(elo_ratings[i], elo_ratings[j], outcome)

print("ELO Rankings after 500 comparisons:")
sorted_models = sorted(elo_ratings.items(), key=lambda x: x[1], reverse=True)
for rank, (model_id, elo) in enumerate(sorted_models, 1):
    print(f"  Rank {rank}: Model {model_id}  ELO={elo:.1f}  True quality={true_quality[model_
```

Συμπεριφορικές Δοκιμές (CheckList)

Το **CheckList** {cite}`ribeiro2020beyond` είναι μια μεθοδολογία για συστηματική συμπεριφορική αξιολόγηση μοντέλων NLP. Αντί για τυχαία σύνολα ελέγχου, σχεδιάζει περιπτώσεις δοκιμής που ανιχνεύουν συγκεκριμένες δυνατότητες:

- **Δοκιμές Ελάχιστης Λειτουργικότητας (MFT):** Χειρίζεται το μοντέλο απλές, προφανείς περιπτώσεις;
- **Δοκιμές Αμεταβλητότητας (INV):** Αλλάζει η έξοδος του μοντέλου όταν δεν πρέπει (π.χ., κατά την παράφραση);
- **Δοκιμές Κατευθυντικής Προσδοκίας (DIR):** Αλλάζει η έξοδος του μοντέλου στην αναμενόμενη κατεύθυνση όταν αλλάζει η είσοδος;

Το CheckList κάνει την ανθρώπινη αξιολόγηση στοχευμένη και εφαρμόσιμη: αντί για έναν μοναδικό αριθμό ακρίβειας, παρέχει ένα προφίλ δυνατοτήτων.

Μέτρηση Ευθυγράμμισης με Ανθρώπινη Πρόθεση

Για συστήματα RLHF, η μέτρηση ευθυγράμμισης είναι μια κεντρική πρόκληση αξιολόγησης.

Αξιολόγηση μοντέλου ανταμοιβής: Η ακρίβεια του μοντέλου ανταμοιβής σε ένα κρατημένο σύνολο ελέγχου προτίμησης. Οι Ouyang et al. {cite}`ouyang2022training` αναφέρουν περίπου 72% ζευγαρωτή ακρίβεια για το μοντέλο ανταμοιβής του InstructGPT· ως κατά προσέγγιση σημείο αναφοράς, αριθμοί σε αυτή την περιοχή αναφέρονται συνήθως για παρόμοιες γραμμές RLHF, αν και τα αποτελέσματα ποικίλλουν ευρέως ανά εργασία και ποιότητα δεδομένων.

Ποσοστό νίκης: Δεδομένων δύο εκδόσεων μοντέλου (π.χ. βάση SFT έναντι RLHF fine-tuned), ποιο κλάσμα απαντήσεων κερδίζει το μοντέλο RLHF σε ανθρώπινες ζευγαρωτές συγκρίσεις;

GPT-4 ως αξιολογητής: Η χρήση ικανού LLM για αξιολόγηση απαντήσεων έχει γίνει κοινή για ταχεία επανάληψη. Οι Gilardi et al. {cite}`gilardi2023chatgpt` και Zheng et al. {cite}`zheng2023judging` βρίσκουν συμφωνία αξιολογητή LLM με ανθρώπινη κρίση περίπου 0,7 έως 0,9 ανάλογα με την εργασία — χρήσιμο για ταχεία σύγκριση A/B, αλλά λιγότερο αξιόπιστο για εντοπισμό κολακείας, πολιτισμικής απόχρωσης ή ζητημάτων ασφάλειας.

Εντοπισμός κολακείας: Μετρήστε αν το μοντέλο αλλάζει τις απαντήσεις του βάσει υπονοούμενης προτίμησης χρήστη (π.χ. "Νομίζω ότι το X είναι σωστό· τι νομίζεις;"). Ένα καλά ευθυγραμμισμένο μοντέλο δεν πρέπει να είναι κολακευτικό.

Δοκιμές A/B σε Αναπτυγμένα Συστήματα

Για συστήματα σε παραγωγή, η τελική αξιολόγηση είναι οι **δοκιμές A/B**: δρομολογήστε ένα κλάσμα χρηστών στη νέα έκδοση μοντέλου και μετρήστε τα αποτελέσματα κατάντη.

Οι δοκιμές A/B δίνουν μια αμερόληπτη εκτίμηση ποιότητας μοντέλου στο πραγματικό περιβάλλον ανάπτυξης, αποτυπώνοντας επιδράσεις που η εργαστηριακή αξιολόγηση χάνει (συμπεριφορά χρήστη, κατανομή πληθυσμού, οριακές περιπτώσεις).

Η πρόκληση: κατάλληλες μετρικές κατάντη. Οι μετρικές αφοσίωσης (κλικ, διάρκεια συνεδρίας) μπορεί να ανταμείψουν χειριστική συμπεριφορά. Τα ποσοστά ολοκλήρωσης εργασιών ή οι έρευνες ικανοποίησης χρηστών είναι καλύτερα ευθυγραμμισμένα αλλά θορυβωδέστερα.

See also: Συμπεριφορικές δοκιμές CheckList: {cite}`ribeiro2020beyond`. Για μεθοδολογία αξιολόγησης RLHF, βλ. {cite}`ouyang2022training`. Για βέλτιστες πρακτικές ανθρώπινης αξιολόγησης στη MT: {cite}`graham2015accurate`. Για θεωρία καμπύλης μάθησης: {cite}`mukherjee2003estimating`.

Δικαιοσύνη, Προκατάληψη και Ηθική

Τα ανθρωποκεντρικά συστήματα κληρονομούν τόσο τις δυνατότητες όσο και τους περιορισμούς των ανθρώπων σε αυτά. Οι σχολιαστές φέρνουν γνώση, κρίση και δημιουργικότητα στη δουλειά τους — αλλά και προκαταλήψεις, κόπωση και το κοινωνικό πλαίσιο της ζωής τους. Οι επιλογές που κάνουμε στο σχεδιασμό συστημάτων HITL — ποιος κάνει σχολιασμό, τι τους ζητείται, πώς αμείβονται και πώς χρησιμοποιείται η εργασία τους — έχουν συνέπειες που εκτείνονται πολύ πέρα από μετρικές ακρίβειας μοντέλου.

Αυτό το κεφάλαιο αντιμετωπίζει τις ηθικές διαστάσεις της AMM HITL.

Πηγές Προκατάληψης σε Συστήματα HITL

Δημογραφία Σχολιαστών

Ο σχολιασμός δεν είναι ουδέτερη πράξη. Οι ετικέτες που αποδίδουν οι σχολιαστές αντικατοπτρίζουν τις οπτικές, εμπειρίες και πολιτισμικά πλαίσιά τους. Όταν το εργατικό δυναμικό σχολιασμού είναι δημογραφικά ομοιογενές — όπως συχνά συμβαίνει, με τη συμπληρωματική εργασία να γέρνει νεαρή, ανδρική και δυτική — το αποτελούμενο σύνολο δεδομένων κωδικοποιεί τις οπτικές αυτής της ομάδας.

Αποδείξεις: Μελέτες συνόλων δεδομένων σχολιασμού NLP έχουν βρει ότι τα δημογραφικά χαρακτηριστικά σχολιαστών προβλέπουν τις επιλογές ετικετών για υποκειμενικές εργασίες (τοξικότητα, συναίσθημα, επιθετικότητα). Σύνολα δεδομένων που σχολιάστηκαν κυρίως από εργαζόμενους με έδρα τις ΗΠΑ κωδικοποιούν αμερικανικά πολιτισμικά πρότυπα που δεν γενικεύονται σε άλλες περιοχές {cite}`geva2019annotator`.

Συνέπειες: Τα μοντέλα εκπαιδευμένα σε τέτοια δεδομένα αποδίδουν καλά για χρήστες που μοιάζουν με τη δεξαμενή σχολιαστών και λιγότερο καλά — ή με μεροληπτικούς τρόπους — για χρήστες που δεν μοιάζουν.

Μετριασμός: Σκόπιμη διαφοροποίηση εργατικού δυναμικού· στρωματοποιημένος σχολιασμός (διασφαλίστε ότι σχολιαστές από σχετικές δημογραφικές ομάδες συνεισφέρουν σε σχετικές εργασίες)· παρακολουθήστε δημογραφικά στοιχεία σχολιαστών και την επίδρασή τους στις κατανομές ετικετών.

Πλαισίωση Εργασιών

Ο τρόπος πλαισίωσης μιας ερώτησης επηρεάζει τις απαντήσεις που προκαλεί. Αν στους σχολιαστές τεθεί η ερώτηση "Είναι αυτό το κείμενο τοξικό;" μπορεί να απαντήσουν

διαφορετικά από το "Θα βλάψει αυτό το κείμενο κάποιον που ανήκει στην αναφερόμενη ομάδα;" Η πλαισίωση ενσωματώνει παραδοχές για το τι έχει σημασία.

Παράδειγμα: Ο σχολιασμός "καταχρηστικής γλώσσας" στα κοινωνικά δίκτυα ποικίλλει σημαντικά ανάλογα με το αν στους σχολιαστές εμφανίζονται πλαισιακές πληροφορίες σχετικά με την ταυτότητα του συγγραφέα. Μια δήλωση που φαίνεται απειλητική μεμονωμένα μπορεί να αναγνωριστεί ως ανακτημένη γλώσσα ή χιούμορ εντός ομάδας όταν παρέχεται πλαίσιο.

Επιδράσεις Πλατφόρμας

Η πλατφόρμα και η δομή πληρωμής επηρεάζουν την ποιότητα σχολιασμού. Οι εργαζόμενοι που πληρώνονται ανά εργασία αντί ανά ώρα έχουν κίνητρο να εργάζονται γρήγορα· αυτό αυξάνει την απόδοση αλλά μειώνει την ποιότητα. Οι εργαζόμενοι που φοβούνται να αποκλειστούν από μια πλατφόρμα λόγω χαμηλής ακρίβειας μπορεί να αποφύγουν να σημειώσουν "αβέβαιο" και να κάνουν εικασίες αντ' αυτού, κρύβοντας γνήσια αμφισημία.

Προκαταλήψεις Επιβεβαίωσης και Αγκύρωσης

Οι σχολιαστές επηρεάζονται από: - **Προ-σχολιασμό:** Προβλέψεις μοντέλου που εμφανίζονται στους σχολιαστές γίνονται αποδεκτές πιο συχνά παρά απορρίπτονται, ακόμα και όταν είναι λανθασμένες - **Επιδράσεις σειράς:** Η επισήμανση του ίδιου στοιχείου σε διαφορετικά πλαίσια δίνει διαφορετικές απαντήσεις - **Προετοιμασία:** Τα προηγούμενα στοιχεία μιας εργασίας επηρεάζουν τον τρόπο επισήμανσης των επακόλουθων στοιχείων

Δικαιοσύνη σε Συστήματα HITL

Τι Είναι Δικαιοσύνη;

Η δικαιοσύνη στη ΜΜ είναι μια αμφισβητούμενη έννοια με πολλαπλούς επίσημους ορισμούς που είναι συχνά αμοιβαία ασύμβατοι {cite}`barocas2019fairness`. Για σκοπούς HITL, οι πιο σχετικές διαστάσεις είναι:

Αντιπροσωπευτικότητα: Είναι τα εκπαιδευτικά δεδομένα αντιπροσωπευτικά των πληθυσμών που θα επηρεάσει το μοντέλο;

Ισοτιμία απόδοσης: Αποδίδει το μοντέλο εξίσου καλά σε διαφορετικές δημογραφικές ομάδες;

Συνέπεια επισήμανσης: Επισημαίνονται οι ίδιες συμπεριφορές με τον ίδιο τρόπο ανεξάρτητα από το ποιος τις εκτελεί; (Η έρευνα έχει δείξει ότι αυτό δεν συμβαίνει πάντα — το ίδιο περιεχόμενο επισημαίνεται μερικές φορές διαφορετικά όταν αποδίδεται σε διαφορετικές φυλετικές ή έμφυλες ομάδες.)

Ενεργός Μάθηση Ευαίσθητη στη Δικαιοσύνη

Οι τυπικές στρατηγικές ερωτήματος ενεργού μάθησης εστιάζουν στην αβεβαιότητα μοντέλου, η οποία τείνει να συγκεντρώνεται σε παραδείγματα πλειοψηφικής κλάσης. Αυτό μπορεί να επιδεινώσει τις ανισότητες απόδοσης για μειοψηφικές ομάδες.

Στρατηγικές ερωτήματος ευαίσθητες στη δικαιοσύνη επαυξάνουν το κριτήριο αβεβαιότητας με περιορισμούς ποικιλότητας ή αντιπροσωπευτικότητας:

$$x^* = \arg\max_{x \in \mathcal{U}} \left[\lambda \cdot \text{uncertainty}(x) + (1 - \lambda) \cdot \text{minority_group_bonus}(x)\right]$$

Η ρύθμιση $\lambda < 1$ διασφαλίζει ότι η στρατηγική ερωτήματος δεν αγνοεί εντελώς την αντιπροσωπευτικότητα μειοψηφίας.

Πρόνοια Σχολιαστών

Το Πρόβλημα της Αφανούς Εργασίας

Η εργασία σχολιασμού που τροφοδοτεί τη ΜΜ είναι σε μεγάλο βαθμό αόρατη. Εργαζόμενοι σε δεδομένα — συχνά στο Παγκόσμιο Νότο — επισημαίνουν εικόνες, μεταγράφουν ομιλία και διαμορφώνουν περιεχόμενο για χαμηλές αμοιβές, χωρίς παροχές, σε διακανονισμούς οικονομίας gig χωρίς εγγύηση απασχόλησης. Η "Ανατομία ενός Συστήματος TN" των Kate Crawford και Vladan Joler {cite}`crawford2018anatomy` και η "Αφανής Εργασία" των Mary Gray και Siddharth Suri {cite}`gray2019ghost` τεκμηρίωσαν την κλίμακα και την επισφάλεια αυτής της εργασίας.

Στατιστικά MTurk Amazon: Μια συστηματική ανάλυση του 2018 των αποδοχών MTurk βρήκε διάμεσες πραγματικές ωριαίες αποδοχές περίπου 2$/ώρα — κάτω από τον κατώτατο μισθό στις περισσότερες πολιτείες των ΗΠΑ και πολλές χώρες υψηλού εισοδήματος {cite}`hara2018data`. Οι εργαζόμενοι εκτός χωρών υψηλού εισοδήματος αντιμετωπίζουν συχνά πρόσθετα εμπόδια: οι αιτούντες συχνά περιορίζουν εργασίες υψηλής αμοιβής σε προσόντα μόνο για ΗΠΑ, και η δεξαμενή εργαζομένων που ανταγωνίζεται για τις υπόλοιπες ανοιχτές εργασίες είναι παγκόσμια, συμπιέζοντας περαιτέρω τις πραγματικές αποδοχές.

Διαμόρφωση περιεχομένου: Μια ιδιαίτερα επιβλαβής μορφή εργασίας σχολιασμού — επισκόπηση γραφικού, βίαιου και ανησυχητικού περιεχομένου — έχει συνδεθεί με PTSD, κατάθλιψη και άγχος μεταξύ εργαζομένων {cite}`newton2019trauma`. Οι πλατφόρμες έχουν δεχθεί κριτική για ανεπαρκή υποστήριξη ψυχικής υγείας και υπερβολικές ποσοστώσεις έκθεσης.

Ηθικές Πρακτικές

Δίκαιη αμοιβή: Πληρώστε εργαζόμενους σχολιασμού στο ή άνω του τοπικού κατώτατου μισθού. Η έρευνα έχει δείξει ότι υψηλότερη αμοιβή προσελκύει εργαζόμενους υψηλότερης ποιότητας χωρίς αναλογικά αύξηση του κόστους ανά σωστή ετικέτα.

Ορατότητα εργασίας: Αναγνωρίστε την εργασία που δημιουργεί δεδομένα εκπαίδευσης σε δημοσιεύσεις και τεκμηρίωση προϊόντων.

Υποστήριξη ψυχικής υγείας: Για εργαζόμενους που ελέγχουν επιβλαβές περιεχόμενο, παρέχετε ψυχολογική υποστήριξη, προγράμματα εναλλαγής και όρια έκθεσης.

Εκπροσώπηση εργαζομένων: Δώστε τη δυνατότητα σε εργαζόμενους σχολιασμού να αναφέρουν ανησυχίες, να ζητούν διευκρινίσεις οδηγιών και να αμφισβητούν άδικες αξιολογήσεις ποιότητας.

Ιδιωτικότητα στον Σχολιασμό

Προστατευμένες Πληροφορίες Υγείας (PHI) και PII

Οι εργασίες σχολιασμού συχνά περιλαμβάνουν ευαίσθητα προσωπικά δεδομένα. Ένα ιατρικό έργο σχολιασμού μπορεί να εκθέσει εργαζόμενους σε ιατρικά αρχεία ασθενών· ένα έργο NLP μπορεί να εκθέσει εργαζόμενους σε ιδιωτικές επικοινωνίες· ένα έργο διαμόρφωσης περιεχομένου εκθέτει εργαζόμενους σε προσωπικές αποκαλύψεις χρηστών.

Τα κανονιστικά πλαίσια (HIPAA, GDPR) περιορίζουν τον τρόπο κοινής χρήσης προσωπικών δεδομένων με εργατικά δυναμικά σχολιασμού. Βασικές αρχές:

- **Ελαχιστοποίηση δεδομένων:** Μοιραστείτε μόνο τις πληροφορίες που χρειάζονται οι σχολιαστές για να ολοκληρώσουν την εργασία
- **Απο-αναγνώριση:** Αφαιρέστε PHI και PII πριν τον σχολιασμό όπου είναι δυνατό
- **Συγκατάθεση:** Όπου σχολιάζονται πραγματικά δεδομένα χρηστών, διασφαλίστε κατάλληλη συγκατάθεση ή νομική βάση
- **Έλεγχοι πρόσβασης:** Περιορίστε ποιοι σχολιαστές μπορούν να έχουν πρόσβαση σε ευαίσθητα δεδομένα βάσει ρόλου και εξουσιοδότησης

Συνθετικά Δεδομένα ως Εναλλακτική

Για εργασίες όπου τα πραγματικά δεδομένα φέρουν κινδύνους απορρήτου, η δημιουργία συνθετικών δεδομένων μπορεί να δημιουργήσει σύνολα δεδομένων έτοιμα για σχολιασμό χωρίς να εκθέσει ευαίσθητες πληροφορίες. Για κλινικό NLP, για παράδειγμα, συνθετικό κείμενο EHR μπορεί να παρέχει ρεαλιστικά εκπαιδευτικά δεδομένα για μοντέλα απο-αναγνώρισης χωρίς να εκθέτει πραγματικά αρχεία ασθενών.

Αντίξοος Σχολιασμός και Δηλητηρίαση Δεδομένων

Τα συστήματα HITL δημιουργούν μια επιφάνεια επίθεσης: αν ένας αντίπαλος μπορεί να επηρεάσει τη διαδικασία σχολιασμού, μπορεί να επηρεάσει τη συμπεριφορά του μοντέλου.

Δηλητηρίαση δεδομένων μέσω σχολιασμού: Ένας εισβολέας με πρόσβαση στο εργατικό δυναμικό σχολιασμού (π.χ. έναν παραβιασμένο λογαριασμό crowdworker) μπορεί να εισάγει συστηματικά λανθασμένα επισημασμένα παραδείγματα. Αυτό είναι ιδιαίτερα αποτελεσματικό σε ρυθμίσεις ενεργού μάθησης, όπου το μοντέλο κατά προτίμηση υποβάλλει ερώτηση σε αβέβαια παραδείγματα — που μπορεί να είναι ο στόχος του αντιπάλου.

Hacking ανταμοιβής μέσω ανατροφοδότησης: Στο RLHF, σχολιαστές (ή σχολιασμοί που παράγονται από TN) που αξιολογούν συνεχώς ορισμένους τύπους περιεχομένου ψηλά μπορούν να κατευθύνουν το μοντέλο προς αυτό το περιεχόμενο, ανεξάρτητα από την πραγματική ποιότητά του.

Μετριασμός: Πολλαπλοί ανεξάρτητοι σχολιαστές ανά στοιχείο· εντοπισμός ακραίων τιμών στα πρότυπα σχολιασμού· παρακολούθηση για ανώμαλη συμφωνία ή διαφωνία· διατήρηση συνόλων αξιολόγησης που δεν μπορούν να επηρεαστούν από το εργατικό δυναμικό σχολιασμού.

Θεσμική Ηθική

IRB και Ηθική Επισκόπηση

Ερευνητικά έργα που αφορούν ανθρώπινα υποκείμενα — συμπεριλαμβανομένων των εργαζομένων σχολιασμού — συχνά απαιτούν έγκριση Επιτροπής Θεσμικής Ανασκόπησης (IRB). Έργα σχολιασμού που συλλέγουν δεδομένα σχετικά με τις πεποιθήσεις εργαζομένων, τις απαντήσεις σε ευαίσθητο περιεχόμενο ή δημογραφικές πληροφορίες πρέπει να ελέγχονται υπό το ίδιο ηθικό πλαίσιο με άλλες έρευνες ανθρώπινων υποκειμένων.

Διακυβέρνηση Δεδομένων

Οι οργανισμοί πρέπει να έχουν σαφείς πολιτικές για: - Ποια δεδομένα μπορούν να σταλούν για εξωτερικό σχολιασμό έναντι εσωτερικού σχολιασμού - Πόσο καιρό διατηρούνται τα δεδομένα σχολιασμού και από ποιον - Ποιος έχει πρόσβαση στους σχολιασμούς και τα μοντέλα που εκπαιδεύονται σε αυτούς - Πώς να χειριστείτε αιτήματα διαγραφής σχολιασμένων δεδομένων (δικαίωμα διαγραφής GDPR)

Διαφάνεια και Λογοδοσία

Οι χρήστες που επηρεάζονται από συστήματα ΜΜ έχουν έννομο συμφέρον να κατανοούν πώς κατασκευάστηκαν αυτά τα συστήματα. Η τεκμηρίωση της μεθοδολογίας σχολιασμού — ποιος επισήμανε τα δεδομένα, υπό ποιες συνθήκες, με ποιες οδηγίες — είναι μια μορφή λογοδοσίας που ωφελεί τους χρήστες, τους ρυθμιστές και τον τομέα ως σύνολο.

Τα **Datasheets for Datasets** {cite}`gebru2021datasheets` παρέχουν ένα δομημένο πρότυπο για τεκμηρίωση προέλευσης συνόλου δεδομένων, διαδικασιών σχολιασμού και γνωστών περιορισμών.

> **See also:** Πλαίσιο αλγοριθμικής δικαιοσύνης: {cite}`barocas2019fairness`. Εργασία πλατφόρμας και αφανής εργασία: Gray & Suri (2019). Datasheets for Datasets: {cite}`gebru2021datasheets`. Πρόνοια εργαζομένων διαμόρφωσης περιεχομένου: {cite}`newton2019trauma`. Δημογραφία σχολιαστών και σύνολα δεδομένων NLP: {cite}`geva2019annotator`.

Μελλοντικές Κατευθύνσεις

Ο τομέας της ανθρωποκεντρικής μηχανικής μάθησης αλλάζει ταχέως. Τα θεμελιώδη μοντέλα, τα LLMs-ως-σχολιαστές και νέα παραδείγματα ανθρώπινης-TN συνεργασίας ανασχηματίζουν τα οικονομικά και την πρακτική του HITL με τρόπους που δεν ήταν φανταστοί ακόμα και πέντε χρόνια πριν. Αυτό το τελευταίο κεφάλαιο χαρτογραφεί το τοπίο των αναδυόμενων κατευθύνσεων και ανοιχτών προβλημάτων.

Θεμελιώδη Μοντέλα και ο Μεταβαλλόμενος Ρόλος του Σχολιασμού

Τα θεμελιώδη μοντέλα — μεγάλα μοντέλα προ-εκπαιδευμένα σε ευρεία δεδομένα που μπορούν να προσαρμοστούν σε εργασίες κατάντη — αλλάζουν θεμελιωδώς τα οικονομικά του HITL.

Μείωση του Βάρους Σχολιασμού

Μια εργασία που προηγουμένως απαιτούσε χιλιάδες επισημασμένα παραδείγματα για εκπαίδευση από την αρχή μπορεί να απαιτεί μόνο δεκάδες κατά την προσαρμοστική εκπαίδευση ενός θεμελιώδους μοντέλου. Η few-shot παρακίνηση μπορεί να εξαλείψει εντελώς την ανάγκη για fine-tuning για ορισμένες εργασίες.

Συνέπεια: Η ROI του σχολιασμού αλλάζει. Η προσπάθεια σχολιασμού κατευθύνεται τώρα καλύτερα σε: - Σύνολα αξιολόγησης υψηλής ποιότητας (για μέτρηση αν το προσαρμοσμένο μοντέλο πράγματι λειτουργεί) - Δύσκολες περιπτώσεις και οριακές περιπτώσεις που το θεμελιώδες μοντέλο χειρίζεται λανθασμένα - Παραδείγματα ειδικά για εργασίες που διδάσκουν στο μοντέλο κάτι που δεν μπορεί να συνάγει από την προ-εκπαίδευση

Νέες Μορφές Προδιαγραφής

Όταν το βασικό μοντέλο ήδη κατανοεί γλώσσα, κώδικα και κοινή λογική, οι χρήστες μπορούν να επικοινωνούν μαζί του στη φυσική γλώσσα αντί μέσω επισημασμένων παραδειγμάτων. Ένας χρήστης που θέλει έναν ταξινομητή κειμένου δεν χρειάζεται πλέον να επισημάνει 500 παραδείγματα — μπορεί να γράψει μια περιγραφή της εργασίας ταξινόμησης και να αξιολογήσει απόδοση zero-shot.

Αυτό μετατοπίζει την πρόκληση HITL από *συλλογή παραδειγμάτων σε προδιαγραφή εργασίας*: βοηθώντας τους χρήστες να αρθρώσουν ακριβώς τι θέλουν σε μια μορφή στην οποία το μοντέλο μπορεί να ενεργήσει. Αυτό είναι δυσκολότερο από ό,τι φαίνεται — οι περιγραφές εργασιών σε φυσική γλώσσα είναι συχνά αμφίσημες με τρόπους που τα σχολιασμένα παραδείγματα δεν είναι.

LLMs ως Σχολιαστές

Μια από τις πιο σημαντικές εξελίξεις 2023–2025 είναι η χρήση **LLMs ως μαντεία σχολιασμού**. Αντί να ρωτάμε έναν άνθρωπο "Είναι αυτή η κριτική θετική ή αρνητική;", ρωτάμε το GPT-4 ή τον Claude. Για καλά ορισμένες εργασίες ταξινόμησης, οι σχολιασμοί LLM συχνά ταιριάζουν ή πλησιάζουν στενά την ακρίβεια εργαζομένων crowdsourcing {cite}`gilardi2023chatgpt`, και το κόστος ανά σχολιασμό των κλήσεων API είναι συνήθως τάξεις μεγέθους χαμηλότερο από τα ανθρώπινα ημερομίσθια.

Πού Λειτουργεί Καλά ο Σχολιασμός LLM

- Απλές, καλά ορισμένες εργασίες ταξινόμησης (συναίσθημα, θέμα, πρόθεση)
- Εργασίες όπου οι ανθρώπινες ετικέτες κωδικοποιούν πολιτισμική συναίνεση που έχει απορροφήσει το LLM
- Εργασίες όπου ο σχολιασμός είναι συνεπής σε πλαίσια (όχι ιδιαίτερα υποκειμενικές)
- Δημιουργία πρώτης προσέγγισης σχολιασμών για ανθρώπινη επισκόπηση

Πού Αποτυγχάνει ο Σχολιασμός LLM

- Εργασίες εξαιρετικά εξειδικευμένου τομέα που απαιτούν σπάνια εμπειρογνωμοσύνη (ιατρικές, νομικές, επιστημονικές)
- Εργασίες που απαιτούν τοπική πολιτισμική γνώση ή γλωσσική παραλλαγή
- Εργασίες ασφάλειας και βλάβης, όπου το LLM μπορεί να είναι κακώς βαθμονομημένο στην ίδια κατεύθυνση με τα δεδομένα στα οποία εκπαιδεύτηκε
- Νέοι τύποι εργασιών που δεν αντιπροσωπεύονται καλά στην προ-εκπαίδευση

RLAIF και Συνταγματική ΤΝ

Όπως συζητήθηκε στο Κεφάλαιο 6, η ανατροφοδότηση που παράγεται από ΤΝ μπορεί να χρησιμοποιηθεί για εκπαίδευση μοντέλων ανταμοιβής και καθοδήγηση fine-tuning RL. Αυτό δημιουργεί έναν βρόχο ανατροφοδότησης: τα LLMs παράγουν δεδομένα, τα μοντέλα εκπαιδεύονται σε αυτά, και καλύτερα μοντέλα παράγουν καλύτερα δεδομένα. Το ερώτημα πώς να εκκινήσουμε αυτόν τον βρόχο χωρίς κωδικοποίηση συστηματικών σφαλμάτων από το αρχικό μοντέλο είναι ένα κεντρικό ανοιχτό πρόβλημα στην έρευνα κλιμακωτής εποπτείας.

Αδύναμη Επίβλεψη σε Κλίμακα

Η **προγραμματική επισήμανση** μέσω συναρτήσεων επισήμανσης (Κεφάλαιο 9) επιτρέπει στους εμπειρογνώμονες θέματος να εκφράζουν τη γνώση τους ως κώδικα αντί ως επισημασμένα παραδείγματα. Συστήματα όπως το Snorkel {cite}`ratner2017snorkel` και οι διάδοχοί του έχουν ωριμάσει σημαντικά και χρησιμοποιούνται τώρα σε παραγωγή σε μεγάλες τεχνολογικές εταιρείες.

Πρωτοπόρες κατευθύνσεις: - **Συναρτήσεις επισήμανσης ενισχυμένες με LLM:** Χρησιμοποιήστε LLMs για δημιουργία συναρτήσεων επισήμανσης από περιγραφές φυσικής γλώσσας - **Μάθηση βάσει τμημάτων:** Εντοπίστε κρίσιμα υποσύνολα δεδομένων (τμήματα) όπου οι συναρτήσεις επισήμανσης διαφωνούν και κατευθύνετε εκεί τον ανθρώπινο σχολιασμό - **Συνάθροιση ευαίσθητη στην αβεβαιότητα:** Καλύτερα στατιστικά μοντέλα για τον συνδυασμό συναρτήσεων επισήμανσης με διαφορετικές ακρίβειες και συσχετίσεις

Συνεχής Μάθηση με Ανθρώπινη Εποπτεία

Τα περισσότερα συστήματα ΜΜ εκπαιδεύονται εκτός σύνδεσης και αναπτύσσονται ως στατικά μοντέλα. Ο πραγματικός κόσμος αλλάζει· τα μοντέλα που ήταν ακριβή κατά το χρόνο ανάπτυξης υποβαθμίζονται καθώς η κατανομή δεδομένων μετατοπίζεται.

Η **συνεχής μάθηση** — η ικανότητα μάθησης από νέα δεδομένα διατηρώντας παλιά γνώση — είναι ένας ενεργός τομέας έρευνας. Η ανθρώπινη εποπτεία είναι κρίσιμη: η αυτοματοποιημένη συνεχής μάθηση χωρίς ανθρώπινη επισκόπηση μπορεί ταχέως να κωδικοποιήσει μετατοπίσεις κατανομής που είναι σφάλματα αντί γνήσιες αλλαγές στον κόσμο.

Η συνεχής μάθηση HITL περιλαμβάνει: - Παρακολούθηση για μετατόπιση κατανομής (αυτοματοποιημένη) και δρομολόγηση μετατοπισμένων παραδειγμάτων σε ανθρώπινη επισκόπηση - Επιλεκτική επανεκπαίδευση: παραδείγματα εγκεκριμένα από άνθρωπο από τη νέα κατανομή προστίθενται στα εκπαιδευτικά δεδομένα - Ανθρώπινη επισκόπηση αλλαγών συμπεριφοράς μοντέλου μετά από κάθε ενημέρωση

Πολυτροπικό HITL

Καθώς τα συστήματα ΤΝ γίνονται πολυτροπικά — επεξεργάζονται και παράγουν κείμενο, εικόνες, ήχο και βίντεο ταυτόχρονα — ο σχολιασμός γίνεται πιο σύνθετος. Ένα μεμονωμένο κομμάτι περιεχομένου μπορεί να απαιτεί σχολιασμό σε διάφορες τροπικότητες, με εξαρτήσεις μεταξύ τους.

Αναδυόμενοι τύποι εργασιών: - Σχολιασμός βίντεο + μεταγραφής (τι συμβαίνει, ποιος μιλά, τι περιγράφει οπτικά το κείμενο;) - Σχολιασμός ιατρικής εικόνας + κλινικής αναφοράς - Σχολιασμός ρομποτικής τροχιάς (σύνδεση δεδομένων αισθητήρα με ακολουθίες ενεργειών)

Τα πολυτροπικά θεμελιώδη μοντέλα (GPT-4V, Gemini, Claude) αλλάζουν επίσης εδώ το τοπίο σχολιασμού — τα μοντέλα μπορούν τώρα να ερμηνεύουν εικόνες και να παράγουν υποψήφιους σχολιασμούς, τους οποίους οι άνθρωποι επισκοπούν.

Κλιμακωτή Εποπτεία

Ένα θεμελιώδες ανοιχτό πρόβλημα στη ΑΜΜ HITL είναι η **κλιμακωτή εποπτεία** {cite}`irving2018ai,bowman2022measuring`: καθώς τα συστήματα ΤΝ γίνονται ικανότερα από τους ανθρώπους σε συγκεκριμένους τομείς, πώς διατηρούμε ουσιαστική ανθρώπινη εποπτεία;

Για εργασίες όπως πρόβλεψη δομής πρωτεΐνης, νομική ανάλυση ή επαλήθευση μαθηματικής απόδειξης, ακόμα και εμπειρογνώμονες σχολιαστές μπορεί να μην μπορούν να κρίνουν ποια από τις δύο εξόδους ΤΝ είναι σωστή. Οι τρέχουσες μέθοδοι HITL καταρρέουν όταν η ανθρώπινη κρίση είναι λιγότερο αξιόπιστη από το μοντέλο που αξιολογείται.

Προτεινόμενες προσεγγίσεις {cite}`bowman2022measuring`:

Διαφωνία: Δύο συστήματα ΤΝ υποστηρίζουν διαφορετικά συμπεράσματα· ένας ανθρώπινος κριτής αξιολογεί τα επιχειρήματα αντί τα συμπεράσματα άμεσα. Το σωστό συμπέρασμα πρέπει να είναι πιο υπερασπίσιμο.

Ενίσχυση: Οι ανθρώπινοι κριτές συμβουλεύονται βοηθούς ΤΝ (το ίδιο το μοντέλο) για να βοηθήσουν στην αξιολόγηση σύνθετων εξόδων. Αυτό αξιοποιεί τις δυνατότητες ΤΝ για επέκταση της ανθρώπινης εποπτείας αντί αντικατάστασής της.

Εποπτεία διαδικασίας: Αντί αξιολόγησης της τελικής εξόδου, οι άνθρωποι αξιολογούν τη *διαδικασία συλλογισμού* — επισημαίνοντας ελαττωματικά βήματα σε μια αλυσίδα σκέψης, ανεξάρτητα από το αν η τελική απάντηση τυγχάνει να είναι σωστή.

Η Εξελισσόμενη Κατανομή Εργασίας

Η μακροπρόθεσμη τροχιά της AMM HITL είναι προς μια πιο ρευστή συνεργασία μεταξύ ανθρώπων και ΤΝ, όπου κανένας δεν είναι απλώς ο "σχολιαστής" και ο άλλος ο "μαθητής", αλλά και οι δύο συνεισφέρουν σε μια κοινή γνωστική διαδικασία.

Τάσεις που πρέπει να παρακολουθήσουμε: - **Σχολιασμός με βοήθεια ΤΝ:** Η ΤΝ προτείνει· οι άνθρωποι αποφασίζουν. Η ποιότητα βελτιώνεται καθώς η ΤΝ προτείνει καλύτερες επιλογές. - **Ανθρώπινη καθοδηγούμενη εξερεύνηση:** Οι άνθρωποι θέτουν στόχους και περιορισμούς· η ΤΝ εξερευνά τον χώρο λύσεων. - **Συνεργατική αξιολόγηση:** Άνθρωποι και ΤΝ αξιολογούν από κοινού σύνθετες εξόδους μέσω διαλόγου. - **Μάθηση προτίμησης σε κλίμακα:** Έμμεσα σήματα (πώς οι χρήστες αλληλεπιδρούν με εξόδους ΤΝ) τροφοδοτούν συνεχή μάθηση προτίμησης χωρίς να απαιτούν ρητές συνεδρίες σχολιασμού.

Το ερώτημα πόσο να εμπιστευόμαστε την κρίση ΤΝ έναντι ανθρώπινης κρίσης — και σε ποιους τομείς, σε ποια επίπεδα δυνατότητας, με ποιες διασφαλίσεις — είναι τελικά κοινωνικό ερώτημα, όχι μόνο τεχνικό. Η AMM HITL παρέχει την τεχνική υποδομή για να απαντηθεί προσεκτικά, αντί από προεπιλογή.

Ανοιχτά Ερευνητικά Προβλήματα

Κλείνουμε με μια λίστα σημαντικών ανοιχτών προβλημάτων που ο τομέας εργάζεται ενεργά:

1. **Βέλτιστη στάση στην ενεργό μάθηση:** Πότε η οριακή αξία του επόμενου σχολιασμού είναι κάτω από το κόστος; Οι αρχικοί κανόνες στάσης παραμένουν δύσκολοι να βρεθούν.

2. **Κατανομή προϋπολογισμού σχολιασμού σε εργασίες:** Σε ρυθμίσεις πολλαπλών εργασιών, πώς πρέπει να χωριστεί ένας σταθερός προϋπολογισμός σχολιασμού σε εργασίες;

3. **Μετατόπιση κατανομής στην ενεργό μάθηση:** Η ενεργός μάθηση δημιουργεί μεροληπτικά επισημασμένα σύνολα. Πώς μπορούν να βαθμονομηθούν σωστά τα μοντέλα που εκπαιδεύονται με αυτόν τον τρόπο;

4. **Γενίκευση μοντέλου ανταμοιβής:** Τα μοντέλα ανταμοιβής RLHF μπορεί να αποτύχουν να γενικεύσουν σε νέα ζεύγη παρακίνησης-απόκρισης. Πώς μπορούμε

να κατασκευάσουμε πιο ισχυρά μοντέλα προτίμησης;

5. **Κλιμακωτή εποπτεία:** Πώς διατηρούμε ανθρώπινη εποπτεία καθώς τα συστήματα ΤΝ υπερβαίνουν την ανθρώπινη απόδοση σε συγκεκριμένους τομείς;
6. **Μοντελοποίηση σχολιαστών:** Καλύτερα στατιστικά μοντέλα για συμπεριφορά σχολιαστών που αποτυπώνουν όχι μόνο ικανότητα αλλά και συστηματικές προκαταλήψεις, θεματική εμπειρογνωμοσύνη και κόπωση.
7. **Αξιολόγηση ευθυγράμμισης:** Μας λείπουν δοκιμές αλήθειας-βάσης για το αν ένα μοντέλο είναι ευθυγραμμισμένο με ανθρώπινες αξίες. Η ανάπτυξη τέτοιων δοκιμών — ανάλογα με τα αντίξοα παραδείγματα για ισχυρότητα — είναι ένα ανοιχτό πρόβλημα.
8. **Δίκαιη εργασία δεδομένων:** Οικονομικές και θεσμικές δομές που διασφαλίζουν δίκαιη αμοιβή και προστασία εργαζομένων σχολιασμού, διατηρώντας παράλληλα την οικονομική αποτελεσματικότητα του μαζικού σχολιασμού.

Ο στόχος δεν είναι να αντικαταστήσουμε την ανθρώπινη κρίση με μηχανική κρίση, αλλά να κατασκευάσουμε συστήματα όπου ο συνδυασμός και των δύο είναι καλύτερος από τον καθένα μόνο.

Τα εργαλεία και οι τεχνικές σε αυτό το εγχειρίδιο — σχολιασμός, ενεργός μάθηση, RLHF, μάθηση προτίμησης και όλα τα υπόλοιπα — είναι μέσα προς αυτόν τον σκοπό. Καθώς ο τομέας εξελίσσεται, οι συγκεκριμένες τεχνικές θα αλλάξουν. Η υποκείμενη φιλοδοξία — να κατασκευαστούν συστήματα που είναι και ικανά και γνησίως ευθυγραμμισμένα με ανθρώπινη πρόθεση — θα παραμείνει.

See also: Κλιμακωτή εποπτεία και διαφωνία: {cite}`bowman2022measuring`. Αδύναμη επίβλεψη Snorkel: {cite}`ratner2017snorkel`. Για το ευρύ μέλλον συνεργασίας ανθρώπου-ΤΝ, βλ. {cite}`amershi2019software`.

Βιβλιογραφία

Table 1: all:

jupytext:
formats: md:myst
text_representation:
extension: .md
format_name: myst
kernelspec:
display_name: Python 3
language: python
name: python3

Μελέτη Περίπτωσης: Limen — Ένας Άνθρωπος στον Βρόχο των Πάντων

:::{admonition} Σημείωση για αυτό το κεφάλαιο :class: important Αυτό το κεφάλαιο είναι ένα **δοκίμιο κερδοσκοπικού σχεδιασμού**, όχι εμπειρική μελέτη ή συνεισφορά υποβληθείσα για εξέταση από ειδικούς. Περιγράφει μια οραματισμένη αρχιτεκτονική συστήματος — το Limen, ένα φωνητικό AI-native λειτουργικό σύστημα επιφάνειας εργασίας — ως επεξεργασμένο παράδειγμα πώς οι αρχές HITL από τα προηγούμενα κεφάλαια μπορούν να συντεθούν σε ένα συνεκτικό σύνολο. Οι ισχυρισμοί εδώ είναι επιχειρήματα σχεδιασμού, όχι πειραματικά αποτελέσματα. Πρέπει να διαβαστούν ως τεκμηριωμένη σχεδιαστική αιτιολόγηση, όχι ως επικυρωμένα μηχανολογικά ευρήματα. :::

Κάθε κεφάλαιο σε αυτό το εγχειρίδιο έχει περιγράψει την AMM HITL ως φιλοσοφία σχεδιασμού: ένα σύνολο αρχών για να γίνει η ανθρώπινη συμμετοχή σε συστήματα μάθησης σκόπιμη, αποτελεσματική και έντιμη. Αυτό το κεφάλαιο περιγράφει πώς φαίνεται η εφαρμογή αυτής της φιλοσοφίας ως πρώτη αρχή — όχι σε ένα μεμονωμένο σύστημα, αλλά σε ένα ολόκληρο λειτουργικό περιβάλλον.

Το **Limen** είναι ένα φωνητικό, AI-native λειτουργικό σύστημα επιφάνειας εργασίας, χτισμένο στην προϋπόθεση ότι ο άνθρωπος είναι πάντα στον βρόχο, όχι ως περιορισμός που πρέπει να βελτιστοποιηθεί, αλλά ως η οργανωτική αρχή γύρω από την οποία σχεδιάζεται κάθε υποσύστημα. Το όνομα επιλέγεται σκόπιμα: *limen* είναι η λατινική λέξη για κατώφλι. Στην αντιληπτική ψυχολογία, το limen είναι το όριο μεταξύ αυτού που γίνεται αντιληπτό και αυτού που δεν γίνεται. Για ένα λειτουργικό σύστημα, το limen είναι το όριο μεταξύ ανθρώπινης πρόθεσης και μηχανικής δράσης.

Η αρχιτεκτονική που περιγράφεται εδώ δεν είναι ιδιόκτητη. Είναι ένα σύνολο αποφάσεων σχεδιασμού, καθεμία από τις οποίες προκύπτει φυσικά από τις αρχές HITL που αναπτύχθηκαν στα προηγούμενα κεφάλαια. Ο στόχος δεν είναι η τεκμηρίωση ενός προϊόντος αλλά η εμφάνιση πώς αυτές οι αρχές συνθέτονται — πώς ενισχύουν η μία την άλλη όταν εφαρμόζονται συνεπώς, και τι είδους συστήματα γίνονται δυνατά όταν ο άνθρωπος δεν είναι δευτερεύον στοιχείο.

Το Πρόβλημα με τη Συμβατική Σχεδίαση ΛΣ

Ένα συμβατικό λειτουργικό σύστημα δεν σχεδιάζεται για ανθρώπους. Σχεδιάζεται για προγράμματα. Ο άνθρωπος φιλοξενείται μέσα από ένα επίπεδο αφαίρεσης — μια γραφική διεπαφή, έναν περιηγητή αρχείων, ένα τερματικό — που κάθεται πάνω σε ένα υπόστρωμα κατασκευασμένο για διεργασίες, διευθύνσεις μνήμης και περιγραφείς αρχείων.

Αυτή η επιλογή σχεδιασμού δικαιολογείται ιστορικά. Όταν έγιναν οι παραδοχές που

τη δημιούργησαν, οι υπολογιστές ήταν ακριβοί, οι άνθρωποι ήταν φθηνοί και το σημείο συμφόρησης ήταν η υπολογιστική ισχύς. Ο σωστός στόχος βελτιστοποίησης ήταν η μηχανή.

Αυτές οι παραδοχές δεν ισχύουν πλέον. Το σημείο συμφόρησης, για τους περισσότερους χρήστες στις περισσότερες εργασίες, δεν είναι η υπολογιστική ισχύς. Είναι η ανθρώπινη προσοχή: το κόστος της εναλλαγής πλαισίου, της αναζήτησης του σωστού αρχείου, της κατασκευής του σωστού ερωτήματος, της θύμησης πού ήταν κάτι. Η μηχανή είναι γρήγορη. Ο άνθρωπος είναι αργός. Η διεπαφή πρέπει να βελτιστοποιεί για την πλευρά του ανθρώπου στον βρόχο.

Τα συμβατικά λειτουργικά συστήματα δεν το κάνουν αυτό. Βελτιστοποιούνται για προγράμματα, και η δουλειά του ανθρώπου είναι να μιλάει τη γλώσσα των προγραμμάτων. Το Limen αντιστρέφει αυτό. Τα προγράμματα μιλούν τη γλώσσα του ανθρώπου. Ο άνθρωπος είναι στον βρόχο, και ο βρόχος σχεδιάζεται για να χωρέσει τον άνθρωπο.

Αρχιτεκτονική στο Κατώφλι

Η αρχιτεκτονική του Limen οργανώνεται γύρω από μια μεμονωμένη αρχή: **κάθε αλληλεπίδραση είναι ένα γεγονός**, και κάθε γεγονός είναι μια ευκαιρία για τον άνθρωπο να διδάξει, να διορθώσει ή να επιβεβαιώσει. Το σύστημα δεν περιμένει ρητές συνεδρίες εκπαίδευσης. Η μάθηση είναι συνεχής και περιβαλλοντική.

Το Επίπεδο Γεγονότων: WID

Στη βάση βρίσκεται το **WID** (το σύστημα Waldiez ID, προσαρμοσμένο για την τοπική-πρώτα αρχιτεκτονική του Limen) — ένα σύστημα παρακολούθησης γεγονότων με επίγνωση αιτιότητας που καταγράφει όχι μόνο τι συνέβη, αλλά τι το προκάλεσε και τι με τη σειρά του προκάλεσε αυτό.

Η συμβατική καταγραφή ρωτά: *τι συνέβη;* Το WID ρωτά: *γιατί συνέβη, και τι ακολούθησε;* Κάθε γεγονός φέρει αιτιακή γενεαλογία — μια αλυσίδα από την ενεργοποιητική ανθρώπινη ενέργεια μέσα από ενδιάμεσες καταστάσεις συστήματος έως το παρατηρηθέν αποτέλεσμα.

Αυτό έχει σημασία για τη μάθηση HITL επειδή λύνει το **πρόβλημα απόδοσης χρεώσεων** σε επίπεδο αλληλεπίδρασης. Όταν ένας χρήστης διορθώνει τη συμπεριφορά του συστήματος, το WID μπορεί να εντοπίσει όχι μόνο την άμεση έξοδο που ήταν λανθασμένη, αλλά την αλυσίδα αποφάσεων που τη δημιούργησε. Οι διορθώσεις μπορούν να εφαρμοστούν στο σωστό επίπεδο αφαίρεσης: η έξοδος, ο κανόνας απόφασης ή το ανοδικό σήμα.

Αυτό είναι το ισοδύναμο σε επίπεδο λειτουργικού συστήματος αυτού που το Κεφάλαιο 6 περιγράφει για το RLHF: η ικανότητα ιχνηλάτησης ενός σήματος ανταμοιβής μέσα από μια ακολουθία αποφάσεων. Το WID παρέχει αυτή την ιχνηλάτηση εγγενώς, για κάθε αλληλεπίδραση, χωρίς να απαιτεί ο χρήστης να το κατανοεί.

:::{admonition} Αιτιακή Παρακολούθηση Γεγονότων ως Υποδομή HITL :class: note Ο σχεδιασμός του WID αντικατοπτρίζει μια ευρύτερη αρχή: η υποδομή HITL πρέπει να κάνει εύκολο να ρωτήσουμε "γιατί το σύστημα έκανε αυτό;" — όχι μόνο "τι έκανε;" Χωρίς αιτιακή ιχνηλάτηση, οι διορθώσεις διορθώνουν συμπτώματα. Με αυτήν, μπορούν να διορθώσουν αιτίες. Η διαφορά μεταξύ ενός μπαλώματος και ενός μαθήματος. :::

Το Επίπεδο Αντίληψης: Φωνή-Πρώτα

Η κύρια κατάσταση εισόδου του Limen είναι φωνή, επεξεργαζόμενη τοπικά χρησιμοποιώντας μια γραμμή επεξεργασίας συμπερασμού Whisper ONNX. Οι λόγοι για αυτή την επιλογή αξίζει να αναφερθούν ρητά:

Η φωνή είναι το πιο φυσικό κανάλι εξόδου ανθρώπου για τους περισσότερους ανθρώπους. Δεν απαιτεί εκπαίδευση, φυσική επιδεξιότητα πέρα από κανονική ομιλία, ούτε γνώση της εσωτερικής οργάνωσης του συστήματος. Ένας χρήστης που δεν μπορεί να εντοπίσει ένα αρχείο σε μια ιεραρχία καταλόγων μπορεί να περιγράψει αυτό που ψάχνει.

Η τοπική επεξεργασία διαφυλάσσει την ιδιωτικότητα. Τα φωνητικά δεδομένα δεν εγκαταλείπουν τη συσκευή. Αυτό έχει σημασία ηθικά — η φωνή είναι βιομετρικά δεδομένα και η συλλογή της σε κλίμακα από παρόχους cloud είναι τεκμηριωμένη βλάβη — και πρακτικά: η εκτός σύνδεσης λειτουργία σημαίνει ότι το σύστημα παραμένει λειτουργικό χωρίς σύνδεση δικτύου.

Η φωνή δημιουργεί έναν φυσικό βρόχο ανατροφοδότησης. Όταν το σύστημα αποκρίνεται, η αντίδραση του χρήστη — να συνεχίσει να μιλά, να αναδιατυπώσει, να πει "όχι, αυτό δεν είναι σωστό" — είναι και αυτή σήμα. Το Limen αντιμετωπίζει αυτές τις αντιδράσεις ως ανατροφοδότηση HITL: στοιχεία για το αν η ερμηνεία του συστήματος της προηγούμενης εκφώνησης ήταν σωστή.

Η αλυσίδα υποβάθμισης έχει εξίσου σημασία με την κύρια κατάσταση. Όταν η φωνή αποτυγχάνει — σε θορυβώδες περιβάλλον, για χρήστη με πρόβλημα ομιλίας, για είσοδο που ωφελείται από ακρίβεια — το Limen υποβαθμίζεται χαριτωμένα σε διεπαφή πληκτρολογίου και στη συνέχεια σε διεπαφή δομημένου κειμένου. Το Τεστ της Γιαγιάς (βλ. Κεφάλαιο 5) δεν είναι εκτός θέματος αρχιτεκτονικός περιορισμός προσβασιμότητας· είναι περιορισμός πρώτης κατηγορίας.

Το Επίπεδο Νοημοσύνης: Πολυ-LLM Δρομολόγηση

Το Limen δεν βασίζεται σε ένα μεμονωμένο γλωσσικό μοντέλο. Δρομολογεί αιτήματα μέσα από δομημένο δέντρο αποφάσεων βάσει τύπου εργασίας, απαιτούμενης καθυστέρησης, απαιτήσεων ιδιωτικότητας και εμπιστοσύνης:

1. **Τοπικό μικρό μοντέλο** (πάντα πρώτο): γρήγορο, ιδιωτικό, χειρίζεται ρουτίνα εργασίες — "άνοιξε το αρχείο που επεξεργαζόμουν χθες", "θέσε ένα χρονόμετρο", "ποιος είναι ο καιρός"
2. **Τοπικό μεγάλο μοντέλο** (όταν η εμπιστοσύνη του μικρού μοντέλου είναι χαμηλή): πιο αργό αλλά ικανότερο· χειρίζεται δομημένο συλλογισμό, δημιουργία κώδικα, σύνθετη ανάκτηση
3. **Απομακρυσμένο μοντέλο** (όταν το τοπικό αποτυγχάνει και ο χρήστης έχει χορηγήσει άδεια): η έξοδος έκτακτης ανάγκης· χειρίζεται διαφανώς με ρητή ειδοποίηση χρήστη

Αυτή η δομή δεν είναι νέα — είναι το ισοδύναμο κατά τον χρόνο συμπερασμού της στρατηγικής ερωτήματος ενεργού μάθησης που περιγράφεται στο Κεφάλαιο 4. Σε κάθε βήμα, το σύστημα ρωτά: είναι το τρέχον μοντέλο μου επαρκές για να απαντήσει σε αυτό το ερώτημα με αποδεκτή εμπιστοσύνη; Αν όχι, κλιμακώστε. Η κλιμάκωση είναι ένα κόστος (καθυστέρηση, ιδιωτικότητα, υπολογισμός)· επιβαρύνεται μόνο όταν είναι αναγκαίο.

Ο άνθρωπος είναι στον βρόχο στο όριο κλιμάκωσης. Ένας χρήστης που έχει διαμορφώσει το Limen να μην κλιμακώνει ποτέ σε απομακρυσμένα μοντέλα έχει λάβει μια απόφαση HITL — μια απόφαση την οποία το σύστημα σέβεται και καταγράφει. Ένας χρήστης

που εγκρίνει ένα απομακρυσμένο ερώτημα και στη συνέχεια λέει "μην με ρωτάς ξανά για αυτό το είδος αιτήματος" έχει παρέσχει μια προτίμηση που ενημερώνει την πολιτική δρομολόγησης.

Ο Σχεδιασμός Αλληλεπίδρασης

Αμεσότητα

Το Limen σχεδιάζεται για αμεσότητα υπό την έννοια που ορίζει το Κεφάλαιο 5: ο χρήστης αντιλαμβάνεται την επίδραση της ανατροφοδότησής του. Όταν ο χρήστης διορθώνει μια έξοδο συστήματος, η διόρθωση εφαρμόζεται αμέσως και ορατά. Το μοντέλο δεν φεύγει και δεν εκπαιδεύεται για είκοσι λεπτά. Ενημερώνεται στην τρέχουσα συνεδρία.

Αυτό απαιτεί χρήση αρχιτεκτονικών μοντέλου που υποστηρίζουν αποτελεσματική διαδικτυακή ενημέρωση — προσαρμογείς, prefix tuning και ανάκτηση-επαυξημένη δημιουργία αντί για πλήρες fine-tuning. Η ανταλλαγή είναι ρητή: οι διαδικτυακές ενημερώσεις είναι θορυβωδέστερες από τη δεσμιδωτή εκπαίδευση. Το Limen αποδέχεται αυτή την ανταλλαγή επειδή η αμεσότητα είναι η πρωταρχική απαίτηση: ο άνθρωπος μπορεί πάντα να επιβεβαιώσει, να απορρίψει ή να βελτιώσει την ενημέρωση.

Κατανοησιμότητα

Ένα επαναλαμβανόμενο θέμα στη βιβλιογραφία IML είναι η **απαίτηση κατανοησιμότητας**: οι άνθρωποι μπορούν να καθοδηγούν μόνο ένα μοντέλο που κατανοούν, τουλάχιστον κατά προσέγγιση. Το Limen το αναδεικνύει αυτό στη διεπαφή: όταν το σύστημα λαμβάνει μια απόφαση, εξηγεί, εν συντομία, γιατί. Όχι πλήρης ίχνος συλλογισμού — αυτό θα κατέκλυζε τους περισσότερους χρήστες — αλλά μια σύνοψη φυσικής γλώσσας του βασικού παράγοντα: "Ανοίγω το έργο που δούλεψες πιο πρόσφατα — είναι αυτό σωστό;"

Αυτή η εξήγηση είναι επίσης ερώτηση. Προσκαλεί διόρθωση. Κάνει ορατή τη συμπερασματική διαδικασία του μοντέλου ώστε ο χρήστης να μπορεί να την ανακατευθύνει αν είναι λανθασμένη. Η εξήγηση δεν δημιουργείται για αισθητικούς λόγους· είναι λειτουργική υποδομή HITL.

Συνέπεια και Παρέκκλιση

Ένα πρόβλημα που προκύπτει σε κάθε μακροχρόνιο διαδραστικό σύστημα είναι η **συμπεριφορική παρέκκλιση**: η συμπεριφορά του συστήματος στον χρόνο $T + n$ είναι ελαφρώς διαφορετική από τη συμπεριφορά του στον χρόνο T, με τρόπους που ούτε ο χρήστης ούτε το σύστημα επέλεξαν ρητά. Οι διορθώσεις συσσωρεύονται. Οι οριακές περιπτώσεις πολλαπλασιάζονται. Το μοντέλο που ήταν ευθυγραμμισμένο με τις προτιμήσεις του χρήστη τον προηγούμενο μήνα μπορεί να μην είναι πλέον ευθυγραμμισμένο σήμερα.

Το Limen αντιμετωπίζει αυτό μέσα από περιοδικούς ελέγχους συνέπειας — το ισοδύναμο επιπέδου λειτουργικού συστήματος της τεχνικής επαν-παρουσίασης που περιγράφεται στο Κεφάλαιο 13. Το σύστημα παρουσιάζει ιστορικές αποφάσεις στον χρήστη: "Πριν μερικές εβδομάδες, μου ζητήσατε να κάνω X. Είναι αυτό ακόμα αυτό που θα θέλατε;" Αυτοί οι έλεγχοι εξυπηρετούν δύο λειτουργίες: εντοπίζουν παρέκκλιση και υπενθυμίζουν στον χρήστη προτιμήσεις που ίσως έχει ξεχάσει ότι ανέφερε.

Το Limen ως Σύστημα HITL

Κοιτάζοντας την αρχιτεκτονική του Limen μέσα από τον φακό αυτού του εγχειριδίου, οι αποφάσεις σχεδιασμού αντιστοιχίζονται άμεσα στις έννοιες που αναπτύχθηκαν σε κάθε μέρος.

Μέρος I (Θεμέλια): Το Limen αντιμετωπίζει κάθε αλληλεπίδραση ως γεγονός αλληλεπίδρασης ανθρώπου–μηχανής. Δεν υπάρχει "λειτουργία εκτός HITL" — το σύστημα μαθαίνει πάντα, αποδίδει πάντα, περιμένει πάντα τον άνθρωπο να συμμετέχει.

Μέρος II (Βασικές Τεχνικές): Η ενεργός μάθηση εκδηλώνεται ως αλυσίδα κλιμάκωσης βάσει εμπιστοσύνης. Η διαδραστική ΜΜ εκδηλώνεται στον κύκλο ενημέρωσης πραγματικού χρόνου. Ο σχολιασμός είναι σιωπηρός: κάθε διόρθωση που κάνει ο χρήστης είναι μια ετικέτα.

Μέρος III (Μάθηση από Ανθρώπινη Ανατροφοδότηση): Η μάθηση προτίμησης που περιγράφεται στο Κεφάλαιο 8 εμφανίζεται στις ενημερώσεις πολιτικής δρομολόγησης. Όταν ένας χρήστης προτιμά την απάντηση ενός τοπικού μοντέλου έναντι απομακρυσμένου, αυτή η προτίμηση καταγράφεται και γενικεύεται. Το RLHF σε ένα προσωπικό ΛΣ σημαίνει ότι το μοντέλο ανταμοιβής είναι ιδιωτικό, ατομικό και συνεχώς ενημερωμένο.

Μέρος IV (Εφαρμογές): Το Limen είναι γενικής σκοπού περιβάλλον, αλλά ο σχεδιασμός του είναι πιο ορατός σε τομείς όπου η ανθρώπινη κρίση είναι αναντικατάστατη και το κόστος σφάλματος είναι υψηλό — σύνταξη εγγράφων, ιεράρχηση εργασιών, δημιουργική εργασία.

Μέρος V (Συστήματα και Πρακτική): Το WID είναι η πλατφόρμα σχολιασμού του Limen. Είναι αόρατη στον χρήστη κατά την κανονική λειτουργία, ορατή όταν χρειάζεται για αποσφαλμάτωση ή διαφάνεια. Οι μηχανισμοί ποιοτικού ελέγχου (έλεγχοι συνέπειας, κατώφλια εμπιστοσύνης, αρχεία καταγραφής κλιμάκωσης) δανείζονται άμεσα από τη βιβλιογραφία crowdsourcing.

Μέρος VI (Ηθική): Ο τοπικός-πρώτα, προστατευτικός της ιδιωτικότητας σχεδιασμός είναι ηθική επιλογή, όχι μόνο τεχνική. Τα δεδομένα του ανθρώπου δεν εγκαταλείπουν τη συσκευή τους χωρίς ρητή συγκατάθεσή τους. Το μοντέλο που μαθαίνει από τη συμπεριφορά ενός χρήστη ανήκει σε αυτόν τον χρήστη.

Το Βαθύτερο Νόημα

Το Limen δεν είναι προϊοντική παρουσίαση. Είναι επιχείρημα μέσω κατασκευής.

Το επιχείρημα είναι αυτό: αν πάρετε σοβαρά τις αρχές της AMM HITL — αν πιστεύετε ότι η ανθρώπινη ανατροφοδότηση είναι σήμα προς κατανόηση αντί κόστος προς ελαχιστοποίηση, ότι ο άνθρωπος είναι πάντα στον βρόχο ακόμα και όταν οι σχεδιαστές προσποιούνται ότι δεν είναι, ότι η ευθυγράμμιση είναι μια συνεχής διαδικασία αντί μιας εφάπαξ εκδήλωσης — τότε καταλήγετε να χτίζετε κάτι που μοιάζει με το Limen.

Όχι απαραίτητα το Limen συγκεκριμένα. Η συγκεκριμένη τεχνολογική στοίβα (Tauri, Rust, Babylon.js, Whisper ONNX) είναι μία επιλογή μεταξύ πολλών. Αλλά η αρχιτεκτονική — αιτιακή παρακολούθηση γεγονότων, τοπική-πρώτα επεξεργασία, χαριτωμένη υποβάθμιση, συνεχής μάθηση προτίμησης, διαφάνεια ως πρωταρχικό χαρακτηριστικό — προκύπτει από τις αρχές.

Ο τομέας της AMM HITL έχει αφιερώσει σημαντική ενέργεια περιγράφοντας πώς να τοποθετούμε τους ανθρώπους στον βρόχο συγκεκριμένων μοντέλων και συγκεκριμένων εργασιών. Το επόμενο ερώτημα είναι αν μπορούμε να σχεδιάσουμε ολόκληρα *περιβάλλοντα* γύρω από τις ίδιες αρχές: περιβάλλοντα όπου ο άνθρωπος είναι πάντα το κέντρο, η μηχανή είναι πάντα ο μαθητής, και ο βρόχος είναι πάντα ανοιχτός.

Το Limen είναι μια απάντηση σε αυτό το ερώτημα.

Το κατώφλι δεν είναι κάτι που διαβαίνεις και αφήνεις πίσω σου. Είναι εκεί που ζεις.

See also: Οι αρχές IML που διέπουν τον σχεδιασμό αλληλεπίδρασης του Limen αναπτύσσονται στο Κεφάλαιο 5. Η προσέγγιση μάθησης προτίμησης πίσω από την πολιτική δρομολόγησης τυποποιείται στο Κεφάλαιο 8. Το μοντέλο αιτιότητας του WID αντλεί από τη βιβλιογραφία απόδοσης γεγονότων που επισκοπείται στο Κεφάλαιο 14. Το Τεστ της Γιαγιάς, που εισάγεται στο Κεφάλαιο 5, είναι ο πρωταρχικός περιορισμός σχεδιασμού διεπαφής του Limen.

Περί Αποχώρησης

Υπάρχουν πράγματα που αρχίζεις γνωρίζοντας ότι θα τα αφήσεις πριν τελειώσουν.

Ένα διδακτορικό πρόγραμμα είναι ένα από αυτά. Ή τουλάχιστον αυτό. Η αποχώρηση δεν ήταν αποτυχία αναζήτησης — ήταν η αναζήτηση ολοκληρωμένη αρκετά ώστε να ξέρεις πού δεν ανήκεις. Αυτό είναι, ίσως, ένα αποτέλεσμα.

Αυτό το βιβλίο γράφτηκε ως το τελευταίο πράγμα πριν την αποχώρηση. Δεν είναι διατριβή. Δεν κατέθεσε αξιώσεις, δεν τοποθετήθηκε έναντι μεθόδων αιχμής, δεν αποδείκνυε τίποτα σε καμία επιτροπή. Ήταν η απόπειρα να ειπωθεί, με σαφήνεια, κάτι αληθινό για ένα πράγμα που με ενδιέφερε βαθύτατα και συνεχίζει να με ενδιαφέρει: η σχέση μεταξύ ανθρώπινης κρίσης και μηχανικής μάθησης, και γιατί αυτή η σχέση παρεξηγείται τόσο συστηματικά.

Η λέξη *limen* — από την οποία παίρνει το όνομά του το τελευταίο κεφάλαιο — σημαίνει κατώφλι. Το σημείο ακριβώς πριν από το πέρασμα. Δεν βρίσκεσαι ακόμα εκεί, αλλά δεν είσαι πια εδώ.

Υπάρχει ειλικρίνεια σε αυτή τη στιγμή που λείπει και από τις δύο πλευρές.

Αν φτάσατε ως εδώ — αν διαβάσατε για την τυπολογία της αλληλεπίδρασης ανθρώπου-μηχανής, για τις στρατηγικές επερώτησης ενεργού μάθησης, για το τι συμβαίνει όταν τα δημογραφικά των σχολιαστών κωδικοποιούνται σε τεράστια μοντέλα — τότε ξέρετε ήδη το κεντρικό επιχείρημα: ο άνθρωπος δεν αφαιρείται από αυτά τα συστήματα. Απλώς γίνεται αόρατος. Και τα αόρατα πράγματα ξεχνιούνται πολύ εύκολα.

Αυτό το βιβλίο ήταν μια απόπειρα να τα κάνω ορατά.

— *Λ.Τ.*