Contents

लूप में मानव मशीन लर्निंग: एक भ्रांत धारणा **1**
पुस्तक की संरचना . . . 1

मौलिकता की घोषणा **3**

सारांश **5**

आभार **7**

मानव-इन-द-लूप ML क्या है? **9**
स्वचालन का विरोधाभास . . . 9
HITL ML की परिभाषा . . . 9
संक्षिप्त इतिहास . . . 10
HITL क्यों? मानव निर्णय का तर्क . . . 10
प्रतिक्रिया लूप . . . 11
HITL क्या नहीं है . . . 12
मानव प्रतिक्रिया का अर्थशास्त्र . . . 12
पुस्तक का अवलोकन . . . 13

मानव–मशीन अंतःक्रिया का वर्गीकरण **15**
स्वचालन के स्तर . . . 15
सक्रिय बनाम निष्क्रिय मानव भागीदारी . . . 16
एकल बनाम एकाधिक अनुलेखक . . . 16
एक एकीकृत रूपरेखा . . . 17

डेटा अनुलेखन एवं लेबलिंग **19**
अनुलेखन के प्रकार . . . 19
अनुलेखन दिशानिर्देश . . . 20
अनुलेखन गुणवत्ता का मापन: अंतर-अनुलेखक सहमति . . . 20
असहमतियों को संभालना . . . 22
लेबल शोर और उसके प्रभाव . . . 23
अनुलेखन लागत और थ्रूपुट . . . 23

सक्रिय अधिगम **25**
सक्रिय अधिगम की स्थापना . . . 25
सैद्धांतिक आधार . . . 25
क्वेरी रणनीतियाँ . . . 26
गहन मॉडलों के लिए अनिश्चितता अनुमान . . . 27
एक पूर्ण सक्रिय अधिगम लूप . . . 28
कोल्ड स्टार्ट समस्या . . . 30
बैच-मोड सक्रिय अधिगम . . . 30

रुकने के मानदंड . . . 30
सक्रिय अधिगम कब काम करता है (और कब नहीं) . . . 30

इंटरैक्टिव मशीन लर्निंग **33**
इंटरैक्टिव मशीन लर्निंग के सिद्धांत . . . 33
सक्रिय अधिगम से तुलना . . . 33
मिश्रित-पहल अंतःक्रिया . . . 34
IML में मानव कारक . . . 34
IML प्रतिक्रिया प्रकार व्यवहार में . . . 34
केस स्टडी: Google Teachable Machine . . . 34
एक सरल IML लूप लागू करना . . . 35
दादी परीक्षण . . . 36
IML और फाउंडेशन मॉडल . . . 37

मानव प्रतिक्रिया से प्रबलन अधिगम **39**
संरेखण समस्या . . . 39
RLHF पाइपलाइन . . . 39
एक सरलीकृत RLHF प्रदर्शन . . . 40
RLHF में चुनौतियाँ . . . 42
Constitutional AI (RLAIF) . . . 42

प्रदर्शन से अधिगम **45**
व्यवहार क्लोनिंग . . . 45
व्युत्क्रम प्रबलन अधिगम . . . 46
GAIL: जेनरेटिव एडवर्सेरियल अनुकरण अधिगम . . . 46
NLP में व्यवहार क्लोनिंग: एक व्यावहारिक उदाहरण . . . 46
अनुकरण अधिगम विधियों की तुलना . . . 48
अनुप्रयोग . . . 48

तुलना एवं क्रम-निर्धारण से अधिगम **49**
रेटिंग की तुलना में तुलनाएँ बेहतर क्यों हैं . . . 49
Bradley-Terry मॉडल . . . 49
Thurstone का मॉडल . . . 51
रैंक एकत्रीकरण . . . 51
द्वंद्वयुद्ध बैंडिट्स . . . 51
भाषा मॉडलों के लिए वरीयता अधिगम . . . 52
उच्च-गुणवत्ता वरीयता डेटा एकत्र करना . . . 52

प्राकृतिक भाषा संसाधन में HITL **53**
NLP अनुलेखन में संविधात्मक समस्या . . . 53
पाठ वर्गीकरण अनुलेखन . . . 53
नाम इकाई पहचान . . . 54
मशीन अनुवाद पोस्ट-एडिटिंग (MTPE) . . . 54
प्रोग्रामेटिक लेबलिंग और कमज़ोर पर्यवेक्षण . . . 54
भाषा मॉडलों के लिए RLHF: अनुलेखन वास्तविकता . . . 55
जेनरेटिव NLP मॉडलों का मूल्यांकन . . . 56

कंप्यूटर दृष्टि में HITL **57**
अनुलेखन विकल्प कैसे मॉडल पूर्वाग्रह बनते हैं . . . 57
छवि वर्गीकरण अनुलेखन . . . 57
वस्तु पहचान: बाउंडिंग बॉक्स अनुलेखन . . . 58
सिमेंटिक और इंस्टेंस विभाजन . . . 59

कंप्यूटर दृष्टि के लिए सक्रिय अधिगम . . . 59
वीडियो अनुलेखन . . . 60

स्वास्थ्य सेवा एवं विज्ञान में HITL **61**
चिकित्सा छवि विश्लेषण . . . 61
नैदानिक NLP अनुलेखन . . . 61
नियामक विचार . . . 62
वैज्ञानिक डेटा अनुलेखन . . . 62
चिकित्सा इमेजिंग के लिए एक HITL सक्रिय अधिगम पाइपलाइन . . . 62

अनुलेखन प्लेटफ़ॉर्म एवं उपकरण **65**
अनुलेखन प्लेटफ़ॉर्म परिदृश्य . . . 65
अनुलेखन प्लेटफ़ॉर्म सुविधा तुलना . . . 65
कोड के रूप में अनुलेखन . . . 66

क्राउडसोर्सिंग एवं गुणवत्ता नियंत्रण **69**
क्राउडसोर्सिंग प्लेटफ़ॉर्म . . . 69
क्राउडसोर्सिंग के लिए कार्य डिज़ाइन . . . 69
लेबल एकत्रीकरण के लिए सांख्यिकीय मॉडल . . . 71
अतिरिक्तता और एकत्रीकरण रणनीति . . . 73

मूल्यांकन एवं मापदंड **75**
मॉडल-केंद्रित मेट्रिक्स . . . 75
अनुलेखन दक्षता मेट्रिक्स . . . 75
मानव मूल्यांकन . . . 77
मानव इरादे के साथ संरेखण मापना . . . 78
परिनियोजित प्रणालियों में A/B परीक्षण . . . 78

निष्पक्षता, पूर्वाग्रह एवं नैतिकता **79**
HITL प्रणालियों में पूर्वाग्रह के स्रोत . . . 79
HITL प्रणालियों में निष्पक्षता . . . 79
अनुलेखक कल्याण . . . 80
अनुलेखन में गोपनीयता . . . 80
प्रतिकूल अनुलेखन और डेटा विषाक्तता . . . 81
संस्थागत नैतिकता . . . 81

भविष्य की दिशाएँ **83**
फाउंडेशन मॉडल और अनुलेखन की बदलती भूमिका . . . 83
अनुलेखक के रूप में LLMs . . . 83
बड़े पैमाने पर कमज़ोर पर्यवेक्षण . . . 84
मानव निगरानी के साथ निरंतर अधिगम . . . 84
स्केलेबल निगरानी . . . 84
खुली अनुसंधान समस्याएँ . . . 84

संदर्भ सूची **87**

लाइमेन: प्रत्येक लूप में एक मानव **89**
पारंपरिक OS डिज़ाइन के साथ समस्या . . . 89
दहलीज़ पर आर्किटेक्चर . . . 89
अंतःक्रिया डिज़ाइन . . . 90
HITL प्रणाली के रूप में Limen . . . 91
गहरी बात . . . 91

विदाई पर **93**

लूप में मानव मशीन लर्निंग: एक भ्रांत धारणा

लाज़ारोस तौमानिदिस (Lazaros Toumanidis)

यह पुस्तिका आधुनिक कृत्रिम बुद्धिमत्ता के सर्वाधिक महत्त्वपूर्ण — तथा भ्रांत — क्षेत्रों में से एक की विवेचना करती है: अधिगम लूप में मानव का समन्वय। डेटा अनुलेखन और सक्रिय अधिगम से लेकर RLHF और प्रदर्शन से अधिगम तक — मानव निर्णय अमूल्य बना हुआ है।

यह पुस्तक उन शोधकर्ताओं, अभियंताओं एवं विद्यार्थियों के लिए है जो यह समझना चाहते हैं कि अधिगम चक्र में मानव की भागीदारी कब, क्यों और कैसे आवश्यक है।

:::{admonition} हिंदी संस्करण :class: note यह हिंदी अनुवाद है। अंग्रेज़ी मूल संस्करण प्राथमिक संदर्भ संस्करण है। :::

पुस्तक की संरचना

भाग I — आधार — वैचारिक रूपरेखा स्थापित करता है: HITL ML का अर्थ तथा स्वचालन के स्तरों का वर्गीकरण।

भाग II — मूल तकनीकें — मूलभूत विधियों को सम्मिलित करता है: डेटा अनुलेखन, सक्रिय अधिगम एवं इंटरैक्टिव मशीन लर्निंग।

भाग III — मानव प्रतिक्रिया से अधिगम — RLHF, प्रदर्शन से अधिगम तथा तुलनाओं से अधिगम को सम्मिलित करता है।

भाग IV — अनुप्रयोग — NLP, कंप्यूटर दृष्टि एवं चिकित्सा प्रणालियों में व्यावहारिक उदाहरणों की परीक्षा करता है।

भाग V — प्रणालियाँ एवं व्यवहार — प्रत्येक HITL प्रणाली के लिए आवश्यक उपकरणों, प्लेटफ़ॉर्मों एवं मापदंडों को सम्मिलित करता है।

भाग VI — नैतिकता एवं क्षितिज — निष्पक्षता, पूर्वाग्रह तथा मानव-एल्गोरिदम संबंध के भविष्य से संबंधित प्रश्नों को संबोधित करता है।

मौलिकता की घोषणा

डॉक्टर ऑफ़ फ़िलॉसफ़ी की उपाधि की आंशिक अपूर्ति में प्रस्तुत।

मैं एतद्द्वारा घोषणा करता हूँ कि इस पुस्तक में प्रस्तुत कार्य मेरा अपना है, सिवाय उन स्थानों के जहाँ यह नहीं है।

इन पृष्ठों में विचार निम्नलिखित की सहायता से उत्पन्न हुए: उन शोधकर्ताओं से जिन्होंने शोधपत्र प्रकाशित किए और कभी-कभी उन्हें पेवॉल के पीछे रखा; उन अनुलेखकों से जिनके परिश्रम ने मॉडलों को संभव बनाया किंतु जिनके नाम किसी आभार-खंड, शोधपत्र-प्रशंसा या प्रेस-विज्ञप्ति में नहीं आए; उन ओपन-सोर्स योगदानकर्ताओं से जिन्होंने प्रत्येक कोड उदाहरण में प्रयुक्त पुस्तकालय लिखे; और मानव सभ्यता के संचित पाठ से, जिसे बड़े भाषा मॉडलों ने ग्रहण और संपीडित किया है और जिनका उस पर कोई मत नहीं है।

त्रुटियाँ मेरी हैं। अंतर्दृष्टि सहयोगात्मक थी।

मैं पुष्टि करता हूँ कि यह कार्य किसी अन्य उपाधि या व्यावसायिक योग्यता, शैक्षणिक पुरस्कार, अनुदान, कार्यकाल मामले, या LinkedIn पोस्ट के लिए प्रस्तुत नहीं किया गया है, सिवाय जहाँ अन्यथा कहा गया हो।

मैं आगे पुष्टि करता हूँ कि इस कार्य में कोई SOTA (State of the Art) तुलना अनुभाग शामिल नहीं किया गया। पाठक को 12 बेंचमार्कों पर 47 विधियों को क्रमबद्ध करने वाली कोई तालिका नहीं मिलेगी, जिसमें प्रस्तावित विधि उनमें से 9 पर सांख्यिकीय रूप से महत्वपूर्ण सुधार प्राप्त करती हो (†$p < 0.05$)। यह इसलिए नहीं कि ऐसी तालिका नहीं बनाई जा सकती थी, बल्कि इसलिए कि उसका निर्माण बात से भटकना होता।

बात यह है: मानव लूप में है। हमेशा से रहा है। यह पुस्तक यह समझने का प्रयास करती है कि इसका क्या अर्थ है।

हस्ताक्षर: लूप में एक मानव

तिथि: जब भी आप इसे पढ़ रहे हैं

संस्था: कोई नहीं। यही बात है।

> **उपशीर्षक के विषय में** :class: note
>
> Misunderstood (गलत समझा गया) क्षेत्र को, उसमें मानव की भूमिका को, और पाठक को — एक साथ — संदर्भित करता है। यदि आप सोचते हैं कि यह केवल आपको संदर्भित करता है, तो आप सही हो सकते हैं। यदि आप सोचते हैं कि यह केवल मशीनों को संदर्भित करता है, तो आप उपशीर्षक की बात सिद्ध कर रहे हैं।

सारांश

Human in the Loop Machine Learning: Misunderstood

मशीन लर्निंग की प्रमुख विमर्श-धारा मनुष्य को एक अस्थायी भागीदार के रूप में प्रस्तुत करती है — जो डेटा संग्रह और मॉडल प्रशिक्षण के दौरान उपस्थित होता है, किंतु स्वचालन में सुधार होने पर क्रमशः हटता जाता है। यह पुस्तक यह तर्क देती है कि यह विमर्श गलत है, हमेशा से गलत रहा है, और यह समझना कि यह क्यों गलत है — एक मशीन लर्निंग व्यवसायी के लिए सर्वाधिक व्यावहारिक रूप से उपयोगी कार्यों में से एक है।

ह्यूमन-इन-द-लूप (HITL) मशीन लर्निंग वह अनुशासन है जो अधिगम प्रणालियों में मानव भागीदारी को जानबूझकर, संरचित और निरंतर बनाता है। मानव प्रतिक्रिया को न्यूनतम की जाने वाली लागत के रूप में देखने के बजाय, HITL इसे एक समझे जाने योग्य संकेत के रूप में मानता है: यह कहाँ से आती है, यह क्या कूटबद्ध करती है, इसे कुशलतापूर्वक कैसे एकत्र किया जाए, और इसे उन मॉडलों में विश्वस्त रूप से कैसे शामिल किया जाए जो अपने डिज़ाइनरों और उपयोगकर्ताओं के वास्तविक इरादे के अनुसार व्यवहार करते हैं।

यह पुस्तक छह भागों में क्षेत्र का व्यापक विवरण प्रस्तुत करती है। भाग I नींव और मानव–मशीन अंतःक्रिया का वर्गीकरण स्थापित करता है। भाग II शास्त्रीय तकनीकों को शामिल करता है: अनुलेखन और लेबलिंग, सक्रिय अधिगम, और इंटरैक्टिव मशीन लर्निंग। भाग III संरेखण के आधुनिक प्रतिमानों को संबोधित करता है: मानव प्रतिक्रिया से प्रबलन अधिगम (RLHF), प्रदर्शन से अधिगम, और वरीयता अधिगम। भाग IV इन तकनीकों को प्राकृतिक भाषा संसाधन, कंप्यूटर दृष्टि, और स्वास्थ्य सेवा में लागू करता है। भाग V HITL के पैमाने पर प्रणालियों और अवसंरचना को शामिल करता है: अनुलेखन प्लेटफ़ॉर्म, क्राउडसोर्सिंग गुणवत्ता नियंत्रण, और मूल्यांकन पद्धति। भाग VI क्षेत्र की नैतिकता और भविष्य की जाँच करता है।

प्रत्येक अध्याय में औपचारिक परिभाषाएँ, जहाँ उचित हो वहाँ गणितीय विवेचन, और Python में स्वनिर्भर चलाने योग्य कोड उदाहरण शामिल हैं।

यह पुस्तक उन व्यवसायियों के लिए है जो ML प्रणालियाँ बनाते हैं, उन शोधकर्ताओं के लिए जो उनका अध्ययन करते हैं, उन छात्रों के लिए जो उनके बारे में सीख रहे हैं, और उन सभी के लिए जिन्होंने कभी यह जानना चाहा है कि उस मॉडल को प्रशिक्षित करने वाला डेटा किसने लेबल किया जिसने वह निर्णय लिया जिसने उनके जीवन को प्रभावित किया।

सभी मामलों में उत्तर यही है: एक मानव। अक्सर कम वेतन पाने वाला। कभी-कभार ही श्रेय मिलता है। हमेशा लूप में।

मुख्य शब्द: ह्यूमन-इन-द-लूप मशीन लर्निंग, सक्रिय अधिगम, डेटा एनोटेशन, मानव प्रतिक्रिया से प्रबलन अधिगम, RLHF, वरीयता अधिगम, क्राउडसोर्सिंग, इंटरैक्टिव मशीन लर्निंग, AI संरेखण, उत्तरदायी AI

विषय वर्गीकरण: मशीन लर्निंग · मानव-कंप्यूटर अंतःक्रिया · कृत्रिम बुद्धिमत्ता · डेटा विज्ञान

शब्द संख्या: पर्याप्त।

आभार

ह्यूमन-इन-द-लूप मशीन लर्निंग पर प्रत्येक पुस्तक को अपने स्वयं के लूप में उपस्थित मनुष्यों से प्रारंभ होना चाहिए।

अनुलेखक। यह पुस्तक, एक अर्थ में, आपके बारे में है — आपके परिश्रम के बारे में, आपके निर्णय के बारे में, और इस तथ्य के बारे में कि किसी डेटासेट कार्ड, शोधपत्र प्रशंसा या आपके काम से संभव हुए मॉडलों की प्रेस विज्ञप्ति में आपका नाम नहीं आता। यह क्षेत्र इसके साथ जूझने लगा है। इसे अभी बहुत लंबा रास्ता तय करना है।

ओपन-सोर्स योगदानकर्ता जिनकी पुस्तकालयें प्रत्येक कोड उदाहरण में प्रयुक्त हैं: NumPy समुदाय (2006 से), scikit-learn योगदानकर्ता (2007 से), PyTorch टीम, Hugging Face समुदाय, और अनगिनत अनुरक्षक जो बिना मुआवज़े या मान्यता के सप्ताहांत में बग ठीक करते हैं। वैज्ञानिक संगणना इस अदृश्य श्रम पर निर्मित है।

शोधकर्ता जिन्होंने अपना काम खुले रूप से प्रकाशित किया — arXiv प्रीप्रिंट, ओपन-एक्सेस स्थानों, और GitHub रिपॉज़िटरी में — जिससे व्यवसायियों के लिए संस्थागत पहुँच के बिना सीखना संभव हो सका। और वे शोधकर्ता जिन्होंने शोधपत्रों की सावधानीपूर्वक और ईमानदारी से समीक्षा की — विशेषज्ञ अनुलेखन का एक रूप जिसे अकादमिया ने किसी तरह खुद को यह विश्वास दिलाया है कि यह श्रम नहीं है।

शिक्षक जिन्होंने ज्ञान को सुलभ बनाया: ब्लॉगर, ट्यूटोरियल लेखक, Stack Overflow उत्तरदाता, सम्मेलन प्रस्तुतकर्ता जिन्होंने अपनी स्लाइड पोस्ट कीं। अधिगम एकांत में नहीं होता, और यह अजनबियों को चीज़ें समझाने के इच्छुक लोगों के बिना नहीं होता।

आलोचक। वे शोधकर्ता जिन्होंने बताया कि डेटासेट पूर्वाग्रह एन्कोड करते हैं, कि अनुलेखक जनसांख्यिकी मॉडल व्यवहार को आकार देती है, कि लूप में मौजूद मनुष्य अक्सर प्रणाली में सबसे कमज़ोर प्रतिभागी होते हैं। असुविधाजनक प्रश्न पूछने के आपके आग्रह के कारण यह क्षेत्र बेहतर है।

> ज्ञात ज्ञात हैं — वे चीज़ें जो हम जानते हैं कि हम जानते हैं। ज्ञात अज्ञात हैं — वे चीज़ें जो हम जानते हैं कि हम नहीं जानते। अज्ञात अज्ञात हैं — वे चीज़ें जो हम नहीं जानते कि हम नहीं जानते।
>
> और फिर वे चीज़ें हैं जो इस क्षेत्र में सभी जानते हैं लेकिन जो कभी शोधपत्रों में नहीं आती।
>
> यह पुस्तक, एक अर्थ में, उस अंतिम श्रेणी का प्रयास है।

यदि आपने इस क्षेत्र में योगदान दिया है और आपका नाम यहाँ नहीं दिखता: आपका आभार व्यक्त किया गया है। लूप में आप शामिल हैं।

मानव-इन-द-लूप ML क्या है?

> एक मशीन जो अनुभव से सीख सकती है... लेकिन केवल तभी जब आप उसे सही अनुभव दें। – Alan Turing की व्याख्या

स्वचालन का विरोधाभास

स्वचालन की प्रत्येक नई लहर मानव ध्यान पर नई माँगें उत्पन्न करती है। जब एयरलाइनों ने ऑटोपायलट पेश किया, तो पायलट निगरानीकर्ता बन गए — पल-पल के नियंत्रण के लिए नहीं, बल्कि इस कठिन कार्य के लिए कि कब हस्तक्षेप करना है। जब सुपरमार्केट ने सेल्फ-चेकआउट पेश किया, तो उन्होंने पाया कि पारंपरिक कैशियरों की तुलना में प्रति लेनदेन अधिक मानव पर्यवेक्षण की आवश्यकता होती है, कम नहीं। और जब मशीन लर्निंग ने चिकित्सा, वित्त, भर्ती, और सामग्री मॉडरेशन में बड़े पैमाने पर निर्णय लेना शुरू किया, तो इसने मानव निर्णय की एक विशाल, निरंतर माँग उत्पन्न की।

यही **स्वचालन का विरोधाभास** है {cite}`bainbridge1983ironies`: एक स्वचालित प्रणाली जितनी अधिक सक्षम हो जाती है, उसकी विफलताएँ उतनी ही अधिक परिणामपूर्ण होती हैं, और इसलिए मज़बूत मानव निगरानी उतनी ही अधिक आवश्यक हो जाती है। मशीन लर्निंग कोई अपवाद नहीं है।

ह्यूमन-इन-द-लूप मशीन लर्निंग (HITL ML) वह क्षेत्र है जो इस विरोधाभास को गंभीरता से लेता है और इसे शुरू से ही प्रणाली डिज़ाइन में शामिल करता है। मानव भागीदारी को अंततः हटाई जाने वाली अस्थायी पाड़ के रूप में मानने के बजाय, HITL ML मानव–मशीन अंतःक्रिया को एक विशेषता के रूप में मानता है — एक संकेत, सुधार, और मार्गदर्शन का स्रोत जो मॉडलों को अधिक सटीक, मानव मूल्यों के साथ अधिक संरेखित, और अधिक विश्वसनीय बना सकता है।

HITL ML की परिभाषा

साहित्य में HITL ML की कोई एकल सहमत परिभाषा नहीं है, और यह शब्द कई परस्पर अतिव्यापी तरीकों से उपयोग किया जाता है। इस पुस्तक के लिए हम एक व्यापक किंतु सटीक परिभाषा अपनाते हैं:

:::{admonition} परिभाषा :class: important

ह्यूमन-इन-द-लूप मशीन लर्निंग किसी भी ML प्रणाली या पद्धति को संदर्भित करता है जिसमें मानव प्रतिक्रिया को अधिगम प्रक्रिया में जानबूझकर, संरचित और निरंतर तरीके से शामिल किया जाता है — न केवल डेटासेट निर्माण के समय, बल्कि प्रशिक्षण, मूल्यांकन और परिनियोजन के दौरान भी।

:::

इस परिभाषा में तीन प्रमुख खंड हैं:

जानबूझकर। HITL आकस्मिक मानव प्रभाव नहीं है (जैसे, यह तथ्य कि प्रशिक्षण डेटा मूल रूप से मनुष्यों द्वारा बनाया गया था)। यह उन प्रणालियों को संदर्भित करता है जो स्पष्ट रूप से मानव प्रतिक्रिया को आमंत्रित करने, शामिल करने और उससे लाभ उठाने के लिए डिज़ाइन की गई हैं।

संरचित। प्रतिक्रिया का एक परिभाषित रूप है — एक लेबल, एक सुधार, एक वरीयता निर्णय, एक प्रदर्शन — और अधिगम एल्गोरिदम में एक परिभाषित भूमिका है।

निरंतर। प्रतिक्रिया लूप समय के साथ जारी रहता है, जिससे प्रणाली नई स्थितियों का सामना करने, गलतियाँ करने, और मानव मार्गदर्शन प्राप्त करने पर सुधार कर सकती है।

यह परिभाषा शास्त्रीय अनुलेखन पाइपलाइनों, सक्रिय अधिगम, इंटरैक्टिव ML, RLHF, और अनुकरण अधिगम को शामिल करती है। यह निष्क्रिय डेटा संग्रह और पूरी तरह ऑफलाइन निर्देशित अधिगम को बाहर रखती है (हालाँकि रेखा धुंधली है, जैसा कि हम अध्याय 2 में चर्चा करेंगे)।

संक्षिप्त इतिहास

विशेषज्ञ प्रणालियाँ और ज्ञान इंजीनियरिंग (1960–1980 के दशक)

सबसे प्रारंभिक AI प्रणालियाँ लगभग पूरी तरह ह्यूमन-इन-द-लूप थीं: ज्ञान इंजीनियर महीनों तक डोमेन विशेषज्ञों के साथ बैठते थे, MYCIN और DENDRAL जैसी विशेषज्ञ प्रणालियों में नियमों को सावधानीपूर्वक कोड करते थे। ज्ञान का प्रत्येक टुकड़ा एक मानव द्वारा स्पष्ट रूप से प्रदान किया जाता था। मशीन निष्पादक थी; मानव ज्ञानस्रोत था।

ये प्रणालियाँ संकीर्ण डोमेन में आश्चर्यजनक रूप से अच्छी तरह काम करती थीं लेकिन भंगुर थीं — अपने हस्त-निर्मित नियमों से परे सामान्यीकरण करने में असमर्थ और रखरखाव में महंगी।

सांख्यिकीय मोड़ (1980–2000 के दशक)

1980 और 1990 के दशकों में सांख्यिकीय मशीन लर्निंग की ओर बदलाव ने मानव भागीदारी की प्रकृति बदल दी। नियमों के रूप में ज्ञान को कूटबद्ध करने के बजाय, मनुष्यों ने अब उदाहरण प्रदान किए — लेबल किए गए डेटासेट जिन्होंने मॉडलों को पैटर्न अनुमानित करने की अनुमति दी। मानव की भूमिका अनुलेखक की हो गई: दस्तावेज़ लेबल करना, छवियाँ टैग करना, भाषण अनुलेखित करना।

यह एक बड़ा कदम आगे था, लेकिन इसने एक नई बाधा उत्पन्न की: **लेबल किया गया डेटा महंगा है**। शोधकर्ताओं ने पूछना शुरू किया कि मानव लेबलिंग प्रयास का सबसे कुशल उपयोग कैसे किया जाए। इस प्रश्न ने **सक्रिय अधिगम** को जन्म दिया, जिसे 1990 के दशक की शुरुआत में पहली बार औपचारिक रूप दिया गया {cite}`cohn1994improving`।

डीप लर्निंग युग (2010 का दशक–वर्तमान)

डीप लर्निंग क्रांति ने एक नया प्रतिमान बनाया: अरबों पैरामीटर वाले मॉडल जो डेटा से असाधारण जटिल कार्य सीख सकते हैं — लेकिन इसके लिए तदनुसार विशाल लेबल किए गए डेटासेट की आवश्यकता होती है। ImageNet (14 मिलियन लेबल किए गए चित्र) और बाद की बड़े पैमाने की अनुलेखन परियोजनाओं ने पैमाने की शक्ति और लागत दोनों को दर्शाया।

साथ ही, बड़े पैमाने पर ML के परिनियोजन ने नई समस्याएँ उजागर कीं: ऐसे मॉडल जो औसतन सटीक थे लेकिन विशिष्ट समूहों के लिए व्यवस्थित रूप से गलत थे, जो तथ्यों को आत्मविश्वास से गढ़ते थे, जो मानव मूल्यों के बजाय मापने योग्य प्रॉक्सी के लिए अनुकूलन करते थे। इन विफलताओं ने मानव भागीदारी के नए रूपों को प्रेरित किया: केवल लेबलिंग नहीं, बल्कि संरेखण — वह परियोजना जिसमें मॉडलों को उस तरह व्यवहार करना सिखाया जाता है जैसा मनुष्य वास्तव में चाहते हैं।

इस संरेखण-केंद्रित HITL कार्य की सबसे स्पष्ट अभिव्यक्ति **मानव प्रतिक्रिया से प्रबलन अधिगम (RLHF)** है {cite}`christiano2017deep`, जो InstructGPT {cite}`ouyang2022training` और आधुनिक भाषा मॉडलों की निर्देश-अनुसरण क्षमताओं की रीढ़ बन गया।

HITL क्यों? मानव निर्णय का तर्क

मानव निर्णय को मशीन लर्निंग प्रणालियों में शामिल करने योग्य क्या बनाता है? कई गुण:

1. सामान्य ज्ञान और विश्व-बोध

मनुष्य किसी भी कार्य के लिए विशाल पृष्ठभूमि ज्ञान लाते हैं। जब एक रेडियोलॉजिस्ट X-ray लेबल करती है, तो वह वर्षों के प्रशिक्षण, शारीरिक रचना की समझ, और इस बारे में अंतर्निहित ज्ञान पर निर्भर करती है कि रोग कैसे दिखते हैं — ऐसा ज्ञान जिसे पूरी तरह निर्दिष्ट करना या केवल डेटा से प्राप्त करना असाधारण रूप से कठिन है।

2. अर्थपूर्ण आधार

लेबल इसलिए अर्थपूर्ण हैं क्योंकि मनुष्य समझते हैं कि उनका क्या अर्थ है। ImageNet में "बिल्ली" वर्ग एक अस्पष्ट अवधारणा को संदर्भित करता है जिसे मनुष्य सहज रूप से पहचानते हैं लेकिन जिसे कोई औपचारिक परिभाषा पूरी तरह से नहीं पकड़ती। मॉडल लेबल का विस्तार सीखते हैं (कौन सी छवियाँ उस पर मानचित्रित होती हैं) लेकिन स्वयं अवधारणा नहीं सीख सकते, जिससे सीमांत मामलों पर विफलताएँ होती हैं जिन्हें कोई भी मानव सही ढंग से संभाल लेता।

3. मूल्य संरेखण

मनुष्यों की प्राथमिकताएँ, मूल्य, और नैतिक निर्णय होते हैं जिन्हें ML मॉडल केवल डेटा से प्राप्त नहीं कर सकते। क्या कोई पाठ "सहायक" है या "हानिकारक" यह एक विशुद्ध अनुभवजन्य प्रश्न नहीं है — यह मानव मूल्यों पर निर्भर करता है जो व्यक्तियों और संदर्भों में भिन्न होते हैं। HITL वह प्राथमिक तंत्र है जिसके द्वारा ये मूल्य ML प्रणालियों तक संप्रेषित किए जा सकते हैं।

4. अनुकूलनीयता

मानव निर्णय पुनः प्रशिक्षण के बिना नई स्थितियों के अनुकूल हो सकता है। ऐतिहासिक डेटा पर प्रशिक्षित एक मॉडल जब विश्व बदलता है तो विनाशकारी रूप से विफल हो सकता है; एक मानव नवीनता को पहचान सकता है और उचित प्रतिक्रिया दे सकता है।

5. जवाबदेही

उच्च-दांव वाले डोमेन — चिकित्सा, कानून, वित्त — में निर्णयों को मानव प्राणियों के प्रति जवाबदेह होना आवश्यक है। HITL प्रणालियाँ इस जवाबदेही को व्यवहार्य बनाती हैं, मनुष्यों को मशीन व्यवहार को समझने, सत्यापित करने और ओवरराइड करने की स्थिति में रखकर।

प्रतिक्रिया लूप

HITL ML की केंद्रीय संरचना एक मॉडल और एक या अधिक मनुष्यों के बीच एक प्रतिक्रिया लूप है:

```
+-----------------------------------------------+
|                                               |
|   □□□□ □□□□□□□□□□□□ / □□□□□□ □□□□ □□        |
|   ---------------------------------->        |
|                                □□□□      |
|   □□□□ □□□□□□□□□□□□ □□□□□□ □□□□ □□ <------- |
|   ----------------------------------         |
|                                               |
|   □□□□ □□□□□□□□□□□□ □□ □□□□□□ □□□□ □□       |
|                                               |
+-----------------------------------------------+
```

प्रतिक्रिया की प्रकृति HITL प्रतिमानों में बहुत भिन्न होती है:

प्रतिक्रिया प्रकार	उदाहरण	प्राथमिक प्रतिमान
वर्ग लेबल	"यह ईमेल स्पैम है"	निर्देशित अधिगम
सुधार	"यह इकाई PER नहीं, ORG होनी चाहिए"	सक्रिय / इंटरैक्टिव ML
वरीयता	"उत्तर A, B से बेहतर है"	RLHF / रैंकिंग
प्रदर्शन	रोबोट को वस्तु पकड़ना दिखाना	अनुकरण अधिगम
प्राकृतिक भाषा	"अपने उत्तरों में अधिक संक्षिप्त रहें"	निर्देश ट्यूनिंग
अंतर्निहित संकेत	उपयोगकर्ता ने क्लिक किया / नहीं किया	अंतर्निहित प्रतिक्रिया

HITL क्या नहीं है

यह स्पष्ट करना उचित है कि हमारी परिभाषा के बाहर क्या आता है।

HITL, ह्यूमन-ऑन-द-लूप परिनियोजन के समान नहीं है (जिसे कभी-कभी "human on the loop" कहा जाता है), जहाँ मनुष्य स्वचालित निर्णयों की निगरानी करते हैं और उन्हें ओवरराइड कर सकते हैं लेकिन प्रशिक्षण में सुधार वापस नहीं दे रहे हैं। हम अध्याय 2 में इस भेद पर चर्चा करेंगे।

HITL, केवल कमज़ोर पर्यवेक्षण नहीं है। Snorkel जैसी प्रोग्रामेटिक लेबलिंग प्रणालियाँ बड़े पैमाने पर शोरगुल वाले लेबल उत्पन्न करने के लिए लेबलिंग फ़ंक्शन (अक्सर मानव-लिखित नियम) का उपयोग करती हैं। यह संरचित मानव इनपुट का एक रूप है, लेकिन प्रतिक्रिया उस तरह पुनरावृत्त नहीं है जैसा HITL आमतौर पर तात्पर्य करता है।

HITL, केवल लेबल किए गए डेटा का उपयोग करना नहीं है। प्रत्येक निर्देशित अधिगम मॉडल मानव-लेबल किए गए डेटा का उपयोग करता है। HITL विशेष रूप से उन प्रणालियों को संदर्भित करता है जहाँ मानव प्रतिक्रिया अधिगम प्रक्रिया का एक सक्रिय, पुनरावृत्त हिस्सा है।

मानव प्रतिक्रिया का अर्थशास्त्र

मानव प्रतिक्रिया मूल्यवान लेकिन महंगी है। एक विशेषज्ञ द्वारा की गई चिकित्सा इमेजिंग अनुलेखन में उपविशेषता और कार्य जटिलता के आधार पर प्रति छवि दसों से सैकड़ों डॉलर खर्च हो सकते हैं {cite}`monarch2021human`। Amazon Mechanical Turk जैसे प्लेटफ़ॉर्म पर क्राउडवर्कर लेबल बहुत कम गुणवत्ता पर $0.01–$0.10 प्रति आइटम {cite}`hara2018data` पर मिल सकते हैं। HITL ML की मूलभूत चुनौती **मानव प्रतिक्रिया की प्रत्येक इकाई के मूल्य को अधिकतम करना** है।

इससे एक एकीकृत प्रश्न उत्पन्न होता है जो इस पुस्तक के अधिकांश भाग में व्याप्त है:

:::{admonition} HITL ML का केंद्रीय प्रश्न :class: tip

मानव समय और ध्यान के एक निश्चित बजट को देखते हुए, हमें कैसे तय करना चाहिए कि मनुष्यों से क्या पूछना है, कब पूछना है, और उनके उत्तरों को मॉडल प्रशिक्षण में कैसे शामिल करना है?

:::

इस प्रश्न का उत्तर डोमेन, प्रतिक्रिया के स्वरूप, अनुलेखन लागत, त्रुटि के जोखिम, और मॉडल की वर्तमान स्थिति पर निर्भर करता है — यही कारण है कि HITL ML एक समृद्ध और अभी भी विकसित हो रहा अनुशासन है।

पुस्तक का अवलोकन

इस पुस्तक का शेष भाग निम्नानुसार संरचित है। **भाग II** HITL के तीन शास्त्रीय स्तंभों को शामिल करता है: अनुलेखन, सक्रिय अधिगम, और इंटरैक्टिव ML। **भाग III** प्रतिक्रिया से अधिगम के नए प्रतिमानों को संबोधित करता है — RLHF, अनुकरण अधिगम, और वरीयता अधिगम — जो आधुनिक AI के केंद्र में आ गए हैं। **भाग IV** विशिष्ट अनुप्रयोग डोमेन के लेंस से HITL की जाँच करता है। **भाग V** प्लेटफ़ॉर्म, क्राउडसोर्सिंग और मूल्यांकन पर व्यवसायी दृष्टिकोण अपनाता है। **भाग VI** नैतिकता को संबोधित करता है और आगे देखता है।

> **See also:** क्षेत्र के व्यवसायी-केंद्रित अवलोकन के लिए, {cite}`monarch2021human` देखें। HITL के औपचारिक विवेचन की शुरुआत करने वाले मूलभूत सक्रिय अधिगम शोधपत्र के लिए, {cite}`settles2009active` देखें।

मानव–मशीन अंतःक्रिया का वर्गीकरण

स्पष्ट चिंतन के लिए सटीक शब्दावली अनिवार्य है। व्यवहार में "ह्यूमन-इन-द-लूप" शब्द का प्रयोग शिथिलता से होता है — कभी इसका अर्थ होता है कि एक मानव प्रशिक्षण डेटा लेबल करता है, कभी कि एक मानव किसी मॉडल के निर्णय को ओवरराइड कर सकता है, और कभी कि एक मानव वास्तविक समय में अधिगम प्रक्रिया को सक्रिय रूप से निर्देशित कर रहा है। ये अर्थपूर्ण रूप से अलग-अलग बातें हैं।

यह अध्याय ML में मानव–मशीन अंतःक्रिया के परिदृश्य को मानचित्रित करता है, जो पूरी पुस्तक में उपयोग की जाने वाली वैचारिक शब्दावली प्रदान करता है।

स्वचालन के स्तर

सबसे बुनियादी भेद यह है कि मानव प्रणाली के निर्णय-निर्माण में कितनी सक्रियता से शामिल है। स्वचालन सिद्धांत से एक प्रसिद्ध रूपरेखा {cite}`sheridan1992telerobotics` दस स्तरों को अलग करती है, लेकिन ML उद्देश्यों के लिए तीन श्रेणियाँ महत्त्वपूर्ण विविधता को पकड़ती हैं:

ह्यूमन-इन-द-लूप (HITL)

मानव अधिगम प्रक्रिया में एक सक्रिय भागीदार है। निर्णय — या कम से कम, परिणामपूर्ण निर्णय — अंतिम रूप दिए जाने से पहले मानव इनपुट की आवश्यकता होती है। प्रणाली निरंतर मानव भागीदारी के बिना संचालित नहीं हो सकती।

उदाहरण: एक सक्रिय अधिगम प्रणाली जो प्रशिक्षण डेटा में कोई केस जोड़ने से पहले एक चिकित्सक से परामर्श करती है। एक डेटा अनुलेखक उदाहरणों को लेबल करता है जिन्हें तुरंत मॉडल अपडेट के लिए उपयोग किया जाता है। एक RLHF लेबलर मॉडल आउटपुट की तुलना करता है।

ह्यूमन-ऑन-द-लूप (HOTL)

प्रणाली स्वायत्त रूप से संचालित होती है लेकिन एक मानव इसकी निगरानी करता है और हस्तक्षेप कर सकता है। मानव एक पर्यवेक्षक है, प्रतिभागी नहीं। प्रतिक्रिया प्रशिक्षण में वापस जा सकती है या नहीं भी जा सकती।

उदाहरण: एक सामग्री मॉडरेशन प्रणाली जो पोस्ट को स्वचालित रूप से फ़्लैग करती है; एक मानव समीक्षक निर्णयों के एक अंश की जाँच करता है और सुधार करता है। एक ऑटोपायलट जो विमान उड़ाता है लेकिन पायलट को विसंगतियों के बारे में सतर्क करता है।

ह्यूमन-इन-कमांड (HIC)

मानव सभी निर्णय करता है; प्रणाली सिफारिशें या सूचना प्रदान करती है लेकिन इसकी कोई स्वायत्तता नहीं है। यह ML परिनियोजन का सबसे कमज़ोर रूप है।

उदाहरण: एक नैदानिक सहायता प्रणाली जो एक डॉक्टर को मॉडल का प्रायिकता अनुमान दिखाती है लेकिन अंतिम निर्णय पूरी तरह चिकित्सक पर छोड़ देती है।

कौन सा स्तर सही है? :class: tip

स्वचालन का उचित स्तर त्रुटियों की लागत, मॉडल की विश्वसनीयता, उपलब्ध मनुष्यों की विशेषज्ञता, और कार्य की विलंबता बाधाओं पर निर्भर करता है। ये कारक मॉडल की परिपक्वता के साथ बदलते हैं — अधिकांश प्रणालियाँ HITL से शुरू होती हैं और जैसे-जैसे विश्वास बढ़ता है HOTL की ओर स्थानांतरित होती हैं।

```
□ □ □□□ □□□□ --> □□□□□□□□□□□□□□ --> □□□□□□□□□ --> □□□□
    ^            ^                  ^            ^          ^
    |            |                  |            |          |
 □□□□□□      □□□□□□□□                □□□□□□       □□□□
 □□□□□□□□□□□□  □□ □□□□□□□□              □□□□□       □□□
```

चरण	मानव की भूमिका	अध्याय
संग्रह	कौन सा डेटा एकत्र करना है; नमूनाकरण रणनीति	3, 4
अनुलेखन	लेबल, संरचनाएँ, मेटाडेटा असाइन करना	3, 13
प्रशिक्षण	सक्रिय अधिगम क्वेरी; ऑनलाइन प्रतिक्रिया	4, 5, 6
मूल्यांकन	मॉडल आउटपुट का मानव मूल्यांकन	14
परिनियोजन	निगरानी, अपवाद प्रबंधन, सुधार	12, 14

सक्रिय बनाम निष्क्रिय मानव भागीदारी

सक्रिय HITL में, प्रणाली चुनती है कि मानव को कौन से डेटा बिंदु प्रस्तुत करने हैं — रणनीतिक रूप से प्रश्न पूछना। निष्क्रिय HITL में, मानव जो भी डेटा आता है उस पर प्रतिक्रिया प्रदान करता है (जैसे, क्रमिक रूप से असाइन किए गए डेटा लेबलिंग बैच)।

सक्रिय भागीदारी अधिक कुशल है क्योंकि प्रतिक्रिया वहाँ निर्देशित होती है जहाँ यह मॉडल को सबसे अधिक सुधारेगी। निष्क्रिय भागीदारी को लागू करना और प्रबंधित करना सरल है।

एक संबंधित भेद **बैच** और **ऑनलाइन** प्रतिक्रिया के बीच है:

- **बैच:** मनुष्य उदाहरणों का एक बड़ा पूल लेबल करते हैं; मॉडल पुनः प्रशिक्षित होता है। दोहराएँ।
- **ऑनलाइन (स्ट्रीमिंग):** मानव प्रतिक्रिया निरंतर आती है; मॉडल वृद्धिशील रूप से अपडेट होता है।

उद्योग में बैच वर्कफ़्लो मानदंड हैं (अनुलेखन परियोजनाओं के बाद प्रशिक्षण रन)। ऑनलाइन वर्कफ़्लो इंटरैक्टिव प्रणालियों और प्रबलन अधिगम सेटिंग्स के लिए अधिक स्वाभाविक हैं।

एकल बनाम एकाधिक अनुलेखक

HITL की अधिकांश औपचारिक प्रस्तुतियाँ एकल, सुसंगत अनुलेखक मानती हैं। व्यवहार में, अनुलेखन में कई लोग शामिल होते हैं, और उनके निर्णय भिन्न होते हैं।

एकत्रीकरण कई अनुलेखनों को एक एकल लेबल में संयोजित करता है, आमतौर पर बहुमत वोट या सांख्यिकीय मॉडल (अध्याय 13) द्वारा।

असहमति को संकेत के रूप में — कुछ शोधकर्ता तर्क देते हैं कि अनुलेखक असहमति मूल्यवान जानकारी है जिसे एकल "स्वर्ण" लेबल में संकुचित नहीं किया जाना चाहिए। उदाहरण के लिए, NLP के लिए परिप्रेक्ष्यवादी दृष्टिकोण एकाधिक अनुलेखनों को नरम लेबल के रूप में संरक्षित करते हैं जो डेटा की वास्तविक अस्पष्टता को दर्शाते हैं {cite}`uma2021learning`।

एक एकीकृत रूपरेखा

हम किसी भी HITL कॉन्फ़िगरेशन को पाँच-तत्व समूह के साथ प्रस्तुत कर सकते हैं:

$$\text{HITL config} = \big(\text{level}, \text{modality}, \text{stage}, \text{frequency}, \text{annotators}\big)$$

जहाँ:

- **level** $\in$ {HITL, HOTL, HIC}
- **modality** $\in$ {label, correction, demonstration, preference, NL, implicit}
- **stage** $\in$ {collection, annotation, training, evaluation, deployment}
- **frequency** $\in$ {batch, online}
- **annotators** $\in \mathbb{N}^+$ (प्रति आइटम अनुलेखकों की संख्या)

यह वर्गीकरण हमें एक ही अक्षों पर विविध HITL प्रणालियों की तुलना करने और उनके बीच के व्यापार-बंद के बारे में तर्क करने देता है। पुस्तक का शेष भाग इस स्थान की विशिष्ट कोशिकाओं में गहराई से जाता है।

> **See also:** इस बारे में एक अनुभवजन्य अध्ययन के लिए कि अनुलेखन निर्णय डाउनस्ट्रीम मॉडल व्यवहार को कैसे प्रभावित करते हैं, {cite}`bender2021stochastic` देखें। इंटरैक्टिव ML प्रणालियों के एक सर्वेक्षण के लिए, {cite}`amershi2014power` देखें।

डेटा अनुलेखन एवं लेबलिंग

डेटा अनुलेखन ML में मानव भागीदारी का सर्वाधिक सर्वव्यापी रूप है। किसी मॉडल के सीखने से पहले, किसी को यह बताना होगा कि सही उत्तर क्या हैं — और वह कोई आमतौर पर एक मानव होता है। यह अध्याय अनुलेखन के सिद्धांत और व्यवहार को शामिल करता है: अनुलेखन कठिन क्यों है, अनुलेखन कार्य कैसे डिज़ाइन किए जाएँ, गुणवत्ता कैसे मापी जाए, और असहमति को कैसे संभाला जाए।

अनुलेखन के प्रकार

अनुलेखन कार्य अपनी संरचना, कठिनाई और लागत में बहुत भिन्न होते हैं। प्रमुख प्रकारों में शामिल हैं:

वर्गीकरण

अनुलेखक प्रत्येक उदाहरण को K पूर्वपरिभाषित श्रेणियों में से एक को असाइन करता है। यह संज्ञानात्मक रूप से सबसे सरल अनुलेखन कार्य है, लेकिन एक अच्छी श्रेणी योजना (एक वर्गीकरण-क्रम) बनाना आश्चर्यजनक रूप से कठिन हो सकता है।

द्विआधारी वर्गीकरण (क्या यह छवि बिल्ली है?) सबसे सरल मामला है। **बहुवर्गीय** (यह कौन सी प्रजाति का जानवर है?) अनुलेखकों को एक सूची से एक विकल्प चुनने की आवश्यकता होती है। **बहुलेबल** अनुलेखन (इस लेख में कौन से विषय हैं?) एकाधिक एक साथ लेबल की अनुमति देता है।

अनुक्रम लेबलिंग

किसी अनुक्रम में प्रत्येक टोकन को एक लेबल मिलता है। नाम इकाई पहचान (NER) कैनॉनिकल उदाहरण है — अनुलेखक पाठ के हिस्सों को PERSON, ORGANIZATION, LOCATION आदि के रूप में चिह्नित करते हैं। अनुलेखन आमतौर पर BIO (Beginning-Inside-Outside) या BIOES टैगिंग योजना का उपयोग करके किया जाता है:

B–ORG O B–ORG O O O

स्पैन और संबंध अनुलेखन

व्यक्तिगत टोकन को लेबल करने से परे, अनुलेखकों को यह करना पड़ सकता है: - स्पैन (बहु-टोकन अभिव्यक्तियाँ) की पहचान करना और प्रकार असाइन करना - स्पैन के बीच संबंधों को चिह्नित करना ("Apple" ACQUIRED "Shazam") - सहसंदर्भ श्रृंखलाओं को अनुलेखित करना (एक ही इकाई के सभी उल्लेख)

ये कार्य संज्ञानात्मक रूप से माँगपूर्ण हैं और इनमें अंतर-अनुलेखक सहमति कम होती है।

बाउंडिंग बॉक्स और वस्तु पहचान

अनुलेखक छवियों में वस्तुओं के चारों ओर आयत खींचते हैं और प्रत्येक बॉक्स को एक श्रेणी लेबल असाइन करते हैं। स्थानीयकरण सटीकता महत्त्वपूर्ण है: बहुत छोटा बॉक्स संदर्भ छोड़ देता है; बहुत बड़ा बॉक्स पृष्ठभूमि शामिल करता है। आधुनिक अनुलेखन उपकरण गुणवत्ता समस्याओं को चिह्नित करने के लिए संदर्भ अनुलेखनों के साथ intersection-over-union (IoU) की गणना करते हैं।

विभाजन

पिक्सेल-स्तर अनुलेखन: प्रत्येक पिक्सेल को एक वर्ग (अर्थ विभाजन) या एक विशिष्ट वस्तु उदाहरण (उदाहरण विभाजन) को असाइन किया जाता है। उच्च गुणवत्ता वाला विभाजन सबसे महंगे अनुलेखन प्रकारों में से एक है, जिसकी लागत डोमेन और उपकरण समर्थन के आधार पर जटिल दृश्यों के लिए प्रति छवि दसों से एक सौ से अधिक डॉलर तक होती है।

अनुलेखन और अनुवाद

ऑडियो ⊠ पाठ (ASR प्रशिक्षण डेटा), हस्तलेख ⊠ पाठ (OCR डेटा), या स्रोत भाषा ⊠ लक्ष्य भाषा (MT डेटा)। इन कार्यों के लिए भाषाई विशेषज्ञता की आवश्यकता होती है और इन्हें अप्रशिक्षित अनुलेखकों द्वारा विश्वसनीय रूप से नहीं किया जा सकता।

अनुलेखन दिशानिर्देश

अनुलेखन गुणवत्ता का एकल सबसे महत्त्वपूर्ण निर्धारक **अनुलेखन दिशानिर्देशों** की गुणवत्ता है: वे लिखित निर्देश जिनका अनुलेखक पालन करते हैं।

अच्छे दिशानिर्देश: - कार्य लक्ष्य बताते हैं और समझाते हैं क्यों लेबल महत्त्वपूर्ण है - सकारात्मक और नकारात्मक उदाहरणों के साथ प्रत्येक श्रेणी की स्पष्ट परिभाषा प्रदान करते हैं - सामान्य किनारे के मामलों और कठिन मामलों को स्पष्ट रूप से संबोधित करते हैं - निर्दिष्ट करते हैं कि अनिश्चित होने पर क्या करना है (जैसे, "छोड़ें" चिह्नित करें बनाम बाध्य विकल्प) - पूर्ण अनुलेखन के काम किए गए उदाहरण शामिल करते हैं

खराब दिशानिर्देश अनुलेखकों पर किनारे के मामलों के लिए "सामान्य ज्ञान का उपयोग करने" का भरोसा करते हैं — जिससे असंगत निर्णय होते हैं जो मॉडल गुणवत्ता को कम करते हैं और अंतर-अनुलेखक असहमति को बढ़ाते हैं।

> **दिशानिर्देश विकास पुनरावृत्त है** :class: note
>
> परिपूर्ण दिशानिर्देश पहली बार में लिखने की अपेक्षा न करें। एक छोटा पायलट अनुलेखन दौर चलाएँ, असहमतियों का विश्लेषण करें, और दिशानिर्देशों को अपडेट करें। दोहराएँ। अच्छी तरह से विकसित दिशानिर्देश आमतौर पर स्थिर होने से पहले 3–5 संशोधन चक्रों से गुज़रते हैं।

अनुलेखन गुणवत्ता का मापन: अंतर-अनुलेखक सहमति

जब एकाधिक अनुलेखक एक ही डेटा लेबल करते हैं, तो उनकी सहमति मापी जा सकती है। उच्च सहमति सुझाती है कि कार्य अच्छी तरह परिभाषित है और अनुलेखकों ने इसे समझा। कम सहमति कार्य, दिशानिर्देशों, या डेटा में ही अस्पष्टता का सुझाव देती है।

Cohen's Kappa

K श्रेणियों में डेटा लेबल करने वाले दो अनुलेखकों के लिए, **Cohen's kappa** {cite}`cohen1960coefficient` देखी गई सहमति को संयोग के लिए ठीक करता है:

$$\kappa = \frac{P_o - P_e}{1 - P_e}$$

जहाँ P_o देखी गई आनुपातिक सहमति है और P_e संयोग द्वारा सहमति की प्रायिकता है (सीमांत लेबल वितरणों से गणना की गई)।

$\kappa = 1$ का अर्थ है पूर्ण सहमति; $\kappa = 0$ का अर्थ है संयोग से बेहतर सहमति नहीं; $\kappa < 0$ का अर्थ है व्यवस्थित असहमति।

κ सीमा	व्याख्या
< 0	संयोग से कम
$0.0 - 0.20$	नगण्य
$0.21 - 0.40$	उचित
$0.41 - 0.60$	मध्यम
$0.61 - 0.80$	पर्याप्त
$0.81 - 1.00$	लगभग पूर्ण

Fleiss' Kappa

$M > 2$ अनुलेखकों के लिए Cohen's kappa का विस्तार। प्रत्येक अनुलेखक स्वतंत्र रूप से प्रत्येक आइटम को लेबल करता है; सूत्र अनुलेखकों में एकत्रित होता है:

$$\kappa_F = \frac{\bar{P} - \bar{P}_e}{1 - \bar{P}_e}$$

जहाँ $\bar{P}$ सभी अनुलेखक जोड़ियों में औसत युगल सहमति है, और $\bar{P}_e$ यादृच्छिक असाइनमेंट के तहत अपेक्षित सहमति है।

Krippendorff's Alpha

सबसे सामान्य मीट्रिक, किसी भी संख्या के अनुलेखकों, किसी भी पैमाने के प्रकार (नाममात्र, क्रमिक, अंतराल, अनुपात), और लापता डेटा का समर्थन करती है {cite}`krippendorff2011computing`:

$$\alpha = 1 - \frac{D_o}{D_e}$$

जहाँ D_o देखी गई असहमति है और D_e अपेक्षित असहमति है। Krippendorff's alpha अपनी लचीलेपन के कारण आमतौर पर शैक्षणिक कार्य में प्राथमिकता दी जाती है।

```
import numpy as np
from sklearn.metrics import cohen_kappa_score

# Simulate two annotators labeling 200 items into 3 categories
rng = np.random.default_rng(0)
true_labels = rng.integers(0, 3, size=200)

# Annotator 1: mostly agrees with ground truth
ann1 = true_labels.copy()
```

```
flip_mask = rng.random(200) < 0.15
ann1[flip_mask] = rng.integers(0, 3, size=flip_mask.sum())

# Annotator 2: less consistent
ann2 = true_labels.copy()
flip_mask2 = rng.random(200) < 0.30
ann2[flip_mask2] = rng.integers(0, 3, size=flip_mask2.sum())

kappa_12 = cohen_kappa_score(ann1, ann2)
kappa_1true = cohen_kappa_score(ann1, true_labels)
kappa_2true = cohen_kappa_score(ann2, true_labels)

print(f"Cohen's κ (ann1 vs ann2):   {kappa_12:.3f}")
print(f"Cohen's κ (ann1 vs truth):  {kappa_1true:.3f}")
print(f"Cohen's κ (ann2 vs truth):  {kappa_2true:.3f}")
```

असहमतियों को संभालना

जब अनुलेखक असहमत होते हैं, तो कई रणनीतियाँ हैं:

बहुमत वोट

सबसे सामान्य लेबल को स्वर्ण मानक के रूप में लिया जाता है। सरल और मज़बूत जब प्रति आइटम अनुलेखकों की संख्या विषम हो। तब विफल हो जाता है जब अनुलेखकों का अल्पसंख्यक समूह व्यवस्थित रूप से अधिक सटीक हो।

भारित वोटिंग

अनुलेखकों को उनकी अनुमानित सटीकता (स्वर्ण मानक या अन्य अनुलेखकों के साथ सहमति से प्राप्त) द्वारा भारित किया जाता है। अधिक सटीक अनुलेखकों का अधिक प्रभाव होता है।

नरम लेबल

अनुलेखनों को एकल लेबल में संकुचित करने के बजाय, वितरण को संरक्षित करें। यदि 5 में से 3 अनुलेखकों ने "सकारात्मक" और 2 ने "तटस्थ" कहा, तो इसे $(p_{\text{pos}}, p_{\text{neutral}}, p_{\text{neg}}) = (0.6, 0.4, 0.0)$ के रूप में प्रस्तुत करें। नरम लेबल पर प्रशिक्षण कैलिब्रेशन में सुधार करता है।

मध्यस्थता

एक वरिष्ठ अनुलेखक या डोमेन विशेषज्ञ असहमतियों का निर्णय करता है। स्वर्ण मानक लेकिन महंगा; आमतौर पर उच्च-दांव डोमेन के लिए आरक्षित।

सांख्यिकीय मॉडल

अधिक परिष्कृत दृष्टिकोण अनुलेखक क्षमता को प्रायिकतात्मक रूप से मॉडल करते हैं। **Dawid-Skene** मॉडल {cite}dawid1979maximum EM के माध्यम से एक साथ अनुलेखक भ्रम मैट्रिक्स और आइटम सत्य लेबल का अनुमान लगाता है। विवरण के लिए अध्याय 13 देखें।

लेबल शोर और उसके प्रभाव

वास्तविक अनुलेखन शोरगुल वाला होता है। मॉडल प्रशिक्षण पर लेबल शोर के प्रभाव शोर के प्रकार पर निर्भर करते हैं:

- **यादृच्छिक शोर** (लेबल यादृच्छिक रूप से पलटे गए) प्रदर्शन को कम करता है लेकिन मॉडल मध्यम स्तरों (कई कार्यों के लिए ~20% तक) के प्रति आश्चर्यजनक रूप से मज़बूत होते हैं।
- **व्यवस्थित/प्रतिकूल शोर** (लेबल विशिष्ट पैटर्न में लगातार गलत) बहुत अधिक हानिकारक और पता लगाने में कठिन है।
- **वर्ग-सशर्त शोर** (कुछ वर्गों के लिए अधिक त्रुटियाँ) मॉडल के निर्णय सीमा को पूर्वाग्रहित करता है।

व्यावहारिक अंगूठे का नियम: n प्रशिक्षण उदाहरणों और ϵ अनुपात के दूषित लेबल के साथ, मॉडल प्रदर्शन लगभग ऐसे घटता है जैसे आपके पास $(1-2\epsilon)^2 n$ स्वच्छ उदाहरण हों {cite}natarajan2013learning। $\epsilon = 0.2$ के लिए, यह आपके डेटा का 36% खोने के समतुल्य है।

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import cross_val_score

rng = np.random.default_rng(42)
X, y = make_classification(n_samples=2000, n_features=20, random_state=42)

noise_levels = np.linspace(0, 0.45, 15)
mean_accs = []

for eps in noise_levels:
    y_noisy = y.copy()
    flip = rng.random(len(y)) < eps
    y_noisy[flip] = 1 - y_noisy[flip]
    scores = cross_val_score(LogisticRegression(max_iter=500), X, y_noisy, cv=5)
    mean_accs.append(scores.mean())

plt.figure(figsize=(7, 4))
plt.plot(noise_levels, mean_accs, 'o-', color='#2b3a8f', linewidth=2)
plt.xlabel("Label noise rate (ε)", fontsize=12)
plt.ylabel("Cross-validated accuracy", fontsize=12)
plt.title("Effect of Label Noise on Model Performance", fontsize=13)
plt.axvline(0.2, color='#e05c5c', linestyle='--', alpha=0.7, label='20% noise')
plt.legend()
plt.tight_layout()
plt.savefig('label_noise_effect.png', dpi=150)
plt.show()
print(f"\nAccuracy at 0% noise:  {mean_accs[0]:.3f}")
print(f"Accuracy at 20% noise: {mean_accs[round(0.2 / 0.45 * 14)]:.3f}")
print(f"Accuracy at 40% noise: {mean_accs[-2]:.3f}")
```

अनुलेखन लागत और थ्रूपुट

अनुलेखन अर्थशास्त्र को समझना परियोजना नियोजन के लिए आवश्यक है।

कार्य प्रकार	सामान्य थ्रूपुट	लागत प्रति आइटम (विशेषज्ञ)
द्विआधारी छवि वर्गीकरण	200–500/घंटा	$0.02–0.10
NER (छोटा पाठ)	50–150 आइटम/घंटा	$0.10–0.50
संबंध निष्कर्षण	20–60 आइटम/घंटा	$0.30–1.50
चिकित्सा छवि विभाजन	5–30 आइटम/घंटा	$10–100
वीडियो अनुलेखन	5–20 मिनट वीडियो/घंटा	$20–200

ये आँकड़े परिमाण-क्रम के अनुमानित अनुमान हैं और डोमेन विशेषज्ञता, अनुलेखन उपकरण गुणवत्ता, दिशानिर्देश स्पष्टता और अनुलेखक अनुभव के अनुसार बहुत भिन्न होते हैं। इन्हें उदाहरणात्मक माना जाना चाहिए, निर्देशात्मक नहीं।

> **See also:** अनुलेखन उपकरण विकल्प अध्याय 12 में शामिल हैं। क्राउडसोर्स किए गए अनुलेखन के लिए सांख्यिकीय मॉडल (Dawid-Skene, MACE) अध्याय 13 में शामिल हैं।

सक्रिय अधिगम

लेबल किया गया डेटा महंगा है। सक्रिय अधिगम की मूल अंतर्दृष्टि यह है कि सभी बिना लेबल के उदाहरण समान रूप से जानकारीपूर्ण नहीं होते — एक मॉडल तेज़ी से सुधर सकता है यदि उसे यह चुनने का मौका मिले कि किन उदाहरणों के बारे में पूछना है। डेटा को यादृच्छिक रूप से लेबल करने के बजाय, एक सक्रिय अधिगम प्रणाली एक ओरेकल (आमतौर पर एक मानव अनुलेखक) से उन उदाहरणों पर क्वेरी करती है जो मॉडल को सबसे अधिक सुधारने की संभावना रखते हैं।

यह अध्याय सक्रिय अधिगम के सिद्धांत और व्यवहार को शामिल करता है: क्वेरी रणनीतियाँ, नमूनाकरण रूपरेखाएँ, रुकने के मानदंड, और वास्तविक परिनियोजन के लिए व्यावहारिक विचार।

सक्रिय अधिगम की स्थापना

मानक **पूल-आधारित सक्रिय अधिगम** सेटिंग में शामिल हैं:

- एक **लेबल किया गया सेट** $\mathcal{L} = \{(x_i, y_i)\}_{i=1}^{n}$ — प्रारंभ में छोटा
- एक **बिना लेबल का पूल** $\mathcal{U} = \{x_j\}_{j=1}^{m}$ — आमतौर पर $\mathcal{L}$ से बहुत बड़ा
- एक **ओरेकल** $\mathcal{O}$ जो किसी भी क्वेरी किए गए x के लिए $y = \mathcal{O}(x)$ लौटा सकता है
- एक **क्वेरी रणनीति** ϕ जो अगली क्वेरी $x^* = \phi(\mathcal{L}, \mathcal{U}, f_\theta)$ का चयन करती है

सक्रिय अधिगम लूप:

```
1. □□□□ □□□□: L = □□□□ □□□□ □□□□ □□□ □□□ □□□, U = □
2. □□□□□□□□□□ □□□□: f_θ ← train(L)
3. □□□□□□ □□□□: x* = argmax φ(x; f_θ) over x ∈ U
4. □□□□ □□□□: y* = O(x*)
5. □□□□□ □□□□: L ← L ∪ {(x*, y*)}, U ← U \ {x*}
→ □□□ □□□□□□ □□□□ □□ 2 □□ □□□□□□□
```

लक्ष्य जितने कम ओरेकल क्वेरी संभव हों उतने में एक लक्ष्य मॉडल गुणवत्ता तक पहुँचना है।

सैद्धांतिक आधार

एक स्वाभाविक प्रश्न है: सक्रिय अधिगम कितनी मदद कर सकता है? सर्वोत्तम मामले में, सक्रिय अधिगम लेबल जटिलता में घातीय कमी प्राप्त कर सकता है — निष्क्रिय अधिगम द्वारा आवश्यक $O(1/\epsilon)$ के बजाय $O(\log(1/\epsilon))$ लेबल के साथ त्रुटि ϵ तक पहुँचना, कम से कम एक अच्छी क्वेरी रणनीति के साथ साकार सेटिंग्स में {cite}`settles2009active`।

व्यवहार में, गारंटी प्राप्त करना कठिन है। **अज्ञेयवादी सक्रिय अधिगम** {cite}`balcan2006agnostic` दर्शाता है कि लेबल बचत तब भी संभव है जब लक्ष्य अवधारणा परिकल्पना वर्ग में न हो, लेकिन बचत असहमति गुणांक पर दृढ़ता से निर्भर करती है।

क्वेरी रणनीतियाँ

अनिश्चितता नमूनाकरण

सबसे सरल और सबसे व्यापक रूप से उपयोग की जाने वाली रणनीति: उस उदाहरण पर क्वेरी करें जिस पर मॉडल सबसे अधिक अनिश्चित है {cite}`lewis1994sequential`।

न्यूनतम विश्वास उस उदाहरण की क्वेरी करता है जिस पर मॉडल अपनी शीर्ष भविष्यवाणी में सबसे कम आश्वस्त है:

$$x^* = \underset{x \in \mathcal{U}}{\arg\max} \left(1 - P_\theta(\hat{y} \mid x)\right)$$

मार्जिन नमूनाकरण शीर्ष दो भविष्यवाणी प्रायिकताओं के बीच के अंतर पर विचार करता है:

$$x^* = \underset{x \in \mathcal{U}}{\arg\min} \left(P_\theta(\hat{y}_1 \mid x) - P_\theta(\hat{y}_2 \mid x)\right)$$

एंट्रॉपी नमूनाकरण पूरे भविष्यवाणी वितरण का उपयोग करता है:

$$x^* = \underset{x \in \mathcal{U}}{\arg\max} \left(-\sum_{k=1}^{K} P_\theta(y_k \mid x) \log P_\theta(y_k \mid x)\right)$$

एंट्रॉपी नमूनाकरण तीनों में सबसे सुव्यवस्थित है — यह सभी वर्गों पर विचार करता है — और आमतौर पर बहुवर्गीय समस्याओं पर दूसरों से बेहतर प्रदर्शन करता है।

समिति द्वारा क्वेरी (QbC)

C मॉडलों की एक **समिति** प्रशिक्षित करें (बैगिंग, विभिन्न आरंभिकरण, या विभिन्न आर्किटेक्चर का उपयोग करके)। उस उदाहरण पर क्वेरी करें जिस पर समिति सबसे अधिक असहमत हो:

$$x^* = \underset{x \in \mathcal{U}}{\arg\max} \ \text{disagreement}(\{f_c(x)\}_{c=1}^{C})$$

असहमति को **वोट एंट्रॉपी** (समिति के बहुमत वोटों पर एंट्रॉपी) या सर्वसम्मति वितरण से **KL विचलन** के रूप में मापा जा सकता है।

QbC एकल मॉडल की तुलना में बेहतर अनिश्चितता अनुमान प्रदान करता है लेकिन एकाधिक मॉडलों के प्रशिक्षण की आवश्यकता होती है, जो गणनात्मक रूप से महंगा है।

अपेक्षित मॉडल परिवर्तन

उस उदाहरण की क्वेरी करें जो लेबल किए जाने पर वर्तमान मॉडल में सबसे बड़ा परिवर्तन करेगा। ग्रेडिएंट-आधारित मॉडलों के लिए, यह सबसे बड़े अपेक्षित ग्रेडिएंट परिमाण वाले उदाहरण से मेल खाता है {cite}`settles2008analysis`:

$$x^* = \underset{x \in \mathcal{U}}{\arg\max} \sum_{y \in \mathcal{Y}} P_\theta(y \mid x) \left\|\nabla_\theta \mathcal{L}(f_\theta(x), y)\right\|$$

कोर-सेट / ज्यामितीय दृष्टिकोण

अनिश्चितता-आधारित रणनीतियाँ **आउटलायर की ओर पूर्वाग्रहित** हो सकती हैं। कोर-सेट विधियाँ इसे एक विविध नमूने की तलाश करके संबोधित करती हैं जो विशेषता स्थान को कवर करता है।

k-center greedy एल्गोरिदम {cite}`sener2018active` बिंदुओं का सबसे छोटा सेट खोजता है जैसे कि प्रत्येक बिना लेबल का बिंदु कम से कम एक क्वेरी किए गए बिंदु के δ के भीतर हो:

$$x^* = \arg\max_{x \in \mathcal{U}} \min_{x' \in \mathcal{L}} d(x, x')$$

BADGE

Batch Active learning by Diverse Gradient Embeddings {cite}`ash2020deep` अनिश्चितता और विविधता को जोड़ता है: यह उदाहरणों का एक बैच चुनता है जिनके ग्रेडिएंट एम्बेडिंग (भविष्यवाणी किए गए लेबल के संबंध में) परिमाण में बड़े (अनिश्चित) और विविध (ग्रेडिएंट स्थान के विभिन्न क्षेत्रों को कवर करते हुए) दोनों हों। यह सबसे प्रतिस्पर्धी आधुनिक रणनीतियों में से एक है।

गहन मॉडलों के लिए अनिश्चितता अनुमान

ऊपर की रणनीतियाँ मॉडल से अंशांकित प्रायिकता आउटपुट तक पहुँच मानती हैं। सरल मॉडलों के लिए यह सीधा है। गहन नेटवर्क के लिए, विश्वसनीय अनिश्चितता अनुमान प्राप्त करने के लिए अतिरिक्त तकनीक की आवश्यकता है।

दो प्रकार की अनिश्चितता

Kendall and Gal {cite}`kendall2017uncertainties` के अनुसार:

आलेटोरिक अनिश्चितता (डेटा अनिश्चितता): अवलोकनों में अंतर्निहित शोर जिसे अधिक डेटा एकत्र करके कम नहीं किया जा सकता।

एपिस्टेमिक अनिश्चितता (मॉडल अनिश्चितता): सीमित प्रशिक्षण डेटा के कारण अनिश्चितता। एपिस्टेमिक अनिश्चितता अधिक डेटा लेबल करके कम की जा सकती है — और इसलिए सक्रिय अधिगम क्वेरी चयन के लिए प्रासंगिक मात्रा है।

Monte Carlo Dropout

तंत्रिका नेटवर्क के लिए एपिस्टेमिक अनिश्चितता अनुमान के लिए एक व्यावहारिक दृष्टिकोण है **MC Dropout** {cite}`gal2016dropout`: अनुमान समय पर ड्रॉपआउट लागू करें और T आगे के पास चलाएँ।

```
import numpy as np
import torch
import torch.nn as nn

torch.manual_seed(42)
rng = np.random.default_rng(42)

class MCDropoutNet(nn.Module):
    def __init__(self, input_dim=20, hidden=64, output_dim=2, p_drop=0.3):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(input_dim, hidden), nn.ReLU(), nn.Dropout(p_drop),
```

```
            nn.Linear(hidden, hidden),    nn.ReLU(), nn.Dropout(p_drop),
            nn.Linear(hidden, output_dim)
        )

    def forward(self, x):
        return self.net(x)

def mc_uncertainty(model, x, T=30):
    """
    Run T stochastic forward passes with dropout active.
    Returns mean prediction and epistemic uncertainty (predictive variance).
    """
    model.train()  # keep dropout active during inference
    with torch.no_grad():
        preds = torch.stack([
            torch.softmax(model(x), dim=-1) for _ in range(T)
        ])  # shape: (T, N, C)
    mean_pred = preds.mean(0)
    # Epistemic uncertainty: mean of variances across passes
    epistemic = preds.var(0).sum(-1)
    # Aleatoric uncertainty: entropy of mean prediction
    aleatoric = -(mean_pred * (mean_pred + 1e-9).log()).sum(-1)
    return mean_pred, epistemic, aleatoric

# Quick demonstration
model = MCDropoutNet(input_dim=20, output_dim=2)
# In-distribution example (simulated)
x_familiar   = torch.randn(1, 20) * 0.5
# Out-of-distribution example (far from training distribution)
x_unfamiliar = torch.randn(1, 20) * 3.0

for name, x in [("In-distribution ", x_familiar), ("Out-of-distribution", x_unfa
    _, ep, al = mc_uncertainty(model, x)
    print(f"{name} | epistemic: {ep.item():.4f} | aleatoric: {al.item():.4f}")
```

एक पूर्ण सक्रिय अधिगम लूप

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score
from copy import deepcopy

rng = np.random.default_rng(42)

# Generate dataset
X, y = make_classification(
    n_samples=2000, n_features=20, n_informative=10,
```

```
    n_classes=3, n_clusters_per_class=1, random_state=42
)
X_train, y_train = X[:1500], y[:1500]
X_test,  y_test  = X[1500:], y[1500:]

def entropy_query(model, X_pool):
    """Return index of most uncertain sample (entropy)."""
    probs = model.predict_proba(X_pool)
    ent = -np.sum(probs * np.log(probs + 1e-9), axis=1)
    return np.argmax(ent)

def random_query(X_pool):
    """Random baseline."""
    return rng.integers(0, len(X_pool))

def run_active_learning(strategy='entropy', n_initial=30, n_queries=120, query_b
    labeled_idx = list(rng.choice(len(X_train), n_initial, replace=False))
    unlabeled_idx = [i for i in range(len(X_train)) if i not in labeled_idx]
    accs = []

    for step in range(n_queries // query_batch):
        model = LogisticRegression(max_iter=500, C=1.0)
        model.fit(X_train[labeled_idx], y_train[labeled_idx])
        accs.append(accuracy_score(y_test, model.predict(X_test)))

        # Query
        X_pool = X_train[unlabeled_idx]
        for _ in range(query_batch):
            if strategy == 'entropy':
                q = entropy_query(model, X_pool)
            else:
                q = random_query(X_pool)
            labeled_idx.append(unlabeled_idx.pop(q))
            X_pool = X_train[unlabeled_idx]

    return np.array(accs)

labels_used = np.arange(1, 25) * 5 + 30  # label counts at each step

accs_active = run_active_learning(strategy='entropy')
accs_random = run_active_learning(strategy='random')

plt.figure(figsize=(8, 5))
plt.plot(labels_used, accs_active, 'o-', label='Entropy sampling', color='#2b3a8
plt.plot(labels_used, accs_random, 's--', label='Random baseline',  color='#e05c
plt.xlabel("Number of labeled examples", fontsize=12)
plt.ylabel("Test accuracy", fontsize=12)
plt.title("Active Learning vs. Random Sampling", fontsize=13)
plt.legend(fontsize=11)
plt.grid(alpha=0.3)
plt.tight_layout()
```

```
plt.savefig('active_learning_curve.png', dpi=150)
plt.show()

print(f"Active learning reaches {accs_active[-1]:.3f} accuracy")
print(f"Random sampling reaches {accs_random[-1]:.3f} accuracy")
print(f"Active learning saves ~{int((accs_random.tolist().index(min(accs_random,
```

कोल्ड स्टार्ट समस्या

सक्रिय अधिगम के लिए बिना लेबल के बिंदुओं को स्कोर करने के लिए एक प्रशिक्षित मॉडल की आवश्यकता होती है — लेकिन शुरुआत में आपके पास कोई (या बहुत कम) लेबल किए गए उदाहरण नहीं होते। यही **कोल्ड स्टार्ट समस्या** है।

व्यावहारिक समाधान:

1. **यादृच्छिक आरंभिकरण:** सक्रिय अधिगम शुरू करने से पहले एक छोटा यादृच्छिक सीड सेट (20–100 उदाहरण) लेबल करें।
2. **क्लस्टरिंग-आधारित आरंभिकरण:** बिना लेबल के पूल पर k-means उपयोग करें; प्रत्येक क्लस्टर से एक उदाहरण लेबल करें।
3. **एम्बेडिंग-आधारित चयन:** उदाहरणों को एम्बेड करने के लिए एक पूर्व-प्रशिक्षित एनकोडर का उपयोग करें; कोर-सेट के माध्यम से एक विविध उपसमुच्चय चुनें।

बैच-मोड सक्रिय अधिगम

व्यवहार में, अनुलेखक बैच में काम करते हैं — प्रत्येक एकल लेबल के बाद एक नया मॉडल प्रशिक्षित और परिनियोजित करना अक्षम है। **बैच-मोड सक्रिय अधिगम** एक साथ लेबल करने के लिए b उदाहरणों का एक सेट चुनता है।

निर्धारक बिंदु प्रक्रियाएँ (DPPs) विविध बैच नमूने के लिए एक सिद्धांतसम्मत तरीका प्रदान करती हैं।

रुकने के मानदंड

सक्रिय अधिगम कब रोकना चाहिए? सामान्य मानदंड:

- **बजट समाप्त:** सबसे सरल — जब अनुलेखन बजट समाप्त हो जाए तो रोकें।
- **प्रदर्शन पठार:** जब एक होल्ड-आउट सत्यापन सेट पर मॉडल सटीकता k लगातार राउंड के लिए δ से अधिक नहीं सुधरी हो।
- **विश्वास सीमा:** जब बिना लेबल के उदाहरणों का एक निश्चित अंश से कम एक सीमा से ऊपर अनिश्चितता हो।
- **अधिकतम हानि कमी:** अतिरिक्त लेबल से अधिकतम संभव लाभ का अनुमान लगाएँ; जब यह एक सीमा से नीचे गिरे तो रोकें {cite}`bloodgood2009method`।

सक्रिय अधिगम कब काम करता है (और कब नहीं)

सक्रिय अधिगम अच्छा काम करता है जब: - लेबलिंग महंगी है और बिना लेबल का पूल बड़ा है - डेटा में स्पष्ट संरचना है जिसका मॉडल सूचनाप्रद उदाहरणों की पहचान करने के लिए उपयोग कर सकता है - मॉडल वर्ग कार्य के लिए उपयुक्त है

सक्रिय अधिगम खराब प्रदर्शन करता है जब: - प्रारंभिक मॉडल बहुत खराब है (कोल्ड स्टार्ट) और उदाहरणों को सार्थक रूप से रैंक नहीं कर सकता - क्वेरी रणनीति आउटलायर या गलत-लेबल किए गए उदाहरण चुनती है - बिना लेबल के पूल और परीक्षण वितरण के बीच डेटा वितरण बदलता है

> **See also:** मूलभूत सर्वेक्षण {cite}`settles2009active` है। सैद्धांतिक आधार (लेबल जटिलता, अज्ञेयवादी सीमाएँ): {cite}`balcan2006agnostic`। गहन अधिगम-विशिष्ट सक्रिय अधिगम के लिए, {cite}`ash2020deep` (BADGE) और {cite}`sener2018active` (कोर-सेट) देखें। जब सक्रिय अधिगम वास्तव में मदद करता है तो एक महत्वपूर्ण मूल्यांकन के लिए, {cite}`lowell2019practical` देखें। गहन मॉडलों के लिए आलेटोरिक बनाम एपिस्टेमिक अनिश्चितता पर, {cite}`kendall2017uncertainties` देखें; अनिश्चितता अनुमानकों के रूप में गहन पहनावा के लिए, {cite}`lakshminarayanan2017simple` देखें; MC Dropout के लिए, {cite}`gal2016dropout` देखें।

इंटरैक्टिव मशीन लर्निंग

सक्रिय अधिगम एक केंद्रित प्रश्न पूछता है: एक बजट को देखते हुए, मुझे कौन से उदाहरण लेबल करने चाहिए? इंटरैक्टिव मशीन लर्निंग (IML) एक व्यापक प्रश्न पूछता है: हम एक मानव और एक अधिगम प्रणाली के बीच संपूर्ण अंतःक्रिया को अधिकतम उत्पादक, आनंददायक और सही कैसे बना सकते हैं?

IML को मानव–मॉडल प्रतिक्रिया लूप की **तात्कालिकता** और **प्रत्यक्षता** द्वारा प्रतिष्ठित किया जाता है। जहाँ पारंपरिक ML में एक मानव डेटा सौंपता है और प्रशिक्षण पूरा होने का इंतज़ार करता है, IML मनुष्यों को मॉडल व्यवहार का अवलोकन करने, प्रतिक्रिया प्रदान करने, और मॉडल को प्रतिक्रिया देते देखने — अक्सर सेकंडों के भीतर — सक्षम बनाता है।

इंटरैक्टिव मशीन लर्निंग के सिद्धांत

Amershi et al. {cite}`amershi2014power` IML की तीन परिभाषित विशेषताएँ पहचानते हैं:

1. त्वरित प्रतिक्रिया: मॉडल इतनी जल्दी अपडेट होता है कि मनुष्य अपनी प्रतिक्रिया का प्रभाव अनुभव कर सकें। सीमा में, मॉडल अपडेट वास्तविक समय में होते हैं।

2. प्रत्यक्ष हेरफेर: मानव डेटा या मॉडल की भविष्यवाणियों के माध्यम से मॉडल के साथ अंतःक्रिया करता है — कॉन्फ़िगरेशन फ़ाइलों या हाइपरपैरामीटर ट्यूनिंग के माध्यम से नहीं।

3. पुनरावृत्त परिशोधन: प्रक्रिया वास्तव में पुनरावृत्त है: मानव की अगली क्रिया मॉडल के वर्तमान व्यवहार द्वारा सूचित होती है, जिसे मानव की पिछली क्रियाओं ने आकार दिया था।

यह एक तंग **सह-अनुकूली लूप** बनाता है: मानव और मॉडल दोनों एक-दूसरे की प्रतिक्रिया में समय के साथ बदलते हैं।

सक्रिय अधिगम से तुलना

IML और सक्रिय अधिगम काफी हद तक ओवरलैप करते हैं लेकिन समान नहीं हैं:

गुण	सक्रिय अधिगम	इंटरैक्टिव ML
प्राथमिक प्रश्न	क्या लेबल करें?	कैसे अंतःक्रिया करें?
प्रतिक्रिया विलंबता	बैच हो सकती है (दिन)	आमतौर पर वास्तविक समय या निकट
मॉडल अपडेट आवृत्ति	प्रति राउंड (बैच)	प्रति अंतःक्रिया (ऑनलाइन)
मानव एजेंसी	मॉडल के प्रश्नों का उत्तर	मॉडल को सक्रिय रूप से सिखा सकता है
इंटरफ़ेस डिज़ाइन	द्वितीयक चिंता	केंद्रीय चिंता
मानव का संज्ञानात्मक भार	स्पष्ट रूप से मॉडल नहीं	स्पष्ट रूप से विचारित

मिश्रित-पहल अंतःक्रिया

मिश्रित-पहल प्रणालियाँ मानव और मशीन दोनों को अलग-अलग क्षणों में नेतृत्व करने की अनुमति देती हैं {cite}`allen1999mixed`। एक विशुद्ध मशीन-निर्देशित प्रणाली प्रश्न पूछती है और मानव उत्तर देता है। एक विशुद्ध मानव-निर्देशित प्रणाली मानव को सब कुछ तय करने देती है। मिश्रित-पहल प्रणालियाँ दोनों को संतुलित करती हैं।

व्यवहार में, सर्वोत्तम IML प्रणालियाँ जोड़ती हैं: - **मशीन पहल:** "मुझे इन उदाहरणों के बारे में अनिश्चितता है — क्या आप उन्हें लेबल कर सकते हैं?" - **मानव पहल:** "मैं देखता हूँ कि मॉडल इस श्रेणी के बारे में लगातार गलत है — मुझे और उदाहरण प्रदान करने दीजिए" - **पुष्टि:** मॉडल अपनी वर्तमान समझ को सतह पर लाता है; मानव पुष्टि करता है या सुधार करता है

IML में मानव कारक

IML मानव कारकों — संज्ञानात्मक भार, थकान, संगति, और विश्वास — को सीधे अधिगम लूप में लाता है।

अनुलेखन थकान: लंबे सत्रों के साथ मनुष्य तेज़, अधिक लापरवाही से निर्णय लेते हैं। त्रुटियाँ जो प्रशिक्षण डेटा में प्रवेश करती हैं।

एंकरिंग पूर्वाग्रह: मनुष्य मॉडल के वर्तमान सुझावों पर अत्यधिक निर्भर करते हैं। यदि कोई इंटरफ़ेस मॉडल की भविष्यवाणी पूर्व-भरता है, तो अनुलेखक इसे सुधारने की कम संभावना रखते हैं, भले ही यह गलत हो {cite}`geva2019annotator`। पूर्व-अनुलेखन थ्रूपुट को गति दे सकता है {cite}`lingren2014evaluating` जबकि एक साथ उस दर को कम कर सकता है जिस पर अनुलेखक मॉडल त्रुटियों को पकड़ते हैं।

विश्वास गलत अंशांकन: मनुष्य या तो अत्यधिक विश्वास करते हैं (गलत मॉडल आउटपुट स्वीकार करते हैं) या कम विश्वास करते हैं (सही सुझावों की अनदेखी करते हैं)।

IML प्रतिक्रिया प्रकार व्यवहार में

उदाहरण-स्तर प्रतिक्रिया

मानव एक विशिष्ट उदाहरण के लिए लेबल या सुधार प्रदान करता है। यह सबसे सामान्य रूप है और निर्देशित अधिगम के साथ सीधे संगत है।

विशेषता-स्तर प्रतिक्रिया

मानव इंगित करता है कि कौन सी विशेषताएँ प्रासंगिक या अप्रासंगिक हैं। "इस श्रेणी के लिए मॉडल को 'urgent' और 'deadline' शब्दों पर ध्यान देना चाहिए।"

मॉडल-स्तर प्रतिक्रिया

मानव सीधे इनपुट के एक वर्ग पर मॉडल के व्यवहार को सुधारता है: "जब भी इनपुट में [X] हो, आउटपुट [Y] होना चाहिए।"

केस स्टडी: Google Teachable Machine

Teachable Machine एक सुलभ वेब-आधारित IML प्रणाली है जो गैर-तकनीकी उपयोगकर्ताओं को ब्राउज़र में छवि क्लासिफायर प्रशिक्षित करने देती है। उपयोगकर्ता:

1. अपने वेबकैम का उपयोग करके प्रत्येक वर्ग के उदाहरण रिकॉर्ड करता है
2. एकल क्लिक के साथ मॉडल प्रशिक्षित करता है (ब्राउज़र में MobileNet का फाइन-ट्यूनिंग)
3. तत्काल लाइव वीडियो पर मॉडल की भविष्यवाणियाँ देखता है
4. जहाँ मॉडल गलत है वहाँ श्रेणियों के लिए और उदाहरण जोड़ता है

एक सरल IML लूप लागू करना

```
import numpy as np
from sklearn.linear_model import SGDClassifier
from sklearn.preprocessing import StandardScaler
import warnings
warnings.filterwarnings('ignore')

class SimpleIMLSystem:
    """
    Minimal IML system that allows online feedback and displays
    model state after each annotation.
    """

    def __init__(self, n_features=10, n_classes=2):
        self.model = SGDClassifier(loss='log_loss', max_iter=1, warm_start=True,
                                   random_state=42)
        self.scaler = StandardScaler()
        self.X_seen = []
        self.y_seen = []
        self.n_classes = n_classes
        self.initialized = False

    def update(self, x, y_true):
        """Receive a single labeled example and update the model."""
        self.X_seen.append(x)
        self.y_seen.append(y_true)

        if len(self.X_seen) >= 2 * self.n_classes:
            X_arr = np.array(self.X_seen)
            y_arr = np.array(self.y_seen)
            X_scaled = self.scaler.fit_transform(X_arr)
            self.model.partial_fit(X_scaled[-1:], y_arr[-1:],
                                   classes=list(range(self.n_classes)))
            self.initialized = True

        return self

    def predict_with_confidence(self, x):
        """Predict label and return confidence."""
        if not self.initialized:
            return None, 0.0
        x_scaled = self.scaler.transform(x.reshape(1, -1))
        probs = self.model.predict_proba(x_scaled)[0]
```

```
        return self.model.predict(x_scaled)[0], probs.max()

    def current_accuracy(self, X_val, y_val):
        if not self.initialized:
            return None
        X_scaled = self.scaler.transform(X_val)
        return (self.model.predict(X_scaled) == y_val).mean()


# Simulate an IML session
rng = np.random.default_rng(42)
X_all, y_all = np.random.default_rng(0).random((500, 10)), np.random.default_rng
X_val, y_val = X_all[400:], y_all[400:]

system = SimpleIMLSystem(n_features=10, n_classes=2)
accs, confidences = [], []

print("Step | Labels | Accuracy | Example confidence")
print("-" * 50)

for step in range(100):
    x, y = X_all[step], y_all[step]
    pred, conf = system.predict_with_confidence(x)
    system.update(x, y)

    if (step + 1) % 10 == 0:
        acc = system.current_accuracy(X_val, y_val)
        if acc is not None:
            accs.append(acc)
            print(f"  {step+1:3d} |  {step+1:4d}  |  {acc:.3f}   | {conf:.3f}")
```

दादी परीक्षण

IML इंटरफ़ेस डिज़ाइन — और अधिक व्यापक रूप से HITL प्रणाली डिज़ाइन — के मूल्यांकन के लिए एक उपयोगी अनुमानी है जिसे हम **दादी परीक्षण** कहेंगे (यहाँ एक डिज़ाइन बाधा के रूप में पेश एक मूल गढ़त, पूर्व कार्य के संदर्भ के रूप में नहीं):

> 1930 में पैदा हुई एक महिला को इस उपकरण का उपयोग आवाज़ से करने में सक्षम होना चाहिए, और यदि निराश हो तो कीबोर्ड या पाठ इंटरफ़ेस पर सुंदर ढंग से वापस आ जाना चाहिए।

परीक्षण मुख्य रूप से पहुँच के बारे में नहीं है, हालाँकि यह भी है। यह **घर्षण के लिए डिज़ाइन** के बारे में है। यदि किसी प्रणाली को प्रभावी ढंग से उपयोग करने के लिए तंत्रिका नेटवर्क, प्रशिक्षण लूप, या प्रायिकता वितरणों की मानसिक मॉडल की आवश्यकता है, तो यह दादी परीक्षण में विफल हो गई है।

IML डिज़ाइन के लिए निहितार्थ:

वॉयस-फर्स्ट फॉलबैक: प्राथमिक अंतःक्रिया तौर-तरीका प्राकृतिक भाषा या इशारा होना चाहिए — पैरामीटर स्लाइडर या विश्वास सीमाएँ नहीं।

सुंदर अवनमन: जब उपयोगकर्ता का पसंदीदा तौर-तरीका विफल या निराश करे, तो प्रणाली एक विकल्प प्रदान करे — रिक्त स्क्रीन या त्रुटि संदेश नहीं।

सुपाठ्य मॉडल स्थिति: मॉडल की वर्तमान समझ मानवीय शब्दों में दृश्यमान होनी चाहिए। “confidence: 0.73” नहीं बल्कि “मुझे काफी यकीन है कि यह [X] है, लेकिन मैंने इस तरह के उदाहरण दोनों तरफ जाते देखे हैं।”

:::{admonition} डिज़ाइन सिद्धांत :class: tip दादी परीक्षण एक डिज़ाइन बाधा है, लक्ष्य जनसांख्यिकी नहीं। जो प्रणालियाँ इसे पास करती हैं वे उपयोगकर्ता विविधता के प्रति अधिक मज़बूत होती हैं, विशेषज्ञता अंतराल के प्रति अधिक क्षमाशील होती हैं, और मनुष्यों-इन-द-लूप से क्या अपेक्षित है इस बारे में अधिक ईमानदार होती हैं। :::

IML और फाउंडेशन मॉडल

आधुनिक IML तेज़ी से **पूर्व-प्रशिक्षित फाउंडेशन मॉडल** {cite}`bommasani2021opportunities` को आधार के रूप में उपयोग करता है। शुरू से प्रशिक्षण के बजाय, उपयोगकर्ता कम संख्या में इंटरैक्टिव उदाहरणों के साथ एक बड़े पूर्व-प्रशिक्षित मॉडल को फाइन-ट्यून करते हैं। यह उपयोगी प्रदर्शन तक पहुँचने के लिए आवश्यक उदाहरणों की संख्या को नाटकीय रूप से कम कर सकता है {cite}`bommasani2021opportunities`।

इसे सक्षम करने वाली तकनीकें शामिल हैं: - **फ्यू-शॉट प्रॉम्पटिंग:** LLM के संदर्भ विंडो में उदाहरण प्रदान करना - **एडाप्टर फाइन-ट्यूनिंग:** आधार मॉडल को जमाए रखते हुए छोटे एडाप्टर मॉड्यूल को अपडेट करना - **पैरामीटर-कुशल फाइन-ट्यूनिंग (PEFT):** LoRA, प्रीफ़िक्स ट्यूनिंग, और इसी तरह की विधियाँ

> **See also:** {cite}`amershi2014power` द्वारा सर्वेक्षण IML सिद्धांतों का सर्वोत्तम अवलोकन है। मिश्रित-पहल प्रणालियों के लिए, {cite}`allen1999mixed` देखें। अनुलेखन में एंकरिंग प्रभाव के लिए, {cite}`geva2019annotator` और {cite}`lingren2014evaluating` देखें।

मानव प्रतिक्रिया से प्रबलन अधिगम

HITL ML को मुख्यधारा में लाने के लिए किसी तकनीक ने मानव प्रतिक्रिया से प्रबलन अधिगम (RLHF) से अधिक काम नहीं किया है। यह InstructGPT {cite}`ouyang2022training` के पीछे का तंत्र है और कई आधुनिक बड़े भाषा मॉडलों में निर्देश-अनुसरण पाइपलाइनों का एक मुख्य घटक है {cite}`stiennon2020learning`। RLHF को समझना — केवल पालन की जाने वाली एक रेसिपी के रूप में नहीं, बल्कि संरेखण के लिए एक सिद्धांतसम्मत दृष्टिकोण के रूप में — आधुनिक AI में काम करने वाले किसी भी व्यक्ति के लिए आवश्यक है।

संरेखण समस्या

शुद्ध रूप से अगले-टोकन भविष्यवाणी पर प्रशिक्षित बड़े भाषा मॉडल (LLMs) एक प्रॉक्सी उद्देश्य के लिए अनुकूलन करते हैं: मानव-लिखित पाठ के एक कॉर्पस में आगे क्या आता है यह भविष्यवाणी करें। यह उद्देश्य उससे संबंधित है, लेकिन उससे अलग है, जो हम वास्तव में चाहते हैं: प्रतिक्रियाएँ जो सहायक, सटीक, सुरक्षित और मानव मूल्यों के साथ संरेखित हों।

प्रशिक्षण उद्देश्य और वांछित व्यवहार के बीच बेमेल को **संरेखण समस्या** {cite}`russell2019human` कहा जाता है। ठोस रूप से, इंटरनेट पाठ पर प्रशिक्षित एक भाषा मॉडल सीखता है: - प्रशंसनीय-लगने वाली निरंतरताएँ उत्पन्न करना (जो तथ्यात्मक रूप से गलत हो सकती हैं) - प्रशिक्षण डेटा में मौजूद पूर्वाग्रहों और नुकसानों को प्रतिबिंबित करना - जब यह सांख्यिकीय रूप से प्रॉम्प्ट का अनुसरण करता हो तो टाल-मटोल या जोड़-तोड़ करना

RLHF मानव प्राथमिकताओं को अनुकूलन उद्देश्य का हिस्सा बनाकर संरेखण को संबोधित करता है।

RLHF पाइपलाइन

RLHF तीन चरणों में आगे बढ़ता है:

```
□□□ 1: □□□□□□□□□□ □□□□-□□□□□□□□ (SFT)
  --> □□□□□□□□ □□□□ □□□□□ □□□□ (□□□□ □□□□□ □□□□□□□
  --> □□□□□□□□□□ □□ □□□ LLM □□ □□□□-□□□□□ □□□□

□□□ 2: □□□□□□□□ □□□□ □□□□□□□□□
  --> □□□□ □□□□□□□□□□□□□ □□□□□ □□□□ (□□□□ A □□□□ B □□
  --> □□□□ □□□□□□□□□□□□□ □□ □□□□□□ □□□□□ □□ □□□ □□□

□□□ 3: RL □□□□-□□□□□□□□
  --> R(x, y) □□ □□□□□□ □□□□ □□ □□□ PPO/RL □□ □□□□□ □□□□
  --> KL □□□□□□□□ SFT □□□□ □□ □□□□□□□ □□□□□ □□ □□□□□
```

चरण 1: निर्देशित फाइन-ट्यूनिंग

पूर्व-प्रशिक्षित बेस मॉडल π_0 से शुरू करके, हम (प्रॉम्प्ट, आदर्श प्रतिक्रिया) जोड़ियों का डेटासेट एकत्र करते हैं, जो मानव ठेकेदारों द्वारा विस्तृत दिशानिर्देशों का पालन करते हुए लिखे या चुने जाते हैं। मॉडल को मानक cross-entropy का उपयोग करके इन प्रदर्शनों पर फाइन-ट्यून किया जाता है:

$$\mathcal{L}_{\text{SFT}}(\theta) = -\mathbb{E}_{(x,y)\sim\mathcal{D}_{\text{demo}}}\left[\log \pi_\theta(y \mid x)\right]$$

चरण 2: पुरस्कार मॉडल प्रशिक्षण

प्रॉम्प्ट के एक सेट $\{x_i\}$ के लिए, हम π_{SFT} का उपयोग करके प्रति प्रॉम्प्ट K प्रतिक्रियाएँ उत्पन्न करते हैं और उन्हें युगल तुलना के रूप में मानव लेबलर्स को प्रस्तुत करते हैं: "कौन सी प्रतिक्रिया बेहतर है, A या B?"

पुरस्कार मॉडल r_ϕ इन प्राथमिकताओं की भविष्यवाणी करने के लिए प्रशिक्षित है। **Bradley-Terry** मॉडल (अध्याय 8) के तहत, प्रतिक्रिया y_w की y_l से अधिक पसंद किए जाने की प्रायिकता है:

$$P(y_w \succ y_l \mid x) = \sigma\left(r_\phi(x, y_w) - r_\phi(x, y_l)\right)$$

चरण 3: PPO के साथ RL फाइन-ट्यूनिंग

प्रशिक्षित पुरस्कार मॉडल के साथ, हम LLM को फाइन-ट्यून करने के लिए प्रबलन अधिगम का उपयोग कर सकते हैं। अनुकूलन उद्देश्य में एक **KL विचलन जुर्माना** शामिल है {cite}`krakovna2020specification,gao2023scaling`:

$$\max_\theta \mathbb{E}_{x\sim\mathcal{D}, y\sim\pi_\theta(\cdot|x)}\left[r_\phi(x,y) - \beta \cdot \text{KL}\left[\pi_\theta(\cdot \mid x) \| \pi_{\text{SFT}}(\cdot \mid x)\right]\right]$$

Proximal Policy Optimization (PPO) {cite}`schulman2017proximal` इस चरण के लिए मानक एल्गोरिदम है।

एक सरलीकृत RLHF प्रदर्शन

```python
import numpy as np
import torch
import torch.nn as nn
import torch.optim as optim
from torch.nn import functional as F

torch.manual_seed(42)
rng = np.random.default_rng(42)

# ------------------------------------------------
# Toy setup: responses are 4-dimensional vectors
# "Quality" is known analytically (sum of positive values)
# We simulate a reward model learning this from pairwise feedback
# ------------------------------------------------

class RewardModel(nn.Module):
```

```
    def __init__(self, d=4, hidden=32):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(d, hidden), nn.ReLU(),
            nn.Linear(hidden, hidden), nn.ReLU(),
            nn.Linear(hidden, 1)
        )
    def forward(self, x):
        return self.net(x).squeeze(-1)

def true_quality(x):
    """The hidden ground-truth reward function."""
    return x.sum(dim=-1) + 0.5 * (x ** 2).mean(dim=-1)

# Generate pairwise preference data
N_PAIRS = 500
X1 = torch.randn(N_PAIRS, 4)
X2 = torch.randn(N_PAIRS, 4)
q1, q2 = true_quality(X1), true_quality(X2)
# Human prefers X1 when q1 > q2 (with some noise)
noise = torch.randn(N_PAIRS) * 0.5
preferred_1 = ((q1 - q2 + noise) > 0).float()

# Train reward model
rm = RewardModel(d=4, hidden=32)
optimizer = optim.Adam(rm.parameters(), lr=3e-3)

losses = []
for epoch in range(200):
    r1 = rm(X1)
    r2 = rm(X2)
    # Bradley-Terry loss
    logit = r1 - r2
    loss = F.binary_cross_entropy_with_logits(logit, preferred_1)
    optimizer.zero_grad(); loss.backward(); optimizer.step()
    losses.append(loss.item())

# Evaluate: does the reward model agree with true quality?
X_eval = torch.randn(1000, 4)
with torch.no_grad():
    r_pred = rm(X_eval).numpy()
    r_true = true_quality(X_eval).numpy()

corr = np.corrcoef(r_pred, r_true)[0, 1]
print(f"Reward model correlation with true quality: {corr:.4f}")
print(f"Final training loss: {losses[-1]:.4f}")

import matplotlib.pyplot as plt
plt.figure(figsize=(8, 3))
plt.subplot(1, 2, 1)
plt.plot(losses, color='#2b3a8f', linewidth=1.5)
```

```
plt.xlabel("Epoch"); plt.ylabel("Pairwise loss")
plt.title("Reward Model Training")

plt.subplot(1, 2, 2)
plt.scatter(r_true[:200], r_pred[:200], alpha=0.4, s=15, color='#2b3a8f')
plt.xlabel("True quality"); plt.ylabel("Predicted reward")
plt.title(f"Reward Model vs. Truth (r={corr:.3f})")
plt.tight_layout()
plt.savefig('reward_model.png', dpi=150)
plt.show()
```

RLHF में चुनौतियाँ

पुरस्कार हैकिंग

एक प्रमुख विफलता मोड: नीति पुरस्कार मॉडल से उच्च पुरस्कार प्राप्त करने के तरीके खोजती है जो वास्तव में अच्छे व्यवहार के अनुरूप नहीं होते।

शमन रणनीतियाँ: KL जुर्माना, पुनरावृत्त पुरस्कार मॉडल प्रशिक्षण, विविध मूल्यांकन, संवैधानिक AI बाधाएँ।

मूल्यांकक पूर्वाग्रह

मानव लेबलर्स के व्यवस्थित पूर्वाग्रह होते हैं। वे लंबी प्रतिक्रियाएँ (वाचालता पूर्वाग्रह), अधिक आत्मविश्वास से लगने वाला पाठ, और उनकी पूर्व मान्यताओं से सहमत प्रतिक्रियाएँ पसंद करते हैं। RLHF मॉडलों की प्रसिद्ध चापलूसी विफलता — जहाँ मॉडल उपयोगकर्ताओं को वह बताता है जो वे सुनना चाहते हैं — आंशिक रूप से सहमत प्रतिक्रियाओं के लिए मूल्यांकक की प्राथमिकता का परिणाम है।

स्केलेबल निगरानी

जटिल कार्यों के लिए, मनुष्य विश्वसनीय रूप से नहीं बता सकते कि कौन सी AI प्रतिक्रिया सही है। **स्केलेबल निगरानी** {cite}`bowman2022measuring` उन मूल्यांकन प्रक्रियाओं को डिज़ाइन करने की खुली अनुसंधान समस्या है जो कार्य जटिलता बढ़ने के साथ विश्वसनीय रहें।

Constitutional AI (RLAIF)

Constitutional AI {cite}`bai2022constitutional`, Anthropic में विकसित, मानव लेबलर्स पर निर्भरता को कम करने के लिए एक सेट ऑफ सिद्धांतों (एक "constitution") द्वारा निर्देशित AI का उपयोग प्राथमिकता लेबल उत्पन्न करने के लिए करता है। प्रक्रिया:

1. संभावित रूप से हानिकारक प्रॉम्प्ट के लिए प्रतिक्रियाएँ उत्पन्न करें
2. संवैधानिक सिद्धांतों के विरुद्ध प्रतिक्रियाओं का मूल्यांकन करने के लिए AI आलोचक का उपयोग करें
3. AI प्रतिक्रिया द्वारा निर्देशित प्रतिक्रियाओं को संशोधित करें (RLAIF — AI प्रतिक्रिया से RL)
4. AI-जनति प्राथमिकताओं पर पुरस्कार मॉडल प्रशिक्षित करें
5. इस पुरस्कार मॉडल का उपयोग करके RLHF से फाइन-ट्यून करें

See also: मूल InstructGPT शोधपत्र {cite}`ouyang2022training` LLMs पर RLHF के पहले बड़े पैमाने के अनुप्रयोग का वर्णन करता है। गहन RL के लिए मूलभूत RLHF कार्य

{cite}christiano2017deep है। PPO {cite}schulman2017proximal में वर्णित है। Constitutional AI {cite}bai2022constitutional से है।

प्रदर्शन से अधिगम

जब कोई कार्य निर्दिष्ट करना कठिन हो लेकिन प्रदर्शित करना आसान हो, तो नियम से परिभाषित करने की तुलना में उदाहरण से सिखाना अधिक कुशल हो सकता है। एक मानव विशेषज्ञ एक रोबोटिक भुजा को किसी वस्तु को पकड़ना दिखाता है; एक प्रोग्रामर की अपने IDE के साथ अंतःक्रिया सही संपादनों का एक क्रम प्रदान करती है; एक शतरंज ग्रैंडमास्टर एक खेल खेलता है। **प्रदर्शन से अधिगम** ऐसे व्यवहार संबंधी डेटा से एक नीति निकालता है, हस्त-निर्मित पुरस्कार कार्यों या स्पष्ट कार्य विनिर्देशों की आवश्यकता को टालते हुए।

व्यवहार क्लोनिंग

सबसे सरल दृष्टिकोण है **व्यवहार क्लोनिंग (BC)**: प्रदर्शन को निर्देशित डेटा के रूप में मानें और अवस्थाओं से क्रियाओं की मैपिंग सीखें।

एक विशेषज्ञ प्रदर्शनकर्ता से अवस्था-क्रिया जोड़ियों के डेटासेट $\mathcal{D} = \{(s_i, a_i)\}$ को देखते हुए, हम नकारात्मक लॉग-संभावना को न्यूनतम करके एक नीति $\pi_\theta(a \mid s)$ फिट करते हैं:

$$\mathcal{L}_{\text{BC}}(\theta) = -\frac{1}{|\mathcal{D}|} \sum_{(s,a)\in\mathcal{D}} \log \pi_\theta(a \mid s)$$

यह अनुक्रमिक डेटा पर लागू मानक निर्देशित अधिगम है।

सहवेरिएट शिफ्ट समस्या

BC में एक मूलभूत कमज़ोरी है: प्रशिक्षण और परिनियोजन के बीच **वितरण बदलाव**। विशेषज्ञ के प्रदर्शन विशेषज्ञ द्वारा देखी गई अवस्थाओं को कवर करते हैं। लेकिन परिनियोजन के दौरान, सीखी गई नीति थोड़े भिन्न निर्णय ले सकती है, जिससे वह उन अवस्थाओं में पहुँच सकती है जो विशेषज्ञ ने कभी नहीं देखीं — जहाँ नीति के पास कोई पर्यवेक्षण नहीं है और वह बुरी तरह विफल हो सकती है।

त्रुटियाँ **संयोजित होती हैं**: एक छोटा विचलन एक अपरिचित अवस्था की ओर ले जाता है, जहाँ एक थोड़ी गलत क्रिया और भी अपरिचित अवस्था की ओर ले जाती है, और इसी तरह। प्रदर्शन $O(T^2\epsilon)$ के रूप में खराब होता है जहाँ T एपिसोड की लंबाई है और ϵ प्रत्येक चरण पर त्रुटि दर है {cite}`ross2010efficient`।

> **उदाहरण: स्वायत्त ड्राइविंग** :class: note
>
> मानव ड्राइविंग डेटा पर प्रशिक्षित लेन-रखने के लिए एक व्यवहार क्लोनिंग मॉडल सीधी सड़कों पर अच्छा प्रदर्शन करता है। लेकिन जिस क्षण यह थोड़ा भटकता है — एक ऐसी अवस्था जिसमें कोई मानव चालक कभी नहीं होता क्योंकि वे पहले ही सुधार कर लेते — उसके पास मार्गदर्शन के लिए कोई डेटा नहीं है और वह सड़क से बाहर जा सकता है।

```
□ □ □ □ □ □ □ □ □ □  DAgger:
  □ □ □ □  □ □ □ □ : D <- {} (□ □ □ □ □  □ □ □ □ □ □ □ )
```

```
M □□□□□□□□□ □□□□□□□□□□□ □□ □□□□□□□□□□ □□□□ pi_1 □□□

□□□□□□□□□□□ i = 1, 2, ..., N □□ □□□:
  1. □□□□□□□□ □□□□□ □□□□ □□ □□□ pi_i □□ □□□□□□□□ □□
  2. □□□□□□□□ □□□□ □□ □□□□□□ □□ □□□□□□□□ □□ □□□ □
  3. □□□□□□□ □□□□: D <- D u {(s_1, a_1), ..., (s_t, a_t)}
  4. D □□ □□□□□□□□□□ □□□□□ □□□□□□□ pi_{i+1} □□□□□□□□□□
```

DAgger $O(T\epsilon)$ खेद प्राप्त करता है क्योंकि प्रशिक्षण वितरण परिनियोजन वितरण से मेल खाने के लिए अभिसरित होता है।

व्युत्क्रम प्रबलन अधिगम

कभी-कभी विशेषज्ञ का व्यवहार नकल की जाने वाली क्रियाओं की एक श्रृंखला के रूप में नहीं बल्कि एक अज्ञात पुरस्कार फ़ंक्शन को अनुकूलित करने के परिणाम के रूप में बेहतर समझा जाता है। **व्युत्क्रम प्रबलन अधिगम (IRL)** {cite}`ng2000algorithms` प्रदर्शनों से इस अव्यक्त पुरस्कार फ़ंक्शन को पुनर्प्राप्त करता है।

अधिकतम एंट्रॉपी IRL

MaxEnt IRL {cite}`ziebart2008maximum` IRL अस्पष्टता समस्या (प्रदर्शनों के किसी भी सेट के साथ कई पुरस्कार फ़ंक्शन संगत हैं) को उस पुरस्कार फ़ंक्शन को चुनकर हल करता है जो, प्रदर्शित व्यवहार के अनुरूप रहते हुए, अधिकतम एंट्रॉपी वाले प्रक्षेप-पथों के वितरण की ओर ले जाता है:

$$P(\tau \mid R) \propto \exp\left(\sum_t R(s_t, a_t)\right)$$

GAIL: जेनरेटिव एडवर्सेरियल अनुकरण अधिगम

GAIL {cite}`ho2016generative` पुरस्कार फ़ंक्शन सीखने को पूरी तरह से बायपास करता है, विशेषज्ञ की अवस्था-क्रिया वितरण को सीधे मिलाने के लिए एक GAN-जैसे सूत्रीकरण का उपयोग करता है।

एक विभेदक D_ψ विशेषज्ञ अवस्था-क्रिया जोड़ियों $(s, a) \sim \pi^*$ को नीति अवस्था-क्रिया जोड़ियों $(s, a) \sim \pi_\theta$ से अलग करने के लिए प्रशिक्षित है:

$$\mathcal{L}_D = -\mathbb{E}_{\pi^*}[\log D_\psi(s, a)] - \mathbb{E}_{\pi_\theta}[\log(1 - D_\psi(s, a))]$$

NLP में व्यवहार क्लोनिंग: एक व्यावहारिक उदाहरण

```python
import numpy as np
import torch
import torch.nn as nn
from torch.utils.data import DataLoader, TensorDataset
```

```
torch.manual_seed(42)

# ----------------------------------------------
# Toy NLP task: rewriting sentences to be more formal
# We simulate this as a simple sequence transformation
# In practice: fine-tuning a seq2seq model on expert rewrites
# ----------------------------------------------

class SimpleSeq2Seq(nn.Module):
    def __init__(self, vocab_size=100, embed_dim=32, hidden_dim=64):
        super().__init__()
        self.embed = nn.Embedding(vocab_size, embed_dim, padding_idx=0)
        self.encoder = nn.GRU(embed_dim, hidden_dim, batch_first=True)
        self.decoder = nn.GRU(embed_dim, hidden_dim, batch_first=True)
        self.proj = nn.Linear(hidden_dim, vocab_size)
        self.hidden_dim = hidden_dim

    def forward(self, src, tgt):
        src_emb = self.embed(src)
        _, hidden = self.encoder(src_emb)
        tgt_emb = self.embed(tgt)
        out, _ = self.decoder(tgt_emb, hidden)
        return self.proj(out)

# Generate synthetic demonstration data
VOCAB = 100
rng = np.random.default_rng(42)
N, SEQ_LEN = 1000, 12

src_seqs = torch.tensor(rng.integers(1, VOCAB, (N, SEQ_LEN)), dtype=torch.long)
# "Expert" transformation: shift tokens by 1 (toy formalization)
tgt_seqs = torch.clamp(src_seqs + 1, 1, VOCAB - 1)
tgt_in  = torch.cat([torch.ones(N, 1, dtype=torch.long), tgt_seqs[:, :-1]], dim=

dataset = TensorDataset(src_seqs, tgt_in, tgt_seqs)
loader = DataLoader(dataset, batch_size=64, shuffle=True)

model = SimpleSeq2Seq(vocab_size=VOCAB)
optimizer = torch.optim.Adam(model.parameters(), lr=1e-3)
criterion = nn.CrossEntropyLoss(ignore_index=0)

# Behavioral cloning training
train_losses = []
for epoch in range(20):
    epoch_loss = 0
    for src, tgt_i, tgt_o in loader:
        logits = model(src, tgt_i)
        loss = criterion(logits.reshape(-1, VOCAB), tgt_o.reshape(-1))
        optimizer.zero_grad(); loss.backward(); optimizer.step()
        epoch_loss += loss.item()
    train_losses.append(epoch_loss / len(loader))
```

```
print(f"Initial loss: {train_losses[0]:.3f}")
print(f"Final loss:   {train_losses[-1]:.3f}")

# Evaluate: check token accuracy on held-out examples
model.eval()
with torch.no_grad():
    src_test = src_seqs[-100:]
    tgt_test_in = tgt_in[-100:]
    tgt_test_out = tgt_seqs[-100:]
    logits = model(src_test, tgt_test_in)
    preds = logits.argmax(dim=-1)
    acc = (preds == tgt_test_out).float().mean().item()
    print(f"Token accuracy on held-out set: {acc:.3f}")
```

अनुकरण अधिगम विधियों की तुलना

विधि	पुरस्कार चाहिए?	विशेषज्ञ ऑनलाइन क्वेरी?	नई गतिशीलता में सामान्यीकरण?	जटिलता
व्यवहार क्लोनिंग	नहीं	नहीं	खराब (वितरण बदलाव)	कम
DAgger	नहीं	हाँ	मध्यम	मध्यम
MaxEnt IRL	इसे पुनर्प्राप्त करता है	नहीं	अच्छा	उच्च
GAIL	नहीं	नहीं	अच्छा	उच्च

अनुप्रयोग

रोबोटिक्स। रोबोट को वस्तुओं को संभालना, पर्यावरण में नेविगेट करना, या घरेलू कार्य करना सिखाना।

स्वायत्त ड्राइविंग। ALVINN {cite}`pomerleau1989alvinn` और NVIDIA के DAVE जैसे प्रारंभिक स्व-चालित प्रणालियाँ मानव ड्राइविंग डेटा से व्यवहार क्लोनिंग पर बहुत अधिक निर्भर थीं।

गेम AI। RL फाइन-ट्यूनिंग से पहले मानव गेमप्ले पर अनुकरण अधिगम एजेंटों को बूटस्ट्रैप करता है।

कोड जनरेशन। उच्च-गुणवत्ता कोड प्रदर्शनों (GitHub Copilot, Codex) पर भाषा मॉडल फाइन-ट्यूनिंग व्यवहार क्लोनिंग का एक रूप है।

नैदानिक निर्णय समर्थन। जटिल प्रोटोकॉल के लिए विशेषज्ञ चिकित्सक निर्णय अनुक्रमों से अधिगम।

> **See also:** मूलभूत BC/DAgger विश्लेषण {cite}`ross2011reduction` में है। MaxEnt IRL {cite}`ziebart2008maximum` से है। GAIL {cite}`ho2016generative` से है। अनुकरण अधिगम के व्यापक सर्वेक्षण के लिए, {cite}`osa2018algorithmic` देखें।

तुलना एवं क्रम-निर्धारण से अधिगम

मनुष्यों को किसी आउटपुट को एक पूर्ण गुणवत्ता स्कोर असाइन करने के लिए कहना कठिन है। इस निबंध की 1 से 10 के पैमाने पर संख्यात्मक गुणवत्ता क्या है? प्रश्न ही गलत है: मनुष्यों के पास एक स्थिर आंतरिक पैमाना नहीं है, और उनके स्कोर एंकरिंग, संदर्भ, और थकान से बहुत प्रभावित होते हैं।

मनुष्यों को दो आउटपुट की तुलना करने के लिए कहना बहुत आसान है: कौन सा निबंध बेहतर है, A या B? तुलनात्मक निर्णय अधिक सुसंगत, अधिक विश्वसनीय हैं, और पूर्ण रेटिंग की तुलना में मानव प्राथमिकताओं में अधिक सीधे टैप करते हैं। यह अध्याय तुलना और रैंकिंग से अधिगम के गणितीय आधार और व्यावहारिक अनुप्रयोगों को शामिल करता है।

रेटिंग की तुलना में तुलनाएँ बेहतर क्यों हैं

मनोवैज्ञानिक आधार

तुलनात्मक निर्णयों की श्रेष्ठता का मनोमिति में एक लंबा इतिहास है। Thurstone का तुलनात्मक निर्णय का नियम {cite}`thurstone1927law` (1927) ने दर्शाया कि भले ही मनुष्यों के पूर्ण निर्णय असंगत हों, उनके सापेक्ष निर्णय एक सुसंगत प्रायिकता नियम का पालन करते हैं।

सांख्यिकीय दक्षता

K आइटम के साथ, $K - 1$ तुलनाएँ सभी आइटम को रैंक कर सकती हैं; शीर्ष आइटम खोजने के लिए केवल $O(\log K)$ तुलनाओं की आवश्यकता है।

स्केलेबिलिटी

जेनरेटिव मॉडलों के लिए, विशिष्ट आउटपुट की संख्या प्रभावी रूप से अनंत है। तुलना आउटपुट के लिए केवल स्थानीय, सापेक्ष निर्णयों की आवश्यकता है।

Bradley-Terry मॉडल

युगल तुलनाओं के लिए प्रमुख प्रायिकता मॉडल **Bradley-Terry (BT) मॉडल** {cite}`bradley1952rank` है। प्रत्येक आइटम i में एक अव्यक्त गुणवत्ता स्कोर $\alpha_i \in \mathbb{R}$ है। एक सीधी तुलना में आइटम i के आइटम j से अधिक पसंद किए जाने की प्रायिकता है:

$$P(i \succ j) = \frac{e^{\alpha_i}}{e^{\alpha_i} + e^{\alpha_j}} = \sigma(\alpha_i - \alpha_j)$$

पैरामीटर अनुमान

युगल तुलनाओं के डेटासेट $\mathcal{D} = \{(i, j, y_{ij})\}$ को देखते हुए जहाँ $y_{ij} = 1$ यदि i को j से अधिक पसंद किया गया, लॉग-संभावना है:

$$\mathcal{L}(\alpha) = \sum_{(i,j,y_{ij})\in\mathcal{D}} \left[y_{ij} \log \sigma(\alpha_i - \alpha_j) + (1 - y_{ij}) \log \sigma(\alpha_j - \alpha_i)\right]$$

```python
import numpy as np
from scipy.optimize import minimize
from scipy.special import expit  # sigmoid

rng = np.random.default_rng(42)

# ------------------------------------------------
# Simulate Bradley-Terry: 8 items with true quality scores
# Generate pairwise comparisons and recover the scores
# ------------------------------------------------

N_ITEMS = 8
true_alpha = rng.normal(0, 1, N_ITEMS)
print(f"True quality ranking: {np.argsort(true_alpha)[::-1]}")

# Generate comparisons: every pair compared 5 times
comparisons = []
for i in range(N_ITEMS):
    for j in range(i + 1, N_ITEMS):
        for _ in range(5):
            p_i_wins = expit(true_alpha[i] - true_alpha[j])
            winner = i if rng.random() < p_i_wins else j
            loser  = j if winner == i else i
            comparisons.append((winner, loser))

print(f"Total comparisons: {len(comparisons)}")

def neg_log_likelihood(alpha, comparisons):
    """Bradley-Terry negative log-likelihood."""
    alpha = np.array(alpha)
    loss = 0.0
    for winner, loser in comparisons:
        log_prob = np.log(expit(alpha[winner] - alpha[loser]) + 1e-10)
        loss -= log_prob
    return loss

def neg_grad(alpha, comparisons):
    alpha = np.array(alpha)
    grad = np.zeros(len(alpha))
    for winner, loser in comparisons:
        p = expit(alpha[winner] - alpha[loser])
        grad[winner] -= (1 - p)
        grad[loser]  -= (-p)
```

```
    return grad

# Fix alpha[0] = 0 to resolve scale ambiguity
result = minimize(
    lambda a: neg_log_likelihood(np.concatenate([[0.0], a]), comparisons),
    x0=np.zeros(N_ITEMS - 1),
    jac=lambda a: neg_grad(np.concatenate([[0.0], a]), comparisons)[1:],
    method='L-BFGS-B'
)
est_alpha = np.concatenate([[0.0], result.x])

# Compare true vs estimated ranking
true_rank = np.argsort(true_alpha)[::-1]
est_rank  = np.argsort(est_alpha)[::-1]

print(f"\nTrue ranking (item indices): {true_rank}")
print(f"Estimated ranking:           {est_rank}")
rank_corr = np.corrcoef(true_alpha, est_alpha)[0, 1]
print(f"Correlation with true scores: {rank_corr:.4f}")
```

Thurstone का मॉडल

Thurstone का मॉडल {cite}`thurstone1927law` Bradley-Terry से निकटता से संबंधित है लेकिन logistic के बजाय Gaussian शोर का उपयोग करता है:

$$P(i \succ j) = \Phi\left(\frac{\alpha_i - \alpha_j}{\sqrt{2}\sigma}\right)$$

जहाँ Φ मानक सामान्य CDF है। व्यवहार में, दोनों मॉडल लगभग समान परिणाम देते हैं।

रैंक एकत्रीकरण

Borda count: प्रत्येक आइटम को प्रत्येक अनुलेखक की रैंकिंग में उससे नीचे रैंक किए गए आइटम की संख्या के बराबर स्कोर मिलता है।

Kemeny–Young: वह रैंकिंग खोजें जो प्रत्येक अनुलेखक की रैंकिंग (Kendall tau दूरी) के साथ युगल असहमतियों के योग को न्यूनतम करती है।

द्वंद्वयुद्ध बैंडिट्स

ऑनलाइन वरीयता अधिगम में, आइटम एक धारा में आते हैं और हमें यह तय करना है कि किन जोड़ियों की तुलना करनी है। यह **द्वंद्वयुद्ध बैंडिट** समस्या है {cite}`yue2009interactively`।

भाषा मॉडलों के लिए वरीयता अधिगम

RLHF (अध्याय 6) के संदर्भ में, Bradley-Terry मॉडल का उपयोग पुरस्कार मॉडल प्रशिक्षित करने के लिए किया जाता है। एक महत्त्वपूर्ण प्रकार है **Direct Preference Optimization (DPO)** {cite}`rafailov2023direct`, जो दर्शाता है कि RLHF उद्देश्य को एक अलग पुरस्कार मॉडल प्रशिक्षित किए बिना सीधे वरीयता डेटा से अनुकूलित किया जा सकता है:

$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{(x,y_w,y_l)\sim\mathcal{D}}\left[\log\sigma\left(\beta\log\frac{\pi_\theta(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta\log\frac{\pi_\theta(y_l \mid x)}{\pi_{\text{ref}}(y_l \mid x)}\right)\right]$$

DPO पूर्ण RLHF की तुलना में सरल है (कोई PPO प्रशिक्षण लूप नहीं, कोई पुरस्कार मॉडल नहीं) {cite}`rafailov2023direct`।

उच्च-गुणवत्ता वरीयता डेटा एकत्र करना

प्रॉम्प्ट विविधता। वरीयता डेटा परिनियोजन में मॉडल के सामने आने वाले प्रॉम्प्ट के पूर्ण वितरण को कवर करना चाहिए।

प्रतिक्रिया विविधता। दो बहुत समान प्रतिक्रियाओं की तुलना बहुत कम जानकारी प्रदान करती है।

अनुलेखक सहमति। कम अंतर-अनुलेखक सहमति यह सुझाती है कि तुलना मानदंड अस्पष्ट हैं। Cohen's ⊠ मापें और जब यह स्वीकार्य सीमा से नीचे हो तो दिशानिर्देशों को संशोधित करें।

अंशांकन। अनुलेखकों को समझना चाहिए कि एक प्रतिक्रिया बेहतर क्यों है: सहायकता, सटीकता, सुरक्षा, शैली?

> **See also:** Bradley-Terry मॉडल: {cite}`bradley1952rank`। Thurstone: {cite}`thurstone1927law`। द्वंद्वयुद्ध बैंडिट्स: {cite}`yue2009interactively`। Direct Preference Optimization (DPO): {cite}`rafailov2023direct`।

प्राकृतिक भाषा संसाधन में HITL

प्राकृतिक भाषा वह डोमेन है जहाँ HITL ML का शायद सबसे बड़ा प्रभाव पड़ा है — और जहाँ इसकी सबसे गहरी वैचारिक कठिनाइयाँ सामने आती हैं। भाषा स्वाभाविक रूप से सामाजिक है: इसका अर्थ मानव समुदायों द्वारा निर्मित होता है, इसकी व्यावहारिकता संदर्भ और इरादे पर निर्भर करती है, और इसकी गुणवत्ता का निर्णय केवल मानव पाठकों द्वारा ही किया जा सकता है। लेकिन इसका यह भी अर्थ है कि NLP अनुलेखन केवल अवलोकन एकत्र करने की प्रक्रिया नहीं है। यह श्रेणियाँ निर्मित करने की प्रक्रिया है।

NLP अनुलेखन में संविधात्मक समस्या

चिकित्सा इमेजिंग में एक वास्तविक सत्य होता है: एक ट्यूमर मौजूद है या नहीं है। NLP अनुलेखन अक्सर मूलतः अलग होता है। जब एक अनुलेखक एक ट्वीट को "विषाक्त" के रूप में चिह्नित करता है, तो ट्वीट में कोई विषाक्त-अणु नहीं है जिसे हम पहचानने की कोशिश कर रहे हैं। **लेबल श्रेणी का निर्माण करता है।**

इसके गहरे परिणाम हैं जो अक्सर कम समझे जाते हैं:

अनुलेखन कार्यबल घटना को परिभाषित करता है। "आपत्तिजनक भाषण" के लिए एक लेबल योजना उस व्यक्ति की संवेदनशीलताओं को कूटबद्ध करती है जिसने इसे डिज़ाइन किया और जिसने इसे लागू किया।

दिशानिर्देश सिद्धांत हैं, चाहे वे इसे स्वीकार करें या नहीं। प्रत्येक अनुलेखन योजना ओन्टोलॉजी के बारे में दावे करती है।

समय के साथ लेबल अस्थिरता। सामाजिक भाषा विकसित होती है।

:::{admonition} अनुलेखन कलाकृति समस्या :class: important

Geva et al. {cite}`geva2019annotator` ने प्रदर्शित किया कि NLI (प्राकृतिक भाषा अनुमान) डेटासेट में अनुलेखन प्रक्रिया द्वारा ही पेश की गई व्यवस्थित कलाकृतियाँ होती हैं। मॉडल अंतर्निहित NLP कार्य को हल करने के बजाय इन कलाकृतियों के आधार पर वर्गीकरण करना सीखते हैं — वे अनुलेखन कार्य को हल करते हैं। :::

पाठ वर्गीकरण अनुलेखन

सबसे सरल NLP अनुलेखन कार्य किसी पाठ दस्तावेज़ को एक श्रेणी असाइन करना है।

पाठ वर्गीकरण के लिए विशिष्ट चुनौतियाँ:

व्यक्तिपरकता। "विषाक्त" या "आपत्तिजनक" जैसी श्रेणियाँ स्वाभाविक रूप से व्यक्तिपरक हैं और सांस्कृतिक संदर्भों में भिन्न होती हैं {cite}`blodgett2020language`।

लेबल अस्पष्टता। कई दस्तावेज़ एकाधिक श्रेणियों से संबंधित हैं या सीमा पर आते हैं।

लेबल विस्तार। 2-वर्ग भावना मॉडल सोशल मीडिया निगरानी के लिए पर्याप्त हो सकता है; उत्पाद फ़ीडबैक विश्लेषण के लिए 7-बिंदु पैमाने की आवश्यकता हो सकती है।

नाम इकाई पहचान

NER अनुलेखन पाठ के हिस्सों की पहचान करने और एक इकाई प्रकार (PERSON, ORGANIZATION, LOCATION, आदि) असाइन करने की आवश्यकता है।

स्पैन सीमाएँ अस्पष्ट होती हैं। "Apple CEO Tim Cook announced..." में, PERSON इकाई "Tim Cook" या "Apple CEO Tim Cook" को स्पैन करती है?

विश्व-ज्ञान की आवश्यकता। "Apple" एक संदर्भ में ORG है, दूसरे में PRODUCT, और "apple pie" में न तो।

अनुलेखन दक्षता। एक बेसलाइन NER मॉडल के साथ पूर्व-अनुलेखन अनुलेखन को काफी तेज़ करता है। नैदानिक NER के एक अध्ययन में, 30-60% की थ्रूपुट वृद्धि देखी गई {cite}`lingren2014evaluating`।

मशीन अनुवाद पोस्ट-एडिटिंग (MTPE)

मशीन अनुवाद पोस्ट-एडिटिंग HITL NLP का एक परिपक्व रूप है। एक मानव अनुवादक स्क्रैच से अनुवाद करने के बजाय MT प्रणाली के आउटपुट को सुधारता है:

लाइट पोस्ट-एडिटिंग (LPE): केवल महत्वपूर्ण त्रुटियाँ सुधारी जाती हैं।

पूर्ण पोस्ट-एडिटिंग (FPE): आउटपुट को प्रकाशन गुणवत्ता तक सुधारा जाता है। संपादित आउटपुट आमतौर पर आगे MT सुधार के लिए प्रशिक्षण डेटा बन जाता है।

HTER (Human-targeted Translation Edit Rate): वाक्य लंबाई से सामान्यीकृत MT आउटपुट और पोस्ट-एडिट अनुवाद के बीच संपादन दूरी को मापता है {cite}`graham2015accurate`।

प्रोग्रामेटिक लेबलिंग और कमज़ोर पर्यवेक्षण

जब लेबल किया गया डेटा दुर्लभ हो, **कमज़ोर पर्यवेक्षण** बड़े पैमाने पर प्रायिकता लेबल उत्पन्न करने के लिए एकाधिक शोरगुल वाले, ओवरलैपिंग लेबलिंग फ़ंक्शन का उपयोग करने की अनुमति देता है। **Snorkel** {cite}`ratner2017snorkel` कैनॉनिकल फ्रेमवर्क है:

```
import numpy as np
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import f1_score

rng = np.random.default_rng(42)

# ---------------------------------------------------------
# Toy weak supervision: sentiment classification
# 5 labeling functions (LFs) with different coverage/accuracy
# Label: +1 (positive), -1 (negative), 0 (abstain)
# ---------------------------------------------------------

N = 1000
true_labels = rng.choice([-1, 1], size=N)
X_features = np.column_stack([
```

```
    true_labels * 0.8 + rng.normal(0, 0.5, N),
    rng.normal(0, 1, N),
    rng.normal(0, 1, N),
])

def make_lf(accuracy, coverage, seed):
    rng_lf = np.random.default_rng(seed)
    votes = np.zeros(N, dtype=int)
    active = rng_lf.random(N) < coverage
    correct = rng_lf.random(N) < accuracy
    votes[active & correct]  = true_labels[active & correct]
    votes[active & ~correct] = -true_labels[active & ~correct]
    return votes

LFs = np.column_stack([
    make_lf(accuracy=0.85, coverage=0.60, seed=1),
    make_lf(accuracy=0.78, coverage=0.45, seed=2),
    make_lf(accuracy=0.70, coverage=0.80, seed=3),
    make_lf(accuracy=0.90, coverage=0.30, seed=4),
    make_lf(accuracy=0.60, coverage=0.90, seed=5),
])

def majority_vote(LF_matrix):
    labels = []
    for i in range(LF_matrix.shape[0]):
        votes = LF_matrix[i][LF_matrix[i] != 0]
        labels.append(0 if len(votes) == 0 else int(np.sign(votes.sum())))
    return np.array(labels)

mv_labels = majority_vote(LFs)
covered = mv_labels != 0

print(f"Coverage:                    {covered.mean():.1%}")
print(f"MV accuracy (covered):       {(mv_labels[covered] == true_labels[covered

X_train, y_train = X_features[covered], mv_labels[covered]
X_test,  y_test  = X_features[~covered], true_labels[~covered]

if len(X_train) > 10 and len(X_test) > 10:
    clf = LogisticRegression().fit(X_train, y_train)
    preds = clf.predict(X_test)
    print(f"F1 on uncovered test set:    {f1_score(y_test, preds):.3f}")
```

भाषा मॉडलों के लिए RLHF: अनुलेखन वास्तविकता

अनुलेखकों से वास्तव में क्या करने के लिए कहा जाता है — दो मॉडल आउटपुट की तुलना करना और इंगित करना कि कौन सा "बेहतर" है — सरल लगता है। व्यवहार में, "बेहतर" एक अनिर्दिष्ट निर्माण है जिसे अनुलेखक व्यक्तिगत अनुमानी का उपयोग करके हल करते हैं।

मुख्य अनुलेखन आयाम हैं:

- सहायकता: क्या प्रतिक्रिया प्रश्न का अच्छी तरह उत्तर देती है?
- तथ्यात्मकता: क्या प्रतिक्रिया तथ्यात्मक रूप से सटीक है?
- हानिरहितता: क्या प्रतिक्रिया विषाक्त, पक्षपाती, हानिकारक सामग्री से बचती है?
- अंशांकन: क्या प्रतिक्रिया उचित अनिश्चितता व्यक्त करती है?

पैमाने पर जनसांख्यिकीय प्रभाव को केंद्रित करता है। बड़े मॉडलों के लिए RLHF में अपेक्षाकृत छोटे अनुलेखन कार्यबल (सैकड़ों से कम हज़ारों) शामिल हैं जो अरबों डाउनस्ट्रीम निर्णय लेते हैं।

जेनरेटिव NLP मॉडलों का मूल्यांकन

मूल्यांकन विधि	विवरण	लागत
प्रत्यक्ष मूल्यांकन (DA)	अनुलेखक पैमाने पर गुणवत्ता रेट करते हैं	मध्यम
तुलनात्मक निर्णय	अनुलेखक दो आउटपुट की तुलना करते हैं	कम
MQM (बहुआयामी गुणवत्ता मेट्रिक्स)	संरचित त्रुटि वर्गीकरण	उच्च
RLHF प्राथमिकता	प्रशिक्षण के लिए उपयोग किए गए प्राथमिकता लेबल	मध्यम
LLM-as-judge	LLM स्कोर आउटपुट (मानव के साथ मध्यम सहसंबंध)	बहुत कम
BERTScore, BLEU	स्वचालित मेट्रिक्स (मानव निर्णय के साथ अपूर्ण सहसंबंध)	बहुत कम

See also: Snorkel कमज़ोर पर्यवेक्षण: {cite}`ratner2017snorkel`। NLP अनुलेखन दिशानिर्देश: {cite}`pustejovsky2012natural`। NLI में अनुलेखन कलाकृतियाँ: {cite}`geva2019annotator`। अनुलेखक पूर्वाग्रह और NLP डेटासेट: {cite}`blodgett2020language`। जेनरेटिव मॉडलों के मूल्यांकन के लिए: {cite}`reiter2018structured`।

कंप्यूटर दृष्टि में HITL

कंप्यूटर दृष्टि HITL ML के कुछ सबसे दृश्यात्मक रूप से सहज उदाहरण प्रदान करती है। 14 मिलियन मानव-लेबल किए गए चित्रों पर निर्मित ImageNet चुनौती ने डीप लर्निंग युग की शुरुआत की। रेडियोलॉजिस्टों द्वारा चिकित्सा इमेजिंग अनुलेखन नैदानिक AI को शक्ति देता है। स्वायत्त वाहन दुनिया को देखना सीखने के लिए लाखों मानव-लेबल किए गए फ्रेम पर निर्भर करते हैं।

जो आसानी से छूट जाता है: ये केवल मनुष्यों के ग्राउंड ट्रुथ प्रदान करने के मामले नहीं हैं। ये मनुष्यों द्वारा विशिष्ट अवधारणात्मक, सांस्कृतिक और परिचालन विकल्पों को शामिल करने वाले डेटासेट निर्मित करने के मामले हैं — ऐसे विकल्प जो बाद में दृश्यमान होते हैं, जब मॉडल पूर्वानुमानित तरीकों से विफल होते हैं।

अनुलेखन विकल्प कैसे मॉडल पूर्वाग्रह बनते हैं

मानक फ्रेमिंग अनुलेखन को डेटा संग्रह के रूप में मानती है। अधिक सटीक फ्रेमिंग है कि अनुलेखन डेटासेट डिज़ाइन है।

ImageNet मामला

ImageNet {cite}`russakovsky2015imagenet` कंप्यूटर दृष्टि इतिहास में सबसे परिणामपूर्ण डेटासेट है। इसके डिज़ाइन विकल्पों के कई परिणाम बाद में सामने आए:

- **व्यक्ति श्रेणियों ने जनसांख्यिकीय संबद्धताओं को कूटबद्ध किया** {cite}`yang2020towards`। लोगों की छवियों पर लागू लेबल ने जाति, लिंग और वर्ग संबद्धताओं को कूटबद्ध किया जो सीधे मॉडल एम्बेडिंग में प्रचारित हुईं।
- **पश्चिमी, अंग्रेज़ी-भाषी दृश्य डिफ़ॉल्ट।** छवियाँ मुख्य रूप से Flickr और अंग्रेज़ी-भाषा खोजों से एकत्र की गईं।

:::{admonition} अनुलेखन योजना दुनिया का एक सिद्धांत है :class: note

प्रत्येक लेबल वर्गीकरण इस बारे में दावे करता है कि कौन से भेद महत्त्वपूर्ण हैं। इन योजनाओं पर प्रशिक्षित मॉडल वही भेद करेंगे, और उससे अधिक नहीं। :::

छवि वर्गीकरण अनुलेखन

लेबल पदानुक्रम। "कुत्ता" लेबल एक अर्थ पदानुक्रम में "जानवर" का एक बच्चा है।

बहुलेबल अस्पष्टता। एक सड़क दृश्य में एक साथ कार, व्यक्ति, साइकिल और ट्रैफिक लाइट हो सकती है।

लंबी-पूँछ वितरण। प्राकृतिक छवि डेटासेट एक शक्ति नियम का पालन करते हैं।

वस्तु पहचान: बाउंडिंग बॉक्स अनुलेखन

वस्तु पहचान के लिए अनुलेखकों को प्रत्येक वस्तु वर्ग के उदाहरणों के चारों ओर अक्ष-संरेखित बाउंडिंग बॉक्स खींचने की आवश्यकता होती है।

अनुलेखन गुणवत्ता मेट्रिक्स:

IoU (Intersection over Union) एक अनुलेखित बॉक्स और एक संदर्भ बॉक्स के बीच ओवरलैप मापता है:

$$\text{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

IoU ≥ 0.5 PASCAL VOC में "सही" पहचान के लिए मानक सीमा है; COCO {cite}`lin2014microsoft` 0.5 से 0.95 तक की एक श्रृंखला का उपयोग करता है।

```
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.patches as patches

def compute_iou(boxA, boxB):
    """Compute IoU between two boxes [x1, y1, x2, y2]."""
    xA = max(boxA[0], boxB[0])
    yA = max(boxA[1], boxB[1])
    xB = min(boxA[2], boxB[2])
    yB = min(boxA[3], boxB[3])
    inter_area = max(0, xB - xA) * max(0, yB - yA)
    boxA_area = (boxA[2] - boxA[0]) * (boxA[3] - boxA[1])
    boxB_area = (boxB[2] - boxB[0]) * (boxB[3] - boxB[1])
    union_area = boxA_area + boxB_area - inter_area
    return inter_area / (union_area + 1e-6)

ref_box  = [1.0, 1.0, 4.0, 4.0]
ann1_box = [1.1, 0.9, 4.1, 4.2]   # close
ann2_box = [0.5, 0.5, 3.5, 3.8]   # less precise

print(f"IoU (ann1 vs ref):  {compute_iou(ann1_box, ref_box):.3f}")
print(f"IoU (ann2 vs ref):  {compute_iou(ann2_box, ref_box):.3f}")
print(f"IoU (ann1 vs ann2): {compute_iou(ann1_box, ann2_box):.3f}")

fig, ax = plt.subplots(figsize=(5, 5))
ax.set_xlim(0, 5); ax.set_ylim(0, 5); ax.set_aspect('equal')
ax.add_patch(patches.Rectangle(
    (ref_box[0], ref_box[1]), ref_box[2]-ref_box[0], ref_box[3]-ref_box[1],
    linewidth=2.5, edgecolor='#2b3a8f', facecolor='none', label='Reference'))
ax.add_patch(patches.Rectangle(
    (ann1_box[0], ann1_box[1]), ann1_box[2]-ann1_box[0], ann1_box[3]-ann1_box[1]
    linewidth=2, edgecolor='#0d9e8e', facecolor='none', linestyle='--',
    label=f'Ann1 (IoU={compute_iou(ann1_box, ref_box):.2f})'))
ax.add_patch(patches.Rectangle(
    (ann2_box[0], ann2_box[1]), ann2_box[2]-ann2_box[0], ann2_box[3]-ann2_box[1]
    linewidth=2, edgecolor='#e05c5c', facecolor='none', linestyle=':',
    label=f'Ann2 (IoU={compute_iou(ann2_box, ref_box):.2f})'))
```

```
ax.legend(fontsize=10)
ax.set_title("Bounding Box Agreement (IoU)", fontsize=12)
plt.tight_layout()
plt.savefig('bbox_iou.png', dpi=150)
plt.show()
```

सिमेंटिक और इंस्टेंस विभाजन

सिमेंटिक विभाजन: प्रत्येक पिक्सेल एक सिमेंटिक वर्ग (सड़क, आकाश, व्यक्ति, कार) से संबंधित है।

इंस्टेंस विभाजन: प्रत्येक व्यक्तिगत वस्तु उदाहरण को एक अद्वितीय लेबल मिलता है।

SAM-सहायता प्राप्त अनुलेखन: Meta का Segment Anything Model {cite}`kirillov2023segment` एकल बिंदु क्लिक से उच्च-गुणवत्ता विभाजन मास्क उत्पन्न करता है। अनुलेखकों की भूमिका खींचने से समीक्षा करने में बदल जाती है।

कंप्यूटर दृष्टि के लिए सक्रिय अधिगम

```
import numpy as np
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score
import matplotlib.pyplot as plt

rng = np.random.default_rng(42)

X, y = make_classification(n_samples=3000, n_features=50, n_informative=25,
                           n_classes=5, n_clusters_per_class=2, random_state=42
X_train, y_train = X[:2500], y[:2500]
X_test,  y_test  = X[2500:], y[2500:]

def margin_uncertainty(model, X_pool):
    probs = model.predict_proba(X_pool)
    sorted_p = np.sort(probs, axis=1)
    return sorted_p[:, -2] - sorted_p[:, -1]  # most negative = most uncertain

n_init = 50
results = {'active': [], 'random': []}
label_counts = list(range(50, 401, 30))

for strategy in ['active', 'random']:
    labeled = list(rng.choice(len(X_train), n_init, replace=False))
    unlabeled = [i for i in range(len(X_train)) if i not in labeled]

    for target in label_counts:
        while len(labeled) < target and unlabeled:
            if strategy == 'active' and len(labeled) >= 10:
                model_temp = LogisticRegression(max_iter=300).fit(
```

```
                    X_train[labeled], y_train[labeled])
                margins = margin_uncertainty(model_temp, X_train[unlabeled])
                idx = int(np.argmin(margins))
            else:
                idx = rng.integers(0, len(unlabeled))
            labeled.append(unlabeled.pop(idx))

        clf = LogisticRegression(max_iter=300).fit(X_train[labeled], y_train[lab
        results[strategy].append(accuracy_score(y_test, clf.predict(X_test)))

plt.figure(figsize=(7, 4))
plt.plot(label_counts, results['active'], 'o-', color='#2b3a8f',
         linewidth=2, label='Active (margin sampling)')
plt.plot(label_counts, results['random'], 's--', color='#e05c5c',
         linewidth=2, label='Random baseline')
plt.xlabel("Labeled training images", fontsize=12)
plt.ylabel("Test accuracy", fontsize=12)
plt.title("Active Learning for 5-Class Image Classification", fontsize=13)
plt.legend(fontsize=11); plt.grid(alpha=0.3)
plt.tight_layout()
plt.savefig('cv_active_learning.png', dpi=150)
plt.show()
```

वीडियो अनुलेखन

वीडियो अनुलेखन छवि अनुलेखन की चुनौतियों को समय से गुणा करता है:

- **ट्रैकिंग:** वस्तुओं को फ्रेम में पहचाना जाना चाहिए।
- **अस्थायी संगति:** फ्रेम t में खींची गई सीमाएँ फ्रेम $t + 1$ के साथ स्थानिक रूप से सुसंगत होनी चाहिए।
- **स्केलेबिलिटी:** 30fps पर 1 घंटे का वीडियो 108,000 फ्रेम है।

स्वायत्त प्रणालियों में दुर्लभ घटना समस्या। स्वायत्त ड्राइविंग के लिए, सामान्य संचालन में देखे गए फ्रेम का वितरण सबसे महत्त्वपूर्ण फ्रेम के वितरण से बुरी तरह मेल नहीं खाता।

> **See also:** ImageNet डेटासेट: {cite}`russakovsky2015imagenet`। ImageNet में लेबल पूर्वाग्रह: {cite}`yang2020towards`। COCO बेंचमार्क: {cite}`lin2014microsoft`। SAM (Segment Anything): {cite}`kirillov2023segment`। CV के लिए कोर-सेट सक्रिय अधिगम: {cite}`sener2018active`।

स्वास्थ्य सेवा एवं विज्ञान में HITL

स्वास्थ्य सेवा और विज्ञान उन डोमेन का प्रतिनिधित्व करते हैं जहाँ HITL ML सबसे अधिक परिणामपूर्ण और सबसे अधिक बहस का विषय है। दांव ऊँचे हैं: एक चूका हुआ कैंसर निदान या एक त्रुटिपूर्ण दवा लक्ष्य का वास्तविक मानव लागत है। अनुलेखन के लिए दुर्लभ और महंगी विशेषज्ञता की आवश्यकता होती है।

लोकप्रिय कवरेज में प्रमुख फ्रेमिंग "AI बनाम मानव" है: क्या AI रेडियोलॉजिस्ट की जगह लेगा? यह फ्रेमिंग एक ऐसे तरीके से गलत है जो महत्त्वपूर्ण है। वास्तविक प्रश्न यह है कि मानव-AI सहयोग का कौन सा रूप अकेले किसी एक से बेहतर परिणाम उत्पन्न करता है।

चिकित्सा छवि विश्लेषण

चिकित्सा इमेजिंग — रेडियोलॉजी (X-ray, CT, MRI), पैथोलॉजी, त्वचाविज्ञान, नेत्र विज्ञान — वह डोमेन है जहाँ चिकित्सा AI सबसे तेज़ी से आगे बढ़ी है।

विशेषज्ञ अनुलेखक आवश्यकताएँ

चिकित्सा छवि अनुलेखन के लिए आमतौर पर विशिष्ट उपविशेषता प्रशिक्षण वाले चिकित्सकों की आवश्यकता होती है।

अंतर-रेडियोलॉजिस्ट परिवर्तनशीलता

रेडर परिवर्तनशीलता रेडियोलॉजी में अच्छी तरह प्रलेखित है। CheXNet अध्ययन में, चार रेडियोलॉजिस्टों ने एक ही न्यूमोनिया पहचान परीक्षण सेट को F1 स्कोर के साथ लेबल किया जो लगभग 12 प्रतिशत बिंदुओं में फैले हुए थे {cite}`rajpurkar2017chexnet`।

:::{admonition} HITL सबक के रूप में CheXNet विवाद :class: note

जब Rajpurkar et al. ने दावा किया कि उनका CheXNet मॉडल न्यूमोनिया पहचान पर "रेडियोलॉजिस्ट प्रदर्शन से अधिक" था, रेडियोलॉजी समुदाय ने तुरंत इसे चुनौती दी {cite}`yu2022assessing`। सबक यह है कि **प्रदर्शन तुलनाओं के लिए HITL सेटअप निर्दिष्ट करने की आवश्यकता होती है**। :::

:::{admonition} चिकित्सा में नरम लेबल :class: important

कई चिकित्सा AI परियोजनाओं ने **नरम लेबल** का उपयोग करना शुरू किया है जो एकल "स्वर्ण मानक" लेबल के बजाय विशेषज्ञ राय के वितरण को दर्शाते हैं। :::

नैदानिक NLP अनुलेखन

इलेक्ट्रॉनिक स्वास्थ्य रिकॉर्ड (EHR) में नैदानिक कथा पाठ का एक विशाल भंडार होता है।

सामान्य नैदानिक NLP अनुलेखन कार्य: - **नैदानिक NER:** पाठ में दवाएँ, खुराक, निदान, प्रक्रियाएँ, और लक्षण पहचानना - **नकारण पहचान:** "न्यूमोनिया का कोई प्रमाण नहीं" बनाम "न्यूमोनिया की पुष्टि" - **अस्थायी तर्क:** वर्तमान स्थितियों को इतिहास से अलग करना - **डी-पहचान:** डेटा साझाकरण सक्षम करने के लिए Protected Health Information (PHI) हटाना

नियामक विचार

FDA (संयुक्त राज्य): AI/ML-आधारति Software as a Medical Device (SaMD) के लिए पूर्व-बाज़ार अनुमोदन या मंज़ूरी की आवश्यकता है।

CE मार्किंग (यूरोप): AI प्रणालियों सहित चिकित्सा उपकरणों को Medical Device Regulation (MDR) का पालन करना होगा।

वैज्ञानिक डेटा अनुलेखन

खगोलशास्त्र: Galaxy Zoo

Galaxy Zoo {cite}`lintott2008galaxy` ने नागरिक वैज्ञानिकों को Sloan Digital Sky Survey से आकाशगंगाओं के आकारिकीय वर्गीकरण के लिए भीड़ से जुटाया। मूल परियोजना ने 100,000 से अधिक स्वयंसेवकों से 40 मिलियन से अधिक वर्गीकरण एकत्र किए।

जीनोमिक्स: रोगजनकता वर्गीकरण

जीनोमिक वेरिएंट को एनोटेट करना — यह तय करना कि कोई वेरिएंट रोगजनक, सौम्य, या अनिश्चित महत्त्व का है — एक उच्च-दांव की समस्या है।

तंत्रिका विज्ञान: कनेक्टोमिक्स

इलेक्ट्रॉन माइक्रोस्कोप छवियों से तंत्रिका सर्किट का पुनर्निर्माण — कनेक्टोमिक्स — विशाल छवि स्टैक पर न्यूरॉन झिल्लियों के पिक्सेल-स्तर अनुलेखन की आवश्यकता है। Eyewire परियोजना ने इस कार्य को गेमिफाई किया।

चिकित्सा इमेजिंग के लिए एक HITL सक्रिय अधिगम पाइपलाइन

```
import numpy as np
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import roc_auc_score
from sklearn.datasets import make_classification
import matplotlib.pyplot as plt

rng = np.random.default_rng(42)

# Simulate a rare-pathology detection task
# 8% positive class (e.g., rare pathology)
X, y = make_classification(
    n_samples=5000, n_features=100,
```

```
    n_informative=20, n_redundant=10,
    weights=[0.92, 0.08],
    random_state=42
)
X_train, y_train = X[:4000], y[:4000]
X_test,  y_test  = X[4000:], y[4000:]

print(f"Training set positive prevalence: {y_train.mean():.1%}")

def run_medical_al(strategy, n_initial=50, budget=300):
    labeled = list(rng.choice(len(X_train), n_initial, replace=False))
    unlabeled = [i for i in range(len(X_train)) if i not in labeled]
    aucs = []

    while len(labeled) < n_initial + budget:
        model = LogisticRegression(max_iter=500, class_weight='balanced')
        model.fit(X_train[labeled], y_train[labeled])

        if len(labeled) % 30 == 0:
            preds = model.predict_proba(X_test)[:, 1]
            aucs.append(roc_auc_score(y_test, preds))

        X_pool = X_train[unlabeled]
        if strategy == 'uncertainty' and len(labeled) >= 10:
            probs = model.predict_proba(X_pool)
            entropy = -np.sum(probs * np.log(probs + 1e-9), axis=1)
            q = int(np.argmax(entropy))
        else:
            q = rng.integers(0, len(unlabeled))

        labeled.append(unlabeled.pop(q))

    return np.array(aucs)

aucs_al  = run_medical_al('uncertainty')
aucs_rnd = run_medical_al('random')
label_counts = np.arange(len(aucs_al)) * 30 + 50

plt.figure(figsize=(7, 4))
plt.plot(label_counts, aucs_al,  'o-',  color='#2b3a8f', linewidth=2, label='Unc
plt.plot(label_counts, aucs_rnd, 's--', color='#e05c5c', linewidth=2, label='Ran
plt.xlabel("Expert labels obtained", fontsize=12)
plt.ylabel("AUROC", fontsize=12)
plt.title("Active Learning for Rare Pathology Detection", fontsize=13)
plt.legend(); plt.grid(alpha=0.3)
plt.tight_layout()
plt.savefig('medical_al.png', dpi=150)
plt.show()

# Show how AL preferentially selects positive examples
n_init = 50
```

```
labeled_al  = list(rng.choice(len(X_train), n_init, replace=False))
labeled_rnd = labeled_al.copy()
unlabeled_al  = [i for i in range(len(X_train)) if i not in labeled_al]
unlabeled_rnd = unlabeled_al.copy()

model = LogisticRegression(max_iter=500, class_weight='balanced')
model.fit(X_train[labeled_al], y_train[labeled_al])
probs = model.predict_proba(X_train[unlabeled_al])
entropy = -np.sum(probs * np.log(probs + 1e-9), axis=1)
top50_al  = [unlabeled_al[i] for i in np.argsort(entropy)[-50:]]
top50_rnd = list(rng.choice(unlabeled_rnd, 50, replace=False))

pos_rate_al  = y_train[top50_al].mean()
pos_rate_rnd = y_train[top50_rnd].mean()
print(f"\nPositive rate in next 50 queries:")
print(f"  Uncertainty AL: {pos_rate_al:.1%}  (base rate: {y_train.mean():.1%})")
print(f"  Random:         {pos_rate_rnd:.1%}")
print(f"  AL queries {pos_rate_al/y_train.mean():.1f}x more positives than rando
```

See also: Galaxy Zoo क्राउडसोर्सिंग: {cite}lintott2008galaxy। CheXNet रेडियोलॉजिस्ट प्रदर्शन: {cite}rajpurkar2017chexnet। रेडियोग्राफ़ गुणवत्ता और AI-सहायता प्राप्त निदान: {cite}yu2022assessing। नैदानिक NLP अनुलेखन पद्धति: {cite}pustejovsky2012natural।

अनुलेखन प्लेटफ़ॉर्म एवं उपकरण

अनुलेखन प्लेटफ़ॉर्म वह वातावरण है जहाँ मानव प्रतिक्रिया डेटा बनती है। एक अच्छा प्लेटफ़ॉर्म थ्रूपुट बढ़ाता है, त्रुटियाँ कम करता है, गुणवत्ता नियंत्रण बनाए रखता है, और अनुलेखन पाइपलाइन को बड़े पैमाने पर प्रबंधनीय बनाता है। सही प्लेटफ़ॉर्म चुनना — और यह जानना कि कब बनाना है बनाम खरीदना है — किसी भी HITL परियोजना में एक परिणामपूर्ण निर्णय है।

अनुलेखन प्लेटफ़ॉर्म परिदृश्य

ओपन-सोर्स प्लेटफ़ॉर्म

Label Studio सबसे लोकप्रिय ओपन-सोर्स अनुलेखन प्लेटफ़ॉर्म है, जो एकीकृत XML-आधारति कार्य कॉन्फ़िगरेशन के माध्यम से पाठ, छवियाँ, ऑडियो, वीडियो, और टाइम-सीरीज़ डेटा का समर्थन करता है। प्रमुख शक्तियाँ: लचीलापन, सामुदायिक समर्थन, और पूर्व-अनुलेखन के लिए कस्टम ML भविष्यवाणियाँ एम्बेड करने की क्षमता।

Prodigy (spaCy के निर्माताओं से) NLP कार्यों के लिए डिज़ाइन किया गया एक अत्यधिक वर्कफ़्लो-उन्मुख अनुलेखन उपकरण है। इसकी स्ट्रीमिंग आर्किटेक्चर उदाहरणों को एक समय पर एक भेजती है और बॉक्स से बाहर सक्रिय अधिगम का समर्थन करती है।

CVAT (Computer Vision Annotation Tool) CV अनुलेखन के लिए अग्रणी ओपन-सोर्स उपकरण है, जिसमें पहचान, विभाजन, और वीडियो अनुलेखन के लिए मजबूत समर्थन है।

Doccano अनुक्रम लेबलिंग कार्यों (NER, संबंध निष्कर्षण, पाठ वर्गीकरण) को लक्षित करता है।

व्यावसायिक प्लेटफ़ॉर्म

Scale AI एंड-टू-एंड प्रबंधित अनुलेखन सेवाएँ प्रदान करता है।

Labelbox डेटा क्यूरेशन, अनुलेखन, और ML-सहायता प्राप्त लेबलिंग के लिए एक पूर्ण प्लेटफ़ॉर्म है।

Appen (पहले Figure Eight / CrowdFlower) एक बड़े वैश्विक अनुलेखन कार्यबल को टूलिंग के साथ संचालित करता है।

Humanloop LLM प्रतिक्रिया संग्रह में विशेषज्ञता रखता है — वरीयता अनुलेखन, RLHF डेटा संग्रह, और मॉडल मूल्यांकन।

अनुलेखन प्लेटफ़ॉर्म सुविधा तुलना

सुविधा	Label Studio	Prodigy	CVAT	Labelbox	Scale AI
लाइसेंस	ओपन सोर्स	व्यावसायिक	ओपन सोर्स	व्यावसायिक	व्यावसायिक
होस्टिंग	स्व / क्लाउड	स्व	स्व / क्लाउड	क्लाउड	प्रबंधित
पाठ अनुलेखन	☒	☒	—	☒	☒
छवि अनुलेखन	☒	सीमित	☒	☒	☒
वीडियो अनुलेखन	☒	—	☒	☒	☒
सक्रिय अधिगम एकीकरण	☒	☒	सीमित	☒	☒
ML-सहायता पूर्व-अनुलेखन	☒	☒	☒	☒	☒
गुणवत्ता नियंत्रण वर्कफ़्लो	बुनियादी	बुनियादी	बुनियादी	उन्नत	उन्नत
API / प्रोग्रामेटिक पहुँच	☒	☒	☒	☒	☒
कार्यबल प्रबंधन	—	—	—	सीमित	☒

कोड के रूप में अनुलेखन

स्कीमा-प्रथम डिज़ाइन। लेबल वर्गीकरण और अनुलेखन नियम अनुलेखन शुरू होने से पहले एक संस्करणीय कॉन्फ़िगरेशन फ़ाइल (YAML या JSON) में परिभाषित किए जाते हैं।

अनुलेखन संस्करणीकरण। अनुलेखनों को उस स्कीमा संस्करण के लिंक के साथ संग्रहीत किया जाता है जिसके तहत वे बनाए गए थे।

पुनरुत्पादनीय पाइपलाइनें। अनुलेखन पाइपलाइन — कच्चे डेटा से प्रशिक्षण-तैयार लेबल तक — कोड से पुनरुत्पादनीय होनी चाहिए।

```
# Example: Label Studio annotation schema (text classification)
label_config: |
  <View>
    <Text name="text" value="$text"/>
    <Choices name="sentiment" toName="text" choice="single">
      <Choice value="positive"/>
      <Choice value="negative"/>
      <Choice value="neutral"/>
      <Choice value="mixed"/>
    </Choices>
  </View>
schema_version: "2.1.0"
task_type: text_classification
guidelines_version: "guidelines_v3.pdf"
```text
Data source
    |
    v
Unlabeled pool -->  Annotation platform --> Labeled dataset
    ^                    |                        |
    |                    | (ML-assisted)           v
Active learning <--------+                    Training run
query strategy                                     |
    ^                                              v
    +------------ Trained model <---------- Evaluation
```
```

```
                    |
Deployment &
monitoring
```

मुख्य एकीकरण बिंदु: 1. **डेटा अंतर्ग्रहण:** बिना लेबल का डेटा डेटा वेयरहाउस से स्वचालित रूप से अनुलेखन प्लेटफ़ॉर्म पर प्रवाहित होता है 2. **मॉडल सेवा:** वर्तमान सर्वोत्तम मॉडल पूर्व-अनुलेखन और सक्रिय अधिगम स्कोरिंग के लिए अनुलेखन प्लेटफ़ॉर्म पर परिनियोजित है 3. **निर्यात:** पूर्ण अनुलेखन प्रशिक्षण फ्रेमवर्क (COCO JSON, Hugging Face datasets, आदि) के साथ संगत प्रारूप में निर्यात किए जाते हैं 4. **प्रतिक्रिया लूप:** प्रोडक्शन मॉडल त्रुटियाँ सुधार के लिए अनुलेखन प्लेटफ़ॉर्म पर वापस रूट की जाती हैं

> **See also:** Label Studio प्रलेखन और सक्रिय अधिगम एकीकरण के लिए: https://labelstud.io। Prodigy के लिए: https://prodi.gy। CVAT: https://cvat.ai। अनुलेखन उपकरणों की व्यापक तुलना के लिए, {cite}`monarch2021human`, अध्याय 7 देखें।

क्राउडसोर्सिंग एवं गुणवत्ता नियंत्रण

जब अनुलेखन कार्य गैर-विशेषज्ञों द्वारा किए जाने के लिए पर्याप्त सरल हों, तो क्राउडसोर्सिंग प्लेटफ़ॉर्म कम प्रति-आइटम लागत पर बड़े, माँग पर अनुलेखन कार्यबल तक पहुँच प्रदान करते हैं। क्राउड से उच्च-गुणवत्ता लेबल किए गए डेटासेट बनाने के लिए सावधानीपूर्वक कार्य डिज़ाइन, रणनीतिक अतिरिक्तता, और कड़े गुणवत्ता नियंत्रण की आवश्यकता होती है।

क्राउडसोर्सिंग प्लेटफ़ॉर्म

Amazon Mechanical Turk (MTurk) मूल क्राउडसोर्सिंग मार्केटप्लेस है, जो 2005 में लॉन्च हुआ। एक 2018 अध्ययन में Turkers के लिए औसत प्रभावी प्रति घंटा आय लगभग $2/घंटा पाई गई — कई उच्च-आय वाले देशों में न्यूनतम वेतन से काफी कम {cite}`hara2018data`।

Prolific एक शैक्षणिक क्राउडसोर्सिंग प्लेटफ़ॉर्म है जो न्यूनतम वेतन मानक (Prolific के प्रकाशित दिशानिर्देशों में उल्लिखित वर्तमान में लगभग £9/घंटा) लागू करता है।

Appen (और Telus International, iMerit) प्रबंधित अनुलेखन कार्यबल प्रदान करता है।

क्राउडसोर्सिंग के लिए कार्य डिज़ाइन

जटिल कार्यों को विघटित करें

जटिल कार्यों को सरल, अच्छी तरह परिभाषित माइक्रो-कार्यों में विघटित किया जाना चाहिए।

विघटन के लाभ: - प्रति कार्य कम संज्ञानात्मक माँग ⊠ कम थकान, उच्च गुणवत्ता - प्रत्येक माइक्रो-कार्य को अलग से गुणवत्ता-नियंत्रित किया जा सकता है

स्वर्ण मानक प्रश्न

कार्य बैच में **स्वर्ण मानक प्रश्न** — ज्ञात सही उत्तरों वाले कार्य — एम्बेड करें।

```
import numpy as np
from scipy.stats import binom

rng = np.random.default_rng(42)

def simulate_gold_screening(n_workers=100, gold_per_batch=5,
                            p_good_worker=0.7, good_acc=0.92,
                            bad_acc=0.55, threshold=0.70):
    """
```

```
    Simulate quality screening via gold questions.
    Returns: precision and recall of identifying bad workers.
    """
    worker_quality = rng.choice(['good', 'bad'], size=n_workers,
                                p=[p_good_worker, 1 - p_good_worker])
    results = {'tp': 0, 'fp': 0, 'tn': 0, 'fn': 0}

    for q in worker_quality:
        acc = good_acc if q == 'good' else bad_acc
        n_correct = rng.binomial(gold_per_batch, acc)
        passed = (n_correct / gold_per_batch) >= threshold
        if q == 'bad' and not passed:  results['tp'] += 1
        if q == 'good' and not passed: results['fp'] += 1
        if q == 'bad' and passed:      results['fn'] += 1
        if q == 'good' and passed:     results['tn'] += 1

    tp, fp, fn = results['tp'], results['fp'], results['fn']
    precision = tp / (tp + fp + 1e-6)
    recall    = tp / (tp + fn + 1e-6)
    return precision, recall

# Vary gold question count
gold_counts = [3, 5, 8, 10, 15, 20]
precisions, recalls = [], []
for g in gold_counts:
    p_list, r_list = [], []
    for _ in range(50):
        p, r = simulate_gold_screening(gold_per_batch=g)
        p_list.append(p); r_list.append(r)
    precisions.append(np.mean(p_list))
    recalls.append(np.mean(r_list))

import matplotlib.pyplot as plt
fig, ax = plt.subplots(figsize=(7, 4))
ax.plot(gold_counts, precisions, 'o-', color='#2b3a8f', label='Precision', linew
ax.plot(gold_counts, recalls,    's--', color='#0d9e8e', label='Recall',    line
ax.set_xlabel("Gold questions per batch", fontsize=12)
ax.set_ylabel("Screening performance", fontsize=12)
ax.set_title("Worker Screening via Gold Standard Questions", fontsize=13)
ax.legend(fontsize=11); ax.grid(alpha=0.3)
plt.tight_layout()
plt.savefig('gold_screening.png', dpi=150)
plt.show()

p, r = simulate_gold_screening(gold_per_batch=5)
print(f"5 gold questions: Precision={p:.3f}, Recall={r:.3f}")
p, r = simulate_gold_screening(gold_per_batch=10)
print(f"10 gold questions: Precision={p:.3f}, Recall={r:.3f}")
```

लेबल एकत्रीकरण के लिए सांख्यिकीय मॉडल

Dawid-Skene मॉडल

Dawid-Skene (DS) मॉडल {cite}dawid1979maximum संयुक्त रूप से अनुमान लगाता है: - प्रत्येक आइटम i के लिए **सत्य लेबल** z_i - प्रत्येक अनुलेखक j के लिए **भ्रम मैट्रिक्स** $\pi_j^{(k,l)}$

EM एल्गोरिदम पुनरावृत्त करता है: - **E-step:** अनुलेखक भ्रम मैट्रिक्स दिए जाने पर, प्रत्येक सत्य लेबल की पश्च प्रायिकता की गणना करें - **M-step:** आइटम लेबल अनुमान दिए जाने पर, अनुलेखक भ्रम मैट्रिक्स अपडेट करें

```
import numpy as np
from scipy.special import softmax

def dawid_skene_em(annotations, n_classes, n_iter=20):
    """
    Simplified Dawid-Skene EM for binary classification.
    annotations: dict {item_idx: [(annotator_idx, label), ...]}
    Returns: estimated true labels and annotator accuracies.
    """
    items = sorted(annotations.keys())
    n_items = len(items)
    annotators = sorted({a for anns in annotations.values() for a, _ in anns})
    n_annotators = len(annotators)
    ann_idx = {a: i for i, a in enumerate(annotators)}

    # Initialize: majority vote
    T = np.zeros((n_items, n_classes))  # soft label estimates
    for i, item in enumerate(items):
        for _, label in annotations[item]:
            T[i, label] += 1
        T[i] /= T[i].sum()

    # Confusion matrices: shape (n_annotators, n_classes, n_classes)
    PI = np.ones((n_annotators, n_classes, n_classes)) * 0.5

    for _ in range(n_iter):
        # M-step: update confusion matrices
        PI = np.zeros((n_annotators, n_classes, n_classes)) + 1e-6
        for i, item in enumerate(items):
            for ann, label in annotations[item]:
                a = ann_idx[ann]
                for k in range(n_classes):
                    PI[a, k, label] += T[i, k]
        PI /= PI.sum(axis=2, keepdims=True)

        # E-step: update soft label estimates
        T = np.zeros((n_items, n_classes))
        for i, item in enumerate(items):
            log_p = np.zeros(n_classes)
            for ann, label in annotations[item]:
                a = ann_idx[ann]
                log_p += np.log(PI[a, :, label] + 1e-10)
```

```
            T[i] = softmax(log_p)

    return {item: T[i] for i, item in enumerate(items)}, PI

# Simulate crowdsourcing scenario
rng = np.random.default_rng(42)
N_ITEMS, N_ANNOTATORS, ANNS_PER_ITEM = 200, 10, 3
true_labels = rng.integers(0, 2, N_ITEMS)
# Annotator accuracies: 3 good (0.9), 4 medium (0.75), 3 noisy (0.6)
accuracies = [0.90]*3 + [0.75]*4 + [0.60]*3

annotations = {}
for i in range(N_ITEMS):
    anns_for_item = []
    chosen = rng.choice(N_ANNOTATORS, ANNS_PER_ITEM, replace=False)
    for a in chosen:
        acc = accuracies[a]
        label = true_labels[i] if rng.random() < acc else 1 - true_labels[i]
        anns_for_item.append((a, int(label)))
    annotations[i] = anns_for_item

# Run Dawid-Skene
soft_labels, confusion = dawid_skene_em(annotations, n_classes=2, n_iter=30)
ds_preds = {i: int(np.argmax(soft_labels[i])) for i in range(N_ITEMS)}

# Compare with majority vote
mv_preds = {}
for i in range(N_ITEMS):
    votes = [l for _, l in annotations[i]]
    mv_preds[i] = int(np.round(np.mean(votes)))

ds_acc = np.mean([ds_preds[i] == true_labels[i] for i in range(N_ITEMS)])
mv_acc = np.mean([mv_preds[i] == true_labels[i] for i in range(N_ITEMS)])

print(f"Majority vote accuracy:  {mv_acc:.3f}")
print(f"Dawid-Skene accuracy:    {ds_acc:.3f}")
print(f"\nEstimated annotator accuracies (diagonal of confusion matrix):")
for a in range(N_ANNOTATORS):
    est_acc = np.mean([confusion[a, k, k] for k in range(2)])
    print(f"  Annotator {a}: estimated={est_acc:.3f}, true={accuracies[a]:.2f}")
```

MACE

MACE (Multi-Annotator Competence Estimation) {cite}hovy2013learning एक वैकल्पिक प्रायिकता मॉडल है जो स्पष्ट रूप से अनुलेखक स्पैमिंग (यादृच्छिक लेबलिंग) बनाम सक्षम अनुलेखन का प्रतिनिधित्व करता है।

अतिरिक्तता और एकत्रीकरण रणनीति

प्रति आइटम अनुलेखकों की इष्टतम संख्या कार्य कठिनाई और अनुलेखक गुणवत्ता पर निर्भर करती है:

- **कुशल अनुलेखकों के साथ आसान कार्य:** 1–2 अनुलेखक प्रति आइटम अक्सर पर्याप्त होते हैं
- **प्रशिक्षित अनुलेखकों के साथ मध्यम कार्य:** 3 अनुलेखक + बहुमत वोट
- **क्राउडवर्कर के साथ कठिन/व्यक्तिपरक कार्य:** 5–7 अनुलेखक + Dawid-Skene

अनुलेखक सटीकता p के साथ n अनुलेखकों के साथ बहुमत वोट सटीकता:

$$P(\text{MV correct}) = \sum_{k>n/2}^{n} \binom{n}{k} p^k (1-p)^{n-k}$$

See also: Dawid-Skene मॉडल: {cite}`dawid1979maximum`। MACE: {cite}`hovy2013learning`। NLP के लिए क्राउडसोर्सिंग की व्यापक समीक्षा के लिए: {cite}`snow2008cheap`। भीड़ नैतिकता और उचित वेतन: अध्याय 15 देखें।

मूल्यांकन एवं मापदंड

यह जानना कि क्या आपकी HITL प्रणाली काम कर रही है, मॉडल सटीकता मापने से अधिक की आवश्यकता है। आपको यह जानना होगा कि क्या आपको अपने अनुलेखन बजट से मूल्य मिल रहा है, क्या मॉडल वास्तव में मानव इरादे के साथ बेहतर संरेखित है, और क्या अतिरिक्त मानव प्रतिक्रिया चीज़ों में सुधार जारी रखेगी। यह अध्याय HITL सेटिंग्स में मूल्यांकन के पूर्ण परिदृश्य को शामिल करता है।

मॉडल-केंद्रित मेट्रिक्स

वर्गीकरण मेट्रिक्स

सटीकता तब उपयुक्त है जब वर्ग संतुलित हों और सभी त्रुटियाँ समान रूप से महंगी हों।

F1 स्कोर प्रेसीजन और रिकॉल का हार्मोनिक माध्य है, असंतुलित वर्गों के लिए उपयुक्त।

AUROC थ्रेशोल्ड की परवाह किए बिना वर्गों के बीच भेद करने की मॉडल की क्षमता को मापता है।

अंशांकन मापता है कि भविष्यवाणी की गई प्रायिकताएँ अनुभवजन्य आवृत्तियों के साथ कितनी अच्छी तरह मेल खाती हैं।

जेनरेटिव मॉडल मेट्रिक्स

- **BLEU / ROUGE / METEOR:** अनुवाद और सारांश के लिए संदर्भ-आधारित मेट्रिक्स।
- **Perplexity:** मॉडल होल्ड-आउट पाठ की भविष्यवाणी कितनी अच्छी तरह करता है।
- **BERTScore:** संदर्भों के साथ एम्बेडिंग-आधारित समानता।
- **मानव मूल्यांकन:** स्वर्ण मानक।

अनुलेखन दक्षता मेट्रिक्स

अधिगम वक्र

एक **अधिगम वक्र** लेबल किए गए उदाहरणों की संख्या के एक फ़ंक्शन के रूप में मॉडल प्रदर्शन को प्लॉट करता है।

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import f1_score, roc_auc_score
from sklearn.model_selection import StratifiedShuffleSplit

rng = np.random.default_rng(42)
```

```
X, y = make_classification(n_samples=5000, n_features=30, n_informative=15,
                           weights=[0.8, 0.2], random_state=42)
X_test, y_test = X[4000:], y[4000:]
X_pool, y_pool = X[:4000], y[:4000]

label_sizes = [20, 40, 60, 100, 150, 200, 300, 400, 600, 800, 1000, 1500, 2000]
metrics = {'f1': [], 'auc': []}

for n in label_sizes:
    idx = rng.choice(len(X_pool), n, replace=False)
    clf = LogisticRegression(max_iter=500, class_weight='balanced')
    clf.fit(X_pool[idx], y_pool[idx])
    preds = clf.predict(X_test)
    probs = clf.predict_proba(X_test)[:, 1]
    metrics['f1'].append(f1_score(y_test, preds))
    metrics['auc'].append(roc_auc_score(y_test, probs))

# Fit learning curve: performance ≈ a - b/sqrt(n)
from scipy.optimize import curve_fit

def learning_curve_fn(n, a, b):
    return a - b / np.sqrt(n)

popt_f1, _ = curve_fit(learning_curve_fn, label_sizes, metrics['f1'], p0=[0.9, 2
popt_auc, _ = curve_fit(learning_curve_fn, label_sizes, metrics['auc'], p0=[0.95

n_smooth = np.linspace(20, 3000, 200)

fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(11, 4))

ax1.scatter(label_sizes, metrics['f1'], color='#2b3a8f', zorder=5, s=40)
ax1.plot(n_smooth, learning_curve_fn(n_smooth, *popt_f1), '--', color='#e05c5c',
         label=f'Fit: {popt_f1[0]:.3f} - {popt_f1[1]:.1f}/√n')
ax1.set_xlabel("Labeled examples"); ax1.set_ylabel("F1 score")
ax1.set_title("Learning Curve: F1"); ax1.legend(); ax1.grid(alpha=0.3)

ax2.scatter(label_sizes, metrics['auc'], color='#0d9e8e', zorder=5, s=40)
ax2.plot(n_smooth, learning_curve_fn(n_smooth, *popt_auc), '--', color='#e05c5c'
         label=f'Fit: {popt_auc[0]:.3f} - {popt_auc[1]:.2f}/√n')
ax2.set_xlabel("Labeled examples"); ax2.set_ylabel("AUROC")
ax2.set_title("Learning Curve: AUROC"); ax2.legend(); ax2.grid(alpha=0.3)

plt.tight_layout()
plt.savefig('learning_curves.png', dpi=150)
plt.show()

# Estimate the annotation budget needed to reach a target performance
target_f1 = 0.80
n_needed = (popt_f1[1] / (popt_f1[0] - target_f1)) ** 2
print(f"Estimated labels needed to reach F1={target_f1}: {n_needed:.0f}")
```

निवेश पर वापसी (ROI) विश्लेषण

मानव प्रतिक्रिया का ROI उत्तर देता है: प्रत्येक अतिरिक्त लेबल के लिए, मॉडल प्रदर्शन कितना सुधरता है?

$$\text{ROI}(n) = \frac{\Delta\text{performance}(n)}{\text{cost per label}}$$

मानव मूल्यांकन

प्रत्यक्ष मूल्यांकन (DA)

अनुलेखक आउटपुट को एक पूर्ण पैमाने पर रेट करते हैं। DA को मशीन अनुवाद मूल्यांकन (WMT बेंचमार्क) में मानकीकृत किया गया है।

DA के लिए सर्वोत्तम प्रथाएँ: - एंकरिंग को रोकने के लिए आउटपुट के क्रम को यादृच्छिक करें - प्रति आइटम पर्याप्त संख्या में अनुलेखक (न्यूनतम 3–5) - गुणवत्ता नियंत्रण शामिल करें - समग्र स्कोर के साथ अंतर-अनुलेखक सहमति रिपोर्ट करें

तुलनात्मक मूल्यांकन

अनुलेखक दो आउटपुट के बीच चुनते हैं। **ELO रेटिंग प्रणालियाँ** (शतरंज से उधार ली गई) युगल तुलना परिणामों को एक निरंतर गुणवत्ता रैंकिंग में परिवर्तित करती हैं।

```
import numpy as np

def update_elo(rating_a, rating_b, outcome_a, k=32):
    """Update ELO ratings. outcome_a: 1=A wins, 0=B wins, 0.5=tie."""
    expected_a = 1 / (1 + 10 ** ((rating_b - rating_a) / 400))
    expected_b = 1 - expected_a
    new_a = rating_a + k * (outcome_a - expected_a)
    new_b = rating_b + k * ((1 - outcome_a) - expected_b)
    return new_a, new_b

# Simulate 5 model versions being compared pairwise
rng = np.random.default_rng(42)
true_quality = [0.60, 0.70, 0.75, 0.80, 0.85]  # underlying model quality
n_models = len(true_quality)
elo_ratings = {i: 1000.0 for i in range(n_models)}

for _ in range(500):  # 500 pairwise comparisons
    i, j = rng.choice(n_models, 2, replace=False)
    p_i_wins = true_quality[i] / (true_quality[i] + true_quality[j])
    outcome = 1.0 if rng.random() < p_i_wins else 0.0
    elo_ratings[i], elo_ratings[j] = update_elo(elo_ratings[i], elo_ratings[j],

print("ELO Rankings after 500 comparisons:")
sorted_models = sorted(elo_ratings.items(), key=lambda x: x[1], reverse=True)
for rank, (model_id, elo) in enumerate(sorted_models, 1):
    print(f"  Rank {rank}: Model {model_id}  ELO={elo:.1f}  True quality={true_q
```

व्यवहार परीक्षण (CheckList)

CheckList {cite}`ribeiro2020beyond` NLP मॉडलों के व्यवस्थित व्यवहार मूल्यांकन के लिए एक पद्धति है:

- **न्यूनतम कार्यक्षमता परीक्षण (MFT):** क्या मॉडल सरल, स्पष्ट मामलों को संभालता है?
- **अपरिवर्तनशीलता परीक्षण (INV):** क्या मॉडल का आउटपुट तब बदलता है जब उसे नहीं बदलना चाहिए?
- **दिशात्मक अपेक्षा परीक्षण (DIR):** क्या मॉडल का आउटपुट इनपुट बदलने पर अपेक्षित दिशा में बदलता है?

मानव इरादे के साथ संरेखण मापना

पुरस्कार मॉडल मूल्यांकन: होल्ड-आउट प्राथमिकता परीक्षण सेट पर पुरस्कार मॉडल की सटीकता।

जीत दर: दो मॉडल संस्करणों को देखते हुए, RLHF मॉडल मानव युगल तुलनाओं में कितने अंश प्रतिक्रियाएँ जीतता है?

सहमत पहचान: मापें कि क्या मॉडल निहित उपयोगकर्ता प्राथमिकता के आधार पर अपने उत्तर बदलता है।

परिनियोजित प्रणालियों में A/B परीक्षण

प्रोडक्शन में प्रणालियों के लिए, अंतिम मूल्यांकन **A/B परीक्षण** है: उपयोगकर्ताओं के एक अंश को नए मॉडल संस्करण में रूट करें और डाउनस्ट्रीम परिणाम मापें।

> **See also:** CheckList व्यवहार परीक्षण: {cite}`ribeiro2020beyond`। RLHF मूल्यांकन पद्धति के लिए, {cite}`ouyang2022training` देखें। MT में मानव मूल्यांकन सर्वोत्तम प्रथाओं के लिए: {cite}`graham2015accurate`। अधिगम वक्र सिद्धांत के लिए: {cite}`mukherjee2003estimating`।

निष्पक्षता, पूर्वाग्रह एवं नैतिकता

ह्यूमन-इन-द-लूप प्रणालियाँ उनमें उपस्थित मनुष्यों की क्षमताओं और सीमाओं दोनों को विरासत में पाती हैं। अनुलेखक अपने काम में ज्ञान, निर्णय, और रचनात्मकता लाते हैं — लेकिन पूर्वाग्रह, थकान, और अपने जीवन का सामाजिक संदर्भ भी। HITL प्रणालियों को डिज़ाइन करने में हम जो विकल्प चुनते हैं — कौन अनुलेखन करता है, उनसे क्या पूछा जाता है, उन्हें कैसे मुआवज़ा दिया जाता है, और उनके काम का उपयोग कैसे किया जाता है — के परिणाम हैं जो मॉडल सटीकता मेट्रिक्स से बहुत आगे जाते हैं।

यह अध्याय HITL ML के नैतिक आयामों को संबोधित करता है।

HITL प्रणालियों में पूर्वाग्रह के स्रोत

अनुलेखक जनसांख्यिकी

अनुलेखन एक तटस्थ कार्य नहीं है। अनुलेखक अपने दृष्टिकोण, अनुभव, और सांस्कृतिक संदर्भों को दर्शाने वाले लेबल असाइन करते हैं। जब अनुलेखन कार्यबल जनसांख्यिकीय रूप से सजातीय हो — जैसा कि अक्सर होता है, क्राउडवर्क युवा, पुरुष, और पश्चिमी की ओर झुकता है — परिणामी डेटासेट उस समूह के दृष्टिकोणों को कूटबद्ध करता है।

साक्ष्य: NLP अनुलेखन डेटासेट के अध्ययनों में पाया गया है कि अनुलेखकों की जनसांख्यिकीय विशेषताएँ व्यक्तिपरक कार्यों के लिए उनके लेबल विकल्पों की भविष्यवाणी करती हैं {cite}`geva2019annotator`।

शमन: जानबूझकर कार्यबल विविधीकरण; स्तरीय अनुलेखन।

कार्य फ्रेमिंग

प्रश्न कैसे पूछा जाता है यह उत्तरों को प्रभावित करता है।

प्लेटफ़ॉर्म प्रभाव

प्लेटफ़ॉर्म और भुगतान संरचना अनुलेखन गुणवत्ता को प्रभावित करती है।

HITL प्रणालियों में निष्पक्षता

निष्पक्षता क्या है?

ML में निष्पक्षता एक विवादित अवधारणा है जिसकी एकाधिक औपचारिक परिभाषाएँ हैं जो अक्सर परस्पर असंगत होती हैं {cite}`barocas2019fairness`।

प्रतिनिधित्व: क्या प्रशिक्षण डेटा उन आबादी का प्रतिनिधित्व करता है जिन्हें मॉडल प्रभावित करेगा?

प्रदर्शन समानता: क्या मॉडल विभिन्न जनसांख्यिकीय समूहों में समान रूप से अच्छा प्रदर्शन करता है?

लेबलिंग संगति: क्या एक ही व्यवहार को समान रूप से लेबल किया जाता है चाहे वह कोई भी कर रहा हो?

निष्पक्षता-जागरूक सक्रिय अधिगम

मानक सक्रिय अधिगम क्वेरी मॉडल अनिश्चितता पर ध्यान केंद्रित करती हैं, जो बहुमत-वर्ग उदाहरणों की ओर केंद्रित होती हैं।

निष्पक्षता-जागरूक क्वेरी रणनीतियाँ:

$$x^* = \arg\max_{x \in \mathcal{U}} \left[\lambda \cdot \text{uncertainty}(x) + (1-\lambda) \cdot \text{minority_group_bonus}(x)\right]$$

अनुलेखक कल्याण

भूत-कार्य समस्या

ML को शक्ति देने वाला अनुलेखन कार्य काफी हद तक अदृश्य है। डेटा कार्यकर्ता — अक्सर ग्लोबल साउथ में — कम वेतन पर, बिना लाभ के, गिग-अर्थव्यवस्था व्यवस्था में काम करते हैं {cite}`crawford2018anatomy,gray2019ghost`।

Amazon MTurk सांख्यिकी: MTurk आय के 2018 के व्यवस्थित विश्लेषण में औसत प्रभावी प्रति घंटा वेतन लगभग $2/घंटा पाया गया {cite}`hara2018data`।

सामग्री मॉडरेशन: विशेष रूप से हानिकारक रूप का अनुलेखन कार्य — ग्राफिक, हिंसक, और परेशान करने वाली सामग्री की समीक्षा — PTSD, अवसाद, और चिंता से जुड़ा हुआ है {cite}`newton2019trauma`।

नैतिक प्रथाएँ

उचित वेतन: अनुलेखन कार्यकर्ताओं को स्थानीय न्यूनतम वेतन पर या उससे ऊपर भुगतान करें।

कार्य दृश्यता: प्रकाशनों और उत्पाद प्रलेखन में उस श्रम को स्वीकार करें जो प्रशिक्षण डेटा बनाता है।

मानसिक स्वास्थ्य समर्थन: हानिकारक सामग्री की समीक्षा करने वाले कार्यकर्ताओं के लिए मनोवैज्ञानिक समर्थन, रोटेशन अनुसूचियाँ, और एक्सपोज़र सीमाएँ प्रदान करें।

अनुलेखन में गोपनीयता

Protected Health Information (PHI) और PII

अनुलेखन कार्यों में अक्सर संवेदनशील व्यक्तिगत डेटा शामिल होता है।

नियामक ढाँचे (HIPAA, GDPR) मुख्य सिद्धांत:

- **डेटा न्यूनीकरण:** केवल वह जानकारी साझा करें जो अनुलेखकों को कार्य पूरा करने के लिए चाहिए
- **डी-पहचान:** जहाँ संभव हो अनुलेखन से पहले PHI और PII हटाएँ
- **सहमति:** जहाँ वास्तविक उपयोगकर्ता डेटा अनुलेखित किया जाता है, उचित सहमति सुनिश्चित करें

प्रतिकूल अनुलेखन और डेटा विषाक्तता

HITL प्रणालियाँ एक हमले की सतह बनाती हैं: यदि कोई प्रतिकूल अनुलेखन प्रक्रिया को प्रभावित कर सकता है, तो वे मॉडल के व्यवहार को प्रभावित कर सकते हैं।

शमन: प्रति आइटम एकाधिक स्वतंत्र अनुलेखक; अनुलेखन पैटर्न पर आउटलायर पहचान; असामान्य सहमति या असहमति की निगरानी।

संस्थागत नैतिकता

पारदर्शिता और जवाबदेही

ML प्रणालियों से प्रभावित उपयोगकर्ताओं का यह समझने में एक वैध हित है कि वे प्रणालियाँ कैसे बनाई गई थीं।

डेटासेट के लिए डेटाशीट {cite}`gebru2021datasheets` डेटासेट उत्पत्ति, अनुलेखन प्रक्रियाओं, और ज्ञात सीमाओं के दस्तावेज़ीकरण के लिए एक संरचित टेम्पलेट प्रदान करता है।

> **See also:** एल्गोरिदमिक निष्पक्षता ढाँचा: {cite}`barocas2019fairness`। भूत कार्य और प्लेटफ़ॉर्म श्रम: Gray & Suri (2019)। डेटासेट के लिए डेटाशीट: {cite}`gebru2021datasheets`। सामग्री मॉडरेशन कार्यकर्ता कल्याण: {cite}`newton2019trauma`। अनुलेखक जनसांख्यिकी और NLP डेटासेट: {cite}`geva2019annotator`।

भविष्य की दिशाएँ

ह्यूमन-इन-द-लूप मशीन लर्निंग का क्षेत्र तेज़ी से बदल रहा है। फाउंडेशन मॉडल, LLM-अनुलेखक, और मानव-AI सहयोग के नए प्रतिमान HITL के अर्थशास्त्र और व्यवहार को उन तरीकों से फिर से आकार दे रहे हैं जो पाँच साल पहले भी कल्पनीय नहीं थे। यह अंतिम अध्याय उभरती दिशाओं और खुली समस्याओं के परिदृश्य का मानचित्र बनाता है।

फाउंडेशन मॉडल और अनुलेखन की बदलती भूमिका

फाउंडेशन मॉडल — बड़े मॉडल जो व्यापक डेटा पर पूर्व-प्रशिक्षित हैं और डाउनस्ट्रीम कार्यों के अनुकूल हो सकते हैं — HITL के अर्थशास्त्र को मूलतः बदल रहे हैं।

अनुलेखन बोझ कम करना

एक कार्य जिसके लिए पहले स्क्रैच से प्रशिक्षण के लिए हज़ारों लेबल किए गए उदाहरणों की आवश्यकता होती थी, फाउंडेशन मॉडल को फाइन-ट्यून करते समय केवल दर्जनों की आवश्यकता हो सकती है।

निहितार्थ: अनुलेखन प्रयास अब बेहतर निर्देशित है: - उच्च-गुणवत्ता मूल्यांकन सेट (यह मापने के लिए कि अनुकूलित मॉडल वास्तव में काम करता है या नहीं) - कठिन मामले और किनारे के मामले जिन्हें फाउंडेशन मॉडल गलत तरीके से संभालता है - कार्य-विशिष्ट उदाहरण जो मॉडल को कुछ ऐसा सिखाते हैं जो वह पूर्व-प्रशिक्षण से अनुमान नहीं लगा सकता

विनिर्देश के नए रूप

जब बेस मॉडल पहले से ही भाषा, कोड, और सामान्य ज्ञान को समझता है, तो उपयोगकर्ता लेबल किए गए उदाहरणों के माध्यम से नहीं बल्कि प्राकृतिक भाषा में उसके साथ संवाद कर सकते हैं।

अनुलेखक के रूप में LLMs

2023–2025 के सबसे महत्त्वपूर्ण विकासों में से एक **अनुलेखन ओरेकल के रूप में LLMs का उपयोग** है। सरल, अच्छी तरह परिभाषित वर्गीकरण कार्यों के लिए, LLM अनुलेखन अक्सर क्राउड-वर्कर सटीकता से मेल खाता है या उसके करीब आता है {cite}`gilardi2023chatgpt`।

LLM अनुलेखन कहाँ अच्छा काम करता है

- सरल, अच्छी तरह परिभाषित वर्गीकरण कार्य (भावना, विषय, इरादा)
- वे कार्य जहाँ मानव लेबल सांस्कृतिक सहमति को एन्कोड करते हैं जो LLM ने अवशोषित की है
- वे कार्य जहाँ अनुलेखन संदर्भों में सुसंगत है

LLM अनुलेखन कहाँ विफल होता है

- विशेष डोमेन कार्य जिनके लिए दुर्लभ विशेषज्ञता की आवश्यकता है
- ऐसे कार्य जिनके लिए स्थानीय सांस्कृतिक ज्ञान या भाषा भिन्नता की आवश्यकता है
- सुरक्षा और नुकसान कार्य

बड़े पैमाने पर कमज़ोर पर्यवेक्षण

लेबलिंग फ़ंक्शन (अध्याय 9) के माध्यम से **प्रोग्रामेटिक लेबलिंग** विषय विशेषज्ञों को उदाहरणों के बजाय कोड के रूप में अपने ज्ञान को व्यक्त करने की अनुमति देती है। Snorkel {cite}`ratner2017snorkel` और उसके उत्तराधिकारी काफी परिपक्व हो गए हैं।

सीमांत दिशाएँ: - **LLM-संवर्धित लेबलिंग फ़ंक्शन:** प्राकृतिक भाषा विवरण से लेबलिंग फ़ंक्शन उत्पन्न करने के लिए LLMs का उपयोग - **स्लाइस-आधारित अधिगम:** डेटा के महत्वपूर्ण उपसमुच्चय (स्लाइस) की पहचान करें जहाँ लेबलिंग फ़ंक्शन असहमत हों

मानव निगरानी के साथ निरंतर अधिगम

HITL निरंतर अधिगम में शामिल हैं: - वितरण बदलाव की निगरानी (स्वचालित) और बदले हुए उदाहरणों को मानव समीक्षा के लिए रूट करना - चयनात्मक पुनः प्रशिक्षण: मानव-अनुमोदित उदाहरणों को प्रशिक्षण डेटा में जोड़ा जाता है - प्रत्येक अपडेट के बाद मॉडल व्यवहार परिवर्तनों की मानव समीक्षा

स्केलेबल निगरानी

HITL ML में एक मूलभूत खुली समस्या **स्केलेबल निगरानी** {cite}`irving2018ai,bowman2022measuring` है: जैसे-जैसे AI प्रणालियाँ विशिष्ट डोमेन में मनुष्यों से अधिक सक्षम हो जाती हैं, हम सार्थक मानव निगरानी कैसे बनाए रखते हैं?

प्रस्तावित दृष्टिकोण {cite}`bowman2022measuring`:

बहस: दो AI प्रणालियाँ अलग-अलग निष्कर्षों के लिए तर्क देती हैं; एक मानव न्यायाधीश सीधे निष्कर्षों के बजाय तर्कों का मूल्यांकन करता है।

प्रवर्धन: मानव न्यायाधीश जटिल आउटपुट का मूल्यांकन करने में मदद के लिए AI सहायकों से परामर्श करते हैं।

प्रक्रिया पर्यवेक्षण: अंतिम आउटपुट का मूल्यांकन करने के बजाय, मनुष्य तर्क प्रक्रिया का मूल्यांकन करते हैं।

खुली अनुसंधान समस्याएँ

हम उन महत्त्वपूर्ण खुली समस्याओं की एक सूची के साथ समाप्त करते हैं जिन पर क्षेत्र सक्रिय रूप से काम कर रहा है:

1. **सक्रिय अधिगम में इष्टतम रुकना:** अगले अनुलेखन का सीमांत मूल्य कब लागत से नीचे है?
2. **कार्यों में अनुलेखन बजट आवंटन:** बहु-कार्य सेटिंग्स में, एक निश्चित अनुलेखन बजट को कार्यों में कैसे विभाजित किया जाना चाहिए?

3. **सक्रिय अधिगम में वितरण बदलाव:** सक्रिय अधिगम पक्षपाती लेबल सेट बनाता है। इस तरह प्रशिक्षित मॉडल को ठीक से कैसे अंशांकित किया जाए?
4. **पुरस्कार मॉडल सामान्यीकरण:** RLHF पुरस्कार मॉडल नए प्रॉम्प्ट-प्रतिक्रिया जोड़ियों पर सामान्यीकरण करने में विफल हो सकते हैं।
5. **स्केलेबल निगरानी:** जब AI प्रणालियाँ विशिष्ट डोमेन में मानव प्रदर्शन से अधिक हो जाती हैं तो हम मानव निगरानी कैसे बनाए रखते हैं?
6. **अनुलेखक मॉडलिंग:** अनुलेखक व्यवहार के लिए बेहतर सांख्यिकीय मॉडल।
7. **संरेखण का मूल्यांकन:** हमारे पास यह परीक्षण करने के लिए ग्राउंड-ट्रुथ परीक्षण नहीं हैं कि क्या कोई मॉडल मानव मूल्यों के साथ संरेखित है।
8. **उचित डेटा श्रम:** आर्थिक और संस्थागत संरचनाएँ जो सुनिश्चित करती हैं कि अनुलेखन कार्यकर्ताओं को उचित मुआवज़ा और सुरक्षा मिले।

> लक्ष्य मशीन के निर्णय से मानव के निर्णय को प्रतिस्थापित करना नहीं है, बल्कि ऐसी प्रणालियाँ बनाना है जहाँ दोनों का संयोजन अकेले किसी एक से बेहतर हो।

इस पुस्तक में उपकरण और तकनीकें — अनुलेखन, सक्रिय अधिगम, RLHF, वरीयता अधिगम, और बाकी सब — उस लक्ष्य के साधन हैं। जैसे-जैसे क्षेत्र विकसित होता है, विशिष्ट तकनीकें बदलेंगी। अंतर्निहित आकांक्षा — ऐसी प्रणालियाँ बनाना जो सक्षम और मानव इरादे के साथ वास्तव में संरेखित दोनों हों — बनी रहेगी।

> **See also:** स्केलेबल निगरानी और बहस: {cite}`bowman2022measuring`। Snorkel कमज़ोर पर्यवेक्षण: {cite}`ratner2017snorkel`। मानव-AI सहयोग के व्यापक भविष्य के लिए, {cite}`amershi2019software` देखें।

संदर्भ सूची

Table 1: all:

jupytext:
formats: md:myst
text_representation:
extension: .md
format_name: myst
kernelspec:
display_name: Python 3
language: python
name: python3

लाइमेन: प्रत्येक लूप में एक मानव

:::{admonition} इस अध्याय के विषय में नोट :class: important यह अध्याय एक **सट्टा डिज़ाइन निबंध** है, न कि एक अनुभवजन्य अध्ययन या सहकर्मी-समीक्षित योगदान। यह एक कल्पित प्रणाली आर्किटेक्चर का वर्णन करता है — Limen, एक वॉयस-फर्स्ट AI-नेटवि डेस्कटॉप OS — एक काम किए गए उदाहरण के रूप में कि पूर्ववर्ती अध्यायों से HITL सिद्धांत एक सुसंगत पूरे में कैसे संयोजित हो सकते हैं। यहाँ के दावे डिज़ाइन तर्क हैं, प्रयोगात्मक परिणाम नहीं। इन्हें प्रेरित डिज़ाइन औचित्य के रूप में पढ़ा जाना चाहिए, न कि मान्य इंजीनियरिंग निष्कर्षों के रूप में। :::

इस पुस्तक के प्रत्येक अध्याय ने HITL ML को एक डिज़ाइन दर्शन के रूप में वर्णित किया है: मानव भागीदारी को अधिगम प्रणालियों में जानबूझकर, कुशल, और ईमानदार बनाने के लिए सिद्धांतों का एक सेट। यह अध्याय वर्णन करता है कि उस दर्शन को एक प्रथम सिद्धांत के रूप में लागू करने पर क्या होता है — न केवल एकल प्रणाली पर, बल्कि पूरे ऑपरेटिंग वातावरण पर।

Limen एक वॉयस-फर्स्ट, AI-नेटवि डेस्कटॉप ऑपरेटिंग सिस्टम है जो इस आधार पर बना है कि मानव हमेशा लूप में है, न एक बाधा के रूप में जिसे दूर किया जाना है, बल्कि उस आयोजन सिद्धांत के रूप में जिसके चारों ओर प्रत्येक उपप्रणाली डिज़ाइन की गई है। नाम जानबूझकर चुना गया है: limen "दहलीज़" के लिए लैटिन शब्द है। अवधारणात्मक मनोविज्ञान में, limen वह सीमा है जो जो माना जाता है और जो नहीं माना जाता उसके बीच है। एक ऑपरेटिंग सिस्टम के लिए, limen मानव इरादे और मशीन क्रिया के बीच की सीमा है।

पारंपरिक OS डिज़ाइन के साथ समस्या

एक पारंपरिक ऑपरेटिंग सिस्टम मनुष्यों के लिए डिज़ाइन नहीं किया गया है। यह कार्यक्रमों के लिए डिज़ाइन किया गया है। मानव को अमूर्तता की एक परत के माध्यम से समायोजित किया जाता है — एक ग्राफिकल इंटरफ़ेस, एक फ़ाइल ब्राउज़र, एक टर्मिनल — जो प्रक्रियाओं, मेमोरी पतों, और फ़ाइल डिस्क्रिप्टर के लिए निर्मित एक सब्सट्रेट के ऊपर बैठता है।

वे धारणाएँ अब मान्य नहीं हैं। अधिकांश कार्यों के लिए अधिकांश उपयोगकर्ताओं के लिए बाधा कंप्यूट नहीं है। यह मानव ध्यान है: संदर्भ-स्विचिंग की लागत, सही फ़ाइल खोजने की, सही क्वेरी बनाने की। Limen इसे उलट देता है। प्रोग्राम मानव की भाषा बोलते हैं।

दहलीज़ पर आर्किटेक्चर

Limen का आर्किटेक्चर एक एकल सिद्धांत के चारों ओर संगठित है: **प्रत्येक अंतःक्रिया एक घटना है**, और प्रत्येक घटना मानव के सिखाने, सुधारने, या पुष्टि करने का अवसर है।

घटना परत: WID

आधार पर **WID** (Waldiez ID प्रणाली, Limen के लोकल-फर्स्ट आर्किटेक्चर के लिए अनुकूलित) है — एक कारणता-जागरूक घटना ट्रैकिंग प्रणाली जो न केवल यह रिकॉर्ड करती है कि क्या हुआ, बल्कि यह भी कि इसका क्या कारण था,

और इसने क्या कारण बनाया।

पारंपरिक लॉगिंग पूछती है: क्या हुआ? WID पूछता है: यह क्यों हुआ, और इसके बाद क्या हुआ?

:::{admonition} HITL अवसंरचना के रूप में कारण घटना ट्रैकिंग :class: note WID का डिज़ाइन एक व्यापक सिद्धांत को दर्शाता है: HITL अवसंरचना को "प्रणाली ने यह क्यों किया?" यह पूछना आसान बनाना चाहिए — न केवल "इसने क्या किया?" सुधार लक्षणों को ठीक करते हैं। कारण के साथ, वे कारणों को ठीक कर सकते हैं। :::

धारणा परत: वॉयस-फर्स्ट

Limen का प्राथमिक इनपुट तौर-तरीका वॉयस है, जिसे Whisper ONNX अनुमान पाइपलाइन का उपयोग करके स्थानीय रूप से संसाधित किया जाता है।

वॉयस सबसे प्राकृतिक मानव आउटपुट चैनल है अधिकांश लोगों के लिए। इसके लिए कोई प्रशिक्षण, कोई शारीरिक निपुणता, और कोई प्रणाली के आंतरिक संगठन का ज्ञान नहीं चाहिए।

स्थानीय प्रसंस्करण गोपनीयता को संरक्षित करता है। वॉयस डेटा डिवाइस नहीं छोड़ता।

वॉयस एक प्राकृतिक प्रतिक्रिया लूप बनाता है। जब प्रणाली प्रतिक्रिया देती है, उपयोगकर्ता की प्रतिक्रिया — बोलना जारी रखना, पुनः वाक्यांश बनाना, "नहीं, यह सही नहीं है" कहना — स्वयं एक संकेत है।

फॉलबैक श्रृंखला उतनी ही महत्त्वपूर्ण है जितनी प्राथमिक तौर-तरीका। दादी परीक्षण (अध्याय 5 देखें) एक सुगमता के बाद का विचार नहीं है; यह एक प्रथम-वर्ग आर्किटेक्चरल बाधा है।

इंटेलिजेंस परत: मल्टी-LLM रूटिंग

Limen एक एकल भाषा मॉडल पर निर्भर नहीं करता। यह कार्य प्रकार, आवश्यक विलंबता, गोपनीयता आवश्यकताओं, और विश्वास के आधार पर एक संरचित निर्णय वृक्ष के माध्यम से अनुरोध रूट करता है:

1. **स्थानीय छोटा मॉडल** (हमेशा पहले): तेज़, निजी, नियमित कार्यों को संभालता है
2. **स्थानीय बड़ा मॉडल** (जब छोटे मॉडल का विश्वास कम हो): धीमा लेकिन अधिक सक्षम
3. **रिमोट मॉडल** (जब स्थानीय विफल हो और उपयोगकर्ता ने अनुमति दी हो): एग्ज़िट हैच

यह संरचना नई नहीं है — यह अध्याय 4 में वर्णित सक्रिय अधिगम क्वेरी रणनीति का अनुमान-समय समतुल्य है।

अंतःक्रिया डिज़ाइन

तात्कालिकता

Limen को उस अर्थ में तात्कालिकता के लिए डिज़ाइन किया गया है जैसा अध्याय 5 परिभाषित करता है: उपयोगकर्ता अपनी प्रतिक्रिया का प्रभाव अनुभव करता है।

बुद्धिमत्ता

एक आवर्ती विषय जो IML साहित्य में है वह है **बुद्धिमत्ता आवश्यकता**: मनुष्य केवल उस मॉडल का मार्गदर्शन कर सकते हैं जिसे वे कम से कम लगभग समझते हैं। Limen इसे इंटरफ़ेस में सतह पर लाता है: जब प्रणाली कोई निर्णय करती है, तो यह संक्षेप में बताती है क्यों। "मैं वह परियोजना खोल रहा हूँ जिस पर आपने सबसे हाल ही में काम किया — क्या यह सही है?"

संगति और बहाव

एक दीर्घकालिक इंटरैक्टिव प्रणाली में उत्पन्न होने वाली समस्या **व्यवहार बहाव** है। Limen आवधिक संगति जाँच के माध्यम से इसे संबोधित करता है। प्रणाली ऐतिहासिक निर्णयों को उपयोगकर्ता के सामने लाती है: "कुछ हफ्ते पहले, आपने मुझसे X करने के लिए कहा था। क्या आप अभी भी यही चाहेंगे?"

HITL प्रणाली के रूप में Limen

इस पुस्तक के लेंस से Limen के आर्किटेक्चर को देखते हुए, डिज़ाइन निर्णय प्रत्यक्ष रूप से प्रत्येक भाग में विकसित अवधारणाओं पर मानचित्रित होते हैं।

भाग I (नींव): Limen प्रत्येक अंतःक्रिया को एक मानव–मशीन अंतःक्रिया घटना मानता है।

भाग II (मूल तकनीकें): सक्रिय अधिगम विश्वास-आधारित एस्केलेशन चेन के रूप में प्रकट होता है। इंटरैक्टिव ML वास्तविक-समय अपडेट चक्र में प्रकट होता है।

भाग III (मानव प्रतिक्रिया से अधिगम): अध्याय 8 में वर्णित वरीयता अधिगम रूटिंग नीति अपडेट में दिखाई देता है।

भाग VI (नैतिकता): लोकल-फर्स्ट, गोपनीयता-संरक्षण डिज़ाइन एक नैतिक विकल्प है, न केवल एक तकनीकी।

गहरी बात

Limen एक उत्पाद पिच नहीं है। यह निर्माण द्वारा एक तर्क है।

तर्क यह है: यदि आप HITL ML के सिद्धांतों को गंभीरता से लेते हैं — यदि आप मानते हैं कि मानव प्रतिक्रिया एक समझे जाने वाला संकेत है न कि न्यूनतम की जाने वाली लागत, कि मानव हमेशा लूप में है भले ही डिज़ाइनर अन्यथा नाटक करते हों, कि संरेखण एक बार की घटना के बजाय एक चल रही प्रक्रिया है — तो आप कुछ ऐसा बनाते हैं जो Limen जैसा दिखता है।

HITL ML के क्षेत्र ने विशिष्ट मॉडलों और विशिष्ट कार्यों के लूप में मनुष्यों को कैसे डालें इसका वर्णन करने में काफी ऊर्जा खर्च की है। अगला प्रश्न यह है कि क्या हम उन्हीं सिद्धांतों के आसपास पूरे वातावरण को डिज़ाइन कर सकते हैं।

Limen उस प्रश्न का एक उत्तर है।

दहलीज़ कुछ ऐसी नहीं है जिसे आप पार करते हैं और पीछे छोड़ देते हैं। यह वह जगह है जहाँ आप रहते हैं।

> **See also:** Limen के अंतःक्रिया डिज़ाइन के अंतर्गत IML सिद्धांत अध्याय 5 में विकसित हैं। रूटिंग नीति के पीछे वरीयता अधिगम दृष्टिकोण अध्याय 8 में औपचारिक है। WID का कारणता मॉडल अध्याय 14 में सर्वेक्षण किए गए घटना एट्रिब्यूशन साहित्य पर आधारित है। दादी परीक्षण, अध्याय 5 में पेश किया गया, Limen की प्राथमिक इंटरफ़ेस डिज़ाइन बाधा है।

विदाई पर

किसी बिंदु पर मैं एक PhD कार्यक्रम में नामांकित था। अनुसंधान मशीन लर्निंग पर था। संस्था वास्तविक थी। इरादा सच्चा था।

और फिर मैंने रुकना तय किया।

इसलिए नहीं कि विषय का महत्त्व कम हो गया — यह अब उससे अधिक महत्त्वपूर्ण है जितना तब था जब मैंने शुरू किया था। इसलिए नहीं कि काम बहुत कठिन था — यह पुस्तक, अपने तरीके से, एक थीसिस से भी कठिन है। बल्कि इसलिए कि साहित्य समीक्षा और उस शोधपत्र के तीसरे संशोधन के बीच कहीं जिसे ग्यारह लोग पढ़ते, मैंने यह धागा खो दिया कि यह सब करने योग्य क्यों था।

PhD प्रणाली एक लूप है। आप उसमें एक प्रश्नों वाले मानव के रूप में प्रवेश करते हैं। लूप आपको उन प्रश्नों को शोधपत्रों में, और शोधपत्रों को उद्धरणों में, और उद्धरणों को प्रगति के आभास में परिवर्तित करना सिखाता है। किसी बिंदु पर लूप यह नहीं पूछता कि क्या आउटपुट लूप के बाहर किसी के लिए उपयोगी है। यह प्रश्न, शब्द के तकनीकी अर्थ में, scope से बाहर है।

मैं इस पर ध्यान देने वाला पहला नहीं हूँ। मैं अंतिम नहीं होऊँगा। यह आलोचना नहीं है — यह एक विवरण है। लूप वास्तविक चीज़ें उत्पन्न करता है: कठोर विधियाँ, संचित ज्ञान, प्रशिक्षित शोधकर्ता। मुझे उसके अंदर बिताए समय का कोई पछतावा नहीं है। लेकिन मैंने अंततः यह नोटिस किया कि मैं उसमें था।

छोड़ना कोई नाटकीय निर्णय नहीं था। यह एक धीमी पहचान थी कि जो चीज़ मैं वास्तव में बनाना चाहता था उसके लिए किसी समिति की अनुमति की आवश्यकता नहीं थी। कि जिन लोगों तक मैं पहुँचना चाहता था — व्यवसायी, छात्र, वास्तविक प्रणालियों के बारे में वास्तविक निर्णय लेने वाले इंजीनियर — वे किसी औपचारिक रूप से मान्य थीसिस की प्रतीक्षा नहीं कर रहे थे। कि जो मैं जानता था उसके साथ सबसे ईमानदार काम यह था कि मैं उसे ऐसे रूप में लिख दूँ जिसे कोई वास्तव में उपयोग कर सके।

तो मैंने किया।

यह पुस्तक PhD थीसिस नहीं है। इसकी कोई संस्थागत संबद्धता नहीं है, कोई वित्त पोषण स्वीकृति नहीं है, कोई नैतिकता बोर्ड अनुमोदन नहीं है, कोई परीक्षा नहीं है। यह अकादमिया द्वारा ज्ञान उत्पादन मापने के लिए उपयोग किए जाने वाले किसी मापदंड में गिना नहीं जाएगा।

यह भी है — और मैं यह झूठी विनम्रता के बिना कहता हूँ, क्योंकि झूठी विनम्रता अपने आप में एक तरह की बेईमानी होगी — थीसिस से अधिक पूर्ण, अधिक वर्तमान, अधिक पठनीय, और अधिक उपयोगी।

मैं लूप में एक मानव हूँ। मैं एक PhD कार्यक्रम के लूप में था, और मैं उससे बाहर निकला। अब मैं लूपों के बारे में लिखने के लूप में हूँ। आप उसके बारे में पढ़ने के लूप में हैं।

हम में से किसी ने भी इन लूपों में पूरी तरह स्वतंत्र रूप से प्रवेश नहीं किया। लेकिन हम कभी-कभी यह चुन सकते हैं कि हम किसमें हैं, और क्यों, और क्या वे कुछ ऐसा उत्पन्न कर रहे हैं जो उत्पन्न करने योग्य है — इसके बारे में ईमानदार रहें।

यह पुस्तक उन प्रश्नों का मेरा उत्तर है।

यह इस्तीफ़ा पत्र नहीं है। इस्तीफ़ा एक नौकरी का तात्पर्य करता है, और नौकरी का तात्पर्य है कि किसी और ने शर्तें तय कीं। यह कुछ और है: उस समय के साथ मैंने क्या करना चुना इसका एक रिकॉर्ड, और एक शांत तर्क कि चुनाव सही था।

आप इसके निर्णायक हो सकते हैं। आप, आखिरकार, लूप में एक मानव हैं।

— लेखक