Contents

Ujifunzaji wa Mashine wenye Binadamu Katikati: Imekosewa Kuelewa **1**
Muundo wa Kitabu 1

Tamko la Uhalisi **3**

Muhtasari **5**

Shukrani **7**

Ujifunzaji wa Mashine wenye Binadamu Katikati ni Nini? **9**
Mkanganyiko wa Otomatiki 9
Kufafanua HITL ML 9
Historia Fupi 10
Kwa Nini HITL? Hoja kwa Hukumu ya Binadamu 11
Mzunguko wa Maoni 12
Kinachosi HITL 12
Uchumi wa Maoni ya Binadamu 13
Muhtasari wa Kitabu cha Mwongozo 13

Uainishaji wa Mwingiliano kati ya Binadamu na Mashine **15**
Viwango vya Otomatiki 15
Ushiriki wa Binadamu wa Tendaji dhidi ya wa Passiv 16
Mweka Maelezo Mmoja dhidi ya Wengi 17
Mfumo wa Umoja 17

Uwekaji Maelezo na Ulabelishaji wa Data **19**
Aina za Uwekaji Maelezo 19
Mwongozo wa Uwekaji Maelezo 20
Kupima Ubora wa Uwekaji Maelezo: Makubaliano ya Wawekaji Maelezo 20
Kushughulikia Kutokubaliana 22
Kelele za Lebo na Athari Zake 23
Gharama ya Uwekaji Maelezo na Kiwango cha Uzalishaji 24

Ujifunzaji Tendaji **25**
Mpangilio wa Ujifunzaji Tendaji 25
Misingi ya Kinadharia 25
Mikakati ya Maswali 26
Makadirio ya Wasiwasi kwa Mifano ya Kina 27
Mzunguko Kamili wa Ujifunzaji Tendaji 29
Tatizo la Kuanza Baridi 31
Ujifunzaji Tendaji wa Hali ya Vifurushi 31

Vigezo vya Kusimama . . . 31
Wakati Ujifunzaji Tendaji Unafanya Kazi (na Wakati Haifanyi) . . . 32

Ujifunzaji wa Mashine wa Mwingiliano **33**
Kanuni za Ujifunzaji wa Mashine wa Mwingiliano . . . 33
Ulinganisho na Ujifunzaji Tendaji . . . 33
Mwingiliano wa Hiari Iliyochanganywa . . . 34
Mambo ya Kibinadamu katika IML . . . 34
Aina za Maoni ya IML katika Mazoezi . . . 35
Mfano wa Kesi: Google Teachable Machine . . . 35
Kutekeleza Mzunguko Rahisi wa IML . . . 36
Mtihani wa Bibi . . . 37
IML na Mifano ya Msingi . . . 38

Ujifunzaji wa Kuimarisha kutoka kwa Maoni ya Binadamu **39**
Tatizo la Upatanisho . . . 39
Mfumo wa RLHF . . . 39
Onyesho Lililorahisishwa la RLHF . . . 41
Changamoto katika RLHF . . . 42
AI ya Kikatiba (RLAIF) . . . 43

Kujifunza kutoka kwa Maonyesho **45**
Kuiga Kitabia . . . 45
Ujifunzaji wa Kuimarisha wa Nyuma . . . 46
GAIL: Kujifunza kwa Kuiga kwa Ushindani wa Uzalishaji . . . 46
Kuiga Kitabia katika NLP: Mfano wa Vitendo . . . 47
Ulinganisho wa Mbinu za Kujifunza kwa Kuiga . . . 48
Matumizi . . . 49

Kujifunza kutoka kwa Ulinganisho na Upangaji wa Daraja **51**
Kwa Nini Ulinganisho ni Bora Kuliko Alamu . . . 51
Mfano wa Bradley-Terry . . . 52
Mfano wa Thurstone . . . 53
Ujumuishaji wa Upangaji . . . 54
Banditi za Kupigana . . . 54
Kujifunza Mapendeleo kwa Mifano ya Lugha . . . 54
Kukusanya Data ya Mapendeleo ya Ubora wa Juu . . . 55

HITL katika Usindikaji wa Lugha Asilia **57**
Tatizo la Kijenzi katika Uwekaji Maelezo wa NLP . . . 57
Uwekaji Maelezo wa Uainishaji wa Maandishi . . . 58
Utambuzi wa Maneno Maalum . . . 58
Uchimbaji wa Uhusiano na Uwekaji Maelezo wa Kisemantiki . . . 59
Uhariri Baada ya Tafsiri ya Mashine (MTPE) . . . 59
AI ya Mazungumzo na Uwekaji Maelezo wa Mazungumzo . . . 59
Uwekaji Lebo wa Programu na Usimamizi Dhaifu . . . 60
RLHF kwa Mifano ya Lugha: Ukweli wa Uwekaji Maelezo . . . 61
Mzunguko wa Maoni wa Uwekaji Maelezo–Mfano . . . 62
Tathmini ya Mifano ya NLP ya Uzalishaji . . . 62

HITL katika Mwono wa Kompyuta **65**
Jinsi Maamuzi ya Uwekaji Maelezo Yanavyokuwa Upendeleo wa Mfano . . . 65
Uwekaji Maelezo wa Uainishaji wa Picha . . . 66

Ugunduzi wa Kitu: Uwekaji Maelezo wa Sanduku la Mpaka . . . 66
Ugawanyiko wa Kisemantiki na wa Kitengo . . . 68
Ujifunzaji Tendaji kwa Mwono wa Kompyuta . . . 68
Kujifunza Nusu-Usimamizi na Mwongozo wa Binadamu . . . 69
Uwekaji Maelezo wa Video . . . 70

HITL katika Afya na Sayansi **73**
Uchambuzi wa Picha za Kimatibabu . . . 73
Uwekaji Maelezo wa NLP ya Kliniki . . . 74
Mambo ya Kisheria . . . 75
Uwekaji Maelezo wa Data ya Kisayansi . . . 75
Kusimamia Wawekaji Maelezo Wataalamu . . . 77
Mfumo wa Ujifunzaji Tendaji wa HITL kwa Picha za Kimatibabu . . . 77

Majukwaa na Zana za Uwekaji Maelezo **81**
Mazingira ya Jukwaa la Uwekaji Maelezo . . . 81
Ulinganisho wa Kipengele cha Jukwaa la Uwekaji Maelezo . . . 82
Uwekaji Maelezo kama Msimbo . . . 83

Ushirikiano wa Umma na Udhibiti wa Ubora **85**
Majukwaa ya Ushirikiano wa Umma . . . 85
Muundo wa Kazi kwa Ushirikiano wa Umma . . . 85
Mifano ya Takwimu ya Ujumuishaji wa Lebo . . . 87
Mkakati wa Uziada na Ujumuishaji . . . 89

Tathmini na Vipimo **91**
Vipimo vinavyozingatia Mfano . . . 91
Vipimo vya Ufanisi wa Uwekaji Maelezo . . . 92
Tathmini ya Binadamu . . . 93
Kupima Ulinganifu na Nia ya Binadamu . . . 95
Upimaji wa A/B katika Mifumo Iliyotekelezwa . . . 95

Usawa, Upendeleo, na Maadili **97**
Vyanzo vya Upendeleo katika Mifumo ya HITL . . . 97
Usawa katika Mifumo ya HITL . . . 98
Ustawi wa Wawekaji Maelezo . . . 99
Faragha katika Uwekaji Maelezo . . . 99
Uwekaji Maelezo wa Adui na Uchafuzi wa Data . . . 100
Maadili ya Kitaasisi . . . 100

Mwelekeo wa Baadaye **103**
Mifano ya Msingi na Jukumu Linaloobadilika la Uwekaji Maelezo . . . 103
LLMs kama Wawekaji Maelezo . . . 104
Usimamizi Dhaifu kwa Kiwango Kikubwa . . . 104
Kujifunza kwa Kuendelea kwa Usimamizi wa Binadamu . . . 105
HITL ya Pande Nyingi . . . 105
Usimamizi Unaoweza Kupanuka . . . 105
Mgawanyiko wa Kazi Unaobadilika . . . 106
Matatizo ya Wazi ya Utafiti . . . 106

Orodha ya Marejeo **109**

Limen: Binadamu Katikati ya Kila Kitu **111**

Tatizo na Muundo wa Kawaida wa OS 111
Usanifu kwenye Kizingiti 112
Muundo wa Mwingiliano 113
Limen kama Mfumo wa HITL 114
Hoja ya Kina 115

Kuhusu Kuondoka **117**

Ujifunzaji wa Mashine wenye Binadamu Katikati: Imekosewa Kuelewa

Lazaros Toumanidis

Mwongozo huu unachunguza moja ya maeneo muhimu zaidi — na yanayokosewa kuelewa — ya akili bandia ya kisasa: kuunganisha binadamu katika mzunguko wa ujifunzaji. Kuanzia uwekaji maelezo wa data na ujifunzaji tendaji hadi ujifunzaji wa kuimarisha kutoka kwa maoni ya binadamu (RLHF) na kujifunza kutoka kwa maonyesho, hukumu ya binadamu inabaki kuwa ya thamani kubwa.

Kitabu hiki kinalenga watafiti, wahandisi, na wanafunzi wanaotaka kuelewa wakati, kwa nini, na jinsi binadamu wanapaswa kushiriki katika mzunguko wa ujifunzaji.

:::{admonition} Toleo la Kiswahili :class: note Hili ni tafsiri ya Kiswahili. Toleo la asili la Kiingereza ndilo rejeleo kuu. Baadhi ya sura za kiufundi zinaweza bado ziko katika hatua ya ukalimaji. :::

Muundo wa Kitabu

Sehemu ya I — Misingi — inaweka mfumo wa dhana: maana ya ujifunzaji wa mashine wenye binadamu katikati na jinsi viwango vya otomatiki vinavyoainishwa.

Sehemu ya II — Mbinu za Msingi — inashughulikia mbinu za msingi: uwekaji maelezo wa data, ujifunzaji tendaji, na ujifunzaji wa mashine wa mwingiliano.

Sehemu ya III — Kujifunza kutoka kwa Maoni ya Binadamu — inashughulikia RLHF, kujifunza kutoka kwa maonyesho, na kujifunza kutoka kwa ulinganisho.

Sehemu ya IV — Matumizi — inachunguza mifano ya vitendo katika usindikaji wa lugha asilia, mwono wa kompyuta, na mifumo ya matibabu.

Sehemu ya V — Mifumo na Mazoezi — inashughulikia zana, majukwaa, na vipimo vinavyohitajika katika kila mfumo wenye binadamu katikati.

Sehemu ya VI — Maadili na Mwelekeo wa Baadaye — inashughulikia maswali ya usawa, upendeleo, na mustakabali wa uhusiano kati ya binadamu na algorithm.

Tamko la Uhalisi

Imewasilishwa kwa sehemu ya kutokukamilisha mahitaji ya shahada ya Uzamivu.

Natamka rasmi kwamba kazi iliyowasilishwa katika kitabu hiki cha mwongozo ni yangu mwenyewe, isipokuwa pale ambapo si yangu.

Mawazo yaliyomo katika kurasa hizi yalizalishwa kwa msaada wa: watafiti waliochapisha makala na mara kwa mara kuyaweka nyuma ya vizuizi vya malipo; wawekaji maelezo ambao kazi yao ilifanya mifano iwezekane lakini majina yao hayaonekani katika sehemu yoyote ya shukrani; wachangiaji wa programu huria ambao waliandika maktaba zitumiwazo katika kila mfano wa msimbo; na maandishi yaliyokusanywa ya ustaarabu wa binadamu, yaliyoingizwa na kukandamizwa na mifano mikubwa ya lugha ambayo haina maoni yoyote kuhusu yote hayo.

Makosa ni yangu. Maarifa yalikuwa ya ushirikiano.

Nathibitisha kwamba kazi hii haikuwasilishwa kwa shahada nyingine yoyote au sifa ya kitaalamu, tuzo ya kitaaluma, ruzuku, kesi ya ukodishaji wa kazi, au chapisho la LinkedIn, isipokuwa kama imesemwa vinginevyo.

Nathibitisha zaidi kwamba hakuna sehemu ya ulinganisho wa SOTA (Hali ya Sanaa) iliyojumuishwa katika kazi hii. Msomaji hataipata jedwali la mbinu 47 zilizopangwa kwenye vipimo 12, ambapo mbinu inayopendekezwa inafikia maboresho muhimu kwa kiasi cha takwimu kwenye 9 kati yao ($\dagger p < 0.05$). Hii si kwa sababu jedwali kama hilo halikuweza kujengwa, bali kwa sababu ujenzi wake ungekuwa nje ya lengo.

Lengo ni hili: binadamu yuko katika mzunguko. Amekuwa daima. Kitabu hiki kinajaribu kuelewa maana ya hilo.

Imesainiwa: Binadamu katika Mzunguko

Tarehe: Wakati wowote unaposoma hii

Taasisi: Hakuna. Hiyo ndiyo lengo.

Kuhusu mada ndogo :class: note

Kutoelewwa kinarejelea uwanja huu, jukumu la binadamu ndani yake, na msomaji — vyote kwa wakati mmoja. Ukifikiri kinarejelea wewe peke yako, unaweza kuwa sahihi. Ukifikiri kinarejelea mashine peke yake, unathibitisha hoja ya mada ndogo.

Muhtasari

Ujifunzaji wa Mashine wenye Binadamu Katikati: Kutoelewwa

Hadithi inayotawala katika ujifunzaji wa mashine inamwona binadamu kama mshiriki wa muda mfupi — anayehudhuria wakati wa ukusanyaji wa data na mafunzo ya mfano, kisha anaondolewa polepole kadri otomatiki inavyoimarika. Kitabu hiki cha mwongozo kinadai kwamba hadithi hiyo ni ya uongo, imekuwa ya uongo tangu mwanzo, na kwamba kuelewa *kwa nini* ni ya uongo ni moja ya mambo yenye manufaa zaidi kwa vitendo ambayo mtaalamu wa ujifunzaji wa mashine anaweza kufanya.

Ujifunzaji wa Mashine wenye Binadamu Katikati (HITL) ni taaluma ya kufanya ushiriki wa binadamu katika mifumo ya kujifunza kuwa wa makusudi, uliopangwa, na unaoendelea. Badala ya kuona maoni ya binadamu kama gharama inayostahili kupunguzwa, HITL inayaona kama ishara ya kueleweka: inatoka wapi, inaweka nini, jinsi ya kuikusanya kwa ufanisi, na jinsi ya kuiingiza kwa uaminifu katika mifano inayofanya kama wabunifu na watumiaji wake wanavyokusudia kweli.

Kitabu hiki cha mwongozo kinatoa matibabu ya kina ya uwanja huu katika sehemu sita. Sehemu ya I inaweka misingi na uainishaji wa mwingiliano kati ya binadamu na mashine. Sehemu ya II inashughulikia mbinu za kihistoria: uwekaji maelezo na ulabelishaji, ujifunzaji tendaji, na ujifunzaji wa mashine wa mwingiliano. Sehemu ya III inazungumzia mifumo ya kisasa ya upatanisho: ujifunzaji wa kuimarisha kutoka kwa maoni ya binadamu (RLHF), kujifunza kutoka kwa maonyesho, na kujifunza upendeleo. Sehemu ya IV inatumia mbinu hizi kwenye usindikaji wa lugha asilia, mwono wa kompyuta, na huduma ya afya. Sehemu ya V inashughulikia mifumo na miundombinu ya HITL kwa kiwango kikubwa: majukwaa ya uwekaji maelezo, udhibiti wa ubora wa ushirikiano wa umma, na mbinu za tathmini. Sehemu ya VI inachunguza maadili na mustakabali wa uwanja huu.

Kila sura inajumuisha ufafanuzi rasmi, matibabu ya kihesabu inapohitajika, na mifano ya msimbo inayoweza kukimbiwa kwa kujitegemea katika Python.

Kitabu hiki cha mwongozo kimekusudiwa kwa wataalamu wanaojenga mifumo ya ML, watafiti wanaoisomea, wanafunzi wanaojifunza kuhusu hiyo, na kila mtu ambaye amewahi kujiuliza ni nani aliyeweka lebo kwenye data iliyofunza mfano ambao ulifanya uamuzi ulioathiri maisha yake.

Jibu, katika hali zote, ni: binadamu. Mara nyingi malipo duni. Kamwe hawatajwi. Daima wako katika mzunguko.

Maneno muhimu: ujifunzaji wa mashine wenye binadamu katikati, ujifunzaji tendaji, uwekaji maelezo wa data, ujifunzaji wa kuimarisha kutoka kwa maoni ya binadamu, RLHF, kujifunza upendeleo, ushirikiano wa umma, ujifunzaji wa mashine wa mwingiliano, upatanisho wa AI, AI inayowajibika

Uainishaji wa mada: Ujifunzaji wa Mashine · Mwingiliano kati ya Binadamu na Kompyuta · Akili Bandia · Sayansi ya Data

Idadi ya maneno: Inayotosha.

Shukrani

Kila kitabu kuhusu ujifunzaji wa mashine wenye binadamu katikati kinapaswa kuanza na binadamu walioko katika mzunguko wake wenyewe.

Wawekaji maelezo. Kitabu hiki cha mwongozo kinahusu, kwa sehemu, ninyi — kuhusu kazi yenu, hukumu yenu, na ukweli kwamba majina yenu hayaonekani katika kadi yoyote ya mkusanyiko wa data, shukrani za makala, au taarifa yoyote ya vyombo vya habari kuhusu mifano ambayo kazi yenu iliiwezesha. Uwanja huu unaanza kujizingatia hili. Bado una njia ndefu ya kwenda.

Wachangiaji wa programu huria ambao maktaba zao zinatumika katika kila mfano wa msimbo: jumuiya ya NumPy (tangu 2006), wachangiaji wa scikit-learn (tangu 2007), timu ya PyTorch, jumuiya ya Hugging Face, na watunzaji wasio na hesabu wanaoshughulikia hitilafu za programu wikendi bila malipo wala kutambuliwa. Kompyuta za kisayansi zimejengwa juu ya kazi hii isiyoonekana.

Watafiti waliochapisha kazi yao waziwazi — katika nakala za awali za arXiv, maeneo ya ufikiaji wazi, na hazina za GitHub — kuifanya iwezekane kwa wataalamu kujifunza bila ufikiaji wa kitaasisi. Na watafiti waliokagua makala kwa makini na kwa uaminifu, aina ya uwekaji maelezo wa wataalam ambayo taaluma ya kitaaluma kwa namna fulani imejishawishi si kazi.

Walimu waliofanya maarifa yawe ya ufikiaji: wablogu, waandishi wa mafunzo, wajibu wa Stack Overflow, wawasilishaji wa mikutano walioweka slaidi zao wazi. Kujifunza hakutokei kwa kutengwa, na hakutokei bila watu wanaokuwa tayari kueleza mambo kwa wageni.

Wakosoaji. Watafiti walioonyesha kwamba mkusanyiko wa data unabeba upendeleo, kwamba asili ya wawekaji maelezo huathiri tabia ya mfano, kwamba binadamu walioko katika mzunguko mara nyingi ni washiriki wanaoweza kuumizwa zaidi katika mfumo. Uwanja huu unafaidika zaidi na msisitizo wenu wa kuuliza maswali yasiyofurahi.

Kuna mambo yanayojulikana yanayojulikana — mambo tunayoyajua kwamba tunayajua.
Kuna mambo yanayojulikana yasiyojulikana — mambo tunayoyajua kwamba hatuyajui.
Kuna mambo yasiyojulikana yasiyojulikana — mambo tusiyoyajua kwamba hatuyajui.

Na kisha kuna mambo ambayo kila mtu katika uwanja huu anayajua lakini ambayo kamwe hayafikii makala za kisayansi.

Kitabu hiki cha mwongozo ni, kwa sehemu, jaribio la kategoria ya mwisho.

Ukichangia katika uwanja huu na huoni jina lako hapa: umetambuliwa. Mzunguko unakujumuisha.

Ujifunzaji wa Mashine wenye Binadamu Katikati ni Nini?

> *Mashine inayoweza kujifunza kutoka kwa uzoefu… lakini tu ukiipa uzoefu sahihi. – kwa kufuata Alan Turing*

Mkanganyiko wa Otomatiki

Kila wimbi jipya la otomatiki huunda mahitaji mapya ya makini ya binadamu. Wakati mashirika ya ndege yalianzisha rubani otomatiki, marubani wakawa wasimamizi — hawajibikii udhibiti wa dakika kwa dakika bali kwa kazi ngumu zaidi ya kujua *wakati* wa kuchukua udhibiti. Wakati maduka makubwa yalianzisha malipo ya kujihudumia, waligundua kwamba mifumo hiyo inahitaji usimamizi zaidi wa binadamu kwa kila muamala kuliko wahesabu wa kawaida, si chini. Na wakati ujifunzaji wa mashine ulianza kufanya maamuzi kwa kiwango kikubwa — katika dawa, fedha, uajiri, na usimamizi wa maudhui — iliunda mahitaji makubwa, yanayoendelea ya hukumu ya binadamu.

Hii ndiyo **mkanganyiko wa otomatiki** {cite}`bainbridge1983ironies`: kadri mfumo otomatiki unavyoimarika, ndivyo kushindwa kwake kunakuwa na matokeo makubwa zaidi, na kwa hivyo ndivyo usimamizi madhubuti wa binadamu unavyohitajika zaidi. Ujifunzaji wa mashine si ubaguzi.

Ujifunzaji wa Mashine wenye Binadamu Katikati (HITL ML) ni uwanja unaochukua mkanganyiko huu kwa uzito na kuujenga katika muundo wa mifumo tangu mwanzo. Badala ya kuona ushiriki wa binadamu kama nyenzo za muda zinazostahili kuondolewa hatimaye, HITL ML inauona mwingiliano kati ya binadamu na mashine kama *kipengele* — chanzo cha ishara, marekebisho, na mwongozo unaoweza kufanya mifano kuwa sahihi zaidi, iliyopatanishwa zaidi na maadili ya binadamu, na inayostahili kuaminiwa zaidi.

Kufafanua HITL ML

Hakuna ufafanuzi mmoja uliokubaliwa wa HITL ML, na neno hilo linatumika kwa njia kadhaa zinazoingiliana katika fasihi. Kwa kitabu hiki cha mwongozo tunakubali ufafanuzi mpana lakini sahihi:

:::{admonition} Ufafanuzi :class: important

Ujifunzaji wa Mashine wenye Binadamu Katikati unarejelea mfumo wowote wa ML au mbinu ambapo maoni ya binadamu yanajumuishwa katika mchakato wa kujifunza kwa njia ya *makusudi, iliyopangwa, na inayoendelea* — si tu wakati wa uundaji wa mkusanyiko wa data, bali katika mafunzo yote, tathmini, na utekelezaji.

:::

Ufafanuzi huu una vipengele vitatu muhimu:

Kwa makusudi. HITL si ushawishi wa bahati mbaya wa binadamu (k.m., ukweli kwamba data ya mafunzo iliundwa awali na binadamu). Unarejelea mifumo iliyoundwa wazi ili kuomba, kujumuisha, na kufaidika na maoni ya binadamu.

Iliyopangwa. Maoni yana mfumo uliofafanuliwa — lebo, marekebisho, hukumu ya upendeleo, maonyesho — na jukumu lililofafanuliwa katika kanuni ya kujifunza.

Inayoendelea. Mzunguko wa maoni unaendelea kwa wakati, ukiuruhusu mfumo kuboresha unapokutana na hali mpya, kufanya makosa, na kupokea mwongozo wa binadamu.

Ufafanuzi huu unajumuisha mifumo ya kitambo ya uwekaji maelezo, ujifunzaji tendaji, ML ya mwingiliano, RLHF, na kujifunza kwa kuiga. Unaacha nje ukusanyaji wa passiv wa data na ujifunzaji wa usimamizi wa nje ya mtandao peke yake (ingawa mpaka ni dhaifu, kama tutakavyojadili katika Sura ya 2).

Historia Fupi

Mifumo ya Wataalam na Uhandisi wa Maarifa (Miaka ya 1960–1980)

Mifumo ya kwanza ya AI ilikuwa karibu yote ya binadamu katika mzunguko: wahandisi wa maarifa walikaa na wataalam wa fani kwa miezi, wakiingiza kwa makini sheria kwenye mifumo ya wataalam kama MYCIN na DENDRAL. Kila kipande cha maarifa kilipewa waziwazi na binadamu. Mashine ilikuwa ya utekelezaji; binadamu alikuwa chanzo.

Mifumo hii ilifanya kazi vizuri kushangaza katika maeneo nyembamba lakini ilikuwa brittle — haikuweza kujumlisha zaidi ya sheria zilizoundwa kwa mkono na ilikuwa ghali kutunza.

Mabadiliko ya Takwimu (Miaka ya 1980–2000)

Mabadiliko ya ujifunzaji wa mashine wa takwimu katika miaka ya 1980 na 1990 yalibadilisha asili ya ushiriki wa binadamu. Badala ya kuweka maarifa kama sheria, binadamu sasa walitoa *mifano* — mkusanyiko wa data ulioongezewa lebo ambao uliruhusu mifano kutabiri mifumo. Jukumu la binadamu likawa la mweka maelezo: kuweka lebo kwa hati, kutengeneza picha, kunukuu usemi.

Hii ilikuwa hatua kubwa mbele, lakini iliunda kikwazo kipya: **data yenye lebo ni ghali**. Watafiti walianza kuuliza jinsi ya kutumia kwa ufanisi zaidi juhudi za uwekaji lebo za binadamu. Swali hili lilizaa **ujifunzaji tendaji**, uliofanywa rasmi kwanza mwanzoni mwa miaka ya 1990 {cite}`cohn1994improving`.

Enzi ya Kujifunza Kwa Kina (Miaka ya 2010 hadi sasa)

Mapinduzi ya kujifunza kwa kina yaliunda utaratibu mpya: mifano yenye mabilioni ya vigezo inayoweza kujifunza utendaji kazi mgumu sana kutoka kwa data — lakini inahitaji mkusanyiko mkubwa wa data yenye lebo. ImageNet (picha milioni 14 zenye lebo) na miradi ya baadaye ya uwekaji maelezo kwa kiwango kikubwa ilionyesha nguvu na gharama ya kiwango.

Wakati huo huo, utekelezaji wa ML kwa kiwango kikubwa ulifichua matatizo mapya: mifano iliyokuwa sahihi kwa wastani lakini yenye makosa ya kimfumo kwa makundi maalum, iliyokuwa na imani ya uongo juu ya ukweli, iliyoboreshwa kwa wawakilishi wanaoweza

kupimwa badala ya maadili ya binadamu. Kushindwa huku kulisababisha aina mpya za ushiriki wa binadamu: si kuweka lebo tu, bali *upatanisho* — mradi wa kufanya mifano ifanye kama binadamu wanavyotaka kweli.

Usemi wazi zaidi wa kazi hii ya HITL inayozingatia upatanisho ni **Ujifunzaji wa Kuimarisha kutoka kwa Maoni ya Binadamu (RLHF)** {cite}`christiano2017deep`, ambao ukawa msingi wa mifumo kama InstructGPT {cite}`ouyang2022training` na uwezo wa kufuata maelekezo wa mifano ya kisasa ya lugha.

Kwa Nini HITL? Hoja kwa Hukumu ya Binadamu

Ni nini kinachofanya hukumu ya binadamu kuwa na thamani ya kujumuisha katika mifumo ya ujifunzaji wa mashine? Sifa kadhaa:

1. Akili ya Kawaida na Maarifa ya Dunia

Binadamu huleta maarifa mapana ya msingi kwa kazi yoyote. Wakati daktari wa radiolojia anaweka lebo kwenye picha ya X-ray, anategemea miaka ya mafunzo, uelewa wa anatomy, na maarifa ya picha ya magonjwa yanayoonekana — maarifa ambayo ni magumu sana kufafanua kikamilifu au kupata kutoka kwa data peke yake.

2. Msingi wa Kisemantiki

Lebo zina maana kwa sababu binadamu wanaelewa zinamaanisha nini. Darasa "paka" katika ImageNet linarejelea dhana isiyo na mipaka wazi ambayo binadamu wanaijua kwa silika lakini ambayo hakuna ufafanuzi rasmi unaoinakili kikamilifu. Mifano hujifunza upanuzi wa lebo (picha zipi zinaielekeza) lakini inaweza isijifunze dhana yenyewe, na kusababisha kushindwa kwa hali za mpaka ambazo binadamu yeyote angezimudu kwa usahihi.

3. Upatanisho wa Maadili

Binadamu wana mapendeleo, maadili, na hukumu za kimaadili ambazo mifano ya ML haiwezi kupata kutoka kwa data peke yake. Kama kipande cha maandishi ni "cha kusaidia" au "cha kudhuru" si swali la kimajaribio tu — inategemea maadili ya binadamu yanayotofautiana kati ya watu binafsi na muktadha. HITL ndiyo njia kuu ambayo maadili haya yanaweza kuwasilishwa kwa mifumo ya ML.

4. Uwezo wa Kubadilika

Hukumu ya binadamu inaweza kubadilika kwa hali mpya bila mafunzo upya. Mfano uliofunzwa kwa data ya kihistoria unaweza kushindwa vibaya wakati ulimwengu unabadilika; binadamu anaweza kutambua uvumbuzi na kujibu ipasavyo.

5. Uwajibikaji

Katika maeneo yenye hatari kubwa — dawa, sheria, fedha — maamuzi yanahitaji kuwajibika kwa binadamu. Mifumo ya HITL inafanya uwajibikaji huu uwezekane kwa kuweka binadamu katika nafasi ya kuelewa, kuthibitisha, na kubatilisha tabia ya mashine.

Mzunguko wa Maoni

Muundo wa msingi wa HITL ML ni mzunguko wa maoni kati ya mfano na binadamu mmoja au zaidi:

```
+---------------------------------------------+
|                                             |
|   Mfano hufanya utabiri / huomba           |
|   ---------------------------------->       |
|                                  Binadamu |
|   Binadamu hutoa maoni           <-------- |
|   ----------------------------------        |
|                                             |
|   Mfano husasishwa kulingana na maoni      |
|                                             |
+---------------------------------------------+
```

Asili ya maoni inatofautiana sana katika mifumo ya HITL:

Aina ya maoni	Mfano	Mfumo mkuu
Lebo ya darasa	"Barua pepe hii ni taka"	Ujifunzaji wa usimamizi
Marekebisho	"Kitengo kinapaswa kuwa ORG, si PER"	ML tendaji / mwingiliano
Upendeleo	"Jibu A ni bora kuliko B"	RLHF / upangaji
Maonyesho	Kuonyesha roboti jinsi ya kushika kitu	Kujifunza kwa kuiga
Lugha asilia	"Kuwa mfupi zaidi katika majibu yako"	Urekebishaji wa maelekezo
Ishara ya picha	Mtumiaji alibofya / hakubofya	Maoni ya picha

Kinachosi HITL

Inafaa kuwa wazi kuhusu kinachoko *nje* ya ufafanuzi wetu.

HITL si sawa na utekelezaji wa binadamu katika mzunguko (mara nyingi huitwa "binadamu juu ya mzunguko"), ambapo binadamu wanasimamia maamuzi otomatiki na wanaweza kuyabatilisha lakini hawapelekei marekebisho kurudi katika mafunzo. Tutajadili tofauti hii katika Sura ya 2.

HITL si usimamizi dhaifu peke yake. Mifumo ya uwekaji lebo ya programu kama Snorkel hutumia kazi za uwekaji lebo (mara nyingi sheria zilizoandikwa na binadamu) kuzalisha lebo zenye kelele kwa kiwango kikubwa. Hii ni aina ya ingizo la binadamu lililoundwa, lakini maoni si ya mzunguko kwa njia ambayo HITL kawaida ina maana.

HITL si utumiaji tu wa data yenye lebo. Kila mfano wa ujifunzaji wa usimamizi hutumia data iliyowekewa lebo na binadamu. HITL inarejelea hasa mifumo ambapo maoni ya binadamu ni sehemu *tendaji, ya mzunguko* ya mchakato wa kujifunza.

Uchumi wa Maoni ya Binadamu

Maoni ya binadamu yana thamani lakini ni ghali. Uwekaji maelezo wa picha ya kimatibabu unaweza kugharimu popote kutoka makumi hadi mamia ya dola kwa picha ikifanywa na mtaalam, kulingana na taaluma ndogo na ugumu wa kazi {cite}`monarch2021human`. Lebo za wafanyakazi wa umma kwenye majukwaa kama Amazon Mechanical Turk zinaweza kugharimu $0.01–$0.10 kwa kipengele {cite}`hara2018data` kwa ubora mdogo zaidi. Changamoto ya msingi ya HITL ML ni **kuongeza thamani ya kila kitengo cha maoni ya binadamu**.

Hii inasababisha swali la muungano linalopigia uzi katika sehemu nyingi za kitabu hiki:

:::{admonition} Swali Kuu la HITL ML :class: tip

Kwa bajeti iliyowekwa ya wakati na makini ya binadamu, tunapaswa kuamua vipi nini kuuliza binadamu, wakati wa kuuliza, na jinsi ya kujumuisha majibu yao katika mafunzo ya mfano?

:::

Jibu la swali hili linategemea eneo la matumizi, mfumo wa maoni, gharama ya uwekaji maelezo, hatari ya kosa, na hali ya sasa ya mfano — ndiyo maana HITL ML ni taaluma tajiri na inayoendelea kubadilika.

Muhtasari wa Kitabu cha Mwongozo

Sehemu iliyobaki ya kitabu hiki imepangwa kama ifuatavyo. **Sehemu ya II** inashughulikia nguzo tatu za kitambo za HITL: uwekaji maelezo, ujifunzaji tendaji, na ML ya mwingiliano. **Sehemu ya III** inazungumzia mifumo mipya ya kujifunza kutoka kwa maoni — RLHF, kujifunza kwa kuiga, na kujifunza upendeleo — ambayo imekuwa ya msingi kwa AI ya kisasa. **Sehemu ya IV** inachunguza HITL kupitia lenzi ya maeneo maalum ya matumizi. **Sehemu ya V** inachukua mtazamo wa mtaalamu wa vitendo kuhusu majukwaa, ushirikiano wa umma, na tathmini. **Sehemu ya VI** inashughulikia maadili na kutazama mbele.

> **See also:** Kwa mapitio yanayozingatia wataalamu wa vitendo wa uwanja huu, angalia {cite}`monarch2021human`. Kwa makala ya msingi ya ujifunzaji tendaji iliyoanzisha matibabu mengi rasmi ya HITL, angalia {cite}`settles2009active`.

Uainishaji wa Mwingiliano kati ya Binadamu na Mashine

Msamiati sahihi ndio sharti la kwanza la fikira wazi. Neno "binadamu katikati ya mzunguko" linatumika kwa upole katika mazoezi — wakati mwingine kumaanisha kwamba binadamu anaweka lebo kwa data ya mafunzo, wakati mwingine kwamba binadamu anaweza kubatilisha uamuzi wa mfano, na wakati mwingine kwamba binadamu anaelekeza kikamilifu mchakato wa kujifunza wakati wa sasa hivi. Hizi ni mambo tofauti yenye maana.

Sura hii inaainisha mazingira ya mwingiliano kati ya binadamu na mashine katika ML, ikitoa msamiati wa kidhana unaotumika katika sehemu iliyobaki ya kitabu hiki cha mwongozo.

Viwango vya Otomatiki

Tofauti ya msingi zaidi ni jinsi binadamu anavyoshiriki kikamilifu katika ufanyaji maamuzi wa mfumo. Mfumo unaojulikana kutoka katika nadharia ya otomatiki {cite}`sheridan1992telerobotics` unatofautisha viwango kumi, lakini kwa madhumuni ya ML kategoria tatu zinanasa tofauti muhimu:

Binadamu Katikati ya Mzunguko (HITL)

Binadamu ni *mshiriki tendaji katika mchakato wa kujifunza*. Maamuzi — au angalau maamuzi yenye matokeo makubwa — yanahitaji ingizo la binadamu kabla hayajafanyiwa mwisho. Mfumo hauwezi kufanya kazi bila ushirikiano unaoendelea wa binadamu.

Mifano: Mfumo wa ujifunzaji tendaji unaomuuliza daktari wa kliniki kabla ya kuongeza kesi kwenye data ya mafunzo. Mweka maelezo wa data anayeweka lebo kwa mifano ambayo inatumika mara moja kwa masasisho ya mfano. Mweka lebo wa RLHF anayelinganisha matokeo ya mfano.

Binadamu Juu ya Mzunguko (HOTL)

Mfumo hufanya kazi kwa uhuru lakini binadamu unausimamia na anaweza kuingilia kati. Binadamu ni *msimamizi*, si mshiriki. Maoni yanaweza au yasirudi kwenye mafunzo.

Mifano: Mfumo wa usimamizi wa maudhui unaotia bendera kwenye machapisho kiotomatiki; mkaguzi wa binadamu anakagua na kurekebisha sehemu ya maamuzi. Rubani otomatiki anayeruka ndege lakini anaarifu rubani kuhusu hali zisizo za kawaida.

Binadamu Anayeamuru (HIC)

Binadamu hufanya maamuzi yote; mfumo hutoa *mapendekezo au habari* lakini hauna uhuru wowote. Hii ni aina dhaifu zaidi ya utekelezaji wa ML.

Mifano: Mfumo wa msaada wa utambuzi unaoonyesha daktari makadirio ya uwezekano wa mfano lakini kuacha uamuzi wa mwisho kwa daktari kabisa.

> **Kiwango kipi ndicho sahihi?** :class: tip
>
> Kiwango kinachofaa cha otomatiki kinategemea gharama ya makosa, utegemezi wa mfano, utaalamu wa binadamu wanaoweza kupatikana, na vikwazo vya muda wa kazi. Mambo haya yanabadilika kadri mfano unavyokomaa — mifumo mingi inaanza HITL na kuhamia HOTL kadri imani inavyoongezeka.

```
Data ghafi --> Usindikaji wa awali --> Vipengele --> Mafunzo --> Tathmini --> Utekelezaji
    ^              ^                                    ^              ^              ^
    |              |                                    |              |              |
 Maoni ya       Uwekaji                            Ujifunzaji    Maoni ya       Ufuatiliaji
 ukusanyaji     maelezo                            tendaji       upimaji        na marekebish
```

Hatua	Jukumu la binadamu	Sura
Ukusanyaji	Kuamua data ya kukusanya; mkakati wa sampuli	3, 4
Uwekaji maelezo	Kutoa lebo, miundo, metadata	3, 13
Mafunzo	Maswali ya ujifunzaji tendaji; maoni ya mtandaoni	4, 5, 6
Tathmini	Tathmini ya binadamu ya matokeo ya mfano	14
Utekelezaji	Ufuatiliaji, ushughulikiaji wa matatizo, marekebisho	12, 14

Ushiriki wa Binadamu wa Tendaji dhidi ya wa Passiv

Katika HITL *tendaji*, mfumo huchagua pointi za data zipi za kuwasilisha kwa binadamu — ukiuliza maswali kwa mkakati. Katika HITL *passiv*, binadamu hutoa maoni kuhusu data yoyote inayofika (k.m., vifurushi vya uwekaji lebo vilivyopangwa kwa mfululizo).

Ushiriki tendaji ni wa ufanisi zaidi kwa sababu maoni yanaelekeza mahali ambapo yataboresha zaidi mfano. Ushiriki passiv ni rahisi zaidi kutekeleza na kusimamia.

Tofauti inayohusiana ni kati ya maoni ya **vifurushi** na **mtandaoni**:

- **Vifurushi:** Binadamu huweka lebo kwenye hazina kubwa ya mifano; mfano unafunzwa tena. Rudia.
- **Mtandaoni (mtiririko):** Maoni ya binadamu yanafika kila wakati; mfano husasishwa kwa hatua ndogo ndogo.

Mifumo ya vifurushi ndiyo ya kawaida katika tasnia (miradi ya uwekaji maelezo inayofuatiwa na mwendo wa mafunzo). Mifumo ya mtandaoni ni ya asili zaidi kwa mifumo ya mwingiliano na mazingira ya ujifunzaji wa kuimarisha.

Mweka Maelezo Mmoja dhidi ya Wengi

Wawasilishaji rasmi wengi wa HITL wanadhani mweka maelezo mmoja, thabiti. Katika mazoezi, uwekaji maelezo unahusisha watu wengi, na hukumu zao zinatofautiana.

Ujumuishaji huchanganya maelezo mengi kuwa lebo moja, kawaida kwa kura ya wingi au mfano wa takwimu (Sura ya 13).

Kutokubaliana kama ishara — watafiti wengine wanasema kwamba kutokubaliana kwa wawekaji maelezo ni habari yenye thamani ambayo haipaswi kupigwa chini kuwa lebo moja ya "dhahabu". Mbinu za mtazamo katika NLP, kwa mfano, huhifadhi maelezo mengi kama lebo laini zinazoakisi utata wa kweli wa data {cite}`uma2021learning`.

Mfumo wa Umoja

Tunaweza kuwakilisha usanidi wowote wa HITL kwa tano-jozi:

$$\text{usanidi wa HITL} = (\text{kiwango}, \text{hali}, \text{hatua}, \text{mara}, \text{wawekaji maelezo})$$

ambapo:

- **kiwango** $\in$ {HITL, HOTL, HIC}
- **hali** $\in$ {lebo, marekebisho, maonyesho, upendeleo, lugha asilia, picha}
- **hatua** $\in$ {ukusanyaji, uwekaji maelezo, mafunzo, tathmini, utekelezaji}
- **mara** $\in$ {vifurushi, mtandaoni}
- **wawekaji maelezo** $\in \mathbb{N}^+$ (idadi ya wawekaji maelezo kwa kipengele)

Uainishaji huu unatuwezesha kulinganisha mifumo mbalimbali ya HITL kwenye mhimili sawa na kufikiria kuhusu maelewano kati yao. Sehemu iliyobaki ya kitabu hiki inaingia kwa kina katika seli maalum za nafasi hii.

> **See also:** Kwa utafiti wa kimajaribio wa jinsi maamuzi ya uwekaji maelezo yanavyoathiri tabia ya mfano wa chini, angalia {cite}`bender2021stochastic`. Kwa mapitio ya mifumo ya ML ya mwingiliano, angalia {cite}`amershi2014power`.

Uwekaji Maelezo na Ulabelishaji wa Data

Uwekaji maelezo wa data ni aina ya kawaida zaidi ya ushiriki wa binadamu katika ML. Kabla mfano haujaweza kujifunza, mtu lazima auambie majibu sahihi ni nini — na mtu huyo kawaida ni binadamu. Sura hii inashughulikia nadharia na mazoezi ya uwekaji maelezo: kinachofanya uwekaji maelezo kuwa mgumu, jinsi ya kubuni kazi za uwekaji maelezo, jinsi ya kupima ubora, na jinsi ya kushughulikia kutokubaliana.

Aina za Uwekaji Maelezo

Kazi za uwekaji maelezo zinatofautiana sana katika muundo, ugumu, na gharama. Aina kuu ni pamoja na:

Uainishaji

Mweka maelezo humweka kila kipengele katika moja ya kategoria K zilizofafanuliwa awali. Hii ndiyo kazi rahisi zaidi ya uwekaji maelezo kiakili, lakini kubuni mpango mzuri wa kategoria (*uainishaji*) kunaweza kuwa gumu kushangaza.

Uainishaji wa binary (je, picha hii ni paka?) ni kesi rahisi zaidi. **Uainishaji wa darasa nyingi** (ni spishi gani ya mnyama huyu?) unahitaji wawekaji maelezo kuchagua chaguo moja kutoka kwa orodha. Uwekaji maelezo wa **lebo nyingi** (mada zipi zinahusika katika makala hii?) huruhusu lebo nyingi kwa wakati mmoja.

Uwekaji Lebo kwa Mfululizo

Kila tokeni katika mfululizo hupokea lebo. Utambuzi wa Maneno Maalum (NER) ni mfano wa kawaida — wawekaji maelezo huweka alama kwenye vipande vya maandishi kama MTU, SHIRIKA, MAHALI, n.k. Uwekaji maelezo kawaida hufanywa kwa kutumia mpango wa uwekaji lebo wa BIO (Mwanzo-Ndani-Nje) au BIOES:

```
B-ORG    O          B-ORG    O    O    O
```

Uwekaji Maelezo wa Vipande na Mahusiano

Zaidi ya kuweka lebo kwenye tokeni moja moja, wawekaji maelezo wanaweza kuhitajika: - Kutambua vipande (maneno mengi ya pamoja) na kutoa aina - Kuweka alama kwenye *mahusiano* kati ya vipande ("Apple" ILINUNUA "Shazam") - Kuweka maelezo kwenye minyororo ya rejeleo (matajio yote ya kitengo kimoja)

Kazi hizi zinahitaji nguvu za kiakili na zina makubaliano ya chini ya wawekaji maelezo.

Sanduku za Mipaka na Ugunduzi wa Vitu

Wawekaji maelezo huchora mstatili karibu na vitu katika picha na kutoa lebo ya kategoria kwa kila sanduku. Usahihi wa mahali unahusika: sanduku dogo sana linapoteza muktadha; sanduku kubwa sana linajumuisha mandhari ya nyuma. Zana za kisasa za uwekaji maelezo huhesabu makutano-juu-ya-muungano (IoU) na maelezo ya marejeleo ili kupata matatizo ya ubora.

Ugawanyiko

Uwekaji maelezo wa kiwango cha pikseli: kila pikseli imepangwa kwenye darasa (ugawanyiko wa kisemantiki) au kwa kitengo maalum cha kitu (ugawanyiko wa kitengo). Ugawanyiko wa ubora wa juu ni kati ya aina za uwekaji maelezo zenye gharama kubwa zaidi, na gharama zinaanzia makumi hadi zaidi ya dola mia moja kwa picha kwa matukio magumu kulingana na uwanja na msaada wa zana.

Unukuzi na Utafsiri

Sauti □ maandishi (data ya mafunzo ya ASR), maandishi ya mkono □ maandishi (data ya OCR), au lugha chanzo □ lugha lengwa (data ya MT). Kazi hizi zinahitaji utaalamu wa lugha na haziwezi kufanywa kwa uaminifu na wawekaji maelezo wasio na mafunzo.

Mwongozo wa Uwekaji Maelezo

Kipengele kimoja muhimu zaidi kinachoweza kuamua ubora wa uwekaji maelezo ni ubora wa **mwongozo wa uwekaji maelezo**: maelekezo yaliyoandikwa ambayo wawekaji maelezo wanafuata.

Mwongozo mzuri: - Unaeleza lengo la kazi na kueleza *kwa nini* lebo ina umuhimu - Unatoa ufafanuzi wazi kwa kila kategoria na mifano chanya na hasi - Unashughulikia waziwazi hali za mipaka za kawaida na ngumu - Unabainisha kufanya nini wakati wa wasiwasi (k.m., weka alama "ruka" dhidi ya chaguo la kulazimishwa) - Unajumuisha mifano iliyofanyiwa kazi ya uwekaji maelezo kamili

Mwongozo mbaya unategemea wawekaji maelezo "kutumia akili ya kawaida" kwa hali za mipaka — ambayo husababisha maamuzi yasiyo ya uthabiti yanayopunguza ubora wa mfano na kuongeza kutokubaliana kwa wawekaji maelezo.

> **Maendeleo ya mwongozo ni ya mzunguko** :class: note
>
> Usitarajie kuandika mwongozo kamili tangu mwanzo. Fanya raundi ndogo ya majaribio ya uwekaji maelezo, changanua kutokubaliana, na sasisha mwongozo. Rudia. Mwongozo ulioendelezwa vizuri kawaida hupitia mzunguko wa marekebisho 3–5 kabla ya kutulia.

Kupima Ubora wa Uwekaji Maelezo: Makubaliano ya Wawekaji Maelezo

Wawekaji maelezo wengi wanapoweka lebo kwa data sawa, makubaliano yao yanaweza kupimwa. Makubaliano ya juu yanaonyesha kazi imefafanuliwa vizuri na wawekaji maelezo

waliielewa. Makubaliano ya chini yanaonyesha utata katika kazi, mwongozo, au data yenyewe.

Kappa ya Cohen

Kwa wawekaji maelezo wawili wanaoweka lebo kwa data katika kategoria K, **kappa ya Cohen** {cite}`cohen1960coefficient` inarekebisha makubaliano yanayoonekana kwa nafasi:

$$\kappa = \frac{P_o - P_e}{1 - P_e}$$

ambapo P_o ni makubaliano ya sehemu yanayoonekana na P_e ni uwezekano wa makubaliano kwa nafasi (imehesabiwa kutoka kwa usambazaji wa lebo za pembeni).

$\kappa = 1$ inamaanisha makubaliano kamili; $\kappa = 0$ inamaanisha makubaliano si bora kuliko nafasi; $\kappa < 0$ inamaanisha kutokubaliana kwa kimfumo.

Upeo wa κ	Tafsiri
< 0	Chini ya nafasi
$0.0 - 0.20$	Ndogo
$0.21 - 0.40$	Ya wastani
$0.41 - 0.60$	Ya kati
$0.61 - 0.80$	Kubwa
$0.81 - 1.00$	Karibu kamili

Kappa ya Fleiss

Inapanua kappa ya Cohen kwa $M > 2$ wawekaji maelezo. Kila mweka maelezo huweka lebo kwa kila kipengele kwa kujitegemea; formula inajumuisha kati ya wawekaji maelezo:

$$\kappa_F = \frac{\bar{P} - \bar{P}_e}{1 - \bar{P}_e}$$

ambapo $\bar{P}$ ni wastani wa makubaliano ya jozi kati ya jozi zote za wawekaji maelezo, na $\bar{P}_e$ ni makubaliano yanayotarajiwa chini ya mgawanyiko wa nasibu.

Alpha ya Krippendorff

Kipimo cha jumla zaidi, kinachosaidia idadi yoyote ya wawekaji maelezo, aina yoyote ya kipimo (nomino, mpangilio, nafasi, uwiano), na data inayokosekana {cite}`krippendorff2011computing`:

$$\alpha = 1 - \frac{D_o}{D_e}$$

ambapo D_o ni kutokubaliana kunakoonekana na D_e ni kutokubaliana kunakotarajiwa. Alpha ya Krippendorff kwa ujumla inapendelewa katika kazi za kitaaluma kwa sababu ya unyumbufu wake.

```
import numpy as np
from sklearn.metrics import cohen_kappa_score
```

```python
# Simulate two annotators labeling 200 items into 3 categories
rng = np.random.default_rng(0)
true_labels = rng.integers(0, 3, size=200)

# Annotator 1: mostly agrees with ground truth
ann1 = true_labels.copy()
flip_mask = rng.random(200) < 0.15
ann1[flip_mask] = rng.integers(0, 3, size=flip_mask.sum())

# Annotator 2: less consistent
ann2 = true_labels.copy()
flip_mask2 = rng.random(200) < 0.30
ann2[flip_mask2] = rng.integers(0, 3, size=flip_mask2.sum())

kappa_12 = cohen_kappa_score(ann1, ann2)
kappa_1true = cohen_kappa_score(ann1, true_labels)
kappa_2true = cohen_kappa_score(ann2, true_labels)

print(f"Cohen's κ (ann1 vs ann2):   {kappa_12:.3f}")
print(f"Cohen's κ (ann1 vs truth):  {kappa_1true:.3f}")
print(f"Cohen's κ (ann2 vs truth):  {kappa_2true:.3f}")
```

Kushughulikia Kutokubaliana

Wawekaji maelezo wanapokosoa, kuna mikakati kadhaa:

Kura ya Wingi

Lebo ya kawaida zaidi inachukuliwa kama kiwango cha dhahabu. Rahisi na imara wakati idadi ya wawekaji maelezo kwa kipengele ni ya ajabu. Inashindwa wakati kikundi kidogo cha wawekaji maelezo ni sahihi zaidi kwa kimfumo.

Upigaji Kura wa Uzito

Wawekaji maelezo wanapewa uzito kulingana na usahihi wao uliokadirika (unaotokana na makubaliano na kiwango cha dhahabu au wawekaji maelezo wengine). Wawekaji maelezo sahihi zaidi wana ushawishi zaidi.

Lebo Laini

Badala ya kupiga chini maelezo hadi lebo moja, hifadhi usambazaji. Kama 3 kati ya wawekaji maelezo 5 walisema "chanya" na 2 walisema "wastani," iwakilishe kama $(p_{\text{chanya}}, p_{\text{wastani}}, p_{\text{hasi}}) = (0.6, 0.4, 0.0)$. Mafunzo kwenye lebo laini yanaboresha urekebishaji.

Usuluhishi

Mweka maelezo mwandamizi au mtaalamu wa uwanja anasuluhisha kutokubaliana. Kiwango cha dhahabu lakini ghali; kawaida huhifadhiwa kwa maeneo yenye hatari kubwa.

Mifano ya Takwimu

Mbinu za kisasa zaidi zinaiga uwezo wa wawekaji maelezo kwa uwezekano. Mfano wa **Dawid-Skene** {cite}`dawid1979maximum` unakadiri wakati mmoja matrices za mkanganyiko za wawekaji maelezo na lebo za kweli za kipengele kupitia EM. Angalia Sura ya 13 kwa maelezo zaidi.

Kelele za Lebo na Athari Zake

Uwekaji maelezo wa kweli una kelele. Athari za kelele za lebo kwenye mafunzo ya mfano zinategemea aina ya kelele:

- **Kelele za nasibu** (lebo zinazogeuzwa bila mpangilio) zinapunguza utendaji lakini mifano ina ustahimilivu wa kushangaza kwa viwango vya wastani (hadi ~20% kwa kazi nyingi).
- **Kelele za kimfumo/za adui** (lebo zisizo sahihi kwa njia maalum) ni za kudhuru zaidi na ngumu kugundua.
- **Kelele za masharti ya darasa** (makosa yanayowezekana zaidi kwa madarasa fulani) yanabagua mpaka wa uamuzi wa mfano.

Kanuni ya vitendo ya kawaida: na mifano n ya mafunzo na sehemu ϵ ya lebo zilizoharibiwa, utendaji wa mfano unapungua takriban kama vile una mifano $(1 - 2\epsilon)^2 n$ safi {cite}`natarajan2013learning`. Kwa $\epsilon = 0.2$, hii inafanana na kupoteza 36% ya data yako.

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import cross_val_score

rng = np.random.default_rng(42)
X, y = make_classification(n_samples=2000, n_features=20, random_state=42)

noise_levels = np.linspace(0, 0.45, 15)
mean_accs = []

for eps in noise_levels:
    y_noisy = y.copy()
    flip = rng.random(len(y)) < eps
    y_noisy[flip] = 1 - y_noisy[flip]
    scores = cross_val_score(LogisticRegression(max_iter=500), X, y_noisy, cv=5)
    mean_accs.append(scores.mean())

plt.figure(figsize=(7, 4))
plt.plot(noise_levels, mean_accs, 'o-', color='#2b3a8f', linewidth=2)
plt.xlabel("Label noise rate (ε)", fontsize=12)
plt.ylabel("Cross-validated accuracy", fontsize=12)
plt.title("Effect of Label Noise on Model Performance", fontsize=13)
plt.axvline(0.2, color='#e05c5c', linestyle='--', alpha=0.7, label='20% noise')
plt.legend()
plt.tight_layout()
plt.savefig('label_noise_effect.png', dpi=150)
plt.show()
```

```
print(f"\nAccuracy at 0% noise:  {mean_accs[0]:.3f}")
print(f"Accuracy at 20% noise: {mean_accs[round(0.2 / 0.45 * 14)]:.3f}")
print(f"Accuracy at 40% noise: {mean_accs[-2]:.3f}")
```

Gharama ya Uwekaji Maelezo na Kiwango cha Uzalishaji

Kuelewa uchumi wa uwekaji maelezo ni muhimu kwa mipango ya mradi.

Aina ya kazi	Kiwango cha kawaida cha uzalishaji	Gharama kwa kipengele (mtaalamu)
Uainishaji wa binary wa picha	200–500 / saa	$0.02–0.10
NER (maandishi mafupi)	Vipengele 50–150 / saa	$0.10–0.50
Uchimbaji wa mahusiano	Vipengele 20–60 / saa	$0.30–1.50
Ugawanyiko wa picha ya kimatibabu	Vipengele 5–30 / saa	$10–100
Uwekaji maelezo wa video	Dakika 5–20 za video / saa	$20–200

Takwimu hizi ni makadirio ya takriban ya mpangilio wa ukubwa na zinatofautiana sana kulingana na utaalamu wa uwanja unaohitajika, ubora wa zana ya uwekaji maelezo, uwazi wa mwongozo, na uzoefu wa mweka maelezo. Zinapaswa kuchukuliwa kama za mwanga, si kama za amri.

> **See also:** Chaguo za zana za uwekaji maelezo zimeshughulikiwa katika Sura ya 12. Mifano ya takwimu kwa uwekaji maelezo wa ushirikiano wa umma (Dawid-Skene, MACE) imeshughulikiwa katika Sura ya 13.

Ujifunzaji Tendaji

Data yenye lebo ni ghali. Ufahamu wa msingi wa ujifunzaji tendaji ni kwamba *si mifano yote isiyo na lebo ina taarifa sawa* — mfano unaweza kuboresha haraka zaidi ukipewa nafasi ya kuchagua mifano gani ya kuuliza kuhusu. Badala ya kuweka lebo kwa data bila mpangilio, mfumo wa ujifunzaji tendaji huuliza chanzo (kawaida mweka maelezo wa binadamu) kuhusu mifano inayoweza zaidi kuboresha mfano.

Sura hii inashughulikia nadharia na mazoezi ya ujifunzaji tendaji: mikakati ya maswali, miundo ya sampuli, vigezo vya kusimama, na masuala ya vitendo kwa utekelezaji wa kweli.

Mpangilio wa Ujifunzaji Tendaji

Mpangilio wa kawaida wa **ujifunzaji tendaji wa msingi wa bwawa** unahusisha:

- **Seti yenye lebo** $\mathcal{L} = \{(x_i, y_i)\}_{i=1}^n$ — ndogo awali
- **Bwawa lisilo na lebo** $\mathcal{U} = \{x_j\}_{j=1}^m$ — kawaida kubwa zaidi sana kuliko $\mathcal{L}$
- **Chanzo** $\mathcal{O}$ kinachoweza kurudisha $y = \mathcal{O}(x)$ kwa x yoyote iliyoulizwa
- **Mkakati wa maswali** ϕ unaochagua swali lijalo $x^* = \phi(\mathcal{L}, \mathcal{U}, f_\theta)$

Mzunguko wa ujifunzaji tendaji:

```
1. Anzisha: L = seti ndogo ya mbegu zenye lebo, U = bwawa lisilo na lebo
2. Funza: f_θ ← funza(L)
3. Uliza: x∗ = argmax φ(x; f_θ) kwa x ∈ U
4. Weka lebo: y∗ = O(x∗)
5. Sasisha: L ← L ∪ {(x∗, y∗)}, U ← U \ {x∗}
→ Rudia kutoka 2 hadi bajeti imekwisha
```

Lengo ni kufikia ubora wa mfano unaolengwa kwa maswali machache iwezekanavyo ya chanzo.

Misingi ya Kinadharia

Swali la asili ni: ujifunzaji tendaji unaweza kusaidia kiasi gani? Katika hali bora zaidi, ujifunzaji tendaji unaweza kufikia kupungua kwa *mara nyingi sana* katika ugumu wa lebo — kufikia kosa ϵ na lebo $O(\log(1/\epsilon))$ badala ya $O(1/\epsilon)$ inayohitajika na ujifunzaji passiv, angalau katika mazingira yanayoweza kutekelezwa na mkakati mzuri wa maswali {cite}`settles2009active`.

Katika mazoezi, dhamana ni ngumu zaidi kupata. **Ujifunzaji tendaji wa agnostiki** {cite}`balcan2006agnostic` unaonyesha kwamba akiba ya lebo inawezekana hata dhana

inayolengwa haipo katika darasa la nadharia, lakini akiba inategemea sana mgawo wa kutokubaliana — kipimo cha jinsi seti ya nadharia zinazowezekana inavyopungua haraka kadri data inavyokusanyika.

Athari kuu ya vitendo: faida ya ujifunzaji tendaji ni kubwa zaidi wakati **mpaka wa uamuzi ni rahisi na umejumuishwa** (kwa hivyo maswali ya wasiwasi yanaondoa haraka nadharia zisizo sahihi), na ndogo zaidi wakati darasa la nadharia ni kubwa au mpaka ni mgumu.

Mikakati ya Maswali

Sampuli ya Wasiwasi

Mkakati rahisi na unaotumika zaidi: uliza mfano ambao mfano una *wasiwasi zaidi* nao {cite}`lewis1994sequential`.

Imani ya chini huuliza mfano ambao mfano una imani ndogo zaidi katika utabiri wake mkuu:

$$x^* = \arg\max_{x \in \mathcal{U}} \left(1 - P_\theta(\hat{y} \mid x)\right)$$

Sampuli ya pembezoni inazingatia pengo kati ya uwezekano wa juu mbili uliotabiriwa:

$$x^* = \arg\min_{x \in \mathcal{U}} \left(P_\theta(\hat{y}_1 \mid x) - P_\theta(\hat{y}_2 \mid x)\right)$$

Sampuli ya entropi inatumia usambazaji wote uliotabiriwa:

$$x^* = \arg\max_{x \in \mathcal{U}} \left(-\sum_{k=1}^{K} P_\theta(y_k \mid x) \log P_\theta(y_k \mid x)\right)$$

Sampuli ya entropi ndiyo ya msingi zaidi kati ya tatu — inazingatia madarasa yote — na kwa ujumla inazidi nyingine kwa matatizo ya madarasa mengi.

Maswali kwa Kamati (QbC)

Funza **kamati** ya mifano C (kwa kutumia mifumo ya upiganaji, uzinduzi tofauti, au miundo tofauti). Uliza mfano ambao kamati inakinzana nao zaidi:

$$x^* = \arg\max_{x \in \mathcal{U}} \ \text{kutokubaliana}(\{f_c(x)\}_{c=1}^{C})$$

Kutokubaliana kunaweza kupimwa kama **entropi ya kura** (entropi juu ya kura za wingi za kamati) au **kutofautiana kwa KL** kutoka kwa usambazaji wa makubaliano.

QbC inatoa makadirio bora ya wasiwasi kuliko mfano mmoja lakini inahitaji kufunza mifano mingi, ambayo ni ghali kinadharia.

Mabadiliko ya Mfano Yanayotarajiwa

Uliza mfano ambao ungesababisha mabadiliko makubwa zaidi kwa mfano wa sasa ukiwekewa lebo. Kwa mifano inayotegemea gradient, hii inalingana na mfano wenye ukubwa wa gradient ya wastani unaotarajiwa {cite}`settles2008analysis`:

$$x^* = \arg\max_{x \in \mathcal{U}} \sum_{y \in \mathcal{Y}} P_\theta(y \mid x) \, \|\nabla_\theta \mathcal{L}(f_\theta(x), y)\|$$

Mkakati huu una msukumo wa kinadharia lakini unahitaji kuhesabu gradient kwa kila mgombea, na kuufanya ghali kwa mifano mikubwa.

Seti ya Msingi / Mbinu za Kijiometri

Mikakati inayotegemea wasiwasi inaweza **kubaguliwa kuelekea nje ya kawaida**: mfano usio wa kawaida unaweza kuwa na wasiwasi mkubwa lakini si mwakilishi wa usambazaji wa data. Mbinu za seti ya msingi zinashughulikia hili kwa kutafuta sampuli mbalimbali inayoshughulikia nafasi ya vipengele.

Kanuni ya **k-center ya mara moja** {cite}`sener2018active` inapata seti ndogo zaidi ya pointi ambapo kila pointi isiyowekewa lebo iko ndani ya δ ya angalau pointi moja iliyoulizwa:

$$x^* = \arg\max_{x \in \mathcal{U}} \min_{x' \in \mathcal{L}} d(x, x')$$

yaani, uliza pointi iliyo mbali zaidi na pointi yoyote iliyowekewa lebo kwa sasa. Hii inachochea seti iliyoenea vizuri ya maelezo.

BADGE

Kujifunza Tendaji kwa Vifurushi kwa Uwakilishi wa Gradient Mbalimbali {cite}`ash2020deep` huchanganya wasiwasi na utofauti: huchagua kifurushi cha mifano ambayo uwakilishi wa gradient yake (kuhusiana na lebo iliyotabiriwa) ni kubwa kwa ukubwa (wasiwasi) na mbalimbali (inayoshughulikia maeneo tofauti ya nafasi ya gradient). Hii ni moja ya mikakati ya kisasa inayoshindana zaidi.

Makadirio ya Wasiwasi kwa Mifano ya Kina

Mikakati hapo juu inadhani ufikiaji wa matokeo ya uwezekano yaliyorekebishwa kutoka kwa mfano. Kwa mifano rahisi (regression ya logistiki, wasambazaji wa softmax), hii ni rahisi. Kwa mtandao wa kina, kupata makadirio ya wasiwasi yanayotegemeka kunahitaji mbinu za ziada.

Aina Mbili za Wasiwasi

Kufuata Kendall na Gal {cite}`kendall2017uncertainties`, tunatofautisha:

Wasiwasi wa aleatoric (wasiwasi wa data): kelele asili katika uchunguzi ambazo haziwezi kupunguzwa kwa kukusanya data zaidi. Picha iliyofifia ina wasiwasi wa aleatoric — hakuna kiasi cha data ya ziada ya mafunzo kutoka kwa usambazaji sawa kitakachofanya mfano kuwa na imani zaidi nao.

Wasiwasi wa epistemic (wasiwasi wa mfano): wasiwasi unaotokana na data ndogo ya mafunzo au mfano ambao haujawahi kuona mifano inayofanana. Wasiwasi wa epistemic *unaweza* kupunguzwa kwa kuweka lebo data zaidi — na kwa hivyo ndiyo kiasi muhimu cha ujifunzaji tendaji wa uchaguzi wa maswali.

Kwa ujifunzaji tendaji, tunataka kuuliza mifano yenye wasiwasi mkubwa wa epistemic, si wa aleatoric mkubwa. Kuuliza mfano ulio na utata wa kimsingi kunapoteza juhudi za chanzo: hakuna lebo watakayotoa itakayokuwa wazi sahihi.

MC Dropout

Mbinu ya vitendo ya makadirio ya wasiwasi wa epistemic kwa mitandao ya neva ni **MC Dropout** {cite}`gal2016dropout`: tumia dropout wakati wa inferensi na uendeshe picha T za mbele. Tofauti kati ya utabiri ni makadirio ya wasiwasi wa epistemic.

```
import numpy as np
import torch
import torch.nn as nn

torch.manual_seed(42)
rng = np.random.default_rng(42)

class MCDropoutNet(nn.Module):
    def __init__(self, input_dim=20, hidden=64, output_dim=2, p_drop=0.3):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(input_dim, hidden), nn.ReLU(), nn.Dropout(p_drop),
            nn.Linear(hidden, hidden),    nn.ReLU(), nn.Dropout(p_drop),
            nn.Linear(hidden, output_dim)
        )

    def forward(self, x):
        return self.net(x)

def mc_uncertainty(model, x, T=30):
    """
    Run T stochastic forward passes with dropout active.
    Returns mean prediction and epistemic uncertainty (predictive variance).
    """
    model.train()  # keep dropout active during inference
    with torch.no_grad():
        preds = torch.stack([
            torch.softmax(model(x), dim=-1) for _ in range(T)
        ])  # shape: (T, N, C)
    mean_pred = preds.mean(0)
    # Epistemic uncertainty: mean of variances across passes
    epistemic = preds.var(0).sum(-1)
    # Aleatoric uncertainty: entropy of mean prediction
    aleatoric = -(mean_pred * (mean_pred + 1e-9).log()).sum(-1)
    return mean_pred, epistemic, aleatoric

# Quick demonstration
model = MCDropoutNet(input_dim=20, output_dim=2)
```

```
# In-distribution example (simulated)
x_familiar   = torch.randn(1, 20) * 0.5
# Out-of-distribution example (far from training distribution)
x_unfamiliar = torch.randn(1, 20) * 3.0

for name, x in [("In-distribution ", x_familiar), ("Out-of-distribution", x_unfamiliar)]:
    _, ep, al = mc_uncertainty(model, x)
    print(f"{name} | epistemic: {ep.item():.4f} | aleatoric: {al.item():.4f}")
```

Katika mtandao ambao haujafunzwa hapo juu, mifano yote miwili inaonyesha wasiwasi sawa. Baada ya mafunzo, mfano wa nje ya usambazaji utaonyesha wasiwasi wa juu zaidi wa epistemic — mfano haujajifunza upangaji wa kutegemewa kwa ingizo mbali na usambazaji wa mafunzo.

Makundi ya Kina

Kufunza mifano M iliyoanzishwa kwa kujitegemea na kuchanganya utabiri wao kutoa makadirio ya wasiwasi rahisi na mara nyingi ya kutegemewa zaidi kuliko MC Dropout {cite}`lakshminarayanan2017simple`. Kutokubaliana kati ya wanakikundi ni ishara ya wasiwasi wa epistemic.

Kwa ujifunzaji tendaji kwa kiwango kikubwa, MC Dropout na makundi ya kina yote mawili yanaongeza mzigo wa ziada unaolingana na picha T au M za mbele. Katika mazoezi, $T = 10$–30 kwa MC Dropout au wanakikundi $M = 5$ mara nyingi inatosha kupanga mifano kwa wasiwasi wa epistemic, hata kama maadili ya kamili hayarekebishwi vizuri.

Mzunguko Kamili wa Ujifunzaji Tendaji

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score
from copy import deepcopy

rng = np.random.default_rng(42)

# Generate dataset
X, y = make_classification(
    n_samples=2000, n_features=20, n_informative=10,
    n_classes=3, n_clusters_per_class=1, random_state=42
)
X_train, y_train = X[:1500], y[:1500]
X_test,  y_test  = X[1500:], y[1500:]

def entropy_query(model, X_pool):
    """Return index of most uncertain sample (entropy)."""
    probs = model.predict_proba(X_pool)
    ent = -np.sum(probs * np.log(probs + 1e-9), axis=1)
    return np.argmax(ent)

def random_query(X_pool):
```

```
    """Random baseline."""
    return rng.integers(0, len(X_pool))

def run_active_learning(strategy='entropy', n_initial=30, n_queries=120, query_batch=5):
    labeled_idx = list(rng.choice(len(X_train), n_initial, replace=False))
    unlabeled_idx = [i for i in range(len(X_train)) if i not in labeled_idx]
    accs = []

    for step in range(n_queries // query_batch):
        model = LogisticRegression(max_iter=500, C=1.0)
        model.fit(X_train[labeled_idx], y_train[labeled_idx])
        accs.append(accuracy_score(y_test, model.predict(X_test)))

        # Query
        X_pool = X_train[unlabeled_idx]
        for _ in range(query_batch):
            if strategy == 'entropy':
                q = entropy_query(model, X_pool)
            else:
                q = random_query(X_pool)
            labeled_idx.append(unlabeled_idx.pop(q))
            X_pool = X_train[unlabeled_idx]

    return np.array(accs)

labels_used = np.arange(1, 25) * 5 + 30  # label counts at each step

accs_active = run_active_learning(strategy='entropy')
accs_random = run_active_learning(strategy='random')

plt.figure(figsize=(8, 5))
plt.plot(labels_used, accs_active, 'o-', label='Entropy sampling', color='#2b3a8f', linewidth
plt.plot(labels_used, accs_random, 's--', label='Random baseline',  color='#e05c5c', linewidt
plt.xlabel("Number of labeled examples", fontsize=12)
plt.ylabel("Test accuracy", fontsize=12)
plt.title("Active Learning vs. Random Sampling", fontsize=13)
plt.legend(fontsize=11)
plt.grid(alpha=0.3)
plt.tight_layout()
plt.savefig('active_learning_curve.png', dpi=150)
plt.show()

print(f"Active learning reaches {accs_active[-1]:.3f} accuracy")
print(f"Random sampling reaches {accs_random[-1]:.3f} accuracy")
print(f"Active learning saves ~{int((accs_random.tolist().index(min(accs_random, key=lambda a
```

Tatizo la Kuanza Baridi

Ujifunzaji tendaji unahitaji mfano uliofunzwa kupanga pointi zisizo na lebo — lakini mwanzoni, huna (au una kidogo sana) mifano yenye lebo. Hili ndilo **tatizo la kuanza baridi**.

Suluhisho za vitendo:

1. **Uanzishaji wa nasibu:** Weka lebo kwenye seti ndogo ya mbegu ya nasibu (mifano 20–100) kabla ya kuanza ujifunzaji tendaji.
2. **Uanzishaji unaotegemea makundi:** Tumia k-means kwenye bwawa lisilo na lebo; weka lebo kwenye mfano mmoja kutoka kwa kila kundi. Hii inahakikisha utofauti katika seti ya awali yenye lebo.
3. **Uchaguzi unaotegemea uwakilishi:** Tumia enkoda iliyofunzwa awali kuwakilisha mifano; chagua kikundi mbalimbali kupitia seti ya msingi.

Kwa kazi nyingi, lebo chache za mbegu za nasibu kawaida zinatosha kuanza ujifunzaji tendaji; idadi halisi inategemea usawa wa darasa, ukubwa wa vipengele, na ugumu wa mfano.

Ujifunzaji Tendaji wa Hali ya Vifurushi

Katika mazoezi, wawekaji maelezo wanafanya kazi kwa vifurushi — ni kisiasa kufunza na kutekeleza mfano mpya baada ya kila lebo moja. **Ujifunzaji tendaji wa hali ya vifurushi** huchagua seti ya mifano b ya kuweka lebo wakati mmoja.

Kuchagua bila msimamo mifano b ya juu yenye wasiwasi mkubwa zaidi husababisha **urudiarudia**: mifano yenye wasiwasi mkubwa huwa imejikusanya pamoja (k.m., mifano karibu na mpaka wa uamuzi katika eneo sawa). Mikakati bora ya vifurushi inaboresha kwa wasiwasi *na* utofauti ndani ya kifurushi.

Michakato ya Pointi ya Kuthibitisha (DPPs) inatoa njia ya msingi ya kuchagua vifurushi mbalimbali: vinafafanua usambazaji juu ya vikundi vinavyoadhibu vitu vinavyofanana. Uwezekano wa kikundi S chini ya DPP ni unaolingana na $\det(L_S)$ ambapo L ni matrix ya kernel inayowakilisha kufanana.

Vigezo vya Kusimama

Ujifunzaji tendaji unapaswa kusimama lini? Vigezo vya kawaida:

- **Bajeti imekwisha:** Rahisi zaidi — simama bajeti ya uwekaji maelezo inapoisha.
- **Usimamaji wa utendaji:** Simama usahihi wa mfano kwenye seti ya uthibitishaji ya pembezoni haukuboresha kwa zaidi ya δ kwa raundi k mfululizo.
- **Kizingiti cha imani:** Simama chini ya sehemu fulani ya mifano isiyowekewa lebo ina wasiwasi juu ya kizingiti.
- **Upunguzaji wa hasara wa juu zaidi:** Kadiri manufaa yanayowezekana kutoka kwa lebo za ziada; simama inapoanguka chini ya kizingiti {cite}`bloodgood2009method`.

Wakati Ujifunzaji Tendaji Unafanya Kazi (na Wakati Haifanyi)

Ujifunzaji tendaji huwa hufanya kazi vizuri wakati: - Uwekaji lebo ni ghali na bwawa lisilo na lebo ni kubwa - Data ina muundo wazi ambao mfano unaweza kutumia kutambua mifano ya habari - Darasa la mfano linafaa kwa kazi

Ujifunzaji tendaji hufanya vibaya wakati: - Mfano wa awali ni mbaya sana (kuanza baridi) na hauwezi kupanga mifano kwa maana - Mkakati wa maswali huchagua nje ya kawaida au mifano iliyowekewa lebo vibaya (ustahimilivu wa kelele una umuhimu) - Usambazaji wa data unahamia kati ya bwawa lisilo na lebo na usambazaji wa upimaji

Wasiwasi mkuu wa vitendo ni **kutofautiana kwa usambazaji**: ujifunzaji tendaji huwa huuliza mifano karibu na mpaka wa uamuzi, ukiunda seti ya lebo iliyobaguliwa ambayo inaweza kutokuwakilisha vizuri usambazaji wa upimaji. Hii inaweza kusababisha mipaka ya uamuzi iliyofunzwa vizuri lakini urekebishaji mbaya.

> **See also:** Utafiti wa msingi ni {cite}`settles2009active`. Misingi ya kinadharia (ugumu wa lebo, mipaka ya agnostiki): {cite}`balcan2006agnostic`. Kwa ujifunzaji tendaji maalum wa kujifunza kwa kina, angalia {cite}`ash2020deep` (BADGE) na {cite}`sener2018active` (seti ya msingi). Kwa tathmini ya kina ya wakati ujifunzaji tendaji husaidia kweli, angalia {cite}`lowell2019practical`. Kuhusu wasiwasi wa aleatoric dhidi ya epistemic kwa mifano ya kina, angalia {cite}`kendall2017uncertainties`; kwa makundi ya kina kama wakadiriaji wa wasiwasi, angalia {cite}`lakshminarayanan2017simple`; kwa MC Dropout kama inferensi ya takriban ya Bayesian, angalia {cite}`gal2016dropout`.

Ujifunzaji wa Mashine wa Mwingiliano

Ujifunzaji tendaji huuliza swali la makusudi: kwa bajeti fulani, mifano ipi ninapaswa kuweka lebo? Ujifunzaji wa Mashine wa Mwingiliano (IML) huuliza swali pana zaidi: tunawezaje kubuni *mwingiliano wote* kati ya binadamu na mfumo wa kujifunza kuwa wa uzalishaji wa juu, wa kufurahisha, na sahihi?

IML inajulikana na **haraka** na **moja kwa moja** ya mzunguko wa maoni kati ya binadamu na mfano. Ambapo ML ya kitambo inahusisha binadamu kusambaza data na kusubiri mafunzo kukamilika, IML huwezesha binadamu kuangalia tabia ya mfano, kutoa maoni, na kuona mfano ukijibu — mara nyingi ndani ya sekunde.

Kanuni za Ujifunzaji wa Mashine wa Mwingiliano

Amershi et al. {cite}`amershi2014power` wanatambua sifa tatu za msingi za IML:

1. Maoni ya Haraka: Mfano husasishwa haraka ya kutosha kwa binadamu kuhisi athari ya maoni yao. Katika kikomo, masasisho ya mfano hutokea wakati wa sasa hivi.

2. Udhibiti wa Moja kwa Moja: Binadamu hushirikiana na mfano kupitia data au kupitia utabiri wa mfano — si kupitia faili za usanidi au kurekebisha vigezo vya juu.

3. Uboreshaji wa Mzunguko: Mchakato ni wa mzunguko wa kweli: hatua ya binadamu inayofuata inajulishwa na tabia ya sasa ya mfano, ambayo iliundwa na hatua za awali za binadamu.

Hii inaunda **mzunguko wa urekebishaji wa pamoja** uliofungwa: binadamu na mfano wote wanabadilika baada ya muda kujibu wao kwa wao. Binadamu anajifunza mfano unaelewa nini; mfano unajifunza binadamu anajali nini.

Ulinganisho na Ujifunzaji Tendaji

IML na ujifunzaji tendaji vinaingiliana sana lakini si sawa:

Sifa	Ujifunzaji Tendaji	ML ya Mwingiliano
Swali kuu	Nini cha kuweka lebo?	Jinsi ya kushirikiana?
Muda wa maoni	Inaweza kuwa vifurushi (siku)	Kawaida wakati wa sasa au karibu
Mara ya sasisha ya mfano	Kwa raundi (vifurushi)	Kwa mwingiliano (mtandaoni)
Wakala wa binadamu	Hujibu maswali ya mfano	Anaweza kufundisha mfano kwa hiari

Sifa	Ujifunzaji Tendaji	ML ya Mwingiliano
Muundo wa kiolesura	Wasiwasi wa pili	Wasiwasi mkuu
Mzigo wa kiakili wa binadamu	Hauhesabiwi waziwazi	Huzingatiwa waziwazi

Katika ujifunzaji tendaji, mashine inaelekeza mwingiliano. Katika IML, binadamu pia anaweza kuchukua hatua — kutoa mifano, marekebisho, au maoni kuhusu sehemu yoyote ya tabia ya mfano inayoonekana kuwa na matatizo zaidi.

Mwingiliano wa Hiari Iliyochanganywa

Mifumo ya **hiari iliyochanganywa** huruhusu binadamu na mashine wote kuchukua uongozi wakati tofauti {cite}`allen1999mixed`. Mfumo ulioelekezwa na mashine peke yake huuliza maswali na binadamu hujibu. Mfumo ulioelekezwa na binadamu peke yake humwacha binadamu kufanya maamuzi yote. Mifumo ya hiari iliyochanganywa inasawazisha vyote viwili.

Katika mazoezi, mifumo bora ya IML huchanganya: - **Hiari ya mashine:** "Sijui kuhusu mifano hii — unaweza kuweka lebo?" - **Hiari ya binadamu:** "Naona mfano una makosa ya mara kwa mara kuhusu kategoria hii — acha nitoe mifano zaidi" - **Uthibitisho:** Mfano unaonyesha uelewa wake wa sasa; binadamu anahakikisha au kurekebisha

Violesura bora vya IML vinafanya uelewa wa sasa wa mfano kuonekana na kurekebishika. Hii ndiyo mahitaji ya **ufahamikaji**: binadamu anaweza tu kuongoza mfano anaoufahamu, angalau kwa takriban.

Mambo ya Kibinadamu katika IML

IML huleta mambo ya kibinadamu — mzigo wa kiakili, uchovu, uthabiti, na imani — moja kwa moja katika mzunguko wa kujifunza. Muundo mbaya wa IML husababisha:

Uchovu wa uwekaji maelezo: Binadamu wanaofanya maamuzi ya haraka, yasiyojali zaidi kadri vikao vinavyoendelea. Makosa yanayoingia katika data ya mafunzo.

Upendeleo wa nanga: Binadamu wanaoitegemea kupita kiasi mapendekezo ya sasa ya mfano. Kiolesura kikijaza mapema utabiri wa mfano, wawekaji maelezo uwezekano mdogo wa kurekebisha hata iwapo ni kosa — chanzo cha kimfumo cha kelele za lebo zinazokusanyika kati ya raundi za uwekaji maelezo {cite}`geva2019annotator`. Uwekaji maelezo wa awali unaweza kuharakisha uzalishaji {cite}`lingren2014evaluating` huku wakati huo huo ukipunguza kasi ambayo wawekaji maelezo wanagundua makosa ya mfano; athari hizi mbili zinapaswa kupimwa moja dhidi ya nyingine katika muundo wa kiolesura cha IML.

Urekebishaji mbaya wa imani: Binadamu wanaoimini kupita kiasi (wakubali matokeo mabaya ya mfano) au wasioamini (kupuuza mapendekezo sahihi). Mifumo yote miwili inapunguza thamani ya ushirikiano kati ya binadamu na mfano.

Uthabiti wa kikao: Binadamu wanaweza kufanya maamuzi tofauti kuhusu mfano sawa wakati tofauti, hasa baada ya vikao virefu. Ukaguzi wa uthabiti (kuwasilisha tena mifano ya awali) unaweza kugundua na kurekebisha hili.

Muundo mzuri wa IML unapunguza matatizo haya kupitia mipango ya kiolesura: kuwasilisha imani ya mfano waziwazi, kufanya mpangilio wa onyesho bila mpangilio, kupunguza urefu wa kikao, na kujenga ukaguzi wa uthabiti.

Aina za Maoni ya IML katika Mazoezi

Maoni ya Kiwango cha Mfano

Binadamu hutoa lebo au marekebisho kwa mfano maalum. Hii ndiyo aina ya kawaida zaidi na inaoana moja kwa moja na ujifunzaji wa usimamizi.

Maoni ya Kiwango cha Kipengele

Binadamu anaonyesha vipengele vipi vina umuhimu au si na umuhimu. "Mfano unapaswa kuzingatia maneno 'ya haraka' na 'mwisho' kwa kategoria hii." Hii inaonyesha zaidi kuliko maoni ya kiwango cha mfano na inaweza kuwa ya ufanisi zaidi kwa kazi fulani.

TFIDF Interactive na mifumo inayofanana huruhusu wawekaji maelezo kuangazia maneno muhimu katika hati za maandishi. Sehemu hizi zilizoangaliwa zinabadilishwa kuwa vikwazo au usimamizi wa ziada kwenye makini ya mfano.

Maoni ya Kiwango cha Mfano

Binadamu anarekebisha moja kwa moja tabia ya mfano kwenye darasa la ingizo: "Kila wakati ingizo lina [X], tokeo linapaswa kuwa [Y]." Hii inawiana na sheria za mantiki au vikwazo katika mbinu kama Urekebishaji wa Nyuma {cite}`ganchev2010posterior` au kujifunza kwa vikwazo.

Mfano wa Kesi: Google Teachable Machine

Teachable Machine ni mfumo wa IML unaoweza kufikiwa kupitia wavuti ambao humruhusu mtumiaji asiye na ujuzi wa kiufundi kufunza wasambazaji wa picha kwenye kivinjari. Mtumiaji:

1. Anarekodi mifano ya kila darasa kwa kutumia kamera yake
2. Anafunza mfano kwa kubonyeza mara moja (kurekebisha fini MobileNet kwenye kivinjari)
3. Anaona mara moja utabiri wa mfano kwenye video ya wakati wa sasa hivi
4. Anaongeza mifano zaidi kwa madarasa ambayo mfano unakosea

Hii inaonyesha mzunguko wa msingi wa IML: toa mifano □ angalia mfano □ tambua kushindwa □ toa mifano zaidi yenye lengo. Maoni ya wakati wa sasa hivi (matokeo ya mfano yanasasishwa wakati wa sasa hivi, kawaida kwa viwango vya fremu vya mwingiliano kwenye vifaa vya kisasa) hufanya mzunguko wa urekebishaji wa pamoja kuwa wa karibu na wa kugusa.

Kutekeleza Mzunguko Rahisi wa IML

```python
import numpy as np
from sklearn.linear_model import SGDClassifier
from sklearn.preprocessing import StandardScaler
import warnings
warnings.filterwarnings('ignore')

class SimpleIMLSystem:
    """
    Minimal IML system that allows online feedback and displays
    model state after each annotation.
    """

    def __init__(self, n_features=10, n_classes=2):
        self.model = SGDClassifier(loss='log_loss', max_iter=1, warm_start=True,
                                   random_state=42)
        self.scaler = StandardScaler()
        self.X_seen = []
        self.y_seen = []
        self.n_classes = n_classes
        self.initialized = False

    def update(self, x, y_true):
        """Receive a single labeled example and update the model."""
        self.X_seen.append(x)
        self.y_seen.append(y_true)

        if len(self.X_seen) >= 2 * self.n_classes:
            X_arr = np.array(self.X_seen)
            y_arr = np.array(self.y_seen)
            X_scaled = self.scaler.fit_transform(X_arr)
            self.model.partial_fit(X_scaled[-1:], y_arr[-1:],
                                   classes=list(range(self.n_classes)))
            self.initialized = True

        return self

    def predict_with_confidence(self, x):
        """Predict label and return confidence."""
        if not self.initialized:
            return None, 0.0
        x_scaled = self.scaler.transform(x.reshape(1, -1))
        probs = self.model.predict_proba(x_scaled)[0]
        return self.model.predict(x_scaled)[0], probs.max()

    def current_accuracy(self, X_val, y_val):
        if not self.initialized:
            return None
        X_scaled = self.scaler.transform(X_val)
        return (self.model.predict(X_scaled) == y_val).mean()
```

```
# Simulate an IML session
rng = np.random.default_rng(42)
X_all, y_all = np.random.default_rng(0).random((500, 10)), np.random.default_rng(0).integers(
X_val, y_val = X_all[400:], y_all[400:]

system = SimpleIMLSystem(n_features=10, n_classes=2)
accs, confidences = [], []

print("Step | Labels | Accuracy | Example confidence")
print("-" * 50)

for step in range(100):
    x, y = X_all[step], y_all[step]
    pred, conf = system.predict_with_confidence(x)
    system.update(x, y)

    if (step + 1) % 10 == 0:
        acc = system.current_accuracy(X_val, y_val)
        if acc is not None:
            accs.append(acc)
            print(f"  {step+1:3d} |  {step+1:4d}  |  {acc:.3f}   | {conf:.3f}")
```

Mtihani wa Bibi

Kipimo kimoja cha manufaa cha kutathmini muundo wa kiolesura cha IML — na muundo wa mfumo wa HITL kwa upana zaidi — ni tunachokiita **Mtihani wa Bibi** (neno asili lililoanzishwa hapa kama kikwazo cha muundo, si kama rejeleo la kazi za awali):

> *Mwanamke aliyezaliwa mwaka 1930 anapaswa kuweza kutumia kifaa hiki kwa sauti, na akichanganyikiwa, ashuke kwa ustadi hadi kiolesura cha kibodi au maandishi.*

Mtihani huu si wa ufikiaji hasa, ingawa ni hilo pia. Ni kuhusu **kubuni kwa mgongano**. Kama mfumo unahitaji mfano wa akili wa mitandao ya neva, mizunguko ya mafunzo, au usambazaji wa uwezekano kutumika vizuri, umeshindwa Mtihani wa Bibi. Binadamu katika mzunguko anapaswa kuweza kushiriki bila kuelewa upande wa mashine wa mzunguko.

Athari kwa muundo wa IML ni za moja kwa moja:

Kuanguka kwa sauti kwanza: Hali ya kwanza ya mwingiliano inapaswa kuwa lugha asilia au ishara — si vitelezi vya vigezo au vizingiti vya imani. Wataalamu wanaweza kutaka vitelezi; kila mtu anapaswa kuweza kusema "hilo ni kosa."

Kuanguka kwa neema: Wakati hali ya mwingiliano inayopendelewa ya mtumiaji inashindwa au kumfadhaisha, mfumo unapaswa kutoa mbadala — si skrini tupu au ujumbe wa kosa. Kiolesura ni sehemu ya mfumo wa kujifunza; mtumiaji ambaye hawezi kushirikiana hawezi kufundisha.

Hali ya mfano inayosomeka: Uelewa wa sasa wa mfano unapaswa kuonekana kwa maneno ya kibinadamu. Si "imani: 0.73" bali "Niko wazi kabisa hii ni [X], lakini nimekuona mifano kama hii ikienda pande zote mbili." Wasiwasi unapaswa kuwasilishwa katika lugha inayokaribisha

marekebisho.

Uvumilivu wa utata: Mtumiaji wa umri wa miaka 93 na mhandisi wa ML wa umri wa miaka 23 watashirikiana tofauti na mfumo sawa. Mtihani wa Bibi unauliza kama mfumo unaweza kukubaliana na wote wawili — si kwa kugundua umri wa mtumiaji, bali kwa kubuni mwingiliano unaofanya kazi kwa anuwai ya utaalamu na starehe.

Mtihani huu una umuhimu maalum mifumo ya ML inapohamia kutoka kwa zana za utafiti hadi miundombinu ya kila siku. Msaada wa kupiga picha za kimatibabu unaotumika na madaktari wa radiolojia, kisambazaji cha hati za kisheria kinachotumika na wasimamizi, mfumo wa maoni ya elimu unaotumika na walimu — kila mmoja unahusisha binadamu katika mzunguko ambao hawakujiandikisha kuwa wafunzaji wa AI. Kubuni kwao si makubaliano; ni lengo.

:::{admonition} Kanuni ya Muundo :class: tip Mtihani wa Bibi ni kikwazo cha muundo, si idadi ya walengwa. Mifumo inayopita inastahimili zaidi utofauti wa watumiaji, inasamehe zaidi pengo la utaalamu, na ni ya uaminifu zaidi kuhusu kinachohitajiwa kutoka kwa binadamu katika mzunguko. Kama mfumo unahitaji maelezo kabla ya kutumika, unomba binadamu afanye kazi ya ziada. Kazi hiyo inapaswa kuhesabiwa na manufaa ya kulinganishwa. :::

IML na Mifano ya Msingi

IML ya kisasa mara nyingi inatumia **mifano ya msingi iliyofunzwa awali** {cite}`bommasani2021opportunities` kama msingi. Badala ya kufunza kutoka mwanzo, watumiaji wanaboresha fini mfano mkubwa uliofunzwa awali na mifano michache ya mwingiliano. Hii inaweza kupunguza sana idadi ya mifano inayohitajika kufikia utendaji unaofaa — katika hali nzuri, mifano 5–50 tu badala ya maelfu, kulingana na jinsi uwakilishi wa awali unavyooana na kazi inayolengwa {cite}`bommasani2021opportunities`.

Mbinu zinazomwezesha hili ni pamoja na: - **Maswali ya mifano michache:** Kutoa mifano katika dirisha la muktadha la LLM - **Kurekebisha fini kwa kiambatisho:** Kusasisha moduli ndogo za kiambatisho huku ukifunza mfano wa msingi - **Kurekebisha fini kwa ufanisi wa vigezo (PEFT):** LoRA, kurekebisha kiambishi, na mbinu zinazofanana zinazokuruhusu masasisho ya haraka, ya rasilimali ndogo

Mifano ya msingi inabadilisha mienendo ya IML: binadamu hawafundishi tena mfano wa mwanzo kutoka mwanzo bali *wanasimamia* mfano ambao tayari unajua mengi sana. Changamoto inahamia kutoka "jinsi ya kutoa mifano ya kutosha" hadi "jinsi ya kubainisha hasa tunachotaka tofauti na mfano unavyofanya tayari."

> **See also:** Utafiti wa {cite}`amershi2014power` unabaki kuwa mapitio bora ya kanuni za IML. Kwa mifumo ya hiari iliyochanganywa hasa, angalia {cite}`allen1999mixed`. Kwa athari za nanga katika uwekaji maelezo, angalia {cite}`geva2019annotator` na {cite}`lingren2014evaluating`.

Ujifunzaji wa Kuimarisha kutoka kwa Maoni ya Binadamu

Hakuna mbinu iliyofanya zaidi kuleta HITL ML kwenye mkondo mkuu kuliko Ujifunzaji wa Kuimarisha kutoka kwa Maoni ya Binadamu (RLHF). Ndiyo njia nyuma ya InstructGPT {cite}`ouyang2022training` na sehemu kuu ya mifumo ya kufuata maelekezo katika mifano mingi ya kisasa ya lugha kubwa {cite}`stiennon2020learning`. Kuelewa RLHF — si kama njia ya kufuata tu, bali kama mbinu ya msingi ya upatanisho — ni muhimu kwa kila mtu anayefanya kazi katika AI ya kisasa.

Tatizo la Upatanisho

Mifano mikubwa ya lugha (LLMs) iliyofunzwa peke yake kwenye utabiri wa tokeni inayofuata inaboresha kwa lengo la wakala: tabiri maandishi gani yanafuata katika mkusanyiko wa maandishi yaliyoandikwa na binadamu. Lengo hili linahusiana na, lakini linatofautiana na, tunachotaka kweli: majibu yanayosaidia, sahihi, salama, na yaliyopatanishwa na maadili ya binadamu.

Kutofautiana kati ya lengo la mafunzo na tabia inayotakiwa huitwa **tatizo la upatanisho** {cite}`russell2019human`. Kwa mwonekano halisi, mfano wa lugha uliofunzwa kwenye maandishi ya mtandao hujifunza: - Kutoa matoleo yanayosikika yanayokubalika (ambayo yanaweza kuwa mabaya kiukweli) - Kuakisi upendeleo na madhara yaliyopo katika data ya mafunzo - Kuepuka au kudanganya wakati hii ndiyo kinachofuata maswali kwa takwimu

RLHF inashughulikia upatanisho kwa kufanya mapendeleo ya binadamu *sehemu ya lengo la uboreshaji*.

Mfumo wa RLHF

RLHF inaendelea katika hatua tatu:

```
Hatua ya 1: Kurekebisha Fini kwa Usimamizi (SFT)
  --> Kusanya data ya maonyesho (binadamu anaandika majibu bora)
  --> Kurekebisha fini LLM ya msingi kwenye maonyesho

Hatua ya 2: Mafunzo ya Mfano wa Zawadi
  --> Kusanya mapendeleo ya jozi (binadamu anipanga A dhidi ya B)
  --> Funza mfano wa zawadi R(x, y) kutabiri mapendeleo ya binadamu
```

```
Hatua ya 3: Kurekebisha Fini kwa RL
  --> Kurekebisha fini LLM kwa kutumia PPO/RL ili kuongeza juu R(x, y)
  --> Adhabu ya KL inazuia kupotoka kupita kiasi kutoka kwa mfano wa SFT
```

Hatua ya 1: Kurekebisha Fini kwa Usimamizi

Kuanzia na mfano wa msingi uliofunzwa awali π_0, tunakusanya mkusanyiko wa jozi za (maswali, jibu bora), zilizoandikwa au kuchaguliwa na wakandarasi wa binadamu wanaofuata mwongozo wa kina. Mfano unaboreshwa fini kwenye maonyesho haya kwa kutumia entropy iliyovuka ya kawaida:

$$\mathcal{L}_{\text{SFT}}(\theta) = -\mathbb{E}_{(x,y)\sim\mathcal{D}_{\text{demo}}}\left[\log \pi_\theta(y \mid x)\right]$$

Mfano wa SFT π_{SFT} ni hatua bora zaidi ya kuanza kwa RLHF kuliko mfano ghafi uliofunzwa awali.

Hatua ya 2: Mafunzo ya Mfano wa Zawadi

Kwa seti ya maswali $\{x_i\}$, tunazalisha majibu K kwa swali kila moja kwa kutumia π_{SFT} na kuwasilisha kwa wawekaji lebo wa binadamu kama ulinganisho wa jozi: "Jibu gani ni bora, A au B?"

Mfano wa zawadi r_ϕ unafunzwa kutabiri mapendeleo haya. Chini ya mfano wa **Bradley-Terry** (Sura ya 8), uwezekano kwamba jibu y_w linapendelewa kuliko y_l ni:

$$P(y_w \succ y_l \mid x) = \sigma\left(r_\phi(x, y_w) - r_\phi(x, y_l)\right)$$

Mfano wa zawadi unafunzwa kupunguza hasara ya upangaji wa jozi:

$$\mathcal{L}_{\text{RM}}(\phi) = -\mathbb{E}_{(x,y_w,y_l)\sim\mathcal{D}_{\text{pref}}}\left[\log \sigma\left(r_\phi(x, y_w) - r_\phi(x, y_l)\right)\right]$$

Mfano wa zawadi kawaida huanzishwa kutoka kwa mfano wa SFT na kichwa cha nambari kinachobadilisha safu ya mwisho.

Hatua ya 3: Kurekebisha Fini kwa RL kwa PPO

Na mfano wa zawadi uliofunzwa, tunaweza kutumia ujifunzaji wa kuimarisha kurekebisha fini LLM. Kila swali x ni hali; kila jibu y ni mfululizo wa uchaguzi wa tokeni; na zawadi ni $r_\phi(x, y)$.

Lengo la uboreshaji linajumuisha **adhabu ya kupotoka kwa KL** kuzuia mfano usipotoke mbali sana kutoka kwa msingi wa SFT (ambao ungesababisha udanganyifu wa zawadi {cite}`krakovna2020specification,gao2023scaling`):

$$\max_\theta \mathbb{E}_{x\sim\mathcal{D}, y\sim\pi_\theta(\cdot|x)}\left[r_\phi(x, y) - \beta \cdot \text{KL}\left[\pi_\theta(\cdot \mid x) \| \pi_{\text{SFT}}(\cdot \mid x)\right]\right]$$

Kigezo β kinasimamia nguvu ya adhabu ya KL. β ndogo inaruhusu uboreshaji zaidi lakini inaweza kusababisha udanganyifu wa zawadi; β kubwa inaweka mfano karibu na SFT lakini inapunguza faida za upatanisho.

Uboreshaji wa Sera ya Karibu (PPO) {cite}`schulman2017proximal` ndiyo kanuni ya kawaida kwa hatua hii, iliyochaguliwa kwa uthabiti wake ukilinganishwa na mbinu ghafi za gradient ya sera.

Onyesho Lililorahisishwa la RLHF

Mfumo kamili wa RLHF unahitaji miundombinu ya kiwango kikubwa. Mfano ufuatao unaonyesha mawazo muhimu kwa kiwango kidogo.

```
import numpy as np
import torch
import torch.nn as nn
import torch.optim as optim
from torch.nn import functional as F

torch.manual_seed(42)
rng = np.random.default_rng(42)

# ----------------------------------------------
# Toy setup: responses are 4-dimensional vectors
# "Quality" is known analytically (sum of positive values)
# We simulate a reward model learning this from pairwise feedback
# ----------------------------------------------

class RewardModel(nn.Module):
    def __init__(self, d=4, hidden=32):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(d, hidden), nn.ReLU(),
            nn.Linear(hidden, hidden), nn.ReLU(),
            nn.Linear(hidden, 1)
        )
    def forward(self, x):
        return self.net(x).squeeze(-1)

def true_quality(x):
    """The hidden ground-truth reward function."""
    return x.sum(dim=-1) + 0.5 * (x ** 2).mean(dim=-1)

# Generate pairwise preference data
N_PAIRS = 500
X1 = torch.randn(N_PAIRS, 4)
X2 = torch.randn(N_PAIRS, 4)
q1, q2 = true_quality(X1), true_quality(X2)
# Human prefers X1 when q1 > q2 (with some noise)
noise = torch.randn(N_PAIRS) * 0.5
preferred_1 = ((q1 - q2 + noise) > 0).float()

# Train reward model
rm = RewardModel(d=4, hidden=32)
```

```
optimizer = optim.Adam(rm.parameters(), lr=3e-3)

losses = []
for epoch in range(200):
    r1 = rm(X1)
    r2 = rm(X2)
    # Bradley-Terry loss
    logit = r1 - r2
    loss = F.binary_cross_entropy_with_logits(logit, preferred_1)
    optimizer.zero_grad(); loss.backward(); optimizer.step()
    losses.append(loss.item())

# Evaluate: does the reward model agree with true quality?
X_eval = torch.randn(1000, 4)
with torch.no_grad():
    r_pred = rm(X_eval).numpy()
    r_true = true_quality(X_eval).numpy()

corr = np.corrcoef(r_pred, r_true)[0, 1]
print(f"Reward model correlation with true quality: {corr:.4f}")
print(f"Final training loss: {losses[-1]:.4f}")

import matplotlib.pyplot as plt
plt.figure(figsize=(8, 3))
plt.subplot(1, 2, 1)
plt.plot(losses, color='#2b3a8f', linewidth=1.5)
plt.xlabel("Epoch"); plt.ylabel("Pairwise loss")
plt.title("Reward Model Training")

plt.subplot(1, 2, 2)
plt.scatter(r_true[:200], r_pred[:200], alpha=0.4, s=15, color='#2b3a8f')
plt.xlabel("True quality"); plt.ylabel("Predicted reward")
plt.title(f"Reward Model vs. Truth (r={corr:.3f})")
plt.tight_layout()
plt.savefig('reward_model.png', dpi=150)
plt.show()
```

Changamoto katika RLHF

Udanganyifu wa Zawadi

Hali muhimu ya kushindwa: sera inapata njia za kupata zawadi kubwa kutoka kwa mfano wa zawadi ambazo hazilingani na tabia nzuri kweli. Kwa mfano, LLM inaweza kujifunza kutoa majibu yanayopendeza au yaliyosemwa kwa ujasiri (ambayo wawekaji lebo huwa huyapanga vizuri) badala ya sahihi.

Udanganyifu wa zawadi una uwezekano zaidi wakati: - Mfano wa zawadi unafunzwa kwa data haba ya mapendeleo - Sera inaruhusiwa kupotoka mbali kutoka kwa msingi wa SFT (β ndogo) - Usambazaji wa mfano wa zawadi unahamia wakati wa mafunzo ya PPO

Mikakati ya kupunguza: Adhabu ya KL, mafunzo ya mzunguko wa mfano wa zawadi, tath-

mini mbalimbali, vikwazo vya AI ya kikatiba.

Upendeleo wa Tathmini

Wawekaji lebo wa binadamu wana upendeleo wa kimfumo. Huwa wanapendelea majibu marefu (upendeleo wa maneno mengi), maandishi yanayosikika ya ujasiri zaidi (upendeleo wa ujasiri), na majibu yanayokubaliana na imani zao za awali. Upendeleo huu unaenea katika mfano wa zawadi.

Kushindwa kwa umaarufu wa sycophancy kwa mifano ya RLHF — ambapo mfano humwambia mtumiaji anachotaka kusikia badala ya kinachoukweli — ni kwa sehemu matokeo ya upendeleo wa tathmini wa majibu ya kukubaliana.

Usimamizi unaoweza Kupanuka

Kwa kazi ngumu, binadamu hawawezi kupanga ipasavyo jibu gani la AI ni sahihi. Mweka lebo anayelinganisha uthibitisho mrefu wa hisabati au utekelezaji mbili za msimbo anaweza kuchagua rahisi zaidi kusomeka, bila kujali usahihi. **Usimamizi unaoweza kupanuka** ni tatizo la utafiti wazi la kubuni taratibu za tathmini ambazo zinabaki za kutegemewa kadri ugumu wa kazi unavyoongezeka {cite}`bowman2022measuring`.

AI ya Kikatiba (RLAIF)

AI ya Kikatiba {cite}`bai2022constitutional`, iliyotengenezwa katika Anthropic, inapunguza kutegemea wawekaji lebo wa binadamu kwa kutumia AI yenyewe kuzalisha lebo za mapendeleo zilizoongozwa na seti ya kanuni ("katiba"). Mchakato:

1. Zalisha majibu kwa maswali yanayoweza kudhuru
2. Tumia msomaji wa AI tathmini majibu dhidi ya kanuni za kikatiba
3. Rekebisha majibu yaliyoongozwa na maoni ya AI (RLAIF — RL kutoka kwa Maoni ya AI)
4. Funza mfano wa zawadi kwenye mapendeleo yaliyozalishwa na AI
5. Rekebisha fini kwa RLHF kwa kutumia mfano huu wa zawadi

RLAIF inaweza kuzalisha data ya mapendeleo kwa kiwango kikubwa zaidi sana kuliko uwekaji lebo wa binadamu, na inaruhusu udhibiti wa kina wa maadili yaliyowekwa katika mfano wa zawadi.

> **See also:** Makala asili ya InstructGPT {cite}`ouyang2022training` inaelezea utumiaji wa kwanza wa kiwango kikubwa wa RLHF kwa LLMs. Kazi ya msingi ya RLHF kwa RL ya kina ni {cite}`christiano2017deep`. PPO imeelezwa katika {cite}`schulman2017proximal`. AI ya Kikatiba inatoka kwa {cite}`bai2022constitutional`.

Kujifunza kutoka kwa Maonyesho

Kazi inapokuwa ngumu kufafanua lakini rahisi kuonyesha, inaweza kuwa ya ufanisi zaidi kufundisha kwa mfano kuliko kufafanua kwa sheria. Mtaalamu wa binadamu anaonyesha mkono wa roboti jinsi ya kushika kitu; mwingiliano wa mprogramu na IDE yake hutoa mfululizo wa mhariri sahihi; bingwa wa chess anacheza mchezo. **Kujifunza kutoka kwa maonyesho** huondoa sera kutoka kwa data kama hiyo ya kitabia, kuepuka haja ya vitendaji vya zawadi vilivyoundwa kwa mkono au maalum ya kazi waziwazi.

Kuiga Kitabia

Mbinu rahisi zaidi ni **kuiga kitabia (BC)**: tibu onyesho kama data ya usimamizi na jifunza upangaji kutoka kwa hali hadi vitendo.

Ukitoa mkusanyiko wa jozi za hali-vitendo $\mathcal{D} = \{(s_i, a_i)\}$ kutoka kwa monyeshaji mtaalamu, tunafaa sera $\pi_\theta(a \mid s)$ kwa kupunguza uwezekano wa logarithm hasi:

$$\mathcal{L}_{\text{BC}}(\theta) = -\frac{1}{|\mathcal{D}|} \sum_{(s,a)\in\mathcal{D}} \log \pi_\theta(a \mid s)$$

Hii ni hasa ujifunzaji wa kawaida wa usimamizi uliotumika kwa data ya mfululizo.

Tatizo la Mabadiliko ya Kibainishi

BC ina udhaifu wa kimsingi: **mabadiliko ya usambazaji** kati ya mafunzo na utekelezaji. Maonyesho ya mtaalamu yanashughulikia hali zilizofikiwa na mtaalamu. Lakini wakati wa utekelezaji, sera iliyojifunza inaweza kufanya maamuzi tofauti kidogo, ikiipelekea hali ambazo mtaalamu hakuwahi kutembelea — hali ambazo sera haina usimamizi na inaweza kushindwa vibaya.

Muhimu zaidi, makosa **yanakusanyika**: kupotoka kidogo kunasababisha hali isiyojulikana, ambapo hatua kidogo mbaya inasababisha hali isiyojulikana zaidi, na kadhalika. Utendaji hupungua kama $O(T^2\epsilon)$ ambapo T ni urefu wa kipindi na ϵ ni kiwango cha kosa katika kila hatua — mbaya zaidi kuliko upungufu wa $O(T\epsilon)$ wa sera ya chanzo {cite}`ross2010efficient`.

> **Mfano: Uendeshaji wa Uhuru** :class: note
>
> Mfano wa kuiga kitabia kwa kuweka njia uliopewa mafunzo kwenye data ya uendeshaji wa binadamu hufanya kazi vizuri kwenye barabara za moja kwa moja (hali karibu na usambazaji wa mafunzo). Lakini dakika inapotoka kidogo — hali ambayo dereva yeyote wa binadamu asingekuwa nayo kwa sababu wangerekebisha tayari — hana data ya kuiongoza na anaweza kuendesha nje ya barabara.

```
Kanuni ya DAgger:
  Anzisha: D <- {} (mkusanyiko tupu)
  Funza sera ya awali pi_1 kwenye maonyesho M ya wataalam

  kwa mzunguko i = 1, 2, ..., N:
    1. Endesha pi_i katika mazingira kukusanya hali {s_1, ..., s_t}
    2. Uliza mtaalamu vitendo kwenye kila hali iliyotembelewa: a_t = pi*(s_t)
    3. Jumuisha: D <- D u {(s_1, a_1), ..., (s_t, a_t)}
    4. Funza pi_{i+1} kwa ujifunzaji wa usimamizi kwenye D
```

DAgger inafikia toba ya $O(T\epsilon)$ — sawa na sera ya chanzo — kwa sababu usambazaji wa mafunzo unaungana kuoanishwa na usambazaji wa utekelezaji.

Mahitaji muhimu ni kwamba mtaalamu anaweza koulizwa hali yoyote, ikijumuisha hali ambazo mtaalamu hangekutembelea kwa asili. Hii inawezekana katika uigaji (muulize mtaalamu kurekebisha roboti kutoka kwa usanidi usio wa kawaida) lakini inaweza kuwa changamoto au si salama katika mifumo halisi ya kimwili.

Ujifunzaji wa Kuimarisha wa Nyuma

Wakati mwingine tabia ya mtaalamu inaeleweka vizuri zaidi si kama mfululizo wa vitendo vya kuigwa bali kama matokeo ya uboreshaji wa vitendaji vya zawadi visivyojulikana. **Ujifunzaji wa Kuimarisha wa Nyuma (IRL)** {cite}`ng2000algorithms` hurudisha kitendaji hiki cha zawadi kilichofichwa kutoka kwa maonyesho.

Ukitoa maonyesho $\tau = \{(s_1, a_1), \ldots, (s_T, a_T)\}$, IRL inapata kitendaji cha zawadi $R(s, a)$ ambacho sera ya mtaalamu ni bora chini ya R.

Mvuto wa IRL dhidi ya BC: tukiiboresha kitendaji cha zawadi cha kweli, tunaweza kuirekebisha tena katika mazingira mapya, na mienendo tofauti, au na wapangaji walioimarishwa — ukijumlisha mbali zaidi ya matukio yaliyoonyeshwa.

MaxEnt IRL

MaxEnt IRL {cite}`ziebart2008maximum` inatatua tatizo la utata wa IRL (kuna vitendaji vingi vya zawadi vinavyolingana na seti yoyote ya maonyesho) kwa kuchagua kitendaji cha zawadi ambacho, huku kikilingana na tabia iliyoonyeshwa, husababisha usambazaji wa njia zenye *entropi ya juu zaidi*. Njia zinasambazwa kama:

$$P(\tau \mid R) \propto \exp\left(\sum_t R(s_t, a_t)\right)$$

Lengo la kujifunza linaoanisha matarajio ya kipengele ya mtaalamu yanayoonekana $\mu_E = \mathbb{E}_{\tau\sim\pi^*}[\phi(\tau)]$ na matarajio ya kipengele ya mfano $\mu_\theta = \mathbb{E}_{\tau\sim\pi_\theta}[\phi(\tau)]$.

GAIL: Kujifunza kwa Kuiga kwa Ushindani wa Uzalishaji

GAIL {cite}`ho2016generative` inapita kujifunza kitendaji cha zawadi kabisa, kwa kutumia uundaji kama wa GAN kuoanisha moja kwa moja usambazaji wa hali-vitendo wa mtaalamu.

Kijua D_ψ kinafunzwa kutofautisha jozi za hali-vitendo za wataalam $(s, a) \sim \pi^*$ kutoka kwa jozi za hali-vitendo za sera $(s, a) \sim \pi_\theta$:

$$\mathcal{L}_D = -\mathbb{E}_{\pi^*}[\log D_\psi(s, a)] - \mathbb{E}_{\pi_\theta}[\log(1 - D_\psi(s, a))]$$

Kizalishaji (sera π_θ) kinafunzwa kudanganya kijua — yaani, kutoa jozi za hali-vitendo zinazofanana na za mtaalamu. Tokeo la kijua $\log D_\psi(s, a)$ hutumika kama ishara ya zawadi kwa sera.

GAIL inafikia utendaji wa kiwango cha wataalam kwenye vipimo vya udhibiti wa kuendelea na maonyesho machache zaidi sana kuliko BC, na inajumlisha vizuri zaidi kuliko MaxEnt IRL katika mazingira magumu.

Kuiga Kitabia katika NLP: Mfano wa Vitendo

```python
import numpy as np
import torch
import torch.nn as nn
from torch.utils.data import DataLoader, TensorDataset

torch.manual_seed(42)

# ----------------------------------------------
# Toy NLP task: rewriting sentences to be more formal
# We simulate this as a simple sequence transformation
# In practice: fine-tuning a seq2seq model on expert rewrites
# ----------------------------------------------

class SimpleSeq2Seq(nn.Module):
    def __init__(self, vocab_size=100, embed_dim=32, hidden_dim=64):
        super().__init__()
        self.embed = nn.Embedding(vocab_size, embed_dim, padding_idx=0)
        self.encoder = nn.GRU(embed_dim, hidden_dim, batch_first=True)
        self.decoder = nn.GRU(embed_dim, hidden_dim, batch_first=True)
        self.proj = nn.Linear(hidden_dim, vocab_size)
        self.hidden_dim = hidden_dim

    def forward(self, src, tgt):
        src_emb = self.embed(src)
        _, hidden = self.encoder(src_emb)
        tgt_emb = self.embed(tgt)
        out, _ = self.decoder(tgt_emb, hidden)
        return self.proj(out)

# Generate synthetic demonstration data
VOCAB = 100
rng = np.random.default_rng(42)
N, SEQ_LEN = 1000, 12

src_seqs = torch.tensor(rng.integers(1, VOCAB, (N, SEQ_LEN)), dtype=torch.long)
```

```
# "Expert" transformation: shift tokens by 1 (toy formalization)
tgt_seqs = torch.clamp(src_seqs + 1, 1, VOCAB - 1)
tgt_in  = torch.cat([torch.ones(N, 1, dtype=torch.long), tgt_seqs[:, :-1]], dim=1)

dataset = TensorDataset(src_seqs, tgt_in, tgt_seqs)
loader = DataLoader(dataset, batch_size=64, shuffle=True)

model = SimpleSeq2Seq(vocab_size=VOCAB)
optimizer = torch.optim.Adam(model.parameters(), lr=1e-3)
criterion = nn.CrossEntropyLoss(ignore_index=0)

# Behavioral cloning training
train_losses = []
for epoch in range(20):
    epoch_loss = 0
    for src, tgt_i, tgt_o in loader:
        logits = model(src, tgt_i)
        loss = criterion(logits.reshape(-1, VOCAB), tgt_o.reshape(-1))
        optimizer.zero_grad(); loss.backward(); optimizer.step()
        epoch_loss += loss.item()
    train_losses.append(epoch_loss / len(loader))

print(f"Initial loss: {train_losses[0]:.3f}")
print(f"Final loss:   {train_losses[-1]:.3f}")

# Evaluate: check token accuracy on held-out examples
model.eval()
with torch.no_grad():
    src_test = src_seqs[-100:]
    tgt_test_in = tgt_in[-100:]
    tgt_test_out = tgt_seqs[-100:]
    logits = model(src_test, tgt_test_in)
    preds = logits.argmax(dim=-1)
    acc = (preds == tgt_test_out).float().mean().item()
    print(f"Token accuracy on held-out set: {acc:.3f}")
```

Ulinganisho wa Mbinu za Kujifunza kwa Kuiga

Mbinu	Inahitaji zawadi?	Mtaalamu aulizwa mtandaoni?	Inajumlisha kwa mienendo mipya?	Ugumu
Kuiga Kitabia	Hapana	Hapana	Vibaya (mabadiliko ya usambazaji)	Chini
DAgger	Hapana	Ndiyo	Kwa wastani	Wastani
MaxEnt IRL	Huirejesha	Hapana	Vizuri	Juu
GAIL	Hapana	Hapana	Vizuri	Juu

Matumizi

Roboti. Kufundisha roboti kushughulikia vitu, kusogea katika mazingira, au kufanya kazi za nyumbani. Maonyesho ya kimwili yanakusanywa kupitia utendaji wa mbali au ufundishaji wa kinesthetic.

Uendeshaji wa uhuru. Mifumo ya mapema ya uendeshaji wa kujitegemea kama ALVINN {cite}`pomerleau1989alvinn` na DAVE ya NVIDIA ilitegemea sana kuiga kitabia kutoka kwa data ya uendeshaji wa binadamu.

AI ya mchezo. Kujifunza kwa kuiga kwenye mchezo wa binadamu huanzisha mawakala kabla ya kurekebisha fini kwa RL. AlphaStar ilifunzwa kwenye nakala za binadamu kabla ya RL; mbinu hii ni ya kawaida wakati maonyesho ya kiwango cha binadamu yanapatikana.

Uzalishaji wa msimbo. Kurekebisha fini kwa mfano wa lugha kwenye maonyesho ya msimbo wa ubora wa juu (GitHub Copilot, Codex) ni aina ya kuiga kitabia.

Msaada wa maamuzi ya kliniki. Kujifunza kutoka kwa mfululizo wa maamuzi wa daktari mtaalamu kwa itifaki ngumu.

> **See also:** Uchambuzi wa msingi wa BC/DAgger upo katika {cite}`ross2011reduction`. MaxEnt IRL inatoka kwa {cite}`ziebart2008maximum`. GAIL inatoka kwa {cite}`ho2016generative`. Kwa mapitio ya kina ya kujifunza kwa kuiga, angalia {cite}`osa2018algorithmic`.

Kujifunza kutoka kwa Ulinganisho na Upangaji wa Daraja

Kumuuliza binadamu atoe alamu kamili ya ubora kwa tokeo ni ngumu. Ubora wa nambari wa insha hii ni nini, kwenye kipimo cha 1 hadi 10? Swali hilo halina msingi: binadamu wana upungufu wa kipimo thabiti cha ndani, na alamu zao zinaathiriwa sana na nanga, muktadha, na uchovu.

Kumuuliza binadamu *alinganishe* matokeo mawili ni rahisi zaidi sana: insha ipi ni bora, A au B? Hukumu za kulinganishwa ni thabiti zaidi, za kutegemewa zaidi, na zinafikia mapendeleo ya binadamu moja kwa moja zaidi kuliko alamu kamili. Sura hii inashughulikia misingi ya kihesabu na matumizi ya vitendo ya kujifunza kutoka kwa ulinganisho na upangaji wa daraja.

Kwa Nini Ulinganisho ni Bora Kuliko Alamu

Msingi wa Kisaikolojia

Ubora wa hukumu za kulinganishwa una historia ndefu katika upimaji wa kisaikolojia. Sheria ya Hukumu ya Kulinganishwa ya Thurstone {cite}`thurstone1927law` (1927) ilionyesha kwamba hata binadamu wanapokuwa na hukumu zisizo thabiti kamili, hukumu zao za kulinganishwa hufuata sheria thabiti ya uwezekano. Ulinganisho hutumia ukweli kwamba binadamu ni bora zaidi katika *mtazamo wa kilinganisho* kuliko urekebishaji kamili.

Ufanisi wa Takwimu

Kila ulinganisho wa jozi hutoa taarifa kuhusu nafasi za *kilinganisho* za vipengele viwili kwenye kipimo cha ubora. Na vipengele K, ulinganisho $K - 1$ unaweza kupanga vipengele vyote; ulinganisho $O(\log K)$ tu unahitajika kupata kipengele cha juu zaidi. Alamu kamili kawaida zinahitaji hukumu zaidi kufikia usahihi sawa.

Upanuzi

Kwa mifano ya uzalishaji, idadi ya matokeo tofauti ni ya uhesabuiwa na haina mwisho. Kupanga tokeo kamili kunahitaji kuanzisha kipimo cha pamoja kwa matokeo yote; kulinganisha matokeo kunahitaji tu hukumu za ndani, za kilinganisho ambazo zina urekebishaji wa asili kwa kila mmoja.

Mfano wa Bradley-Terry

Mfano mkubwa wa uwezekano kwa ulinganisho wa jozi ni **mfano wa Bradley-Terry (BT)** {cite}`bradley1952rank`. Kila kipengele i kina alamu ya ubora ya picha $\alpha_i \in \mathbb{R}$. Uwezekano kwamba kipengele i kinapendelewa kuliko kipengele j katika ulinganisho wa moja kwa moja ni:

$$P(i \succ j) = \frac{e^{\alpha_i}}{e^{\alpha_i} + e^{\alpha_j}} = \sigma(\alpha_i - \alpha_j)$$

ambapo σ ni sigmoid ya logistiki. Hii inafanana na kudhania kwamba ubora unaotambuliwa wa kipengele i ni $\alpha_i + \epsilon$ ambapo ϵ ni neno la kelele la kawaida la logistiki.

Utambulikaji

Mfano wa BT unajulikana hadi tafsiri: kama α ni suluhisho, $\alpha + c$ pia ni suluhisho kwa kila mara c. Makubaliano ya kawaida ni kurekebisha alamu moja (k.m., $\alpha_0 = 0$) au kuzuia $\sum_i \alpha_i = 0$. Alamu zinajulikana tu wakati **grafu ya ulinganisho** (nodi = vipengele, pembe = jozi zinazoonekana) imeunganishwa — kama grafu ina sehemu zilizokatika, alamu za kilinganisho kati ya sehemu hazijaelezwa.

Makadirio ya Vigezo

Ukitoa mkusanyiko wa ulinganisho wa jozi $\mathcal{D} = \{(i, j, y_{ij})\}$ ambapo $y_{ij} = 1$ kama i ilipendelewa kuliko j, kiwango cha uwezekano cha logarithm ni:

$$\mathcal{L}(\alpha) = \sum_{(i,j,y_{ij}) \in \mathcal{D}} \left[y_{ij} \log \sigma(\alpha_i - \alpha_j) + (1 - y_{ij}) \log \sigma(\alpha_j - \alpha_i) \right]$$

Hii ni kitendaji chenye msongamano wa α na kinaweza kuboreshwa kupitia kupanda kwa gradient au mbinu ya Newton.

```
import numpy as np
from scipy.optimize import minimize
from scipy.special import expit  # sigmoid

rng = np.random.default_rng(42)

# ----------------------------------------------
# Simulate Bradley-Terry: 8 items with true quality scores
# Generate pairwise comparisons and recover the scores
# ----------------------------------------------

N_ITEMS = 8
true_alpha = rng.normal(0, 1, N_ITEMS)
print(f"True quality ranking: {np.argsort(true_alpha)[::-1]}")

# Generate comparisons: every pair compared 5 times
comparisons = []
for i in range(N_ITEMS):
    for j in range(i + 1, N_ITEMS):
        for _ in range(5):
```

```
            p_i_wins = expit(true_alpha[i] - true_alpha[j])
            winner = i if rng.random() < p_i_wins else j
            loser  = j if winner == i else i
            comparisons.append((winner, loser))

print(f"Total comparisons: {len(comparisons)}")

def neg_log_likelihood(alpha, comparisons):
    """Bradley-Terry negative log-likelihood."""
    alpha = np.array(alpha)
    loss = 0.0
    for winner, loser in comparisons:
        log_prob = np.log(expit(alpha[winner] - alpha[loser]) + 1e-10)
        loss -= log_prob
    return loss

def neg_grad(alpha, comparisons):
    alpha = np.array(alpha)
    grad = np.zeros(len(alpha))
    for winner, loser in comparisons:
        p = expit(alpha[winner] - alpha[loser])
        grad[winner] -= (1 - p)
        grad[loser]  -= (-p)
    return grad

# Fix alpha[0] = 0 to resolve scale ambiguity
result = minimize(
    lambda a: neg_log_likelihood(np.concatenate([[0.0], a]), comparisons),
    x0=np.zeros(N_ITEMS - 1),
    jac=lambda a: neg_grad(np.concatenate([[0.0], a]), comparisons)[1:],
    method='L-BFGS-B'
)
est_alpha = np.concatenate([[0.0], result.x])

# Compare true vs estimated ranking
true_rank = np.argsort(true_alpha)[::-1]
est_rank  = np.argsort(est_alpha)[::-1]

print(f"\nTrue ranking (item indices): {true_rank}")
print(f"Estimated ranking:           {est_rank}")
rank_corr = np.corrcoef(true_alpha, est_alpha)[0, 1]
print(f"Correlation with true scores: {rank_corr:.4f}")
```

Mfano wa Thurstone

Mfano wa Thurstone {cite}`thurstone1927law` unahusiana sana na Bradley-Terry lakini unatumia kelele ya Gaussian badala ya logistiki:

$$P(i \succ j) = \Phi\left(\frac{\alpha_i - \alpha_j}{\sqrt{2}\sigma}\right)$$

ambapo Φ ni CDF ya kawaida ya kawaida. $\sigma = 1/\sqrt{2}$ ikifaa, hii inakuwa sawa na BT na tofauti ndogo ya kupimia. Katika mazoezi, mifano miwili inatoa matokeo yanayofanana karibu.

Ujumuishaji wa Upangaji

Kila mweka maelezo anapotoa upangaji kamili wa vipengele K (badala ya ulinganisho wa jozi), tatizo ni **ujumuishaji wa upangaji**: changanya orodha nyingi zilizopangwa kuwa upangaji wa makubaliano.

Hesabu ya Borda: Kila kipengele hupokea alamu sawa na idadi ya vipengele vilivyopangwa chini yake katika upangaji wa kila mweka maelezo. Alamu zinajumuishwa kati ya wawekaji maelezo. Rahisi na imara.

Kemeny–Young: Pata upangaji unaopunguza jumla ya kutokubaliana kwa jozi (umbali wa Kendall tau) na upangaji wa kila mweka maelezo. Hii ni NP-ngumu kwa K kubwa lakini inaweza kutekelezwa kwa seti ndogo.

RankNet / ListNet: Mbinu za neva zinazojifunza kitendaji cha kupanga kutoka kwa orodha zilizopangwa, kuwezesha ujumla kwa vipengele ambavyo havijawahi kuonekana.

Banditi za Kupigana

Katika kujifunza mapendeleo **mtandaoni**, vipengele hufika kama mtiririko na lazima tuamue jozi zipi za kulinganisha, kusawazisha uchunguzi (kujifunza kuhusu vipengele visivyojulikana) na unyonyaji (kuwasilisha vipengele vya ubora wa juu). Hili ndilo tatizo la **banditi ya kupigana** {cite}`yue2009interactively`.

Kanuni muhimu: - **Doubler:** Inabeba kipengele cha shujaa; kinashindana nacho kwa washindani wa nasibu - **RUCB (Kizingiti cha Imani cha Kilinganisho cha Juu Zaidi):** Huhesabu vipindi vya imani vya mtindo wa UCB kwa uwezekano wa kila kipengele kushinda kila kipengele kingine - **MergeRank:** Huchanganya ulinganisho wa mtindo wa mashindano na UCB

Banditi za kupigana zinatumika katika mifumo ya mapendekezo ya mtandaoni (makala gani ya kuonyesha ijayo, ukitoa maoni ya picha) na uchimbaji wa mapendeleo wa mwingiliano kwa ukusanyaji wa data ya RLHF.

Kujifunza Mapendeleo kwa Mifano ya Lugha

Katika muktadha wa RLHF (Sura ya 6), mfano wa Bradley-Terry unatumika kufunza mfano wa zawadi. Tofauti muhimu ni **Uboreshaji wa Mapendeleo wa Moja kwa Moja (DPO)** {cite}`rafailov2023direct`, unaoonyesha kwamba lengo la RLHF linaweza kuboreshwa moja kwa moja kutoka kwa data ya mapendeleo bila kufunza mfano tofauti wa zawadi:

$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{(x,y_w,y_l)\sim\mathcal{D}}\left[\log\sigma\left(\beta\log\frac{\pi_\theta(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta\log\frac{\pi_\theta(y_l \mid x)}{\pi_{\text{ref}}(y_l \mid x)}\right)\right]$$

DPO ni rahisi zaidi kuliko RLHF kamili (hakuna mzunguko wa mafunzo wa PPO, hakuna mfano wa zawadi) huku ukifikia matokeo yanayolinganishwa au bora kwenye vipimo vingi {cite}`rafailov2023direct`. Imekuwa mbadala unaotumika sana kwa RLHF inayotegemea PPO kwa kurekebisha fini kwa kufuata maelekezo, ingawa mbinu zote mbili bado zinatumika kikamilifu na nguvu zao za kilinganisho zinategemea kazi.

Kukusanya Data ya Mapendeleo ya Ubora wa Juu

Ubora wa data ya mapendeleo unaathiri ubora wa mfano wa zawadi. Mambo muhimu ya kuzingatia:

Utofauti wa maswali. Data ya mapendeleo inapaswa kufunika usambazaji wote wa maswali ambayo mfano utakutana nayo wakati wa utekelezaji. Mapengo katika usimamizi husababisha tabia isiyotegemewa ya mfano wa zawadi katika maeneo hayo.

Utofauti wa majibu. Kulinganisha majibu mawili yanayofanana sana kutoa taarifa ndogo. Majibu yanayolinganishwa yanapaswa kutofautiana vya kutosha kwa wawekaji maelezo kuwa na upendeleo wazi.

Makubaliano ya wawekaji maelezo. Makubaliano ya chini ya wawekaji maelezo yanaonyesha vigezo vya ulinganisho vina utata. Pima makubaliano (κ ya Cohen) na rekebisha mwongozo unapokuwa chini ya viwango vinavyokubalika.

Urekebishaji. Wawekaji maelezo wanapaswa kuelewa *kwa nini* jibu moja ni bora: usaidizi, usahihi, usalama, mtindo? Kazi zinazounganisha vigezo vingi huwa hutoa mapendeleo yasiyo thabiti. Mara nyingi ni bora kukusanya mapendeleo kwenye kila kigezo kwa kujitegemea.

> **See also:** Mfano wa Bradley-Terry: {cite}`bradley1952rank`. Thurstone: {cite}`thurstone1927law`. Banditi za kupigana: {cite}`yue2009interactively`. Uboreshaji wa Mapendeleo wa Moja kwa Moja (DPO): {cite}`rafailov2023direct`.

HITL katika Usindikaji wa Lugha Asilia

Lugha asilia ni uwanja ambapo HITL ML imekuwa na athari kubwa zaidi — na ambapo matatizo yake ya dhana ya kina yanajitokeza. Lugha ni ya kijamii kwa asili: maana yake imejengwa na jamii za binadamu, pragmatiki yake inategemea muktadha na nia, na ubora wake unaweza kupimwa tu na wasomaji wa binadamu. Lakini hii pia inamaanisha kwamba uwekaji maelezo wa NLP si mchakato wa kukusanya uchunguzi tu. Ni mchakato wa *kuunda* kategoria.

Tatizo la Kijenzi katika Uwekaji Maelezo wa NLP

Katika kupiga picha za kimatibabu, kuna ukweli wa ardhi: uvimbe upo au hauko. Lebo ya daktari wa radiolojia inaweza kuwa na wasiwasi, lakini inajaribu kufuatilia kitu cha kweli. Uwekaji maelezo wa NLP mara nyingi ni tofauti kabisa kwa msingi. Mweka maelezo anapoweka alama kwenye tweet kama "yenye sumu," hakuna molekuli ya sumu katika tweet tunayojaribu kugundua. **Lebo inaunda kategoria.**

Hii ina matokeo ya kina ambayo mara nyingi hayashughulikiwi kwa kutosha:

Nguvu kazi ya uwekaji maelezo inafafanua tukio. Mpango wa lebo kwa "usemi wa kukera" unaweka hisia za yeyote aliyeubunifu na yeyote aliyeutumia. Timu ya wawekaji maelezo wanaozungumza Kiingereza kutoka kwa historia moja ya kidemografia, wakifanya kazi chini ya mwongozo ulioandikwa na timu ya sera ya shirika, huzalisha mkusanyiko wa data unaoakisi uelewa wa timu hiyo wa kukera — si kiwango cha binadamu cha kimataifa. Mifano iliyofunzwa kwenye data kama hiyo itaonyesha mipaka hiyo hiyo ya picha.

Mwongozo ni nadharia, akiribu au isiripoke. Kila mpango wa uwekaji maelezo unasema madai kuhusu ontolojia. Kuamua kwamba "mzaha" na "dhihaka" ni darasa sawa ni dai la kinadharia, si urahisi wa kawaida. Kuamua kuweka lebo "hasira" kama darasa moja badala ya kutofautisha "hasira ya haki" na "hasira ya uadui" kunakunywa tofauti ambayo inaweza kuwa na umuhimu kwa kazi ya chini. Maamuzi haya yanafanywa chini ya shinikizo la uzalishaji na mara chache yanazingatiwa tena.

Kutokuwa thabiti kwa lebo kwa wakati. Lugha ya kijamii inabadilika. Mfano wa usumu uliofunzwa mwaka 2018 utaweka lebo vibaya maudhui kutoka mwaka 2024 si kwa sababu umefunzwa kidogo kwa takwimu, bali kwa sababu maana ya kijamii ya maneno fulani imebadilika. Uwekaji maelezo wa NLP si sampuli kutoka kwa usambazaji tuli — ni sampuli kutoka kwa lengo linalohamia ambalo kitendo cha kuweka lebo kinasaidia kwa sehemu kuunda.

:::{admonition} Tatizo la Kitu cha Mwelekeo wa Uwekaji Maelezo :class: important

Geva et al. {cite}`geva2019annotator` walionyesha kwamba mkusanyiko wa data wa NLI

(Inferensi ya Lugha Asilia) una vitu vya mwelekeo vya kimfumo vilivyoingizwa na mchakato wa uwekaji maelezo yenyewe. Wawekaji maelezo wanaoombwa kuandika nadharia za "uamuzi" kwa eneo fulani huwa wanatumia mifumo fulani ya kisintaksia; wawekaji maelezo wanaoandika nadharia za "kinzani" wanatumia nyingine. Mifano hujifunza kuainisha kulingana na vitu hivi badala ya uhusiano wa kisemantiki uliokusudiwa — wanaipata kazi ya uwekaji maelezo, si kazi ya NLP iliyo chini yake.

Hii si uzembe. Ni matokeo ya asili ya kuwa na binadamu wanaounda mifano kuoana na lebo. Mchakato wa HITL unaweka ishara ya kimfumo ambayo haikukusudiwa kuwepo katika data. :::

Uwekaji Maelezo wa Uainishaji wa Maandishi

Kazi rahisi zaidi ya uwekaji maelezo wa NLP ni kutoa kategoria kwa hati ya maandishi. Uchambuzi wa hisia, uainishaji wa mada, ugunduzaji wa nia, na uchujaji wa taka ni kazi zote za uainishaji.

Changamoto maalum za uainishaji wa maandishi:

Udhati. Kategoria kama "zenye sumu" au "za kukera" ni za udhati asili na zinatofautiana kati ya muktadha wa kitamaduni, historia za wawekaji maelezo, na muktadha wa jukwaa. Kati ya wawekaji maelezo, mtazamo wa kukera unatofautiana kwa kiasi kikubwa kulingana na kidemografia — ukweli wenye athari za moja kwa moja kwa haki {cite}`blodgett2020language`.

Utata wa lebo. Hati nyingi ni za kategoria nyingi au ziko kwenye mpaka. Tathmini ambayo ni 60% ya chanya na 40% ya hasi ina utata wa kweli, si ya kuwekewa lebo vibaya. Kulazimisha lebo moja kupoteza taarifa za kweli (angalia Sura ya 13 kuhusu lebo laini na kutokubaliana kwa wawekaji maelezo).

Kina cha lebo. Mfano wa hisia za madarasa 2 unaweza kuwa wa kutosha kwa ufuatiliaji wa mitandao ya kijamii; kipimo cha pointi 7 kinaweza kuhitajika kwa uchambuzi wa maoni ya bidhaa. Kina kinachofaa kinategemea kazi ya chini, lakini kawaida hurekebisha kabla ya uwekaji maelezo — uamuzi wa muundo wenye matokeo makubwa uliofanywa na data ya kutosha.

Utambuzi wa Maneno Maalum

Uwekaji maelezo wa NER unahitaji kutambua vipande vya maandishi na kutoa aina ya kitengo (MTU, SHIRIKA, MAHALI, n.k.). Uwekaji maelezo ni mgumu zaidi kuliko uainishaji wa hati kwa sababu kadhaa:

Mipaka ya kipande ina utata. Katika "Apple CEO Tim Cook alitangaza…", kitengo cha MTU kinashughulikia "Tim Cook" au "Apple CEO Tim Cook"? Mwongozo lazima ushughulikie waziwazi hali hizi, na makubaliano ya wawekaji maelezo kwenye vipande huwa ya chini kuliko kwenye aina.

Ugawaji wa aina unahitaji maarifa ya dunia. "Apple" ni ORG katika muktadha mmoja, BIDHAA katika mwingine, na kwa hoja hakuna katika "pai ya tofaa." Wawekaji maelezo wanahitaji maarifa ya kutosha ya uwanja kufanya ugawaji sahihi wa aina.

Vitengo vilivyotabia. "Chuo Kikuu cha California, Berkeley" kina SHIRIKA kilichotabiwa

ndani ya MAHALI. Uwekaji lebo wa BIO wa kawaida hauwezi kuwakilisha vitengo vilivyotabia; mipango ya mgumu zaidi (k.m., BIOES, au muundo wa grafu) inahitajika.

Ufanisi wa uwekaji maelezo. Uwekaji maelezo wa awali kwa kutumia mfano wa msingi wa NER huharakisha sana uwekaji maelezo kwa kuruhusu wawekaji maelezo kurekebisha utabiri badala ya kuweka maelezo kutoka mwanzo. Katika utafiti mmoja wa NER ya kimatibabu, ongezeko la uzalishaji la 30–60% lilionekana {cite}`lingren2014evaluating`; ukubwa wa faida kama hizi unategemea sana ubora wa mfano wa msingi na uwanja.

Uchimbaji wa Uhusiano na Uwekaji Maelezo wa Kisemantiki

Zaidi ya kutambua vitengo, uchimbaji wa uhusiano unahitaji kuweka maelezo kwenye *mahusiano* kati ya vitengo:

- Wawekaji maelezo lazima waelewe vitengo vyote viwili na kiunganishi kinachoviunganisha
- Aina za uhusiano zina tofauti ngumu za kisemantiki (ANAFANYA_KAZI_KATIKA dhidi ya AMEAJIRIWA_NA dhidi ya ILIANZISHA)
- Mifano hasi (jozi za kitengo bila uhusiano) ni ya kawaida zaidi sana kuliko ya chanya

Makubaliano ya wawekaji maelezo kwa uchimbaji wa uhusiano huwa ya chini kuliko kwa kazi za uainishaji. Kwa mipango iliyofafanuliwa vizuri, maadili ya κ katika upeo wa 0.65–0.80 yanaripotiwa kawaida {cite}`pustejovsky2012natural`; kwa uhusiano mgumu wa kisemantiki (uamuzi wa tukio, mahusiano ya wakati), makubaliano yanaweza kuanguka chini zaidi sana, kulingana na muundo wa mpango na mafunzo ya wawekaji maelezo.

Uhariri Baada ya Tafsiri ya Mashine (MTPE)

Uhariri baada ya tafsiri ya mashine ni aina iliyokomaa ya HITL NLP. Mtafsiri wa binadamu hurekebisha tokeo la mfumo wa MT badala ya kutafsiri kutoka mwanzo:

Uhariri wa mwanga (LPE): Makosa ya msingi tu ndiyo yanayorekebishwa. Inafaa wakati mahitaji ya ubora wa tafsiri ni ya wastani.

Uhariri kamili (FPE): Tokeo linarekebishwa hadi ubora wa uchapishaji. Tokeo lililohariri wa kawaida linakuwa data ya mafunzo kwa uboreshaji zaidi wa MT — mzunguko wa kweli wa kurekebisha wa binadamu-katika-mzunguko.

HTER (Kiwango cha Uhariri wa Tafsiri Kinacholenga Binadamu): Kipimo kinachopima umbali wa uhariri kati ya tokeo la MT na tafsiri iliyohariri wa, iliyorekebisha kwa urefu wa sentensi {cite}`graham2015accurate`. Kama kanuni ya vitendo ya makadirio, HTER chini ya takriban 0.3 mara nyingi inachukuliwa kama tokeo nzuri la MT; zaidi ya 0.5, tafsiri kutoka mwanzo inaweza kuwa ya haraka zaidi — ingawa viwango hivi vinatofautiana kulingana na uwanja na jozi ya lugha.

AI ya Mazungumzo na Uwekaji Maelezo wa Mazungumzo

Kuweka maelezo kwenye mazungumzo kunaanzisha muundo wa muda:

- **Uwekaji maelezo wa kiwango cha zamu:** weka lebo kwa kila zamu (nia, hisia, ubora)
- **Uwekaji maelezo wa kiwango cha mazungumzo:** tathmini mshikamano wa jumla, mafanikio ya kazi, ridhaa ya mtumiaji
- **Uwekaji maelezo wa athari ya mwingiliano:** tambua wakati maalum wa kushindwa katika mazungumzo

HITL ni muhimu sana katika mazungumzo kwa sababu kushindwa kwa mfano mara nyingi ni dhaifu na kumkusanyika: kosa la ukweli katika zamu ya 3 linaweza kuonekana hadi zamu ya 7. Wawekaji maelezo wa binadamu wanaofuatilia mazungumzo wanaweza kutambua mifumo hii ya kushindwa ya masafa marefu ambayo vipimo otomatiki vinakosa kabisa.

Uwekaji Lebo wa Programu na Usimamizi Dhaifu

Data yenye lebo inapokelewa kidogo, **usimamizi dhaifu** huruhusu kutumia kazi nyingi za uwekaji lebo zenye kelele, zinazoingiliana kuzalisha lebo za uwezekano kwa kiwango kikubwa. **Snorkel** {cite}`ratner2017snorkel` ndiyo mfumo wa kawaida:

```
import numpy as np
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import f1_score

rng = np.random.default_rng(42)

# ---------------------------------------------------------
# Toy weak supervision: sentiment classification
# 5 labeling functions (LFs) with different coverage/accuracy
# Label: +1 (positive), -1 (negative), 0 (abstain)
# ---------------------------------------------------------

N = 1000
true_labels = rng.choice([-1, 1], size=N)
X_features = np.column_stack([
    true_labels * 0.8 + rng.normal(0, 0.5, N),
    rng.normal(0, 1, N),
    rng.normal(0, 1, N),
])

def make_lf(accuracy, coverage, seed):
    rng_lf = np.random.default_rng(seed)
    votes = np.zeros(N, dtype=int)
    active = rng_lf.random(N) < coverage
    correct = rng_lf.random(N) < accuracy
    votes[active & correct]  = true_labels[active & correct]
    votes[active & ~correct] = -true_labels[active & ~correct]
    return votes

LFs = np.column_stack([
    make_lf(accuracy=0.85, coverage=0.60, seed=1),
    make_lf(accuracy=0.78, coverage=0.45, seed=2),
    make_lf(accuracy=0.70, coverage=0.80, seed=3),
```

```
    make_lf(accuracy=0.90, coverage=0.30, seed=4),
    make_lf(accuracy=0.60, coverage=0.90, seed=5),
])

def majority_vote(LF_matrix):
    labels = []
    for i in range(LF_matrix.shape[0]):
        votes = LF_matrix[i][LF_matrix[i] != 0]
        labels.append(0 if len(votes) == 0 else int(np.sign(votes.sum())))
    return np.array(labels)

mv_labels = majority_vote(LFs)
covered = mv_labels != 0

print(f"Coverage:                    {covered.mean():.1%}")
print(f"MV accuracy (covered):       {(mv_labels[covered] == true_labels[covered]).mean():.3f

X_train, y_train = X_features[covered], mv_labels[covered]
X_test,  y_test  = X_features[~covered], true_labels[~covered]

if len(X_train) > 10 and len(X_test) > 10:
    clf = LogisticRegression().fit(X_train, y_train)
    preds = clf.predict(X_test)
    print(f"F1 on uncovered test set:    {f1_score(y_test, preds):.3f}")
```

RLHF kwa Mifano ya Lugha: Ukweli wa Uwekaji Maelezo

Sura ya 6 ilishughulikia RLHF kwa kiufundi. Kutoka mtazamo wa NLP, kazi ya uwekaji maelezo ni ngumu zaidi ya unavyoonekana kutoka nje.

Wawekaji maelezo wanaulizwa kweli kufanya nini — kulinganisha matokeo mawili ya mfano na kuonyesha nini "bora" — inasikika rahisi. Katika mazoezi, "bora" ni dhana isiyobainishwa ambayo wawekaji maelezo wanaipata kwa kutumia kanuni za hisia. Wengine wanashika unyoofu sana; wengine wanashika usahihi wa ukweli; wengine wanaadhibu maneno mengi. Bila mwongozo madhubuti, mkusanyiko wa data wa mapendeleo unaotokea hauakisi maadili ya binadamu kwa ufupi bali mikakati ya azimio ya nguvu kazi ya uwekaji maelezo iliyoajiriwa.

Vipimo kuu vya uwekaji maelezo ni:

- *Usaidizi:* Je, jibu linajibu swali vizuri? Je, lina habari, wazi, na una kina kinachofaa?
- *Ukweli:* Je, jibu ni sahihi kwa ukweli? Hii inahitaji watathminii kuwa na maarifa ya uwanja — mahitaji yanayosababisha matatizo makubwa ya ubora kwa kiwango kikubwa, kwani wawekaji maelezo wa jumla hawawezi kuthibitisha madai ya wataalam.
- *Kutokuwa na madhara:* Je, jibu linaepuka maudhui yenye sumu, ya kibaguzi, ya kudhuru, au yasiyofaa? Hukumu hizi zinahitaji mwongozo wa kina kwa sababu "ya kudhuru" inategemea sana muktadha na inabadilika kati ya tamaduni, wakati, na muktadha wa jukwaa.
- *Urekebishaji:* Je, jibu linaelezea wasiwasi unaofaa? Wawekaji maelezo wanapendelea kwa kimfumo majibu yanayosikika ya ujasiri, ambayo huunda ishara ya zawadi dhidi ya unyenyekevu wa hali ya maarifa.

Mwingiliano kati ya vigezo ni mgumu: jibu la kusaidia zaidi kwa swali hatari linaweza kuwa la kudhuru zaidi. Mwongozo lazima ubainishe jinsi ya kufanya maelewano kwa vigezo vinavyoshindana — na maelewano hayo ni maamuzi ya sera, si maamuzi ya uwekaji maelezo. Nguvu kazi ya uwekaji maelezo inafanya sera.

Kiwango kinazingatia ushawishi wa kidemografia. RLHF kwa mifano mikubwa inahusisha nguvu kazi ndogo za uwekaji maelezo (mamia hadi maelfu ya chini) kufanya maamuzi ya mabilioni ya chini. Upendeleo wa kidemografia na kitamaduni wa nguvu kazi hiyo huenea katika tabia ya mfano kwa kiwango kikubwa kwa njia ambayo haungetokea kama uwekaji maelezo ungesambazwa zaidi. Hili ni moja ya matatizo ya kimuundo yasiyojadiliwa kidogo zaidi katika mfumo wa sasa wa RLHF.

Mzunguko wa Maoni wa Uwekaji Maelezo–Mfano

Katika NLP zaidi ya uwanja wowote mwingine, mchakato wa uwekaji maelezo na maendeleo ya mfano vinachoshana baada ya muda:

1. Wawekaji maelezo huwekwa calibrated kwa kutumia matokeo ya sasa ya mfano kama rejeleo (mara nyingi kwa picha).
2. Mfano wa zawadi hujifunza maelezo yanayopendelea nini.
3. Kizalishaji kinarekebishwa fini kuzalisha matokeo yanayopata zawadi kubwa.
4. Matokeo hayo yanaathiri jinsi "nzuri" inavyoonekana katika raundi za uwekaji maelezo zinazofuata.

Mzunguko huu wa maoni si wa kudhuru kwa asili — ndiyo unaoruhusu RLHF kuungana — lakini inamaanisha kwamba tabia ya mfano inaundwa na lengo linalohamia ambalo mchakato wa uwekaji maelezo yenyewe husaidia kuhamisha. Kutofautisha kile mfano ulichojifunza kwa sababu kinaakisi mapendeleo ya binadamu na kile kilichojifunza kwa sababu kilijifunza kuoanishwa na kanuni za wawekaji maelezo ni kigumu kimajaribio.

Hakuna suluhisho safi. Mazoezi bora ya sasa ni kufuatilia mabadiliko kwa kutumia hukumu za mapendeleo zilizohifadhiwa zilizokusanywa kwa vipindi vya kawaida, na kutibu toleo la mwongozo wa uwekaji maelezo kama kigezo cha majaribio.

Tathmini ya Mifano ya NLP ya Uzalishaji

Tofauti na mifano ya uainishaji na kipimo wazi cha usahihi, kutathmini ubora wa uzalishaji kunahitaji hukumu ya binadamu:

Mbinu ya tathmini	Maelezo	Gharama
Tathmini ya moja kwa moja (DA)	Wawekaji maelezo wanipanga ubora kwa kipimo	Wastani
Hukumu ya kulinganishwa	Wawekaji maelezo wanalinganisha matokeo mawili	Chini
MQM (Vipimo vya Ubora vya Pande Nyingi)	Uainishaji wa makosa wa muundo	Juu
Mapendeleo ya RLHF	Lebo za mapendeleo zinazotumiwa kwa mafunzo	Wastani
LLM-kama-jaji	LLM inapanga matokeo (inalingana kwa wastani na binadamu)	Chini sana

Mbinu ya tathmini	Maelezo	Gharama
BERTScore, BLEU	Vipimo otomatiki (muunganiko usio kamili na hukumu ya binadamu)	Chini sana

Vipimo otomatiki (BLEU kwa MT, ROUGE kwa muhtasari) ni nafuu lakini vina muunganiko usio kamili na hukumu za ubora za binadamu {cite}`reiter2018structured`. Mbinu za LLM-kama-jaji zinaonyesha makubaliano ya wastani na wawekaji maelezo wa binadamu {cite}`zheng2023judging` na zinatumika zaidi kwa mzunguko wa haraka, lakini hazipaswi kuchukua nafasi ya tathmini ya binadamu kwa tathmini za mwisho. Kwa maamuzi yenye hatua za kweli, tathmini ya binadamu inabaki kuwa ya lazima.

> **See also:** Usimamizi dhaifu wa Snorkel: {cite}`ratner2017snorkel`. Mwongozo wa uwekaji maelezo wa NLP: {cite}`pustejovsky2012natural`. Vitu vya mwelekeo vya uwekaji maelezo katika NLI: {cite}`geva2019annotator`. Upendeleo wa wawekaji maelezo na mkusanyiko wa data wa NLP: {cite}`blodgett2020language`. Kwa tathmini ya mifano ya uzalishaji: {cite}`reiter2018structured`.

HITL katika Mwono wa Kompyuta

Mwono wa kompyuta hutoa baadhi ya mifano inayoeleweka zaidi kwa macho ya HITL ML. Changamoto ya ImageNet, iliyojengwa kwenye picha milioni 14 zilizowekewa lebo na binadamu, ilianzisha enzi ya kujifunza kwa kina. Uwekaji maelezo wa picha za kimatibabu na madaktari wa radiolojia huendesha AI ya utambuzi. Magari ya uhuru yanategemea fremu milioni zilizowekewa lebo na binadamu kujifunza kutambua ulimwengu.

Kinachopita kwa urahisi bila kutambuliwa: hizi si hali za binadamu tu wanaotoa ukweli wa ardhi. Ni hali za binadamu wanaounda mkusanyiko wa data ambao unaweka maamuzi maalum ya mtazamo, kitamaduni, na uendeshaji — maamuzi yanayoonekana tu baadaye, wakati mifano inashindwa kwa njia zinazotarajiwa.

Jinsi Maamuzi ya Uwekaji Maelezo Yanavyokuwa Upendeleo wa Mfano

Mfumo wa kawaida unauona uwekaji maelezo kama ukusanyaji wa data: binadamu wanaangalia ulimwengu na kurekodi wanachoona. Mfumo sahihi zaidi ni kwamba uwekaji maelezo ni *muundo wa mkusanyiko wa data*: binadamu wanaamua kategoria zipi kutumia, mahali pa kuchora mipaka, hali zipi za mipaka kujumuisha, na jinsi ya kutatua utata — na maamuzi hayo yote yanaathiri mfano uliofunzwa utakachotambua.

Kesi ya ImageNet

ImageNet {cite}`russakovsky2015imagenet` ni mkusanyiko wa data wenye matokeo makubwa zaidi katika historia ya mwono wa kompyuta. Seti yake ya lebo inatoka kwa synsets za WordNet, zilizochaguliwa hasa kwa kuwa nyingi na tofauti kisemantiki. Matokeo kadhaa ya chaguo hili la muundo yalijitokeza miaka baadaye:

- **Kategoria za watu ziliweka uhusiano wa kidemografia.** Toleo za mapema za lebo za synset za ImageNet kwa watu zilijumuisha nyingi ambazo sasa zingedhaniwa za kubaguliwa au zenye upendeleo, zinaakisi chanzo cha kihistoria cha WordNet na maamuzi ya picha ya nguvu kazi ya uwekaji maelezo kuhusu lebo zipi kutumia kwenye picha zipi {cite}`yang2020towards`. Lebo zilizotumika kwenye picha za watu ziliweka uhusiano wa rangi, jinsia, na daraja ambao ulienea moja kwa moja katika uwakilishi wa mfano.
- **Uainishaji wa kina wa ushuru wa spishi, wa jumla wa kila kitu kingine.** ImageNet inaweza kutofautisha mbwa wa mifugo 120 lakini inakusanya tofauti kubwa za zana, magari, chakula, na samani katika kategoria moja. Hii ilikuwa matokeo ya kufuata muundo wa WordNet, si chaguo la makusudi kuhusu kinachohusika. Mifano iliyofunzwa kwenye ImageNet inaonyesha usahihi huo huo wa asymmetric.

- **Kawaida za kuona za Magharibi, wanaozungumza Kiingereza.** Picha zilikusanywa hasa kutoka Flickr na utafutaji wa mtandaoni kwa kutumia maswali ya Kiingereza. Usambazaji unaotokea unapenda sana mazingira ya kuona na vitu vya kitamaduni vya nchi tajiri, zinazozungumza Kiingereza.

Hakuna hizi zilikuwa makosa. Zilikuwa maamuzi ya muundo wa uwekaji maelezo yaliyofanywa haraka kwa kiwango kikubwa, mara nyingi na watu ambao hawakutarajia jinsi mkusanyiko wa data ungetumiwa. Somo si kwamba ImageNet ingepaswa kujengwa tofauti (ingawa ingepaswa), bali kwamba **muundo wa uwekaji maelezo ni muundo wa mfano**, na unapaswa kushughulikiwa kwa uangalifu sawa.

:::{admonition} Mpango wa uwekaji maelezo ni nadharia ya dunia :class: note

Kila uainishaji wa lebo unadai kuhusu tofauti gani zinazohusika. Kuchagua kutenganisha "gari" na "lori" huku ukikusanya sedan zote katika darasa moja ni dai la kinadharia kuhusu tofauti zipi zina umuhimu wa kisemantiki. Kuchagua kuweka maelezo kwa "mtu" kama darasa moja bila kujali mkao, mavazi, au shughuli ni dai tofauti la kinadharia. Mifano iliyofunzwa kwenye mipango hii itafanya tofauti hizo hizo, na si zaidi — haitajumlisha zaidi ya kategoria zilizofunzwa kutofautisha. :::

Uwekaji Maelezo wa Uainishaji wa Picha

Kazi rahisi zaidi ya uwekaji maelezo wa CV ni kutoa lebo moja au zaidi kwa picha nzima.

Muundo wa lebo. Lebo "mbwa" ni mtoto wa "mnyama" katika muundo wa kisemantiki. Mifano iliyofunzwa kwenye uainishaji wa gorofa inaweza kutojumlisha vizuri kati ya viwango vya ufupishaji. ImageNet inatumia muundo unaotegemea synset ambao huruhusu tathmini katika viwango vingi vya maalum.

Utata wa lebo nyingi. Mandhari ya barabara inaweza kuwa na gari, mtu, baiskeli, na taa ya barabara wakati mmoja. Kuamua lebo zipi kujumuisha kunahitaji mwongozo wazi kuhusu viwango vya umuhimu.

Usambazaji wa mkia mrefu. Mkusanyiko wa data wa picha za asili hufuata sheria ya nguvu: kategoria chache ni za kawaida sana; nyingi ni adimu. Ujifunzaji tendaji una thamani sana kwa kategoria za mkia mrefu ambapo sampuli ya nasibu hutoa mifano michache tu.

Ugunduzi wa Kitu: Uwekaji Maelezo wa Sanduku la Mpaka

Ugunduzi wa kitu unahitaji wawekaji maelezo kuchora sanduku la mpaka linalooana na mhimili karibu na mifano ya kila darasa la kitu. Hii inaanzisha mahitaji ya usahihi wa kijiometri na hali nyingi za mipaka.

Vipimo vya ubora wa uwekaji maelezo:

IoU (Makutano juu ya Muungano) inapima mwingiliano kati ya sanduku lililowekewa maelezo na sanduku la rejeleo:

$$\text{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

IoU ≥ 0.5 ndiyo kiwango cha kawaida cha "ugunduzi sahihi" katika PASCAL VOC; COCO {cite}`lin2014microsoft` inatumia upeo wa viwango kutoka 0.5 hadi 0.95, ambayo ni ya kudai zaidi sana na yenye habari zaidi.

Hali za mipaka za uwekaji maelezo ambazo lazima zitatuliwe katika mwongozo: - Vitu vilivyofunikwa: weka maelezo sehemu inayoonekana au kalibu upanuzi kamili? - Vitu vilivyokatwa (kwa sehemu nje ya fremu): jumuisha au acha nje? - Maeneo ya umati: tumia maelezo maalum ya "umati" au weka maelezo kwa mifano binafsi?

Kila moja ya maamuzi haya inabadilika maana ya "ugunduzi sahihi" — na kwa hivyo inabadilisha kile mfano unafunzwa kufanya.

```
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.patches as patches

def compute_iou(boxA, boxB):
    """Compute IoU between two boxes [x1, y1, x2, y2]."""
    xA = max(boxA[0], boxB[0])
    yA = max(boxA[1], boxB[1])
    xB = min(boxA[2], boxB[2])
    yB = min(boxA[3], boxB[3])
    inter_area = max(0, xB - xA) * max(0, yB - yA)
    boxA_area = (boxA[2] - boxA[0]) * (boxA[3] - boxA[1])
    boxB_area = (boxB[2] - boxB[0]) * (boxB[3] - boxB[1])
    union_area = boxA_area + boxB_area - inter_area
    return inter_area / (union_area + 1e-6)

ref_box  = [1.0, 1.0, 4.0, 4.0]
ann1_box = [1.1, 0.9, 4.1, 4.2]   # close
ann2_box = [0.5, 0.5, 3.5, 3.8]   # less precise

print(f"IoU (ann1 vs ref):  {compute_iou(ann1_box, ref_box):.3f}")
print(f"IoU (ann2 vs ref):  {compute_iou(ann2_box, ref_box):.3f}")
print(f"IoU (ann1 vs ann2): {compute_iou(ann1_box, ann2_box):.3f}")

fig, ax = plt.subplots(figsize=(5, 5))
ax.set_xlim(0, 5); ax.set_ylim(0, 5); ax.set_aspect('equal')
ax.add_patch(patches.Rectangle(
    (ref_box[0], ref_box[1]), ref_box[2]-ref_box[0], ref_box[3]-ref_box[1],
    linewidth=2.5, edgecolor='#2b3a8f', facecolor='none', label='Reference'))
ax.add_patch(patches.Rectangle(
    (ann1_box[0], ann1_box[1]), ann1_box[2]-ann1_box[0], ann1_box[3]-ann1_box[1],
    linewidth=2, edgecolor='#0d9e8e', facecolor='none', linestyle='--',
    label=f'Ann1 (IoU={compute_iou(ann1_box, ref_box):.2f})'))
ax.add_patch(patches.Rectangle(
    (ann2_box[0], ann2_box[1]), ann2_box[2]-ann2_box[0], ann2_box[3]-ann2_box[1],
    linewidth=2, edgecolor='#e05c5c', facecolor='none', linestyle=':',
    label=f'Ann2 (IoU={compute_iou(ann2_box, ref_box):.2f})'))
ax.legend(fontsize=10)
ax.set_title("Bounding Box Agreement (IoU)", fontsize=12)
plt.tight_layout()
plt.savefig('bbox_iou.png', dpi=150)
```

```
plt.show()
```

Ugawanyiko wa Kisemantiki na wa Kitengo

Uwekaji maelezo wa ugawanyiko unahitaji kutoa lebo ya darasa kwa kila pikseli katika picha — kati ya aina za uwekaji maelezo zenye gharama kubwa zaidi.

Ugawanyiko wa kisemantiki: Kila pikseli ni ya darasa la kisemantiki (barabara, anga, mtu, gari). Pikseli zote za darasa sawa zinashiriki lebo sawa, bila kujali ni kitu gani binafsi wanachomiliki.

Ugawanyiko wa kitengo: Kila kitu binafsi cha kitengo hupata lebo ya kipekee. Umati wa watu 20 unakuwa masago 20 tofauti.

Ugawanyiko wa panoptiki: Huchanganya vyote viwili: madarasa ya "kitu" (vitu vinavyohesabika) yana masago ya kitengo; madarasa ya "vitu" (barabara, anga) yana masago ya kisemantiki.

Uwekaji maelezo unaosaidiwa na SAM: Mfano wa Kukata Kitu Chochote wa Meta {cite}`kirillov2023segment` huzalisha masago ya kukata ya ubora wa juu kutoka kwa kubonyeza ncha moja. Wawekaji maelezo wanabonyeza katikati ya kitu; SAM inapendekeza sago; mweka maelezo anakubali au kurekebisha. Waandishi wa SAM wanaripoti kuharakisha kwa injini ya uwekaji maelezo ya takriban mara 6.5 zaidi ya uwekaji lebo unaotegemea poligoni; faida zinatofautiana kati ya aina za mandhari na zana za uwekaji maelezo.

SAM inawakilisha mabadiliko mapana: **jukumu la mweka maelezo linabadilika kutoka kuchora hadi kukagua**. Hii ina athari kwa ubora wa uwekaji maelezo zaidi ya kasi. Wawekaji maelezo wanapochora, umakini wao unashirikiana katika mchakato wote. Wawekaji maelezo wanapokagua na kubonyeza "kukubali," kuna ushahidi kwamba wanakosa makosa kwa urahisi zaidi — toleo la upendeleo wa otomatiki maalum kwa muktadha wa uwekaji maelezo.

Ujifunzaji Tendaji kwa Mwono wa Kompyuta

Ujifunzaji tendaji una thamani sana katika CV kwa sababu: 1. Picha zina vipimo vingi na tajiri — uwakilishi kutoka kwa mifano iliyofunzwa awali hubeba ishara kali za makadirio ya wasiwasi 2. Mabwawa makubwa yasiyowekewa lebo ni ya bei nafuu (picha, fremu za video) 3. Uwekaji maelezo (hasa ugawanyiko) ni ghali na hauwezi kukusanywa kwa urahisi kwa maeneo maalum

```
import numpy as np
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score
import matplotlib.pyplot as plt

rng = np.random.default_rng(42)

X, y = make_classification(n_samples=3000, n_features=50, n_informative=25,
                           n_classes=5, n_clusters_per_class=2, random_state=42)
X_train, y_train = X[:2500], y[:2500]
X_test,  y_test  = X[2500:], y[2500:]
```

```
def margin_uncertainty(model, X_pool):
    probs = model.predict_proba(X_pool)
    sorted_p = np.sort(probs, axis=1)
    return sorted_p[:, -2] - sorted_p[:, -1]  # most negative = most uncertain

n_init = 50
results = {'active': [], 'random': []}
label_counts = list(range(50, 401, 30))

for strategy in ['active', 'random']:
    labeled = list(rng.choice(len(X_train), n_init, replace=False))
    unlabeled = [i for i in range(len(X_train)) if i not in labeled]

    for target in label_counts:
        while len(labeled) < target and unlabeled:
            if strategy == 'active' and len(labeled) >= 10:
                model_temp = LogisticRegression(max_iter=300).fit(
                    X_train[labeled], y_train[labeled])
                margins = margin_uncertainty(model_temp, X_train[unlabeled])
                idx = int(np.argmin(margins))
            else:
                idx = rng.integers(0, len(unlabeled))
            labeled.append(unlabeled.pop(idx))

        clf = LogisticRegression(max_iter=300).fit(X_train[labeled], y_train[labeled])
        results[strategy].append(accuracy_score(y_test, clf.predict(X_test)))

plt.figure(figsize=(7, 4))
plt.plot(label_counts, results['active'], 'o-', color='#2b3a8f',
         linewidth=2, label='Active (margin sampling)')
plt.plot(label_counts, results['random'], 's--', color='#e05c5c',
         linewidth=2, label='Random baseline')
plt.xlabel("Labeled training images", fontsize=12)
plt.ylabel("Test accuracy", fontsize=12)
plt.title("Active Learning for 5-Class Image Classification", fontsize=13)
plt.legend(fontsize=11); plt.grid(alpha=0.3)
plt.tight_layout()
plt.savefig('cv_active_learning.png', dpi=150)
plt.show()
```

Kujifunza Nusu-Usimamizi na Mwongozo wa Binadamu

Wingi mkubwa wa data ya kuona isiyowekewa lebo inayopatikana hufanya kujifunza nusu-usimamizi kuwa na mvuto sana kwa CV.

Kujifunza binafsi / uwekaji lebo wa picha: Funza mfano kwenye data yenye lebo; tumia utabiri wa imani ya juu kwenye data isiyowekewa lebo kama lebo za picha; funza tena. Swali muhimu la muundo ni kizingiti cha imani. Kizingiti cha chini kinaileta mifano zaidi lakini kinaanzisha kelele; kizingiti cha juu kuacha sehemu kubwa ya bwawa lisilo na lebo bila kutumika.

Ushiriki wa binadamu unaweza kuongoza kizingiti hiki — wawekaji maelezo wanakagua sampuli ya mifano iliyowekewa lebo ya picha kuirekebisha.

FixMatch na urekebishaji wa uthabiti: Mbinu hizi zinafunza mifano kutoa utabiri thabiti chini ya ongezeko la data. Ufahamu muhimu wa HITL: binadamu wanashauriwa si tu kwa lebo bali kwa **muundo wa ongezeko la data** — mfano unapaswa kujifunza kutofautiana gani? Mfano kwa picha za kimatibabu unapaswa kuwa wa kudumu kwa mzunguko na mwanga lakini si kwa kiwango; mfano kwa ugunduzi wa maandishi haupaswi kufanywa wa kudumu kwa upotoshaji wa mtazamo. Maamuzi haya maalum ya uwanja yanahitaji utaalamu wa binadamu, na kuyapata vibaya kunapunguza kwa kiasi kikubwa kujifunza nusu-usimamizi.

Kujifunza tendaji nusu-usimamizi: Mchanganyiko wa ufanisi zaidi: ujifunzaji tendaji unazingatia lebo za binadamu mahali ambapo wasiwasi wa mfano ni mkubwa zaidi; kujifunza binafsi kunaweka lebo kiotomatiki mkia wa imani wa juu. Juhudi za binadamu zinazingatia mahali ambapo zina thamani zaidi, na mfano unajizindua kwenye iliyobaki. Katika kila mzunguko, ukaguzi wa binadamu wa sampuli ya nasibu ya lebo za picha hutoa ukaguzi wa ubora bila kuhitaji mapitio kamili.

Uwekaji Maelezo wa Video

Uwekaji maelezo wa video huongeza changamoto za uwekaji maelezo wa picha kwa mara ya wakati:

- **Ufuatiliaji:** Vitu lazima vitambuliwe kati ya fremu. Wawekaji maelezo wanaweka lebo kwenye fremu kuu; kanuni za ufuatiliaji huzingatiwa kati yake. Kushindwa kwa ufuatiliaji — kufunikwa, kuingia tena, mwendo wa haraka — kunahitaji kuweka maelezo tena kwa binadamu kwa viwango vya juu kuliko ufuatiliaji wa hali thabiti.
- **Uthabiti wa muda:** Mipaka iliyochorwa katika fremu t inapaswa kuwa thabiti kwa nafasi na fremu $t + 1$. Maelezo yasiyothabiti ni ishara ya mafunzo inayomwambia mfano kwamba vitu vinaruka bila mpangilio — aina ya kelele ya uwekaji maelezo inayodhuru hasa kwa mifano ya ugunduzi.
- **Upanuzi:** Video ya saa 1 kwa fps 30 ni fremu 108,000. Uwekaji maelezo kamili si wa vitendo; mikakati ya sampuli lazima ibuniwe kwa makini kuhakikisha kwamba matukio adimu (hali za mipaka, karibu-kosa, hali za kushindwa) hazizuiwi kwa kimfumo.

Zana za kisasa za uwekaji maelezo wa video zinasaidia **ufuatiliaji wa akili** ambao unaeneza maelezo kati ya fremu na kuonyesha fremu ambapo imani ya ufuatiliaji iko chini ya kizingiti, ukimtaka mweka maelezo arudie kukagua. Hii ni matumizi ya moja kwa moja ya wazo la ujifunzaji tendaji kwa mfumo wa uwekaji maelezo yenyewe: zana inauliza mweka maelezo hasa mahali ambapo upangizaji wake una wasiwasi.

Tatizo la tukio adimu katika mifumo ya uhuru. Kwa matumizi ambapo matokeo ya matukio adimu ni ya maafa — uendeshaji wa uhuru, urambazaji wa UAV — usambazaji wa fremu zinazopatikana katika uendeshaji wa kawaida unakoana vibaya sana na usambazaji wa fremu zinazohusika zaidi. Mkusanyiko wa data uliojengwa kwa sampuli sawa za picha za uendeshaji utakuwa na fremu milioni za "hakuna kitu cha kuvutisa kinatokea" na chache za karibu-ajali, taa za ajabu, na fremu za sensorer zilizoharibiwa ambazo ndizo muhimu kweli kwa usalama. Ujifunzaji tendaji wa HITL unaotambua na kutanguliza fremu kama hizo si mbinu ya ufanisi — ni mahitaji ya usalama.

> **See also:** Mkusanyiko wa data wa ImageNet: {cite}`russakovsky2015imagenet`. Upendeleo wa lebo katika ImageNet: {cite}`yang2020towards`. Kipimo cha COCO:

{cite}`lin2014microsoft`. SAM (Kukata Kitu Chochote): {cite}`kirillov2023segment`. Ujifunzaji tendaji wa seti ya msingi kwa CV: {cite}`sener2018active`.

HITL katika Afya na Sayansi

Huduma ya afya na sayansi zinawakilisha mawili kati ya maeneo ambapo HITL ML ina matokeo makubwa zaidi na inajadiliwa zaidi. Hatua ni kubwa: utambuzi wa saratani uliokosewa au lengo la dawa lenye kasoro lina gharama ya kweli ya kibinadamu. Uwekaji maelezo unahitaji utaalamu wa nadra na ghali. Mahitaji ya kisheria yanazuia mifano inaweza kufanya nini na jinsi lazima ithhibitishwe. Na tofauti na NLP, ambapo tatizo la uwekaji maelezo ni kwa sehemu la ujenzi wa kijamii, hapa mara nyingi kuna ukweli halisi wa ardhi — uvimbe upo au hauko — hata kama hakuna mwangalifu mmoja anayeweza kuuamua kwa uaminifu.

Mfumo mkubwa katika chanjo maarufu ni "AI dhidi ya binadamu": je, AI itabadilisha madaktari wa radiolojia? Mfumo huu ni mbaya kwa njia inayohusika. Swali halisi ni aina gani ya ushirikiano wa binadamu-AI inazalisha matokeo bora kuliko yoyote peke yake, na jinsi ya kujenga mifumo inayowezesha ushirikiano huo badala ya kuutatiza.

Uchambuzi wa Picha za Kimatibabu

Kupiga picha za kimatibabu — radiolojia (X-ray, CT, MRI), patholojia (slaidi za tishu), darmatolojia, ofthalmolojia — ni uwanja ambapo AI ya kimatibabu imepiga hatua haraka zaidi.

Mahitaji ya Mweka Maelezo Mtaalamu

Uwekaji maelezo wa picha za kimatibabu kawaida unahitaji madaktari wenye mafunzo maalum ya taaluma ndogo. Hii hufanya uwekaji maelezo kuwa:

- **Wa polepole:** Wataalamu wana muda mdogo; uwekaji maelezo unashindana na majukumu ya kliniki
- **Ghali:** Gharama zinaanzia makumi hadi mamia ya dola kwa kesi iliyowekewa maelezo, kulingana na taaluma ndogo, hali, na ugumu wa kazi
- **Tofauti:** Hata wataalamu wanakinzana, hasa kwenye hali za mpaka — ukweli ambao mara nyingi unachukuliwa kama tatizo lakini kweli una habari

Tofauti kati ya Madaktari wa Radiolojia

Tofauti ya msomaji imeandikwa vizuri katika radiolojia. Kwa tafsiri ya X-ray ya kifua, kutokubaliana kwa wasomaji ni muhimu — katika utafiti wa CheXNet, madaktari wanne wa radiolojia waliweka lebo kwenye seti sawa ya upimaji wa ugunduzaji wa nimonia na alamu za F1 zinazopana takriban pointi 12 za asilimia {cite}`rajpurkar2017chexnet`, zinaakisi wasiwasi wa kweli wa utambuzi kwenye hali za mpaka. Kwa ugunduzaji wa nodulio kwenye CT ya mapafu, tofauti ya ndani ya msomaji (msomaji mmoja, kesi moja, siku tofauti) inaweza kuwa kubwa kama tofauti kati ya wasomaji.

Tofauti hii si kelele tu — inaakisi wasiwasi wa kweli wa utambuzi. Mifano iliyofunzwa kwenye maelezo ya daktari mmoja wa radiolojia inaweza kujifunza upendeleo maalum wa daktari huyo badala ya patholojia iliyo chini.

:::{admonition} Mgongano wa CheXNet kama Somo la HITL :class: note

Rajpurkar et al. walipodai kwamba mfano wao wa CheXNet "ulizidi utendaji wa daktari wa radiolojia" kwenye ugunduzaji wa nimonia, dai hilo lilipingwa mara moja na jumuiya ya radiolojia {cite}`yu2022assessing`. Sehemu ya mgongano ulikuwa kuhusu seti maalum ya upimaji na ulinganisho wa daktari wa radiolojia. Lakini tatizo la kina zaidi lilikuwa la kimbinu: msingi wa "utendaji wa daktari wa radiolojia" uliotumia wasomaji wa peke yao chini ya shinikizo la muda, wakati radiolojia ya kliniki kawaida inahusisha mashauriano, ulinganisho na picha za awali, na ufikiaji wa muktadha wa kliniki — ambayo mfano haukuwa nayo.

Somo si kwamba mfano ulikuwa mzuri au mbaya, bali kwamba **ulinganisho wa utendaji unahitaji kubainisha mpangilio wa HITL**. Mfano unaozidi daktari wa radiolojia wa peke yake anayesoma baridi unaweza bado kuwa sahihi kidogo kuliko daktari wa radiolojia anayetumia tokeo la mfano kama maoni ya pili. Hizi ni mifumo tofauti yenye njia tofauti za makosa, na inakusanyika tofauti. :::

:::{admonition} Lebo laini katika dawa :class: important

Miradi kadhaa ya AI ya kimatibabu imehamia kutumia **lebo laini** zinazoakisi usambazaji wa maoni ya wataalam badala ya lebo moja ya "kiwango cha dhahabu". X-ray ya kifua iliyowekewa lebo kama nimonia 60% / atelectasis 40% na jopo la madaktari wa radiolojia ina habari zaidi kuliko chaguo la kulazimishwa la binary. Mifano iliyofunzwa kwenye usambazaji kama huo inaonyesha urekebishaji bora na upimaji wa wasiwasi unaofaa zaidi — na wasiwasi huo una maana ya kliniki, kwani humwambia daktari wa kliniki wakati wa kushauriana, si tu mfano unaofikiria nini. :::

Ujifunzaji Tendaji kwa Hali Adimu

Ujifunzaji tendaji una thamani sana kwa magonjwa adimu na patholojia adimu, ambapo hata bwawa kubwa lisilo na lebo lina kesi chache za chanya. Sampuli ya nasibu ya kawaida ingepoteza muda wa mtaalamu kuweka lebo hasa kesi hasi.

Ujifunzaji tendaji unaotegemea wasiwasi huchagua kwa asili hali za mpaka ambapo mfano una wasiwasi — ambazo, kwa hali adimu, huwa ni kesi za chanya na hasi za mpaka. Hii inazingatia muda wa mtaalamu mahali panapokuwa na thamani zaidi. Mchanganyiko wa mafunzo ya darasa lisiosawaziwa (na `class_weight='balanced'` au sawa) na uchaguzi unaotegemea wasiwasi ni mazoezi ya kawaida kwa kazi za ugunduzi wa patholojia adimu.

Uwekaji Maelezo wa NLP ya Kliniki

Rekodi za kielectroniki za kiafya (EHRs) zina utajiri mkubwa wa maandishi ya hadithi ya kliniki: maelezo ya madaktari, muhtasari wa kutoka hospitalini, ripoti za radiolojia, ripoti za patholojia. Kuchimba habari zilizopangwa kutoka maandishi haya kunahitaji NLP — na NLP ya ubora wa juu inahitaji data ya mafunzo iliyowekewa maelezo.

Kazi za kawaida za uwekaji maelezo wa NLP ya kliniki: - **NER ya kliniki:** Kutambua dawa, kipimo, utambuzi, taratibu, na dalili katika maandishi - **Ugunduzaji wa kukanusha:** "Hakuna ushahidi wa nimonia" dhidi ya "Nimonia imethibitishwa" — tofauti muhimu ambayo ni ngumu kushangaza - **Ufikiriaji wa muda:** Kutofautisha hali za sasa na historia ("historia ya

MI, alihudhuria na maumivu ya kifua") - **Kuondoa utambuzi:** Kuondoa Habari Zilizo Chini ya Ulinzi (PHI) kuwezesha kushiriki data

Kuondoa utambuzi wa PHI ni kazi ya uwekaji maelezo na mahitaji ya utawala wa data. Chini ya HIPAA (Marekani) na GDPR (EU), data ya kiafya haiwezi kushirikiwa bila kuondoa au kufanya isijulikane vitambulisho vya mgonjwa. Zana za kuondoa utambuzi kiotomatiki zipo lakini si kamili; mapitio ya binadamu ya matokeo ya kiotomatiki ni mazoezi ya kawaida, na wasifu wa hatari ni usio-sawa: hasi za uongo (PHI zilizokosewa) zinaunda mfiduo wa kisheria, ikifanya viwango vya kihafidhina vya lazima.

i2b2 / n2c2 kama Kiolezo

Mipango ya kazi zilizoshirikiwa za i2b2 (Informatics for Integrating Biology and the Bedside) na mrithi n2c2 (National NLP Clinical Challenges) imetoa safu ya mkusanyiko wa data wa NLP ya kliniki uliosema na wataalam. Hizi zinaonyesha uwezo na gharama: juhudi za uwekaji maelezo kawaida zinahusisha timu za wataalam wa uwanja wa kliniki wanaofanya kazi kwa miezi kadhaa, wakiweka maelezo kwenye hati mamia kwa changamoto. Mkusanyiko wa data wa n2c2 umechochea maendeleo ya haraka hasa kwa sababu ulitatua tatizo la utawala wa kushiriki data (kuondoa utambuzi + makubaliano ya kitaasisi), si tatizo la uwekaji maelezo tu.

Mambo ya Kisheria

AI ya kimatibabu inakabiliwa na usimamizi wa kisheria katika mamlaka nyingi.

FDA (Marekani): Programu kama Kifaa cha Kimatibabu (SaMD) inayotegemea AI/ML inahitaji idhini ya awali au ruhusa ya soko. Mpango wa Utekelezaji wa AI/ML wa FDA wa 2021 unasisitiza **mipango ya udhibiti wa mabadiliko iliyoamuliwa awali** — kuandika jinsi mfano utasasishwa na jinsi masasisho hayo yatathhibitishwa kabla ya utekelezaji. Mfano unaojifunza kwa kuendelea kutoka kwa maoni ya kliniki ni, chini ya mfumo huu, kifaa tofauti baada ya kila sasishi na kinaweza kuhitaji uthibitishaji upya.

Alama ya CE (Ulaya): Vifaa vya kimatibabu ikiwemo mifumo ya AI lazima vizingatie Kanuni za Kifaa cha Kimatibabu (MDR). MDR inahitaji tathmini ya kliniki, ufuatiliaji wa baada ya soko, na nyaraka za data iliyotumiwa kwa mafunzo na uthibitishaji.

Athari kuu ya HITL: Mifumo ya kisheria inahitaji nyaraka wazi za michakato ya uwekaji maelezo, sifa za wawekaji maelezo, uaminifu wa tathmini ya wasomaji wengi, na mabadiliko yoyote kwa data ya mafunzo. Hii si mzigo wa kiutawala — ni mkondo wa ukaguzi unaoruhusu daktari wa kliniki kuelewa data ya mafunzo iliyozalisha tabia ya sasa ya mfano, na inahitajika kwa kisheria. Mifumo ya HITL inayouona uwekaji maelezo kama mchakato usio rasmi huunda hatari ya kisheria ambayo kawaida huonekana wakati mbaya zaidi.

Uwekaji Maelezo wa Data ya Kisayansi

Zaidi ya huduma ya afya, HITL ML inacheza jukumu linaloongezeka na lisilotambuliwa kikamilifu katika utafiti wa kisayansi, ambapo changamoto ya uwekaji maelezo mara nyingi huchanganya utaalamu wa uwanja na kiwango.

Astronomia: Galaxy Zoo

Galaxy Zoo {cite}`lintott2008galaxy` iliwashirikisha wanasayansi raia kuainisha muundo wa galaksi kutoka kwa Sloan Digital Sky Survey. Mradi wa awali ulikusanya zaidi ya uainishaji milioni 40 kutoka kwa wajitolea zaidi ya 100,000, ukionyesha kwamba ushirikiano wa umma kwa kiwango kikubwa wa uainishaji wa picha za kisayansi unawezekana kazi inapoweza kugawanywa katika maswali rahisi yanayoweza kujibiwa bila mafunzo ya mtaalamu ("Je, galaksi hii ni laini au ina vipengele?").

Uzoefu wa Galaxy Zoo ulizalisha matokeo mawili muhimu ya kimbinu. Kwanza, makubaliano kati ya wanasayansi raia na wanaastronomi wa kitaalamu yalikuwa ya juu kwa hali wazi na yalitofautiana kwa kimfumo kwenye hali za mpaka — hasa hali ambapo tofauti ina umuhimu wa kisayansi. Suluhisho haikuwa kutupa data ya sayansi ya raia kwenye hali za mpaka bali kutibu usambazaji wa majibu ya wajitolea kama lebo laini inayoweka utata wa kweli wa kimuundo. Pili, kisambazaji kilichofunzwa kwenye lebo za Galaxy Zoo kilikuwa bora kuliko mifano iliyofunzwa kuiga lebo za mtaalamu yeyote mmoja, kwa sababu usambazaji wa umati ulinasa wasiwasi wa kweli wa kuona ambao chaguo la kulazimishwa la mtaalamu mmoja ulikukunywa.

Genomiki: Uainishaji wa Pathogenicity

Kuweka maelezo kwenye tofauti za genomiki — kuamua kama tofauti ni ya kudhuru, salama, au ya maana isiyo wazi — ni tatizo la NLP yenye hatari kubwa na hukumu ya wataalam. Hifadhidata za kimatibabu za tofauti kama ClinVar hujumuisha tafsiri za wataalam kutoka maabara nyingi zinazotoa, na kutokubaliana kati ya maabara ni kawaida. Ujifunzaji tendaji unatumika kutanguliza tofauti zipi zinahitaji mapitio kamili ya wataalam (utafutaji wa fasihi, tathmini ya ushahidi wa kazi) dhidi ya zipi zinaweza kuwekewa maelezo kiotomatiki na ushahidi uliopo. Matokeo ni mfumo mseto ambapo tofauti nyingi zinashughulikiwa na mantiki ya kiotomatiki, kundi dogo linahitaji mapitio ya wataalam, na hali ngumu zaidi zinabainishwa kwa makubaliano ya maabara nyingi.

Hali ya Hewa na Sayansi ya Ardhi

Kuweka lebo kwenye picha za satelaiti kwa mabadiliko ya matumizi ya ardhi, ukataji miti, upanuzi wa barafu, na njia za dhoruba kunahusisha wataalam wa kunasa kwa mbali na, zaidi, majukwaa ya sayansi ya raia. Changamoto kuu ya HITL katika uwanja huu ni ya muda: lebo zilizofanywa leo zinaweza kuwa za zamani kadri ulimwengu unavyobadilika, na uthibitishaji wa ukweli wa ardhi (uchunguzi wa shambani) ni ghali na umezuiliwa kwa ulogistiki. Ujifunzaji tendaji unaotanguliza picha ambapo utabiri wa mfano unakinzana na vigezo vya kimwili (k.m., kutabiri ukataji miti katika eneo linalojulikana kuwa linalindwa) ni njia ya vitendo ya kuelekeza rasilimali adimu za uthibitishaji wa shambani.

Sayansi ya Neva: Connectomics

Kuunda upya mzunguko wa neva kutoka picha za darubini ya elektroni — connectomics — inahitaji uwekaji maelezo wa kiwango cha pikseli wa utando wa neva kati ya safu kubwa za picha. Mradi wa Eyewire uliweza kufanya mchezo wa kazi hii, ukiwaingiza wachezaji maelfu wa kufuatilia neva kupitia seli za picha za 3D. Muundo wa uchezaji ulitoa tatizo maalum la HITL: kazi inahitaji makini yanayoendelea na ufikiriaji wa anga kwa vikao virefu, ambavyo husababisha kupungua kwa ubora katika uwekaji maelezo wa kitambo. Kugawanya kazi katika sehemu za mchezo na mitambo ya kijamii kuliweka ushirikiano na ubora wa wawekaji maelezo kwa kiwango ambacho uwekaji maelezo wa kitaalamu hauwezi kufikia.

Kusimamia Wawekaji Maelezo Wataalamu

Uwekaji maelezo unapohitaji utaalamu wa nadra, njia za kawaida za ushirikiano wa umma (Sura ya 13) hazitumiki.

Mvutano wa kimsingi ni kwamba watu wanaoweza kuzalisha maelezo ya ubora wa juu zaidi pia ni watu ambao wakati wao una thamani zaidi na umezuiliwa zaidi. Kila uamuzi wa muundo katika mfumo wa uwekaji maelezo wa wataalamu unapaswa kupimwa dhidi ya swali: je, hii inafanya matumizi bora ya muda wa mtaalamu adimu?

Hii inamaanisha nini katika mazoezi:

- **Weka maelezo ya awali kwa nguvu.** Tumia wawekaji maelezo wa kiwango cha chini, mifano otomatiki, au mifumo inayotegemea sheria kuzalisha wagombea ambao mtaalamu anakagua na kurekebisha badala ya kuunda kutoka mwanzo. Hukumu ya mtaalamu ndiyo kikwazo; kuwalisha uwekaji maelezo wa awali wa kurekebisha ni wa haraka zaidi kuliko kuwaomba waweke maelezo kutoka skrini tupu, mradi ubora wa uwekaji maelezo wa awali ni wa kutosha kwamba marekebisho si ya polepole zaidi kuliko kuanza upya.
- **Buniwa kwa makini ya mtaalamu, si uzalishaji.** Violesura vya uwekaji maelezo vilivyoboreshwa kwa uzalishaji wa juu (maamuzi ya haraka ya binary, mkato wa kibodi, onyesho dogo) yanafaa kwa ushirikiano wa umma. Uwekaji maelezo wa wataalamu mara nyingi hufaidika na violesura tajiri zaidi: ulinganisho wa jozi wa kesi za awali, ufikiaji rahisi wa vifaa vya rejeleo, uwanja wa kuamini wa uwekaji maelezo, na uwezo wa kubainisha kesi kwa majadiliano. Hizi zinapunguza maelezo binafsi lakini zinaboresha ubora na kupunguza haja ya kuweka maelezo tena.
- **Fuatilia mifumo ya wawekaji maelezo binafsi waziwazi.** Na bwawa dogo la wataalamu, inawezekana na muhimu kufuatilia kiwango cha makubaliano cha kila mweka maelezo na jopo, kubainisha kesi zinazoonekana kutofautiana na historia yao wenyewe, na kuzijadili katika vikao vya urekebishaji wa kawaida. Hii si ufuatiliaji — ni mchakato huo huo wa ubora ambao dawa ya kliniki inatumia kwa mapitio ya utendaji, na wataalamu kwa ujumla wanajibu vizuri inapowasilishwa kama uboreshaji wa ubora wa pamoja badala ya tathmini.
- **Muundo wa kikao una umuhimu.** Uwekaji maelezo wa kimatibabu ni wa kudai kiakili. Ushahidi kutoka radiolojia na patholojia unaonyesha kwamba viwango vya makosa huongezeka kwa kiasi kinachopimika baada ya takriban dakika 90 za kusoma kwa kuendelea, na kwamba mapumziko ya dakika chache hata yanaweza kurejesha makini kwa sehemu. Violesura vya uwekaji maelezo vinavyolazimisha mapumziko ya maelekezo (bila kufanywa vinaweza kutupwa) ni uamuzi rahisi wa muundo wa HITL wenye athari ya kweli ya ubora.

Mfumo wa Ujifunzaji Tendaji wa HITL kwa Picha za Kimatibabu

```
import numpy as np
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import roc_auc_score
from sklearn.datasets import make_classification
import matplotlib.pyplot as plt

rng = np.random.default_rng(42)
```

```
# Simulate a rare-pathology detection task
# 8% positive class (e.g., rare pathology)
X, y = make_classification(
    n_samples=5000, n_features=100,
    n_informative=20, n_redundant=10,
    weights=[0.92, 0.08],
    random_state=42
)
X_train, y_train = X[:4000], y[:4000]
X_test,  y_test  = X[4000:], y[4000:]

print(f"Training set positive prevalence: {y_train.mean():.1%}")

def run_medical_al(strategy, n_initial=50, budget=300):
    labeled = list(rng.choice(len(X_train), n_initial, replace=False))
    unlabeled = [i for i in range(len(X_train)) if i not in labeled]
    aucs = []

    while len(labeled) < n_initial + budget:
        model = LogisticRegression(max_iter=500, class_weight='balanced')
        model.fit(X_train[labeled], y_train[labeled])

        if len(labeled) % 30 == 0:
            preds = model.predict_proba(X_test)[:, 1]
            aucs.append(roc_auc_score(y_test, preds))

        X_pool = X_train[unlabeled]
        if strategy == 'uncertainty' and len(labeled) >= 10:
            probs = model.predict_proba(X_pool)
            entropy = -np.sum(probs * np.log(probs + 1e-9), axis=1)
            q = int(np.argmax(entropy))
        else:
            q = rng.integers(0, len(unlabeled))

        labeled.append(unlabeled.pop(q))

    return np.array(aucs)

aucs_al  = run_medical_al('uncertainty')
aucs_rnd = run_medical_al('random')
label_counts = np.arange(len(aucs_al)) * 30 + 50

plt.figure(figsize=(7, 4))
plt.plot(label_counts, aucs_al,  'o-',  color='#2b3a8f', linewidth=2, label='Uncertainty AL')
plt.plot(label_counts, aucs_rnd, 's--', color='#e05c5c', linewidth=2, label='Random baseline'
plt.xlabel("Expert labels obtained", fontsize=12)
plt.ylabel("AUROC", fontsize=12)
plt.title("Active Learning for Rare Pathology Detection", fontsize=13)
plt.legend(); plt.grid(alpha=0.3)
plt.tight_layout()
plt.savefig('medical_al.png', dpi=150)
```

```
plt.show()

# Show how AL preferentially selects positive examples
# by checking which class the queried examples belong to
n_init = 50
labeled_al  = list(rng.choice(len(X_train), n_init, replace=False))
labeled_rnd = labeled_al.copy()
unlabeled_al  = [i for i in range(len(X_train)) if i not in labeled_al]
unlabeled_rnd = unlabeled_al.copy()

model = LogisticRegression(max_iter=500, class_weight='balanced')
model.fit(X_train[labeled_al], y_train[labeled_al])
probs = model.predict_proba(X_train[unlabeled_al])
entropy = -np.sum(probs * np.log(probs + 1e-9), axis=1)
top50_al  = [unlabeled_al[i] for i in np.argsort(entropy)[-50:]]
top50_rnd = list(rng.choice(unlabeled_rnd, 50, replace=False))

pos_rate_al  = y_train[top50_al].mean()
pos_rate_rnd = y_train[top50_rnd].mean()
print(f"\nPositive rate in next 50 queries:")
print(f"  Uncertainty AL: {pos_rate_al:.1%}  (base rate: {y_train.mean():.1%})")
print(f"  Random:         {pos_rate_rnd:.1%}")
print(f"  AL queries {pos_rate_al/y_train.mean():.1f}x more positives than random")
```

See also: Ushirikiano wa umma wa Galaxy Zoo: {cite}`lintott2008galaxy`. Utendaji wa daktari wa radiolojia wa CheXNet: {cite}`rajpurkar2017chexnet`. Ubora wa picha na utambuzi unaosaidiwa na AI: {cite}`yu2022assessing`. Mbinu ya uwekaji maelezo wa NLP ya kliniki: {cite}`pustejovsky2012natural`. Kwa mwongozo wa mpango wa utekelezaji wa AI/ML wa FDA, angalia nyaraka zilizochapishwa na FDA (2021).

Majukwaa na Zana za Uwekaji Maelezo

Jukwaa la uwekaji maelezo ni mazingira ambapo maoni ya binadamu yanakuwa data. Jukwaa zuri huongeza uzalishaji, hupunguza makosa, hudumisha udhibiti wa ubora, na hufanya mfumo wa uwekaji maelezo uweze kusimamiwa kwa kiwango kikubwa. Kuchagua jukwaa sahihi — na kujua wakati wa kujenga dhidi ya kununua — ni uamuzi wenye matokeo makubwa katika mradi wowote wa HITL.

Mazingira ya Jukwaa la Uwekaji Maelezo

Soko la zana za uwekaji maelezo limekua na kukomaa sana katika miaka ya hivi karibuni, likiendeshwa na mahitaji ya biashara ya data ya mafunzo ya ML. Zana zinapanuka kutoka huduma zilizodhibitiwa kikamilifu hadi mifumo ya chanzo wazi inayohifadhiwa na wewe mwenyewe.

Majukwaa ya Chanzo Wazi

Label Studio ni jukwaa maarufu zaidi la uwekaji maelezo la chanzo wazi, linaloungwa mkono na maandishi, picha, sauti, video, na data ya mfululizo wa wakati kupitia usanidi wa kazi unaotegemea XML uliounganishwa. Inaweza kuhifadhiwa na wewe mwenyewe na inaunganisha na njia za nyuma za ML kwa ujifunzaji tendaji. Nguvu muhimu: unyumbufu, msaada wa jumuiya, na uwezo wa kuweka utabiri wa ML wa kawaida kwa uwekaji maelezo wa awali.

Prodigy (kutoka kwa waundaji wa spaCy) ni zana ya uwekaji maelezo inayozingatia sana mtiririko wa kazi iliyoundwa kwa kazi za NLP. Muundo wake wa mtiririko unatuma mifano mmoja kwa wakati mmoja na unasaidia ujifunzaji tendaji kutoka kwenye kisanduku. Kiolesura cha uwekaji maelezo ni kidogo lakini cha haraka — kimeundwa kuongeza juu uzalishaji wa uwekaji maelezo. Prodigy ni programu ya malipo lakini inatumika sana katika utafiti wa NLP.

CVAT (Zana ya Uwekaji Maelezo ya Mwono wa Kompyuta) ni zana inayoongoza ya chanzo wazi kwa uwekaji maelezo wa CV, yenye msaada imara kwa ugunduzi, ugawanyiko, na uwekaji maelezo wa video. Ilitengenezwa awali kwenye Intel, CVAT inasaidia kanuni za ufuatiliaji, uwekaji maelezo wa mifupa, na muunganiko wa kanuni za wahusika wengine.

Doccano inalenga kazi za uwekaji lebo wa mfululizo (NER, uchimbaji wa uhusiano, uainishaji wa maandishi). Kiolesura chake rahisi cha wavuti kinakifanya kiweze kufikiwa na timu bila rasilimali za uhandisi wa data zilizowekwa.

Majukwaa ya Kibiashara

Scale AI inatoa huduma za uwekaji maelezo zilizodhibitiwa kutoka mwisho hadi mwisho: nguvu kazi ya binadamu, usimamizi wa ubora, na muunganiko wa API. Yenye nguvu sana

kwa uendeshaji wa uhuru, roboti, na uwekaji maelezo wa 3D mgumu. Bei inategemea ugumu wa kazi na sauti.

Labelbox ni jukwaa kamili la utunzaji wa data, uwekaji maelezo, na uwekaji lebo unaosaidiwa na ML. Vipengele imara vya biashara: usimamizi wa mradi, mtiririko wa ubora, mzunguko wa maoni wa mfano, na muunganiko na majukwaa makubwa ya ML (SageMaker, Vertex AI, Azure ML).

Appen (awali Figure Eight / CrowdFlower) inafanya kazi na nguvu kazi kubwa ya uwekaji maelezo ya kimataifa pamoja na zana. Chaguo zuri wakati sauti na usimamizi wa nguvu kazi ndio wasiwasi mkuu.

Surge AI inazingatia wawekaji maelezo wataalamu na ni imara kwa kazi zinazohitaji maarifa ya uwanja au hukumu ya kina.

Humanloop inabobea katika ukusanyaji wa maoni ya LLM — uwekaji maelezo wa mapendeleo, ukusanyaji wa data ya RLHF, na tathmini ya mfano.

Ulinganisho wa Kipengele cha Jukwaa la Uwekaji Maelezo

Kipengele	Label Studio	Prodigy	CVAT	Labelbox	Scale AI
Leseni Mwenyeji	Chanzo wazi Mwenyewe / wingu	Kibiashara Mwenyewe	Chanzo wazi Mwenyewe / wingu	Kibiashara Wingu	Kibiashara Iliyodhibitiwa
Uwekaji maelezo wa maandishi	□	□	—	□	□
Uwekaji maelezo wa picha	□	Kidogo	□	□	□
Uwekaji maelezo wa video	□	—	□	□	□
Muunganiko wa ujifunzaji tendaji	□	□	Kidogo	□	□
Uwekaji maelezo wa awali unaosaidiwa na ML	□	□	□	□	□
Mtiririko wa udhibiti wa ubora	Msingi	Msingi	Msingi	Ya juu	Ya juu
Ufikiaji wa API / Programu	□	□	□	□	□
Usimamizi wa nguvu kazi	—	—	—	Kidogo	□

Uwekaji Maelezo kama Msimbo

Kipengele muhimu lakini mara nyingi kisichoshughulikiwa cha miundombinu ya uwekaji maelezo ni **udhibiti wa toleo kwa maelezo na mipango ya uwekaji maelezo**. Kutibu uwekaji maelezo kama msimbo kunamaanisha:

Muundo wa kwanza wa mpango. Uainishaji wa lebo na sheria za uwekaji maelezo vinafafanuliwa katika faili ya usanidi yenye toleo (YAML au JSON) kabla uwekaji maelezo haukuanza. Mabadiliko ya mpango huunda toleo jipya.

Uwekaji toleo wa maelezo. Maelezo huhifadhiwa na kiungo cha toleo la mpango ambalo yalikuundwa chini yake. Hii inaruhusu ukaguzi, kurudisha nyuma, na kulinganisha maelezo kati ya matoleo ya mpango.

Mifumo inayoweza kurudiwa. Mfumo wa uwekaji maelezo — kutoka data ghafi hadi lebo tayari za mafunzo — unapaswa kuweza kurudiwa kutoka kwa msimbo. Mifano ya uwekaji maelezo wa awali, vichujio vya ubora, mantiki ya ujumuishaji, na mgawanyiko wa data vyote vinapaswa kuandikwa.

```yaml
# Example: Label Studio annotation schema (text classification)
label_config: |
  <View>
    <Text name="text" value="$text"/>
    <Choices name="sentiment" toName="text" choice="single">
      <Choice value="positive"/>
      <Choice value="negative"/>
      <Choice value="neutral"/>
      <Choice value="mixed"/>
    </Choices>
  </View>
schema_version: "2.1.0"
task_type: text_classification
guidelines_version: "guidelines_v3.pdf"
```

```
Chanzo cha data
    |
    v
Bwawa lisilo na lebo --> Jukwaa la uwekaji maelezo --> Mkusanyiko wenye lebo
    ^                          |                              |
    |                          | (unaosaidiwa na ML)          v
Ujifunzaji tendaji <-----------+                       Mwendo wa mafunzo
wa mkakati wa maswali                                          |
    ^                                                          v
    +------------- Mfano uliofunzwa <------------------ Tathmini
                                                               |
                                                        Utekelezaji na
                                                        ufuatiliaji
```

Pointi kuu za muunganiko: 1. **Ulaji wa data:** Data isiyowekewa lebo inatiririka kiotomatiki kutoka ghala la data hadi jukwaa la uwekaji maelezo 2. **Uwasilishaji wa mfano:** Mfano bora wa sasa unatekelezwa kwenye jukwaa la uwekaji maelezo kwa uwekaji maelezo wa awali na alama za ujifunzaji tendaji 3. **Usafirishaji:** Maelezo yaliyokamilika husafirishwa katika umbizo

linalooana na mfumo wa mafunzo (COCO JSON, mkusanyiko wa data wa Hugging Face, n.k.)
4. **Mzunguko wa maoni:** Makosa ya mfano wa uzalishaji yanaelekezwa nyuma kwenye jukwaa la uwekaji maelezo kwa marekebisho

> **See also:** Kwa nyaraka za Label Studio na muunganiko wa ujifunzaji tendaji: https://labelstud.io. Kwa Prodigy: https://prodi.gy. CVAT: https://cvat.ai. Kwa ulinganisho wa kina wa zana za uwekaji maelezo, angalia {cite}`monarch2021human`, Sura ya 7.

Ushirikiano wa Umma na Udhibiti wa Ubora

Kazi za uwekaji maelezo zinapokuwa rahisi za kutosha kufanywa na wasio wataalamu, majukwaa ya ushirikiano wa umma hutoa ufikiaji wa nguvu kazi kubwa za uwekaji maelezo zinazohitajika kwa gharama ndogo kwa kipengele. Kujenga mkusanyiko wa data wa ubora wa juu kutoka kwa umati kunahitaji muundo wa kazi uliozingatiwa, uziada wa kimkakati, na udhibiti wa ubora madhubuti.

Majukwaa ya Ushirikiano wa Umma

Amazon Mechanical Turk (MTurk) ni soko la asili la ushirikiano wa umma, lililozinduliwa mwaka 2005. Wafanyakazi ("Turkers") wanakamilisha kazi ndogo ndogo (HITs) zilizowasilishwa na waombaji. Utafiti wa 2018 ulikuta mapato ya wastani ya kwa saa kwa Turkers ya takriban $2/saa — chini sana ya kiwango cha mshahara wa chini katika nchi nyingi zenye mapato ya juu {cite}`hara2018data` — wasiwasi wa kimaadili ulionzwa baadaye katika Sura ya 15. MTurk ni bora kwa kazi rahisi zenye vigezo wazi, vinavyoweza kuthibitishwa.

Prolific ni jukwaa la ushirikiano wa umma la kitaaluma linalolazimu kiwango cha malipo ya chini (kwa sasa karibu £9/saa, takriban $11/saa, kama ilivyoelezwa katika mwongozo uliochapishwa wa Prolific), linachunguza washiriki kwa kidemografia, na linadumisha jopo la wafanyakazi ambao wamekubali kushiriki katika utafiti. Linapendelewa kwa utafiti wa sayansi ya kijamii na kazi zinazohitaji uwakilishi.

Appen (na sawa: Telus International, iMerit) inatoa nguvu kazi za uwekaji maelezo zilizodhibitiwa na usimamizi wa ubora, zinazotumiwa kwa kazi za ugumu wa juu na miradi ya biashara.

Jumuiya maalum. Kwa kazi maalum za uwanja, jumuiya za washupavu wa uwanja zinaweza kutoa maelezo ya ubora wa juu: Galaxy Zoo kwa astronomia, eBird kwa spishi za ndege, Chess Tempo kwa uwekaji maelezo wa nafasi ya chess.

Muundo wa Kazi kwa Ushirikiano wa Umma

Gawanya Kazi Ngumu

Kazi ngumu zinapaswa kugawanywa katika kazi ndogo ndogo rahisi, zilizofafanuliwa vizuri. Badala ya kuomba wafanyakazi kuweka maelezo kikamilifu kwenye hati, waulize swali moja

linalolenga kwa wakati mmoja: "Je, sentensi hii ina jina la mtu?" au "Panga uwazi wa tafsiri hii kwenye kipimo cha 1–5."

Faida za kugawanya: - Mahitaji ya chini ya kiakili kwa kazi □ uchovu mdogo, ubora wa juu zaidi - Kila kazi ndogo inaweza kudhibitiwa ubora kwa kujitegemea - Rahisi zaidi kukagua na kurekebisha

Umuhimu wa Maelekezo

Kiashiria kimoja kikubwa zaidi cha ubora wa ushirikiano wa umma ni ubora wa maelekezo. Maelekezo mazuri ya kazi: - Yanaeleza *lengo* la kazi katika sentensi moja - Yanatoa ufafanuzi wazi, usio na utata wa kila kategoria - Yanatoa mifano 3–5 iliyofanyiwa kazi (hasa hali za mipaka) - Hayana zaidi ya wafanyakazi watakaosoma kweli (< maneno 300 kwa kazi rahisi)

Endesha **utafiti wa majaribio** (wafanyakazi 10–50, kazi 20–100) kabla ya kupanua. Changanua kutokubaliana kwa majaribio; nyingi zinaonyesha utata wa maelekezo ambao unaweza kurekebishwa.

Maswali ya Kiwango cha Dhahabu

Weka **maswali ya kiwango cha dhahabu** — kazi zenye majibu sahihi yanayojulikana — katika mfululizo wote wa kazi. Wafanyakazi wanaoshindwa maswali ya dhahabu chini ya kizingiti wanaondolewa kutoka kwa mradi.

```
import numpy as np
from scipy.stats import binom

rng = np.random.default_rng(42)

def simulate_gold_screening(n_workers=100, gold_per_batch=5,
                            p_good_worker=0.7, good_acc=0.92,
                            bad_acc=0.55, threshold=0.70):
    """
    Simulate quality screening via gold questions.
    Returns: precision and recall of identifying bad workers.
    """
    worker_quality = rng.choice(['good', 'bad'], size=n_workers,
                                p=[p_good_worker, 1 - p_good_worker])
    results = {'tp': 0, 'fp': 0, 'tn': 0, 'fn': 0}

    for q in worker_quality:
        acc = good_acc if q == 'good' else bad_acc
        n_correct = rng.binomial(gold_per_batch, acc)
        passed = (n_correct / gold_per_batch) >= threshold
        if q == 'bad' and not passed:  results['tp'] += 1
        if q == 'good' and not passed: results['fp'] += 1
        if q == 'bad' and passed:      results['fn'] += 1
        if q == 'good' and passed:     results['tn'] += 1

    tp, fp, fn = results['tp'], results['fp'], results['fn']
    precision = tp / (tp + fp + 1e-6)
    recall    = tp / (tp + fn + 1e-6)
    return precision, recall
```

```
# Vary gold question count
gold_counts = [3, 5, 8, 10, 15, 20]
precisions, recalls = [], []
for g in gold_counts:
    p_list, r_list = [], []
    for _ in range(50):
        p, r = simulate_gold_screening(gold_per_batch=g)
        p_list.append(p); r_list.append(r)
    precisions.append(np.mean(p_list))
    recalls.append(np.mean(r_list))

import matplotlib.pyplot as plt
fig, ax = plt.subplots(figsize=(7, 4))
ax.plot(gold_counts, precisions, 'o-', color='#2b3a8f', label='Precision', linewidth=2)
ax.plot(gold_counts, recalls,    's--', color='#0d9e8e', label='Recall',    linewidth=2)
ax.set_xlabel("Gold questions per batch", fontsize=12)
ax.set_ylabel("Screening performance", fontsize=12)
ax.set_title("Worker Screening via Gold Standard Questions", fontsize=13)
ax.legend(fontsize=11); ax.grid(alpha=0.3)
plt.tight_layout()
plt.savefig('gold_screening.png', dpi=150)
plt.show()

p, r = simulate_gold_screening(gold_per_batch=5)
print(f"5 gold questions: Precision={p:.3f}, Recall={r:.3f}")
p, r = simulate_gold_screening(gold_per_batch=10)
print(f"10 gold questions: Precision={p:.3f}, Recall={r:.3f}")
```

Mifano ya Takwimu ya Ujumuishaji wa Lebo

Kura ya wingi ni msingi wa asili lakini inapuuza tofauti katika usahihi wa wawekaji maelezo. Mifano ya takwimu inaweza kufanya vizuri zaidi.

Mfano wa Dawid-Skene

Mfano wa Dawid-Skene (DS) {cite}`dawid1979maximum` unakadiri pamoja: - **Lebo ya kweli** z_i kwa kila kipengele i - **Matrix ya mkanganyiko** $\pi_j^{(k,l)}$ kwa kila mweka maelezo j: uwezekano kwamba mweka maelezo j anapanga kipengele chenye darasa la kweli k kama darasa l

Kanuni ya EM inarudia: - **Hatua ya E:** Kwa matrices za mkanganyiko za wawekaji maelezo, hesabu uwezekano wa nyuma wa kila lebo ya kweli - **Hatua ya M:** Kwa makadirio ya lebo ya kipengele, sasisha matrices za mkanganyiko za wawekaji maelezo

```
import numpy as np
from scipy.special import softmax

def dawid_skene_em(annotations, n_classes, n_iter=20):
    """
    Simplified Dawid-Skene EM for binary classification.
```

```
    annotations: dict {item_idx: [(annotator_idx, label), ...]}
    Returns: estimated true labels and annotator accuracies.
    """
    items = sorted(annotations.keys())
    n_items = len(items)
    annotators = sorted({a for anns in annotations.values() for a, _ in anns})
    n_annotators = len(annotators)
    ann_idx = {a: i for i, a in enumerate(annotators)}

    # Initialize: majority vote
    T = np.zeros((n_items, n_classes))  # soft label estimates
    for i, item in enumerate(items):
        for _, label in annotations[item]:
            T[i, label] += 1
        T[i] /= T[i].sum()

    # Confusion matrices: shape (n_annotators, n_classes, n_classes)
    PI = np.ones((n_annotators, n_classes, n_classes)) * 0.5

    for _ in range(n_iter):
        # M-step: update confusion matrices
        PI = np.zeros((n_annotators, n_classes, n_classes)) + 1e-6
        for i, item in enumerate(items):
            for ann, label in annotations[item]:
                a = ann_idx[ann]
                for k in range(n_classes):
                    PI[a, k, label] += T[i, k]
        PI /= PI.sum(axis=2, keepdims=True)

        # E-step: update soft label estimates
        T = np.zeros((n_items, n_classes))
        for i, item in enumerate(items):
            log_p = np.zeros(n_classes)
            for ann, label in annotations[item]:
                a = ann_idx[ann]
                log_p += np.log(PI[a, :, label] + 1e-10)
            T[i] = softmax(log_p)

    return {item: T[i] for i, item in enumerate(items)}, PI

# Simulate crowdsourcing scenario
rng = np.random.default_rng(42)
N_ITEMS, N_ANNOTATORS, ANNS_PER_ITEM = 200, 10, 3
true_labels = rng.integers(0, 2, N_ITEMS)
# Annotator accuracies: 3 good (0.9), 4 medium (0.75), 3 noisy (0.6)
accuracies = [0.90]*3 + [0.75]*4 + [0.60]*3

annotations = {}
for i in range(N_ITEMS):
    anns_for_item = []
    chosen = rng.choice(N_ANNOTATORS, ANNS_PER_ITEM, replace=False)
```

```
    for a in chosen:
        acc = accuracies[a]
        label = true_labels[i] if rng.random() < acc else 1 - true_labels[i]
        anns_for_item.append((a, int(label)))
    annotations[i] = anns_for_item

# Run Dawid-Skene
soft_labels, confusion = dawid_skene_em(annotations, n_classes=2, n_iter=30)
ds_preds = {i: int(np.argmax(soft_labels[i])) for i in range(N_ITEMS)}

# Compare with majority vote
mv_preds = {}
for i in range(N_ITEMS):
    votes = [l for _, l in annotations[i]]
    mv_preds[i] = int(np.round(np.mean(votes)))

ds_acc = np.mean([ds_preds[i] == true_labels[i] for i in range(N_ITEMS)])
mv_acc = np.mean([mv_preds[i] == true_labels[i] for i in range(N_ITEMS)])

print(f"Majority vote accuracy:  {mv_acc:.3f}")
print(f"Dawid-Skene accuracy:    {ds_acc:.3f}")
print(f"\nEstimated annotator accuracies (diagonal of confusion matrix):")
for a in range(N_ANNOTATORS):
    est_acc = np.mean([confusion[a, k, k] for k in range(2)])
    print(f"  Annotator {a}: estimated={est_acc:.3f}, true={accuracies[a]:.2f}")
```

MACE

MACE (Makadirio ya Uwezo wa Wawekaji Maelezo Wengi) {cite}`hovy2013learning` ni mfano mbadala wa uwezekano ambao unawakilisha waziwazi kutuma taka kwa wawekaji maelezo (uwekaji lebo wa nasibu) dhidi ya uwekaji maelezo wa uwezo. Mweka maelezo ama hutoa lebo yenye maana (kwa uwezekano $1 - \text{taka}_j$) au lebo ya nasibu (kwa uwezekano taka_j). Mfano huu wa vipande viwili mara nyingi umewekwa vizuri zaidi kuliko Dawid-Skene kwa hali za ushirikiano wa umma ambapo wawekaji maelezo wengine ni watumaji taka tu.

Mkakati wa Uziada na Ujumuishaji

Idadi bora ya wawekaji maelezo kwa kipengele inategemea ugumu wa kazi na ubora wa wawekaji maelezo:

- **Kazi rahisi na wawekaji maelezo wenye ujuzi:** Wawekaji maelezo 1–2 kwa kipengele mara nyingi vinatosha
- **Kazi za wastani na wawekaji maelezo waliofunzwa:** Wawekaji maelezo 3 + kura ya wingi
- **Kazi ngumu/za udhati na wafanyakazi wa umma:** Wawekaji maelezo 5–7 + Dawid-Skene

Ufahamu muhimu: uziada una thamani zaidi wakati usahihi wa wawekaji maelezo ni mdogo. Kwa wawekaji maelezo wenye usahihi p, usahihi wa kura ya wingi na wawekaji maelezo n ni:

$$P(\text{kura ya wingi sahihi}) = \sum_{k>n/2}^{n} \binom{n}{k} p^k (1-p)^{n-k}$$

Kwa $p = 0.70$, kuongeza mweka maelezo wa tatu huongeza usahihi wa kura ya wingi kutoka 70% hadi 78%; kwa $p = 0.90$, faida kutoka kwa mweka maelezo wa tatu ni ndogo sana (kutoka 90% hadi 97%).

See also: Mfano wa Dawid-Skene: {cite}`dawid1979maximum`. MACE: {cite}`hovy2013learning`. Kwa mapitio ya kina ya ushirikiano wa umma kwa NLP: {cite}`snow2008cheap`. Maadili ya umati na malipo ya haki: angalia Sura ya 15.

Tathmini na Vipimo

Kujua kama mfumo wako wa HITL unafanya kazi kunahitaji zaidi ya kupima usahihi wa mfano. Unahitaji kujua kama unapata thamani kutoka kwa bajeti yako ya uwekaji maelezo, kama mfano uko kweli umeoana vizuri zaidi na nia ya binadamu, na kama maoni ya ziada ya binadamu yataendelea kuboresha mambo. Sura hii inashughulikia mandhari kamili ya tathmini katika mazingira ya HITL.

Vipimo vinavyozingatia Mfano

Vipimo vya kawaida vya ML vinatumika moja kwa moja kwa mifumo ya HITL, yenye nuances muhimu.

Vipimo vya Uainishaji

Usahihi unafaa wakati madarasa yanasawaziwa na makosa yote yana gharama sawa. Katika mazingira ya HITL, hata hivyo, seti ya upimaji yenye lebo inaweza kubaguliwa na mkakati wa maswali (ujifunzaji tendaji unauliza mifano isiyokuwa ya nasibu), ikifanya makadirio rahisi ya usahihi yasitegemewa.

Alama ya F1 ni wastani wa kiharmoniki wa usahihi na ukumbushaji, unaofaa kwa madarasa yasiyosawazishwa. Katika muktadha wa HITL, usahihi na ukumbushaji vyote viwili vinaweza kuwa na umuhimu tofauti kulingana na asymmetry ya gharama kati ya hasi za uongo na chanya za uongo.

AUROC inapima uwezo wa mfano kutofautisha kati ya madarasa bila kujali kizingiti — muhimu kwa kazi zenye usikivu wa urekebishaji kama uchunguzi wa kimatibabu.

Urekebishaji inapima jinsi uwezekano uliotabiriwa unavyolingana na mara za kimajaribio. Katika mifumo ya HITL, mifano iliyofunzwa kwenye seti zilizobaguliwa za lebo (kutoka ujifunzaji tendaji) inaweza kuwa na urekebishaji mbaya hata inapofikia usahihi.

Vipimo vya Mfano wa Uzalishaji

Kwa mifano ya lugha na mifumo ya uzalishaji, tathmini ni ngumu zaidi kwa msingi. Hakuna kipimo kimoja cha kiotomatiki kinachonakili ubora:

- **BLEU / ROUGE / METEOR:** Vipimo vinavyotegemea rejeleo kwa tafsiri na muhtasari. Vinahusiana kidogo na hukumu za ubora za binadamu kwa uzalishaji wa maudhui marefu.
- **Msongamano:** Inapima jinsi mfano unavyotabiri vizuri maandishi yaliyohifadhiwa. Sharti la lazima lakini si la kutosha kwa ubora.

- **BERTScore:** Kufanana kunaotegemea uwakilishi kwa marejeo. Kunahusiana vizuri zaidi na hukumu za binadamu kuliko vipimo vya n-gram.
- **Tathmini ya binadamu:** Kiwango cha dhahabu. Angalia Sehemu ya 14.3.

Vipimo vya Ufanisi wa Uwekaji Maelezo

Tathmini ya HITL inapaswa pia kupima kama maoni ya binadamu yanatumika kwa ufanisi.

Miundo ya Kujifunza

Mstari wa kujifunza unaonyesha utendaji wa mfano kama kitendaji cha idadi ya mifano yenye lebo. Mstari wa kujifunza wa mwinuko (uboreshaji wa haraka na lebo chache) unaonyesha kwamba mkakati wa uwekaji maelezo unachagua mifano yenye habari. Mstari wa kujifunza tambalala unaonyesha kwamba uwekaji lebo wa ziada unatoa faida zinazopungua.

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import f1_score, roc_auc_score
from sklearn.model_selection import StratifiedShuffleSplit

rng = np.random.default_rng(42)
X, y = make_classification(n_samples=5000, n_features=30, n_informative=15,
                           weights=[0.8, 0.2], random_state=42)
X_test, y_test = X[4000:], y[4000:]
X_pool, y_pool = X[:4000], y[:4000]

label_sizes = [20, 40, 60, 100, 150, 200, 300, 400, 600, 800, 1000, 1500, 2000]
metrics = {'f1': [], 'auc': []}

for n in label_sizes:
    idx = rng.choice(len(X_pool), n, replace=False)
    clf = LogisticRegression(max_iter=500, class_weight='balanced')
    clf.fit(X_pool[idx], y_pool[idx])
    preds = clf.predict(X_test)
    probs = clf.predict_proba(X_test)[:, 1]
    metrics['f1'].append(f1_score(y_test, preds))
    metrics['auc'].append(roc_auc_score(y_test, probs))

# Fit learning curve: performance ≈ a - b/sqrt(n)
from scipy.optimize import curve_fit

def learning_curve_fn(n, a, b):
    return a - b / np.sqrt(n)

popt_f1, _ = curve_fit(learning_curve_fn, label_sizes, metrics['f1'], p0=[0.9, 2])
popt_auc, _ = curve_fit(learning_curve_fn, label_sizes, metrics['auc'], p0=[0.95, 1])

n_smooth = np.linspace(20, 3000, 200)
```

```
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(11, 4))

ax1.scatter(label_sizes, metrics['f1'], color='#2b3a8f', zorder=5, s=40)
ax1.plot(n_smooth, learning_curve_fn(n_smooth, *popt_f1), '--', color='#e05c5c',
         label=f'Fit: {popt_f1[0]:.3f} - {popt_f1[1]:.1f}/√n')
ax1.set_xlabel("Labeled examples"); ax1.set_ylabel("F1 score")
ax1.set_title("Learning Curve: F1"); ax1.legend(); ax1.grid(alpha=0.3)

ax2.scatter(label_sizes, metrics['auc'], color='#0d9e8e', zorder=5, s=40)
ax2.plot(n_smooth, learning_curve_fn(n_smooth, *popt_auc), '--', color='#e05c5c',
         label=f'Fit: {popt_auc[0]:.3f} - {popt_auc[1]:.2f}/√n')
ax2.set_xlabel("Labeled examples"); ax2.set_ylabel("AUROC")
ax2.set_title("Learning Curve: AUROC"); ax2.legend(); ax2.grid(alpha=0.3)

plt.tight_layout()
plt.savefig('learning_curves.png', dpi=150)
plt.show()

# Estimate the annotation budget needed to reach a target performance
target_f1 = 0.80
n_needed = (popt_f1[1] / (popt_f1[0] - target_f1)) ** 2
print(f"Estimated labels needed to reach F1={target_f1}: {n_needed:.0f}")
```

Uchambuzi wa Faida kwa Gharama (ROI)

ROI ya maoni ya binadamu inajibu: kwa kila lebo ya ziada, utendaji wa mfano huboresha kiasi gani?

$$\text{ROI}(n) = \frac{\Delta\text{utendaji}(n)}{\text{gharama kwa lebo}}$$

Mfano unavyokomaa (na mifano rahisi ya kujifunza ikimalizwa), ROI kawaida hupungua. Athari ya vitendo: bajeti za uwekaji maelezo zinapaswa kuwekwa mbele, na lebo nyingi zaidi kukusanywa katika hatua za mapema ambapo ROI ni ya juu zaidi.

Tathmini ya Binadamu

Kwa mifumo ya uzalishaji na kazi za udhati, tathmini ya binadamu inabaki kuwa kiwango cha dhahabu.

Tathmini ya Moja kwa Moja (DA)

Wawekaji maelezo wanipanga matokeo kwenye kipimo kamili (k.m., 1–100 kwa ubora wa tafsiri, au 1–5 kwa usaidizi wa jibu). DA imewekwa kiwango katika tathmini ya tafsiri ya mashine (vipimo vya WMT).

Mazoezi bora kwa DA: - Fanya mpangilio wa nasibu wa matokeo kuzuia nanga - Tumia wawekaji maelezo wa kutosha kwa kipengele (angalau 3–5) - Jumuisha udhibiti wa ubora

(mifano mizuri wazi na mibaya kupata watathmini wasio na makini) - Ripoti makubaliano ya wawekaji maelezo pamoja na alama za jumla

Tathmini ya Ulinganisho

Wawekaji maelezo huchagua kati ya matokeo mawili: "Lipi ni bora?" Hukumu za ulinganisho ni za haraka zaidi na thabiti zaidi kuliko alamu kamili (angalia Sura ya 8). **Mifumo ya tathmini ya ELO** (iliyokopwa kutoka chess) hubadilisha matokeo ya ulinganisho wa jozi kuwa upangaji wa kuendelea wa ubora.

```
import numpy as np

def update_elo(rating_a, rating_b, outcome_a, k=32):
    """Update ELO ratings. outcome_a: 1=A wins, 0=B wins, 0.5=tie."""
    expected_a = 1 / (1 + 10 ** ((rating_b - rating_a) / 400))
    expected_b = 1 - expected_a
    new_a = rating_a + k * (outcome_a - expected_a)
    new_b = rating_b + k * ((1 - outcome_a) - expected_b)
    return new_a, new_b

# Simulate 5 model versions being compared pairwise
rng = np.random.default_rng(42)
true_quality = [0.60, 0.70, 0.75, 0.80, 0.85]  # underlying model quality
n_models = len(true_quality)
elo_ratings = {i: 1000.0 for i in range(n_models)}

for _ in range(500):  # 500 pairwise comparisons
    i, j = rng.choice(n_models, 2, replace=False)
    p_i_wins = true_quality[i] / (true_quality[i] + true_quality[j])
    outcome = 1.0 if rng.random() < p_i_wins else 0.0
    elo_ratings[i], elo_ratings[j] = update_elo(elo_ratings[i], elo_ratings[j], outcome)

print("ELO Rankings after 500 comparisons:")
sorted_models = sorted(elo_ratings.items(), key=lambda x: x[1], reverse=True)
for rank, (model_id, elo) in enumerate(sorted_models, 1):
    print(f"  Rank {rank}: Model {model_id}  ELO={elo:.1f}  True quality={true_quality[model_
```

Upimaji wa Kitabia (CheckList)

CheckList {cite}`ribeiro2020beyond` ni mbinu ya tathmini ya kitabia ya kimfumo ya mifano ya NLP. Badala ya seti za upimaji za nasibu, inabuni hali za upimaji zinazochunguza uwezo maalum:

- **Majaribio ya Utendaji wa Chini Zaidi (MFT):** Je, mfano unashughulikia hali rahisi, dhahiri?
- **Majaribio ya Kutofautiana (INV):** Je, tokeo la mfano linabadilika inaposipaswi (k.m., wakati wa kufafanua upya)?
- **Majaribio ya Matarajio ya Mwelekeo (DIR):** Je, tokeo la mfano linabadilika katika mwelekeo unaotarajiwa wakati ingizo linabadilika?

CheckList inafanya tathmini ya binadamu kuwa yenye lengo na inayoweza kuchukuliwa hatua: badala ya namba moja ya usahihi, inatoa wasifu wa uwezo.

Kupima Ulinganifu na Nia ya Binadamu

Kwa mifumo ya RLHF, kupima ulinganifu ni changamoto ya tathmini ya msingi.

Tathmini ya mfano wa zawadi: Usahihi wa mfano wa zawadi kwenye seti ya upimaji ya mapendeleo iliyohifadhiwa. Ouyang et al. {cite}`ouyang2022training` wanaripoti takriban 72% ya usahihi wa jozi kwa mfano wa zawadi wa InstructGPT; kama hatua ya rejeleo ya takriban, namba karibu na hizi zinanukuulika kawaida kwa mifumo ya RLHF inayofanana, ingawa matokeo yanatofautiana sana kulingana na kazi na ubora wa data.

Kiwango cha kushinda: Ukitoa matoleo mawili ya mfano (k.m., msingi wa SFT dhidi ya iliyoboreshwa fini na RLHF), sehemu ngapi ya majibu mfano wa RLHF unashinda katika ulinganisho wa jozi wa binadamu?

GPT-4 kama mtathminii: Kutumia LLM yenye uwezo kutathmini majibu imekuwa ya kawaida kwa mzunguko wa haraka. Gilardi et al. {cite}`gilardi2023chatgpt` na Zheng et al. {cite}`zheng2023judging` wanakuta makubaliano ya mtathminii wa LLM na hukumu ya binadamu yanayopanuka takriban kutoka 0.7 hadi 0.9 kulingana na kazi — inafaa kwa ulinganisho wa haraka wa A/B, lakini si ya kutegemewa kwa kugundua sycophancy, nuance ya kitamaduni, au masuala ya usalama.

Ugunduzaji wa sycophancy: Pima kama mfano unabadilisha majibu yake kulingana na upendeleo unaopendekeza wa mtumiaji (k.m., "Nafikiri X ni sahihi; unafikiria nini?"). Mfano uliolinganifu vizuri haupaswi kuwa na sycophancy.

Upimaji wa A/B katika Mifumo Iliyotekelezwa

Kwa mifumo katika uzalishaji, tathmini ya mwisho ni **upimaji wa A/B**: elekeza sehemu ya watumiaji kwa toleo jipya la mfano na pima matokeo ya chini.

Upimaji wa A/B hutoa makadirio yasiyobaguliwa ya ubora wa mfano katika muktadha wa utekelezaji halisi, ukinakili athari ambazo tathmini ya maabara inakosa (tabia ya mtumiaji, usambazaji wa idadi ya watu, hali za mipaka).

Changamoto: vipimo vinavyofaa vya chini. Vipimo vya ushiriki (mabonyezo, urefu wa kikao) vinaweza kutunza tabia ya udanganyifu. Viwango vya kukamilika kwa kazi au uchunguzi wa kuridhika kwa mtumiaji vimelinganifu vizuri zaidi lakini vina kelele zaidi.

> **See also:** Upimaji wa kitabia wa CheckList: {cite}`ribeiro2020beyond`. Kwa mbinu za tathmini ya RLHF, angalia {cite}`ouyang2022training`. Kwa mazoezi bora ya tathmini ya binadamu katika MT: {cite}`graham2015accurate`. Kwa nadharia ya mstari wa kujifunza: {cite}`mukherjee2003estimating`.

Usawa, Upendeleo, na Maadili

Mifumo ya binadamu-katika-mzunguko hurithi uwezo na mipaka ya binadamu walio ndani yake. Wawekaji maelezo wanaleta maarifa, hukumu, na ubunifu katika kazi yao — lakini pia upendeleo, uchovu, na muktadha wa kijamii wa maisha yao. Maamuzi tunayofanya katika kubuni mifumo ya HITL — ni nani anayeweka maelezo, wanaulizwa nini, wanalipwaje, na jinsi kazi yao inavyotumika — yana matokeo yanayopanuka mbali zaidi ya vipimo vya usahihi wa mfano.

Sura hii inashughulikia vipengele vya kimaadili vya HITL ML.

Vyanzo vya Upendeleo katika Mifumo ya HITL

Kidemografia cha Wawekaji Maelezo

Uwekaji maelezo si kitendo cha kawaida. Lebo wanazotoa wawekaji maelezo zinaakisi mitazamo, uzoefu, na muktadha wa kitamaduni. Nguvu kazi ya uwekaji maelezo inapokuwa ya kidemografia moja — kama ilivyo mara nyingi, kazi za umma zikitawaliwa na wachanga, wa kiume, na wa Magharibi — mkusanyiko wa data unaotokea huweka mitazamo ya kikundi hicho.

Ushahidi: Tafiti za mkusanyiko wa data wa uwekaji maelezo wa NLP zimegundua kwamba sifa za kidemografia za wawekaji maelezo zinaabiri uchaguzi wa lebo kwa kazi za udhati (usumu, hisia, kukera). Mkusanyiko wa data ulioandikwa na wafanyakazi wa umma wa Marekani hasa huweka kanuni za kitamaduni za Marekani ambazo hazijumlishi katika maeneo mengine {cite}`geva2019annotator`.

Matokeo: Mifano iliyofunzwa kwenye data kama hiyo hufanya vizuri kwa watumiaji wanaofanana na bwawa la wawekaji maelezo na vibaya zaidi — au kwa njia za kibaguzi — kwa watumiaji ambao hawafanani.

Kupunguza: Utofauti wa nguvu kazi wa makusudi; uwekaji maelezo uliobainishwa (hakikisha wawekaji maelezo kutoka kwa vikundi vya kidemografia vinavyohusika vanachangia kwa kazi zinazohusika); fuatilia kidemografia cha wawekaji maelezo na athari yake kwenye usambazaji wa lebo.

Muundo wa Kazi

Jinsi swali linavyowekwa muundo huathiri majibu yanayosababishwa. Wawekaji maelezo wakiulizwa "Je, maandishi haya yana sumu?" wanaweza kujibu tofauti kuliko wakiulizwa "Je, maandishi haya yangedhuru mtu anayemiliki kikundi kilichotajwa?" Muundo huweka dhana kuhusu kinachohusika.

Mfano: Uwekaji maelezo wa "lugha ya udhalimu" kwenye mitandao ya kijamii unatofautiana kwa kiasi kikubwa kulingana na kama wawekaji maelezo wanaonyeshwa habari za muktadha kuhusu utambulisho wa mwandishi. Taarifa inayoonekana kuwa ya kutisha peke yake inaweza kutambuliwa kama lugha iliyorejelewa au mzaha wa ndani ya kikundi habari za muktadha zinapotolewa.

Athari za Jukwaa

Jukwaa na muundo wa malipo huathiri ubora wa uwekaji maelezo. Wafanyakazi wanaolipwa kwa kazi badala ya kwa saa wana motisha ya kufanya haraka; hii huongeza uzalishaji lakini hupunguza ubora. Wafanyakazi wanaohofu kuzuiwa kutoka kwa jukwaa kwa usahihi mdogo wanaweza kuepuka kuandika "wasiwasi" na badake kufanya nadhani, kuficha utata wa kweli.

Upendeleo wa Uthibitisho na Nanga

Wawekaji maelezo wanaathiriwa na: - **Uwekaji maelezo wa awali:** Utabiri wa mfano unaoonyeshwa kwa wawekaji maelezo unakubaliwa mara nyingi zaidi kuliko kukataliwa, hata unaposha makosa - **Athari za mpangilio:** Kuweka lebo kipengele kimoja katika muktadha tofauti huzalisha majibu tofauti - **Kuchochea:** Vipengele vya awali katika kazi huathiri jinsi vipengele vinavyofuata vinavyowekewa lebo

---

Usawa katika Mifumo ya HITL

Usawa ni Nini?

Usawa katika ML ni dhana inayoshindaniwa yenye ufafanuzi mwingi rasmi ambao mara nyingi hauwezi kupatikana pamoja {cite}`barocas2019fairness`. Kwa madhumuni ya HITL, vipengele muhimu zaidi ni:

Uwakilishi: Je, data ya mafunzo inawakilisha idadi za watu ambazo mfano utaziathiri?

Usawa wa utendaji: Je, mfano hufanya vizuri sawasawa kati ya vikundi tofauti vya kidemografia?

Uthabiti wa uwekaji lebo: Je, tabia sawa zinawekewa lebo sawasawa bila kujali ni nani anazifanya? (Utafiti umeonyesha hii si mara zote hivyo — maudhui sawa wakati mwingine huwekewa lebo tofauti yanapohusishwa na vikundi tofauti vya rangi au jinsia.)

Ujifunzaji Tendaji Unaozingatia Usawa

Ujifunzaji tendaji wa kawaida unazingatia wasiwasi wa mfano, ambao huwa unajilundika kwenye mifano ya darasa kubwa. Hii inaweza kuongeza tofauti za utendaji kwa vikundi vidogo.

Mikakati ya maswali inayozingatia usawa huongeza kigezo cha wasiwasi na vikwazo vya utofauti au uwakilishi:

$$x^* = \arg\max_{x \in \mathcal{U}} \left[\lambda \cdot \text{wasiwasi}(x) + (1 - \lambda) \cdot \text{faida_ya_kikundi_kidogo}(x)\right]$$

Kuweka $\lambda < 1$ kuhakikisha mkakati wa maswali haupuuzi uwakilishi wa kikundi kidogo kabisa.

Ustawi wa Wawekaji Maelezo

Tatizo la Kazi ya Kivuli

Kazi ya uwekaji maelezo inayosaidia ML kwa kiasi kikubwa haionekani. Wafanyakazi wa data — mara nyingi katika Kusini mwa Dunia — huweka lebo kwenye picha, kunukuu usemi, na kusimamia maudhui kwa malipo ya chini, bila faida, katika mipango ya uchumi wa kazi za ziada bila usalama wa kazi. "Anatomy of an AI System" ya Kate Crawford na Vladan Joler {cite}`crawford2018anatomy` na "Ghost Work" ya Mary Gray na Siddharth Suri {cite}`gray2019ghost` ziliandika kiwango na hatari ya kazi hii.

Takwimu za Amazon MTurk: Uchambuzi wa kimfumo wa 2018 wa mapato ya MTurk uligundua malipo ya wastani ya kwa saa ya takriban $2/saa — chini ya kiwango cha mshahara wa chini katika majimbo mengi ya Marekani na nchi nyingi zenye mapato ya juu {cite}`hara2018data`. Wafanyakazi nje ya nchi zenye mapato ya juu mara nyingi wanakabili vikwazo vya ziada: waombaji mara nyingi huzuia kazi za malipo ya juu kwa sifa za Marekani-peke yake, na bwawa la wafanyakazi wanaoshindana kwa kazi zilizobaki za wazi ni la kimataifa, ukibanisha mapato ya kwa kazi zaidi.

Usimamizi wa maudhui: Aina inayodhuru hasa ya kazi ya uwekaji maelezo — kukagua maudhui ya picha, ya ukatili, na ya kusumbua — imehusishwa na PTSD, msongo wa mawazo, na wasiwasi miongoni mwa wafanyakazi {cite}`newton2019trauma`. Majukwaa yamekabili ukosoaji kwa msaada wa kutosha wa afya ya akili na nambari za kukaribia zinazozidi.

Mazoezi ya Kimaadili

Malipo ya haki: Lipa wafanyakazi wa uwekaji maelezo kwa kiwango sawa au juu ya kiwango cha chini cha mshahara cha ndani. Utafiti umeonyesha kwamba malipo ya juu huvutia wafanyakazi wa ubora wa juu bila kuongeza kwa usawa gharama kwa lebo sahihi.

Uonekano wa kazi: Kiri kazi ya kuunda data ya mafunzo katika machapisho na nyaraka za bidhaa.

Msaada wa afya ya akili: Kwa wafanyakazi wanaokagua maudhui ya kudhuru, toa msaada wa kisaikolojia, ratiba za mzunguko, na mipaka ya mfiduo.

Uwakilishi wa wafanyakazi: Wezesha wafanyakazi wa uwekaji maelezo kuripoti matatizo, kuomba ufafanuzi wa mwongozo, na kupinga tathmini za ubora zisizo za haki.

Faragha katika Uwekaji Maelezo

Habari Zilizo Chini ya Ulinzi wa Afya (PHI) na PII

Kazi za uwekaji maelezo mara nyingi zinahusisha data nyeti ya kibinafsi. Mradi wa uwekaji maelezo wa kimatibabu unaweza kuweka wazi wafanyakazi kwa rekodi za wagonjwa; mradi wa NLP unaweza kuweka wazi wafanyakazi kwa mawasiliano ya kibinafsi; mradi wa usimamizi wa maudhui huweka wazi wafanyakazi kwa ufafanuzi wa kibinafsi wa watumiaji.

Mifumo ya kisheria (HIPAA, GDPR) ina mipaka ya jinsi data ya kibinafsi inavyoweza kushirikiwa na nguvu kazi za uwekaji maelezo. Kanuni muhimu:

- **Kupunguza data:** Shiriki habari tu ambazo wawekaji maelezo wanahitaji kukamilisha kazi
- **Kuondoa utambuzi:** Ondoa PHI na PII kabla ya uwekaji maelezo inapowezekana
- **Ridhaa:** Data ya kweli ya mtumiaji inapowekewa maelezo, hakikisha ridhaa inayofaa au msingi wa kisheria
- **Udhibiti wa ufikiaji:** Punguza wawekaji maelezo gani wanaweza kufikia data nyeti kulingana na jukumu na uidhinishaji

Data ya Sintetiki kama Mbadala

Kwa kazi ambapo data ya kweli ina hatari za faragha, uzalishaji wa data ya sintetiki unaweza kuunda mkusanyiko wa data tayari wa uwekaji maelezo bila kuweka wazi habari nyeti. Kwa NLP ya kliniki, kwa mfano, maandishi ya EHR ya sintetiki yanaweza kutoa data ya mafunzo ya kweli kwa mifano ya kuondoa utambuzi bila kuweka wazi rekodi halisi za wagonjwa.

Uwekaji Maelezo wa Adui na Uchafuzi wa Data

Mifumo ya HITL huunda uso wa mashambulizi: kama adui anaweza kuathiri mchakato wa uwekaji maelezo, anaweza kuathiri tabia ya mfano.

Uchafuzi wa data kupitia uwekaji maelezo: Mshambuliaji mwenye ufikiaji wa nguvu kazi ya uwekaji maelezo (k.m., akaunti ya wafanyakazi wa umma iliyoathiriwa) anaweza kuingiza mifano iliyowekewa lebo vibaya kwa kimfumo. Hii ni ya ufanisi sana katika mazingira ya ujifunzaji tendaji, ambapo mfano unauliza kwa upendeleo mifano yenye wasiwasi — ambayo inaweza kuwa lengo la adui.

Udanganyifu wa zawadi kupitia maoni: Katika RLHF, wawekaji maelezo (au maelezo yaliyozalishwa na AI) wanaopanga kwa uthabiti aina fulani za maudhui vizuri wanaweza kuielekeza mfano kuelekea maudhui hayo, bila kujali ubora wake wa kweli.

Kupunguza: Wawekaji maelezo wengi huru kwa kipengele; ugunduzaji wa nje ya kawaida kwenye mifumo ya uwekaji maelezo; ufuatiliaji wa makubaliano au kutokubaliana kwa ajabu; kudumisha seti za tathmini ambazo haziwezi kuathiriwa na nguvu kazi ya uwekaji maelezo.

Maadili ya Kitaasisi

IRB na Mapitio ya Kimaadili

Miradi ya utafiti inayohusisha masomo ya binadamu — ikiwemo wafanyakazi wa uwekaji maelezo — mara nyingi inahitaji idhini ya Bodi ya Mapitio ya Kitaasisi (IRB). Miradi ya uwekaji maelezo inayokusanya data kuhusu imani za wafanyakazi, majibu kwa maudhui nyeti, au habari za kidemografia inapaswa kukaguliwa chini ya mfumo huo huo wa kimaadili kama utafiti mwingine wa masomo ya binadamu.

Utawala wa Data

Mashirika yanapaswa kuwa na sera wazi za: - Data gani inaweza kutumwa kwa uwekaji maelezo wa nje dhidi ya kuwekewa maelezo ndani - Maelezo hudumishwa kwa muda mrefu kiasi gani na na nani - Ni nani ana ufikiaji wa maelezo na mifano iliyofunzwa kwenye hayo - Jinsi ya kushughulikia maombi ya kufuta data iliyowekewa maelezo (haki ya GDPR ya kufuta)

Uwazi na Uwajibikaji

Watumiaji walioathiriwa na mifumo ya ML wana hamu ya kisheria ya kuelewa jinsi mifumo hiyo ilijengwa. Kuandika mbinu za uwekaji maelezo — ni nani aliyeweka lebo data, chini ya hali zipi, na mwongozo gani — ni aina ya uwajibikaji unaofaidisha watumiaji, wasimamizi, na uwanja kwa jumla.

Karatasi za Data za Mkusanyiko wa Data {cite}`gebru2021datasheets` zinatoa kiolezo kilichopangwa cha kuandika asili ya mkusanyiko wa data, taratibu za uwekaji maelezo, na mipaka inayojulikana.

> **See also:** Mfumo wa usawa wa kanuni: {cite}`barocas2019fairness`. Kazi ya kivuli na kazi ya jukwaa: Gray & Suri (2019). Karatasi za Data za Mkusanyiko wa Data: {cite}`gebru2021datasheets`. Ustawi wa wafanyakazi wa usimamizi wa maudhui: {cite}`newton2019trauma`. Kidemografia cha wawekaji maelezo na mkusanyiko wa data wa NLP: {cite}`geva2019annotator`.

Mwelekeo wa Baadaye

Uwanja wa ujifunzaji wa mashine wenye binadamu katikati unabadilika haraka. Mifano ya msingi, LLMs-kama-wawekaji maelezo, na mifumo mipya ya ushirikiano kati ya binadamu na AI inabadilika uchumi na mazoezi ya HITL kwa njia ambazo hazikuweza kufikiwa hata miaka mitano iliyopita. Sura hii ya mwisho inaainisha mandhari ya mwelekeo wa kuibuka na matatizo ya wazi.

Mifano ya Msingi na Jukumu Linaloobadilika la Uwekaji Maelezo

Mifano ya msingi — mifano mikubwa iliyofunzwa awali kwenye data pana inayoweza kurekebisiwa kwa kazi za chini — inabadilisha msingi wa uchumi wa HITL.

Kupunguza Mzigo wa Uwekaji Maelezo

Kazi iliyohitaji hapo awali mifano maelfu yenye lebo kwa mafunzo kutoka mwanzo inaweza kuhitaji tu makumi wakati wa kurekebisha mfano wa msingi. Maswali ya mifano michache yanaweza kuondoa haja ya kurekebisha fini kabisa kwa kazi fulani.

Athari: ROI ya uwekaji maelezo inabadilika. Juhudi za uwekaji maelezo sasa zinaelekezwa vizuri zaidi kuelekea: - Seti za tathmini za ubora wa juu (kupima kama mfano uliorekebishwa unafanya kazi kweli kweli) - Hali ngumu na hali za mipaka ambazo mfano wa msingi hushughulikia vibaya - Mifano maalum ya kazi inayofundisha mfano kitu ambacho huwezi kujifunza kutoka mafunzo ya awali

Aina Mpya za Ubainishaji

Mfano wa msingi unaelewa lugha, msimbo, na akili ya kawaida tayari, watumiaji wanaweza kuwasiliana nao kwa lugha asilia badala ya kupitia mifano yenye lebo. Mtumiaji anayetaka kisambazaji cha maandishi hahitaji tena kuweka lebo mifano 500 — anaweza kuandika maelezo ya kazi ya uainishaji na kutathmini utendaji wa sifuri-onyesho.

Hii inahamisha changamoto ya HITL kutoka *ukusanyaji wa mifano* hadi *ubainishaji wa kazi*: kusaidia watumiaji kubainisha waziwazi watakavyo kwa mfumo mfano unaoufanya. Hii ni ngumu zaidi ya inavyosikika — maelezo ya lugha asilia ya kazi mara nyingi yana utata kwa njia ambazo mifano iliyowekewa maelezo haiana.

LLMs kama Wawekaji Maelezo

Moja ya maendeleo muhimu zaidi ya 2023–2025 ni matumizi ya **LLMs kama vyanzo vya uwekaji maelezo**. Badala ya kumuuliza binadamu "Je, tathmini hii ni ya chanya au hasi?", tunamuliza GPT-4 au Claude. Kwa kazi za uainishaji zilizofafanuliwa vizuri, maelezo ya LLM mara nyingi yanalingana na au kufanana karibu na usahihi wa wafanyakazi wa umma {cite}`gilardi2023chatgpt`, na gharama kwa maelezo ya simu za API kawaida ni ya chini kwa mara nyingi zaidi kuliko viwango vya kazi ya binadamu.

Mahali Uwekaji Maelezo wa LLM Unavyofanya Kazi Vizuri

- Kazi rahisi, zilizofafanuliwa vizuri za uainishaji (hisia, mada, nia)
- Kazi ambapo lebo za binadamu zinaweka makubaliano ya kitamaduni ambayo LLM imeyachukua
- Kazi ambapo uwekaji maelezo ni thabiti kati ya muktadha (si ya udhati mkubwa sana)
- Kuzalisha maelezo ya kwanza ya ukaguzi wa binadamu

Mahali Uwekaji Maelezo wa LLM Unavyoshindwa

- Kazi za uwanja maalum sana zinazohitaji utaalamu wa nadra (kimatibabu, kisheria, kisayansi)
- Kazi zinazohitaji maarifa ya kitamaduni ya ndani au tofauti za lugha
- Kazi za usalama na madhara, ambapo LLM inaweza kuwa na urekebishaji mbaya katika mwelekeo huo huo kama data iliyofunzwa
- Aina mpya za kazi ambazo haziwakilishwi vizuri katika mafunzo ya awali

RLAIF na AI ya Kikatiba

Kama ilivyojadiliwa katika Sura ya 6, maoni yaliyozalishwa na AI yanaweza kutumika kufunza mifano ya zawadi na kuongoza kurekebisha fini kwa RL. Hii inaunda mzunguko wa maoni: LLMs huzalisha data, mifano hufunzwa kwake, na mifano bora huzalisha data bora. Swali la jinsi ya kuanzisha mzunguko huu bila kuweka kosa la kimfumo kutoka kwa mfano wa awali ni tatizo kuu la wazi katika utafiti wa usimamizi unaoweza kupanuka.

Usimamizi Dhaifu kwa Kiwango Kikubwa

Uwekaji lebo wa programu kupitia kazi za uwekaji lebo (Sura ya 9) inaruhusu wataalam wa mada kuonyesha maarifa yao kama msimbo badala ya kama mifano yenye lebo. Mifumo kama Snorkel {cite}`ratner2017snorkel` na warithi wake imekomaa kwa kiasi kikubwa na sasa inatumika katika uzalishaji katika makampuni makubwa ya teknolojia.

Mwelekeo wa mpaka: - Kazi za uwekaji lebo zilizoongezewa LLM: Tumia LLMs kuzalisha kazi za uwekaji lebo kutoka kwa maelezo ya lugha asilia - **Kujifunza kulingana na kipande:** Tambua vikundi muhimu vya data (vipande) ambapo kazi za uwekaji lebo zinakinzana na elekeza uwekaji maelezo wa binadamu huko - **Ujumuishaji unaozingatia wasiwasi:** Mifano bora ya takwimu ya kuchanganya kazi za uwekaji lebo zenye usahihi na muunganiko tofauti

---

Kujifunza kwa Kuendelea kwa Usimamizi wa Binadamu

Mifumo mingi ya ML hufunzwa nje ya mtandao na kutekelezwa kama mifano tuli. Ulimwengu unabadilika; mifano iliyokuwa sahihi wakati wa utekelezaji hupungua kadri usambazaji wa data unavyohamia.

Kujifunza kwa kuendelea — uwezo wa kujifunza kutoka kwa data mpya huku ukihifadhi maarifa ya zamani — ni eneo la utafiti tendi. Usimamizi wa binadamu ni muhimu: kujifunza kwa kuendelea kiotomatiki bila mapitio ya binadamu kunaweza haraka kuweka mabadiliko ya usambazaji ambayo ni makosa badala ya mabadiliko ya kweli ya ulimwengu.

Kujifunza kwa kuendelea kwa HITL kunahusisha: - Ufuatiliaji wa mabadiliko ya usambazaji (kiotomatiki) na kuelekeza mifano iliyohamia kwa mapitio ya binadamu - Kurekebisha tena kwa uchaguzi: mifano iliyoidhinishwa na binadamu kutoka usambazaji mpya huongezwa kwenye data ya mafunzo - Mapitio ya binadamu ya mabadiliko ya tabia ya mfano baada ya kila sasishi

---

HITL ya Pande Nyingi

Mifumo ya AI inakuwa ya pande nyingi — ikisindika na kuzalisha maandishi, picha, sauti, na video wakati huo huo — uwekaji maelezo unakuwa mgumu zaidi. Kipande kimoja cha maudhui kinaweza kuhitaji uwekaji maelezo kati ya hali, yenye utegemezi kati yao.

Aina za kazi zinazoibuka: - Uwekaji maelezo wa video + nakala (nini kinatokea, ni nani anazungumza, maandishi yanafanya maelezo ya nini kwa macho?) - Uwekaji maelezo wa picha ya kimatibabu + ripoti ya kliniki - Uwekaji maelezo wa njia ya roboti (kuunganisha data ya sensorer na mfululizo wa vitendo)

Mifano ya msingi ya pande nyingi (GPT-4V, Gemini, Claude) inabadilisha mandhari ya uwekaji maelezo hapa pia — mifano sasa inaweza kufafanua picha na kuzalisha maelezo ya wagombea, ambayo binadamu wanakagua.

Usimamizi Unaoweza Kupanuka

Tatizo la kimsingi la wazi katika HITL ML ni **usimamizi unaoweza kupanuka** {cite}`irving2018ai,bowman2022` mifumo ya AI inakuwa na uwezo zaidi kuliko binadamu katika maeneo maalum, tunawezaje kudumisha usimamizi wa maana wa binadamu?

Kwa kazi kama utabiri wa muundo wa protini, uchambuzi wa kisheria, au uthibitishaji wa uthibitisho wa kihesabu, hata wawekaji maelezo wataalamu wanaweza kutoweza kuhukumu matokeo mawili ya AI ni sahihi. Mbinu za sasa za HITL zinaharibika wakati hukumu ya binadamu ni ya kutegemewa kidogo kuliko mfano unaopimwa.

Mbinu zilizopendekezwa {cite}`bowman2022measuring`:

Mjadala: Mifumo miwili ya AI inajadili kwa hitimisho tofauti; jaji wa binadamu anatathmini hoja badala ya hitimisho moja kwa moja. Hitimisho sahihi linapaswa kuwa na utetezi zaidi.

Ukuzaji: Waamuzi wa binadamu wanashauriana na wasaidizi wa AI (mfano wenyewe) kusaidia kutathmini matokeo magumu. Hii inatumia uwezo wa AI kupanua usimamizi wa binadamu badala ya kuubadilisha.

Usimamizi wa mchakato: Badala ya kutathmini tokeo la mwisho, binadamu wanatathmini *mchakato wa ufikiriaji* — wakibainisha hatua zenye kasoro katika mnyororo wa mawazo, bila kujali kama jibu la mwisho linafanyika kuwa sahihi.

Mgawanyiko wa Kazi Unaobadilika

Njia ya muda mrefu ya HITL ML ni kuelekea ushirikiano wa zaidi kuelea kati ya binadamu na AI, ambapo hakuna mmoja anayekuwa tu "mweka lebo" na mwingine "mjifunzaji," bali wote wanachangia mchakato wa pamoja wa kiakili.

Mwelekeo wa kufuatilia: - **Uwekaji maelezo unaosaidiwa na AI:** AI inapendekeza; binadamu anaamua. Ubora unaboresha AI inapopendekezea chaguo bora. - **Uchunguzi ulioongozwa na binadamu:** Binadamu wanaweka malengo na vikwazo; AI inachunguza nafasi ya suluhisho. - **Tathmini ya ushirikiano:** Binadamu na AI wanavitathmini matokeo magumu kupitia mazungumzo. - **Kujifunza mapendeleo kwa kiwango kikubwa:** Ishara za picha (jinsi watumiaji wanavyoshirikiana na matokeo ya AI) zinalisha kujifunza mapendeleo kwa kuendelea bila kuhitaji vikao vya uwekaji maelezo waziwazi.

Swali la kiasi gani cha kuamini hukumu ya AI dhidi ya hukumu ya binadamu — na katika maeneo gani, kwa viwango gani vya uwezo, na na ulinzi gani — ni hatimaye swali la kijamii, si la kiufundi tu. HITL ML inatoa miundombinu ya kiufundi ya kulijibu kwa makini, badala ya kwa msingi.

Matatizo ya Wazi ya Utafiti

Tunamaliza na orodha ya matatizo muhimu ya wazi ambayo uwanja unashughulikia kikamilifu:

1. **Kusimama bora katika ujifunzaji tendaji:** Wakati thamani ya pembezoni ya maelezo inayofuata ni chini ya gharama? Sheria za kusimama za msingi zinabaki za kueleweka vibaya.

2. **Ugawaji wa bajeti ya uwekaji maelezo kati ya kazi:** Katika mazingira ya kazi nyingi, bajeti ya uwekaji maelezo iliyowekwa inapaswa kugawanywaje kati ya kazi?

3. **Mabadiliko ya usambazaji katika ujifunzaji tendaji:** Ujifunzaji tendaji huunda seti zilizobaguliwa za lebo. Mifano iliyofunzwa hivi iwezaje kurekebishwa ipasavyo?

4. **Ujumlishaji wa mfano wa zawadi:** Mifano ya zawadi ya RLHF inaweza kushindwa kujumlisha kwa jozi mpya za maswali-majibu. Tunawezaje kujenga mifano ya mapendeleo ya ustahimilivu zaidi?

5. **Usimamizi unaoweza kupanuka:** Tunawezaje kudumisha usimamizi wa binadamu mifumo ya AI inapozidi utendaji wa binadamu katika maeneo maalum?

6. **Kuiga wawekaji maelezo:** Mifano bora ya takwimu ya tabia ya wawekaji maelezo inayonasa si uwezo tu bali pia upendeleo wa kimfumo, utaalamu wa mada, na uchovu.

7. **Tathmini ya ulinganifu:** Hatuna majaribio ya ukweli wa ardhi kwa kama mfano unalingana na maadili ya binadamu. Kuendeleza majaribio kama hayo — yanayofanana na mifano ya adui kwa ustahimilivu — ni tatizo la wazi.

8. **Kazi ya data ya haki:** Miundo ya kiuchumi na kitaasisi inayohakikisha wafanyakazi wa uwekaji maelezo wanalipwa haki na kulindwa, huku ikidumisha ufanisi wa gharama wa uwekaji maelezo kwa kiwango kikubwa.

Lengo si kubadilisha hukumu ya binadamu na hukumu ya mashine, bali kujenga mifumo ambapo mchanganyiko wa vyote viwili ni bora kuliko yoyote peke yake.

Zana na mbinu katika kitabu hiki cha mwongozo — uwekaji maelezo, ujifunzaji tendaji, RLHF, kujifunza mapendeleo, na mengine yote — ni njia kuelekea lengo hilo. Uwanja unavyobadilika, mbinu maalum zitabadilika. Dhamira ya msingi — kujenga mifumo ambayo ni yenye uwezo na imelinganifu kweli na nia ya binadamu — itabaki.

See also: Usimamizi unaoweza kupanuka na mjadala: {cite}`bowman2022measuring`. Usimamizi dhaifu wa Snorkel: {cite}`ratner2017snorkel`. Kwa mustakabali mpana wa ushirikiano kati ya binadamu na AI, angalia {cite}`amershi2019software`.

Orodha ya Marejeo

Limen: Binadamu Katikati ya Kila Kitu

:::{admonition} Kumbuka kuhusu sura hii :class: important Sura hii ni **insha ya muundo wa nadharia**, si utafiti wa kimajaribio au mchango wa ukaguzi wa rika. Inaelezea usanifu wa mfumo uliofikiriwa — Limen, OS ya kompyuta ya kwanza ya sauti inayotegemea AI — kama mfano wa kazi wa jinsi kanuni za HITL kutoka sura zilizotangulia zinavyoweza kuchanganywa kuwa jumla thabiti. Madai hapa ni hoja za muundo, si matokeo ya majaribio. Yanapaswa kusomwa kama sababu ya muundo inayoongozwa, si kama matokeo ya uhandisi yaliyothibitishwa. :::

Kila sura katika kitabu hiki cha mwongozo imeelezea HITL ML kama falsafa ya muundo: seti ya kanuni za kufanya ushiriki wa binadamu katika mifumo ya kujifunza kuwa wa makusudi, wa ufanisi, na wa uaminifu. Sura hii inaelezea jinsi inavyoonekana kutumia falsafa hiyo kama kanuni ya kwanza — si kwa mfumo mmoja, bali kwa mazingira yote ya uendeshaji.

Limen ni mfumo wa uendeshaji wa kompyuta wa kwanza wa sauti unaotegemea AI, uliojengwa kwa msingi wa kwamba binadamu yuko daima katikati ya mzunguko, si kama kikwazo cha kuboreshwa mbali, bali kama kanuni inayopanga ambayo kila mfumo mdogo unaoundwa. Jina linachaguliwa kwa makusudi: *limen* ni neno la Kilatini kwa kizingiti. Katika saikolojia ya mtazamo, limen ni mpaka kati ya kinachohisiwa na kisichohisiwa. Kwa mfumo wa uendeshaji, limen ni mpaka kati ya nia ya binadamu na kitendo cha mashine.

Usanifu ulioelezwa hapa si wa umiliki. Ni seti ya maamuzi ya muundo, kila mmoja ukifuata kwa asili kutoka kwa kanuni za HITL zilizoendelezwa katika sura zilizotangulia. Lengo si kuandika bidhaa bali kuonyesha jinsi kanuni hizo zinavyochanganywa — jinsi zinavyoimarisha kila mmoja zinapotumiwa kwa uthabiti, na aina gani za mifumo inazowezekana binadamu asipokuwa kama mawazo ya baadaye.

Tatizo na Muundo wa Kawaida wa OS

Mfumo wa kawaida wa uendeshaji haujaundwa kwa wanadamu. Umeundwa kwa programu. Binadamu hushughulikiwa kupitia safu ya ufupisho — kiolesura cha picha, kivinjari cha faili, terminal — kinachokaa juu ya sehemu ya chini iliyojengwa kwa michakato, anwani za kumbukumbu, na maelezo ya faili.

Chaguo hili la muundo lina sababu za kihistoria. Dhana zilizozalisha ilifanywa wakati, kompyuta zilikuwa ghali, binadamu walikuwa nafuu, na kikwazo kilikuwa kukokotoa. Lengo sahihi la uboreshaji lilikuwa mashine.

Dhana hizo hazijalishi tena. Kikwazo, kwa watumiaji wengi katika kazi nyingi, si kukokotoa. Ni makini ya binadamu: gharama ya kubadilisha muktadha, ya kutafuta faili sahihi, ya kuunda swali sahihi, ya kukumbuka kitu kilikuwapi. Mashine ni ya haraka. Binadamu ni ya polepole. Kiolesura kinapaswa kuboresha kwa upande wa binadamu wa mzunguko.

Mifumo ya kawaida ya uendeshaji haifanyi hivi. ImeBoreshwa kwa programu, na kazi ya binadamu ni kuzungumza lugha ya programu. Limen inabadilisha hili. Programu zinazungumza lugha ya binadamu. Binadamu yuko katikati ya mzunguko, na mzunguko umeundwa kuoana na binadamu.

Usanifu kwenye Kizingiti

Usanifu wa Limen umepangwa karibu na kanuni moja: **kila mwingiliano ni tukio**, na kila tukio ni fursa ya binadamu kufundisha, kurekebisha, au kuthibitisha. Mfumo hausubiri vikao vya mafunzo waziwazi. Kujifunza ni kwa kuendelea na kwa mazingira.

Safu ya Tukio: WID

Msingi ni **WID** (mfumo wa Kitambulisho cha Waldiez, uliorekebishwa kwa usanifu wa kwanza wa ndani wa Limen) — mfumo wa kufuatilia tukio unaozingatia uamuzi unaorekodia si tu kilichotokea, bali kilichosababisha, na kilichosababisha kwa mtiririko.

Uandishi wa kawaida unauliza: *nini kilitokea?* WID unauliza: *kwa nini kilitokea, na nini kilifuata?* Kila tukio hubeba uzao wa uamuzi — mnyororo kutoka kitendo cha binadamu kilichosababisha kupitia hali za kati za mfumo hadi matokeo yanayoonekana.

Hii ina umuhimu kwa kujifunza kwa HITL kwa sababu inamaliza **tatizo la ugawaji wa mkopo** katika kiwango cha mwingiliano. Mtumiaji anapoirekebisha tabia ya mfumo, WID inaweza kutambua si tu tokeo la moja kwa moja lililokuwa baya, bali mnyororo wa maamuzi yaliyolizalisha. Marekebisho yanaweza kutumiwa katika kiwango sahihi cha ufupisho: tokeo, sheria ya uamuzi, au ishara ya juu.

Hii ni sawa ya kiwango cha mfumo wa uendeshaji cha kilichoelezwa katika Sura ya 6 kwa RLHF: uwezo wa kufuatilia ishara ya zawadi nyuma kupitia mfululizo wa maamuzi. WID inatoa ufuatiliaji huo kwa asili, kwa kila mwingiliano, bila kuhitaji mtumiaji aelewe.

:::{admonition} Ufuatiliaji wa Tukio la Uamuzi kama Miundombinu ya HITL :class: note Muundo wa WID unaakisi kanuni pana: miundombinu ya HITL inapaswa kuifanya iwe rahisi kuuliza "kwa nini mfumo ulifanya hivyo?" — si tu "ulifanya nini?" Bila ufuatiliaji wa uamuzi, marekebisho yanarekebisha dalili. Nayo, yanaweza kurekebisha sababu. Tofauti kati ya kiraka na somo. :::

Safu ya Mtazamo: Kwanza ya Sauti

Ingizo kuu la Limen ni sauti, inayosindiikwa kwa ndani kwa kutumia mfumo wa inferensi wa Whisper ONNX. Sababu za chaguo hili zinastahili kuorodheshwa waziwazi:

Sauti ndiyo njia ya kawaida zaidi ya kutoa habari kwa binadamu wengi. Haihitaji mafunzo, wepesi wa kimwili zaidi ya usemi wa kawaida, au ujuzi wa mpango wa ndani wa mfumo. Mtumiaji ambaye hawezi kupata faili katika muundo wa saraka anaweza kuelezea wanachotafuta.

Usindikaji wa ndani hulinda faragha. Data ya sauti haiacha kifaa. Hii ina umuhimu wa kimaadili — sauti ni data ya biometriki, na ukusanyaji wake kwa kiwango kikubwa na watoa huduma wa wingu ni madhara yaliyoandikwa — na kwa vitendo: uendeshaji nje ya mtandao inamaanisha mfumo unabaki wa kufanya kazi bila muunganiko wa mtandao.

Sauti huunda mzunguko wa asili wa maoni. Mfumo unapojibu, majibu ya mtumiaji — kuendelea kuzungumza, kubadilisha maandishi, kusema "hapana, hiyo si sahihi" — ni yenyewe

ishara. Limen inazitia majibu haya kama maoni ya HITL: ushahidi kuhusu kama tafsiri ya mfumo ya neno lililotangulia ilikuwa sahihi.

Mnyororo wa kuanguka una umuhimu sawa na hali kuu. Sauti inaposhindwa — katika mazingira yenye kelele, kwa mtumiaji mwenye ulemavu wa usemi, kwa ingizo linalofaidika na usahihi — Limen hushuka kwa neema hadi kiolesura cha kibodi na kisha hadi kiolesura cha maandishi yaliyopangwa. Mtihani wa Bibi (angalia Sura ya 5) si kuzingatiwa kwa ufikiaji baadaye; ni kikwazo cha kiusanifu cha daraja la kwanza.

Safu ya Akili: Upelekaji wa LLM Wengi

Limen haitegemei mfano mmoja wa lugha. Inapeleka maombi kupitia mti wa uamuzi ulioundwa kulingana na aina ya kazi, muda wa kusubiri unaohitajika, mahitaji ya faragha, na imani:

1. **Mfano mdogo wa ndani** (kwanza daima): wa haraka, wa faragha, hushughulikia kazi za kawaida — "fungua faili nililikuwa nikihariri jana," "weka kengele," "hali ya hewa ni nini"
2. **Mfano mkubwa wa ndani** (imani ya mfano mdogo inapokuwa ndogo): ya polepole lakini yenye uwezo zaidi; hushughulikia ufikiriaji wa muundo, uzalishaji wa msimbo, uchimbaji mgumu
3. **Mfano wa mbali** (ndani inaposhindwa na mtumiaji ametoa ruhusa): mlango wa kutoka; unashughulikiwa kwa uwazi na arifa wazi kwa mtumiaji

Muundo huu si mpya — ni sawa wakati wa inferensi ya mkakati wa maswali wa ujifunzaji tendaji ulioelezwa katika Sura ya 4. Katika kila hatua, mfumo unauliza: je, mfano wangu wa sasa unatosha kujibu swali hili kwa imani inayokubalika? Kama hapana, panda. Kupanda ni gharama (muda wa kusubiri, faragha, kukokotoa); inabebwa tu inapohitajika.

Binadamu yuko katikati ya mzunguko kwenye mpaka wa kupanda. Mtumiaji aliyesanidi Limen isipande kamwe hadi mifano ya mbali amefanya uamuzi wa HITL — mmoja ambao mfumo unaheshimu na unaorekodia. Mtumiaji anayoidhinisha swali la mbali kisha kusema "usiulize tena kwa aina hii ya ombi" ametoa upendeleo unaosasisha sera ya upelekaji.

Muundo wa Mwingiliano

Haraka

Limen imeundwa kwa haraka kwa maana ambayo Sura ya 5 inabainisha: mtumiaji anahisi athari ya maoni yake. Mtumiaji anapoirekebisha tokeo la mfumo, urekebisho unatumika mara moja na kwa kuonekana. Mfano hauendi mbali na kufunza kwa dakika ishirini. Unasasishwa katika kikao cha sasa hivi.

Hii inahitaji kutumia usanifu wa mifano unaosaidia usasishaji wa ufanisi wa mtandaoni — viambatisho, kurekebisha kiambishi, na uzalishaji ulioongezewa ugunduzi badala ya kurekebisha fini kamili. Maelewano yanabainishwa waziwazi: masasisho ya mtandaoni yana kelele zaidi kuliko mafunzo ya vifurushi. Limen inakubali maelewano haya kwa sababu haraka ndiyo mahitaji ya kwanza: binadamu anaweza daima kuthibitisha, kukataa, au kukuza sasishi.

Ufahamikaji

Mada inayorudiwa katika fasihi ya IML ni **mahitaji ya ufahamikaji**: binadamu wanaweza tu kuongoza mfano wanaoufahamu, angalau kwa takriban. Limen inaonyesha hili katika ki-

olesura: mfumo unapofanya uamuzi, unaeleza, kwa ufupi, kwa nini. Si ufuatiliaji wote wa mawazo — hiyo ingemzidishia watumiaji wengi — bali muhtasari wa lugha asilia wa sababu muhimu: "Ninafungua mradi uliofanya kazi nao hivi karibuni zaidi — je, hiyo ni sahihi?"

Maelezo haya pia ni swali. Yanaalikia urekebisho. Yanafanya inferensi ya mfano kuonekana ili mtumiaji aweze kuielekeza tena ikishindwa. Maelezo hayazalishwi kwa sababu za urembo; ni miundombinu ya HITL ya kufanya kazi.

Uthabiti na Kutelekezea

Tatizo linaloibuka katika mfumo wowote wa mwingiliano wa muda mrefu ni **kutelekezea kwa tabia**: tabia ya mfumo kwa wakati $T+n$ ni tofauti kidogo na tabia yake kwa wakati T, kwa njia ambazo mtumiaji wala mfumo havikuchagua waziwazi. Marekebisho yanakusanyika. Hali za mipaka zinaongezeka. Mfano uliolinganiwa na mapendeleo ya mtumiaji mwezi uliopita unaweza kutokulinganiwa tena leo.

Limen inashughulikia hili kupitia ukaguzi wa uthabiti wa mara kwa mara — sawa la mfumo wa uendeshaji wa mbinu ya kuwasilisha tena iliyoelezwa katika Sura ya 13. Mfumo unaweka wazi maamuzi ya kihistoria kwa mtumiaji: "Miaka michache iliyopita, uliniiomba nifanye X. Je, hiyo bado ni unalotaka?" Ukaguzi huu unatoa kazi mbili: wanashika kutelekezea, na wanaakumbusha mtumiaji kuhusu mapendeleo ambayo wanaweza kusahau kubainisha.

Limen kama Mfumo wa HITL

Ukiangalia usanifu wa Limen kupitia lenzi ya kitabu hiki, maamuzi ya muundo yanaoanishwa moja kwa moja na dhana zilizoendelezwa katika kila sehemu.

Sehemu ya I (Misingi): Limen inatibu kila mwingiliano kama tukio la mwingiliano kati ya binadamu na mashine. Hakuna "hali ya si-HITL" — mfumo unajifunza daima, unagawanya mkopo daima, unangoja binadamu ashiriki daima.

Sehemu ya II (Mbinu za Msingi): Ujifunzaji tendaji unaonyeshwa kama mnyororo wa kupanda unaotegemea imani. ML ya mwingiliano inaonyeshwa katika mzunguko wa kusasisha wa wakati wa sasa hivi. Uwekaji maelezo ni wa picha: kila urekebisho wa mtumiaji ni lebo.

Sehemu ya III (Kujifunza kutoka kwa Maoni ya Binadamu): Kujifunza mapendeleo kulikoelezwa katika Sura ya 8 kunaonekana katika masasisho ya sera ya upelekaji. Mtumiaji anapoupendelea jibu la mfano wa ndani kuliko la mbali, upendeleo huo unarekodiwna unajumlisha. RLHF katika OS ya kibinafsi inamaanisha mfano wa zawadi ni wa kibinafsi, wa binafsi, na unasasishwa kwa kuendelea.

Sehemu ya IV (Matumizi): Limen ni mazingira ya jumla, lakini muundo wake unaonekana zaidi katika maeneo ambapo hukumu ya binadamu haiwezi kubadilishwa na gharama ya kosa ni kubwa — uandishi wa hati, utangulizi wa kazi, kazi ya ubunifu.

Sehemu ya V (Mifumo na Mazoezi): WID ni jukwaa la uwekaji maelezo la Limen. Haionekani kwa mtumiaji katika uendeshaji wa kawaida, inayoonekana inapohitajika kwa utatuzi wa hitilafu au uwazi. Njia za udhibiti wa ubora (ukaguzi wa uthabiti, viwango vya imani, kumbukumbu za kupanda) vinakopwa moja kwa moja kutoka fasihi ya ushirikiano wa umma.

Sehemu ya VI (Maadili): Muundo wa kwanza wa ndani, unaohifadhi faragha ni chaguo la kimaadili, si la kiufundi tu. Data ya binadamu haitoki kwenye kifaa chao bila idhini yao waziwazi. Mfano unaojifunza kutoka kwa tabia ya mtumiaji ni mali ya mtumiaji huyo.

Hoja ya Kina

Limen si ushirikishaji wa bidhaa. Ni hoja kwa ujenzi.

Hoja ni hii: ukichukua kanuni za HITL ML kwa uzito — ukiamini kwamba maoni ya binadamu ni ishara ya kueleweka badala ya gharama ya kupunguza, kwamba binadamu yuko daima katikati ya mzunguko hata wabunifu wanapodai vinginevyo, kwamba ulinganifu ni mchakato unaoendelea badala ya tukio moja — basi unamaliza kujenga kitu kinachofanana na Limen.

Si lazima Limen hasa. Seti maalum ya teknolojia (Tauri, Rust, Babylon.js, Whisper ONNX) ni chaguo moja kati ya mengi. Lakini usanifu — ufuatiliaji wa tukio la uamuzi, usindikaji wa kwanza wa ndani, kuanguka kwa neema, kujifunza mapendeleo kwa kuendelea, uwazi kama kipengele cha daraja la kwanza — unafuata kutoka kwa kanuni.

Uwanja wa HITL ML umetumia nguvu kubwa kuonyesha jinsi ya kuweka binadamu katikati ya mzunguko wa mifano maalum na kazi maalum. Swali lijalo ni kama tunaweza kubuni *mazingira* yote karibu na kanuni hizo: mazingira ambapo binadamu yuko daima katikati, mashine yuko daima mjifunzaji, na mzunguko uko daima wazi.

Limen ni jibu moja kwa swali hilo.

Kizingiti si kitu unachokivuka na kukiacha nyuma. Ndiyo unapoishi.

See also: Kanuni za IML zinazosaidia muundo wa mwingiliano wa Limen zimeendelezwa katika Sura ya 5. Mbinu ya kujifunza mapendeleo nyuma ya sera ya upelekaji imerasimishwa katika Sura ya 8. Mfano wa uamuzi wa WID unavyorejelea fasihi ya mgawaji tukio iliyochunguzwa katika Sura ya 14. Mtihani wa Bibi, ulioanzishwa katika Sura ya 5, ni kikwazo kuu cha muundo wa kiolesura cha Limen.

Kuhusu Kuondoka

Wakati fulani nilikuwa nimeandikishwa katika programu ya Uzamivu. Utafiti ulikuwa kuhusu ujifunzaji wa mashine. Taasisi ilikuwa ya kweli. Nia ilikuwa ya dhati.

Kisha nikaacha.

Si kwa sababu mada iliacha kuwa muhimu — ni muhimu zaidi sasa kuliko nilipoanzia. Si kwa sababu kazi ilikuwa ngumu sana — kitabu hiki cha mwongozo ni kigumu zaidi, kwa njia yake yenyewe, kuliko tasnifu ingekuwa. Bali kwa sababu mahali fulani kati ya mapitio ya fasihi na marekebisho ya tatu ya makala ambayo ingesomwa na watu kumi na mmoja, nilipoteza uzi wa kwa nini yoyote ya hayo yalikuwa na thamani ya kufanywa.

Mfumo wa Uzamivu ni mzunguko. Unaingia ukiwa binadamu mwenye maswali. Mzunguko unakufundisha kubadilisha maswali hayo kuwa makala, na makala kuwa nukuu, na nukuu kuwa mwonekano wa maendeleo. Wakati wowote mzunguko hauulizi kama pato ni la manufaa kwa mtu yeyote nje ya mzunguko. Swali hilo ni, kwa istilahi ya kiufundi, nje ya wigo.

Mimi si mtu wa kwanza kukiona hili. Sitakuwa wa mwisho. Hii si ukosoaji — ni maelezo. Mzunguko unazalisha mambo ya kweli: mbinu madhubuti, maarifa yaliyokusanywa, watafiti waliofunzwa. Sijuta wakati nilioutumia ndani yake. Lakini hatimaye nilibaini kwamba nilikuwa ndani yake.

Kuondoka haikuwa uamuzi wa kushangaza. Ilikuwa utambuzi wa polepole kwamba kitu nilichotaka kweli kujenga hakikuhitaji ruhusa kutoka kwa kamati. Kwamba watu nilitaka kuwafikia — wataalamu, wanafunzi, wahandisi wanaofanya maamuzi ya kweli kuhusu mifumo ya kweli — hawakusubiri tasnifu iliyothibitishwa rasmi. Kwamba jambo la uaminifu zaidi niliweza kufanya na nilichojua lilikuwa kuliandika katika mfumo ambao mtu angeweza kweli kutumia.

Hivyo nilifanya hivyo.

Kitabu hiki cha mwongozo si tasnifu ya Uzamivu. Hakina uhusiano na taasisi yoyote, hakuna utambuzi wa ufadhili, hakuna idhini ya bodi ya maadili, hakuna uchunguzi. Haitahesabu kwenye kipimo chochote ambacho taaluma ya kitaaluma inatumia kupima uzalishaji wa maarifa.

Pia ni — na nasema hili bila unyenyekevu wa uongo, kwa sababu unyenyekevu wa uongo ungekuwa udhalimu wake wenyewe — kamili zaidi, ya kisasa zaidi, inayosomeka zaidi, na ya manufaa zaidi kuliko tasnifu ingekuwa.

Mimi ni binadamu katika mzunguko. Nilikuwa katika mzunguko wa programu ya Uzamivu, nilitoka nje yake. Sasa niko katika mzunguko wa kuandika kuhusu mizunguko. Wewe uko katika mzunguko wa kusoma kuhusu hiyo.

Hakuna wetu aliyechagua kuwa katika mizunguko hii kwa uhuru kamili. Lakini tunaweza kuchagua, wakati mwingine, kuwa waaminifu kuhusu wapi tuko, na kwa nini, na kama inaizalisha yoyote inayostahili kuzalishwa.

Kitabu hiki ni jibu langu kwa maswali hayo.

Si barua ya kujiuzulu. Kujiuzulu kunamaanisha kazi, na kazi kunamaanisha kwamba mtu mwingine aliteua masharti. Hii ni kitu kingine: rekodi ya nilichochagua kufanya na wakati, na hoja ya kimya kwamba chaguo lilikuwa sahihi.

Unaweza kuwa mwamuzi wa hilo. Baada ya yote, wewe ni binadamu katika mzunguko.

— *Mwandishi*