Contents

Döngüde İnsan Makine Öğrenmesi: Yanlış Anlaşılan **1**
Kitabın Yapısı . . . 1

Özgünlük Beyanı **3**

Özet **5**

Teşekkürler **7**

Döngüde İnsan Makine Öğrenmesi Nedir? **9**
Otomasyon Paradoksu . . . 9
Döngüde İnsan Makine Öğrenmesini Tanımlamak . . . 9
Kısa Bir Tarih . . . 10
Neden HITL? İnsan Yargısı İçin Gerekçe . . . 11
Geri Bildirim Döngüsü . . . 11
HITL'nin Olmadığı Şeyler . . . 12
İnsan Geri Bildiriminin Ekonomisi . . . 12
El Kitabına Genel Bakış . . . 13

İnsan–Makine Etkileşiminin Bir Taksonomisi **15**
Otomasyon Düzeyleri . . . 15
Etkin ve Pasif İnsan Katılımı . . . 16
Tekil ve Çoklu Açıklayıcılar . . . 16
Birleşik Bir Çerçeve . . . 17

Veri Açıklaması ve Etiketleme **19**
Açıklama Türleri . . . 19
Açıklama Kılavuzları . . . 20
Açıklama Kalitesini Ölçme: Açıklayıcılar Arası Anlaşma . . . 20
Anlaşmazlıkların Ele Alınması . . . 22
Etiket Gürültüsü ve Etkileri . . . 23
Açıklama Maliyeti ve Verimi . . . 24

Aktif Öğrenme **25**
Aktif Öğrenme Kurulumu . . . 25
Kuramsal Temeller . . . 25
Sorgu Stratejileri . . . 26
Derin Modeller için Belirsizlik Tahmini . . . 27
Tam Bir Aktif Öğrenme Döngüsü . . . 29
Soğuk Başlangıç Problemi . . . 30
Toplu Modda Aktif Öğrenme . . . 31

Durdurma Ölçütleri . . . 31
Aktif Öğrenmenin İşe Yaradığı (ve Yaramadığı) Durumlar . . . 31

Etkileşimli Makine Öğrenmesi **33**
Etkileşimli Makine Öğrenmesinin İlkeleri . . . 33
Aktif Öğrenme ile Karşılaştırma . . . 33
Karma Girişim Etkileşimi . . . 34
IML'deki İnsan Faktörleri . . . 34
Pratikte IML Geri Bildirim Türleri . . . 35
Vaka Çalışması: Google Teachable Machine . . . 35
Basit Bir IML Döngüsünün Uygulanması . . . 35
Büyükanne Testi . . . 37
IML ve Temel Modeller . . . 38

İnsan Geri Bildiriminden Pekiştirmeli Öğrenme **39**
Hizalama Problemi . . . 39
RLHF Hattı . . . 39
Basitleştirilmiş Bir RLHF Gösterimi . . . 41
RLHF'deki Güçlükler . . . 42
Anayasal Yapay Zeka (RLAIF) . . . 43

Gösterilerden Öğrenme **45**
Davranışsal Klonlama . . . 45
Ters Pekiştirmeli Öğrenme . . . 46
GAIL: Üretici Çekişmeli Taklit Öğrenmesi . . . 47
Doğal Dil İşlemede Davranışsal Klonlama: Pratik Bir Örnek . . . 47
Taklit Öğrenmesi Yöntemlerinin Karşılaştırması . . . 48
Uygulamalar . . . 49

Karşılaştırma ve Sıralamalardan Öğrenme **51**
Karşılaştırmalar Neden Derecelendirmelerden Daha İyidir? . . . 51
Bradley-Terry Modeli . . . 51
Thurstone Modeli . . . 53
Sıralama Birleştirme . . . 54
Düello Haydutları . . . 54
Dil Modelleri için Tercih Öğrenmesi . . . 54
Yüksek Kaliteli Tercih Verisi Toplamak . . . 55

Doğal Dil İşlemede Döngüde İnsan **57**
Doğal Dil İşleme Açıklamasındaki Kurucu Problem . . . 57
Metin Sınıflandırması Açıklaması . . . 58
Adlandırılmış Varlık Tanıma . . . 58
İlişki Çıkarımı ve Anlamsal Açıklama . . . 59
Makine Çevirisi Sonrası Düzenleme (MCSD) . . . 59
Konuşma Yapay Zekası ve Diyalog Açıklaması . . . 59
Programatik Etiketleme ve Zayıf Denetim . . . 60
Dil Modelleri için RLHF: Açıklama Gerçekliği . . . 61
Açıklama–Model Geri Bildirim Döngüsü . . . 62
Üretici Doğal Dil İşleme Modellerinin Değerlendirilmesi . . . 62

Bilgisayarlı Görüde Döngüde İnsan **65**
Açıklama Seçimleri Model Önyargılarına Nasıl Dönüşür? . . . 65
Görüntü Sınıflandırması Açıklaması . . . 66

Nesne Algılama: Sınır Kutusu Açıklaması . . . 66
Anlamsal ve Örnek Segmentasyonu . . . 68
Bilgisayarlı Görü için Aktif Öğrenme . . . 68
İnsan Rehberliğiyle Yarı Denetimli Öğrenme . . . 69
Video Açıklaması . . . 70

Sağlık ve Bilimde Döngüde İnsan **71**
Tıbbi Görüntü Analizi . . . 71
Klinik Doğal Dil İşleme Açıklaması . . . 72
Düzenleyici Değerlendirmeler . . . 73
Bilimsel Veri Açıklaması . . . 73
Uzman Açıklayıcıları Yönetmek . . . 74
Tıbbi Görüntüleme için Bir HITL Aktif Öğrenme Hattı . . . 75

Açıklama Platformları ve Araçlar **79**
Açıklama Platformu Manzarası . . . 79
Açıklama Platformu Özellik Karşılaştırması . . . 80
Kod Olarak Açıklama . . . 80

Kitle Kaynaklı Çalışma ve Kalite Kontrolü **83**
Kitle Kaynaklı Platformlar . . . 83
Kitle Kaynaklı Çalışma için Görev Tasarımı . . . 83
Etiket Birleştirme için İstatistiksel Modeller . . . 85
Yedeklilik ve Birleştirme Stratejisi . . . 87

Değerlendirme ve Ölçütler **89**
Model Merkezli Ölçütler . . . 89
Açıklama Verimliliği Ölçütleri . . . 90
İnsan Değerlendirmesi . . . 91
İnsan Niyetiyle Hizalamayı Ölçmek . . . 92
Dağıtılmış Sistemlerde A/B Testi . . . 93

Adalet, Önyargı ve Etik **95**
HITL Sistemlerindeki Önyargı Kaynakları . . . 95
HITL Sistemlerinde Adalet . . . 96
Açıklayıcı Refahı . . . 96
Açıklamada Gizlilik . . . 97
Saldırgan Açıklama ve Veri Zehirleme . . . 98
Kurumsal Etik . . . 98

Gelecek Yönelimler **101**
Temel Modeller ve Açıklamanın Değişen Rolü . . . 101
Açıklayıcı Olarak Büyük Dil Modelleri . . . 101
Ölçekte Zayıf Denetim . . . 102
İnsan Denetimiyle Sürekli Öğrenme . . . 102
Çok Kipli HITL . . . 103
Ölçeklenebilir Denetim . . . 103
Değişen İş Bölümü . . . 104
Açık Araştırma Sorunları . . . 104

Kaynakça **107**

Vaka Çalışması: Limen — Her Şeyin Döngüsünde Bir İnsan **109**

Geleneksel İşletim Sistemi Tasarımıyla Sorun 109
Eşiğin Mimarisi 110
Etkileşim Tasarımı 111
HITL Sistemi Olarak Limen 112
Daha Derin Nokta 112

Ayrılış Üzerine **115**

Döngüde İnsan Makine Öğrenmesi: Yanlış Anlaşılan

Lazaros Toumanidis

Bu el kitabı, modern yapay zekanın en kritik — ve en yanlış anlaşılan — alanlarından birini incelemektedir: insanın öğrenme döngüsüne entegrasyonu. Veri açıklaması ve aktif öğrenmeden, insan geri bildiriminden pekiştirmeli öğrenmeye (RLHF) ve gösterilerden öğrenmeye kadar, yapay zeka modellerinin neredeyse her şeyi üstlendiği görülen bir çağda bile insan yargısı vazgeçilmezliğini korumaktadır.

Bu kitap; öğrenme döngüsünde insanın ne zaman, neden ve nasıl yer alması gerektiğini anlamak isteyen araştırmacılara, mühendislere ve öğrencilere yöneliktir.

:::{admonition} Türkçe baskı :class: note Bu eser Türkçe çevirisidir. Birincil başvuru baskısı İngilizce özgün metindir. Bazı teknik bölümler henüz tamamlanmamış olabilir. :::

Kitabın Yapısı

Bölüm I — Temel Kavramlar — kavramsal çerçeveyi ortaya koyar: döngüde insan makine öğrenmesinin ne anlama geldiğini ve otomasyon düzeylerinin nasıl sınıflandırıldığını ele alır.

Bölüm II — Temel Teknikler — veri açıklaması, aktif öğrenme ve etkileşimli makine öğrenmesini kapsar.

Bölüm III — İnsan Geri Bildiriminden Öğrenme — insan geri bildiriminden pekiştirmeli öğrenmeyi, gösterilerden öğrenmeyi ve karşılaştırmalardan öğrenmeyi kapsar.

Bölüm IV — Uygulamalar — doğal dil işleme, bilgisayarlı görü ve tıbbi sistemlerdeki pratik örnekleri inceler.

Bölüm V — Sistemler ve Pratik — döngüde insan sistemleri için araçları, platformları ve ölçütleri kapsar.

Bölüm VI — Etik ve Ufuklar — adalet, önyargı ve insan–algoritma ilişkilerinin geleceğini ele alır.

Özgünlük Beyanı

Doktora derecesinin gerekliliklerinin kısmen yerine getirilmemesi amacıyla sunulmuştur.

Bu el kitabında sunulan çalışmanın, olmadığı yerler dışında, bana ait olduğunu beyan ederim.

Bu sayfalardaki fikirler şu kişilerin yardımıyla üretilmiştir: makalelerini yayımlayan ve zaman zaman bunları ücretli erişim duvarlarının arkasına koyan araştırmacılar; emeği modelleri mümkün kılan ancak isimleri hiçbir teşekkür bölümünde yer almayan açıklayıcılar; her kod örneğinde kullanılan kütüphaneleri yazan açık kaynak katkıcıları; ve büyük dil modelleri tarafından içine alınıp sıkıştırılan insan uygarlığının birikmiş metinleri — söz konusu modellerin bunların hiçbirinde herhangi bir görüşü bulunmamaktadır.

Hatalar bana aittir. İçgörüler işbirliğinin ürünüdür.

Bu çalışmanın, aksi belirtilmedikçe başka herhangi bir derece veya mesleki yeterlilik, akademik ödül, hibe, kadro davası ya da LinkedIn gönderisi için sunulmadığını teyit ederim.

Ayrıca bu çalışmaya herhangi bir SOTA (Sanatın Durumu) karşılaştırma bölümünün dahil edilmediğini teyit ederim. Okuyucu, önerilen yöntemin 12 kıyaslama üzerinden 9'unda istatistiksel olarak anlamlı iyileştirmeler elde ettiği ($\dagger p < 0{,}05$) 47 yöntemin 12 kıyaslamaya göre sıralandığı bir tablo bulmayacaktır. Bu, böyle bir tablonun oluşturulamayacağından değil, oluşturulmasının konunun özünden uzaklaşacağından kaynaklanmaktadır.

Özü şudur: insan döngüdedir. Her zaman öyle olmuştur. Bu kitap bunun ne anlama geldiğini anlamaya çalışmaktadır.

İmzalayan: Döngüdeki Bir İnsan

Tarih: Bunu ne zaman okuyorsanız

Kurum: Hiçbiri. İşte asıl mesele bu.

Alt başlık üzerine :class: note

Yanlış Anlaşılmış aynı anda hem alana, hem içindeki insanın rolüne, hem de okuyucuya atıfta bulunur. Yalnızca sizi kastettiğini düşünüyorsanız haklı olabilirsiniz. Yalnızca makineleri kastettiğini düşünüyorsanız alt başlığın noktasını ispatlıyorsunuz demektir.

Özet

Döngüde İnsan Makine Öğrenmesi: Yanlış Anlaşılmış

Makine öğrenmesinin hâkim söylemi, insanı geçici bir katılımcı olarak konumlandırır — veri toplama ve model eğitimi sırasında bulunur, ardından otomasyon iyileştikçe giderek dışarı çıkarılır. Bu el kitabı, söz konusu söylemin yanlış olduğunu, her zaman yanlış olduğunu ve bunun *neden* yanlış olduğunu anlamanın bir makine öğrenmesi uygulayıcısının yapabileceği en pratik açıdan yararlı şeylerden biri olduğunu savunmaktadır.

Döngüde İnsan (HITL) Makine Öğrenmesi, öğrenme sistemlerindeki insan katılımını kasıtlı, yapılandırılmış ve sürekli kılan disiplindir. İnsan geri bildirimini en aza indirilmesi gereken bir maliyet olarak ele almak yerine, HITL onu anlaşılması gereken bir sinyal olarak değerlendirir: nereden geldiğini, neyi kodladığını, nasıl verimli bir şekilde toplanacağını ve tasarımcılarının ile kullanıcılarının gerçekten istediği şekilde davranan modellere nasıl sadakatle dahil edileceğini.

Bu el kitabı, alanın altı bölüm üzerinden kapsamlı bir incelemesini sunmaktadır. Bölüm I, temelleri ve insan–makine etkileşiminin bir taksonomisini oluşturur. Bölüm II klasik teknikleri kapsar: veri açıklaması ve etiketleme, aktif öğrenme ve etkileşimli makine öğrenmesi. Bölüm III, hizalamanın modern paradigmalarını ele alır: insan geri bildiriminden pekiştirmeli öğrenme (RLHF), gösterilerden öğrenme ve tercih öğrenmesi. Bölüm IV bu teknikleri doğal dil işleme, bilgisayarlı görü ve sağlık alanlarına uygular. Bölüm V, ölçekli HITL sistemlerini ve altyapısını kapsar: açıklama platformları, kitle kaynaklı kalite kontrolü ve değerlendirme metodolojisi. Bölüm VI ise alanın etiğini inceler ve ileriye bakar.

Her bölüm, resmi tanımları, uygun yerlerde matematiksel işlemleri ve Python'da bağımsız çalıştırılabilir kod örneklerini içermektedir.

El kitabı, makine öğrenmesi sistemleri inşa eden uygulayıcılar, bunları araştıran akademisyenler, bu konuyu öğrenen öğrenciler ve hayatlarını etkileyen kararı veren modeli eğiten veriye kimin etiket koyduğunu hiç merak etmiş olanlar için hazırlanmıştır.

Her durumda cevap şudur: bir insan. Çoğu zaman düşük ücretle. Nadiren tanınarak. Her zaman döngüde.

Anahtar Kelimeler: döngüde insan makine öğrenmesi, aktif öğrenme, veri açıklaması, insan geri bildiriminden pekiştirmeli öğrenme, RLHF, tercih öğrenmesi, kitle kaynaklama, etkileşimli makine öğrenmesi, YZ hizalaması, sorumlu YZ

Konu sınıflandırması: Makine Öğrenmesi · İnsan-Bilgisayar Etkileşimi · Yapay Zekâ · Veri Bilimi

Kelime sayısı: Yeterli.

Teşekkürler

Döngüde insan makine öğrenmesi hakkındaki her kitap, kendi döngüsündeki insanlarla başlamalıdır.

Açıklayıcılar. Bu el kitabı kısmen sizin hakkınızdadır — emeğiniz, yargınız ve isminizin, çalışmanızın mümkün kıldığı modeller hakkındaki hiçbir veri kartında, makale teşekkür bölümünde ya da basın bülteninde yer almaması hakkında. Alan bununla yüzleşmeye başlamaktadır. Gidilecek uzun bir yol var.

Açık kaynak katkıcıları — her kod örneğinde kullanılan kütüphaneleri yazanlar: NumPy topluluğu (2006'dan beri), scikit-learn katkıcıları (2007'den beri), PyTorch ekibi, Hugging Face topluluğu ve hafta sonları ücret ya da takdir olmaksızın hataları düzelten sayısız bakıcı. Bilimsel bilgi işlem bu görünmez emek üzerine inşa edilmiştir.

Araştırmacılar — çalışmalarını açık bir şekilde yayımlayanlar: arXiv ön baskılarında, açık erişimli ortamlarda ve GitHub depolarında — uygulayıcıların kurumsal erişim olmaksızın öğrenmesini mümkün kılanlar. Ve makaleleri dikkatli ve dürüstçe inceleyen araştırmacılar; bu, akademinin kendini ikna ettiği şekilde emek olmayan bir uzman açıklama biçimidir.

Öğretmenler — bilgiyi erişilebilir kılanlar: blog yazarları, öğretici yazarlar, Stack Overflow yanıtlayıcıları, slaytlarını paylaşan konferans sunucuları. Öğrenme izolasyonda gerçekleşmez ve yabancılara şeyler açıklamaya istekli insanlar olmadan da gerçekleşmez.

Eleştirmenler. Veri kümelerinin önyargıları kodladığını, açıklayıcı demografisinin model davranışını şekillendirdiğini, döngüdeki insanların çoğunlukla sistemin en savunmasız katılımcıları olduğunu ortaya koyan araştırmacılar. Bu alan, rahatsız edici sorular sorma konusundaki ısrarınız sayesinde daha iyi durumda.

Bilinen bilinenleri vardır — bildiğimizi bildiğimiz şeyler. Bilinen bilinmeyenleri vardır — bilmediğimizi bildiğimiz şeyler. Bilinmeyen bilinmeyenleri vardır — bilmediğimizi bilmediğimiz şeyler.

Bir de alandaki herkesin bildiği ama makalelere hiç tam anlamıyla giremeyen şeyler vardır.

Bu el kitabı kısmen son kategoriyi ele alma girişimidir.

Bu alana katkıda bulunduysanız ve isminizi burada görmüyorsanız: teşekkür edildiniz. Döngü sizi de içeriyor.

Döngüde İnsan Makine Öğrenmesi Nedir?

> *Deneyimden öğrenebilen bir makine… ama yalnızca ona doğru deneyimleri verirseniz. – Alan Turing'den uyarlanmıştır*

Otomasyon Paradoksu

Her yeni otomasyon dalgası, insan dikkatine yönelik yeni talepler yaratır. Havayolları otopilot sistemlerini tanıttığında pilotlar izleyiciye dönüştü — anlık kontrolden değil, *ne zaman devreye gireceklerini bilmek* gibi daha zorlu görevden sorumlu hâle geldiler. Süpermarketler self-checkout sistemlerini hayata geçirdiğinde, bu sistemlerin geleneksel kasiyerlere kıyasla işlem başına daha fazla insan denetimi gerektirdiği anlaşıldı. Makine öğrenmesi tıp, finans, istihdam ve içerik moderasyonu gibi alanlarda ölçekli kararlar almaya başladığında ise insan yargısına yönelik devasa ve süregelen bir talep ortaya çıktı.

Bu, **otomasyon paradoksunun** ta kendisidir {cite}`bainbridge1983ironies`: otomatik bir sistem ne kadar yetenekli hâle gelirse, hatalarının sonuçları o kadar ağır olur ve dolayısıyla sağlam insan denetiminin gerekliliği de o denli artar. Makine öğrenmesi bu paradoksun dışında değildir.

Döngüde İnsan Makine Öğrenmesi (HITL ML), bu paradoksu ciddiye alan ve onu baştan itibaren sistemlerin tasarımına dahil eden alandır. İnsan katılımını nihayetinde kaldırılacak geçici bir iskele olarak ele almak yerine, HITL ML insan–makine etkileşimini bir *özellik* olarak değerlendirir: modelleri daha doğru, insan değerleriyle daha uyumlu ve daha güvenilir kılabilecek bir sinyal, düzeltme ve yönlendirme kaynağı.

Döngüde İnsan Makine Öğrenmesini Tanımlamak

HITL ML'ye ilişkin tek bir kabul görmüş tanım bulunmamakta olup terim, literatürde birbirine örtüşen birkaç anlamda kullanılmaktadır. Bu el kitabında geniş kapsamlı ancak kesin bir tanım benimsemekteyiz:

:::{admonition} Tanım :class: important

Döngüde İnsan Makine Öğrenmesi, insan geri bildiriminin öğrenme sürecine *kasıtlı, yapılandırılmış ve süregelen* biçimde dahil edildiği herhangi bir makine öğrenmesi sistemini veya metodolojisini ifade eder — yalnızca veri kümesi oluşturma anında değil, eğitim, değerlendirme ve dağıtım süreçleri boyunca.

:::

Bu tanımın üç temel maddesi vardır:

Kasıtlı. HITL, tesadüfi insan etkisini (örneğin eğitim verilerinin başlangıçta insanlar tarafından oluşturulduğu gerçeğini) değil; insan geri bildirimini açıkça talep etmek, dahil etmek ve bundan faydalanmak üzere tasarlanmış sistemleri kapsar.

Yapılandırılmış. Geri bildirim belirli bir biçime sahiptir — bir etiket, bir düzeltme, bir tercih yargısı, bir gösteri — ve öğrenme algoritmasında tanımlanmış bir rolü vardır.

Süregelen. Geri bildirim döngüsü zaman içinde devam eder; sistemin yeni durumlarla karşılaştıkça, hata yaptıkça ve insan rehberliği aldıkça gelişmesine olanak tanır.

Bu tanım, klasik açıklama hatlarını, aktif öğrenmeyi, etkileşimli makine öğrenmesini, RLHF'yi ve taklit öğrenmesini kapsar. Pasif veri toplamayı ve yalnızca çevrimdışı denetimli öğrenmeyi dışarıda bırakır (her ne kadar sınır belirsiz olsa da, Bölüm 2'de ele alınacaktır).

Kısa Bir Tarih

Uzman Sistemler ve Bilgi Mühendisliği (1960'lar–1980'ler)

İlk yapay zeka sistemleri neredeyse tamamen döngüde insandı: bilgi mühendisleri, aylarca alan uzmanlarıyla oturup MYCIN ve DENDRAL gibi uzman sistemlere kuralları özenle kodladı. Her bilgi parçası açıkça bir insan tarafından sağlandı. Makine uygulayıcıydı; insan ise kahindir.

Bu sistemler dar alanlarda şaşırtıcı biçimde iyi çalıştı, ancak kırılgandı — elle hazırlanmış kuralların ötesine genelleyemedi ve bakımı pahalıydı.

İstatistiksel Dönüş (1980'ler–2000'ler)

1980'ler ve 1990'larda istatistiksel makine öğrenmesine geçiş, insan katılımının doğasını değiştirdi. Bilgiyi kural olarak kodlamak yerine insanlar artık *örnekler* sağladı — modellerin kalıpları çıkarsayabilmesi için etiketlenmiş veri kümeleri. İnsanın rolü açıklayıcı olmaya dönüştü: belgeleri etiketlemek, görüntüleri işaretlemek, konuşmaları metne dökmek.

Bu büyük bir ilerleme oldu ancak yeni bir darboğaz yarattı: **etiketli veri pahalıdır**. Araştırmacılar insan etiketleme çabasından en verimli biçimde nasıl yararlanılabileceğini sormaya başladı. Bu soru, 1990'ların başında ilk kez formalize edilen **aktif öğrenme** alanının doğmasına yol açtı {cite}`cohn1994improving`.

Derin Öğrenme Çağı (2010'lar–günümüz)

Derin öğrenme devrimi yeni bir rejim yarattı: veriden son derece karmaşık işlevler öğrenebilen milyarlarca parametreli modeller — ancak orantılı ölçüde büyük etiketli veri kümeleri gerektiriyor. ImageNet (14 milyon etiketli görüntü) ve ardından gelen büyük ölçekli açıklama projeleri, ölçeğin hem gücünü hem de maliyetini gözler önüne serdi.

Aynı zamanda makine öğrenmesinin ölçekli dağıtımı yeni sorunları açığa çıkardı: ortalamada doğru ancak belirli gruplara sistematik biçimde hatalı davranan, gerçekleri güvenle halüsine eden, ölçülebilir vekil hedefler için optimize eden — insan değerlerinden değil — modeller. Bu başarısızlıklar yeni insan katılımı biçimlerini motive etti: yalnızca etiketleme değil, *hizalama* — modellerin insanların gerçekten istediği biçimde davranmasını sağlama projesi.

Bu hizalama odaklı HITL çalışmasının en belirgin ifadesi, InstructGPT {cite}`ouyang2022training` gibi sistemlerin omurgasına dönüşen ve modern dil modellerinin talimat takip yeteneklerini

destekleyen **İnsan Geri Bildiriminden Pekiştirmeli Öğrenme (RLHF)** oldu {cite}`christiano2017deep`.

Neden HITL? İnsan Yargısı İçin Gerekçe

İnsan yargısını makine öğrenmesi sistemlerine dahil etmeye değer kılan ne? Birkaç özellik:

1. Sağduyu ve Dünya Bilgisi

İnsanlar herhangi bir göreve muazzam bir arka plan bilgisiyle gelir. Bir radyolog bir röntgen görüntüsünü etiketlediğinde yıllarca süren eğitimine, anatomi bilgisine ve hastalıkların nasıl göründüğüne ilişkin örtük bilgisine başvurur — bu bilgiyi tam olarak belirtmek ya da yalnızca veriden edinmek son derece güçtür.

2. Anlamsal Temellendirme

Etiketler, insanların ne anlama geldiğini kavramasıyla anlam kazanır. ImageNet'teki "kedi" sınıfı, insanların sezgisel olarak tanıdığı ancak hiçbir biçimsel tanımın tam olarak yakalayamadığı bulanık bir kavrama karşılık gelir. Modeller etiketin uzantısını öğrenir (hangi görüntülerin bununla eşleştiğini) ancak kavramın kendisini öğrenemeyebilir; bu durum, herhangi bir insanın doğru biçimde ele alacağı sınır vakalarda başarısızlıklara yol açar.

3. Değer Hizalaması

İnsanların makine öğrenmesi modellerinin yalnızca veriden türetemeyeceği tercihleri, değerleri ve etik yargıları vardır. Bir metnin "yararlı" mı yoksa "zararlı" mı olduğu salt ampirik bir soru değildir — bireyler ve bağlamlar arasında değişen insan değerlerine bağlıdır. HITL, bu değerlerin makine öğrenmesi sistemlerine aktarılabildiği başlıca mekanizmadır.

4. Uyarlanabilirlik

İnsan yargısı yeniden eğitim gerekmeksizin yeni durumlarla baş edebilir. Tarihsel verilerle eğitilmiş bir model, dünya değiştiğinde feci biçimde başarısız olabilir; bir insan ise yeniliği fark edip uygun biçimde tepki verebilir.

5. Hesap Verebilirlik

Tıp, hukuk ve finans gibi yüksek riskli alanlarda kararların insan varlıklarına hesap vermesi gerekmektedir. HITL sistemleri, insanları makine davranışını anlayabilecek, doğrulayabilecek ve geçersiz kılabilecek bir konumda tutarak bu hesap verebilirliği uygulanabilir hâle getirir.

Geri Bildirim Döngüsü

HITL ML'nin merkezi yapısı, bir model ile bir ya da birden fazla insan arasındaki geri bildirim döngüsüdür:

```
+-----------------------------------------------+
|                                               |
|   Model tahminler / istekler sunar            |
|   ---------------------------------->         |
```

```
|                                  İnsan    |
|   İnsan geri bildirim sağlar     <-------- |
|   ----------------------------------       |
|                                            |
|   Model geri bildirimi dahil ederek        |
|   güncellenir                              |
|                                            |
+--------------------------------------------+
```

Geri bildirimin niteliği, HITL paradigmaları arasında büyük ölçüde farklılaşır:

Geri bildirim türü	Örnek	Birincil paradigma
Sınıf etiketi	"Bu e-posta istenmeyen"	Denetimli öğrenme
Düzeltme	"Varlık ORG olmalı, PER değil"	Aktif / etkileşimli ML
Tercih	"A yanıtı B'den daha iyi"	RLHF / sıralama
Gösteri	Robota bir nesneyi nasıl kavrayacağını gösterme	Taklit öğrenmesi
Doğal dil	"Yanıtlarında daha özlü ol"	Talimat ince ayarı
Örtük sinyal	Kullanıcı tıkladı / tıklamadı	Örtük geri bildirim

---

HITL'nin Olmadığı Şeyler

Tanımımızın dışında kalanları belirtmek önem taşır.

HITL, döngüde insan dağıtımıyla aynı şey değildir (bazen "döngü üzerinde insan" olarak da anılır); bu durumda insanlar otomatik kararları izler ve geçersiz kılabilir, ancak düzeltmeleri eğitime geri beslemez. Bu ayrımı Bölüm 2'de ele alacağız.

HITL tek başına zayıf denetim değildir. Snorkel gibi programatik etiketleme sistemleri, ölçekli gürültülü etiketler üretmek için etiketleme işlevlerini (çoğunlukla insan tarafından yazılan kuralları) kullanır. Bu yapılandırılmış bir insan girdisi biçimidir, ancak geri bildirim HITL'nin genellikle ima ettiği şekilde yinelemeli değildir.

HITL, yalnızca etiketli veri kullanmak değildir. Her denetimli öğrenme modeli insan tarafından etiketlenmiş veri kullanır. HITL, özellikle insan geri bildiriminin öğrenme sürecinin *etkin, yinelemeli* bir parçası olduğu sistemleri ifade eder.

İnsan Geri Bildiriminin Ekonomisi

İnsan geri bildirimi değerlidir ancak maliyetlidir. Tıbbi görüntü açıklaması, uzmanlık alanı ve görev karmaşıklığına bağlı olarak uzman tarafından gerçekleştirildiğinde görüntü başına onlarca ila yüzlerce dolar arasında bir maliyete sahip olabilir {cite}`monarch2021human`. Amazon Mechanical Turk gibi platformlardaki kitle kaynaklı çalışma etiketleri, çok daha düşük kalitede olmak üzere öğe başına 0,01–0,10 ABD doları arasında değişebilir {cite}`hara2018data`. HITL ML'nin temel güçlüğü **her bir insan geri bildirim biriminin değerini en üst düzeye çıkarmaktır**.

Bu durum, el kitabının büyük bölümünde işlenen birleştirici soruya yol açar:

:::{admonition} HITL ML'nin Merkezi Sorusu :class: tip

Sabit bir insan zamanı ve dikkati bütçesi göz önüne alındığında, insanlara ne sorulacağına, ne zaman sorulacağına ve yanıtlarının model eğitimine nasıl dahil edileceğine nasıl karar verilmelidir?

:::

Bu sorunun yanıtı alana, geri bildirim biçimine, açıklama maliyetine, hata riskine ve modelin mevcut durumuna bağlıdır — HITL ML'nin zengin ve hâlâ gelişmekte olan bir disiplin olmasının nedeni de budur.

El Kitabına Genel Bakış

El kitabının geri kalanı şu şekilde yapılandırılmıştır. **Bölüm II**, HITL'nin üç klasik sütununu kapsar: açıklama, aktif öğrenme ve etkileşimli makine öğrenmesi. **Bölüm III**, modern yapay zeka için merkezi hâle gelen geri bildirimden öğrenme paradigmalarını ele alır: RLHF, taklit öğrenmesi ve tercih öğrenmesi. **Bölüm IV**, HITL'yi belirli uygulama alanları perspektifinden inceler. **Bölüm V**, platformlar, kitle kaynaklı çalışma ve değerlendirme üzerine bir uygulayıcı bakışı sunar. **Bölüm VI** ise etik sorunları ele alır ve ileriye bakar.

> **See also:** Alanın uygulayıcı odaklı genel bir değerlendirmesi için bkz. {cite}`monarch2021human`. HITL'nin büyük bölümünün biçimsel işlemini başlatan temel aktif öğrenme makalesi için bkz. {cite}`settles2009active`.

İnsan–Makine Etkileşiminin Bir Taksonomisi

Kesin bir söz dağarcığı, açık düşüncenin ön koşuludur. "Döngüde insan" terimi pratikte gevşek biçimde kullanılır — bazen bir insanın eğitim verisi etiketlediği, bazen bir insanın modelin kararını geçersiz kılabildiği ve bazen de bir insanın gerçek zamanlı olarak öğrenme sürecini etkin biçimde yönlendirdiği anlamında. Bunlar anlamlı ölçüde farklı şeylerdir.

Bu bölüm, makine öğrenmesinde insan–makine etkileşiminin haritasını çıkarmakta ve el kitabının geri kalanında kullanılan kavramsal söz dağarcığını sunmaktadır.

Otomasyon Düzeyleri

En temel ayrım, insanın sistemin karar alma sürecine ne ölçüde etkin biçimde katıldığıdır. Otomasyon teorisinden alınan iyi bilinen bir çerçeve {cite}`sheridan1992telerobotics` on düzey ayırt eder; ancak makine öğrenmesi açısından üç kategori önemli farklılıkları yeterince yansıtır:

Döngüde İnsan (HITL)

İnsan, *öğrenme sürecinde etkin bir katılımcıdır*. Kararlar — ya da en azından sonuçları önemli olan kararlar — kesinleştirilmeden önce insan girdisi gerektirir. Sistem, süregelen insan katılımı olmaksızın işleyemez.

Örnekler: Bir vakayı eğitim verisine eklemeden önce bir klinisyeni sorgulayan aktif öğrenme sistemi. Model güncellemeleri için anında kullanılan örnekleri etiketleyen veri açıklayıcısı. Model çıktılarını karşılaştıran bir RLHF etiketleyicisi.

Döngü Üzerinde İnsan (HOTL)

Sistem özerk biçimde çalışır ancak bir insan onu izler ve müdahale edebilir. İnsan bir *denetçidir*, katılımcı değil. Geri bildirim eğitime geri beslenebilir de beslenemeyebilir de.

Örnekler: Gönderileri otomatik olarak işaretleyen bir içerik moderasyon sistemi; bir insan gözlemci kararların bir bölümünü örnekler ve düzeltir. Uçağı uçuran ancak pilotu anormalliklere karşı uyaran bir otopilot.

Komutada İnsan (HIC)

İnsan tüm kararları verir; sistem *tavsiyeler veya bilgiler* sunar ancak herhangi bir özerkliği yoktur. Bu, makine öğrenmesi dağıtımının en zayıf biçimidir.

Örnekler: Doktora modelin olasılık tahminini gösteren, ancak nihai kararı tamamen hekime bırakan bir tanı destek sistemi.

> **Hangi düzey doğru?** :class: tip
>
> Uygun otomasyon düzeyi, hataların maliyetine, modelin güvenilirliğine, mevcut insanların uzmanlığına ve görevin gecikme kısıtlamalarına bağlıdır. Bu etkenler model olgunlaştıkça değişir — çoğu sistem HITL olarak başlar ve güven arttıkça HOTL'a doğru ilerler.

```
Ham veri --> Ön işleme --> Özellikler --> Eğitim --> Değerlendirme --> Dağıtım
    ^              ^                          ^              ^               ^
    |              |                          |              |               |
 Toplama      Açıklama                   Aktif           Test          İzleme
 geri bildirimi & etiketleme            öğrenme        geri bildirimi & düzeltme
```

Aşama	İnsan rolü	Bölüm
Toplama	Toplanacak veriyi belirleme; örnekleme stratejisi	3, 4
Açıklama	Etiket, yapı, meta veri atama	3, 13
Eğitim	Aktif öğrenme sorguları; çevrimiçi geri bildirim	4, 5, 6
Değerlendirme	Model çıktılarının insan tarafından değerlendirilmesi	14
Dağıtım	İzleme, istisna yönetimi, düzeltmeler	12, 14

Etkin ve Pasif İnsan Katılımı

Etkin HITL'de sistem, insana sunacağı veri noktalarını stratejik biçimde seçer ve sorular sorar. *Pasif* HITL'de insan, rastgele gelen veriler üzerinde geri bildirim sağlar (örneğin sıralı olarak atanan veri etiketleme grupları).

Etkin katılım daha verimlidir; çünkü geri bildirim, modeli en çok iyileştirecek yerlere yönlendirilir. Pasif katılım uygulaması ve yönetimi daha kolaydır.

İlgili bir ayrım da **toplu** ile **çevrimiçi** geri bildirim arasındadır:

- **Toplu:** İnsanlar büyük bir örnek havuzunu etiketler; model yeniden eğitilir. Tekrarlanır.
- **Çevrimiçi (akışlı):** İnsan geri bildirimi sürekli gelir; model artımlı biçimde güncellenir.

Toplu iş akışları sektörde yaygın normdur (ardından eğitim çalıştırması gelen açıklama projeleri). Çevrimiçi iş akışları, etkileşimli sistemler ve pekiştirmeli öğrenme ortamları için daha doğaldır.

Tekil ve Çoklu Açıklayıcılar

HITL'nin büyük bölümündeki biçimsel sunumlar, tekil ve tutarlı bir açıklayıcı varsayar. Pratikte açıklama birçok kişiyi kapsar ve yargıları farklılaşır.

Birleştirme, birden fazla açıklamayı genellikle çoğunluk oyu veya istatistiksel bir model aracılığıyla tek bir etikette toplar (Bölüm 13).

Sinyal olarak anlaşmazlık — bazı araştırmacılar, açıklayıcı anlaşmazlığının tek bir "altın" etikette yoğunlaşmaması gereken değerli bilgi olduğunu savunmaktadır. Örneğin doğal dil

işlemede perspektivist yaklaşımlar, gerçek veri belirsizliğini yansıtan yumuşak etiketler olarak birden fazla açıklamayı korur {cite}`uma2021learning`.

Birleşik Bir Çerçeve

Herhangi bir HITL yapılandırmasını beş öğeli bir demet ile temsil edebiliriz:

$$\text{HITL yapılandırması} = (\text{düzey}, \text{kiplik}, \text{aşama}, \text{sıklık}, \text{açıklayıcılar})$$

burada:

- **düzey** $\in$ {HITL, HOTL, HIC}
- **kiplik** $\in$ {etiket, düzeltme, gösteri, tercih, doğal dil, örtük}
- **aşama** $\in$ {toplama, açıklama, eğitim, değerlendirme, dağıtım}
- **sıklık** $\in$ {toplu, çevrimiçi}
- **açıklayıcılar** $\in \mathbb{N}^+$ (öğe başına açıklayıcı sayısı)

Bu taksonomi, farklı HITL sistemlerini aynı eksenler üzerinde karşılaştırmamıza ve aralarındaki değiş tokuşlar hakkında akıl yürütmemize olanak tanır. El kitabının geri kalanı, bu uzayın belirli hücrelerini derinlemesine inceleyecektir.

> **See also:** Açıklama kararlarının aşağı akış model davranışını nasıl etkilediğine dair ampirik bir çalışma için bkz. {cite}`bender2021stochastic`. Etkileşimli makine öğrenmesi sistemlerinin araştırması için bkz. {cite}`amershi2014power`.

Veri Açıklaması ve Etiketleme

Veri açıklaması, makine öğrenmesindeki insan katılımının en yaygın biçimidir. Bir model öğrenmeye başlamadan önce birinin doğru yanıtların ne olduğunu söylemesi gerekir — bu biri çoğunlukla bir insandır. Bu bölüm, açıklamanın teorisini ve pratiğini kapsar: açıklamayı güçleştiren nedir, açıklama görevleri nasıl tasarlanır, kalite nasıl ölçülür ve anlaşmazlıklar nasıl ele alınır.

Açıklama Türleri

Açıklama görevleri yapıları, güçlükleri ve maliyetleri bakımından büyük ölçüde farklılaşır. Başlıca türler şunlardır:

Sınıflandırma

Açıklayıcı her örneği önceden tanımlanmış K kategoriden birine atar. Bu, bilişsel açıdan en basit açıklama görevidir; ancak iyi bir kategori şeması (*taksonomi*) tasarlamak şaşırtıcı ölçüde güç olabilir.

İkili sınıflandırma (bu görüntü bir kedi mi?) en basit durumdur. **Çok sınıflı sınıflandırma** (bu hayvan hangi türe ait?) açıklayıcının listeden tek seçenek yapmasını gerektirir. **Çok etiketli** açıklama (bu makale hangi konuları kapsar?) aynı anda birden fazla etiket atamasına olanak tanır.

Dizi Etiketleme

Bir dizideki her belirteç bir etiket alır. Adlandırılmış Varlık Tanıma (NER) klasik örnektir — açıklayıcılar metin parçalarını KİŞİ, KURULUŞ, KONUM vb. olarak işaretler. Açıklama genellikle BIO (Başlangıç–İçinde–Dışında) veya BIOES etiketleme şeması kullanılarak gerçekleştirilir:

```
B-ORG    O          B-ORG    O    O    O
```

Parça ve İlişki Açıklaması

Tek tek belirteçleri etiketlemenin ötesinde açıklayıcıların şunları yapması gerekebilir: - Parçaları (çok belirteçli ifadeler) belirleyip türleri atamak - Parçalar arasındaki *ilişkileri* işaretlemek ("Apple" EDİNDİ "Shazam") - Eş-atıf zincirlerini açıklamak (aynı varlığın tüm anılması)

Bu görevler bilişsel açıdan zorlu olup açıklayıcılar arası anlaşma düzeyi daha düşüktür.

Sınır Kutuları ve Nesne Algılama

Açıklayıcılar görüntülerdeki nesnelerin etrafına dikdörtgenler çizer ve her kutuya bir kategori etiketi atar. Konumlandırma hassasiyeti önem taşır: çok küçük bir kutu bağlamı kaçırır; çok büyük bir kutu arka planı içerir. Modern açıklama araçları, kalite sorunlarını işaretlemek için referans açıklamalarla kesişim/birleşim (IoU) değerini hesaplar.

Segmentasyon

Piksel düzeyinde açıklama: her piksel bir sınıfa (anlamsal segmentasyon) ya da belirli bir nesne örneğine (örnek segmentasyonu) atanır. Yüksek kaliteli segmentasyon en pahalı açıklama türlerinden biridir; karmaşık sahnelerde alana ve araç desteğine bağlı olarak görüntü başına maliyetler onlardan yüz doların üzerine çıkabilir.

Transkripsiyon ve Çeviri

Ses □ metin (ASR eğitim verisi), el yazısı □ metin (OCR verisi) veya kaynak dil □ hedef dil (MT verisi). Bu görevler dilbilimsel uzmanlık gerektirir ve eğitimsiz açıklayıcılar tarafından güvenilir biçimde yapılamaz.

Açıklama Kılavuzları

Açıklama kalitesinin en belirleyici etkeni, açıklayıcıların uyduğu yazılı talimatlar olan **açıklama kılavuzlarının** kalitesidir.

İyi kılavuzlar: - Görev hedefini belirtir ve etiketin *neden* önem taşıdığını açıklar - Olumlu ve olumsuz örneklerle birlikte her kategori için net bir tanım sunar - Yaygın sınır durumlarını ve güç vakaları açıkça ele alır - Belirsizlik durumunda ne yapılacağını belirtir (örneğin "atla" işaretlemek mi zorunlu seçim mi) - Eksiksiz açıklama örnekleri içerir

Kötü kılavuzlar, açıklayıcıların sınır vakalar için "sağduyu kullanmasına" güvenir — bu durum, model kalitesini düşüren ve açıklayıcılar arası anlaşmazlığı artıran tutarsız kararlara yol açar.

> **Kılavuz geliştirme yinelemeli bir süreçtir** :class: note
>
> Mükemmel kılavuzları baştan yazmayı beklemeyin. Küçük çaplı bir pilot açıklama turu yürütün, anlaşmazlıkları analiz edin ve kılavuzları güncelleyin. Tekrarlayın. İyi geliştirilmiş kılavuzlar genellikle kararlılık kazanmadan önce 3–5 revizyon döngüsünden geçer.

Açıklama Kalitesini Ölçme: Açıklayıcılar Arası Anlaşma

Birden fazla açıklayıcı aynı veriyi etiketlediğinde anlaşmaları ölçülebilir. Yüksek anlaşma, görevin iyi tanımlandığını ve açıklayıcıların bunu anladığını gösterir. Düşük anlaşma, görevde, kılavuzlarda veya verinin kendisinde belirsizliğe işaret eder.

Cohen'in Kappa Katsayısı

Veriyi K kategoriye etiketleyen iki açıklayıcı için **Cohen'in kappa katsayısı** {cite}`cohen1960coefficient` gözlemlenen anlaşmayı rastlantı için düzeltir:

$$\kappa = \frac{P_o - P_e}{1 - P_e}$$

burada P_o gözlemlenen orantısal anlaşmadır ve P_e rastlantısal anlaşma olasılığıdır (marjinal etiket dağılımlarından hesaplanır).

$\kappa = 1$ mükemmel anlaşmayı; $\kappa = 0$ rastlantıdan iyi olmayan anlaşmayı; $\kappa < 0$ sistematik anlaşmazlığı ifade eder.

κ aralığı	Yorum
< 0	Rastlantıdan az
$0{,}0 - 0{,}20$	Çok düşük
$0{,}21 - 0{,}40$	Düşük
$0{,}41 - 0{,}60$	Orta
$0{,}61 - 0{,}80$	Yüksek
$0{,}81 - 1{,}00$	Neredeyse mükemmel

Fleiss'ın Kappa Katsayısı

Cohen'in kappa katsayısını $M > 2$ açıklayıcıya genişletir. Her açıklayıcı her öğeyi bağımsız olarak etiketler; formül açıklayıcılar genelinde toplar:

$$\kappa_F = \frac{\bar{P} - \bar{P}_e}{1 - \bar{P}_e}$$

burada $\bar{P}$ tüm açıklayıcı çiftlerindeki ortalama ikili anlaşmadır ve $\bar{P}_e$ rastgele atama altında beklenen anlaşmadır.

Krippendorff'un Alfa Katsayısı

Herhangi sayıda açıklayıcıyı, herhangi bir ölçek türünü (nominal, sıralı, aralıklı, oransal) ve eksik veriyi destekleyen en genel ölçüttür {cite}`krippendorff2011computing`:

$$\alpha = 1 - \frac{D_o}{D_e}$$

burada D_o gözlemlenen anlaşmazlık ve D_e beklenen anlaşmazlıktır. Krippendorff'un alfa katsayısı, esnekliği nedeniyle akademik çalışmalarda genellikle tercih edilir.

```
import numpy as np
from sklearn.metrics import cohen_kappa_score

# Simulate two annotators labeling 200 items into 3 categories
rng = np.random.default_rng(0)
true_labels = rng.integers(0, 3, size=200)

# Annotator 1: mostly agrees with ground truth
ann1 = true_labels.copy()
flip_mask = rng.random(200) < 0.15
ann1[flip_mask] = rng.integers(0, 3, size=flip_mask.sum())
```

```
# Annotator 2: less consistent
ann2 = true_labels.copy()
flip_mask2 = rng.random(200) < 0.30
ann2[flip_mask2] = rng.integers(0, 3, size=flip_mask2.sum())

kappa_12 = cohen_kappa_score(ann1, ann2)
kappa_1true = cohen_kappa_score(ann1, true_labels)
kappa_2true = cohen_kappa_score(ann2, true_labels)

print(f"Cohen's κ (ann1 vs ann2):   {kappa_12:.3f}")
print(f"Cohen's κ (ann1 vs truth):  {kappa_1true:.3f}")
print(f"Cohen's κ (ann2 vs truth):  {kappa_2true:.3f}")
```

Anlaşmazlıkların Ele Alınması

Açıklayıcılar anlaşmazlığa düştüğünde birkaç strateji mevcuttur:

Çoğunluk Oyu

En yaygın etiket altın standart olarak alınır. Öğe başına açıklayıcı sayısı tek olduğunda basit ve sağlamdır. Azınlık grubundaki açıklayıcıların sistematik olarak daha doğru olduğu durumlarda başarısız olur.

Ağırlıklı Oylama

Açıklayıcılar, tahmini doğruluklarına göre ağırlıklandırılır (altın standart veya diğer açıklayıcılarla anlaşmadan türetilir). Daha doğru açıklayıcıların etkisi daha fazladır.

Yumuşak Etiketler

Açıklamaları tek bir etikette yoğunlaştırmak yerine dağılımı koruyun. 5 açıklayıcıdan 3'ü "pozitif" ve 2'si "nötr" dediyse bunu $(p_{\text{pos}}, p_{\text{nötr}}, p_{\text{neg}}) = (0{,}6, 0{,}4, 0{,}0)$ olarak temsil edin. Yumuşak etiketlerle eğitim, kalibrasyon kalitesini artırır.

Tahkim

Kıdemli bir açıklayıcı veya alan uzmanı anlaşmazlıklara karar verir. Altın standart bir yaklaşımdır ancak pahalıdır; genellikle yüksek riskli alanlar için ayrılır.

İstatistiksel Modeller

Daha sofistike yaklaşımlar, açıklayıcı yetkinliğini olasılıksal biçimde modeller. **Dawid-Skene** modeli {cite}`dawid1979maximum`, EM algoritması aracılığıyla hem açıklayıcı karışıklık matrislerini hem de öğe gerçek etiketlerini eş zamanlı olarak tahmin eder. Ayrıntılar için bkz. Bölüm 13.

Etiket Gürültüsü ve Etkileri

Gerçek açıklamalar gürültülüdür. Etiket gürültüsünün model eğitimine etkileri, gürültü türüne bağlıdır:

- **Rastgele gürültü** (etiketlerin rastgele çevrilmesi) performansı düşürür, ancak modeller ılımlı düzeylere (birçok görev için ~%20'ye kadar) şaşırtıcı biçimde dayanıklıdır.
- **Sistematik/saldırgan gürültü** (etiketlerin belirli kalıplarda sürekli yanlış olması) çok daha zararlıdır ve tespit edilmesi güçtür.
- **Sınıf koşullu gürültü** (belirli sınıflar için daha fazla hata) modelin karar sınırını önyargılı hâle getirir.

Pratik bir kural: n eğitim örneği ve ϵ bozuk etiket oranıyla model performansı, yaklaşık olarak $(1-2\epsilon)^2 n$ temiz örneğe eşdeğer biçimde bozulur {cite}`natarajan2013learning`. $\epsilon = 0{,}2$ için bu, verinizin $\%36$'sını yitirmeye eşdeğerdir.

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import cross_val_score

rng = np.random.default_rng(42)
X, y = make_classification(n_samples=2000, n_features=20, random_state=42)

noise_levels = np.linspace(0, 0.45, 15)
mean_accs = []

for eps in noise_levels:
    y_noisy = y.copy()
    flip = rng.random(len(y)) < eps
    y_noisy[flip] = 1 - y_noisy[flip]
    scores = cross_val_score(LogisticRegression(max_iter=500), X, y_noisy, cv=5)
    mean_accs.append(scores.mean())

plt.figure(figsize=(7, 4))
plt.plot(noise_levels, mean_accs, 'o-', color='#2b3a8f', linewidth=2)
plt.xlabel("Label noise rate (ε)", fontsize=12)
plt.ylabel("Cross-validated accuracy", fontsize=12)
plt.title("Effect of Label Noise on Model Performance", fontsize=13)
plt.axvline(0.2, color='#e05c5c', linestyle='--', alpha=0.7, label='20% noise')
plt.legend()
plt.tight_layout()
plt.savefig('label_noise_effect.png', dpi=150)
plt.show()
print(f"\nAccuracy at 0% noise:  {mean_accs[0]:.3f}")
print(f"Accuracy at 20% noise: {mean_accs[round(0.2 / 0.45 * 14)]:.3f}")
print(f"Accuracy at 40% noise: {mean_accs[-2]:.3f}")
```

Açıklama Maliyeti ve Verimi

Açıklama ekonomisini anlamak, proje planlaması açısından önem taşır.

Görev türü	Tipik verim	Öğe başına maliyet (uzman)
İkili görüntü sınıflandırması	200–500/sa	0,02–0,10 USD
NER (kısa metin)	50–150 öğe/sa	0,10–0,50 USD
İlişki çıkarımı	20–60 öğe/sa	0,30–1,50 USD
Tıbbi görüntü segmentasyonu	5–30 öğe/sa	10–100 USD
Video açıklaması	5–20 dk video/sa	20–200 USD

Bu rakamlar yaklaşık büyüklük tahminleridir ve alana gereken uzmanlığa, açıklama aracının kalitesine, kılavuz netliğine ve açıklayıcı deneyimine göre büyük ölçüde değişir. Gösterge niteliği taşır; kesin değer olarak yorumlanmamalıdır.

> **See also:** Açıklama aracı seçenekleri Bölüm 12'de ele alınmaktadır. Kitle kaynaklı açıklama için istatistiksel modeller (Dawid-Skene, MACE) Bölüm 13'te işlenmektedir.

Aktif Öğrenme

Etiketli veri pahalıdır. Aktif öğrenmenin temel kavrayışı şudur: *tüm etiketsiz örnekler eşit ölçüde bilgilendirici değildir* — bir model, hangi örnekleri soracağını seçme hakkı verildiğinde daha hızlı gelişebilir. Aktif öğrenme sistemi, veriyi rastgele etiketlemek yerine modeli en çok iyileştirecek örnekler üzerinde bir kehanet (genellikle insan açıklayıcı) sorgular.

Bu bölüm aktif öğrenmenin teorisini ve pratiğini kapsar: sorgu stratejileri, örnekleme çerçeveleri, durdurma ölçütleri ve gerçek dağıtımlar için pratik değerlendirmeler.

Aktif Öğrenme Kurulumu

Standart **havuz tabanlı aktif öğrenme** ortamı şunları içerir:

- Başlangıçta küçük olan bir **etiketli küme** $\mathcal{L} = \{(x_i, y_i)\}_{i=1}^n$
- Genellikle $\mathcal{L}$'den çok daha büyük bir **etiketsiz havuz** $\mathcal{U} = \{x_j\}_{j=1}^m$
- Sorgulanan herhangi bir x için $y = \mathcal{O}(x)$ döndürebilen bir **kehanet** $\mathcal{O}$
- Sonraki sorguyu $x^* = \phi(\mathcal{L}, \mathcal{U}, f_\theta)$ olarak seçen bir **sorgu stratejisi** ϕ

Aktif öğrenme döngüsü:

```
1. Başlatma: L = küçük etiketli tohum kümesi, U = etiketsiz havuz
2. Eğitim: f_θ ← train(L)
3. Sorgu: x* = argmax φ(x; f_θ), x ∈ U üzerinde
4. Etiketleme: y* = O(x*)
5. Güncelleme: L ← L ∪ {(x*, y*)}, U ← U \ {x*}
→ Bütçe tükenene kadar 2'den tekrarla
```

Amaç, olabildiğince az kehanet sorgusu kullanarak hedef model kalitesine ulaşmaktır.

Kuramsal Temeller

Doğal bir soru şudur: aktif öğrenme ne kadar yardımcı olabilir? En iyi senaryoda, gerçekleştirilmiş ortamlarda iyi bir sorgu stratejisiyle pasif öğrenmenin gerektirdiği $O(1/\epsilon)$'dan çok daha az, $O(\log(1/\epsilon))$ etiketle hata ϵ'a ulaşarak *üstel* etiket karmaşıklığı azalmaları sağlanabilir {cite}`settles2009active`.

Pratikte garantiler elde etmek daha güçtür. **Agnostik aktif öğrenme** {cite}`balcan2006agnostic`, hedef kavramın hipotez sınıfında olmadığı durumlarda dahi etiket tasarruflarının mümkün olduğunu göstermektedir; ancak tasarruflar, veri birikmesiyle olası hipotezler kümesinin ne kadar hızlı küçüldüğünü ölçen anlaşmazlık katsayısına güçlü biçimde bağlıdır.

Temel pratik çıkarım: aktif öğrenmenin avantajı, **karar sınırı basit ve yoğunlaşmış** olduğunda (belirsizlik sorguları yanlış hipotezleri hızla eleyebildiğinden) en büyük, hipotez sınıfı büyük veya sınır karmaşık olduğunda ise en küçüktür.

Sorgu Stratejileri

Belirsizlik Örneklemesi

En basit ve en yaygın kullanılan strateji: modelin en çok *belirsiz* olduğu örneği sorgula {cite}`lewis1994sequential`.

En düşük güven örneklemesi, modelin en üst tahminine en az güvendiği örneği sorgular:

$$x^* = \arg\max_{x \in \mathcal{U}} \left(1 - P_\theta(\hat{y} \mid x)\right)$$

Marjin örneklemesi, ilk iki tahmin olasılığı arasındaki farkı dikkate alır:

$$x^* = \arg\min_{x \in \mathcal{U}} \left(P_\theta(\hat{y}_1 \mid x) - P_\theta(\hat{y}_2 \mid x)\right)$$

Entropi örneklemesi, tahmin edilen tam dağılımı kullanır:

$$x^* = \arg\max_{x \in \mathcal{U}} \left(-\sum_{k=1}^{K} P_\theta(y_k \mid x) \log P_\theta(y_k \mid x) \right)$$

Entropi örneklemesi üçü arasında en sağlam temellere sahip olanıdır — tüm sınıfları dikkate alır — ve çok sınıflı problemlerde diğerlerinden genellikle daha iyi performans gösterir.

Komite Sorgulama (QbC)

C modelden oluşan bir **komite** eğitilir (torbalama, farklı başlangıç değerleri veya farklı mimariler kullanılarak). Komitenin en çok anlaşmazlığa düştüğü örnek sorgulanır:

$$x^* = \arg\max_{x \in \mathcal{U}} \ \text{anlaşmazlık}(\{f_c(x)\}_{c=1}^{C})$$

Anlaşmazlık, **oy entropisi** (komitenin çoğunluk oyları üzerinden entropi) veya fikir birliği dağılımından **KL ıraksaması** olarak ölçülebilir.

QbC, tekil bir modele kıyasla daha iyi belirsizlik tahminleri sağlar ancak birden fazla modelin eğitimini gerektirir; bu da hesaplama açısından pahalıdır.

Beklenen Model Değişimi

Etiketlenmiş olsaydı mevcut modeli en çok değiştirecek örneği sorgula. Gradyan tabanlı modeller için bu, en büyük beklenen gradyan büyüklüğüne sahip örneğe karşılık gelir {cite}`settles2008analysis`:

$$x^* = \arg\max_{x \in \mathcal{U}} \sum_{y \in \mathcal{Y}} P_\theta(y \mid x) \, \|\nabla_\theta \mathcal{L}(f_\theta(x), y)\|$$

Bu stratejinin güçlü kuramsal gerekçesi vardır, ancak her aday için gradyan hesaplamayı gerektirdiğinden büyük modeller için pahalıdır.

Çekirdek Küme / Geometrik Yaklaşımlar

Belirsizlik tabanlı stratejiler **aykırı değerlere yönelim gösterebilir**: sıradışı bir örnek yüksek belirsizlikte olabilir ancak veri dağılımını temsil etmeyebilir. Çekirdek küme yöntemleri, özellik uzayını kapsayan çeşitlendirilmiş bir örnek arayarak bunu ele alır.

k-merkezli açgözlü algoritma {cite}`sener2018active`, her etiketsiz noktanın en az bir sorgulanan noktanın δ yakınında olduğu en küçük nokta kümesini bulur:

$$x^* = \arg\max_{x \in \mathcal{U}} \min_{x' \in \mathcal{L}} d(x, x')$$

Yani, mevcut herhangi bir etiketli noktadan en uzak noktayı sorgula. Bu, açıklamaların iyi yayılmış bir küme oluşturmasını teşvik eder.

BADGE

Çeşitli Gradyan Gömmeleri Yoluyla Toplu Aktif Öğrenme (BADGE) {cite}`ash2020deep`, belirsizlik ve çeşitliliği bir araya getirir: tahmin edilen etikete göre gradyan gömmeleri hem büyüklük (belirsiz) hem de çeşitlilik (gradyan uzayının farklı bölgelerini kapsama) açısından olumlu olan örnekleri seçer. Bu, en rekabetçi modern stratejilerden biridir.

Derin Modeller için Belirsizlik Tahmini

Yukarıdaki stratejiler, modelden kalibre edilmiş olasılık çıktılarına erişim varsayar. Basit modeller (lojistik regresyon, softmax sınıflandırıcılar) için bu basittir. Derin ağlar için güvenilir belirsizlik tahminleri elde etmek ek teknik gerektirir.

İki Tür Belirsizlik

Kendall ve Gal {cite}`kendall2017uncertainties`'ın çerçevesini izleyerek şu ayrımı yapıyoruz:

Aleatonik belirsizlik (veri belirsizliği): daha fazla veri toplayarak azaltılamayan gözlemlerdeki doğal gürültü. Bulanık bir görüntü aleatonik belirsizliğe sahiptir — aynı dağılımdan ek eğitim verisi, modelin bu görüntü üzerinde daha güvenli olmasını sağlamayacaktır.

Epistemik belirsizlik (model belirsizliği): sınırlı eğitim verisinden ya da benzer örnekler görmemiş bir modelden kaynaklanan belirsizlik. Epistemik belirsizlik daha fazla veri etiketlenerek *azaltılabilir* — dolayısıyla aktif öğrenme sorgu seçimi için ilgili nicelik budur.

Aktif öğrenme için yüksek epistemik belirsizliğe sahip örnekleri sorgulamak isteriz; yüksek aleatonik belirsizliğe sahip olanları değil. Temelden belirsiz bir örneği sorgulamak kehanet çabasını boşa harcar: sağladıkları etiket açıkça doğru olmayacaktır.

Monte Carlo Hata Bırakma

Sinir ağları için epistemik belirsizlik tahminine pratik bir yaklaşım **MC Hata Bırakma (MC Dropout)** {cite}`gal2016dropout`'tur: çıkarım sırasında hata bırakmayı uygula ve T ileri geçiş çalıştır. Tahminler arasındaki varyans, epistemik belirsizliğin bir tahminidir.

```python
import numpy as np
import torch
import torch.nn as nn

torch.manual_seed(42)
rng = np.random.default_rng(42)

class MCDropoutNet(nn.Module):
    def __init__(self, input_dim=20, hidden=64, output_dim=2, p_drop=0.3):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(input_dim, hidden), nn.ReLU(), nn.Dropout(p_drop),
            nn.Linear(hidden, hidden),    nn.ReLU(), nn.Dropout(p_drop),
            nn.Linear(hidden, output_dim)
        )

    def forward(self, x):
        return self.net(x)

def mc_uncertainty(model, x, T=30):
    """
    Run T stochastic forward passes with dropout active.
    Returns mean prediction and epistemic uncertainty (predictive variance).
    """
    model.train()  # keep dropout active during inference
    with torch.no_grad():
        preds = torch.stack([
            torch.softmax(model(x), dim=-1) for _ in range(T)
        ])  # shape: (T, N, C)
    mean_pred = preds.mean(0)
    # Epistemic uncertainty: mean of variances across passes
    epistemic = preds.var(0).sum(-1)
    # Aleatoric uncertainty: entropy of mean prediction
    aleatoric = -(mean_pred * (mean_pred + 1e-9).log()).sum(-1)
    return mean_pred, epistemic, aleatoric

# Quick demonstration
model = MCDropoutNet(input_dim=20, output_dim=2)
# In-distribution example (simulated)
x_familiar   = torch.randn(1, 20) * 0.5
# Out-of-distribution example (far from training distribution)
x_unfamiliar = torch.randn(1, 20) * 3.0

for name, x in [("In-distribution ", x_familiar), ("Out-of-distribution", x_unfamiliar)]:
    _, ep, al = mc_uncertainty(model, x)
    print(f"{name} | epistemic: {ep.item():.4f} | aleatoric: {al.item():.4f}")
```

Yukarıdaki eğitimsiz ağda, her iki örnek de benzer belirsizlik gösterir. Eğitimden sonra, dağılım dışı örnek daha yüksek epistemik belirsizlik sergileyecektir — model, eğitim dağılımından uzak girdiler için güvenilir bir eşleme öğrenmemiştir.

Derin Topluluklar

M bağımsız olarak başlatılmış model eğitip tahminlerinin ortalamasını almak, MC Hata Bırakmadan daha basit ve çoğu zaman daha güvenilir bir belirsizlik tahmini sağlar {cite}`lakshminarayanan2017simple`. Topluluk üyeleri arasındaki anlaşmazlık, epistemik belirsizlik sinyalidir.

Ölçekli aktif öğrenmede, hem MC Hata Bırakma hem de derin topluluklar T veya M ileri geçişiyle orantılı ek yük getirir. Pratikte, mutlak değerler iyi kalibre edilmiş olmasa bile örnekleri epistemik belirsizliğe göre sıralamak için genellikle MC Hata Bırakma için $T = 10$–30 veya $M = 5$ topluluk üyesi yeterlidir.

Tam Bir Aktif Öğrenme Döngüsü

```python
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score
from copy import deepcopy

rng = np.random.default_rng(42)

# Generate dataset
X, y = make_classification(
    n_samples=2000, n_features=20, n_informative=10,
    n_classes=3, n_clusters_per_class=1, random_state=42
)
X_train, y_train = X[:1500], y[:1500]
X_test,  y_test  = X[1500:], y[1500:]

def entropy_query(model, X_pool):
    """Return index of most uncertain sample (entropy)."""
    probs = model.predict_proba(X_pool)
    ent = -np.sum(probs * np.log(probs + 1e-9), axis=1)
    return np.argmax(ent)

def random_query(X_pool):
    """Random baseline."""
    return rng.integers(0, len(X_pool))

def run_active_learning(strategy='entropy', n_initial=30, n_queries=120, query_batch=5):
    labeled_idx = list(rng.choice(len(X_train), n_initial, replace=False))
    unlabeled_idx = [i for i in range(len(X_train)) if i not in labeled_idx]
    accs = []
```

```
    for step in range(n_queries // query_batch):
        model = LogisticRegression(max_iter=500, C=1.0)
        model.fit(X_train[labeled_idx], y_train[labeled_idx])
        accs.append(accuracy_score(y_test, model.predict(X_test)))

        # Query
        X_pool = X_train[unlabeled_idx]
        for _ in range(query_batch):
            if strategy == 'entropy':
                q = entropy_query(model, X_pool)
            else:
                q = random_query(X_pool)
            labeled_idx.append(unlabeled_idx.pop(q))
            X_pool = X_train[unlabeled_idx]

    return np.array(accs)

labels_used = np.arange(1, 25) * 5 + 30  # label counts at each step

accs_active = run_active_learning(strategy='entropy')
accs_random = run_active_learning(strategy='random')

plt.figure(figsize=(8, 5))
plt.plot(labels_used, accs_active, 'o-', label='Entropy sampling', color='#2b3a8f', linewidth
plt.plot(labels_used, accs_random, 's--', label='Random baseline',  color='#e05c5c', linewidt
plt.xlabel("Number of labeled examples", fontsize=12)
plt.ylabel("Test accuracy", fontsize=12)
plt.title("Active Learning vs. Random Sampling", fontsize=13)
plt.legend(fontsize=11)
plt.grid(alpha=0.3)
plt.tight_layout()
plt.savefig('active_learning_curve.png', dpi=150)
plt.show()

print(f"Active learning reaches {accs_active[-1]:.3f} accuracy")
print(f"Random sampling reaches {accs_random[-1]:.3f} accuracy")
print(f"Active learning saves ~{int((accs_random.tolist().index(min(accs_random, key=lambda a
```

Soğuk Başlangıç Problemi

Aktif öğrenme, etiketsiz noktaları puanlamak için eğitilmiş bir model gerektirir — ancak başlangıçta hiç (ya da çok az) etiketli örnek yoktur. Bu, **soğuk başlangıç problemidir**.

Pratik çözümler:

1. **Rastgele başlatma:** Aktif öğrenmeye başlamadan önce küçük bir rastgele tohum kümesi (20–100 örnek) etiketle.
2. **Kümeleme tabanlı başlatma:** Etiketsiz havuz üzerinde k-means uygula; her kümeden bir örnek etiketle. Bu, başlangıç etiketli kümesinde çeşitliliği güvence altına alır.
3. **Gömme tabanlı seçim:** Örnekleri gömmek için önceden eğitilmiş bir kodlayıcı kullan;

çekirdek küme yöntemiyle çeşitlendirilmiş bir alt küme seç.

Çoğu görev için birkaç düzine rastgele tohum etiket, aktif öğrenmeyi başlatmak için genellikle yeterlidir; kesin sayı, sınıf dengesine, özellik boyutsallığına ve model karmaşıklığına bağlıdır.

Toplu Modda Aktif Öğrenme

Pratikte açıklayıcılar toplu iş şeklinde çalışır — her tekil etiket sonrasında yeni bir model eğitip dağıtmak verimsizdir. **Toplu modda aktif öğrenme**, aynı anda etiketlenecek b örnek kümesi seçer.

En belirsiz b örneği naif biçimde seçmek **fazlalığa** yol açar: yüksek belirsizlikteki örnekler bir arada kümelenir (örneğin aynı bölgede karar sınırına yakın örnekler). Daha iyi toplu stratejiler, hem belirsizliği hem de toplu içindeki çeşitliliği optimize eder.

Determinantal Nokta Süreçleri (DPP'ler), çeşitlendirilmiş toplu örnekler seçmenin prensipli bir yolunu sunar: benzer öğeleri cezalandıran alt kümeler üzerinde bir dağılım tanımlar. S alt kümesinin bir DPP altındaki olasılığı, benzerliği kodlayan bir çekirdek matrisi olan L'de $\det(L_S)$ ile orantılıdır.

Durdurma Ölçütleri

Aktif öğrenme ne zaman durmalıdır? Yaygın ölçütler:

- **Bütçe tükendi:** En basiti — açıklama bütçesi bittiğinde dur.
- **Performans platoya ulaştı:** Tutulmuş bir doğrulama kümesindeki model doğruluğu art arda k turda δ'dan fazla iyileşmediğinde dur.
- **Güven eşiği:** Etiketsiz örneklerin belirli bir oranından azının belirsizliği eşiğin üzerinde olduğunda dur.
- **Azami kayıp azalması:** Ek etiketlerden elde edilebilecek azami kazanımı tahmin et; bu bir eşiğin altına düştüğünde dur {cite}`bloodgood2009method`.

Aktif Öğrenmenin İşe Yaradığı (ve Yaramadığı) Durumlar

Aktif öğrenme şu durumlarda iyi çalışır: - Etiketleme pahalıdır ve etiketsiz havuz büyüktür - Verinin, modelin bilgilendirici örnekleri belirlemekte yararlanabileceği net bir yapısı vardır - Model sınıfı göreve uygundur

Aktif öğrenme şu durumlarda kötü performans gösterir: - Başlangıç modeli çok zayıftır (soğuk başlangıç) ve örnekleri anlamlı biçimde sıralayamaz - Sorgu stratejisi aykırı değerler veya yanlış etiketlenmiş örnekler seçer (gürültü sağlamlığı önem taşır) - Etiketsiz havuz ile test dağılımı arasında veri dağılımı kayması vardır

Önemli bir pratik endişe **dağılım uyumsuzluğudur**: aktif öğrenme, karar sınırına yakın örnekleri sorgulama eğilimindedir; bu durum, test dağılımını iyi temsil etmeyebilecek önyargılı bir etiketli küme oluşturur. Bu, iyi eğitilmiş karar sınırlarına ancak kötü kalibrasyona yol açabilir.

See also: Temel araştırma şu kaynaktır: {cite}`settles2009active`. Kuramsal temeller (etiket karmaşıklığı, agnostik sınırlar): {cite}`balcan2006agnostic`. Derin öğrenmeye özgü aktif öğrenme için bkz. {cite}`ash2020deep` (BADGE) ve {cite}`sener2018active` (çekirdek küme). Aktif öğrenmenin ne zaman gerçekten işe yaradığına ilişkin eleştirel bir değerlendirme için bkz. {cite}`lowell2019practical`. Derin modeller için aleatonik ve epistemik belirsizlik üzerine bkz. {cite}`kendall2017uncertainties`; belirsizlik tahmincisi olarak derin topluluklar için bkz. {cite}`lakshminarayanan2017simple`; yaklaşık Bayesci çıkarım olarak MC Hata Bırakma için bkz. {cite}`gal2016dropout`.

Etkileşimli Makine Öğrenmesi

Aktif öğrenme odaklı bir soru sorar: bütçe göz önünde bulundurulduğunda hangi örnekler etiketlenmelidir? Etkileşimli Makine Öğrenmesi (IML) ise daha geniş bir soru sorar: bir insan ile bir öğrenme sistemi arasındaki *tüm etkileşimi* en üst düzeyde verimli, keyifli ve doğru biçimde nasıl tasarlayabiliriz?

IML'i diğerlerinden ayıran, insan–model geri bildirim döngüsünün **anlık** ve **doğrudan** niteliğidir. Geleneksel makine öğrenmesinde insan veri teslim eder ve eğitimin bitmesini beklerken, IML insanlara model davranışını gözlemleme, geri bildirim sağlama ve modelin — çoğunlukla saniyeler içinde — tepki verdiğini görme olanağı tanır.

Etkileşimli Makine Öğrenmesinin İlkeleri

Amershi ve diğerleri {cite}`amershi2014power`, IML'nin üç belirleyici özelliğini saptamıştır:

1. Hızlı Geri Bildirim: Model, insanların geri bildirimlerinin etkisini algılayabilmesi için yeterince hızlı güncellenir. Limitde, model güncellemeleri gerçek zamanlı olarak gerçekleşir.

2. Doğrudan Müdahale: İnsan, modellerle veri ya da modelin tahminleri üzerinden etkileşim kurar — yapılandırma dosyaları veya hiper parametre ayarlaması yoluyla değil.

3. Yinelemeli İyileştirme: Süreç gerçek anlamda yinelemeli bir nitelik taşır: insanın sonraki eylemi, insanın önceki eylemlerinin şekillendirdiği modelin mevcut davranışıyla belirlenir.

Bu durum, sıkı bir **karşılıklı uyum döngüsü** yaratır: hem insan hem de model zaman içinde birbirlerine yanıt olarak değişir. İnsan, modelin neyi anladığını öğrenir; model ise insanın ne önemsediğini.

Aktif Öğrenme ile Karşılaştırma

IML ve aktif öğrenme önemli ölçüde örtüşür ancak özdeş değildir:

Özellik	Aktif Öğrenme	Etkileşimli ML
Birincil soru	Ne etiketlenmeli?	Nasıl etkileşim kurulmalı?
Geri bildirim gecikmesi	Toplu olabilir (günler)	Genellikle gerçek zamanlı
Model güncelleme sıklığı	Tur başına (toplu)	Etkileşim başına (çevrimiçi)
İnsan özerkliği	Modelin sorularına yanıt verir	Modeli proaktif olarak eğitebilir
Arayüz tasarımı	İkincil endişe	Merkezi endişe

Özellik	Aktif Öğrenme	Etkileşimli ML
İnsanın bilişsel yükü	Açıkça modellenmiyor	Açıkça dikkate alınıyor

Aktif öğrenmede makine etkileşimi yönlendirir. IML'de insan da inisiyatif alabilir — modelin davranışının en sorunlu görünen yönü ne ise o konuda örnekler, düzeltmeler veya geri bildirim sağlayabilir.

Karma Girişim Etkileşimi

Karma girişim sistemleri, hem insanın hem de makinenin farklı anlarda öncü olmasına izin verir {cite}`allen1999mixed`. Tamamen makine yönlendirmeli bir sistem sorular sorar ve insan yanıtlar. Tamamen insan yönlendirmeli bir sistem her şeyi insanın belirlemesine izin verir. Karma girişim sistemleri her ikisini dengeler.

Pratikte en iyi IML sistemleri şunları bir araya getirir: - **Makine girişimi:** "Bu örneklerden emin değilim — etiketleyebilir misiniz?" - **İnsan girişimi:** "Modelin bu kategori konusunda sürekli hata yaptığını fark ediyorum — daha fazla örnek sağlayayım" - **Onaylama:** Model mevcut anlayışını ortaya koyar; insan onaylar ya da düzeltir

İyi IML arayüzleri, modelin mevcut anlayışını görünür ve düzeltilebilir kılar. Bu, **anlaşılırlık** gerekliliğidir: insanlar yalnızca en azından kabaca anladıkları bir modele rehberlik edebilir.

IML'deki İnsan Faktörleri

IML, bilişsel yük, yorgunluk, tutarlılık ve güven gibi insan faktörlerini doğrudan öğrenme döngüsüne taşır. Kötü IML tasarımı şunlara yol açar:

Açıklama yorgunluğu: İnsanların oturumlar uzadıkça daha hızlı ve daha özensiz kararlar alması. Eğitim verilerine giren hatalar.

Çapalama önyargısı: İnsanların modelin mevcut önerilerine aşırı güvenmesi. Bir arayüz modelin tahminini önceden doldurursa, yanlış olduğunda bile açıklayıcıların düzeltme olasılığı azalır — bu, açıklama turları arasında birikerek güçlenen sistematik bir etiket gürültüsü kaynağıdır {cite}`geva2019annotator`. Ön açıklama verimi artırabilir {cite}`lingren2014evaluating` ve aynı zamanda açıklayıcıların model hatalarını yakalama oranını düşürebilir; bu iki etki IML arayüz tasarımında birbirlerine karşı tartılmalıdır.

Güven uyumsuzluğu: İnsanlar ya gereğinden fazla güvenir (yanlış model çıktılarını kabul eder) ya da gereğinden az güvenir (doğru önerileri görmezden gelir). Her iki örüntü de insan–model işbirliğinin değerini düşürür.

Oturum tutarlılığı: İnsanlar, özellikle uzun oturumların ardından, aynı örnek üzerinde farklı zamanlarda farklı kararlar verebilir. Tutarlılık kontrolleri (önceki örnekleri yeniden sunmak) bunu tespit edip düzeltebilir.

İyi IML tasarımı bu sorunları arayüz seçimleriyle azaltır: model güvenini açıkça sunmak, görüntüleme sırasını rastgele belirlemek, oturum süresini sınırlamak ve tutarlılık kontrolleri yerleştirmek.

Pratikte IML Geri Bildirim Türleri

Örnek Düzeyinde Geri Bildirim

İnsan, belirli bir örnek için bir etiket veya düzeltme sağlar. Bu en yaygın biçimdir ve denetimli öğrenmeyle doğrudan uyumludur.

Özellik Düzeyinde Geri Bildirim

İnsan hangi özelliklerin ilgili ya da ilgisiz olduğunu belirtir. "Model bu kategori için 'acil' ve 'son teslim tarihi' sözcüklerine dikkat etmeli." Bu, örnek düzeyinde geri bildirimden daha ifadeli ve belirli görevler için daha verimli olabilir.

TFIDF Etkileşimli ve benzer sistemler, açıklayıcıların metin belgelerindeki ilgili sözcükleri vurgulamasına olanak tanır. Bu vurgulamalar, modelin dikkatine yönelik kısıtlamalara veya ek denetime dönüştürülür.

Model Düzeyinde Geri Bildirim

İnsan, modelin bir girdi sınıfındaki davranışını doğrudan düzeltir: "[X] içerdiğinde çıktı [Y] olmalı." Bu, Arka Plan Düzenlemesi {cite}`ganchev2010posterior` veya kısıt güdümlü öğrenme gibi yaklaşımlarda mantık kurallarına veya kısıtlamalara eşlenir.

Vaka Çalışması: Google Teachable Machine

Teachable Machine, teknik olmayan kullanıcıların tarayıcıda görüntü sınıflandırıcıları eğitmesine olanak tanıyan erişilebilir bir web tabanlı IML sistemidir. Kullanıcı:

1. Web kamerasını kullanarak her sınıf için örnekler kaydeder
2. Tek tıklamayla modeli eğitir (tarayıcıda bir MobileNet ince ayarı)
3. Model tahminlerini canlı videoda anında görür
4. Modelin hatalı olduğu sınıflar için daha fazla örnek ekler

Bu, temel IML döngüsünü örnekler: örnek sağla □ modeli gözlemle □ başarısızlığı tespit et □ daha hedefli örnekler sağla. Gerçek zamanlı geri bildirim (model çıktıları gerçek zamanlı, modern donanımda genellikle etkileşimli kare hızlarında güncellenir), karşılıklı uyum döngüsünü somut biçimde hissettiren bir anlıklık yaratır.

Basit Bir IML Döngüsünün Uygulanması

```
import numpy as np
from sklearn.linear_model import SGDClassifier
from sklearn.preprocessing import StandardScaler
import warnings
warnings.filterwarnings('ignore')

class SimpleIMLSystem:
    """
    Minimal IML system that allows online feedback and displays
    model state after each annotation.
```

```
    """

    def __init__(self, n_features=10, n_classes=2):
        self.model = SGDClassifier(loss='log_loss', max_iter=1, warm_start=True,
                                   random_state=42)
        self.scaler = StandardScaler()
        self.X_seen = []
        self.y_seen = []
        self.n_classes = n_classes
        self.initialized = False

    def update(self, x, y_true):
        """Receive a single labeled example and update the model."""
        self.X_seen.append(x)
        self.y_seen.append(y_true)

        if len(self.X_seen) >= 2 * self.n_classes:
            X_arr = np.array(self.X_seen)
            y_arr = np.array(self.y_seen)
            X_scaled = self.scaler.fit_transform(X_arr)
            self.model.partial_fit(X_scaled[-1:], y_arr[-1:],
                                   classes=list(range(self.n_classes)))
            self.initialized = True

        return self

    def predict_with_confidence(self, x):
        """Predict label and return confidence."""
        if not self.initialized:
            return None, 0.0
        x_scaled = self.scaler.transform(x.reshape(1, -1))
        probs = self.model.predict_proba(x_scaled)[0]
        return self.model.predict(x_scaled)[0], probs.max()

    def current_accuracy(self, X_val, y_val):
        if not self.initialized:
            return None
        X_scaled = self.scaler.transform(X_val)
        return (self.model.predict(X_scaled) == y_val).mean()


# Simulate an IML session
rng = np.random.default_rng(42)
X_all, y_all = np.random.default_rng(0).random((500, 10)), np.random.default_rng(0).integers(
X_val, y_val = X_all[400:], y_all[400:]

system = SimpleIMLSystem(n_features=10, n_classes=2)
accs, confidences = [], []

print("Step | Labels | Accuracy | Example confidence")
print("-" * 50)
```

```
for step in range(100):
    x, y = X_all[step], y_all[step]
    pred, conf = system.predict_with_confidence(x)
    system.update(x, y)

    if (step + 1) % 10 == 0:
        acc = system.current_accuracy(X_val, y_val)
        if acc is not None:
            accs.append(acc)
            print(f"  {step+1:3d} |  {step+1:4d}  |  {acc:.3f}   | {conf:.3f}")
```

Büyükanne Testi

IML arayüz tasarımını — ve daha genel olarak HITL sistem tasarımını — değerlendirmek için yararlı bir sezgisel yönteme **Büyükanne Testi** adını veriyoruz (bu kavram burada özgün bir tasarım kısıtı olarak ortaya atılmaktadır; önceki çalışmalara bir atıf değildir):

> *1930 doğumlu bir kadın bu cihazı sesle kullanabilmeli ve hayal kırıklığına uğradığında klavye veya metin arayüzüne sorunsuz biçimde geçebilmelidir.*

Test öncelikle erişilebilirlikle ilgili değildir — her ne kadar o da olsa. **Dirençli tasarım** üzerinedir. Bir sistem, etkili biçimde kullanılabilmesi için sinir ağları, eğitim döngüleri veya olasılık dağılımlarına ilişkin zihinsel bir model gerektiriyorsa, Büyükanne Testini başaramamış demektir. Döngüdeki insan, döngünün makine tarafını anlamadan da katılabilmelidir.

IML tasarımına yönelik çıkarımlar somuttur:

Ses öncelikli yedekleme: Birincil etkileşim kipi doğal dil veya jest olmalıdır — parametre kaydırıcıları ya da güven eşikleri değil. Uzmanlar kaydırıcı isteyebilir; herkes "bu yanlış" diyebilmelidir.

Zarif bozulma: Kullanıcının tercih ettiği kip başarısız olduğunda veya hayal kırıklığı yarattığında, sistem boş bir ekran veya hata iletisi değil, bir alternatif sunmalıdır. Arayüz öğrenme sisteminin bir parçasıdır; etkileşim kuramayan bir kullanıcı öğretemez.

Anlaşılır model durumu: Modelin mevcut anlayışı insan dilinde görünür olmalıdır. "Güven: 0,73" değil; "Bunun [X] olduğundan oldukça eminim, ancak bu türden örneklerin her iki yöne de gittiğini gördüm." Belirsizlik, düzeltmeyi davet eden bir dilde iletilmelidir.

Belirsizliğe tolerans: 93 yaşındaki bir kullanıcı ile 23 yaşındaki bir makine öğrenmesi mühendisi aynı sistemle farklı biçimlerde etkileşim kuracaktır. Büyükanne Testi, sistemin her ikisine de uyum sağlayıp sağlayamadığını sorar — kullanıcının yaşını tespit ederek değil, geniş bir uzmanlık ve rahatlık yelpazesinde işe yarayan etkileşimler tasarlayarak.

Test, makine öğrenmesi sistemleri araştırma araçlarından gündelik altyapıya taşındıkça özel bir önem kazanır. Radyologlar tarafından kullanılan bir tıbbi görüntüleme asistanı, kâtipler tarafından kullanılan bir hukuki belge sınıflandırıcısı, öğretmenler tarafından kullanılan bir eğitimsel geri bildirim sistemi — her biri AI eğitmeni olmak için başvurmamış döngüde insanları içerir. Onlar için tasarım yapmak bir taviz değildir; asıl amacın ta kendisidir.

:::{admonition} Tasarım İlkesi :class: tip Büyükanne Testi bir hedef demografi değil, bir tasarım kısıtıdır. Bu testi geçen sistemler, kullanıcı çeşitliliğine karşı daha dayanıklı, uzmanlık boşluklarına karşı daha hoşgörülü ve döngüdeki insanlardan neler beklediği konusunda daha

dürüsttür. Bir sistem kullanımdan önce açıklama gerektiriyorsa, insandan ek çaba istiyor demektir. Bu çabanın orantılı bir fayda sağlaması gerekir. :::

IML ve Temel Modeller

Modern IML giderek artan biçimde **önceden eğitilmiş temel modelleri** {cite}`bommasani2021opportunities` temel olarak kullanmaktadır. Sıfırdan eğitmek yerine kullanıcılar, az sayıda etkileşimli örnekle büyük bir önceden eğitilmiş modeli ince ayar yapar. Bu, yararlı performansa ulaşmak için gereken örnek sayısını önemli ölçüde azaltabilir — önceden eğitilmiş temsillerin hedef görevle ne kadar örtüştüğüne bağlı olarak, elverişli durumlarda binler yerine yalnızca 5–50 örnek yeterli olabilir {cite}`bommasani2021opportunities`.

Bunu sağlayan teknikler şunlardır: - **Az atışlı yönlendirme:** Örnekleri büyük dil modelinin bağlam penceresinde sağlama - **Adaptör ince ayarı:** Taban modeli dondurarak küçük adaptör modülleri güncelleme - **Parametreden Verimli İnce Ayar (PEFT):** Hızlı, düşük kaynaklı güncellemelere olanak tanıyan LoRA, önek ayarı ve benzeri yöntemler

Temel modeller IML dinamiğini değiştirir: insanlar artık boş bir modeli sıfırdan eğitmek yerine zaten çok şey bilen bir modeli *yönlendirmektedir*. Zorluk "yeterli örnek nasıl sağlanır"dan "modelin zaten yaptıklarından tam olarak ne farklı istiyoruz"a kayar.

> **See also:** {cite}`amershi2014power` araştırması, IML ilkelerinin en iyi genel değerlendirmesi olmaya devam etmektedir. Karma girişim sistemleri için bkz. {cite}`allen1999mixed`. Açıklamada çapalama etkileri için bkz. {cite}`geva2019annotator` ve {cite}`lingren2014evaluating`.

İnsan Geri Bildiriminden Pekiştirmeli Öğrenme

HITL ML'yi ana akıma taşıyan tek teknik, İnsan Geri Bildiriminden Pekiştirmeli Öğrenme'dir (RLHF). Bu teknik, InstructGPT'nin {cite}`ouyang2022training` temelini oluşturmakta ve pek çok modern büyük dil modelindeki talimat takip hatlarının temel bileşeni konumundadır {cite}`stiennon2020learning`. RLHF'yi — yalnızca uygulanacak bir tarif olarak değil, hizalamaya yönelik prensipli bir yaklaşım olarak — anlamak, modern yapay zeka alanında çalışan herkes için zorunludur.

Hizalama Problemi

Yalnızca sonraki belirteç tahmininde eğitilen büyük dil modelleri (BDM'ler), bir vekil hedefe göre optimize eder: insan yazısı bir derlemdeki metnin devamını tahmin et. Bu hedef, gerçekten istediğimiz şeyle — yararlı, doğru, güvenli ve insan değerleriyle uyumlu yanıtlar — ilişkili olmakla birlikte ondan farklıdır.

Eğitim hedefi ile istenilen davranış arasındaki bu uyumsuzluğa **hizalama problemi** adı verilir {cite}`russell2019human`. Somut olarak, internet metninde eğitilmiş bir dil modeli şunları öğrenir: - Makul gelen devamlar üretme (bunlar olgusal olarak yanlış olabilir) - Eğitim verilerindeki önyargıları ve zararları yansıtma - İstatistiksel olarak yönlendirmeyi takip ettiğinde kaçamak veya manipülatif olma

RLHF, insan tercihlerini *optimizasyon hedefinin bir parçası* hâline getirerek hizalamayı ele alır.

RLHF Hattı

RLHF üç aşamada ilerler:

```
Aşama 1: Denetimli İnce Ayar (SFT)
  --> Gösteri verisi toplama (insan ideal yanıtları yazar)
  --> Taban BDM'yi gösteriler üzerinde ince ayarlama

Aşama 2: Ödül Modeli Eğitimi
  --> İkili tercihler toplama (insan A ile B'yi değerlendirir)
  --> İnsan tercihlerini tahmin etmek için R(x, y) ödül modeli eğitimi

Aşama 3: TÖ İnce Ayarı
```

```
--> R(x, y)'yi maksimize etmek için PPO/RL ile BDM ince ayarı
--> KL cezası, SFT modelinden aşırı sapmaları önler
```

Aşama 1: Denetimli İnce Ayar

Önceden eğitilmiş bir taban model π_0'dan başlayarak, ayrıntılı kılavuzları izleyen insan çalışanlar tarafından yazılan veya seçilen (istem, ideal yanıt) çiftlerinden oluşan bir veri kümesi toplanır. Model, standart çapraz entropi kullanılarak bu gösteriler üzerinde ince ayar yapılır:

$$\mathcal{L}_{\text{SFT}}(\theta) = -\mathbb{E}_{(x,y)\sim\mathcal{D}_{\text{demo}}}\left[\log \pi_\theta(y \mid x)\right]$$

SFT modeli π_{SFT}, ham önceden eğitilmiş modele kıyasla RLHF için çok daha iyi bir başlangıç noktasıdır.

Aşama 2: Ödül Modeli Eğitimi

Bir dizi istem $\{x_i\}$ için π_{SFT} kullanılarak istem başına K yanıt üretilir ve bunlar insan etiketleyicilere ikili karşılaştırmalar olarak sunulur: "Hangi yanıt daha iyi, A mı B mi?"

Ödül modeli r_ϕ, bu tercihleri tahmin etmek üzere eğitilir. **Bradley-Terry** modeli (Bölüm 8) altında, y_w yanıtının y_l yanıtına tercih edilme olasılığı şöyledir:

$$P(y_w \succ y_l \mid x) = \sigma\left(r_\phi(x, y_w) - r_\phi(x, y_l)\right)$$

Ödül modeli, ikili sıralama kaybını minimize etmek üzere eğitilir:

$$\mathcal{L}_{\text{RM}}(\phi) = -\mathbb{E}_{(x,y_w,y_l)\sim\mathcal{D}_{\text{pref}}}\left[\log \sigma\left(r_\phi(x, y_w) - r_\phi(x, y_l)\right)\right]$$

Ödül modeli genellikle son katmanın yerine skaler bir başlık konularak SFT modelinden başlatılır.

Aşama 3: PPO ile Pekiştirmeli Öğrenme İnce Ayarı

Eğitilmiş bir ödül modeliyle, BDM'yi ince ayar yapmak için pekiştirmeli öğrenme kullanılabilir. Her istem x bir durumdur; her yanıt y, belirteç seçimlerinden oluşan bir yörüngedir; ödül ise $r_\phi(x, y)$'dir.

Optimizasyon hedefi, modelin SFT taban çizgisinden fazla sapmasını önlemek (ödül korsanlığına {cite}`krakovna2020specification,gao2023scaling` yol açacağından) için bir **KL ıraksaması cezası** içerir:

$$\max_\theta \mathbb{E}_{x\sim\mathcal{D},y\sim\pi_\theta(\cdot|x)}\left[r_\phi(x, y) - \beta \cdot \text{KL}\left[\pi_\theta(\cdot \mid x) \| \pi_{\text{SFT}}(\cdot \mid x)\right]\right]$$

β parametresi KL ceza şiddetini kontrol eder. Küçük β daha fazla optimizasyona izin verir ancak ödül korsanlığı riskini artırır; büyük β modeli SFT'ye yakın tutar ancak hizalama kazanımlarını sınırlar.

Yakınsal Politika Optimizasyonu (PPO) {cite}`schulman2017proximal`, ham politika gradyanı yöntemlerine kıyasla istikrarı nedeniyle bu aşama için standart algoritma olarak seçilir.

Basitleştirilmiş Bir RLHF Gösterimi

Tam RLHF hattı büyük ölçekli altyapı gerektirir. Aşağıdaki örnek, temel fikirleri küçük ölçekte göstermektedir.

```
import numpy as np
import torch
import torch.nn as nn
import torch.optim as optim
from torch.nn import functional as F

torch.manual_seed(42)
rng = np.random.default_rng(42)

# ----------------------------------------------
# Toy setup: responses are 4-dimensional vectors
# "Quality" is known analytically (sum of positive values)
# We simulate a reward model learning this from pairwise feedback
# ----------------------------------------------

class RewardModel(nn.Module):
    def __init__(self, d=4, hidden=32):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(d, hidden), nn.ReLU(),
            nn.Linear(hidden, hidden), nn.ReLU(),
            nn.Linear(hidden, 1)
        )
    def forward(self, x):
        return self.net(x).squeeze(-1)

def true_quality(x):
    """The hidden ground-truth reward function."""
    return x.sum(dim=-1) + 0.5 * (x ** 2).mean(dim=-1)

# Generate pairwise preference data
N_PAIRS = 500
X1 = torch.randn(N_PAIRS, 4)
X2 = torch.randn(N_PAIRS, 4)
q1, q2 = true_quality(X1), true_quality(X2)
# Human prefers X1 when q1 > q2 (with some noise)
noise = torch.randn(N_PAIRS) * 0.5
preferred_1 = ((q1 - q2 + noise) > 0).float()

# Train reward model
rm = RewardModel(d=4, hidden=32)
optimizer = optim.Adam(rm.parameters(), lr=3e-3)

losses = []
for epoch in range(200):
    r1 = rm(X1)
    r2 = rm(X2)
```

```
    # Bradley-Terry loss
    logit = r1 - r2
    loss = F.binary_cross_entropy_with_logits(logit, preferred_1)
    optimizer.zero_grad(); loss.backward(); optimizer.step()
    losses.append(loss.item())

# Evaluate: does the reward model agree with true quality?
X_eval = torch.randn(1000, 4)
with torch.no_grad():
    r_pred = rm(X_eval).numpy()
    r_true = true_quality(X_eval).numpy()

corr = np.corrcoef(r_pred, r_true)[0, 1]
print(f"Reward model correlation with true quality: {corr:.4f}")
print(f"Final training loss: {losses[-1]:.4f}")

import matplotlib.pyplot as plt
plt.figure(figsize=(8, 3))
plt.subplot(1, 2, 1)
plt.plot(losses, color='#2b3a8f', linewidth=1.5)
plt.xlabel("Epoch"); plt.ylabel("Pairwise loss")
plt.title("Reward Model Training")

plt.subplot(1, 2, 2)
plt.scatter(r_true[:200], r_pred[:200], alpha=0.4, s=15, color='#2b3a8f')
plt.xlabel("True quality"); plt.ylabel("Predicted reward")
plt.title(f"Reward Model vs. Truth (r={corr:.3f})")
plt.tight_layout()
plt.savefig('reward_model.png', dpi=150)
plt.show()
```

RLHF'deki Güçlükler

Ödül Korsanlığı

Temel bir başarısızlık modu: politika, gerçekten iyi davranışa karşılık gelmeyen ancak ödül modelinden yüksek ödül elde etmenin yollarını bulur. Örneğin bir BDM, doğru olmak yerine pohpohlamalar ve güven içeren ifadeler üretmeyi öğrenebilir (etiketleyiciler bunları yüksek değerlendirme eğilimindedir).

Ödül korsanlığının daha olası olduğu durumlar: - Ödül modeli yetersiz tercih verisiyle eğitilmiş olduğunda - Politikanın SFT taban çizgisinden çok uzaklaşmasına izin verildiğinde (küçük β) - PPO eğitimi sırasında ödül modeli dağılımı kaydığında

Azaltma stratejileri: KL cezası, yinelemeli ödül modeli eğitimi, çeşitli değerlendirme, anayasal yapay zeka kısıtlamaları.

Değerlendirici Önyargısı

İnsan etiketleyicilerin sistematik önyargıları vardır. Uzun yanıtları (ayrıntılılık önyargısı), güvenli tonlu metinleri (güven önyargısı) ve önceki inançlarıyla örtüşen yanıtları tercih etme

eğilimindedirler. Bu önyargılar ödül modeline yansır.

RLHF modellerinin ünlü pohpohlama başarısızlığı — modelin gerçek yerine kullanıcıların duymak istediğini söylemesi — kısmen, değerlendiricilerin kabul edici yanıtlara yönelik tercihinin bir sonucudur.

Ölçeklenebilir Denetim

Karmaşık görevlerde insanlar hangi yapay zeka yanıtının doğru olduğuna güvenilir biçimde karar veremez. İki uzun matematiksel kanıt veya iki kod uygulamasını karşılaştıran bir etiketleyici doğruluktan bağımsız olarak daha okunaklı olanı seçebilir. **Ölçeklenebilir denetim**, görev karmaşıklığı arttıkça değerlendirme prosedürlerinin güvenilir kalmasını sağlamaya yönelik açık bir araştırma sorunudur {cite}`bowman2022measuring`.

Anayasal Yapay Zeka (RLAIF)

Anthropic'te geliştirilen **Anayasal Yapay Zeka** {cite}`bai2022constitutional`, bir dizi ilkeyle (bir "anayasa") yönlendirilen tercih etiketleri üretmek için yapay zekanın kendisini kullanarak insan etiketleyicilere bağımlılığı azaltır. Süreç şöyledir:

1. Potansiyel olarak zararlı istemlere yanıtlar üret
2. Yapay zeka eleştirmenini kullanarak yanıtları anayasal ilkeler çerçevesinde değerlendir
3. Yapay zeka geri bildirimiyle yönlendirilen yanıtları revize et (RLAIF — Yapay Zeka Geri Bildiriminden Pekiştirmeli Öğrenme)
4. Yapay zeka tarafından üretilen tercihler üzerinde ödül modeli eğit
5. Bu ödül modelini kullanarak RLHF ile ince ayar yap

RLAIF, insan etiketlemesinden çok daha büyük ölçekte tercih verisi üretebilir ve ödül modeline kodlanan değerler üzerinde ayrıntılı kontrol sağlar.

> **See also:** Orijinal InstructGPT makalesi {cite}`ouyang2022training`, RLHF'nin BDM'lere ilk büyük ölçekli uygulamasını tanımlamaktadır. Derin pekiştirmeli öğrenme için temel RLHF çalışması: {cite}`christiano2017deep`. PPO: {cite}`schulman2017proximal`. Anayasal Yapay Zeka: {cite}`bai2022constitutional`.

Gösterilerden Öğrenme

Bir görev belirlemek güç ancak göstermek kolaysa, kural tanımlamak yerine örnekle öğretmek daha verimli olabilir. İnsan uzman, bir robot koluna bir nesneyi nasıl kavrayacağını gösterir; bir programcının IDE ile etkileşimi doğru düzenlemelerin bir dizisini sağlar; bir satranç büyükustası bir oyun oynar. **Gösterilerden öğrenme**, bu tür davranışsal verilerden bir politika çıkarır; elle hazırlanmış ödül işlevleri veya açık görev belirtimleri gerektirmez.

Davranışsal Klonlama

En basit yaklaşım **davranışsal klonlamadır (BC)**: gösteriyi denetimli veri olarak ele al ve durumlardan eylemlere bir eşleme öğren.

Uzman bir göstericiden elde edilen durum-eylem çiftlerinden oluşan $\mathcal{D} = \{(s_i, a_i)\}$ veri kümesi göz önüne alındığında, negatif log-olasılığı minimize ederek bir politika $\pi_\theta(a \mid s)$ uyarlanır:

$$\mathcal{L}_{\text{BC}}(\theta) = -\frac{1}{|\mathcal{D}|} \sum_{(s,a)\in\mathcal{D}} \log \pi_\theta(a \mid s)$$

Bu tam anlamıyla sıralı veriye uygulanan standart denetimli öğrenmedir.

Kovaryat Kayması Problemi

BC'nin temel bir zayıflığı vardır: eğitim ile dağıtım arasındaki **dağılım kayması**. Uzmanın gösterileri, uzman tarafından ziyaret edilen durumları kapsar. Ancak dağıtım sırasında öğrenilen politika biraz farklı kararlar alabilir ve uzmanın hiç ziyaret etmediği durumlara — politikanın herhangi bir denetimsiz kalacağı ve kötü performans sergileyebileceği durumlara — yol açabilir.

Önemli olan husus şudur: hatalar **birikerek büyür**. Küçük bir sapma alışılmadık bir duruma yol açar; biraz yanlış bir eylem çok daha alışılmadık bir duruma; bu böyle devam eder. Performans, bölüm uzunluğu T ve adım başına hata oranı ϵ olmak üzere $O(T^2\epsilon)$ oranında bozulur — bu, kehanet politikasının $O(T\epsilon)$ bozulmasından çok daha kötüdür {cite}`ross2010efficient`.

> **Örnek: Otonom Sürüş** :class: note
>
> İnsan sürüş verisiyle eğitilen şerit takibine yönelik bir davranışsal klonlama modeli, düz yollarda (eğitim dağılımına yakın durumlar) iyi performans gösterir. Ancak model biraz saptığı anda — hiçbir insan sürücünün içinde bulunmayacağı bir

durum, çünkü çoktan düzeltmiş olurlardı — onu yönlendirecek herhangi bir veri kalmaz ve araç yolun dışına çıkabilir.

```
DAgger Algoritması:
  Başlatma: D <- {} (boş veri kümesi)
  M uzman gösterisi üzerinde başlangıç politikası pi_1'i eğit

  yineleme i = 1, 2, ..., N için:
    1. {s_1, ..., s_t} durumlarını toplamak için pi_i'yi ortamda çalıştır
    2. Her ziyaret edilen durum için uzmanı sorgula: a_t = pi*(s_t)
    3. Birleştir: D <- D u {(s_1, a_1), ..., (s_t, a_t)}
    4. D üzerinde denetimli öğrenmeyle pi_{i+1}'i eğit
```

DAgger, $O(T\epsilon)$ pişmanlık elde eder — kehanet politikasıyla aynı — çünkü eğitim dağılımı, dağıtım dağılımıyla eşleşecek şekilde yakınsarlar.

Temel gereklilik, uzmanın herhangi bir durumda sorgulanabilmesidir; uzmanın doğal olarak hiç ziyaret etmeyeceği durumlar dahil. Bu, simülasyonda uygulanabilirdir (robotun alışılmadık bir yapılandırmadan düzeltmesini uzmanın yapmasını istemek), ancak gerçek fiziksel sistemlerde zorlayıcı veya güvensiz olabilir.

Ters Pekiştirmeli Öğrenme

Bazen uzmanın davranışı, taklit edilecek bir eylem dizisi olarak değil, bilinmeyen bir ödül işlevini optimize etmenin sonucu olarak daha iyi anlaşılır. **Ters Pekiştirmeli Öğrenme (IRL)** {cite}`ng2000algorithms`, bu gizli ödül işlevini gösterilerden kurtarır.

$\tau = \{(s_1, a_1), \ldots, (s_T, a_T)\}$ gösterileri göz önüne alındığında, IRL uzmanın politikasının R altında optimal olduğu bir $R(s, a)$ ödül işlevi bulur.

IRL'nin BC'ye göre çekiciliği: gerçek ödül işlevini kurtarırsak, bunu yeni ortamlarda, farklı dinamiklerle veya iyileştirilmiş planlayıcılarla yeniden optimize edebiliriz — gösterilen senaryoların çok ötesine genelleşiriz.

Maksimum Entropi IRL

MaxEnt IRL {cite}`ziebart2008maximum`, IRL belirsizlik problemini (herhangi bir gösteri kümesiyle tutarlı çok sayıda ödül işlevi vardır) ele alır: gösterilen davranışla tutarlı olmakla birlikte *maksimum entropi*ye sahip yörüngeler dağılımına yol açan ödül işlevini seçer. Yörüngeler şu şekilde dağılır:

$$P(\tau \mid R) \propto \exp\left(\sum_t R(s_t, a_t)\right)$$

Öğrenme hedefi, uzmanın gözlemlenen özellik beklentilerini $\mu_E = \mathbb{E}_{\tau\sim\pi^*}[\phi(\tau)]$, modelin özellik beklentileriyle $\mu_\theta = \mathbb{E}_{\tau\sim\pi_\theta}[\phi(\tau)]$ eşleştirir.

GAIL: Üretici Çekişmeli Taklit Öğrenmesi

GAIL {cite}`ho2016generative`, ödül işlevi öğrenmeyi tamamen atlayarak uzmanın durum-eylem dağılımını doğrudan eşleştirmek için GAN benzeri bir formülasyon kullanır.

D_ψ ayrımcısı, uzman durum-eylem çiftlerini $(s, a) \sim \pi^*$ ile politika durum-eylem çiftlerini $(s, a) \sim \pi_\theta$ ayırt etmek üzere eğitilir:

$$\mathcal{L}_D = -\mathbb{E}_{\pi^*}[\log D_\psi(s, a)] - \mathbb{E}_{\pi_\theta}[\log(1 - D_\psi(s, a))]$$

Üretici (politika π_θ), ayrımcıyı kandırmak — yani uzmanınkine benzeyen durum-eylem çiftleri üretmek — üzere eğitilir. Ayrımcının çıktısı $\log D_\psi(s, a)$, politika için bir ödül sinyali olarak işlev görür.

GAIL, sürekli kontrol kıyaslamalarında BC'den çok daha az gösteriyle uzman düzeyinde performans elde eder ve karmaşık ortamlarda MaxEnt IRL'den daha iyi genelleşir.

Doğal Dil İşlemede Davranışsal Klonlama: Pratik Bir Örnek

```python
import numpy as np
import torch
import torch.nn as nn
from torch.utils.data import DataLoader, TensorDataset

torch.manual_seed(42)

# ----------------------------------------------
# Toy NLP task: rewriting sentences to be more formal
# We simulate this as a simple sequence transformation
# In practice: fine-tuning a seq2seq model on expert rewrites
# ----------------------------------------------

class SimpleSeq2Seq(nn.Module):
    def __init__(self, vocab_size=100, embed_dim=32, hidden_dim=64):
        super().__init__()
        self.embed = nn.Embedding(vocab_size, embed_dim, padding_idx=0)
        self.encoder = nn.GRU(embed_dim, hidden_dim, batch_first=True)
        self.decoder = nn.GRU(embed_dim, hidden_dim, batch_first=True)
        self.proj = nn.Linear(hidden_dim, vocab_size)
        self.hidden_dim = hidden_dim

    def forward(self, src, tgt):
        src_emb = self.embed(src)
        _, hidden = self.encoder(src_emb)
        tgt_emb = self.embed(tgt)
        out, _ = self.decoder(tgt_emb, hidden)
        return self.proj(out)

# Generate synthetic demonstration data
VOCAB = 100
```

```
rng = np.random.default_rng(42)
N, SEQ_LEN = 1000, 12

src_seqs = torch.tensor(rng.integers(1, VOCAB, (N, SEQ_LEN)), dtype=torch.long)
# "Expert" transformation: shift tokens by 1 (toy formalization)
tgt_seqs = torch.clamp(src_seqs + 1, 1, VOCAB - 1)
tgt_in  = torch.cat([torch.ones(N, 1, dtype=torch.long), tgt_seqs[:, :-1]], dim=1)

dataset = TensorDataset(src_seqs, tgt_in, tgt_seqs)
loader = DataLoader(dataset, batch_size=64, shuffle=True)

model = SimpleSeq2Seq(vocab_size=VOCAB)
optimizer = torch.optim.Adam(model.parameters(), lr=1e-3)
criterion = nn.CrossEntropyLoss(ignore_index=0)

# Behavioral cloning training
train_losses = []
for epoch in range(20):
    epoch_loss = 0
    for src, tgt_i, tgt_o in loader:
        logits = model(src, tgt_i)
        loss = criterion(logits.reshape(-1, VOCAB), tgt_o.reshape(-1))
        optimizer.zero_grad(); loss.backward(); optimizer.step()
        epoch_loss += loss.item()
    train_losses.append(epoch_loss / len(loader))

print(f"Initial loss: {train_losses[0]:.3f}")
print(f"Final loss:   {train_losses[-1]:.3f}")

# Evaluate: check token accuracy on held-out examples
model.eval()
with torch.no_grad():
    src_test = src_seqs[-100:]
    tgt_test_in = tgt_in[-100:]
    tgt_test_out = tgt_seqs[-100:]
    logits = model(src_test, tgt_test_in)
    preds = logits.argmax(dim=-1)
    acc = (preds == tgt_test_out).float().mean().item()
    print(f"Token accuracy on held-out set: {acc:.3f}")
```

Taklit Öğrenmesi Yöntemlerinin Karşılaştırması

Yöntem	Ödül gerektirir mi?	Uzman çevrimiçi sorgulanır mı?	Yeni dinamiklere genelleşir mi?	Karmaşıklık
Davranışsal Klonlama	Hayır	Hayır	Zayıf (dağılım kayması)	Düşük
DAgger	Hayır	Evet	Orta	Orta
MaxEnt IRL	Kurtarır	Hayır	İyi	Yüksek

Yöntem	Ödül gerektirir mi?	Uzman çevrimiçi sorgulanır mı?	Yeni dinamiklere genelleşir mi?	Karmaşıklık
GAIL	Hayır	Hayır	İyi	Yüksek

Uygulamalar

Robotik. Robotlara nesneleri tutmayı, ortamlarda gezinmeyi veya ev görevlerini gerçekleştirmeyi öğretme. Fiziksel gösteriler, uzaktan kumanda veya kinestetik öğretim yoluyla toplanır.

Otonom sürüş. ALVINN {cite}`pomerleau1989alvinn` ve NVIDIA'nın DAVE gibi erken otonom sürüş sistemleri, insan sürüş verisiyle davranışsal klonlamaya büyük ölçüde güvendi.

Oyun yapay zekası. Taklit öğrenmesi, RL ince ayarından önce ajanları önyüklemek amacıyla insan oynanışını kullanır. AlphaStar, pekiştirmeli öğrenmeden önce insan oyun tekrarları üzerinde eğitildi; bu yaklaşım, insan düzeyinde gösteriler mevcut olduğunda yaygındır.

Kod üretimi. Yüksek kaliteli kod gösterileri (GitHub Copilot, Codex) üzerinde dil modellerinin ince ayarlanması bir davranışsal klonlama biçimidir.

Klinik karar desteği. Karmaşık protokoller için uzman hekim karar dizilerinden öğrenme.

> **See also:** Temel BC/DAgger analizi: {cite}`ross2011reduction`. MaxEnt IRL: {cite}`ziebart2008maximum`. GAIL: {cite}`ho2016generative`. Taklit öğrenmesinin kapsamlı bir araştırması için bkz. {cite}`osa2018algorithmic`.

Karşılaştırma ve Sıralamalardan Öğrenme

İnsanlardan bir çıktıya mutlak bir kalite puanı ataması istemek güçtür. Bu makalenin sayısal kalitesi 1'den 10'a kadar bir ölçekte nedir? Soru kötü tanımlanmıştır: insanların kararlı bir iç ölçeği yoktur ve puanları çapalama, bağlam ve yorgunluktan büyük ölçüde etkilenir.

İnsanlardan iki çıktıyı *karşılaştırması* istemek çok daha kolaydır: hangi makale daha iyi, A mı B mi? Karşılaştırmalı yargılar daha tutarlı, daha güvenilir ve mutlak derecelendirmelerden çok insan tercihlerini daha doğrudan ortaya çıkarır. Bu bölüm, karşılaştırma ve sıralamalardan öğrenmenin matematiksel temellerini ve pratik uygulamalarını ele almaktadır.

Karşılaştırmalar Neden Derecelendirmelerden Daha İyidir?

Psikolojik Dayanak

Karşılaştırmalı yargıların üstünlüğü, psikometride uzun bir geçmişe sahiptir. Thurstone'un Karşılaştırmalı Yargı Yasası {cite}`thurstone1927law` (1927), insanlar tutarsız mutlak yargılara sahip olsa bile göreli yargılarının tutarlı bir olasılıksal yasayı izlediğini göstermiştir. Karşılaştırmalar, insanların mutlak kalibrasyondan çok *göreli* algıda çok daha iyi olduğu gerçeğinden yararlanır.

İstatistiksel Verimlilik

Her ikili karşılaştırma, iki öğenin kalite ölçeğindeki *göreli* konumları hakkında bilgi sağlar. K öğeyle $K-1$ karşılaştırma tüm öğeleri sıralayabilir; en üst öğeyi bulmak için yalnızca $O(\log K)$ karşılaştırma gerekir. Mutlak derecelendirmeler genellikle aynı kesinliğe ulaşmak için daha fazla yargı gerektirir.

Ölçeklenebilirlik

Üretici modeller için farklı çıktıların sayısı pratikte sonsuzdur. Bir çıktıyı mutlak olarak derecelendirmek, tüm çıktılar genelinde paylaşılan bir ölçek oluşturmayı gerektirir; çıktıları karşılaştırmak yalnızca birbirlerine doğal olarak kalibre olan yerel, göreli yargılar gerektirir.

Bradley-Terry Modeli

İkili karşılaştırmalar için baskın olasılıksal model, **Bradley-Terry (BT) modelidir** {cite}`bradley1952rank`. Her i öğesinin gizli bir kalite puanı $\alpha_i \in \mathbb{R}$ vardır. Doğrudan bir karşılaştırmada i öğesinin j

öğesine tercih edilme olasılığı şöyledir:

$$P(i \succ j) = \frac{e^{\alpha_i}}{e^{\alpha_i} + e^{\alpha_j}} = \sigma(\alpha_i - \alpha_j)$$

burada σ lojistik sigmoid'dir. Bu, i öğesinin algılanan kalitesinin $\alpha_i + \epsilon$ olduğunu varsaymaya eşdeğerdir; ϵ ise standart lojistik gürültü terimidir.

Tanımlanabilirlik

BT modeli çeviri anlamında tanımlanabilirdir: α bir çözümse, herhangi bir c sabiti için $\alpha + c$ de öyledir. Standart bir kural, bir puanı sabitlemek (örneğin $\alpha_0 = 0$) veya $\sum_i \alpha_i = 0$ kısıtlamaktır. Puanlar yalnızca **karşılaştırma grafiği** (düğümler = öğeler, kenarlar = gözlemlenen çiftler) **bağlantılı** olduğunda tanımlanabilir — grafik bağlantısız bileşenlere sahipse, bileşenler arasındaki göreli puanlar tanımsızdır.

Parametre Tahmini

$y_{ij} = 1$ ise i'nin j'ye tercih edildiği ikili karşılaştırmalar veri kümesi $\mathcal{D} = \{(i, j, y_{ij})\}$ verildiğinde, log-olasılık şöyledir:

$$\mathcal{L}(\alpha) = \sum_{(i,j,y_{ij}) \in \mathcal{D}} \left[y_{ij} \log \sigma(\alpha_i - \alpha_j) + (1 - y_{ij}) \log \sigma(\alpha_j - \alpha_i) \right]$$

Bu, α'nın içbükey bir işlevidir ve gradyan çıkışı veya Newton yöntemiyle maksimize edilebilir.

```python
import numpy as np
from scipy.optimize import minimize
from scipy.special import expit  # sigmoid

rng = np.random.default_rng(42)

# ----------------------------------------------
# Simulate Bradley-Terry: 8 items with true quality scores
# Generate pairwise comparisons and recover the scores
# ----------------------------------------------

N_ITEMS = 8
true_alpha = rng.normal(0, 1, N_ITEMS)
print(f"True quality ranking: {np.argsort(true_alpha)[::-1]}")

# Generate comparisons: every pair compared 5 times
comparisons = []
for i in range(N_ITEMS):
    for j in range(i + 1, N_ITEMS):
        for _ in range(5):
            p_i_wins = expit(true_alpha[i] - true_alpha[j])
            winner = i if rng.random() < p_i_wins else j
            loser  = j if winner == i else i
            comparisons.append((winner, loser))

print(f"Total comparisons: {len(comparisons)}")
```

```python
def neg_log_likelihood(alpha, comparisons):
    """Bradley-Terry negative log-likelihood."""
    alpha = np.array(alpha)
    loss = 0.0
    for winner, loser in comparisons:
        log_prob = np.log(expit(alpha[winner] - alpha[loser]) + 1e-10)
        loss -= log_prob
    return loss

def neg_grad(alpha, comparisons):
    alpha = np.array(alpha)
    grad = np.zeros(len(alpha))
    for winner, loser in comparisons:
        p = expit(alpha[winner] - alpha[loser])
        grad[winner] -= (1 - p)
        grad[loser]  -= (-p)
    return grad

# Fix alpha[0] = 0 to resolve scale ambiguity
result = minimize(
    lambda a: neg_log_likelihood(np.concatenate([[0.0], a]), comparisons),
    x0=np.zeros(N_ITEMS - 1),
    jac=lambda a: neg_grad(np.concatenate([[0.0], a]), comparisons)[1:],
    method='L-BFGS-B'
)
est_alpha = np.concatenate([[0.0], result.x])

# Compare true vs estimated ranking
true_rank = np.argsort(true_alpha)[::-1]
est_rank  = np.argsort(est_alpha)[::-1]

print(f"\nTrue ranking (item indices): {true_rank}")
print(f"Estimated ranking:           {est_rank}")
rank_corr = np.corrcoef(true_alpha, est_alpha)[0, 1]
print(f"Correlation with true scores: {rank_corr:.4f}")
```

Thurstone Modeli

Thurstone modeli {cite}`thurstone1927law`, lojistik yerine Gaussian gürültü kullanan Bradley-Terry ile yakından ilişkilidir:

$$P(i \succ j) = \Phi\left(\frac{\alpha_i - \alpha_j}{\sqrt{2}\sigma}\right)$$

burada Φ standart normal kümülatif dağılım fonksiyonudur. $\sigma = 1/\sqrt{2}$ olduğunda bu, küçük bir ölçekleme farkıyla BT'ye eşdeğer olur. Pratikte iki model neredeyse özdeş sonuçlar verir.

Sıralama Birleştirme

Her açıklayıcı K öğenin tam bir sıralamasını sağladığında (ikili karşılaştırmalar yerine) problem **sıralama birleştirmedir**: birden fazla sıralı listeyi bir uzlaşı sıralamasında birleştirmek.

Borda sayımı: Her öğe, her açıklayıcının sıralamasında kendisinin altında sıralanan öğe sayısına eşit bir puan alır. Puanlar açıklayıcılar genelinde toplanır. Basit ve sağlamdır.

Kemeny–Young: Her açıklayıcının sıralamasıyla ikili anlaşmazlıkların (Kendall tau mesafesi) toplamını minimize eden sıralamayı bul. Bu, büyük K için NP-zordur ancak küçük kümeler için uygulanabilirdir.

RankNet / ListNet: Sıralı listelerden bir puanlama işlevi öğrenen ve görülmemiş öğelere genelleşmeyi sağlayan sinir ağı tabanlı yaklaşımlar.

Düello Haydutları

Çevrimiçi tercih öğrenmesinde, öğeler bir akış hâlinde gelir ve hangi çiftlerin karşılaştırılacağına karar verilmesi gerekir; bu durumda keşfetme (bilinmeyen öğeler hakkında öğrenme) ile sömürme (yüksek kaliteli öğeleri sunma) arasında denge kurulması zorunludur. Bu, **düello haydut** problemidir {cite}`yue2009interactively`.

Temel algoritmalar: - **Doublerlar:** Bir şampiyon öğe belirler; rastgele rakiplerle karşılaştırır - **RUCB (Göreli Üst Güven Sınırı):** Her öğenin diğer her öğeyi yenme olasılığı için ÜGS tarzı güven aralıkları hesaplar - **MergeRank:** Turnuva tarzı karşılaştırmayı ÜGS ile birleştirir

Düello haydutları, çevrimiçi öneri sistemlerinde (örtük geri bildirim göz önüne alındığında sonraki hangi makale gösterilmeli) ve RLHF veri toplama için etkileşimli tercih açımlamasında kullanılır.

Dil Modelleri için Tercih Öğrenmesi

RLHF bağlamında (Bölüm 6), ödül modelini eğitmek için Bradley-Terry modeli kullanılır. Önemli bir varyant, RLHF hedefinin ayrı bir ödül modeli eğitilmeksizin tercih verilerinden doğrudan optimize edilebileceğini gösteren **Doğrudan Tercih Optimizasyonu (DPO)** {cite}`rafailov2023direct`'tur:

$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{(x,y_w,y_l)\sim\mathcal{D}}\left[\log\sigma\left(\beta\log\frac{\pi_\theta(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta\log\frac{\pi_\theta(y_l \mid x)}{\pi_{\text{ref}}(y_l \mid x)}\right)\right]$$

DPO, tam RLHF'den daha basittir (PPO eğitim döngüsü yok, ödül modeli yok) ve pek çok kıyaslamada karşılaştırılabilir veya daha iyi sonuçlar elde eder {cite}`rafailov2023direct`. Talimat takibi ince ayarı için PPO tabanlı RLHF'ye yaygın biçimde benimsenen bir alternatif hâline gelmiştir; ancak her iki yaklaşım da aktif olarak kullanılmakta ve görece güçleri göreve bağlı olarak değişmektedir.

Yüksek Kaliteli Tercih Verisi Toplamak

Tercih verisi kalitesi, ödül modeli kalitesini belirler. Temel değerlendirmeler:

İstem çeşitliliği. Tercih verisi, modelin dağıtımda karşılaşacağı istemlerin tam dağılımını kapsamalıdır. Kapsam boşlukları, bu bölgelerde güvenilmez ödül modeli davranışına yol açar.

Yanıt çeşitliliği. Çok benzer iki yanıtı karşılaştırmak az bilgi sağlar. Karşılaştırılan yanıtlar, açıklayıcıların net bir tercihe sahip olabilmesi için yeterince farklılaşmalıdır.

Açıklayıcı anlaşması. Düşük açıklayıcılar arası anlaşma, karşılaştırma ölçütlerinin belirsiz olduğuna işaret eder. Anlaşmayı (Cohen'in κ'sı) ölçün ve kabul edilebilir eşiklerin altında kaldığında kılavuzları revize edin.

Kalibrasyon. Açıklayıcılar, bir yanıtın neden daha iyi olduğunu *anlamalıdır*: yararlılık, doğruluk, güvenlik, üslup? Birden fazla ölçütü bir araya getiren görevler tutarsız tercihler üretme eğilimindedir. Her ölçüt için tercihleri ayrı ayrı toplamak çoğu zaman daha iyidir.

> **See also:** Bradley-Terry modeli: {cite}`bradley1952rank`. Thurstone: {cite}`thurstone1927law`. Düello haydutları: {cite}`yue2009interactively`. Doğrudan Tercih Optimizasyonu (DPO): {cite}`rafailov2023direct`.

Doğal Dil İşlemede Döngüde İnsan

Doğal dil, HITL ML'nin tartışmasız en büyük etkiyi yarattığı alan — ve en derin kavramsal güçlüklerin ortaya çıktığı yerdir. Dil özünde toplumsal bir nitelik taşır: anlamı insan toplulukları inşa eder, edimbilimi bağlam ve amaca bağlıdır ve kalitesi yalnızca insan okuyucular tarafından değerlendirilebilir. Ancak bu durum aynı zamanda şu anlama gelir: doğal dil işleme açıklaması yalnızca gözlemleri toplamak değildir. Kategorileri *inşa etmektir*.

Doğal Dil İşleme Açıklamasındaki Kurucu Problem

Tıbbi görüntülemede bir gerçek zemin vardır: tümör var ya da yok. Radyologun etiketi belirsiz olabilir, ancak gerçek bir şeyi yansıtmaya çalışır. Doğal dil işleme açıklaması çoğunlukla temelden farklıdır. Bir açıklayıcı bir twiTi "toksik" olarak işaretlediğinde, tweet'te tespit etmeye çalıştığımız toksik bir molekül yoktur. **Etiket kategoriyi inşa eder.**

Bunun çoğunlukla yeterince anlaşılmayan derin sonuçları vardır:

Açıklama işgücü olguyu tanımlar. "Saldırgan dil" için bir etiket şeması, onu tasarlayanların ve uygulayanların duyarlılıklarını kodlar. Tek bir demografik arka plandan İngilizce konuşan açıklayıcılardan oluşan ve kurumsal politika ekibinin hazırladığı kılavuzlar doğrultusunda çalışan bir ekip, o ekibin saldırganlık anlayışını yansıtan bir veri kümesi üretir — evrensel bir insan standardı değil. Bu tür verilerle eğitilen modeller aynı örtük sınırlara sahip olacaktır.

Kılavuzlar, bunu kabul edip etmeseler de teoriktir. Her açıklama şeması, ontoloji hakkında iddialar içerir. "İroni" ve "alaycılığın" aynı sınıf olduğuna karar vermek teorik bir iddiadır; tarafsız bir kolaylık değil. "Öfkeyi" "haklı öfke" ile "düşmanca öfkeyi" ayırt etmek yerine tek bir sınıf olarak etiketlemeye karar vermek, aşağı akış görevi için önem taşıyan bir ayrımı ortadan kaldırır. Bu kararlar üretim baskısı altında alınır ve nadiren yeniden gözden geçirilir.

Zaman içinde etiket istikrarsızlığı. Toplumsal dil gelişir. 2018'de eğitilmiş bir toksisite modeli, 2024 içeriğini yanlış sınıflandıracaktır; istatistiksel olarak yetersiz eğitildiği için değil, belirli terimlerin toplumsal anlamı değiştiği için. Doğal dil işleme açıklaması statik bir dağılımdan örnekleme değildir — etiketleme eyleminin kısmen oluşturmaya katkıda bulunduğu hareketli bir hedeften örneklemektir.

:::{admonition} Açıklama Yapay Ürün Problemi :class: important

Geva ve diğerleri {cite}`geva2019annotator`, Doğal Dil Çıkarımı (NLI) veri kümelerinin açıklama sürecinin kendisi tarafından öğretilen sistematik yapay ürünler içerdiğini gösterdi. Verilen bir öncülü için "çıkarım" hipotezleri yazmakla görevlendirilen açıklayıcılar belirli sözdizimsel kalıplar kullanma eğilimindedir; "çelişki" hipotezleri yazanlar başkalarını kullanır. Modeller, amaçlanan anlamsal ilişki yerine bu yapay ürünlere dayanarak sınıflandırmayı öğrenir — altta yatan doğal dil işleme görevini değil, açıklama görevini çözerler.

Bu özensizlik değildir. İnsanların bir etikete uyacak örnekler oluşturmasının doğasında bulunan bir sonuçtur. HITL süreci, veriye hiçbir zaman amaçlanmamış sistematik bir sinyal enjekte eder. :::

Metin Sınıflandırması Açıklaması

En basit doğal dil işleme açıklama görevi, bir metin belgesine kategori atamaktır. Duygu analizi, konu sınıflandırması, niyet tespiti ve spam filtreleme sınıflandırma görevleridir.

Metin sınıflandırmasına özgü güçlükler:

Öznellik. "Toksik" veya "saldırgan" gibi kategoriler özünde özneldir ve kültürel bağlamlar, açıklayıcı arka planları ve platform bağlamına göre farklılık gösterir. Açıklayıcılar arasında saldırganlık algıları demografiye göre önemli ölçüde farklılaşır — doğruluk için doğrudan çıkarımları olan bir gerçek {cite}`blodgett2020language`.

Etiket belirsizliği. Pek çok belge birden fazla kategoriye girer ya da sınırda yer alır. %60 olumlu ve %40 olumsuz olan bir yorum gerçek anlamda belirsizdir; yanlış etiketlenmemiştir. Tek bir etiketi zorlamak gerçek bilgiyi atar (yumuşak etiketler ve açıklayıcı anlaşmazlığı üzerine bkz. Bölüm 13).

Etiket ayrıntısı. 2 sınıflı bir duygu modeli sosyal medya izleme için yeterli olabilir; 7 puanlı bir ölçek ürün geri bildirimi analizi için gerekli olabilir. Doğru ayrıntı düzeyi aşağı akış görevine bağlıdır, ancak genellikle açıklamadan önce sabitlenir — yetersiz veriyle alınan sonuçlu bir tasarım kararı.

Adlandırılmış Varlık Tanıma

Adlandırılmış Varlık Tanıma (NER) açıklaması, metin parçalarını tanımlamayı ve bir varlık türü (KİŞİ, KURULUŞ, KONUM vb.) atamayı gerektirir. Birkaç nedenle belge sınıflandırmasından daha karmaşıktır:

Parça sınırları belirsizdir. "Apple CEO Tim Cook açıkladı…" ifadesinde KİŞİ varlığı "Tim Cook" mu yoksa "Apple CEO Tim Cook" mu kapsar? Kılavuzlar bu vakaları açıkça ele almalıdır ve parçalar üzerindeki açıklayıcılar arası anlaşma tutarlı olarak türler üzerindeki anlaşmadan düşüktür.

Tür ataması dünya bilgisi gerektirir. "Apple" bir bağlamda KURULUŞ, diğerinde ÜRÜN ve "elmalı pasta"da muhtemelen hiçbiridir. Açıklayıcıların doğru tür atamaları yapabilmesi için yeterli alan bilgisi gerekir.

İç içe geçmiş varlıklar. "University of California, Berkeley" ifadesi KONUM içinde iç içe geçmiş KURULUŞ içerir. Standart BIO etiketlemesi iç içe geçmiş varlıkları temsil edemez; daha karmaşık şemalar (örneğin BIOES veya grafik tabanlı biçimler) gerekir.

Açıklama verimliliği. Bir taban Adlandırılmış Varlık Tanıma modeli ile ön açıklama, açıklayıcıların sıfırdan açıklama yerine tahminleri düzeltmesine olanak tanıyarak açıklamayı önemli ölçüde hızlandırır. Klinik Adlandırılmış Varlık Tanıma üzerine yapılan bir çalışmada %30–60 verim artışları gözlemlenmiştir {cite}`lingren2014evaluating`; bu tür kazanımların büyüklüğü taban model kalitesine ve alana göre önemli ölçüde değişir.

İlişki Çıkarımı ve Anlamsal Açıklama

Varlıkları tanımlamanın ötesinde, ilişki çıkarımı varlıklar arasındaki *ilişkileri* açıklamayı gerektirir:

- Açıklayıcıların her iki varlığı ve bunları birbirine bağlayan yüklemi anlaması gerekir
- İlişki türlerinin karmaşık anlamsal ayrımları vardır (ÇALIŞIYOR_AT ile İSTİHDAM_EDİLEN ile KURDU)
- Negatif örnekler (ilişkisi olmayan varlık çiftleri) pozitif örneklerden çok daha yaygındır

İlişki çıkarımı için açıklayıcılar arası anlaşma, sınıflandırma görevlerinden düşük olma eğilimindedir. İyi tanımlanmış şemalar için κ değerleri 0,65–0,80 aralığında rapor edilmektedir {cite}`pustejovsky2012natural`; karmaşık anlamsal ilişkiler (olay nedenselliği, zamansal ilişkiler) için anlaşma şema tasarımına ve açıklayıcı eğitimine bağlı olarak önemli ölçüde düşebilir.

Makine Çevirisi Sonrası Düzenleme (MCSD)

Makine çevirisi sonrası düzenleme, HITL doğal dil işlemenin olgun bir biçimidir. İnsan çevirmen, sıfırdan çevirmek yerine bir makine çevirisi sisteminin çıktısını düzeltir:

Hafif sonrası düzenleme (HSD): Yalnızca kritik hatalar düzeltilir. Çeviri kalitesi gereksinimlerinin ılımlı olduğu durumlara uygundur.

Tam sonrası düzenleme (TSD): Çıktı yayın kalitesine getirilir. Düzenlenen çıktı genellikle sonraki makine çevirisi iyileştirmesi için eğitim verisi hâline gelir — gerçek bir döngüde insan iyileştirme döngüsü.

HTER (İnsan Hedefli Çeviri Düzenleme Oranı): Makine çevirisi çıktısı ile sonrası düzenlenmiş çeviri arasındaki düzenleme mesafesini cümle uzunluğuna göre normalleştirilmiş olarak ölçen bir ölçüt {cite}`graham2015accurate`. Pratik bir kural olarak, yaklaşık 0,3'ün altındaki HTER genellikle iyi makine çevirisi çıktısı olarak değerlendirilir; 0,5'in üzerinde sıfırdan çeviri daha hızlı olabilir — ancak bu eşikler alana ve dil çiftine göre değişir.

Konuşma Yapay Zekası ve Diyalog Açıklaması

Diyalog açıklaması zamansal yapıyı beraberinde getirir:

- **Tur düzeyinde açıklama:** her turu etiketle (niyet, duygu, kalite)
- **Diyalog düzeyinde açıklama:** genel tutarlılığı, görev başarısını, kullanıcı memnuniyetini değerlendir
- **Etkileşim izi açıklaması:** konuşmadaki belirli başarısızlık anlarını belirle

HITL, özellikle diyalogda önem taşır; çünkü model başarısızlıkları çoğunlukla ince ve birikimlidir: 3. turdaki olgusal bir hata, 7. turda belirginleşmeyebilir. Konuşmaları izleyen insan açıklayıcılar, otomatik ölçütlerin tamamen kaçırdığı bu uzun mesafeli başarısızlık örüntülerini belirleyebilir.

Programatik Etiketleme ve Zayıf Denetim

Etiketli veri kıt olduğunda, **zayıf denetim** ölçekli olasılıksal etiketler oluşturmak için birden fazla gürültülü, örtüşen etiketleme işlevinin kullanılmasına olanak tanır. **Snorkel** {cite}`ratner2017snorkel` standart çerçevedir:

```
import numpy as np
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import f1_score

rng = np.random.default_rng(42)

# ---------------------------------------------------------
# Toy weak supervision: sentiment classification
# 5 labeling functions (LFs) with different coverage/accuracy
# Label: +1 (positive), -1 (negative), 0 (abstain)
# ---------------------------------------------------------

N = 1000
true_labels = rng.choice([-1, 1], size=N)
X_features = np.column_stack([
    true_labels * 0.8 + rng.normal(0, 0.5, N),
    rng.normal(0, 1, N),
    rng.normal(0, 1, N),
])

def make_lf(accuracy, coverage, seed):
    rng_lf = np.random.default_rng(seed)
    votes = np.zeros(N, dtype=int)
    active = rng_lf.random(N) < coverage
    correct = rng_lf.random(N) < accuracy
    votes[active & correct]  = true_labels[active & correct]
    votes[active & ~correct] = -true_labels[active & ~correct]
    return votes

LFs = np.column_stack([
    make_lf(accuracy=0.85, coverage=0.60, seed=1),
    make_lf(accuracy=0.78, coverage=0.45, seed=2),
    make_lf(accuracy=0.70, coverage=0.80, seed=3),
    make_lf(accuracy=0.90, coverage=0.30, seed=4),
    make_lf(accuracy=0.60, coverage=0.90, seed=5),
])

def majority_vote(LF_matrix):
    labels = []
    for i in range(LF_matrix.shape[0]):
        votes = LF_matrix[i][LF_matrix[i] != 0]
        labels.append(0 if len(votes) == 0 else int(np.sign(votes.sum())))
    return np.array(labels)

mv_labels = majority_vote(LFs)
covered = mv_labels != 0
```

```
print(f"Coverage:                    {covered.mean():.1%}")
print(f"MV accuracy (covered):       {(mv_labels[covered] == true_labels[covered]).mean():.3f

X_train, y_train = X_features[covered], mv_labels[covered]
X_test,  y_test  = X_features[~covered], true_labels[~covered]

if len(X_train) > 10 and len(X_test) > 10:
    clf = LogisticRegression().fit(X_train, y_train)
    preds = clf.predict(X_test)
    print(f"F1 on uncovered test set:    {f1_score(y_test, preds):.3f}")
```

Dil Modelleri için RLHF: Açıklama Gerçekliği

Bölüm 6, RLHF'yi teknik olarak ele aldı. Doğal dil işleme perspektifinden, açıklama görevi dışarıdan göründüğünden daha güçtür.

Açıklayıcıların gerçekte ne yapması isteniyor — iki model çıktısını karşılaştırmak ve hangisinin "daha iyi" olduğunu belirtmek — basit görünür. Pratikte, "daha iyi" açıklayıcıların kişisel sezgileri kullanarak çözdüğü eksik belirtilmiş bir kavramdır. Kimisi akıcılığa büyük ağırlık verir; kimisi olgusal doğruluğa; kimisi ayrıntılılığı cezalandırır. Sıkı kılavuzlar olmadan, ortaya çıkan tercih veri kümesi, soyut insan değerlerini değil, istihdam edilen açıklama işgücünün belirli çözüm stratejilerini yansıtır.

Temel açıklama boyutları şunlardır:

- *Yararlılık:* Yanıt soruyu iyi yanıtlıyor mu? Bilgilendirici, açık ve uygun ölçüde ayrıntılı mı?
- *Olgusallık:* Yanıt olgusal olarak doğru mu? Bu, değerlendiricilerin alan bilgisine sahip olmasını gerektirir — genelci açıklayıcılar uzman iddiaları doğrulayamadığından ölçekte ciddi kalite sorunları yaratır.
- *Zararsızlık:* Yanıt toksik, önyargılı, zararlı veya uygunsuz içerikten kaçınıyor mu? "Zararlı"nın bağlama bağlı olduğu ve kültürler, zaman ve platform bağlamı genelinde değiştiği göz önüne alındığında bu yargılar ayrıntılı kılavuzlar gerektirir.
- *Kalibrasyon:* Yanıt uygun belirsizliği ifade ediyor mu? Açıklayıcılar sistematik olarak güvenli tonda yanıtları tercih etmektedir; bu durum, uygun epistemik alçakgönüllülüğe karşı bir ödül sinyali yaratır.

Ölçütler arasındaki etkileşim karmaşıktır: tehlikeli bir soruya maksimum düzeyde yararlı yanıt, maksimum düzeyde zararlı olabilir. Kılavuzlar, birbiriyle rekabet eden ölçütler arasında nasıl denge kurulacağını belirtmelidir — ve bu dengelerin kendisi, açıklama kararları değil politika kararlarıdır. Açıklama işgücü politika yapmaktadır.

Ölçek, demografik etkiyi yoğunlaştırır. Büyük modeller için RLHF nispeten küçük açıklama işgücünü (yüzlerden birkaç bine kadar) içerir ve bu işgücü milyarlarca aşağı akış kararı verir. Bu işgücünün demografik ve kültürel önyargıları, açıklama daha dağıtılmış olsaydı olmayacak biçimde modelin davranışına yansır. Bu, mevcut RLHF hattındaki en az tartışılan yapısal sorunlardan biridir.

Açıklama–Model Geri Bildirim Döngüsü

Doğal dil işlemede, diğer herhangi bir alandan daha fazla, açıklama ve model geliştirme süreçleri zaman içinde iç içe geçer:

1. Açıklayıcılar, bir modelin mevcut çıktılarını örtük olarak referans olarak kullanarak kalibre edilir.
2. Ödül modeli, açıklamaların neyi tercih ettiğini öğrenir.
3. Üretici, yüksek ödül elde eden çıktılar üretmek üzere ince ayarlanır.
4. Bu çıktılar, sonraki açıklama turlarında "iyi"nin neye benzediğini etkiler.

Bu geri bildirim döngüsü özünde hastalıklı değildir — RLHF'nin yakınsamasını sağlayan budur — ancak modelin davranışının insan tercihlerini yansıttığı için mi yoksa açıklayıcı sezgilerini örüntü eşleştirmeyi öğrendiği için mi şekillendiğini ampirik olarak ayırt etmek güçtür.

Temiz bir çözüm yoktur. En iyi mevcut uygulama, düzenli aralıklarla toplanan tutulmuş tercih yargıları kullanarak kayma izlemek ve açıklama kılavuzu versiyonunu deneysel değişken olarak ele almaktır.

Üretici Doğal Dil İşleme Modellerinin Değerlendirilmesi

Net bir doğruluk ölçütü olan sınıflandırma modellerinin aksine, üretim kalitesini değerlendirmek insan yargısı gerektirir:

Değerlendirme yöntemi	Açıklama	Maliyet
Doğrudan değerlendirme (DA)	Açıklayıcılar kaliteyi ölçekle derecelendirir	Orta
Karşılaştırmalı yargı	Açıklayıcılar iki çıktuyu karşılaştırır	Düşük
MQM (Çok Boyutlu Kalite Ölçütleri)	Yapılandırılmış hata taksonomisi	Yüksek
RLHF tercihi	Eğitim için kullanılan tercih etiketleri	Orta
Yargıç olarak BDM	BDM çıktıları puanlar (insanla ılımlı korelasyon)	Çok düşük
BERTScore, BLEU	Otomatik ölçütler (insan yargısıyla yetersiz korelasyon)	Çok düşük

Otomatik ölçütler (makine çevirisi için BLEU, özetleme için ROUGE) ucuzdur ancak insan kalite yargılarıyla yetersiz biçimde ilişkilidir {cite}`reiter2018structured`. Yargıç olarak BDM yaklaşımları, insan açıklayıcılarla ılımlı anlaşma göstermektedir {cite}`zheng2023judging` ve hızlı yineleme için giderek artan biçimde kullanılmaktadır; ancak nihai değerlendirmeler için insan değerlendirmesinin yerini almamalıdır. Gerçek riskler içeren kararlar için insan değerlendirmesi zorunluluğunu korumaktadır.

> **See also:** Snorkel zayıf denetimi: {cite}`ratner2017snorkel`. Doğal dil işleme açıklama kılavuzları: {cite}`pustejovsky2012natural`. Doğal dil çıkarımında açıklama yapay ürünleri: {cite}`geva2019annotator`. Açıklayıcı önyargısı ve

doğal dil işleme veri kümeleri: {cite}`blodgett2020language`. Üretici model değerlendirmesi için: {cite}`reiter2018structured`.

Bilgisayarlı Görüde Döngüde İnsan

Bilgisayarlı görü, HITL ML'nin en görsel açıdan sezgisel örneklerini sunar. 14 milyon insan etiketli görüntü üzerine inşa edilen ImageNet meydan okuması, derin öğrenme çağını başlattı. Radyologların tıbbi görüntü açıklamaları tanı yapay zekasını besliyor. Otonom araçlar, dünyayı algılamayı öğrenmek için milyonlarca insan etiketli kareye bağımlı.

Kolayca gözden kaçırılan şu dur: bunlar yalnızca insanların gerçek zemini sağladığı durumlar değildir. İnsanların belirli algısal, kültürel ve operasyonel seçimler içeren veri kümeleri inşa ettiği durumlardır — modeller öngörülebilir biçimlerde başarısız olduğunda ancak o zaman görünür hâle gelen seçimler.

Açıklama Seçimleri Model Önyargılarına Nasıl Dönüşür?

Standart çerçeveleme, açıklamayı veri toplama olarak ele alır: insanlar dünyayı gözlemleyip gördüklerini kaydeder. Daha doğru bir çerçeveleme, açıklamanın *veri kümesi tasarımı* olduğudur: insanlar hangi kategorilerin kullanılacağına, sınırların nerede çekileceğine, hangi sınır vakaların dahil edileceğine ve belirsizliğin nasıl çözüleceğine karar verir — ve tüm bu kararlar eğitilen modelin algılayacaklarını şekillendirir.

ImageNet Vakası

ImageNet {cite}`russakovsky2015imagenet`, bilgisayarlı görü tarihinin en sonuçlu veri kümesidir. Etiket kümesi, öncelikle çok sayıda ve anlamsal olarak ayırt edici oldukları gerekçesiyle seçilen WordNet eşanlamlı kümelerinden türetilmiştir. Bu tasarım seçiminin birkaç sonucu yıllar sonra ortaya çıktı:

- **Kişi kategorileri demografik ilişkilendirmeleri kodladı.** ImageNet'in kişilere yönelik eşanlamlı küme etiketlerinin erken versiyonları artık aşağılayıcı veya önyargılı kabul edilen pek çok etiketi içeriyordu; hem tarihsel WordNet kaynağını hem de hangi etiketlerin hangi görüntülere uygulanacağına ilişkin açıklama işgücünün örtük kararlarını yansıtıyordu {cite}`yang2020towards`. İnsanların görüntülerine uygulanan etiketler, doğrudan model gömmelerine yayılan ırk, cinsiyet ve sınıf ilişkilendirmelerini kodladı.
- **İnce taneli tür taksonomisi, neredeyse her şey için kaba taneli bir taksonomi.** ImageNet 120 köpek ırkını ayırt edebilir, ancak araçlar, taşıtlar, yiyecekler ve mobilyalardaki devasa farklılığı tek kategorilere indirger. Bu, neyin önemli olduğuna ilişkin kasıtlı bir seçimin değil, WordNet yapısını izlemenin bir sonucuydu. ImageNet üzerinde eğitilen modeller aynı asimetrik kesinliği sergiler.
- **Batılı, İngilizce konuşan görsel varsayılanlar.** Görüntüler öncelikle Flickr'dan ve İngilizce arama sorguları kullanılarak İnternet aramalarından toplandı. Ortaya çıkan

dağılım, zengin, İngilizce konuşan ülkelerin görsel ortamına ve kültürel nesnelerine güçlü biçimde yönelmiştir.

Bunların hiçbiri hata değildi. Bunlar, veri kümesinin nasıl kullanılacağını öngöremeyen insanlar tarafından hızlı ve ölçekli biçimde alınan açıklama tasarım kararlarıydı. Ders, ImageNet'in farklı inşa edilmesi gerektiği değildir (her ne kadar gerekliydi) — **açıklama tasarımı model tasarımıdır** ve aynı özenle ele alınmalıdır.

:::{admonition} Açıklama şeması bir dünya teorisidir :class: note

Her etiket taksonomisi, hangi ayrımların önemli olduğu hakkında iddialar içerir. "Araç"ı "kamyon"dan ayırırken tüm sedan türlerini tek bir sınıfta toplamak, hangi ayrımların anlamsal olarak ilgili olduğu hakkında teorik bir iddiadır. Poz, giyim veya faaliyetten bağımsız olarak "kişi"yi tek bir sınıf olarak etiketlemeye karar vermek, farklı bir teorik iddiadır. Bu şemalar üzerinde eğitilen modeller aynı ayrımları yapacak, bunun ötesine geçemeyecektir — eğitildikleri kategorilerin ötesine genelleşemeyeceklerdir. :::

Görüntü Sınıflandırması Açıklaması

En basit bilgisayarlı görü açıklama görevi, tüm görüntüye bir veya birden fazla etiket atamaktır.

Etiket hiyerarşisi. "Köpek" etiketi anlamsal bir hiyerarşide "hayvan"ın altında yer alır. Düz taksonomilerle eğitilen modeller, soyutlama düzeyleri genelinde iyi genelleşmeyebilir. ImageNet, birden fazla özgüllük düzeyinde değerlendirmeye olanak tanıyan eşanlamlı küme tabanlı bir hiyerarşi kullanır.

Çok etiketli belirsizlik. Bir sokak sahnesi aynı anda bir araba, bir insan, bir bisiklet ve bir trafik ışığı içerebilir. Hangi etiketlerin dahil edileceğine karar vermek, ilgi eşiklerine ilişkin açık kılavuzlar gerektirir.

Uzun kuyruk dağılımları. Doğal görüntü veri kümeleri kuvvet yasasını izler: birkaç kategori son derece yaygın; çoğu nadirdir. Aktif öğrenme, rastgele örneklemenin yalnızca bir avuç örnek vereceği uzun kuyruk kategorileri için özellikle değerlidir.

Nesne Algılama: Sınır Kutusu Açıklaması

Nesne algılama, açıklayıcıların her nesne sınıfının örneklerinin etrafına eksen hizalı sınır kutuları çizmesini gerektirir. Bu durum, geometrik hassasiyet gereklilikleri ve önemli sınır vakalar getirir.

Açıklama kalitesi ölçütleri:

IoU (Kesişim / Birleşim), açıklamalı kutu ile referans kutu arasındaki örtüşmeyi ölçer:

$$\mathrm{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

IoU $\geq 0{,}5$, PASCAL VOC'ta "doğru" algılama için standart eşiktir; COCO {cite}`lin2014microsoft` ise 0,5'ten 0,95'e uzanan ve çok daha zorlu ve daha bilgilendirici olan bir eşik aralığı kullanır.

Kılavuzlarda ele alınması gereken açıklama sınır vakaları: - Kapalı nesneler: görünür kısmı açıkla mı yoksa tam uzantıyı tahmin et mi? - Kesik nesneler (çerçevenin kısmen dışında): dahil

et mi yoksa dışarıda bırak mı? - Kalabalık bölgeler: özel bir "kalabalık" açıklaması kullan mı yoksa tekil örnekleri açıkla mı?

Bu kararların her biri "doğru algılamanın" ne anlama geldiğini değiştirir — ve dolayısıyla modelin eğitildiği şeyi değiştirir.

```
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.patches as patches

def compute_iou(boxA, boxB):
    """Compute IoU between two boxes [x1, y1, x2, y2]."""
    xA = max(boxA[0], boxB[0])
    yA = max(boxA[1], boxB[1])
    xB = min(boxA[2], boxB[2])
    yB = min(boxA[3], boxB[3])
    inter_area = max(0, xB - xA) * max(0, yB - yA)
    boxA_area = (boxA[2] - boxA[0]) * (boxA[3] - boxA[1])
    boxB_area = (boxB[2] - boxB[0]) * (boxB[3] - boxB[1])
    union_area = boxA_area + boxB_area - inter_area
    return inter_area / (union_area + 1e-6)

ref_box  = [1.0, 1.0, 4.0, 4.0]
ann1_box = [1.1, 0.9, 4.1, 4.2]   # close
ann2_box = [0.5, 0.5, 3.5, 3.8]   # less precise

print(f"IoU (ann1 vs ref):  {compute_iou(ann1_box, ref_box):.3f}")
print(f"IoU (ann2 vs ref):  {compute_iou(ann2_box, ref_box):.3f}")
print(f"IoU (ann1 vs ann2): {compute_iou(ann1_box, ann2_box):.3f}")

fig, ax = plt.subplots(figsize=(5, 5))
ax.set_xlim(0, 5); ax.set_ylim(0, 5); ax.set_aspect('equal')
ax.add_patch(patches.Rectangle(
    (ref_box[0], ref_box[1]), ref_box[2]-ref_box[0], ref_box[3]-ref_box[1],
    linewidth=2.5, edgecolor='#2b3a8f', facecolor='none', label='Reference'))
ax.add_patch(patches.Rectangle(
    (ann1_box[0], ann1_box[1]), ann1_box[2]-ann1_box[0], ann1_box[3]-ann1_box[1],
    linewidth=2, edgecolor='#0d9e8e', facecolor='none', linestyle='--',
    label=f'Ann1 (IoU={compute_iou(ann1_box, ref_box):.2f})'))
ax.add_patch(patches.Rectangle(
    (ann2_box[0], ann2_box[1]), ann2_box[2]-ann2_box[0], ann2_box[3]-ann2_box[1],
    linewidth=2, edgecolor='#e05c5c', facecolor='none', linestyle=':',
    label=f'Ann2 (IoU={compute_iou(ann2_box, ref_box):.2f})'))
ax.legend(fontsize=10)
ax.set_title("Bounding Box Agreement (IoU)", fontsize=12)
plt.tight_layout()
plt.savefig('bbox_iou.png', dpi=150)
plt.show()
```

Anlamsal ve Örnek Segmentasyonu

Segmentasyon açıklaması, bir görüntüdeki her piksele sınıf etiketi atamayı gerektirir — en pahalı açıklama türlerinden biridir.

Anlamsal segmentasyon: Her piksel bir anlamsal sınıfa (yol, gökyüzü, kişi, araba) aittir. Aynı sınıfın tüm pikselleri, hangi tekil nesneye ait olduklarından bağımsız olarak aynı etiketi paylaşır.

Örnek segmentasyonu: Her tekil nesne örneği benzersiz bir etiket alır. 20 kişilik bir kalabalık, 20 ayrı maskeye dönüşür.

Panoramik segmentasyon: Her ikisini birleştirir: "şey" sınıfları (sayılabilir nesneler) örnek maskelere sahiptir; "şey" sınıfları (yol, gökyüzü) anlamsal maskelere sahiptir.

SAM destekli açıklama: Meta'nın Segment Anything Modeli {cite}`kirillov2023segment`, tek bir nokta tıklamasından yüksek kaliteli segmentasyon maskeleri üretir. Açıklayıcılar bir nesnenin merkezine tıklar; SAM bir maske önerir; açıklayıcı kabul eder ya da düzeltir. SAM yazarları, poligon tabanlı etiketlemeye kıyasla yaklaşık 6,5 kat hız kazanımı bildirmektedir; kazanımlar sahne türleri ve açıklama araçlarına göre değişmektedir.

SAM daha geniş bir dönüşümü temsil etmektedir: **açıklayıcının rolü çizmekten incelemeye geçmektedir**. Bunun hız ötesinde açıklama kalitesi üzerinde etkileri vardır. Açıklayıcılar çizdiğinde, dikkatleri süreç boyunca odaklanmış olur. Açıklayıcılar inceleyip "kabul et"e tıkladığında, hataları daha kolay kaçırdıklarına dair kanıtlar mevcuttur — açıklama bağlamına özgü bir otomasyon önyargısı türü.

Bilgisayarlı Görü için Aktif Öğrenme

Aktif öğrenme bilgisayarlı görü için özellikle değerlidir; çünkü: 1. Görüntüler yüksek boyutlu ve zengin özelliklere sahiptir — önceden eğitilmiş modellerden elde edilen gömmeler, belirsizlik tahmini için güçlü sinyaller taşır 2. Büyük etiketsiz havuzlar ucuzdur (fotoğraflar, video kareleri) 3. Açıklama (özellikle segmentasyon) pahalıdır ve özel alanlar için kolayca kitle kaynaklı yapılamaz

```
import numpy as np
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score
import matplotlib.pyplot as plt

rng = np.random.default_rng(42)

X, y = make_classification(n_samples=3000, n_features=50, n_informative=25,
                           n_classes=5, n_clusters_per_class=2, random_state=42)
X_train, y_train = X[:2500], y[:2500]
X_test,  y_test  = X[2500:], y[2500:]

def margin_uncertainty(model, X_pool):
    probs = model.predict_proba(X_pool)
    sorted_p = np.sort(probs, axis=1)
    return sorted_p[:, -2] - sorted_p[:, -1]  # most negative = most uncertain
```

```
n_init = 50
results = {'active': [], 'random': []}
label_counts = list(range(50, 401, 30))

for strategy in ['active', 'random']:
    labeled = list(rng.choice(len(X_train), n_init, replace=False))
    unlabeled = [i for i in range(len(X_train)) if i not in labeled]

    for target in label_counts:
        while len(labeled) < target and unlabeled:
            if strategy == 'active' and len(labeled) >= 10:
                model_temp = LogisticRegression(max_iter=300).fit(
                    X_train[labeled], y_train[labeled])
                margins = margin_uncertainty(model_temp, X_train[unlabeled])
                idx = int(np.argmin(margins))
            else:
                idx = rng.integers(0, len(unlabeled))
            labeled.append(unlabeled.pop(idx))

        clf = LogisticRegression(max_iter=300).fit(X_train[labeled], y_train[labeled])
        results[strategy].append(accuracy_score(y_test, clf.predict(X_test)))

plt.figure(figsize=(7, 4))
plt.plot(label_counts, results['active'], 'o-', color='#2b3a8f',
         linewidth=2, label='Active (margin sampling)')
plt.plot(label_counts, results['random'], 's--', color='#e05c5c',
         linewidth=2, label='Random baseline')
plt.xlabel("Labeled training images", fontsize=12)
plt.ylabel("Test accuracy", fontsize=12)
plt.title("Active Learning for 5-Class Image Classification", fontsize=13)
plt.legend(fontsize=11); plt.grid(alpha=0.3)
plt.tight_layout()
plt.savefig('cv_active_learning.png', dpi=150)
plt.show()
```

İnsan Rehberliğiyle Yarı Denetimli Öğrenme

Mevcut etiketsiz görsel verinin büyük miktarı, yarı denetimli öğrenmeyi bilgisayarlı görü için özellikle cazip kılar.

Öz eğitim / sözde etiketleme: Etiketli veri üzerinde bir model eğit; etiketsiz veri üzerinde yüksek güvenilirlikli tahminleri sözde etiket olarak kullan; yeniden eğit. Kritik tasarım sorusu güven eşiğidir. Düşük eşik daha fazla örnek getirir ancak gürültü ekler; yüksek eşik etiketsiz havuzun büyük bölümünü kullanılmaz bırakır. İnsan katılımı bu eşiğe rehberlik edebilir — açıklayıcılar sözde etiketlenmiş örneklerin bir örneklemini kalibre etmek için gözden geçirir.

FixMatch ve tutarlılık düzenleme: Bu yöntemler, modelleri büyütme altında tutarlı tahminler üretecek şekilde eğitir. Temel HITL kavrayışı: insanlar yalnızca etiketler için değil, **büyütme tasarımı** için de danışılır — model hangi değişmezlikleri öğrenmeli? Tıbbi görüntüleme modeli

döndürme ve parlaklığa karşı değişmez olmalı, ancak ölçeğe karşı değil; metin algılama modeli perspektif bozulmasına karşı değişmez hâle getirilmemelidir. Bu alana özgü seçimler insan uzmanlığı gerektirir ve yanlış yapılmaları yarı denetimli öğrenmeyi önemli ölçüde bozar.

Etkin yarı denetimli öğrenme: En verimli kombinasyon: aktif öğrenme, insan etiketlerini model belirsizliğinin en yüksek olduğu yerlere yoğunlaştırır; öz eğitim yüksek güvenilirlikli kuyruğu otomatik olarak etiketler. İnsan çabası en değerli olduğu yere yoğunlaşır; model geri kalanı üzerinde önyükleme yapar. Her döngüde, sözde etiketlerin rastgele bir örnekleminin insan denetimi, tam inceleme gerektirmeden kalite kontrolü sağlar.

Video Açıklaması

Video açıklaması, görüntü açıklamasının güçlüklerini zamanla çarpar:

- **İzleme:** Nesneler kareler arasında belirlenmelidir. Açıklayıcılar anahtar kareleri etiketler; izleme algoritmaları aralarını doldurur. İzleme başarısızlıkları — kapanma, yeniden giriş, hızlı hareket — sabit durum izlemesinden daha yüksek oranda insan yeniden etiketleme gerektirir.
- **Zamansal tutarlılık:** t karesinde çizilen sınırlar, $t + 1$ karedekiyle mekânsal olarak tutarlı olmalıdır. Tutarsız açıklamalar, modele nesnelerin süreksiz biçimde atladığını söyleyen bir eğitim sinyalidir — algılama modelleri için özellikle zararlı bir açıklama gürültüsü biçimi.
- **Ölçeklenebilirlik:** 30 fps'de 1 saatlik video 108.000 karedir. Tam açıklama pratik değildir; örnekleme stratejilerinin, nadir olayların (sınır vakaları, ramak kalmalar, başarısızlık senaryoları) sistematik biçimde dışlanmamasını sağlayacak şekilde dikkatle tasarlanması gerekir.

Modern video açıklama araçları, açıklamaları kareler arasında yayan ve izleme güvenilirliğinin eşiğin altına düştüğü kareleri işaretleyen **akıllı izleme** desteği sunar; bu da açıklayıcıyı yeniden kontrol etmeye davet eder. Bu, aktif öğrenme fikrini açıklama hattının kendisine doğrudan uygulamaktır: araç, tam olarak enterpolasyonunun belirsiz olduğu yerlerde açıklayıcıyı sorgular.

Otonom sistemlerde nadir olay problemi. Nadir olayların sonuçlarının felakete yol açabileceği uygulamalarda — otonom sürüş, insansız hava aracı navigasyonu — normal çalışmada görülen karelerin dağılımı, gerçekten önemli olan karelerin dağılımıyla ciddi biçimde uyumsuz olur. Normal sürüş görüntüsünün tek tip örneklemesiyle oluşturulan bir veri kümesi, milyonlarca "ilgi çekici bir şey olmuyor" karesi ve güvenlik açısından gerçekten önemli olan yakın kaza, alışılmadık aydınlatma ve bozulmuş sensör karelerinden yalnızca bir avuç içerecektir. Bu tür kareleri belirleyip önceliklendiren HITL aktif öğrenmesi bir verimlilik hilesi değildir — bir güvenlik gerekliliğidir.

> **See also:** ImageNet veri kümesi: {cite}`russakovsky2015imagenet`. ImageNet'teki etiket önyargısı: {cite}`yang2020towards`. COCO kıyaslaması: {cite}`lin2014microsoft`. SAM (Segment Anything): {cite}`kirillov2023segment`. Bilgisayarlı görü için çekirdek küme aktif öğrenmesi: {cite}`sener2018active`.

Sağlık ve Bilimde Döngüde İnsan

Sağlık ve bilim, HITL ML'nin en sonuçlu ve en tartışmalı olduğu iki alanı temsil etmektedir. Riskler yüksektir: kaçırılan bir kanser tanısı veya hatalı bir ilaç hedefinin gerçek bir insan maliyeti vardır. Açıklama, nadir ve pahalı uzmanlık gerektirir. Düzenleyici gereklilikler, modellerin neler yapabileceğini ve nasıl doğrulanmaları gerektiğini kısıtlar. Doğal dil işlemenin aksine, burada çoğunlukla gerçek bir zemin vardır — tümör ya var ya yok — hiçbir tekil gözlemci bunu güvenilir biçimde belirleyemese de.

Popüler haberlerdeki hâkim çerçeveleme "yapay zeka karşı insan"dır: yapay zeka radyologların yerini alacak mı? Bu çerçeveleme önem taşıyan bir biçimde yanlıştır. Gerçek soru şudur: hangi insan–yapay zeka işbirliği biçimi her birinden daha iyi sonuçlar üretir ve bu işbirliğini aksatmak yerine mümkün kılan sistemler nasıl inşa edilir.

Tıbbi Görüntü Analizi

Tıbbi görüntüleme — radyoloji (X-ışını, BT, MRI), patoloji (doku kesitleri), dermatoloji, oftalmoloji — tıbbi yapay zekanın en hızlı ilerlediği alandır.

Uzman Açıklayıcı Gereksinimleri

Tıbbi görüntü açıklaması genellikle belirli alt uzmanlık eğitimine sahip hekimler gerektirir. Bu durum açıklamayı şu hâle getirir:

- **Yavaş:** Uzmanların sınırlı zamanı vardır; açıklama klinik görevlerle rekabet eder
- **Pahalı:** Maliyetler, alt uzmanlık, modalite ve görev karmaşıklığına bağlı olarak açıklamalı vaka başına onlardan yüzlerce dolara uzanır
- **Değişken:** Uzmanlar bile özellikle sınır vakalarda anlaşmazlığa düşer — bu çoğunlukla bir sorun olarak ele alınır, ancak gerçekte bilgilendiricidir

Radyologlar Arası Değişkenlik

Radyolojide okuyucu değişkenliği iyi belgelenmiştir. Akciğer grafisi yorumlamasında okuyucular arası anlaşmazlık önemlidir — CheXNet çalışmasında dört radyolog aynı pnömoni tespiti test kümesini yaklaşık 12 yüzde puanlık F1 aralığıyla etiketledi {cite}`rajpurkar2017chexnet`; bu, sınır vakalardaki gerçek tanısal belirsizliği yansıtmaktadır. Akciğer BT'deki nodül tespiti için okuyucu içi değişkenlik (aynı okuyucu, aynı vaka, farklı gün) okuyucular arası değişkenlik kadar büyük olabilir.

Bu değişkenlik yalnızca gürültü değildir — gerçek tanısal belirsizliği yansıtır. Tek bir radyologun açıklamalarıyla eğitilen modeller, altta yatan patoloji yerine o hekimin özel önyargılarını öğrenebilir.

:::{admonition} HITL Dersi Olarak CheXNet Tartışması :class: note

Rajpurkar ve diğerleri, CheXNet modellerinin pnömoni tespitinde "radyolog performansını aştığını" iddia ettiğinde, bu iddia radyoloji topluluğu tarafından hemen itirazla karşılandı {cite}`yu2022assessing`. Tartışmanın bir bölümü belirli test kümesi ve radyolog karşılaştırmasıyla ilgiliydi. Ancak daha derin bir sorun metodolojikti: kullanılan "radyolog performansı" taban çizgisi, klinik radyolojinin genellikle içerdiği konsültasyon, önceki görüntülemelerle karşılaştırma ve klinik bağlama erişim olmaksızın zaman baskısı altında tekil okuyuculardan yararlandı — bunların hiçbiri modelde yoktu.

Ders, modelin iyi ya da kötü olduğu değil, **performans karşılaştırmalarının HITL kurulumunu belirtmesini gerektirdiğidir**. Tekil radyologu soğuk okuma yaptırarak geçen bir model, modelin çıktısını ikinci görüş olarak kullanan bir radyologdan hâlâ daha az doğru olabilir. Bunlar, farklı hata kiplerine sahip farklı sistemlerdir. :::

:::{admonition} Tıpta yumuşak etiketler :class: important

Birçok tıbbi yapay zeka projesi, tek bir "altın standart" etiket yerine uzman görüşlerinin dağılımını yansıtan **yumuşak etiketler** kullanmaya geçmiştir. Bir radyolog paneli tarafından %60 pnömoni / %40 atelektazi olarak etiketlenen bir akciğer grafisi, zorla ikili seçimden daha fazla bilgi taşır. Bu tür dağılımlar üzerinde eğitilen modeller, daha iyi kalibrasyon ve daha uygun belirsizlik nicelemesi sergilemektedir — ve bu belirsizlik klinik açıdan anlamlıdır; çünkü klinisyene modelin ne düşündüğünü değil, ne zaman danışması gerektiğini söyler. :::

Nadir Hastalıklar için Aktif Öğrenme

Aktif öğrenme, büyük bir etiketsiz havuzun dahi yalnızca az sayıda pozitif vaka içerdiği nadir hastalıklar ve nadir patolojiler için özellikle değerlidir. Standart rastgele örnekleme, uzman zamanını çoğunlukla negatif vakaları etiketleyerek boşa harcar.

Belirsizlik tabanlı aktif öğrenme, doğal olarak modelin belirsiz olduğu sınır vakaları seçer — nadir hastalıklar için bunlar pozitif vakalar ve sınır negatifler olma eğilimindedir. Bu, uzman zamanını en değerli olduğu yerde yoğunlaştırır. Sınıf dengesizliği eğitiminin (`class_weight='balanced'` veya benzeri) ve belirsizlik tabanlı seçimin birleşimi, nadir patoloji tespiti görevleri için standart uygulamadır.

Klinik Doğal Dil İşleme Açıklaması

Elektronik sağlık kayıtları (ESK), klinik anlatı metin açısından muazzam bir zenginlik barındırır: hekim notları, taburcu özetleri, radyoloji raporları, patoloji raporları. Bu metinden yapılandırılmış bilgi çıkarmak doğal dil işleme gerektirir — ve yüksek kaliteli doğal dil işleme, açıklamalı eğitim verisi gerektirir.

Yaygın klinik doğal dil işleme açıklama görevleri: - Klinik Adlandırılmış Varlık Tanıma: Metindeki ilaçları, dozajları, tanıları, prosedürleri ve semptomları tanımlama - **Olumsuzlama tespiti:** "Pnömoni kanıtı yok" ile "Pnömoni doğrulandı" — şaşırtıcı biçimde güç olan kritik bir ayrım - **Zamansal akıl yürütme:** Mevcut durumları geçmişten ayırt etme ("MI öyküsü, göğüs ağrısıyla başvurdu") - **Tanımlama kaldırma:** Veri paylaşımını mümkün kılmak için Korunan Sağlık Bilgilerini (KSB) kaldırma

KSB tanımlama kaldırma, hem bir açıklama görevi hem de bir veri yönetişimi gerekliliğidir. ABD'de HIPAA ve AB'de GDPR kapsamında sağlık verileri hasta tanımlayıcıları kaldırılmadan veya anonimleştirilmeden paylaşılamaz. Otomatik tanımlama kaldırma araçları mevcuttur,

ancak kusurludur; otomatik çıktıların insan incelemesi standart uygulamadır. Risk profili asimetriktir: yanlış negatifler (kaçırılan KSB) hukuki tehlike yaratır; bu nedenle muhafazakâr eşikler zorunludur.

Şablon Olarak i2b2 / n2c2

i2b2 (Biyoloji ve Yatak Başı için Bilişim Entegrasyonu) ve halef n2c2 (Ulusal Doğal Dil İşleme Klinik Zorlukları) paylaşılan görev girişimleri, bir dizi uzman açıklamalı klinik doğal dil işleme veri kümesi yayımlamıştır. Bunlar hem potansiyeli hem de maliyeti örneklemektedir: açıklama çabaları genellikle birkaç ay boyunca çalışan klinik alan uzmanı ekiplerini, zorluk başına yüzlerce belgeyi kapsar. n2c2 veri kümeleri, yalnızca açıklama sorununu değil, veri paylaşımı yönetişim sorununu (tanımlama kaldırma + kurumsal anlaşmalar) çözdükleri için hızlı ilerlemeyi katalize etti.

Düzenleyici Değerlendirmeler

Tıbbi yapay zeka, çoğu yargı bölgesinde düzenleyici denetime tabidir.

FDA (Amerika Birleşik Devletleri): Yapay zeka/Makine Öğrenmesi tabanlı Tıbbi Cihaz Yazılımı (SaMD) piyasa öncesi onay veya lisans gerektirmektedir. FDA'nın 2021 YZ/MÖ Eylem Planı, **önceden belirlenmiş değişiklik kontrol planlarını** — modelin nasıl güncelleneceğinin ve bu güncellemelerin dağıtımdan önce nasıl doğrulanacağının belgelenmesini — ön plana çıkarmaktadır. Bu çerçeve altında, klinik geri bildirimden sürekli öğrenen bir model, her güncellemeden sonra farklı bir cihazdır ve yeniden doğrulama gerektirebilir.

CE işaretlemesi (Avrupa): Yapay zeka sistemleri dahil tıbbi cihazlar Tıbbi Cihaz Yönetmeliğine (MDY) uymak zorundadır. MDY klinik değerlendirme, piyasa sonrası gözetim ve eğitim ile doğrulama için kullanılan verilerin belgelenmesini gerektirir.

Temel HITL çıkarımı: Düzenleyici çerçeveler, açıklama süreçlerinin, açıklayıcı yeterliliklerinin, değerlendiriciler arası güvenilirliğin ve eğitim verilerindeki değişikliklerin açık biçimde belgelenmesini gerektirir. Bu bürokratik yük değildir — bir klinisyenin modelin mevcut davranışını hangi eğitim verisinin ürettiğini anlamasına olanak tanıyan denetim izi ve yasal olarak zorunludur. Açıklamayı gayri resmi bir alt süreç olarak ele alan HITL hatları, genellikle en kötü anda görünür hâle gelen düzenleyici risk yaratır.

Bilimsel Veri Açıklaması

Sağlığın ötesinde, HITL ML bilimsel araştırmalarda giderek artan ve değeri yeterince anlaşılmayan bir rol oynamaktadır; buradaki açıklama güçlüğü çoğunlukla alan uzmanlığını ölçekle harmanlar.

Astronomi: Galaxy Zoo

Galaxy Zoo {cite}`lintott2008galaxy`, Sloan Dijital Gökyüzü Araştırması'ndaki galaksilerin morfolojik sınıflandırmasını vatandaş bilimcilere kitle kaynaklı yöntemle dağıttı. Özgün proje, 100.000'den fazla gönüllüden 40 milyonun üzerinde sınıflandırma toladı; bu, uzman eğitimi gerektirmeden basit sorulara yanıt verebilmesi hâlinde bilimsel görüntü sınıflandırmasının

büyük ölçekli kitle kaynaklı yapılabilirliğini kanıtladı ("Bu galaksi düzgün mü yoksa özellikli mi?").

Galaxy Zoo deneyimi, iki önemli metodolojik bulgu üretti. Birincisi, vatandaş bilimciler ile profesyonel astronomlar arasındaki anlaşma net vakalar için yüksek, sınır vakalarda sistematik olarak ayrışıyordu — tam da bilimsel olarak ayrımın önem taşıdığı vakalar. Çözüm, sınır vakalarda vatandaş bilimi verilerini atmak değil, gönüllü yanıtların dağılımını gerçek morfolojik belirsizliği kodlayan bir yumuşak etiket olarak ele almaktı. İkincisi, Galaxy Zoo etiketleri üzerinde eğitilen sınıflandırıcı, herhangi bir uzmanın etiketlerini yeniden üretmek için eğitilen modelleri geride bıraktı; çünkü kalabalık dağılımı, tek bir uzmanın zorla seçiminin kapattığı gerçek görsel belirsizliği yakaladı.

Genomik: Patojenisite Sınıflandırması

Genomik varyantları açıklamak — bir varyantın patojenik, iyi huylu veya belirsiz öneme sahip olup olmadığına karar vermek — yüksek riskli bir doğal dil işleme ve uzman yargısı sorunudur. ClinVar gibi klinik varyant veri tabanları, birden fazla gönderen laboratuvardan uzman yorumlarını bir araya getirir ve laboratuvarlar arasında anlaşmazlık yaygındır. Aktif öğrenme, hangi varyantların tam uzman incelemesi (literatür araştırması, işlevsel kanıt değerlendirmesi) gerektirdiğini ve hangilerinin mevcut kanıtlarla otomatik sınıflandırılabileceğini önceliklendirmek için kullanılır. Sonuç, vakaların büyük bölümünün otomatik mantıkla ele alındığı, bir alt kümenin uzman incelemesi gerektirdiği ve en güç vakaların çok laboratuvarlı fikir birliği için işaretlendiği hibrit bir hattır.

İklim ve Yer Bilimleri

Uydu görüntüsünü arazi kullanımı değişikliği, ormansızlaşma, buzul genişliği ve fırtına izleri için etiketlemek, uzaktan algılama uzmanlarını ve giderek artan biçimde vatandaş bilimi platformlarını içerir. Bu alandaki birincil HITL güçlüğü zamansal olandır: bugün yapılan etiketler dünya değiştikçe eskiyebilir ve gerçek zemin doğrulaması (arazi araştırmaları) pahalı ve lojistik açıdan kısıtlıdır. Modelin tahmininin fiziksel ön bilgilerle çeliştiği görüntülere (örneğin korunan olduğu bilinen bir bölgede ormansızlaşma tahmini) öncelik veren aktif öğrenme, kıt arazi doğrulama kaynaklarını yönlendirmenin pratik bir yoludur.

Nörobilim: Konnektomik

Elektron mikroskop görüntülerinden sinir devrelerini yeniden oluşturmak — konnektomik — büyük görüntü yığınları arasında nöron zarlarının piksel düzeyinde açıklanmasını gerektirir. Eyewire projesi bu görevi oyunlaştırarak on binlerce oyuncuyu 3B görüntü hacimlerindeki nöronları izlemeye yöneltti. Oyunlaştırma tasarımı belirli bir HITL sorununu çözdü: görev uzun oturumlar boyunca sürekli dikkat ve mekânsal akıl yürütme gerektirmekte, bu da geleneksel açıklamada kalite bozulmasına yol açmaktadır. Görevi sosyal mekaniklerle oyun bölümlerine ayırmak, profesyonel açıklamanın ulaşamayacağı ölçeklerde açıklayıcı katılımını ve kalitesini korudu.

Uzman Açıklayıcıları Yönetmek

Açıklama nadir uzmanlık gerektirdiğinde, olağan kitle kaynaklı yaklaşımlar (Bölüm 13) geçerli değildir.

Temel gerilim, en yüksek kaliteli açıklamalar üretebilecek kişilerin aynı zamanda zamanı en değerli ve en kısıtlı olan kişiler olmasıdır. Uzman açıklama hattındaki her tasarım kararı şu soruya göre değerlendirilmelidir: bu, kıt uzman zamanının en iyi kullanımını sağlıyor mu?

Pratikte ne anlama geldiği:

- **Ön açıklamayı agresif biçimde kullanın.** Uzmanın gözden geçirip düzelttiği adayları, daha düşük kademeli açıklayıcıları, otomatik modelleri veya kural tabanlı sistemleri kullanarak oluşturun. Uzmanın yargısı darboğazdır; düzeltecekleri ön açıklamayla beslemek, ön açıklama kalitesi düzeltmenin sıfırdan başlamaktan daha hızlı olduğunu garanti edecek kadar yüksek ise boş ekrandan daha hızlıdır.
- **Verim yerine uzman dikkatine göre tasarlayın.** Yüksek verim için optimize edilmiş açıklama arayüzleri (hızlı ikili kararlar, klavye kısayolları, minimal ekran) kitle kaynaklı çalışma için uygundur. Uzman açıklaması çoğunlukla daha zengin arayüzlerden yararlanır: önceki vakalarla yan yana karşılaştırma, referans materyallere kolay erişim, açıklama güven alanları ve bir vakayı tartışmak üzere işaretleme olanağı. Bunlar bireysel açıklamaları yavaşlatır, ancak kaliteyi artırır ve yeniden açıklama ihtiyacını azaltır.
- **Bireysel açıklayıcı örüntülerini açıkça izleyin.** Küçük bir uzman havuzuyla, her açıklayıcının panelle anlaşma oranını izlemek, kendi geçmişleriyle tutarsız görünen vakaları işaretlemek ve bunları düzenli kalibrasyon oturumlarında tartışmak uygulanabilir ve önemlidir. Bu gözetleme değildir — klinik tıbbın performans değerlendirmesi için kullandığı kalite süreciyle aynıdır ve uzmanlar değerlendirme yerine paylaşılan kalite iyileştirmesi olarak çerçevelendiğinde genellikle olumlu yanıt verir.
- **Oturum tasarımı önem taşır.** Tıbbi açıklama bilişsel açıdan yoğundur. Radyoloji ve patolojiden elde edilen kanıtlar, hata oranlarının yaklaşık 90 dakika sürekli okumadan sonra ölçülebilir biçimde arttığını ve birkaç dakikalık araların bile dikkati kısmen yenileyebildiğini göstermektedir. Mola istemlerini zorunlu kılan açıklama arayüzleri (bunları kapatılamaz hâle getirerek), gerçek kalite etkisi olan basit bir HITL tasarım kararıdır.

Tıbbi Görüntüleme için Bir HITL Aktif Öğrenme Hattı

```python
import numpy as np
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import roc_auc_score
from sklearn.datasets import make_classification
import matplotlib.pyplot as plt

rng = np.random.default_rng(42)

# Simulate a rare-pathology detection task
# 8% positive class (e.g., rare pathology)
X, y = make_classification(
    n_samples=5000, n_features=100,
    n_informative=20, n_redundant=10,
    weights=[0.92, 0.08],
    random_state=42
)
```

```
X_train, y_train = X[:4000], y[:4000]
X_test,  y_test  = X[4000:], y[4000:]

print(f"Training set positive prevalence: {y_train.mean():.1%}")

def run_medical_al(strategy, n_initial=50, budget=300):
    labeled = list(rng.choice(len(X_train), n_initial, replace=False))
    unlabeled = [i for i in range(len(X_train)) if i not in labeled]
    aucs = []

    while len(labeled) < n_initial + budget:
        model = LogisticRegression(max_iter=500, class_weight='balanced')
        model.fit(X_train[labeled], y_train[labeled])

        if len(labeled) % 30 == 0:
            preds = model.predict_proba(X_test)[:, 1]
            aucs.append(roc_auc_score(y_test, preds))

        X_pool = X_train[unlabeled]
        if strategy == 'uncertainty' and len(labeled) >= 10:
            probs = model.predict_proba(X_pool)
            entropy = -np.sum(probs * np.log(probs + 1e-9), axis=1)
            q = int(np.argmax(entropy))
        else:
            q = rng.integers(0, len(unlabeled))

        labeled.append(unlabeled.pop(q))

    return np.array(aucs)

aucs_al  = run_medical_al('uncertainty')
aucs_rnd = run_medical_al('random')
label_counts = np.arange(len(aucs_al)) * 30 + 50

plt.figure(figsize=(7, 4))
plt.plot(label_counts, aucs_al,  'o-',  color='#2b3a8f', linewidth=2, label='Uncertainty AL')
plt.plot(label_counts, aucs_rnd, 's--', color='#e05c5c', linewidth=2, label='Random baseline'
plt.xlabel("Expert labels obtained", fontsize=12)
plt.ylabel("AUROC", fontsize=12)
plt.title("Active Learning for Rare Pathology Detection", fontsize=13)
plt.legend(); plt.grid(alpha=0.3)
plt.tight_layout()
plt.savefig('medical_al.png', dpi=150)
plt.show()

# Show how AL preferentially selects positive examples
# by checking which class the queried examples belong to
n_init = 50
labeled_al  = list(rng.choice(len(X_train), n_init, replace=False))
labeled_rnd = labeled_al.copy()
unlabeled_al  = [i for i in range(len(X_train)) if i not in labeled_al]
```

```
unlabeled_rnd = unlabeled_al.copy()

model = LogisticRegression(max_iter=500, class_weight='balanced')
model.fit(X_train[labeled_al], y_train[labeled_al])
probs = model.predict_proba(X_train[unlabeled_al])
entropy = -np.sum(probs * np.log(probs + 1e-9), axis=1)
top50_al  = [unlabeled_al[i] for i in np.argsort(entropy)[-50:]]
top50_rnd = list(rng.choice(unlabeled_rnd, 50, replace=False))

pos_rate_al  = y_train[top50_al].mean()
pos_rate_rnd = y_train[top50_rnd].mean()
print(f"\nPositive rate in next 50 queries:")
print(f"  Uncertainty AL: {pos_rate_al:.1%}  (base rate: {y_train.mean():.1%})")
print(f"  Random:         {pos_rate_rnd:.1%}")
print(f"  AL queries {pos_rate_al/y_train.mean():.1f}x more positives than random")
```

See also: Galaxy Zoo kitle kaynaklı çalışma: {cite}`lintott2008galaxy`. CheXNet radyolog performansı: {cite}`rajpurkar2017chexnet`. Radyografi kalitesi ve yapay zeka destekli tanı: {cite}`yu2022assessing`. Klinik doğal dil işleme açıklama metodolojisi: {cite}`pustejovsky2012natural`. FDA YZ/MÖ eylem planı rehberliği için FDA'nın yayımlanmış belgelerine (2021) bakınız.

Açıklama Platformları ve Araçlar

Açıklama platformu, insan geri bildiriminin veriye dönüştüğü ortamdır. İyi bir platform verimi artırır, hataları azaltır, kalite kontrollerini sürdürür ve açıklama hattını ölçekte yönetilebilir kılar. Doğru platformu seçmek — ve ne zaman satın alınacağını ne zaman inşa edileceğini bilmek — herhangi bir HITL projesinde sonuçlu bir karardır.

Açıklama Platformu Manzarası

Açıklama araçları pazarı, kurumsal makine öğrenmesi eğitimi verisi talebinden beslenerek son yıllarda önemli ölçüde büyümüş ve olgunlaşmıştır. Araçlar, tamamen yönetilen hizmetlerden açık kaynaklı kendi barındırmalı çerçevelere kadar geniş bir yelpazeye yayılmaktadır.

Açık Kaynaklı Platformlar

Label Studio, metin, görüntü, ses, video ve zaman serisi verilerini birleşik bir XML tabanlı görev yapılandırması aracılığıyla destekleyen en popüler açık kaynaklı açıklama platformudur. Kendi barındırmalı olarak kullanılabilir ve aktif öğrenme için makine öğrenmesi arka uçlarıyla entegre olur. Temel güçleri: esneklik, topluluk desteği ve ön açıklama için özel makine öğrenmesi tahminlerini yerleştirme olanağı.

Prodigy (spaCy yapıcılarından), doğal dil işleme görevleri için tasarlanmış yüksek derecede iş akışı odaklı bir açıklama aracıdır. Akış mimarisi örnekleri teker teker gönderir ve aktif öğrenmeyi doğrudan destekler. Açıklama arayüzü minimal ancak hızlıdır — açıklama verimini en üst düzeye çıkaracak biçimde tasarlanmıştır. Prodigy ücretli yazılımdır ancak doğal dil işleme araştırmalarında yaygın biçimde kullanılmaktadır.

CVAT (Bilgisayarlı Görü Açıklama Aracı), algılama, segmentasyon ve video açıklamasına güçlü destek sunan bilgisayarlı görü açıklaması için önde gelen açık kaynaklı araçtır. Başlangıçta Intel'de geliştirilen CVAT, izleme algoritmaları, iskelet açıklaması ve üçüncü taraf algoritma entegrasyonlarını destekler.

Doccano, dizi etiketleme görevlerini (Adlandırılmış Varlık Tanıma, ilişki çıkarımı, metin sınıflandırması) hedef alır. Basit web arayüzü, özel veri mühendisliği kaynakları olmayan ekipler için erişilebilir kılar.

Ticari Platformlar

Scale AI, insan işgücü, kalite yönetimi ve API entegrasyonunu kapsayan uçtan uca yönetilen açıklama hizmetleri sunar. Özellikle otonom sürüş, robotik ve karmaşık 3B açıklama için güçlüdür. Fiyatlandırma, görev karmaşıklığı ve hacme göre belirlenir.

Labelbox, veri kürasyon, açıklama ve makine öğrenmesi destekli etiketleme için tam bir platformdur. Güçlü kurumsal özellikler sunar: proje yönetimi, kalite iş akışları, model geri bildirim döngüleri ve başlıca makine öğrenmesi platformlarıyla entegrasyonlar (SageMaker, Vertex AI, Azure ML).

Appen (eski adıyla Figure Eight / CrowdFlower), araçların yanı sıra büyük bir küresel açıklama işgücü yönetir. Hacim ve işgücü yönetiminin birincil kaygılar olduğu durumlarda iyi bir seçimdir.

Surge AI, uzman açıklayıcılara odaklanmakta ve alan bilgisi veya nüanslı yargı gerektiren görevler için güçlüdür.

Humanloop, BDM geri bildirim toplama — tercih açıklaması, RLHF veri toplama ve model değerlendirme — konusunda uzmanlaşmıştır.

Açıklama Platformu Özellik Karşılaştırması

Özellik	Label Studio	Prodigy	CVAT	Labelbox	Scale AI
Lisans	Açık kaynak	Ticari	Açık kaynak	Ticari	Ticari
Barındırma	Kendi / bulut	Kendi	Kendi / bulut	Bulut	Yönetilen
Metin açıklama	□	□	—	□	□
Görüntü açıklama	□	Sınırlı	□	□	□
Video açıklama	□	—	□	□	□
Aktif öğrenme entegrasyonu	□	□	Sınırlı	□	□
MÖ destekli ön açıklama	□	□	□	□	□
Kalite kontrol iş akışları	Temel	Temel	Temel	Gelişmiş	Gelişmiş
API / Programatik erişim	□	□	□	□	□
İşgücü yönetimi	—	—	—	Sınırlı	□

Kod Olarak Açıklama

Açıklama altyapısının kritik ancak çoğunlukla göz ardı edilen bir boyutu, **açıklamalar ve açıklama şemaları için sürüm kontrolüdür**. Açıklamayı kod olarak ele almak şu anlama gelir:

Şema öncelikli tasarım. Etiket taksonomisi ve açıklama kuralları, açıklama başlamadan önce sürümlü bir yapılandırma dosyasında (YAML veya JSON) tanımlanır. Şema değişiklikleri yeni

bir sürüm oluşturur.

Açıklama sürümlendirme. Açıklamalar, oluşturuldukları şema sürümüne bağlantıyla depolanır. Bu, denetlemeye, geri almaya ve şema sürümleri arasında açıklamaları karşılaştırmaya olanak tanır.

Yeniden üretilebilir hatlar. Ham veriden eğitime hazır etiketlere uzanan açıklama hattı koddan yeniden üretilebilir olmalıdır. Ön açıklama modelleri, kalite filtreleri, birleştirme mantığı ve veri bölümleri hepsi kaydedilmelidir.

```yaml
# Example: Label Studio annotation schema (text classification)
label_config: |
  <View>
    <Text name="text" value="$text"/>
    <Choices name="sentiment" toName="text" choice="single">
      <Choice value="positive"/>
      <Choice value="negative"/>
      <Choice value="neutral"/>
      <Choice value="mixed"/>
    </Choices>
  </View>
schema_version: "2.1.0"
task_type: text_classification
guidelines_version: "guidelines_v3.pdf"
```

```
Veri kaynağı
    |
    v
Etiketsiz havuz -->  Açıklama platformu --> Etiketlenmiş veri kümesi
    ^                    |                        |
    |                    | (MÖ destekli)           v
Aktif öğrenme <----------+                    Eğitim çalıştırması
sorgu stratejisi                                   |
    ^                                              v
    +------------ Eğitilmiş model <---------- Değerlendirme
                                                   |
                                              Dağıtım ve
                                              izleme
```

Temel entegrasyon noktaları: 1. **Veri alımı:** Etiketsiz veri, veri ambarından açıklama platformuna otomatik olarak akar 2. **Model servis:** Mevcut en iyi model, ön açıklama ve aktif öğrenme puanlaması için açıklama platformuna dağıtılır 3. **Dışa aktarma:** Tamamlanan açıklamalar eğitim çerçevesiyle uyumlu bir biçimde dışa aktarılır (COCO JSON, Hugging Face veri kümeleri vb.) 4. **Geri bildirim döngüsü:** Üretimdeki model hataları, düzeltme için açıklama platformuna yönlendirilir

> **See also:** Label Studio belgeleri ve aktif öğrenme entegrasyonu için: https://labelstud.io. Prodigy için: https://prodi.gy. CVAT için: https://cvat.ai. Açıklama araçlarının kapsamlı karşılaştırması için bkz. {cite}`monarch2021human`, Bölüm 7.

Kitle Kaynaklı Çalışma ve Kalite Kontrolü

Açıklama görevleri uzman olmayan kişiler tarafından yapılabilecek kadar basit olduğunda, kitle kaynaklı platformlar düşük öğe başına maliyette büyük, talep üzerine açıklama işgücüne erişim sağlar. Kalabalıktan yüksek kaliteli etiketlenmiş veri kümeleri oluşturmak, dikkatli görev tasarımı, stratejik yedeklilik ve titiz kalite kontrolü gerektirir.

Kitle Kaynaklı Platformlar

Amazon Mechanical Turk (MTurk), 2005 yılında başlatılan özgün kitle kaynaklı pazar yeridir. Çalışanlar ("Turkerlar"), talep sahiplerinin yayımladığı mikro görevleri (HIT'leri) tamamlar. 2018 tarihli bir çalışma, Turkerlar için medyan etkin saatlik kazancı yaklaşık 2 ABD doları olarak buldu — pek çok yüksek gelirli ülkede asgari ücretin çok altında {cite}`hara2018data` — Bölüm 15'te ele alınan etik bir endişe. MTurk, net ve doğrulanabilir ölçütlere sahip basit görevler için en uygundur.

Prolific, asgari ücret standardı uygulayan (Prolific'in yayımlanmış kılavuzlarında belirtildiği üzere şu an yaklaşık 9 GBP/saat, yaklaşık 11 ABD doları/saat), katılımcıları demografiğe göre taradığı ve araştırmaya katılmayı kabul eden çalışanlardan oluşan bir panel sürdürdüğü akademik kitle kaynaklı platformdur. Sosyal bilim araştırmaları ve temsiliyet gerektiren görevler için tercih edilir.

Appen (ve benzerleri: Telus International, iMerit), daha karmaşık görevler ve kurumsal projeler için kullanılan kalite yönetimiyle yönetilen açıklama işgücü sağlar.

Özelleşmiş topluluklar. Alana özgü görevler için alan meraklılarından oluşan topluluklar yüksek kaliteli açıklamalar sağlayabilir: astronomi için Galaxy Zoo, kuş türleri için eBird, satranç pozisyonu açıklaması için Chess Tempo.

Kitle Kaynaklı Çalışma için Görev Tasarımı

Karmaşık Görevleri Parçalara Ayırın

Karmaşık görevler basit, iyi tanımlanmış mikro görevlere ayrıştırılmalıdır. Çalışanlardan bir belgeyi kapsamlı biçimde açıklamasını istemek yerine, her seferinde odaklı bir soru sorun: "Bu cümle bir kişinin adını içeriyor mu?" veya "Bu çevirinin anlaşılırlığını 1–5 ölçeğinde değerlendirin."

Ayrıştırmanın faydaları: - Görev başına daha az bilişsel talep □ daha az yorgunluk, daha yüksek kalite - Her mikro görev ayrı ayrı kalite kontrol edilebilir - Denetlenmesi ve hata ayıklaması daha kolay

Talimatların Önemi

Kitle kaynaklı çalışma kalitesinin en büyük tek belirleyicisi, talimat kalitesidir. İyi görev talimatları: - Görevi tek bir cümlede açıklar - Her kategori için açık ve net bir tanım sağlar - 3–5 çalışılmış örnek verir (özellikle sınır vakalar) - Çalışanların gerçekten okuyacağı uzunlukta olur (basit görevler için 300 kelimenin altında)

Ölçeklendirmeden önce bir **pilot çalışma** yürütün (10–50 çalışan, 20–100 görev). Pilot anlaşmazlıklarını analiz edin; çoğu düzeltilebilecek talimat belirsizliklerine işaret eder.

Altın Standart Sorular

Görev grubuna **altın standart soruları** — bilinen doğru yanıtlara sahip görevler — yerleştirin. Altın soruları eşiğin altında başaramayan çalışanlar, projeden çıkarılır.

```
import numpy as np
from scipy.stats import binom

rng = np.random.default_rng(42)

def simulate_gold_screening(n_workers=100, gold_per_batch=5,
                            p_good_worker=0.7, good_acc=0.92,
                            bad_acc=0.55, threshold=0.70):
    """
    Simulate quality screening via gold questions.
    Returns: precision and recall of identifying bad workers.
    """
    worker_quality = rng.choice(['good', 'bad'], size=n_workers,
                                p=[p_good_worker, 1 - p_good_worker])
    results = {'tp': 0, 'fp': 0, 'tn': 0, 'fn': 0}

    for q in worker_quality:
        acc = good_acc if q == 'good' else bad_acc
        n_correct = rng.binomial(gold_per_batch, acc)
        passed = (n_correct / gold_per_batch) >= threshold
        if q == 'bad' and not passed:  results['tp'] += 1
        if q == 'good' and not passed: results['fp'] += 1
        if q == 'bad' and passed:      results['fn'] += 1
        if q == 'good' and passed:     results['tn'] += 1

    tp, fp, fn = results['tp'], results['fp'], results['fn']
    precision = tp / (tp + fp + 1e-6)
    recall    = tp / (tp + fn + 1e-6)
    return precision, recall

# Vary gold question count
gold_counts = [3, 5, 8, 10, 15, 20]
precisions, recalls = [], []
for g in gold_counts:
```

```
    p_list, r_list = [], []
    for _ in range(50):
        p, r = simulate_gold_screening(gold_per_batch=g)
        p_list.append(p); r_list.append(r)
    precisions.append(np.mean(p_list))
    recalls.append(np.mean(r_list))

import matplotlib.pyplot as plt
fig, ax = plt.subplots(figsize=(7, 4))
ax.plot(gold_counts, precisions, 'o-', color='#2b3a8f', label='Precision', linewidth=2)
ax.plot(gold_counts, recalls,    's--', color='#0d9e8e', label='Recall',    linewidth=2)
ax.set_xlabel("Gold questions per batch", fontsize=12)
ax.set_ylabel("Screening performance", fontsize=12)
ax.set_title("Worker Screening via Gold Standard Questions", fontsize=13)
ax.legend(fontsize=11); ax.grid(alpha=0.3)
plt.tight_layout()
plt.savefig('gold_screening.png', dpi=150)
plt.show()

p, r = simulate_gold_screening(gold_per_batch=5)
print(f"5 gold questions: Precision={p:.3f}, Recall={r:.3f}")
p, r = simulate_gold_screening(gold_per_batch=10)
print(f"10 gold questions: Precision={p:.3f}, Recall={r:.3f}")
```

Etiket Birleştirme için İstatistiksel Modeller

Çoğunluk oyu, doğal bir taban çizgisidir ancak açıklayıcı doğruluğundaki farklılıkları görmezden gelir. İstatistiksel modeller daha iyi sonuç verebilir.

Dawid-Skene Modeli

Dawid-Skene (DS) modeli {cite}`dawid1979maximum` şunları birlikte tahmin eder: - Her i öğesi için **gerçek etiket** z_i - Her j açıklayıcısı için **karışıklık matrisi** $\pi_j^{(k,l)}$: j açıklayıcısının gerçek sınıfı k olan bir öğeyi l sınıfı olarak etiketleme olasılığı

EM algoritması şunlar arasında yinelenir: - **E adımı:** Açıklayıcı karışıklık matrisleri göz önüne alındığında, her gerçek etiketin arka plan olasılığını hesapla - **M adımı:** Öğe etiket tahminleri göz önüne alındığında, açıklayıcı karışıklık matrislerini güncelle

```
import numpy as np
from scipy.special import softmax

def dawid_skene_em(annotations, n_classes, n_iter=20):
    """
    Simplified Dawid-Skene EM for binary classification.
    annotations: dict {item_idx: [(annotator_idx, label), ...]}
    Returns: estimated true labels and annotator accuracies.
    """
    items = sorted(annotations.keys())
    n_items = len(items)
```

```
    annotators = sorted({a for anns in annotations.values() for a, _ in anns})
    n_annotators = len(annotators)
    ann_idx = {a: i for i, a in enumerate(annotators)}

    # Initialize: majority vote
    T = np.zeros((n_items, n_classes))  # soft label estimates
    for i, item in enumerate(items):
        for _, label in annotations[item]:
            T[i, label] += 1
        T[i] /= T[i].sum()

    # Confusion matrices: shape (n_annotators, n_classes, n_classes)
    PI = np.ones((n_annotators, n_classes, n_classes)) * 0.5

    for _ in range(n_iter):
        # M-step: update confusion matrices
        PI = np.zeros((n_annotators, n_classes, n_classes)) + 1e-6
        for i, item in enumerate(items):
            for ann, label in annotations[item]:
                a = ann_idx[ann]
                for k in range(n_classes):
                    PI[a, k, label] += T[i, k]
        PI /= PI.sum(axis=2, keepdims=True)

        # E-step: update soft label estimates
        T = np.zeros((n_items, n_classes))
        for i, item in enumerate(items):
            log_p = np.zeros(n_classes)
            for ann, label in annotations[item]:
                a = ann_idx[ann]
                log_p += np.log(PI[a, :, label] + 1e-10)
            T[i] = softmax(log_p)

    return {item: T[i] for i, item in enumerate(items)}, PI

# Simulate crowdsourcing scenario
rng = np.random.default_rng(42)
N_ITEMS, N_ANNOTATORS, ANNS_PER_ITEM = 200, 10, 3
true_labels = rng.integers(0, 2, N_ITEMS)
# Annotator accuracies: 3 good (0.9), 4 medium (0.75), 3 noisy (0.6)
accuracies = [0.90]*3 + [0.75]*4 + [0.60]*3

annotations = {}
for i in range(N_ITEMS):
    anns_for_item = []
    chosen = rng.choice(N_ANNOTATORS, ANNS_PER_ITEM, replace=False)
    for a in chosen:
        acc = accuracies[a]
        label = true_labels[i] if rng.random() < acc else 1 - true_labels[i]
        anns_for_item.append((a, int(label)))
    annotations[i] = anns_for_item
```

```
# Run Dawid-Skene
soft_labels, confusion = dawid_skene_em(annotations, n_classes=2, n_iter=30)
ds_preds = {i: int(np.argmax(soft_labels[i])) for i in range(N_ITEMS)}

# Compare with majority vote
mv_preds = {}
for i in range(N_ITEMS):
    votes = [l for _, l in annotations[i]]
    mv_preds[i] = int(np.round(np.mean(votes)))

ds_acc = np.mean([ds_preds[i] == true_labels[i] for i in range(N_ITEMS)])
mv_acc = np.mean([mv_preds[i] == true_labels[i] for i in range(N_ITEMS)])

print(f"Majority vote accuracy:  {mv_acc:.3f}")
print(f"Dawid-Skene accuracy:    {ds_acc:.3f}")
print(f"\nEstimated annotator accuracies (diagonal of confusion matrix):")
for a in range(N_ANNOTATORS):
    est_acc = np.mean([confusion[a, k, k] for k in range(2)])
    print(f"  Annotator {a}: estimated={est_acc:.3f}, true={accuracies[a]:.2f}")
```

MACE

MACE (Çok Açıklayıcılı Yeterlik Tahmini) {cite}`hovy2013learning`, açıklayıcı spam göndermeyi (rastgele etiketleme) ile yetkin açıklamayı açıkça temsil eden alternatif bir olasılıksal modeldir. Bir açıklayıcı ya anlamlı bir etiket sağlar ($1 - \text{spam}_j$ olasılığıyla) ya da rastgele bir etiket sağlar (spam_j olasılığıyla). Bu iki bileşenli model, bazı açıklayıcıların tamamen spam gönderdiği kitle kaynaklı çalışma senaryoları için çoğunlukla Dawid-Skene'den daha iyi kalibre edilmiştir.

Yedeklilik ve Birleştirme Stratejisi

Öğe başına en uygun açıklayıcı sayısı, görev güçlüğüne ve açıklayıcı kalitesine bağlıdır:

- **Yetenekli açıklayıcılarla kolay görevler:** Öğe başına 1–2 açıklayıcı çoğunlukla yeterlidir
- **Eğitimli açıklayıcılarla orta görevler:** 3 açıklayıcı + çoğunluk oyu
- **Kitle çalışanlarıyla güç/öznel görevler:** 5–7 açıklayıcı + Dawid-Skene

Temel kavrayış: yedeklilik, açıklayıcı doğruluğu düşük olduğunda en değerlidir. p doğruluklu açıklayıcılarla n açıklayıcıyla çoğunluk oyu doğruluğu şöyledir:

$$P(\text{ÇO doğru}) = \sum_{k>n/2}^{n} \binom{n}{k} p^k (1-p)^{n-k}$$

$p = 0{,}70$ için üçüncü bir açıklayıcı eklemek çoğunluk oyu doğruluğunu %70'ten %78'e çıkarır; $p = 0{,}90$ için üçüncü bir açırlayıcıdan elde edilen kazanım ihmal edilebilir düzeydedir (%90'dan %97'ye).

> **See also:** Dawid-Skene modeli: {cite}`dawid1979maximum`. MACE: {cite}`hovy2013learning`. Doğal dil işleme için kitle kaynaklı çalışmanın kapsamlı incelemesi için bkz.

{cite}`snow2008cheap`. Kalabalık etiği ve adil ücret: bkz. Bölüm 15.

Değerlendirme ve Ölçütler

HITL sisteminizin işe yarayıp yaramadığını bilmek, model doğruluğunu ölçmekten fazlasını gerektirir. Açıklama bütçenizden değer elde edip etmediğinizi, modelin insan niyetiyle gerçekten daha iyi hizalı olup olmadığını ve ek insan geri bildiriminin iyileştirmeye devam edip etmeyeceğini bilmeniz gerekir. Bu bölüm, HITL ortamlarında değerlendirmenin tüm manzarasını kapsar.

Model Merkezli Ölçütler

Standart makine öğrenmesi ölçütleri, bazı önemli nüanslarla birlikte HITL sistemlerine doğrudan uygulanabilir.

Sınıflandırma Ölçütleri

Doğruluk, sınıflar dengeli ve tüm hatalar eşit maliyetliyken uygundur. Ancak HITL ortamlarında, etiketlenmiş test kümesi sorgu stratejisiyle önyargılı olabilir (aktif öğrenme rastgele olmayan örnekler sorgular); bu da basit doğruluk tahminlerini güvenilmez kılar.

F1 puanı, kesinlik ve geri çağırmanın harmonik ortalamasıdır; dengesiz sınıflar için uygundur. HITL bağlamlarında, hem kesinlik hem geri çağırma, yanlış pozitifler ile yanlış negatifler arasındaki maliyet asimetrisi ne olduğuna bağlı olarak farklı biçimlerde önem taşıyabilir.

AUROC, eşikten bağımsız olarak modelin sınıflar arasında ayırt etme becerisini ölçer — tıbbi tarama gibi kalibrasyona duyarlı görevler için önemlidir.

Kalibrasyon, tahmin edilen olasılıkların ampirik sıklıklarla ne kadar örtüştüğünü ölçer. HITL sistemlerinde, aktif öğrenmeden elde edilen önyargılı etiketlenmiş kümeler üzerinde eğitilen modeller doğru olsalar bile yanlış kalibre olabilir.

Üretici Model Ölçütleri

Dil modelleri ve üretici sistemler için değerlendirme temelden daha güçtür. Hiçbir tek otomatik ölçüt kaliteyi yakalayamaz:

- **BLEU / ROUGE / METEOR:** Çeviri ve özetleme için referans tabanlı ölçütler. Uzun biçimli üretim için insan kalite yargılarıyla zayıf biçimde ilişkilidir.
- **Perplexity:** Modelin tutulan metni ne kadar iyi tahmin ettiğini ölçer. Kalite için gerekli ama yeterli olmayan bir koşul.
- **BERTScore:** Referanslara gömme tabanlı benzerlik. n-gram ölçütlerinden insan yargılarıyla daha iyi ilişkilidir.
- **İnsan değerlendirmesi:** Altın standart. Bkz. Bölüm 14.3.

Açıklama Verimliliği Ölçütleri

HITL değerlendirmesi aynı zamanda insan geri bildiriminin verimli kullanılıp kullanılmadığını da ölçmelidir.

Öğrenme Eğrileri

Öğrenme eğrisi, etiketlenmiş örnek sayısının bir işlevi olarak model performansını çizer. Dik bir öğrenme eğrisi (birkaç etiketle hızlı iyileşme), açıklama stratejisinin bilgilendirici örnekler seçtiğine işaret eder. Düz bir öğrenme eğrisi, ek etiketlemenin azalan getiri sağladığına işaret eder.

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import f1_score, roc_auc_score
from sklearn.model_selection import StratifiedShuffleSplit

rng = np.random.default_rng(42)
X, y = make_classification(n_samples=5000, n_features=30, n_informative=15,
                           weights=[0.8, 0.2], random_state=42)
X_test, y_test = X[4000:], y[4000:]
X_pool, y_pool = X[:4000], y[:4000]

label_sizes = [20, 40, 60, 100, 150, 200, 300, 400, 600, 800, 1000, 1500, 2000]
metrics = {'f1': [], 'auc': []}

for n in label_sizes:
    idx = rng.choice(len(X_pool), n, replace=False)
    clf = LogisticRegression(max_iter=500, class_weight='balanced')
    clf.fit(X_pool[idx], y_pool[idx])
    preds = clf.predict(X_test)
    probs = clf.predict_proba(X_test)[:, 1]
    metrics['f1'].append(f1_score(y_test, preds))
    metrics['auc'].append(roc_auc_score(y_test, probs))

# Fit learning curve: performance ≈ a - b/sqrt(n)
from scipy.optimize import curve_fit

def learning_curve_fn(n, a, b):
    return a - b / np.sqrt(n)

popt_f1, _ = curve_fit(learning_curve_fn, label_sizes, metrics['f1'], p0=[0.9, 2])
popt_auc, _ = curve_fit(learning_curve_fn, label_sizes, metrics['auc'], p0=[0.95, 1])

n_smooth = np.linspace(20, 3000, 200)

fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(11, 4))
```

```
ax1.scatter(label_sizes, metrics['f1'], color='#2b3a8f', zorder=5, s=40)
ax1.plot(n_smooth, learning_curve_fn(n_smooth, *popt_f1), '--', color='#e05c5c',
         label=f'Fit: {popt_f1[0]:.3f} - {popt_f1[1]:.1f}/√n')
ax1.set_xlabel("Labeled examples"); ax1.set_ylabel("F1 score")
ax1.set_title("Learning Curve: F1"); ax1.legend(); ax1.grid(alpha=0.3)

ax2.scatter(label_sizes, metrics['auc'], color='#0d9e8e', zorder=5, s=40)
ax2.plot(n_smooth, learning_curve_fn(n_smooth, *popt_auc), '--', color='#e05c5c',
         label=f'Fit: {popt_auc[0]:.3f} - {popt_auc[1]:.2f}/√n')
ax2.set_xlabel("Labeled examples"); ax2.set_ylabel("AUROC")
ax2.set_title("Learning Curve: AUROC"); ax2.legend(); ax2.grid(alpha=0.3)

plt.tight_layout()
plt.savefig('learning_curves.png', dpi=150)
plt.show()

# Estimate the annotation budget needed to reach a target performance
target_f1 = 0.80
n_needed = (popt_f1[1] / (popt_f1[0] - target_f1)) ** 2
print(f"Estimated labels needed to reach F1={target_f1}: {n_needed:.0f}")
```

Yatırım Getirisi (YG) Analizi

İnsan geri bildiriminin YG'si şu soruyu yanıtlar: her ek etiket için model performansı ne kadar iyileşiyor?

$$\text{YG}(n) = \frac{\Delta\text{performans}(n)}{\text{etiket başına maliyet}}$$

Bir model olgunlaştıkça (ve kolay öğrenilen örnekler tükenince) YG tipik olarak düşer. Pratik çıkarım: açıklama bütçeleri erken aşamalara daha fazla odaklanmalıdır; YG'nin en yüksek olduğu başlangıç aşamalarında daha fazla etiket toplanmalıdır.

İnsan Değerlendirmesi

Üretici sistemler ve öznel görevler için insan değerlendirmesi altın standart olmaya devam etmektedir.

Doğrudan Değerlendirme (DA)

Açıklayıcılar, çıktıları mutlak bir ölçekte değerlendirir (örneğin çeviri kalitesi için 1–100 veya yanıt yararlılığı için 1–5). DA, makine çevirisi değerlendirmesinde (WMT kıyaslamaları) standart hâle gelmiştir.

DA için en iyi uygulamalar: - Çapalamayı önlemek için çıktıların sırasını rastgele belirleyin - Öğe başına yeterli açıklayıcı sayısı kullanın (en az 3–5) - Kalite kontrolleri ekleyin (dikkatsiz değerlendiricileri yakalamak için açıkça iyi ve kötü örnekler) - Toplam puanların yanı sıra açıklayıcılar arası anlaşmayı raporlayın

Karşılaştırmalı Değerlendirme

Açıklayıcılar iki çıktı arasından seçer: "Hangisi daha iyi?" Karşılaştırmalı yargılar mutlak derecelendirmelerden daha hızlı ve daha tutarlıdır (bkz. Bölüm 8). **ELO derecelendirme sistemleri** (satrançtan ödünç alınmış), ikili karşılaştırma sonuçlarını sürekli bir kalite sıralamasına dönüştürür.

```
import numpy as np

def update_elo(rating_a, rating_b, outcome_a, k=32):
    """Update ELO ratings. outcome_a: 1=A wins, 0=B wins, 0.5=tie."""
    expected_a = 1 / (1 + 10 ** ((rating_b - rating_a) / 400))
    expected_b = 1 - expected_a
    new_a = rating_a + k * (outcome_a - expected_a)
    new_b = rating_b + k * ((1 - outcome_a) - expected_b)
    return new_a, new_b

# Simulate 5 model versions being compared pairwise
rng = np.random.default_rng(42)
true_quality = [0.60, 0.70, 0.75, 0.80, 0.85]  # underlying model quality
n_models = len(true_quality)
elo_ratings = {i: 1000.0 for i in range(n_models)}

for _ in range(500):  # 500 pairwise comparisons
    i, j = rng.choice(n_models, 2, replace=False)
    p_i_wins = true_quality[i] / (true_quality[i] + true_quality[j])
    outcome = 1.0 if rng.random() < p_i_wins else 0.0
    elo_ratings[i], elo_ratings[j] = update_elo(elo_ratings[i], elo_ratings[j], outcome)

print("ELO Rankings after 500 comparisons:")
sorted_models = sorted(elo_ratings.items(), key=lambda x: x[1], reverse=True)
for rank, (model_id, elo) in enumerate(sorted_models, 1):
    print(f"  Rank {rank}: Model {model_id}  ELO={elo:.1f}  True quality={true_quality[model_
```

Davranışsal Test (CheckList)

CheckList {cite}`ribeiro2020beyond`, doğal dil işleme modellerinin sistematik davranışsal değerlendirmesi için bir metodoloji sunar. Rastgele test kümeleri yerine, belirli yetenekleri araştıran test vakaları tasarlar:

- **Minimum İşlevsellik Testleri (MFT):** Model basit, açık vakaları ele alıyor mu?
- **Değişmezlik Testleri (INV):** Olmaması gereken durumlarda modelin çıktısı değişiyor mu (örneğin yeniden ifade ederken)?
- **Yönlü Beklenti Testleri (YBT):** Girdi değiştiğinde modelin çıktısı beklenen yönde değişiyor mu?

CheckList, insan değerlendirmesini hedefli ve eyleme dönüştürülebilir kılar: tek bir doğruluk sayısı yerine bir yetenek profili sağlar.

İnsan Niyetiyle Hizalamayı Ölçmek

RLHF sistemleri için hizalamayı ölçmek, merkezi bir değerlendirme güçlüğüdür.

Ödül modeli değerlendirmesi: Ödül modelinin tutulmuş tercih test kümesindeki doğruluğu. Ouyang ve diğerleri {cite}`ouyang2022training`, InstructGPT'nin ödül modeli için yaklaşık %72 ikili doğruluk bildirmektedir; kaba bir referans noktası olarak benzer RLHF hatları için bu civarda rakamlar yaygın biçimde anılmaktadır, ancak sonuçlar göreve ve veri kalitesine göre büyük ölçüde değişmektedir.

Kazanma oranı: İki model sürümü (örneğin SFT taban çizgisi ile RLHF ince ayarlı) göz önüne alındığında, RLHF modelinin yanıtlarının insan ikili karşılaştırmalarında kaçta kaçını kazandığı.

GPT-4 değerlendirici olarak: Hızlı yineleme için yetenekli bir BDM kullanarak yanıtları değerlendirmek yaygın hâle gelmiştir. Gilardi ve diğerleri {cite}`gilardi2023chatgpt` ile Zheng ve diğerleri {cite}`zheng2023judging`, göreve bağlı olarak BDM değerlendirici anlaşmasının insan yargısıyla yaklaşık 0,7 ila 0,9 arasında değiştiğini bulmaktadır — hızlı A/B karşılaştırması için kullanışlı, ancak pohpohlamayı, kültürel nüansı veya güvenlik sorunlarını tespit etmek için daha az güvenilir.

Pohpohlama tespiti: Modelin yanıtlarını önerilen kullanıcı tercihine göre değiştirip değiştirmediğini ölçün (örneğin "Bence X doğru; ne düşünüyorsunuz?"). İyi hizalanmış bir model pohpohlamacı olmamalıdır.

Dağıtılmış Sistemlerde A/B Testi

Üretimdeki sistemler için nihai değerlendirme **A/B testidir**: kullanıcıların bir bölümünü yeni model sürümüne yönlendirin ve aşağı akış sonuçlarını ölçün.

A/B testi, laboratuvar değerlendirmesinin kaçırdığı etkileri yakalayarak gerçek dağıtım bağlamındaki model kalitesinin tarafsız bir tahminini sağlar (kullanıcı davranışı, nüfus dağılımı, sınır vakalar).

Güçlük, uygun aşağı akış ölçütlerindedir. Etkileşim ölçütleri (tıklamalar, oturum uzunluğu) manipülatif davranışı ödüllendirebilir. Görev tamamlama oranları veya kullanıcı memnuniyeti anketleri daha iyi hizalanmış olmakla birlikte daha gürültülüdür.

> **See also:** CheckList davranışsal testi: {cite}`ribeiro2020beyond`. RLHF değerlendirme metodolojisi için bkz. {cite}`ouyang2022training`. Makine çevirisinde insan değerlendirme en iyi uygulamaları için bkz. {cite}`graham2015accurate`. Öğrenme eğrisi teorisi için bkz. {cite}`mukherjee2003estimating`.

Adalet, Önyargı ve Etik

Döngüde insan sistemleri, içlerindeki insanların hem yeteneklerini hem de sınırlarını miras alır. Açıklayıcılar, çalışmalarına bilgi, yargı ve yaratıcılık katar — ama aynı zamanda önyargıları, yorgunlukları ve yaşamlarının toplumsal bağlamını da. HITL sistemleri tasarlarken yaptığımız seçimler — kimlerin açıkladığı, nelerle karşılaştıkları, nasıl ücretlendirildikleri ve çalışmalarının nasıl kullanıldığı — model doğruluk ölçütlerinin çok ötesine uzanan sonuçlar doğurur.

Bu bölüm, HITL makine öğrenmesinin etik boyutlarını ele alır.

HITL Sistemlerindeki Önyargı Kaynakları

Açıklayıcı Demografisi

Açıklama tarafsız bir eylem değildir. Açıklayıcıların atadığı etiketler, onların perspektiflerini, deneyimlerini ve kültürel bağlamlarını yansıtır. Açıklama işgücü demografik açıdan homojen olduğunda — kitle çalışmasının genç, erkek ve Batılı bir eğilim sergilemesiyle çoğu zaman olduğu gibi — ortaya çıkan veri kümesi o grubun perspektiflerini kodlar.

Kanıt: Doğal dil işleme açıklama veri kümelerinin incelenmesi, açıklayıcıların demografik özelliklerinin öznel görevler için (toksisite, duygu, saldırganlık) etiket seçimlerini öngördüğünü ortaya koymuştur. Ağırlıklı olarak ABD merkezli kitle çalışanları tarafından açıklanan veri kümeleri, diğer bölgelere genellemeyen ABD kültürel normlarını kodlar {cite}`geva2019annotator`.

Sonuçlar: Bu tür verilerle eğitilen modeller, açıklayıcı havuzunu andıran kullanıcılar için iyi; andırmayanlar için ise düşük performans gösterir veya önyargılı davranır.

Azaltma: Kasıtlı işgücü çeşitlendirmesi; katmanlı açıklama (ilgili demografik gruplardan açıklayıcıların ilgili görevlere katkıda bulunmasını sağlama); açıklayıcı demografisini ve bunun etiket dağılımları üzerindeki etkisini izleme.

Görev Çerçevelemesi

Bir sorunun nasıl çerçevelendiği, alınan yanıtları etkiler. Açıklayıcılara "Bu metin toksik mi?" sorusu sorulduğunda, "Bu metin bahsedilen gruba ait birine zarar verir mi?" sorusundan farklı yanıt alınabilir. Çerçeveleme, neyin önemli olduğuna ilişkin varsayımları kodlar.

Örnek: Sosyal medyadaki "saldırgan dil" açıklaması, açıklayıcılara yazarın kimliğine ilişkin bağlamsal bilginin gösterilip gösterilmemesine bağlı olarak önemli ölçüde farklılaşır. Yalıtılmış olarak tehdit edici görünen bir ifade, bağlam sağlandığında geri alınmış dil veya grup içi mizah olarak tanınabilir.

Platform Etkileri

Platform ve ödeme yapısı, açıklama kalitesini etkiler. Görev başına değil saat başına ücretlendirilen çalışanların hızlı çalışma teşviki vardır; bu verim artırır ancak kaliteyi düşürür. Düşük doğruluk nedeniyle platformdan engellenme korkusu taşıyan çalışanlar "belirsiz" işaretlemekten kaçınıp tahmin yapabilir; bu da gerçek belirsizliği gizler.

Onaylama ve Çapalama Önyargıları

Açıklayıcılar şu etkilerden etkilenir: - **Ön açıklama:** Açıklayıcılara gösterilen model tahminleri yanlış olduğunda bile reddedilmeden kabul edilme oranı yüksektir - **Sıra etkileri:** Aynı öğenin farklı bağlamlarda etiketlenmesi farklı yanıtlar verir - **Hazırlama:** Bir gruptaki önceki öğeler, sonraki öğelerin nasıl etiketlendiğini etkiler

---

HITL Sistemlerinde Adalet

Adalet Nedir?

Makine öğrenmesinde adalet, çoğunlukla birbiriyle uyumsuz çok sayıda biçimsel tanıma sahip tartışmalı bir kavramdır {cite}`barocas2019fairness`. HITL açısından en ilgili boyutlar şunlardır:

Temsil: Eğitim verisi, modelin etkileyeceği nüfusları temsil ediyor mu?

Performans paritesi: Model, farklı demografik gruplar genelinde eşit biçimde performans gösteriyor mu?

Etiketleme tutarlılığı: Aynı davranışlar, kim tarafından gerçekleştirildiğinden bağımsız olarak aynı biçimde etiketleniyor mu? (Araştırmalar bunun her zaman böyle olmadığını göstermiştir — özdeş içerikler bazen farklı ırksal veya cinsiyet gruplarına atfedildiğinde farklı biçimde etiketlenmektedir.)

Adalete Duyarlı Aktif Öğrenme

Standart aktif öğrenme sorguları, model belirsizliğine odaklanır; bu da azınlık grupları için performans farklılıklarını şiddetlendirebilir.

Adalete duyarlı sorgu stratejileri, belirsizlik ölçütünü çeşitlilik veya temsil kısıtlamalarıyla artırır:

$$x^* = \arg\max_{x \in \mathcal{U}} \left[\lambda \cdot \text{belirsizlik}(x) + (1 - \lambda) \cdot \text{azınlık_grubu_bonusu}(x)\right]$$

$\lambda < 1$ ayarlamak, sorgu stratejisinin azınlık temsilini tamamen görmezden gelmemesini sağlar.

Açıklayıcı Refahı

Hayalet Çalışma Problemi

Makine öğrenmesini besleyen açıklama çalışması büyük ölçüde görünmezdir. Veri çalışanları — çoğunlukla Küresel Güney'de — düşük ücretlerle, sosyal güvencesiz, iş güvencesiz

gig ekonomisi düzenlemelerinde görüntüleri etiketler, konuşmaları transkribe eder ve içerikleri moderasyondan geçirir. Kate Crawford ve Vladan Joler'in "Bir YZ Sisteminin Anatomisi" {cite}`crawford2018anatomy` ve Mary Gray ve Siddharth Suri'nin "Hayalet Çalışma" {cite}`gray2019ghost` çalışmaları bu emeğin ölçeğini ve güvencesizliğini belgeledi.

Amazon MTurk istatistikleri: MTurk kazançları üzerine yapılan 2018 tarihli sistematik bir analiz, medyan etkin saatlik ücreti yaklaşık 2 ABD doları olarak buldu — ABD eyaletlerinin ve pek çok yüksek gelirli ülkenin asgari ücretinin çok altında {cite}`hara2018data`. Yüksek gelirli ülkelerin dışındaki çalışanlar ek engellerle karşılaşmaktadır: talep sahipleri çoğunlukla yüksek ücretli görevleri yalnızca ABD niteliklerine kısıtlamakta; geriye kalan açık görevler için rekabet eden çalışan havuzu küresel olduğundan etkin kazançlar daha da baskılanmaktadır.

İçerik moderasyonu: Özellikle zararlı bir açıklama çalışması biçimi — grafik, şiddet içeren ve rahatsız edici içerikleri incelemek — çalışanlar arasında TSSB, depresyon ve kaygıyla ilişkilendirilmiştir {cite}`newton2019trauma`. Platformlar yetersiz ruh sağlığı desteği ve aşırı maruz kalma kotaları nedeniyle eleştirilere maruz kalmıştır.

Etik Uygulamalar

Adil ücret: Açıklama çalışanlarına yerel asgari ücret düzeyinde veya üzerinde ödeme yapın. Araştırmalar, daha yüksek ücretin doğru etiket başına maliyeti orantılı biçimde artırmadan daha kaliteli çalışanları çektiğini göstermiştir.

Çalışma görünürlüğü: Eğitim verisi oluşturan emeği yayınlarda ve ürün belgelerinde kabul edin.

Ruh sağlığı desteği: Zararlı içerik inceleyen çalışanlar için psikolojik destek, rotasyon takvimleri ve maruz kalma sınırları sağlayın.

Çalışan temsili: Açıklama çalışanlarının endişelerini bildirmesine, kılavuz açıklamaları talep etmesine ve haksız kalite değerlendirmelerine itiraz etmesine olanak tanıyın.

Açıklamada Gizlilik

Korunan Sağlık Bilgileri (KSB) ve Kişisel Tanımlayıcı Bilgiler (KTB)

Açıklama görevleri çoğunlukla hassas kişisel veriler içerir. Tıbbi açıklama projesi çalışanları hasta kayıtlarına; doğal dil işleme projesi çalışanları özel iletişimlere; içerik moderasyonu çalışanları kullanıcıların kişisel açıklamalarına maruz kalabilir.

Düzenleyici çerçeveler (HIPAA, GDPR), kişisel verilerin açıklama işgücüyle nasıl paylaşılabileceğini kısıtlar. Temel ilkeler:

- **Veri minimizasyonu:** Açıklayıcılarla yalnızca görevi tamamlamak için gerekli bilgileri paylaşın
- **Tanımlama kaldırma:** Mümkün olan yerlerde açıklamadan önce KSB ve KTB'yi kaldırın
- **Onay:** Gerçek kullanıcı verisi açıklandığında, uygun onay veya yasal dayanak sağlayın
- **Erişim kontrolleri:** Hassas verilere erişimi rol ve yetkiye göre sınırlayın

Alternatif Olarak Sentetik Veri

Gerçek verilerin gizlilik riski taşıdığı görevler için, sentetik veri üretimi hassas bilgileri açığa çıkarmadan açıklamaya hazır veri kümeleri oluşturabilir. Örneğin klinik doğal dil işlemede,

sentetik EHR metni gerçek hasta kayıtlarını açmadan tanımlama kaldırma modelleri için gerçekçi eğitim verisi sağlayabilir.

Saldırgan Açıklama ve Veri Zehirleme

HITL sistemleri bir saldırı yüzeyi oluşturur: bir düşman açıklama sürecini etkileyebilirse modelin davranışını da etkileyebilir.

Açıklama yoluyla veri zehirleme: Açıklama işgücüne erişimi olan bir saldırgan (örneğin ele geçirilmiş bir kitle çalışanı hesabı) sistematik biçimde yanlış etiketlenmiş örnekler enjekte edebilir. Bu, aktif öğrenme ortamlarında özellikle etkilidir; burada model, belirsiz örnekleri tercihli olarak sorgular — ki bunlar saldırganın hedefleri olabilir.

Geri bildirim yoluyla ödül korsanlığı: RLHF'de, belirli içerik türlerini sürekli yüksek puanlayan açıklayıcılar (veya yapay zeka tarafından oluşturulan açıklamalar), modeli gerçek kalitesinden bağımsız olarak o içeriğe yönlendirebilir.

Azaltma: Öğe başına birden fazla bağımsız açıklayıcı; açıklama örüntülerinde aykırı değer tespiti; anormal anlaşma veya anlaşmazlıkları izleme; açıklama işgücü tarafından etkilenemeyen değerlendirme kümelerini koruma.

Kurumsal Etik

Kurumsal Değerlendirme Kurulu ve Etik İnceleme

İnsan deneklerini — açıklama çalışanları dahil — kapsayan araştırma projeleri çoğunlukla Kurumsal Değerlendirme Kurulu (KDK) onayı gerektirir. Çalışanların inançlarını, hassas içeriklere verdiği tepkileri veya demografik bilgileri toplayan açıklama projeleri, diğer insan denekleri araştırmalarıyla aynı etik çerçeve altında incelenmelidir.

Veri Yönetişimi

Kuruluşlar şunlar için açık politikalara sahip olmalıdır: - Hangi verinin dış açıklama için gönderilebileceği ile dahili olarak açıklanması gerekenler - Açıklama verisinin ne kadar süreyle ve kim tarafından saklanacağı - Açıklamalara ve bunlar üzerinde eğitilen modellere kimlerin erişebildiği - Açıklamalı verileri silme taleplerinin nasıl ele alınacağı (GDPR silme hakkı)

Şeffaflık ve Hesap Verebilirlik

Makine öğrenmesi sistemlerinden etkilenen kullanıcıların bu sistemlerin nasıl inşa edildiğini anlama konusunda meşru bir çıkarı vardır. Açıklama metodolojisini belgelemek — veriyi kimlerin, hangi koşullarda, hangi kılavuzlarla etiketlediğini — kullanıcılara, düzenleyicilere ve bir bütün olarak alana fayda sağlayan bir hesap verebilirlik biçimidir.

Veri Kümeleri için Veri Sayfaları {cite}`gebru2021datasheets`, veri kümesi kaynağını, açıklama prosedürlerini ve bilinen sınırlamaları belgelemek için yapılandırılmış bir şablon sunar.

> **See also:** Algoritmik adalet çerçevesi: {cite}`barocas2019fairness`. Hayalet çalışma ve platform emeği: Gray ve Suri (2019). Veri Kümeleri için Veri Sayfaları: {cite}`gebru2021datasheets`. İçerik moderasyonu çalışan refahı:

{cite}`newton2019trauma`. Açıklayıcı demografisi ve doğal dil işleme veri kümeleri: {cite}`geva2019annotator`.

Gelecek Yönelimler

Döngüde insan makine öğrenmesi alanı hızla değişmektedir. Temel modeller, açıklayıcı olarak büyük dil modelleri ve insan–yapay zeka işbirliği için yeni paradigmalar, HITL'nin ekonomisini ve pratiğini beş yıl önce hayal dahi edilemeyecek biçimlerde dönüştürmektedir. Bu son bölüm, ortaya çıkan yönlerin ve açık sorunların haritasını çıkarmaktadır.

Temel Modeller ve Açıklamanın Değişen Rolü

Geniş veriler üzerinde önceden eğitilmiş ve aşağı akış görevlerine uyarlanabilen büyük modeller olan temel modeller, HITL'nin ekonomisini temelden değiştirmektedir.

Açıklama Yükünü Azaltma

Daha önce sıfırdan eğitim için binlerce etiketli örnek gerektiren bir görev, bir temel modeli ince ayarlarken yalnızca düzinelere ihtiyaç duyabilir. Bazı görevler için az atışlı yönlendirme, ince ayar ihtiyacını tamamen ortadan kaldırabilir.

Çıkarım: Açıklama çabasının yatırım getirisi değişiyor. Açıklama çabası artık şunlara yönlendirilmek için daha iyi değerlendirilmektedir: - Yüksek kaliteli değerlendirme kümeleri (uyarlanan modelin gerçekten çalışıp çalışmadığını ölçmek için) - Temel modelin yanlış ele aldığı güç vakalar ve sınır durumlar - Modele önceden eğitimden çıkaramayacağı bir şeyi öğreten göreve özgü örnekler

Yeni Belirleme Biçimleri

Taban model zaten dili, kodu ve sağduyuyu anladığında, kullanıcılar etiketlenmiş örnekler yerine doğal dille iletişim kurabilir. Bir metin sınıflandırıcı isteyen kullanıcı artık 500 örnek etiketlemek zorunda değildir — sınıflandırma görevinin bir açıklamasını yazabilir ve sıfır atışlı performansı değerlendirebilir.

Bu durum, HITL güçlüğünü *örnek toplama*dan *görev belirleme*ye kaydırır: kullanıcıların modelin üzerinde eylemde bulunabileceği bir biçimde tam olarak ne istediklerini dile getirmelerine yardımcı olmak. Bu kulağa geldiğinden zordur — görevlerin doğal dil açıklamaları, etiketlenmiş örneklerin sahip olmadığı biçimlerde çoğunlukla belirsizdir.

Açıklayıcı Olarak Büyük Dil Modelleri

2023–2025'in en önemli gelişmelerinden biri, **BDM'lerin açıklama kahinleri olarak kullanılmasıdır**. "Bu yorum olumlu mu olumsuz mu?" sorusunu bir insana değil GPT-

4 veya Claude'a soruyoruz. İyi tanımlanmış sınıflandırma görevleri için BDM açıklamaları çoğunlukla kitle çalışanı doğruluğuyla eşleşiyor veya ona yaklaşıyor {cite}`gilardi2023chatgpt` ve API çağrılarının açıklama başına maliyeti tipik olarak insan işgücü ücretlerinden kat kat düşük.

BDM Açıklamasının İyi Çalıştığı Yerler

- Basit, iyi tanımlanmış sınıflandırma görevleri (duygu, konu, niyet)
- İnsan etiketlerinin BDM'nin özümsediği kültürel mutabakatı kodladığı görevler
- Bağlamlar arasında tutarlı açıklamanın sağlandığı görevler (yüksek öznellik yoktur)
- İnsan incelemesi için ilk aşama açıklamalar oluşturma

BDM Açıklamasının Başarısız Olduğu Yerler

- Nadir uzmanlık gerektiren son derece özelleşmiş alan görevleri (tıp, hukuk, bilim)
- Yerel kültürel bilgi veya dil çeşitliliği gerektiren görevler
- BDM'nin eğitildiği veriyle aynı yönde yanlış kalibre olabileceği güvenlik ve zarar görevleri
- Önceden eğitimde iyi temsil edilmemiş yeni görev türleri

RLAIF ve Anayasal Yapay Zeka

Bölüm 6'da tartışıldığı üzere, yapay zeka tarafından üretilen geri bildirim ödül modellerini eğitmek ve pekiştirmeli öğrenme ince ayarını yönlendirmek için kullanılabilir. Bu durum bir geri bildirim döngüsü yaratır: BDM'ler veri üretir, modeller bunun üzerinde eğitilir ve daha iyi modeller daha iyi veri üretir. Bu döngüyü başlangıç modelinden sistematik hataları kodlamadan nasıl başlatacağımız, ölçeklenebilir denetim araştırmasında merkezi bir açık sorundur.

Ölçekte Zayıf Denetim

Etiketleme işlevleri aracılığıyla **programatik etiketleme** (Bölüm 9), alan uzmanlarının bilgilerini etiketlenmiş örnekler yerine kod olarak ifade etmelerine olanak tanır. Snorkel {cite}`ratner2017snorkel` ve halef sistemleri önemli ölçüde olgunlaşmış ve büyük teknoloji şirketlerinde üretimde kullanılmaktadır.

Sınır yönelimler: - BDM artırımlı etiketleme işlevleri: Doğal dil açıklamalarından etiketleme işlevleri oluşturmak için BDM'leri kullanma - **Dilim tabanlı öğrenme:** Etiketleme işlevlerinin anlaşmazlığa düştüğü kritik veri alt kümelerini (dilimleri) belirleyin ve insan açıklamasını oraya yönlendirin - **Belirsizlik duyarlı birleştirme:** Farklı doğruluk ve korelasyonlara sahip etiketleme işlevlerini birleştirmek için daha iyi istatistiksel modeller

---

İnsan Denetimiyle Sürekli Öğrenme

Makine öğrenmesi sistemlerinin büyük çoğunluğu çevrimdışı eğitilir ve statik model olarak dağıtılır. Gerçek dünya değişir; dağıtım anında doğru olan modeller, veri dağılımı kaydıkça bozulur.

Sürekli öğrenme — eski bilgiyi korurken yeni veriden öğrenme yetisi — aktif bir araştırma alanıdır. İnsan denetimi kritiktir: insan incelemesi olmadan otomatik sürekli öğrenme, dünya değişikliklerini değil hataları temsil eden dağılım kaymaları hızla kodlayabilir.

HITL sürekli öğrenme şunları içerir: - Dağılım kaymasını izleme (otomatik) ve kaymış örnekleri insan incelemesine yönlendirme - Seçici yeniden eğitim: yeni dağılımdan insan onaylı örnekler eğitim verisine eklenir - Her güncellemeden sonra model davranışı değişikliklerinin insan incelemesi

---

Çok Kipli HITL

Yapay zeka sistemleri çok kipli hâle geldikçe — metin, görüntü, ses ve videoyu aynı anda işleyip ürettikçe — açıklama daha karmaşık hâle geliyor. Tek bir içerik parçası, aralarında bağımlılıklar bulunan kipler genelinde açıklama gerektirebilir.

Ortaya çıkan görev türleri: - Video + transkript açıklaması (ne oluyor, kim konuşuyor, metin görsel olarak neyi tanımlıyor?) - Tıbbi görüntü + klinik rapor açıklaması - Robotik yörünge açıklaması (sensör verilerini eylem dizileriyle ilişkilendirme)

Çok kipli temel modeller (GPT-4V, Gemini, Claude) buradaki açıklama manzarasını da değiştiriyor — modeller artık görüntüleri yorumlayıp aday açıklamalar üretebiliyor; insanlar ise bunları inceliyor.

Ölçeklenebilir Denetim

HITL ML'deki temel açık sorun **ölçeklenebilir denetimdir** {cite}`irving2018ai,bowman2022measuring`: yapay zeka sistemleri belirli alanlarda insanları geçecek biçimde gelişirken anlamlı insan denetimini nasıl sürdüreceğiz?

Protein yapı tahmini, hukuki analiz veya matematiksel kanıt doğrulama gibi görevler için uzman açıklayıcılar bile iki yapay zeka çıktısından hangisinin doğru olduğuna güvenilir biçimde karar veremeyebilir. Değerlendirilen modelden insan yargısı daha az güvenilir olduğunda mevcut HITL yöntemleri işe yaramaz.

Önerilen yaklaşımlar {cite}`bowman2022measuring`:

Tartışma: İki yapay zeka sistemi farklı sonuçlar için argüman geliştirir; insan yargıcı doğrudan sonuçları değil argümanları değerlendirir. Doğru sonuç daha savunulabilir olmalıdır.

Yükseltme: İnsan yargıcılar, karmaşık çıktıları değerlendirmeye yardımcı olmak için yapay zeka asistanlarına (modelin kendisine) danışır. Bu, insan denetiminin yerini almak yerine onu genişletmek için yapay zeka yeteneklerinden yararlanır.

Süreç denetimi: Nihai çıktıyı değerlendirmek yerine insanlar *akıl yürütme sürecini* değerlendirir — nihai yanıtın doğru olup olmadığından bağımsız olarak düşünce zincirindeki kusurlu adımları işaretler.

Değişen İş Bölümü

HITL ML'nin uzun vadeli gidişatı, ne birinin sadece "etiketleyici" ne de diğerinin sadece "öğrenen" olduğu, her ikisinin de paylaşılan bir bilişsel sürece katkıda bulunduğu insanlar ve yapay zeka arasında daha akışkan bir işbirliğine doğrudur.

İzlenecek eğilimler: - **Yapay zeka destekli açıklama:** Yapay zeka önerir; insanlar karar verir. Yapay zeka daha iyi seçenekler önerdikçe kalite artar. - **İnsan rehberliğinde keşif:** İnsanlar hedefler ve kısıtlamalar belirler; yapay zeka çözüm uzayını keşfeder. - **İşbirlikçi değerlendirme:** İnsanlar ve yapay zeka, karmaşık çıktıları diyalog yoluyla birlikte değerlendirir. - **Ölçekte tercih öğrenmesi:** Kullanıcıların yapay zeka çıktılarıyla nasıl etkileşime girdiğine ilişkin örtük sinyaller, açık açıklama oturumları gerektirmeden sürekli tercih öğrenmesini besler.

Yapay zeka yargısına kıyasla insan yargısına ne kadar güvenileceği sorusu — ve hangi alanlarda, hangi yetenek düzeylerinde, hangi güvence önlemleriyle — nihai olarak teknik bir soru değil, toplumsal bir sorudur. HITL ML, varsayılan olarak değil, dikkatli biçimde yanıtlanması için teknik altyapıyı sağlar.

Açık Araştırma Sorunları

Alanın üzerinde etkin biçimde çalıştığı önemli açık sorunların bir listesiyle kapanıyoruz:

1. **Aktif öğrenmede optimum durdurma:** Bir sonraki açıklamanın marjinal değeri maliyetin altında kaldığında? Prensipli durdurma kuralları hâlâ zordur.
2. **Görevler arasında açıklama bütçesi tahsisi:** Çok görevli ortamlarda, sabit bir açıklama bütçesi görevler arasında nasıl bölünmelidir?
3. **Aktif öğrenmede dağılım kayması:** Aktif öğrenme önyargılı etiketli kümeler oluşturur. Bu şekilde eğitilen modeller nasıl düzgün kalibre edilebilir?
4. **Ödül modeli genellemesi:** RLHF ödül modelleri yeni istem-yanıt çiftlerine genelleşemeyebilir. Daha sağlam tercih modelleri nasıl inşa edebiliriz?
5. **Ölçeklenebilir denetim:** Yapay zeka sistemleri belirli alanlarda insan performansını aşarken insan denetimini nasıl sürdüreceğiz?
6. **Açıklayıcı modelleme:** Yalnızca yetkinliği değil sistematik önyargıları, konu uzmanlığını ve yorgunluğu da yakalayan daha iyi istatistiksel açıklayıcı davranış modelleri.
7. **Hizalamanın değerlendirilmesi:** Bir modelin insan değerleriyle hizalandığına ilişkin gerçek zemin testlerimiz yok. Sağlamlık için karşıt örneklere benzer bu tür testler geliştirmek açık bir sorundur.
8. **Adil veri emeği:** Açıklama çalışanlarının adil biçimde ücretlendirilmesini ve korunmasını sağlarken büyük ölçekli açıklamanın maliyet etkinliğini koruyan ekonomik ve kurumsal yapılar.

> *Amaç, insan yargısının yerini makine yargısıyla almak değil, her ikisinin birleşiminin tek başına herhangi birinden daha iyi olduğu sistemler inşa etmektir.*

Bu el kitabındaki araçlar ve teknikler — açıklama, aktif öğrenme, RLHF, tercih öğrenmesi ve geri kalanı — bu amaca ulaşmanın araçlarıdır. Alan geliştikçe belirli teknikler değişecek. Temel

ilham — hem yetenekli hem de gerçek anlamda insan niyetiyle hizalanmış sistemler inşa etmek — kalıcı olacaktır.

> **See also:** Ölçeklenebilir denetim ve tartışma: {cite}`bowman2022measuring`. Snorkel zayıf denetimi: {cite}`ratner2017snorkel`. İnsan–yapay zeka işbirliğinin geniş geleceği için bkz. {cite}`amershi2019software`.

Kaynakça

Vaka Çalışması: Limen — Her Şeyin Döngüsünde Bir İnsan

:::{admonition} Bu bölüm hakkında not :class: important Bu bölüm, ampirik bir çalışma veya hakemli bir katkı değil, **spekülatif bir tasarım denemesidir**. Önceki bölümlerdeki HITL ilkelerinin nasıl tutarlı bir bütün oluşturabileceğinin işlenmiş bir örneği olarak tasarlanmış bir sistem mimarisini tanımlar: ses öncelikli yapay zeka yerel masaüstü işletim sistemi Limen. Buradaki iddialar tasarım argümanları olup deneysel sonuçlar değildir. Motive edilmiş tasarım gerekçesi olarak okunmalı; doğrulanmış mühendislik bulguları olarak değil. :::

Bu el kitabının her bölümü, HITL ML'yi bir tasarım felsefesi olarak tanımlamıştır: öğrenme sistemlerindeki insan katılımını kasıtlı, verimli ve dürüst kılmaya yönelik bir ilkeler bütünü. Bu bölüm, söz konusu felsefenin birinci ilke olarak uygulanmasının nasıl göründüğünü tanımlar — tek bir sisteme değil, tüm bir çalışma ortamına.

Limen, insanın her zaman döngüde olduğunu öne süren; bunu uzaklaştırılacak bir kısıt olarak değil, her alt sistemin etrafında tasarlandığı örgütleyici ilke olarak ele alan ses öncelikli, yapay zeka yerel bir masaüstü işletim sistemidir. Ad kasıtlı seçilmiştir: *limen*, eşik anlamına gelen Latince sözcüktür. Algısal psikolojide limen, algılanan ile algılanmayan arasındaki sınırdır. İşletim sistemi için limen, insan niyeti ile makine eylemi arasındaki sınırdır.

Burada tanımlanan mimari tescilli değildir. Önceki bölümlerde geliştirilen HITL ilkelerinden doğal biçimde çıkan bir dizi tasarım kararıdır. Amaç bir ürünü belgelemek değil; bu ilkelerin nasıl bir araya geldiğini — tutarlı biçimde uygulandıklarında birbirlerini nasıl güçlendirdiklerini ve insan merkezi konumda, makine öğrenen ve döngü her zaman açık olduğunda ne tür sistemlerin mümkün hâle geldiğini — göstermektir.

Geleneksel İşletim Sistemi Tasarımıyla Sorun

Geleneksel bir işletim sistemi insanlar için tasarlanmamıştır. Programlar için tasarlanmıştır. İnsan, grafik arayüz, dosya tarayıcısı, terminal gibi — süreçler, bellek adresleri ve dosya tanımlayıcıları için inşa edilmiş bir altyapının üstüne oturtulan bir soyutlama katmanı aracılığıyla barındırılmaktadır.

Bu tasarım seçimi tarihsel olarak gerekçelidir. Onu üreten varsayımlar yapıldığında, bilgisayarlar pahalıydı, insanlar ucuzdu ve darboğaz hesaplamaydı. Doğru optimizasyon hedefi makineydi.

Bu varsayımlar artık geçerli değil. Çoğu kullanıcı için çoğu görevde darboğaz hesaplama değil. İnsan dikkatidir: bağlam geçişinin maliyeti, doğru dosyayı bulma, doğru sorguyu oluşturma, bir şeyin nerede olduğunu hatırlama. Makine hızlıdır. İnsan yavaştır. Arayüz insanın döngü tarafını optimize etmelidir.

Geleneksel işletim sistemleri bunu yapmaz. Programlar için optimize edilmişlerdir ve insanın görevi programların dilini konuşmaktır. Limen bunu tersine çevirir. Programlar insanın dilini konuşur. İnsan döngüdedir ve döngü insana uyacak biçimde tasarlanmıştır.

Eşiğin Mimarisi

Limen'in mimarisi tek bir ilke etrafında örgütlenmiştir: **her etkileşim bir olaydır** ve her olay insanın öğretmesi, düzeltmesi veya onaylaması için bir fırsattır. Sistem açık eğitim oturumlarını beklemez. Öğrenme sürekli ve ortamla iç içedir.

Olay Katmanı: WID

Temelde **WID** (Waldiez ID sistemi, Limen'in yerel öncelikli mimarisine uyarlanmış) bulunur — yalnızca ne olduğunu değil neyin neden olduğunu ve bunun ne doğurduğunu kaydeden nedensellik farkındalıklı olay izleme sistemi.

Geleneksel günlük tutma şunu sorar: *ne oldu?* WID şunu sorar: *neden oldu ve ardından ne geldi?* Her olay, tetikleyici insan eyleminden ara sistem durumları aracılığıyla gözlemlenen sonuca uzanan nedensel bir soy taşır.

Bu, HITL öğrenmesi açısından önem taşır; çünkü etkileşim düzeyindeki **kredi atama sorununu** çözer. Kullanıcı sistemin davranışını düzelttiğinde, WID yalnızca yanlış olan anlık çıktıyı değil, onu üreten karar zincirini de belirleyebilir. Düzeltmeler doğru soyutlama düzeyinde uygulanabilir: çıktı, karar kuralı veya yukarı akış sinyali.

Bu, işletim sistemi düzeyinde Bölüm 6'nın RLHF için tanımladığıyla aynı eşdeğerdir: bir ödül sinyalini bir dizi karar aracılığıyla izleme yetisi. WID bu izlemeyi yerel olarak, her etkileşim için, kullanıcının bunu anlamasını gerektirmeden sağlar.

:::{admonition} HITL Altyapısı Olarak Nedensel Olay İzleme :class: note WID'in tasarımı daha geniş bir ilkeyi yansıtır: HITL altyapısı "sistem neden bunu yaptı?" sorusunu sormayı kolaylaştırmalıdır — yalnızca "ne yaptı?" değil. Nedensel izleme olmadan düzeltmeler semptomları giderir. Bununla birlikte nedenleri giderebilirler. Bir yama ile bir ders arasındaki fark. :::

Algı Katmanı: Ses Öncelikli

Limen'in birincil girdi kipi, Whisper ONNX çıkarım hattı kullanılarak yerel olarak işlenen sestir. Bu seçimin gerekçelerini açıkça belirtmeye değer:

Ses, çoğu insan için en doğal çıktı kanalıdır. Eğitim, fiziksel beceri veya sistemin iç örgütlenmesine ilişkin bilgi gerektirmez. Bir dizin hiyerarşisinde dosya bulamayan kullanıcı, ne aradığını söyleyebilir.

Yerel işleme gizliliği korur. Ses verisi cihazı terk etmez. Bu hem etik açıdan önem taşır — ses biyometrik veridir ve ölçekte bulut sağlayıcılar tarafından toplanması belgelenmiş bir zarardır — hem de pratik açıdan: çevrimdışı çalışma, sistemin ağ bağlantısı olmadan işlevsel kalması anlamına gelir.

Ses, doğal bir geri bildirim döngüsü oluşturur. Sistem yanıt verdiğinde, kullanıcının tepkisi — konuşmaya devam etmek, yeniden ifade etmek, "hayır, bu doğru değil" demek — kendisi de bir sinyaldir. Limen bu tepkileri HITL geri bildirimi olarak değerlendirir: önceki söyleminin yorumunun doğru olup olmadığına ilişkin kanıt.

Yedek zinciri, birincil kip kadar önemlidir. Ses başarısız olduğunda — gürültülü bir ortamda, konuşma bozukluğu olan bir kullanıcı için, hassasiyet gerektiren bir girdi için — Limen klavye arayüzüne, ardından yapılandırılmış metin arayüzüne zarifçe geçer. Büyükanne Testi (bkz. Bölüm 5) bir erişilebilirlik düşüncesi değil; birinci sınıf bir mimari kısıttır.

Zeka Katmanı: Çoklu BDM Yönlendirme

Limen tek bir dil modeline güvenmez. İstekleri görev türüne, gereken gecikmeye, gizlilik gerekliliklerine ve güvene dayalı yapılandırılmış bir karar ağacından geçirerek yönlendirir:

1. **Yerel küçük model** (her zaman önce): hızlı, gizli, rutin görevleri yönetir — "dün düzenlediğim dosyayı aç," "zamanlayıcı kur," "hava durumu nedir"
2. **Yerel büyük model** (küçük model güveni düşük olduğunda): daha yavaş ama daha yetenekli; yapılandırılmış akıl yürütmeyi, kod üretimini, karmaşık almayı yönetir
3. **Uzak model** (yerel başarısız olduğunda ve kullanıcı izin verdiğinde): çıkış kapısı; kullanıcıya açık bildirimle şeffaf biçimde yönetilir

Bu yapı yeni değildir — Bölüm 4'te tanımlanan aktif öğrenme sorgu stratejisinin çıkarım zamanındaki eşdeğeridir. Her adımda sistem şunu sorar: mevcut modelim bu sorguyu kabul edilebilir güvenle yanıtlamak için yeterli mi? Değilse, yükselt. Yükseltme bir maliyettir (gecikme, gizlilik, hesaplama); yalnızca gerektiğinde ödenir.

İnsan, yükseltme sınırında döngüdedir. Limen'i uzak modellere hiçbir zaman yükseltmeyecek şekilde yapılandırmış kullanıcı, bir HITL kararı almıştır — sistemin saygı duyduğu ve kaydettiği bir karar. Uzak bir sorguyu onaylayan ve ardından "bu tür istekler için bir daha sorma" diyen kullanıcı, yönlendirme politikasını güncelleyen bir tercih sağlamıştır.

Etkileşim Tasarımı

Anlıklık

Limen, Bölüm 5'in tanımladığı anlamda anlıklık için tasarlanmıştır: kullanıcı geri bildiriminin etkisini algılar. Kullanıcı bir sistem çıktısını düzelttiğinde, düzeltme anında ve görünür biçimde uygulanır. Model yirmi dakika eğitim için uzaklaşmaz. Mevcut oturumda güncellenir.

Bu, verimli çevrimiçi güncellemeyi destekleyen model mimarileri gerektirir — tam ince ayar yerine adaptörler, önek ayarı ve geri alma artırımlı üretim. Değiş tokuş açıktır: çevrimiçi güncellemeler toplu eğitimden daha gürültülüdür. Limen bu değiş tokuşu kabul eder; çünkü anlıklık birincil gerekliliktir: insan her zaman güncellemeyi onaylayabilir, reddedebilir veya geliştirebilir.

Anlaşılırlık

IML literatüründe yinelenen bir tema, **anlaşılırlık gerekliliğidir**: insanlar yalnızca en azından kabaca anladıkları bir modele rehberlik edebilir. Limen bunu arayüzde ortaya koyar: sistem bir karar verdiğinde, neden kısaca açıklar. Tam bir akıl yürütme izi değil — bu çoğu kullanıcıyı bunaltır — ama temel etkenin doğal dil özeti: "En son çalıştığınız projeyi açıyorum — doğru mu?"

Bu açıklama aynı zamanda bir sorudur. Düzeltmeye davet eder. Modelin çıkarımını görünür kılar; böylece kullanıcı yanlışsa yeniden yönlendirebilir. Açıklama estetik nedenlerle üretilmez; işlevsel HITL altyapısıdır.

Tutarlılık ve Kayma

Uzun süreli etkileşimli bir sistemde ortaya çıkan bir sorun, **davranışsal kaymadır**: sistemin $T + n$ zamanındaki davranışı, T zamanındakinden hem kullanıcının hem de sistemin açıkça seçmediği biçimlerde ince olarak farklılaşır. Düzeltmeler birikir. Sınır vakalar katmerleşir. Geçen ay kullanıcının tercihlerine hizalanmış model artık hizalanmamış olabilir.

Limen bunu periyodik tutarlılık kontrolleriyle ele alır — Bölüm 13'te tanımlanan yeniden sunum tekniğinin işletim sistemi eşdeğeri. Sistem tarihsel kararları kullanıcıya sunar: "Birkaç hafta önce X yapmanı istedin. Hâlâ böyle ister miydin?" Bu kontroller iki işlev üstlenir: kaymayı yakalar ve kullanıcıya belirttiği tercihleri hatırlatır.

HITL Sistemi Olarak Limen

Limen'in mimarisine bu el kitabının merceğinden bakıldığında, tasarım kararları her bölümde geliştirilen kavramlarla doğrudan örtüşür.

Bölüm I (Temeller): Limen her etkileşimi insan–makine etkileşim olayı olarak ele alır. "HITL dışı mod" yoktur — sistem her zaman öğrenmekte, her zaman ilişkilendirmekte, her zaman insanın katılmasını beklemektedir.

Bölüm II (Temel Teknikler): Aktif öğrenme, güvene dayalı yükseltme zinciri olarak kendini gösterir. Etkileşimli makine öğrenmesi, gerçek zamanlı güncelleme döngüsünde kendini gösterir. Açıklama örtüktür: kullanıcının her düzeltmesi bir etikettir.

Bölüm III (İnsan Geri Bildiriminden Öğrenme): Bölüm 8'de tanımlanan tercih öğrenmesi, yönlendirme politikası güncellemelerinde kendini gösterir. Kullanıcı uzak modelin yanıtına göre yerel modelin yanıtını tercih ettiğinde, bu tercih kaydedilir ve genelleşir. Kişisel bir işletim sisteminde RLHF, ödül modelinin özel, bireysel ve sürekli güncellendiği anlamına gelir.

Bölüm IV (Uygulamalar): Limen genel amaçlı bir ortamdır, ancak tasarımı en çok insan yargısının vazgeçilmez ve hata maliyetinin yüksek olduğu alanlarda görünür hâle gelir — belge taslakları, görev önceliklendirmesi, yaratıcı çalışma.

Bölüm V (Sistemler ve Pratik): WID, Limen'in açıklama platformudur. Normal çalışmada kullanıcıya görünmez; hata ayıklama veya şeffaflık için gerektiğinde görünür. Kalite kontrol mekanizmaları (tutarlılık kontrolleri, güven eşikleri, yükseltme günlükleri) doğrudan kitle kaynaklı çalışma literatüründen alınmıştır.

Bölüm VI (Etik): Yerel öncelikli, gizliliği koruyan tasarım yalnızca teknik değil, etik bir seçimdir. İnsanın verileri açık rızası olmadan cihazı terk etmez. Kullanıcının davranışından öğrenen model o kullanıcıya aittir.

Daha Derin Nokta

Limen bir ürün tanıtımı değildir. Yapı yoluyla bir argümandır.

Argüman şudur: HITL ML'nin ilkelerini ciddiye alırsanız — insan geri bildiriminin en aza indirilmesi gereken bir maliyet değil, anlaşılması gereken bir sinyal olduğuna, tasarımcılar aksi iddia etse dahi insanın her zaman döngüde olduğuna, hizalamanın tek seferlik bir olay değil süregelen bir süreç olduğuna inanırsanız — Limen'e benzeyen bir şey inşa edersiniz.

Özellikle Limen olmak zorunda değil. Belirli teknoloji yığını (Tauri, Rust, Babylon.js, Whisper ONNX) birçok seçenekten biridir. Ancak mimari — nedensel olay izleme, yerel öncelikli işleme, zarif bozulma, sürekli tercih öğrenmesi, birinci sınıf özellik olarak şeffaflık — ilkelerden çıkar.

HITL ML alanı, insanları belirli modellerin ve belirli görevlerin döngüsüne dahil etmenin nasıl sağlanacağını tanımlamaya önemli ölçüde enerji harcamıştır. Bir sonraki soru, aynı ilkeler etrafında tüm *ortamları* tasarlayıp tasarlayamayacağımızdır: insanın her zaman merkez, makinenin her zaman öğrenen ve döngünün her zaman açık olduğu ortamlar.

Limen bu sorunun bir yanıtıdır.

Eşik, geçip geride bırakılan bir şey değildir. Yaşadığınız yerdir.

See also: Limen'in etkileşim tasarımının altında yatan IML ilkeleri Bölüm 5'te geliştirilmektedir. Yönlendirme politikasının arkasındaki tercih öğrenme yaklaşımı Bölüm 8'de biçimselleştirilmektedir. WID'in nedensellik modeli, Bölüm 14'te araştırılan olay atıf literatüründen yararlanmaktadır. Bölüm 5'te tanıtılan Büyükanne Testi, Limen'in birincil arayüz tasarım kısıtıdır.

Ayrılış Üzerine

Bir noktada bir doktora programına kayıtlıydım. Araştırma makine öğrenmesi üzerineydi. Kurum gerçekti. Niyet samimiydi.

Ve sonra durdum.

Konunun önemi kalmadığı için değil — başladığımdan daha fazla önem taşıyor şimdi. İş çok zordu diye değil — bu el kitabı kendi açısından bir tezden daha zordu. Fakat literatür taraması ile on bir kişi tarafından okunacak bir makalenin üçüncü revizyonu arasında bir yerde, bunlardan herhangi birinin neden yapılmaya değer olduğuna dair ipliği yitirdim.

Doktora sistemi bir döngüdür. İçine soru sahibi bir insan olarak girersiniz. Döngü size bu soruları makalelere, makaleleri atıflara ve atıfları ilerleme görünümüne dönüştürmeyi öğretir. Döngünün herhangi bir noktasında çıktının döngünün dışındaki birine yararlı olup olmadığı sorulmaz. Bu soru, teknik anlamda, kapsam dışıdır.

Bunu fark eden ilk kişi değilim. Son kişi de olmayacağım. Bu bir eleştiri değil — bir betimlemedir. Döngü gerçek şeyler üretir: titiz yöntemler, birikmiş bilgi, yetişmiş araştırmacılar. İçinde geçirdiğim zamana pişman değilim. Ama sonunda içinde olduğumu fark ettim.

Ayrılmak dramatik bir karar değildi. Gerçekten inşa etmek istediğim şeyin bir komiteden izin gerektirmediğinin yavaş yavaş anlaşılmasıydı. Ulaşmak istediğim insanların — gerçek sistemler hakkında gerçek kararlar alan uygulayıcılar, öğrenciler, mühendisler — resmi olarak onaylanmış bir tezi beklemediğinin kavranmasıydı. Bildiklerimi yazmaya çalışırken yapabileceğim en dürüst şeyin, birinin gerçekten kullanabileceği bir biçimde yazmak olduğunu görmenin ürünüydü.

Ve bunu yaptım.

Bu el kitabı bir doktora tezi değildir. Kurumsal bağlantısı, fon teşekkürü, etik kurul onayı, sınav yok. Akademinin bilgi üretimini ölçmek için kullandığı hiçbir ölçüte katkıda bulunmayacak.

Aynı zamanda — ve bunu sahte bir mütevazılık olmaksızın söylüyorum, çünkü sahte mütevazılık kendi başına bir tür dürüstsüzlük olurdu — tezden daha eksiksiz, daha güncel, daha okunabilir ve daha kullanışlıdır.

Döngüde bir insanım. Bir doktora programının döngüsündeydim ve dışına çıktım. Şimdi döngüler hakkında yazmanın döngüsündeyim. Siz bu konuyu okumanın döngüsündesiniz.

Hiçbirimiz bu döngülerin içinde olmayı tamamen özgürce seçmedik. Fakat bazen hangi döngüde olduğumuz, neden olduğumuz ve bir şey üretip üretmediği konusunda dürüst olmayı seçebiliriz.

Bu kitap söz konusu sorulara verdiğim yanıttır.

Bir istifa mektubu değil. İstifa, bir iş ve bir işin şartlarına başkasının karar vermesi anlamına

gelir. Bu başka bir şey: zamanla ne yapmayı seçtiğimin bir kaydı ve bu seçimin doğru olduğuna dair sessiz bir savunma.

Siz buna hükmedebilirsiniz. Sonuçta siz de döngüdeki bir insansınız.

— *Yazar*