# Contents


**人机协同机器学习：被误解的领域** 1
本书结构 . . . . . 1

**原创性声明** 3

**摘要** 5

**致谢** 7

**何谓人机协同机器学习?** 9
自动化悖论 . . . . . 9
人在回路机器学习的定义 . . . . . 9
简史 . . . . . 9
为何选择HITL？人类判断力的价值 . . . . . 10
反馈回路 . . . . . 11
HITL不是什么 . . . . . 11
人类反馈的经济学 . . . . . 11
本手册概述 . . . . . 12

**人机交互的分类体系** 13
自动化程度层次 . . . . . 13
主动参与与被动参与 . . . . . 14
单一标注者与多标注者 . . . . . 14
统一框架 . . . . . 14

**数据标注与标记** 15
标注类型 . . . . . 15
标注指南 . . . . . 16
衡量标注质量：标注者间一致性 . . . . . 16
处理分歧 . . . . . 17
标签噪声及其影响 . . . . . 18
标注成本与吞吐量 . . . . . 19

**主动学习** 21
主动学习的设置 . . . . . 21
理论基础 . . . . . 21
查询策略 . . . . . 22
深度模型的不确定性估计 . . . . . 23
完整的主动学习循环 . . . . . 24
冷启动问题 . . . . . 26
批量模式主动学习 . . . . . 26

停止准则 . . . . . 26
主动学习的适用场景（及不适用场景） . . . . . 27

**交互式机器学习** 29
交互式机器学习的原则 . . . . . 29
与主动学习的比较 . . . . . 29
混合主动交互 . . . . . 29
IML中的人类因素 . . . . . 30
实践中的IML反馈类型 . . . . . 30
案例研究：Google Teachable Machine . . . . . 30
实现一个简单的IML回路 . . . . . 31
祖母测试 . . . . . 32
IML与基础模型 . . . . . 33

**基于人类反馈的强化学习** 35
对齐问题 . . . . . 35
RLHF流程 . . . . . 35
简化版RLHF演示 . . . . . 36
RLHF的挑战 . . . . . 38
宪法AI（RLAIF） . . . . . 38

**从示范中学习** 41
行为克隆 . . . . . 41
逆强化学习 . . . . . 42
GAIL：生成对抗模仿学习 . . . . . 42
NLP中的行为克隆：实践示例 . . . . . 43
模仿学习方法比较 . . . . . 44
应用领域 . . . . . 44

**从比较与排序中学习** 45
为何比较优于评分 . . . . . 45
Bradley-Terry模型 . . . . . 45
Thurstone模型 . . . . . 47
排序聚合 . . . . . 47
决斗赌博机 . . . . . 48
语言模型的偏好学习 . . . . . 48
收集高质量偏好数据 . . . . . 48

**人机协同在自然语言处理中的应用** 49
NLP标注中的建构性问题 . . . . . 49
文本分类标注 . . . . . 49
命名实体识别 . . . . . 50
关系抽取与语义标注 . . . . . 50
机器翻译译后编辑（MTPE） . . . . . 50
对话式AI与对话标注 . . . . . 50
程序化标注与弱监督 . . . . . 51
用于语言模型的RLHF：标注的现实 . . . . . 52
标注-模型反馈回路 . . . . . 52
生成式NLP模型的评估 . . . . . 52

**人机协同在计算机视觉中的应用** 55
标注选择如何变成模型偏见 . . . . . 55
图像分类标注 . . . . . 55

目标检测：边界框标注 . . . . . 56
语义与实例分割 . . . . . 57
计算机视觉的主动学习 . . . . . 57
基于人类引导的半监督学习 . . . . . 58
视频标注 . . . . . 59

**人机协同在医疗与科学中的应用** 61
医学图像分析 . . . . . 61
临床NLP标注 . . . . . 62
监管考量 . . . . . 62
科学数据标注 . . . . . 62
管理专家标注者 . . . . . 63
医学影像HITL主动学习流程 . . . . . 63

**标注平台与工具链** 67
标注平台全景 . . . . . 67
标注平台功能对比 . . . . . 67
标注即代码 . . . . . 68

**众包与质量控制** 71
众包平台 . . . . . 71
众包的任务设计 . . . . . 71
标签聚合的统计模型 . . . . . 73
冗余与聚合策略 . . . . . 75

**评估方法与度量指标** 77
以模型为中心的指标 . . . . . 77
标注效率指标 . . . . . 77
人工评估 . . . . . 79
衡量与人类意图的对齐程度 . . . . . 80
已部署系统中的A/B测试 . . . . . 80

**公平性、偏见与伦理** 81
HITL系统中偏见的来源 . . . . . 81
HITL系统中的公平性 . . . . . 82
标注者福利 . . . . . 82
标注中的隐私问题 . . . . . 83
对抗性标注与数据投毒 . . . . . 83
机构伦理 . . . . . 83

**未来展望** 85
基础模型与标注角色的转变 . . . . . 85
LLM作为标注者 . . . . . 85
大规模弱监督 . . . . . 86
带有人类监督的持续学习 . . . . . 86
多模态HITL . . . . . 86
可扩展监督 . . . . . 86
劳动分工的演变 . . . . . 87
开放研究问题 . . . . . 87

**参考文献** 89

**案例研究：Limen——万物循环中的人类** 91

传统操作系统设计的问题 . . . . . 91
临界值处的架构 . . . . . 91
交互设计 . . . . . 92
Limen作为HITL系统 . . . . . 93
更深层的观点 . . . . . 93

**论离开** 95

# 人机协同机器学习：被误解的领域

**拉扎罗斯 · 图马尼迪斯**

---

本手册深入探讨现代人工智能中最为关键、也最易被误解的领域之一：将人类融入学习循环。从数据标注与主

本书面向希望理解人类何时、为何以及如何参与学习周期的研究人员、工程师与学生。

:::{admonition} 中文版说明 :class: note 本版本为简体中文译本。英文原版为主要参考版本。
:::

---

## 本书结构

**第一部分 — 基础理论** — 构建概念框架，阐明人机协同机器学习的内涵，并对不同层次的自动化水平进行系统分

**第二部分 — 核心技术** — 介绍基础方法，涵盖数据标注、主动学习与交互式机器学习。

**第三部分 — 从人类反馈中学习** — 涵盖基于人类反馈的强化学习、从示范中学习以及从比较中学习等方法。

**第四部分 — 应用实践** — 考察自然语言处理、计算机视觉及医疗系统中的实践案例。

**第五部分 — 系统与工程实践** — 介绍每个人机协同系统在实践中所需的工具、平台与度量指标。

**第六部分 — 伦理与前沿展望** — 探讨公平性、偏见问题以及人类与算法关系的未来走向。

# 原创性声明

以部分不满足博士学位要求的方式提交。

---

本人在此声明，本手册所呈现的工作均为本人独立完成，除非实际并非如此。

这些页面中的思想在以下各方的协助下产生：发表论文并偶尔将其置于付费墙之后的研究人员；其劳动使模型
—它们被大型语言模型摄取与压缩，而那些模型对此没有任何立场。

错误归于本人。洞见来自协作。

本人确认，本作品未曾以任何其他学位或专业资格、学术奖项、科研经费、终身教职申请或LinkedIn帖子的名

本人进一步确认，本作品未包含任何最优性能对比章节（SOTA对比）。读者不会在此发现一张将47种方法在1
< 0.05）。这并非因为无法构建这样一张表格，而是因为构建它将偏离重点。

重点在于：人类始终在回路之中。一直如此。本书试图理解这意味着什么。

---

署名：回路中的一个人类

日期：您阅读此文时的任何时刻

机构：无。这正是重点所在。

---

**关于副标题** :class: note

被误解的，同时指向该领域、人类在其中的角色，以及读者——三者兼顾。如果您认为它仅指向您自己，

# 摘要

**人在回路机器学习：被误解的领域**

机器学习的主流叙事将人类定位为临时参与者——在数据收集和模型训练阶段存在，随后随着自动化的进步而

人在回路（HITL）机器学习是一门将人类参与学习系统的方式变得有意识、有结构且持续进行的学科。与其将人
—使模型的行为真正符合设计者和用户的实际意图。

本手册分六个部分对该领域进行全面论述。第一部分建立基础理论，并构建人机交互的分类体系。第二部分涵

每章均包含正式定义、适当的数学推导，以及可独立运行的Python代码示例。

本手册面向构建机器学习系统的从业者、研究该领域的学者、正在学习相关知识的学生，以及所有曾经好奇过
—是谁标注了训练数据、是谁训练了模型、又是谁做出了影响自己生活的决策——的人。

答案，在所有情况下，都是：一个人类。往往薪资微薄。鲜少获得致谢。却始终身处回路之中。

---

**关键词：** 人在回路机器学习、主动学习、数据标注、基于人类反馈的强化学习、RLHF、偏好学习、众包、交互

**学科分类：** 机器学习 · 人机交互 · 人工智能 · 数据科学

**字数：** 足够。

# 致谢

每一本关于人在回路机器学习的书，都应当从其自身回路中的人类开始。

**标注者们**。 本手册在某种程度上是关于你们的——关于你们的劳动、你们的判断，以及你们的名字从未出现在

**开源贡献者们**，他们的库在每一个代码示例中都得到了使用：NumPy社区（自2006年以来）、scikit-learn贡献者们（自2007年以来）、PyTorch团队、Hugging Face社区，以及无数在周末不计报酬、不求认可

**研究者们**，他们以开放的方式发表成果——通过arXiv预印本、开放获取期刊和GitHub代码库——使从业者无需机构权限便能学习。还有那些认真、诚实地审阅论文的研究者，这是一种专家标注工作，学术

**教育者们**，他们使知识变得触手可及：博主、教程作者、Stack Overflow的答题者、将幻灯片公开发布的会议

**批评者们**。 那些指出数据集编码了偏见、标注者人口构成影响了模型行为、回路中的人类往往是系统中最脆弱

---

> 有已知的已知——我们知道我们所知道的事物。 有已知的未知——我们知道我们不知道的事物。
> 有未知的未知——我们不知道我们不知道的事物。
>
> 然后还有那些领域内每个人都心知肚明 却从未真正进入论文的事物。
>
> 本手册，在某种程度上，是对最后一类事物的一次尝试。

---

如果您为这个领域作出了贡献却未在此看到您的名字：您已被致谢。回路包含您。

# 何谓人机协同机器学习?

一台能从经验中学习的机器……但前提是你给它正确的经验。 – 改述自艾伦 · 图灵

## 自动化悖论

每一次自动化浪潮都会对人类注意力产生新的需求。当航空公司引入自动驾驶仪时，飞行员变成了监控者——他们的职责不再是对飞机进行时刻到时刻的操控，而是承担更艰难的任务：判断何时应该接管。当超市引入

这就是**自动化悖论**{cite}`bainbridge1983ironies`：一个自动化系统越有能力，其失败的后果就越严重，

人在回路机器学习（HITL ML）是一个认真对待这一悖论、并将其从一开始就融入系统设计的领域。HITL ML不是将人类参与视为最终将被移除的临时脚手架，而是将人机交互视为一种特性——一种能使模型更准确、更符合人类价值观且更值得信赖的信号源、纠错机制和引导力量。

---

## 人在回路机器学习的定义

文献中对HITL ML没有统一认可的定义，该术语以几种相互交叠的方式被使用。本手册采用一个宽泛而精确的定

:::{admonition} 定义 :class: important

**人在回路机器学习**是指任何以有意识、有结构且持续进行的方式将人类反馈纳入学习过程的机器学习系统或方——不仅仅在数据集创建时，而是贯穿训练、评估和部署的全过程。

:::

该定义包含三个关键条款：

**有意识**。 HITL并非无意为之的人类影响（例如，训练数据最初由人类创建这一事实）。它指的是被明确设计为

**有结构**。 反馈具有明确的形式——一个标签、一次纠正、一个偏好判断、一次示范——以及在学习算法中的明确角色。

**持续进行**。 反馈回路随时间推移持续运转，使系统能够在遭遇新情境、犯下错误并接受人类引导的过程中不断

该定义涵盖了经典标注流程、主动学习、交互式机器学习、RLHF和模仿学习。它排除了被动数据收集和纯离线

---

## 简史

### 专家系统与知识工程（1960年代至1980年代）

最早的人工智能系统几乎完全是人在回路的：知识工程师与领域专家共同工作数月，将规则艰辛地编码进MYC

这些系统在狭窄领域内的表现出人意料地好，但十分脆弱——无法超越手工制定的规则进行泛化，且维护成本

### 统计学转向（1980年代至2000年代）

1980年代和1990年代转向统计机器学习改变了人类参与的性质。人类不再以规则的形式编码知识，而是提供示
—允许模型从中推断规律的标注数据集。人类的角色变成了标注者：为文档标记类别、为图像打标签、转录语音

这是一大进步，但它造成了新的瓶颈：**标注数据代价高昂**。研究者开始思考如何最高效地利用人类标注资源。
{cite}`cohn1994improving`。

### 深度学习时代（2010年代至今）

深度学习革命创造了一种新的格局：具有数十亿参数的模型能够从数据中学习极其复杂的函数—
—但需要相应规模的庞大标注数据集。ImageNet（1400万张标注图像）及其后的大规模标注项目既展示了规

与此同时，大规模部署机器学习暴露了新的问题：模型在平均水平上准确，但对特定群体系统性地出错；模型
—使模型按照人类实际意图行事的工程。

这一对齐导向的HITL工作最清晰的体现是**基于人类反馈的强化学习**（RLHF）{cite}`christiano2017deep`，
{cite}`ouyang2022training`等系统以及现代语言模型指令遵循能力的核心支柱。

---

## 为何选择HITL？人类判断力的价值

是什么使人类判断力有价值到值得被融入机器学习系统？以下几个属性值得关注：

### 1. 常识与世界知识

人类将大量的背景知识带入任何任务。当一位放射科医生为X光片做标注时，她调用的是多年的训练经验、对解
—这些知识极难从数据中完整指定或获取。

### 2. 语义锚定

标签之所以有意义，是因为人类理解其含义。ImageNet中的”猫”类别指代一个人类凭直觉就能识别、但任

### 3. 价值对齐

人类具有机器学习模型无法单从数据中推导出来的偏好、价值观和伦理判断。一段文本是否”有帮助”或”有
—它取决于因个体和情境而异的人类价值观。HITL是将这些价值观传递给机器学习系统的主要机制。

### 4. 适应性

人类判断力能够适应新颖情境，而无需重新训练。在历史数据上训练的模型可能在世界发生变化时灾难性地失

### 5. 问责性

在高风险领域——医疗、法律、金融——决策需要向人类负责。HITL系统通过将人类保持在能够理解、验证和

---

## 反馈回路

HITL ML的核心结构是模型与一个或多个人类之间的反馈回路：

```
+-----------------------------------------------+
|                                               |
|   □ □ □ □ □ □  / □ □                          |
|   ---------------------------------->         |
|                                   □ □         |
|   □ □ □ □ □ □        <-------- |              |
|   ----------------------------------          |
|                                               |
|   □ □ □ □ □ □ □ □ □ □                        |
|                                               |
+-----------------------------------------------+
```

在不同的HITL范式中，反馈的性质差异极大：

| 反馈类型 | 示例 | 主要范式 |
|---|---|---|
| 类别标签 | “这封邮件是垃圾邮件” | 监督学习 |
| 纠正 | “该实体应为ORG，而非PER” | 主动学习 / 交互式机器学习 |
| 偏好 | “回复A优于B” | RLHF / 排序学习 |
| 示范 | 向机器人展示如何抓取物体 | 模仿学习 |
| 自然语言 | “请让你的回答更简洁” | 指令微调 |
| 隐式信号 | 用户点击了 / 未点击 | 隐式反馈 |

---

## HITL不是什么

有必要明确界定哪些情况不在我们定义的范围之内。

**HITL不等同于部署中的人在回路**（有时称为”人在环上”，human on the loop），在那种情况下，人类监控

**HITL不等同于单独的弱监督**。 像Snorkel这样的程序化标注系统使用标注函数（通常是人类撰写的规则）在规模

**HITL不等同于简单地使用标注数据**。 每个监督学习模型都使用人类标注数据。HITL特指人类反馈是学习过程的主

---

## 人类反馈的经济学

人类反馈有价值，但代价高昂。在专科医师执行的情况下，医学影像标注的成本从数十美元到数百美元不等 {cite}`monarch2021human`。在Amazon Mechanical Turk等平台上，众包工人标签的成本可以低至每条0.0 {cite}`hara2018data`，但质量也低得多。HITL ML的根本挑战在于**最大化每单位人类反馈的价值**。

这引出了一个贯穿本手册大部分内容的统一问题：

:::{admonition} HITL ML的核心问题 :class: tip

在人类时间和注意力预算固定的情况下，我们应该如何决定向人类提问什么、何时提问，以及如何将他们的回

:::

这个问题的答案取决于领域、反馈形式、标注成本、错误风险以及模型当前状态——这正是为什么HITL ML是一个丰富且仍在演进的学科。

---

## 本手册概述

本手册的其余部分结构如下。**第二部分**涵盖HITL的三个经典支柱：标注、主动学习和交互式机器学习。**第三部分**—RLHF、模仿学习和偏好学习——它们已成为现代人工智能的核心。**第四部分**从具体应用领域的视角审视HITL。

> See also: 关于该领域面向从业者的综述，请参见{cite}`monarch2021human`。关于推动HITL形式化处理
> {cite}`settles2009active`。

# 人机交互的分类体系

精确的词汇是清晰思维的前提。“人在回路”这一术语在实践中被宽泛地使用——有时指人类为训练数据添加
本章梳理机器学习中人机交互的全景，提供贯穿本手册其余部分的概念词汇。

---

## 自动化程度层次

最根本的区分是人类在系统决策中的参与程度。自动化理论中一个广为人知的框架{cite}`sheridan1992te`
区分了十个层次，但对于机器学习而言，三个类别足以捕捉主要变化：

### 人在回路（HITL）

人类是学习过程中的主动参与者。决策——至少是关键决策——需要在最终确定之前获得人类输入。没有持续

示例：一个在将病例添加到训练数据之前查询临床医生的主动学习系统。一个标注示例后立即用于模型更新的

### 人在环上（HOTL）

系统自主运行，但人类对其进行监控并可进行干预。人类是监督者，而非参与者。反馈可能流回训练，也可能

示例：一个自动标记帖子的内容审核系统；人类审核者对一部分决策进行抽样和纠正。一架自动驾驶的飞机，

### 人在指挥（HIC）

人类做出所有决策；系统提供建议或信息，但没有自主权。这是最弱的机器学习部署形式。

示例：一个向医生展示模型概率估计的诊断支持系统，但最终决策完全交由医生做出。

> **哪个层次是合适的？** :class: tip
>
> 适当的自动化层次取决于错误的代价、模型的可靠性、可用人员的专业知识以及任务的延迟约束。这些因
> 一大多数系统从HITL起步，随着置信度的提升逐渐迁移至HOTL。

```
□ □ □ □  --> □ □ □  --> □ □  --> □ □  --> □ □  --> □ □
     ^                ^                  ^            ^                ^
     |                |                  |            |                |
 □ □ □ □        □ □            □ □ □ □      □ □ □ □    □ □ □ □ □
                □ □ □
```

| 阶段 | 人类角色 | 章节 |
|---|---|---|
| 数据采集 | 决定采集什么数据；采样策略 | 3, 4 |

| 阶段 | 人类角色 | 章节 |
|---|---|---|
| 标注 | 分配标签、结构、元数据 | 3, 13 |
| 训练 | 主动学习查询；在线反馈 | 4, 5, 6 |
| 评估 | 对模型输出进行人工评估 | 14 |
| 部署 | 监控、异常处理、纠正 | 12, 14 |

---

## 主动参与与被动参与

在主动HITL中，系统选择向人类展示哪些数据点——有策略地提问。在被动HITL中，人类对恰好到来的数据提供

主动参与更高效，因为反馈被引导至最能提升模型性能之处。被动参与更易于实施和管理。

一个相关的区分是**批处理**与**在线**反馈：

- **批处理**： 人类标注大量示例池；模型重新训练。循环往复。
- **在线（流式）**： 人类反馈持续到来；模型增量式更新。

批处理工作流程是业界的常态（标注项目后跟随训练运行）。在线工作流程对于交互式系统和强化学习环境更

---

## 单一标注者与多标注者

大多数HITL的形式化表述假定存在一个单一、一致的标注者。在实践中，标注涉及多个人，且他们的判断存在系

**聚合**将多个标注合并为一个标签，通常通过多数投票或统计模型（第13章）实现。

**分歧作为信号**——一些研究者认为，标注者之间的分歧是有价值的信息，不应被压缩为单一的”黄金”标签。
{cite}`uma2021learning`。

---

## 统一框架

我们可以用一个五元组来表示任何HITL配置：

$$\text{HITL配置} = \big(\text{层次}, \text{形式}, \text{阶段}, \text{频率}, \text{标注者数}\big)$$

其中：

- **层次** $\in$ {HITL, HOTL, HIC}
- **形式** $\in$ {标签, 纠正, 示范, 偏好, 自然语言, 隐式}
- **阶段** $\in$ {数据采集, 标注, 训练, 评估, 部署}
- **频率** $\in$ {批处理, 在线}
- **标注者数** $\in \mathbb{N}^+$（每条数据的标注者数量）

该分类体系使我们能够在相同维度上比较不同的HITL系统，并推理它们之间的权衡取舍。本手册其余部分将深入

> See also: 关于标注决策如何影响下游模型行为的实证研究，请参见{cite}`bender2021stochastic`。
> {cite}`amershi2014power`。

# 数据标注与标记

数据标注是机器学习中人类参与最为普遍的形式。在模型能够学习之前，必须有人告诉它什么是正确答案——而那个人通常是人类。本章涵盖标注的理论与实践：是什么使标注变得困难、如何设计标注任务、如何衡量

---

## 标注类型

标注任务在结构、难度和成本上差异极大。主要类型包括：

### 分类

标注者将每个实例分配到$K$个预定义类别之一。这是认知上最简单的标注任务，但定义良好的类别方案（即分

**二分类**（这张图片是猫吗？）是最简单的情况。**多类分类**（这是什么动物？）要求标注者从列表中选择一个选

### 序列标注

序列中的每个词元都会获得一个标签。命名实体识别（NER）是典型示例——标注者将文本片段标记为PERSO
Inside-Outside）或BIOES标注方案：

B-ORG　　O　　B-ORG　　O　　O　　O

### 片段与关系标注

除了标注单个词元，标注者可能还需要：- 识别片段（多词元表达式）并分配类型 - 标记片段之间的关系（“苹
- 标注共指链（同一实体的所有提及）

这些任务认知要求较高，且标注者间一致性较低。

### 边界框与目标检测

标注者在图像中的物体周围绘制矩形，并为每个框分配类别标签。定位精度至关重要：框太小会遗漏上下文；

### 图像分割

像素级标注：每个像素被分配到一个类别（语义分割）或一个特定对象实例（实例分割）。高质量分割是成本

**转录与翻译**

音频→文本（ASR训练数据）、手写→文本（OCR数据）或源语言→目标语言（机器翻译数据）。这些任务需

---

## 标注指南

决定标注质量最重要的单一因素是**标注指南**的质量：标注者遵循的书面指令。

良好的指南：
- 说明任务目标并解释为什么标签重要
- 为每个类别提供清晰定义，附有正面和负面示例
- 明确处理常见的边缘案例和困难案例
- 说明不确定时应怎么做（例如，标记”跳过”还是强制选择）
- 包含完整标注的有效示例

糟糕的指南在边缘案例上依赖标注者”凭常识判断”——这会导致不一致的决策，降低模型质量并放大标注者

> **指南开发是迭代的** :class: note
>
> 不要期望一开始就写出完美的指南。先进行小规模的试点标注，分析分歧，然后更新指南。如此反复。完

---

## 衡量标注质量：标注者间一致性

当多个标注者为同一数据添加标签时，可以衡量他们的一致性。高一致性表明任务定义明确，标注者理解了任

### Cohen’s Kappa系数

对于两个标注者将数据标注到$K$个类别的情况，Cohen’skappa系数{cite}`cohen1960coefficient`
对偶然因素进行了修正：

$$\kappa = \frac{P_o - P_e}{1 - P_e}$$

其中$P_o$是观测到的比例一致性，$P_e$是偶然一致性的概率（由边缘标签分布计算得出）。

$\kappa = 1$表示完全一致；$\kappa = 0$表示一致性不优于随机；$\kappa < 0$表示系统性分歧。

| $\kappa$范围 | 解释 |
|---|---|
| $< 0$ | 低于随机水平 |
| $0.0 - 0.20$ | 极弱一致性 |
| $0.21 - 0.40$ | 一般一致性 |
| $0.41 - 0.60$ | 中等一致性 |
| $0.61 - 0.80$ | 显著一致性 |
| $0.81 - 1.00$ | 近乎完全一致 |

### Fleiss’ Kappa系数

将Cohen’skappa扩展至$M > 2$名标注者。每位标注者独立为每条数据添加标签；公式跨标注者聚合：

$$\kappa_F = \frac{\bar{P} - \bar{P}_e}{1 - \bar{P}_e}$$

其中$\bar{P}$是所有标注者对之间的平均成对一致性，$\bar{P}_e$是随机分配下的预期一致性。

### Krippendorff’s Alpha系数

最通用的指标，支持任意数量的标注者、任意量表类型（名义、有序、区间、比率）以及缺失数据{cite}krippendorff2011computing：

$$\alpha = 1 - \frac{D_o}{D_e}$$

其中$D_o$是观测到的分歧，$D_e$是预期的分歧。由于其灵活性，Krippendorff’s alpha在学术研究中通常更受青

```
import numpy as np
from sklearn.metrics import cohen_kappa_score

# Simulate two annotators labeling 200 items into 3 categories
rng = np.random.default_rng(0)
true_labels = rng.integers(0, 3, size=200)

# Annotator 1: mostly agrees with ground truth
ann1 = true_labels.copy()
flip_mask = rng.random(200) < 0.15
ann1[flip_mask] = rng.integers(0, 3, size=flip_mask.sum())

# Annotator 2: less consistent
ann2 = true_labels.copy()
flip_mask2 = rng.random(200) < 0.30
ann2[flip_mask2] = rng.integers(0, 3, size=flip_mask2.sum())

kappa_12 = cohen_kappa_score(ann1, ann2)
kappa_1true = cohen_kappa_score(ann1, true_labels)
kappa_2true = cohen_kappa_score(ann2, true_labels)

print(f"Cohen's κ (ann1 vs ann2):   {kappa_12:.3f}")
print(f"Cohen's κ (ann1 vs truth):  {kappa_1true:.3f}")
print(f"Cohen's κ (ann2 vs truth):  {kappa_2true:.3f}")
```

---

## 处理分歧

当标注者意见不一致时，有几种策略可供选择：

### 多数投票

以最常见的标签作为黄金标准。当每条数据的标注者数量为奇数时，该方法简单且稳健。当少数标注者群体系

### 加权投票

标注者根据其估计的准确率进行加权（准确率由与黄金标准或其他标注者的一致性推导得出）。准确率更高的

### 软标签

与其将标注压缩为单一标签，不如保留分布。如果5位标注者中有3位说”正面”，2位说”中性”，则将其表示
$(0.6, 0.4, 0.0)$。在软标签上训练可以改善模型校准。

### 仲裁

由高级标注者或领域专家裁定分歧。这是黄金标准，但代价高昂；通常只在高风险领域使用。

### 统计模型

更复杂的方法以概率方式对标注者能力进行建模。Dawid-Skene模型{cite}dawid1979maximum
通过EM算法同时估计标注者混淆矩阵和数据条目的真实标签。详见第13章。

---

## 标签噪声及其影响

真实的标注是有噪声的。标签噪声对模型训练的影响取决于噪声类型：

- **随机噪声**（标签随机翻转）会降低性能，但模型对中等水平的噪声（许多任务上高达约20%）具有出人意
- **系统性/对抗性噪声**（标签在特定模式下持续出错）危害更大，也更难检测。
- **类别条件噪声**（某些类别更容易出错）会使模型的决策边界产生偏差。

一条实用的经验法则：在有$n$个训练样本且$\epsilon$比例标签被污染的情况下，模型性能大致等同于拥有$(1-2\epsilon)^2 n$个干净样本{cite}natarajan2013learning。对于$\epsilon = 0.2$，这相当于损失了36%的数据。

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import cross_val_score

rng = np.random.default_rng(42)
X, y = make_classification(n_samples=2000, n_features=20, random_state=42)

noise_levels = np.linspace(0, 0.45, 15)
mean_accs = []

for eps in noise_levels:
    y_noisy = y.copy()
    flip = rng.random(len(y)) < eps
    y_noisy[flip] = 1 - y_noisy[flip]
    scores = cross_val_score(LogisticRegression(max_iter=500), X, y_noisy,
    mean_accs.append(scores.mean())

plt.figure(figsize=(7, 4))
```

```
plt.plot(noise_levels, mean_accs, 'o-', color='#2b3a8f', linewidth=2)
plt.xlabel("Label noise rate (ε)", fontsize=12)
plt.ylabel("Cross-validated accuracy", fontsize=12)
plt.title("Effect of Label Noise on Model Performance", fontsize=13)
plt.axvline(0.2, color='#e05c5c', linestyle='--', alpha=0.7, label='20% no
plt.legend()
plt.tight_layout()
plt.savefig('label_noise_effect.png', dpi=150)
plt.show()
print(f"\nAccuracy at 0% noise:  {mean_accs[0]:.3f}")
print(f"Accuracy at 20% noise: {mean_accs[round(0.2 / 0.45 * 14)]:.3f}")
print(f"Accuracy at 40% noise: {mean_accs[-2]:.3f}")
```

---

## 标注成本与吞吐量

理解标注经济学对于项目规划至关重要。

| 任务类型 | 典型吞吐量 | 每条成本（专家） |
|---|---|---|
| 二分类图像分类 | 200–500条/小时 | 0.02–0.10美元 |
| NER（短文本） | 50–150条/小时 | 0.10–0.50美元 |
| 关系抽取 | 20–60条/小时 | 0.30–1.50美元 |
| 医学图像分割 | 5–30条/小时 | 10–100美元 |
| 视频标注 | 5–20分钟视频/小时 | 20–200美元 |

以上数据为大致量级估计，因所需领域专业知识、标注工具质量、指南清晰度和标注者经验的不同而差异极大

See also: 标注工具选项在第12章介绍。众包标注的统计模型（Dawid-Skene、MACE）在第13章介绍。

# 主动学习

标注数据代价高昂。主动学习的核心洞见在于：并非所有未标注样本对信息量的贡献都相同——如果允许模型选择对哪些样本进行提问，它就能以更快的速度提升性能。主动学习系统不是随机标注数据，而

本章涵盖主动学习的理论与实践：查询策略、采样框架、停止准则，以及真实部署中的实践考量。

---

## 主动学习的设置

标准的**基于样本池的主动学习**设置涉及：

- 一个**已标注集** $\mathcal{L} = \{(x_i, y_i)\}_{i=1}^{n}$ ——初始时规模较小
- 一个**未标注样本池** $\mathcal{U} = \{x_j\}_{j=1}^{m}$ ——通常远大于 $\mathcal{L}$
- 一个**标注者** $\mathcal{O}$，能够为任意查询的 $x$ 返回 $y = \mathcal{O}(x)$
- 一个**查询策略** $\phi$，选择下一个查询 $x^* = \phi(\mathcal{L}, \mathcal{U}, f_\theta)$

主动学习循环：

```
1. □ □ □ □ L = □ □ □ □ □ □ □ □ U = □ □ □ □ □ □
2. □ □ □ f_θ ← train(L)
3. □ □ □ x* = argmax φ(x; f_θ)□ x ∈ U
4. □ □ □ y* = O(x*)
5. □ □ □ L ← L ∪ {(x*, y*)}□ U ← U \ {x*}
→ □ □ □ 2□ □ □ □ □ □ □ □
```

目标是使用尽可能少的标注者查询次数，达到目标模型质量。

---

## 理论基础

一个自然的问题是：主动学习能提供多少帮助？在最佳情况下，主动学习能实现标签复杂度的指数级缩减——至少在可实现的设置下，以好的查询策略，能够以 $O(\log(1/\epsilon))$ 个标签将误差降至 $\epsilon$，而被动学习则需要 $O(1/\epsilon)$ 个标签 {cite}`settles2009active`。

在实践中，性能保证更难获得。**不可知主动学习** {cite}`balcan2006agnostic` 表明，即使目标概念不在假设——衡量随着数据积累，合理假设集缩小速度的指标。

关键的实践含义：当**决策边界简单且集中**时（不确定性查询能快速排除错误假设），主动学习的优势最大；当

---

## 查询策略

### 不确定性采样

最简单也最广泛使用的策略：查询模型最不确定的样本 {cite}`lewis1994sequential`。

**最低置信度**查询模型对其最优预测置信度最低的样本：

$$x^* = \underset{x \in \mathcal{U}}{\arg\max} \left(1 - P_\theta(\hat{y} \mid x)\right)$$

**边界采样**考虑排名前两位的预测概率之差：

$$x^* = \underset{x \in \mathcal{U}}{\arg\min} \left(P_\theta(\hat{y}_1 \mid x) - P_\theta(\hat{y}_2 \mid x)\right)$$

**熵采样**使用完整的预测分布：

$$x^* = \underset{x \in \mathcal{U}}{\arg\max} \left( -\sum_{k=1}^{K} P_\theta(y_k \mid x) \log P_\theta(y_k \mid x) \right)$$

熵采样是三者中最有原则的——它考虑所有类别——在多类问题上通常优于其他两种方法。

### 委员会查询（QbC）

训练一个由 $C$ 个模型组成的**委员会**（使用自助法、不同初始化或不同架构）。查询委员会分歧最大的样本：

$$x^* = \underset{x \in \mathcal{U}}{\arg\max} \ \text{disagreement}(\{f_c(x)\}_{c=1}^{C})$$

分歧可以用**投票熵**（委员会多数票的熵）或与共识分布的**KL散度**来衡量。

QbC提供比单一模型更好的不确定性估计，但需要训练多个模型，计算成本较高。

### 预期模型变化

查询会导致当前模型发生最大变化的样本。对于基于梯度的模型，这对应于具有最大预期梯度幅度的样本 {cite}`settles2008analysis`：

$$x^* = \underset{x \in \mathcal{U}}{\arg\max} \sum_{y \in \mathcal{Y}} P_\theta(y \mid x) \left\| \nabla_\theta \mathcal{L}(f_\theta(x), y) \right\|$$

该策略有充分的理论依据，但需要为每个候选样本计算梯度，对于大型模型代价高昂。

### 核心集 / 几何方法

基于不确定性的策略可能**偏向离群点**：一个不寻常的样本可能高度不确定，但不代表数据分布。核心集方法通

**k中心贪婪算法**{cite}`sener2018active` 找到最小的点集，使得每个未标注点都在至少一个被查询点的 $\delta$ 范围内：

$$x^* = \arg\max_{x \in \mathcal{U}} \min_{x' \in \mathcal{L}} d(x, x')$$

即查询距离任何当前已标注点最远的点。这鼓励形成分布均匀的标注集。

### BADGE

BADGE（基于多样梯度嵌入的批量主动学习）{cite}`ash2020deep` 结合了不确定性与多样性：它选择一批样

---

## 深度模型的不确定性估计

上述策略假设能够从模型获取经过校准的概率输出。对于简单模型（逻辑回归、softmax分类器），这很直接。

### 两类不确定性

按照Kendall和Gal的分类 {cite}`kendall2017uncertainties`，我们区分：

**偶然不确定性**（数据不确定性）：观测中固有的噪声，无法通过收集更多数据来消除。一张模糊的图像具有偶
—即使从相同分布收集更多训练数据，也无法使模型对它更有把握。

**认知不确定性**（模型不确定性）：由于训练数据有限或模型未见过类似样本而产生的不确定性。认知不确定性
—因此是主动学习查询选择的相关量。

对于主动学习，我们希望查询具有高认知不确定性的样本，而非高偶然不确定性的样本。查询本质上模糊的样

### 蒙特卡洛Dropout

针对神经网络认知不确定性估计的一种实用方法是MC Dropout {cite}`gal2016dropout`：在推理时应用dro
$T$ 次前向传播。预测结果之间的方差是认知不确定性的估计。

```
import numpy as np
import torch
import torch.nn as nn

torch.manual_seed(42)
rng = np.random.default_rng(42)

class MCDropoutNet(nn.Module):
    def __init__(self, input_dim=20, hidden=64, output_dim=2, p_drop=0.3):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(input_dim, hidden), nn.ReLU(), nn.Dropout(p_drop),
            nn.Linear(hidden, hidden),    nn.ReLU(), nn.Dropout(p_drop),
            nn.Linear(hidden, output_dim)
```

```
        )

    def forward(self, x):
        return self.net(x)

def mc_uncertainty(model, x, T=30):
    """
    Run T stochastic forward passes with dropout active.
    Returns mean prediction and epistemic uncertainty (predictive variance
    """
    model.train()  # keep dropout active during inference
    with torch.no_grad():
        preds = torch.stack([
            torch.softmax(model(x), dim=-1) for _ in range(T)
        ])  # shape: (T, N, C)
    mean_pred = preds.mean(0)
    # Epistemic uncertainty: mean of variances across passes
    epistemic = preds.var(0).sum(-1)
    # Aleatoric uncertainty: entropy of mean prediction
    aleatoric = -(mean_pred * (mean_pred + 1e-9).log()).sum(-1)
    return mean_pred, epistemic, aleatoric

# Quick demonstration
model = MCDropoutNet(input_dim=20, output_dim=2)
# In-distribution example (simulated)
x_familiar   = torch.randn(1, 20) * 0.5
# Out-of-distribution example (far from training distribution)
x_unfamiliar = torch.randn(1, 20) * 3.0

for name, x in [("In-distribution ", x_familiar), ("Out-of-distribution",
    _, ep, al = mc_uncertainty(model, x)
    print(f"{name} | epistemic: {ep.item():.4f} | aleatoric: {al.item():.4
```

在上述未训练的网络中，两个样本显示出相似的不确定性。训练后，分布外样本将显示更高的认知不确定性——模型尚未学习到对距训练分布较远的输入的可靠映射。

### 深度集成

训练 $M$ 个独立初始化的模型并对其预测结果取平均，能提供比MC Dropout更简单且通常更可靠的不确定性估 {cite}`lakshminarayanan2017simple`。集成成员之间的分歧就是认知不确定性信号。

对于大规模主动学习，MC Dropout和深度集成都会增加与 $T$ 或 $M$ 次前向传播成比例的开销。在实践中，MC Dropout的 $T = 10$—$30$ 或集成的 $M = 5$ 个成员，通常足以按认知不确定性对样本进行排序，即使绝对值

---

## 完整的主动学习循环

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
```

```
from sklearn.metrics import accuracy_score
from copy import deepcopy

rng = np.random.default_rng(42)

# Generate dataset
X, y = make_classification(
    n_samples=2000, n_features=20, n_informative=10,
    n_classes=3, n_clusters_per_class=1, random_state=42
)
X_train, y_train = X[:1500], y[:1500]
X_test,  y_test  = X[1500:], y[1500:]

def entropy_query(model, X_pool):
    """Return index of most uncertain sample (entropy)."""
    probs = model.predict_proba(X_pool)
    ent = -np.sum(probs * np.log(probs + 1e-9), axis=1)
    return np.argmax(ent)

def random_query(X_pool):
    """Random baseline."""
    return rng.integers(0, len(X_pool))

def run_active_learning(strategy='entropy', n_initial=30, n_queries=120, q
    labeled_idx = list(rng.choice(len(X_train), n_initial, replace=False))
    unlabeled_idx = [i for i in range(len(X_train)) if i not in labeled_id
    accs = []

    for step in range(n_queries // query_batch):
        model = LogisticRegression(max_iter=500, C=1.0)
        model.fit(X_train[labeled_idx], y_train[labeled_idx])
        accs.append(accuracy_score(y_test, model.predict(X_test)))

        # Query
        X_pool = X_train[unlabeled_idx]
        for _ in range(query_batch):
            if strategy == 'entropy':
                q = entropy_query(model, X_pool)
            else:
                q = random_query(X_pool)
            labeled_idx.append(unlabeled_idx.pop(q))
            X_pool = X_train[unlabeled_idx]

    return np.array(accs)

labels_used = np.arange(1, 25) * 5 + 30  # label counts at each step

accs_active = run_active_learning(strategy='entropy')
accs_random = run_active_learning(strategy='random')

plt.figure(figsize=(8, 5))
```

```
plt.plot(labels_used, accs_active, 'o-', label='Entropy sampling', color='
plt.plot(labels_used, accs_random, 's--', label='Random baseline',  color=
plt.xlabel("Number of labeled examples", fontsize=12)
plt.ylabel("Test accuracy", fontsize=12)
plt.title("Active Learning vs. Random Sampling", fontsize=13)
plt.legend(fontsize=11)
plt.grid(alpha=0.3)
plt.tight_layout()
plt.savefig('active_learning_curve.png', dpi=150)
plt.show()

print(f"Active learning reaches {accs_active[-1]:.3f} accuracy")
print(f"Random sampling reaches {accs_random[-1]:.3f} accuracy")
print(f"Active learning saves ~{int((accs_random.tolist().index(min(accs_r
```

---

## 冷启动问题

主动学习需要经过训练的模型来对未标注点进行评分——但在开始时，你没有（或只有极少）标注样本。这就

实际解决方案：

1. **随机初始化**： 在开始主动学习之前，标注一小批随机种子集（20至100个样本）。
2. **基于聚类的初始化**： 对未标注样本池使用k-means；从每个聚类中标注一个样本。这确保了初始标注集的
3. **基于嵌入的选择**： 使用预训练编码器对样本进行嵌入；通过核心集方法选择多样化的子集。

对于大多数任务，几十个随机种子标签通常足以启动主动学习；确切数量取决于类别平衡、特征维度和模型复

---

## 批量模式主动学习

在实践中，标注者是批量工作的——在每个单一标签之后训练和部署新模型效率低下。**批量模式主动学习**同时
$b$ 个样本进行标注。

简单地选择不确定性最高的前 $b$ 个样本会导致**冗余**：高度不确定的样本往往聚集在一起（例如，在同一区域内

**行列式点过程**（DPP，Determinantal Point Processes）提供了一种有原则的方法来采样多样化的批次：它们
$S$ 在DPP下的概率正比于 $\det(L_S)$，其中 $L$ 是编码相似性的核矩阵。

---

## 停止准则

主动学习应该何时停止？常见准则包括：

- **预算耗尽**： 最简单——当标注预算用完时停止。
- **性能平台期**： 当模型在保留验证集上的精度连续 $k$ 轮没有提升超过 $\delta$ 时停止。
- **置信度阈值**： 当不确定性超过阈值的未标注样本比例低于某个比例时停止。
- **最大损失减少量**： 估计额外标签所能带来的最大收益；当该值降至阈值以下时停止 {cite}bloodgood2009method。

---

## 主动学习的适用场景（及不适用场景）

主动学习在以下情况下表现良好：- 标注昂贵且未标注样本池规模较大 - 数据具有清晰结构，模型可以利用这种
- 模型类别适合该任务

主动学习在以下情况下表现不佳：- 初始模型质量很差（冷启动），无法有意义地对样本进行排序
- 查询策略选择了离群点或错误标注的样本（噪声鲁棒性很重要）- 未标注样本池与测试分布之间存在数据分布

一个关键的实践问题是**分布不匹配**：主动学习倾向于查询决策边界附近的样本，从而创建一个偏斜的已标注集

> See also: 奠基性综述为{cite}`settles2009active`。理论基础（标签复杂度、不可知界）：{cite}`ba
> {cite}`ash2020deep`（BADGE）和{cite}`sener2018active`（核心集）。关于主动学习实际效果的
> {cite}`lowell2019practical`。关于深度模型的偶然与认知不确定性，请参见
> {cite}`kendall2017uncertainties`；关于作为不确定性估计器的深度集成，请参见
> {cite}`lakshminarayanan2017simple`；关于MC Dropout作为近似贝叶斯推断，请参见
> {cite}`gal2016dropout`。

# 交互式机器学习

主动学习提出了一个聚焦的问题：在给定预算的情况下，应该标注哪些样本？交互式机器学习（IML）提出了一

IML的特征在于人机反馈回路的**即时性**与**直接性**。传统机器学习中，人类移交数据并等待训练完成；IML使人类
—通常在数秒内完成。

---

## 交互式机器学习的原则

Amershi等人 {cite}`amershi2014power` 确定了IML的三个定义性特征：

1. **快速反馈**：模型更新速度足够快，使人类能够感知其反馈的效果。在极限情况下，模型更新实时发生。
2. **直接操控**：人类通过数据或模型的预测结果与模型交互——而非通过配置文件或超参数调整。
3. **迭代精化**：这个过程是真正的迭代：人类的下一步行动由模型当前的行为来决定，而模型当前的行为是由人

这创造了一个紧密的**协同适应回路**：人类和模型随时间推移相互响应而共同演变。人类学习模型的理解方式；

---

## 与主动学习的比较

IML和主动学习有很大重叠，但并不相同：

| 属性 | 主动学习 | 交互式机器学习 |
|---|---|---|
| 核心问题 | 标注什么？ | 如何交互？ |
| 反馈延迟 | 可以是批处理（数天） | 通常实时或近实时 |
| 模型更新频率 | 每轮（批处理） | 每次交互（在线） |
| 人类主动性 | 回答模型的问题 | 可以主动教模型 |
| 界面设计 | 次要考量 | 核心考量 |
| 人类认知负荷 | 未被明确建模 | 被明确考虑 |

在主动学习中，机器主导交互。在IML中，人类也可以主动——提供示例、纠正或对模型行为中任何看起来最有

---

## 混合主动交互

**混合主动**系统允许人类和机器在不同时刻各自主导{cite}`allen1999mixed`。纯机器主导的系统提问，人类

在实践中，最好的IML系统结合了：- **机器主动**：“我对这些样本不确定——你能为它们添加标签吗？”
- **人类主动**：“我注意到模型对这个类别始终预测错误——让我提供更多示例” - **确认**：
模型呈现其当前理解；人类确认或纠正

良好的IML界面使模型的当前理解可见且可纠正。这是**可解释性**要求：人类只能引导他们至少能大致理解的模型

---

## IML中的人类因素

IML将人类因素——认知负荷、疲劳、一致性和信任——直接带入学习回路。糟糕的IML设计会导致：

**标注疲劳**：人类在会话延长时做出越来越快、越来越粗糙的决策。进入训练数据的错误。

**锚定偏差**：人类过度依赖模型当前的建议。如果界面预先填写模型的预测，即使预测是错误的，标注者也不太
—这是一种跨标注轮次累积的系统性标签噪声来源{cite}`geva2019annotator`。预标注可以加快吞吐量
{cite}`lingren2014evaluating`，同时降低标注者发现模型错误的比率；在IML界面设计中，必须权衡这两

**信任错误校准**：人类要么过度信任（接受错误的模型输出），要么信任不足（忽视正确的建议）。两种模式都

**会话一致性**：人类可能在不同时间对相同样本做出不同决策，特别是在长时间会话后。一致性检查（重新呈现

良好的IML设计通过界面选择来缓解这些问题：明确呈现模型置信度、随机化显示顺序、限制会话时长，以及建

---

## 实践中的IML反馈类型

### 样本级反馈

人类为特定样本提供标签或纠正。这是最常见的形式，与监督学习直接兼容。

### 特征级反馈

人类指出哪些特征是相关或不相关的。“模型应该关注’紧急’和’截止日期’这两个词来识别这个类别。”

TFIDF Interactive等类似系统允许标注者高亮文本文档中的相关词语。这些高亮被转化为对模型注意力的约束或

### 模型级反馈

人类直接纠正模型对一类输入的行为：“每当输入包含[X]时，输出应该是[Y]。”这映射到后验正则化
{cite}`ganchev2010posterior` 或约束驱动学习等方法中的逻辑规则或约束。

---

## 案例研究：Google Teachable Machine

Teachable Machine是一个易于使用的基于Web的IML系统，允许非技术用户在浏览器中训练图像分类器。用

1. 使用网络摄像头录制每个类别的示例
2. 点击一次按钮即可训练模型（在浏览器中对MobileNet进行微调）
3. 立即查看模型对实时视频的预测结果
4. 为模型预测错误的类别添加更多示例

这说明了IML的核心循环：提供示例 → 观察模型 → 识别失败 → 提供更有针对性的示例。实时反馈（模型输出实

---

## 实现一个简单的IML回路

```
import numpy as np
from sklearn.linear_model import SGDClassifier
from sklearn.preprocessing import StandardScaler
import warnings
warnings.filterwarnings('ignore')

class SimpleIMLSystem:
    """
    Minimal IML system that allows online feedback and displays
    model state after each annotation.
    """

    def __init__(self, n_features=10, n_classes=2):
        self.model = SGDClassifier(loss='log_loss', max_iter=1, warm_start
                                   random_state=42)
        self.scaler = StandardScaler()
        self.X_seen = []
        self.y_seen = []
        self.n_classes = n_classes
        self.initialized = False

    def update(self, x, y_true):
        """Receive a single labeled example and update the model."""
        self.X_seen.append(x)
        self.y_seen.append(y_true)

        if len(self.X_seen) >= 2 * self.n_classes:
            X_arr = np.array(self.X_seen)
            y_arr = np.array(self.y_seen)
            X_scaled = self.scaler.fit_transform(X_arr)
            self.model.partial_fit(X_scaled[-1:], y_arr[-1:],
                                   classes=list(range(self.n_classes)))
            self.initialized = True

        return self

    def predict_with_confidence(self, x):
        """Predict label and return confidence."""
        if not self.initialized:
            return None, 0.0
        x_scaled = self.scaler.transform(x.reshape(1, -1))
        probs = self.model.predict_proba(x_scaled)[0]
        return self.model.predict(x_scaled)[0], probs.max()

    def current_accuracy(self, X_val, y_val):
```

```
        if not self.initialized:
            return None
        X_scaled = self.scaler.transform(X_val)
        return (self.model.predict(X_scaled) == y_val).mean()


# Simulate an IML session
rng = np.random.default_rng(42)
X_all, y_all = np.random.default_rng(0).random((500, 10)), np.random.defau
X_val, y_val = X_all[400:], y_all[400:]

system = SimpleIMLSystem(n_features=10, n_classes=2)
accs, confidences = [], []

print("Step | Labels | Accuracy | Example confidence")
print("-" * 50)

for step in range(100):
    x, y = X_all[step], y_all[step]
    pred, conf = system.predict_with_confidence(x)
    system.update(x, y)

    if (step + 1) % 10 == 0:
        acc = system.current_accuracy(X_val, y_val)
        if acc is not None:
            accs.append(acc)
            print(f"  {step+1:3d} |  {step+1:4d}  |  {acc:.3f}   | {conf:.
```

---

## 祖母测试

评估IML界面设计——以及更广泛地评估HITL系统设计——的一个有用启发式方法，是我们在此称之为**祖母测试**

一位出生于1930年的女性应能通过语音使用这个设备，在遇到困难时，能够优雅地切换到键盘或文本界面

这个测试的主要目的不是可访问性，尽管它也包含这层含义。它是关于**为阻力而设计**。如果一个系统需要用户

这对IML设计的含义是具体的：

**语音优先的回退**：主要交互模式应该是自然语言或手势——而非参数滑块或置信度阈值。专家可能需要滑块；

**优雅降级**：当用户的首选模式失败或令其沮丧时，系统应提供替代方案——而非空白屏幕或错误消息。界面是

**可读的模型状态**：模型的当前理解应该以人类可理解的术语呈现。不是”置信度：0.73”，而是”我相当确定

**对模糊性的容忍**：一位93岁的用户和一位23岁的机器学习工程师会以不同的方式与同一系统互动。祖母测试问
—不是通过检测用户年龄，而是通过设计能在各种专业水平和舒适程度下都有效的交互。

随着机器学习系统从研究工具走向日常基础设施，这个测试变得尤为重要。放射科医生使用的医学影像助手、
—每一个都涉及并未自愿成为AI训练师的回路中的人类。为他们而设计不是让步；这才是重点所在。

:::{admonition} 设计原则 :class: tip 祖母测试是一种设计约束，而非目标受众。通过这个测试的系统对用户多
:::

---

## IML与基础模型

现代IML越来越多地将**预训练基础模型**{cite}`bommasani2021opportunities`作为基础。用户不再从头开
一在有利情况下，可能只需要5至50个示例而非数千个，这取决于预训练表示与目标任务的匹配程度
{cite}`bommasani2021opportunities`。

实现这一点的技术包括：- **少样本提示**： 在大型语言模型的上下文窗口中提供示例- **适配器微调**：
更新小型适配器模块，同时冻结基础模型 - **参数高效微调（PEFT）**： LoRA、前缀调整（prefix
tuning）及类似方法，允许快速、低资源的更新

基础模型改变了IML的动态：人类不再是从零开始教一个空白模型，而是引导一个已经知晓大量知识的模型。按

> See also: {cite}`amershi2014power`的综述仍是IML原则最佳概述。关于混合主动系统，请参见
> {cite}`allen1999mixed`。关于标注中的锚定效应，请参见{cite}`geva2019annotator`
> 和{cite}`lingren2014evaluating`。

# 基于人类反馈的强化学习

没有任何一项技术比基于人类反馈的强化学习（RLHF）更能将HITL ML带入主流视野。它是InstructGPT {cite}`ouyang2022training` 背后的核心机制，也是许多现代大型语言模型指令遵循流程的关键组件 {cite}`stiennon2020learning`。理解RLHF——不仅仅是作为一套可以遵循的技术方案，而是作为一种有原—对任何从事现代人工智能工作的人而言都至关重要。

---

## 对齐问题

纯粹基于下一词元预测进行训练的大型语言模型（LLM）针对一个代理目标进行优化：预测人类书写文本中下一—有帮助、准确、安全且符合人类价值观的回复——相关，但并不相同。

训练目标与期望行为之间的不匹配被称为**对齐问题** {cite}`russell2019human`。具体而言，在互联网文本上
- 产生听起来合理的续写内容（这些内容可能在事实上是错误的）
- 反映训练数据中存在的偏见和有害内容
- 当这是统计上最可能跟随提示的内容时，表现出回避或操纵性行为

RLHF通过将人类偏好纳入优化目标本身来解决对齐问题。

---

## RLHF流程

RLHF分三个阶段进行：

```
□ □ 1□ □ □ □ □ □ SFT□
  --> □ □ □ □ □ □ □ □ □ □ □ □ □ □ □ □
  --> □ □ □ □ □ □ □ □ □ LLM□ □ □ □

□ □ 2□ □ □ □ □ □ □
  --> □ □ □ □ □ □ □ □ □ □ □ □ □ A□ B□ □ □ □ □
  --> □ □ □ □ □ □  R(x, y) □ □ □ □ □ □ □

□ □ 3□ □ □ □ □ □ □
  --> □ □ PPO/RL□ LLM□ □ □ □ □ □ □ □  R(x, y)
  --> KL□ □ □ □ □ □ □ □ □ □ SFT□ □
```

### 阶段1：监督微调

从预训练基础模型 $\pi_0$ 出发，我们收集一个（提示，理想回复）对的数据集，由遵循详细指南的人类承包商撰写

$$\mathcal{L}_{\text{SFT}}(\theta) = -\mathbb{E}_{(x,y)\sim\mathcal{D}_{\text{demo}}}\left[\log \pi_\theta(y \mid x)\right]$$

SFT模型 $\pi_{\text{SFT}}$ 是比原始预训练模型更好的RLHF起始点。

### 阶段2：奖励模型训练

对于一组提示 $\{x_i\}$，我们使用 $\pi_{\text{SFT}}$ 为每个提示生成 $K$ 个回复，并以成对比较的形式呈现给人类标注者：“哪
奖励模型 $r_\phi$ 被训练以预测这些偏好。在Bradley-Terry模型（第8章）下，回复 $y_w$ 优于 $y_l$ 的概率为：

$$P(y_w \succ y_l \mid x) = \sigma\left(r_\phi(x, y_w) - r_\phi(x, y_l)\right)$$

奖励模型被训练以最小化成对排序损失：

$$\mathcal{L}_{\text{RM}}(\phi) = -\mathbb{E}_{(x,y_w,y_l)\sim\mathcal{D}_{\text{pref}}}\left[\log \sigma\left(r_\phi(x, y_w) - r_\phi(x, y_l)\right)\right]$$

奖励模型通常从SFT模型初始化，以标量头替换最后一层。

### 阶段3：使用PPO进行强化学习微调

有了训练好的奖励模型，我们可以使用强化学习对LLM进行微调。每个提示 $x$ 是一个状态；每个回复 $y$ 是词元选择的轨迹；奖励为 $r_\phi(x, y)$。

优化目标包括一个**KL散度惩罚**，以防止模型过度偏离SFT基线（这会导致奖励黑客攻击{cite}`krakovna2020`

$$\max_\theta \mathbb{E}_{x\sim\mathcal{D}, y\sim\pi_\theta(\cdot|x)}\left[r_\phi(x, y) - \beta \cdot \text{KL}\left[\pi_\theta(\cdot \mid x) \| \pi_{\text{SFT}}(\cdot \mid x)\right]\right]$$

参数 $\beta$ 控制KL惩罚强度。较小的 $\beta$ 允许更多优化，但存在奖励黑客攻击风险；较大的 $\beta$ 使模型保持接近SFT，但限制了对齐收益。

**近端策略优化**（PPO）{cite}`schulman2017proximal`是这一阶段的标准算法，因其相对于原始策略梯度

---

## 简化版RLHF演示

完整的RLHF流程需要大规模基础设施。以下示例在小规模上展示了核心思想。

```
import numpy as np
import torch
import torch.nn as nn
import torch.optim as optim
from torch.nn import functional as F

torch.manual_seed(42)
rng = np.random.default_rng(42)
```

```python
# ------------------------------------------------
# Toy setup: responses are 4-dimensional vectors
# "Quality" is known analytically (sum of positive values)
# We simulate a reward model learning this from pairwise feedback
# ------------------------------------------------

class RewardModel(nn.Module):
    def __init__(self, d=4, hidden=32):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(d, hidden), nn.ReLU(),
            nn.Linear(hidden, hidden), nn.ReLU(),
            nn.Linear(hidden, 1)
        )
    def forward(self, x):
        return self.net(x).squeeze(-1)

def true_quality(x):
    """The hidden ground-truth reward function."""
    return x.sum(dim=-1) + 0.5 * (x ** 2).mean(dim=-1)

# Generate pairwise preference data
N_PAIRS = 500
X1 = torch.randn(N_PAIRS, 4)
X2 = torch.randn(N_PAIRS, 4)
q1, q2 = true_quality(X1), true_quality(X2)
# Human prefers X1 when q1 > q2 (with some noise)
noise = torch.randn(N_PAIRS) * 0.5
preferred_1 = ((q1 - q2 + noise) > 0).float()

# Train reward model
rm = RewardModel(d=4, hidden=32)
optimizer = optim.Adam(rm.parameters(), lr=3e-3)

losses = []
for epoch in range(200):
    r1 = rm(X1)
    r2 = rm(X2)
    # Bradley-Terry loss
    logit = r1 - r2
    loss = F.binary_cross_entropy_with_logits(logit, preferred_1)
    optimizer.zero_grad(); loss.backward(); optimizer.step()
    losses.append(loss.item())

# Evaluate: does the reward model agree with true quality?
X_eval = torch.randn(1000, 4)
with torch.no_grad():
    r_pred = rm(X_eval).numpy()
    r_true = true_quality(X_eval).numpy()

corr = np.corrcoef(r_pred, r_true)[0, 1]
```

```
print(f"Reward model correlation with true quality: {corr:.4f}")
print(f"Final training loss: {losses[-1]:.4f}")

import matplotlib.pyplot as plt
plt.figure(figsize=(8, 3))
plt.subplot(1, 2, 1)
plt.plot(losses, color='#2b3a8f', linewidth=1.5)
plt.xlabel("Epoch"); plt.ylabel("Pairwise loss")
plt.title("Reward Model Training")

plt.subplot(1, 2, 2)
plt.scatter(r_true[:200], r_pred[:200], alpha=0.4, s=15, color='#2b3a8f')
plt.xlabel("True quality"); plt.ylabel("Predicted reward")
plt.title(f"Reward Model vs. Truth (r={corr:.3f})")
plt.tight_layout()
plt.savefig('reward_model.png', dpi=150)
plt.show()
```

---

## RLHF的挑战

### 奖励黑客攻击

一个关键的失败模式：策略找到了从奖励模型中获得高分的方式，但这些方式并不对应真正良好的行为。例如

以下情况更容易出现奖励黑客攻击：- 奖励模型在偏好数据不足的情况下进行训练 - 策略被允许大幅偏离S-FT基线（较小的 $\beta$） - 奖励模型分布在PPO训练过程中发生偏移

**缓解策略：** KL惩罚、迭代奖励模型训练、多样化评估、宪法AI约束。

### 评估者偏差

人类标注者存在系统性偏差。他们往往偏好更长的回复（冗长偏差）、听起来更自信的文本（置信偏差），以

RLHF模型臭名昭著的逢迎失败——模型告诉用户他们想听的而不是真实的内容——部分原因就是评估者对顺从

### 可扩展监督

对于复杂任务，人类无法可靠地判断哪个AI回复是正确的。比较两个长篇数学证明或两段代码实现的标注者可
{cite}bowman2022measuring。

---

## 宪法AI（RLAIF）

宪法AI{cite}bai2022constitutional（由Anthropic开发）通过让AI本身基于一套原则（即”宪法”）

1. 对潜在有害的提示生成回复
2. 使用AI评论者根据宪法原则评估回复
3. 在AI反馈的引导下修改回复（RLAIF——基于AI反馈的强化学习）
4. 在AI生成的偏好数据上训练奖励模型

5. 使用这个奖励模型进行RLHF微调

RLAIF能够以远超人类标注的规模生成偏好数据，并允许对奖励模型中编码的价值观进行精细控制。

See also: 原始InstructGPT论文 {cite}ouyang2022training 描述了RLHF在LLM上的第一次大规模应用。深度强化学习中RLHF的奠基性工作为{cite}christiano2017deep。{cite}schulman2017proximal。宪法AI来自{cite}bai2022constitutional。

# 从示范中学习

当一个任务难以明确规定却易于演示时，通过示例教学可能比通过规则定义更为高效。人类专家展示机械臂如

---

## 行为克隆

最简单的方法是**行为克隆**（BC）：将示范视为监督数据，学习从状态到动作的映射。

给定来自专家示范者的状态-动作对数据集 $\mathcal{D} = \{(s_i, a_i)\}$，我们通过最小化负对数似然来拟合策略 $\pi_\theta(a \mid s)$：

$$\mathcal{L}_{\text{BC}}(\theta) = -\frac{1}{|\mathcal{D}|} \sum_{(s,a)\in\mathcal{D}} \log \pi_\theta(a \mid s)$$

这正是应用于序列数据的标准监督学习。

### 协变量偏移问题

BC存在一个根本性弱点：训练与部署之间的**分布偏移**。专家的示范覆盖了专家访问过的状态。但在部署过程中
—在这些状态下，策略没有监督信号，可能会严重失败。

关键在于，错误会**复合累积**：一次小的偏差导致一个不熟悉的状态，在那里一次略微错误的动作导致一个更加
$O(T^2\epsilon)$ 退化，其中 $T$ 是幕长，$\epsilon$ 是每步的错误率——比具有神谕策略的 $O(T\epsilon)$ 退化要糟糕得多
{cite}`ross2010efficient`。

> **示例：自动驾驶** :class: note
>
> 用于车道保持的行为克隆模型在直道上（接近训练分布的状态）表现良好。但一旦它稍微偏离一
> —这是一个人类驾驶员不会处于的状态，因为他们早就纠正了——它就没有数据来引导它，可能会驶离道

```
□ □  DAgger□
  □ □ □ □ D <- {} □ □ □ □ □ □
  □ M□ □ □ □ □ □ □ □ □ □ □ □  pi_1

  □ □ □ □  i = 1, 2, ..., N□
    1. □ □ □ □ □ □  pi_i □ □ □ □ □  {s_1, ..., s_t}
    2. □ □ □ □ □ □ □ □ □ □ □ □ □ □ □ □ a_t = pi*(s_t)
    3. □ □ □ D <- D ∪ {(s_1, a_1), ..., (s_t, a_t)}
    4. □ D□ □ □ □ □ □ □ □ □  pi_{i+1}
```

DAgger实现了 $O(T\epsilon)$ 的遗憾——与神谕策略相同——因为训练分布收敛于部署分布。

关键要求是可以在任意状态上查询专家，包括专家自然从不会访问的状态。在仿真中这是可行的（要求专家从

---

## 逆强化学习

有时，专家的行为最好不是理解为一系列需要模仿的动作序列，而是优化某个未知奖励函数的结果。**逆强化学**
{cite}`ng2000algorithms` 从示范中恢复这个潜在的奖励函数。

给定示范 $\tau = \{(s_1, a_1), \ldots, (s_T, a_T)\}$，IRL找到一个奖励函数 $R(s, a)$，使得专家的策略在 $R$ 下是最优的。

IRL相对于BC的吸引力在于：如果我们恢复了真实的奖励函数，就可以在新的环境中、用不同的动力学或改进的
—泛化能力远超示范场景。

### 最大熵IRL

MaxEnt IRL {cite}`ziebart2008maximum` 通过选择能带来最大熵轨迹分布的奖励函数，解决了IRL的歧义性

$$P(\tau \mid R) \propto \exp\left(\sum_t R(s_t, a_t)\right)$$

学习目标是将专家观测到的特征期望 $\mu_E = \mathbb{E}_{\tau\sim\pi^*}[\phi(\tau)]$ 与模型的特征期望 $\mu_\theta = \mathbb{E}_{\tau\sim\pi_\theta}[\phi(\tau)]$ 相匹配。

---

## GAIL：生成对抗模仿学习

GAIL {cite}`ho2016generative` 完全绕过奖励函数学习，使用类似GAN的形式直接匹配专家的状态-动作分布。

判别器 $D_\psi$ 被训练以区分专家的状态-动作对 $(s, a) \sim \pi^*$ 和策略的状态-动作对 $(s, a) \sim \pi_\theta$：

$$\mathcal{L}_D = -\mathbb{E}_{\pi^*}[\log D_\psi(s, a)] - \mathbb{E}_{\pi_\theta}[\log(1 - D_\psi(s, a))]$$

生成器（策略 $\pi_\theta$）被训练以欺骗判别器——即产生看起来像专家的状态-动作对。判别器的输出 $\log D_\psi(s, a)$ 充当策略的奖励信号。

GAIL在连续控制基准上以远少于BC的示范实现专家级性能，在复杂环境中的泛化能力也优于MaxEnt IRL。

---

## NLP中的行为克隆：实践示例

```
import numpy as np
import torch
import torch.nn as nn
from torch.utils.data import DataLoader, TensorDataset

torch.manual_seed(42)

# ------------------------------------------------
# Toy NLP task: rewriting sentences to be more formal
# We simulate this as a simple sequence transformation
# In practice: fine-tuning a seq2seq model on expert rewrites
# ------------------------------------------------

class SimpleSeq2Seq(nn.Module):
    def __init__(self, vocab_size=100, embed_dim=32, hidden_dim=64):
        super().__init__()
        self.embed = nn.Embedding(vocab_size, embed_dim, padding_idx=0)
        self.encoder = nn.GRU(embed_dim, hidden_dim, batch_first=True)
        self.decoder = nn.GRU(embed_dim, hidden_dim, batch_first=True)
        self.proj = nn.Linear(hidden_dim, vocab_size)
        self.hidden_dim = hidden_dim

    def forward(self, src, tgt):
        src_emb = self.embed(src)
        _, hidden = self.encoder(src_emb)
        tgt_emb = self.embed(tgt)
        out, _ = self.decoder(tgt_emb, hidden)
        return self.proj(out)

# Generate synthetic demonstration data
VOCAB = 100
rng = np.random.default_rng(42)
N, SEQ_LEN = 1000, 12

src_seqs = torch.tensor(rng.integers(1, VOCAB, (N, SEQ_LEN)), dtype=torch.
# "Expert" transformation: shift tokens by 1 (toy formalization)
tgt_seqs = torch.clamp(src_seqs + 1, 1, VOCAB - 1)
tgt_in  = torch.cat([torch.ones(N, 1, dtype=torch.long), tgt_seqs[:, :-1]]

dataset = TensorDataset(src_seqs, tgt_in, tgt_seqs)
loader = DataLoader(dataset, batch_size=64, shuffle=True)

model = SimpleSeq2Seq(vocab_size=VOCAB)
optimizer = torch.optim.Adam(model.parameters(), lr=1e-3)
criterion = nn.CrossEntropyLoss(ignore_index=0)

# Behavioral cloning training
train_losses = []
for epoch in range(20):
```

```
    epoch_loss = 0
    for src, tgt_i, tgt_o in loader:
        logits = model(src, tgt_i)
        loss = criterion(logits.reshape(-1, VOCAB), tgt_o.reshape(-1))
        optimizer.zero_grad(); loss.backward(); optimizer.step()
        epoch_loss += loss.item()
    train_losses.append(epoch_loss / len(loader))

print(f"Initial loss: {train_losses[0]:.3f}")
print(f"Final loss:   {train_losses[-1]:.3f}")

# Evaluate: check token accuracy on held-out examples
model.eval()
with torch.no_grad():
    src_test = src_seqs[-100:]
    tgt_test_in = tgt_in[-100:]
    tgt_test_out = tgt_seqs[-100:]
    logits = model(src_test, tgt_test_in)
    preds = logits.argmax(dim=-1)
    acc = (preds == tgt_test_out).float().mean().item()
    print(f"Token accuracy on held-out set: {acc:.3f}")
```

---

## 模仿学习方法比较

| 方法 | 需要奖励? | 在线查询专家? | 对新动力学的泛化能力? | 复杂度 |
|---|---|---|---|---|
| 行为克隆 | 否 | 否 | 差（分布偏移） | 低 |
| DAgger | 否 | 是 | 中等 | 中 |
| MaxEnt IRL | 可恢复 | 否 | 好 | 高 |
| GAIL | 否 | 否 | 好 | 高 |

---

## 应用领域

**机器人学。** 教机器人操作物体、在环境中导航或执行家务任务。物理示范通过遥操作或运动教学收集。

**自动驾驶。** ALVINN {cite}`pomerleau1989alvinn` 和NVIDIA的DAVE等早期自动驾驶系统大量依赖从人类

**游戏AI。** 在人类游戏数据上进行模仿学习，在强化学习微调前引导智能体。AlphaStar在RL之前先在人类回放

**代码生成。** 在高质量代码示范上进行语言模型微调（GitHub Copilot、Codex）是一种行为克隆形式。

**临床决策支持。** 从专家医生针对复杂协议的决策序列中学习。

> See also: BC/DAgger的奠基性分析见于 {cite}`ross2011reduction`。MaxEnt IRL来自{cite}`ziebart2008maximum`。GAIL来自{cite}`ho2016generative`。关于模仿学习的全面 {cite}`osa2018algorithmic`。

# 从比较与排序中学习

要求人类为一个输出分配绝对质量分数是困难的。这篇文章的数字质量是多少，在1到10的分数上？这个问题本
要求人类比较两个输出则容易得多：哪篇文章更好，A还是B？比较性判断更具一致性、更可靠，也更直接地反

---

## 为何比较优于评分

### 心理学依据

比较性判断的优越性在心理测量学中有悠久的历史。Thurstone的比较判断定律{cite}`thurstone1927law`

### 统计效率

每个成对比较提供了关于两个项目在质量尺度上相对位置的信息。对于 $K$ 个项目，$K - 1$
次比较可以对所有项目进行排序；只需 $O(\log K)$ 次比较就可以找到最优项目。绝对评分通常需要更多判断才

### 可扩展性

对于生成式模型，不同输出的数量实际上是无限的。对一个输出进行绝对评分需要在所有输出之间建立共享尺

---

## Bradley-Terry模型

成对比较最主流的概率模型是Bradley-Terry（BT）模型{cite}`bradley1952rank`。每个项目
$i$ 具有潜在质量分数 $\alpha_i \in \mathbb{R}$。在直接比较中，项目 $i$ 优于项目 $j$ 的概率为：

$$P(i \succ j) = \frac{e^{\alpha_i}}{e^{\alpha_i} + e^{\alpha_j}} = \sigma(\alpha_i - \alpha_j)$$

其中 $\sigma$ 是逻辑Sigmoid函数。这等价于假设项目 $i$ 的感知质量为 $\alpha_i + \epsilon$，其中 $\epsilon$ 是标准逻辑噪声项。

### 可识别性

BT模型在平移意义下可识别：如果 $\alpha$ 是一个解，那么对任意常数 $c$，$\alpha + c$ 也是解。标准惯例是固定一个分数
$\alpha_0 = 0$）或约束 $\sum_i \alpha_i = 0$。只有当**比较图**（节点 = 项目，边 = 观测到的比较对）是**连通的**时，分数才能
—如果图有不连通的分量，跨分量的相对分数是未定义的。

### 参数估计

给定成对比较数据集 $\mathcal{D} = \{(i, j, y_{ij})\}$，其中 $y_{ij} = 1$ 表示 $i$ 优于 $j$，对数似然为：

$$\mathcal{L}(\alpha) = \sum_{(i,j,y_{ij})\in\mathcal{D}} \left[y_{ij} \log \sigma(\alpha_i - \alpha_j) + (1 - y_{ij}) \log \sigma(\alpha_j - \alpha_i)\right]$$

这是 $\alpha$ 的凹函数，可以通过梯度上升或牛顿法最大化。

```python
import numpy as np
from scipy.optimize import minimize
from scipy.special import expit  # sigmoid

rng = np.random.default_rng(42)

# ------------------------------------------------
# Simulate Bradley-Terry: 8 items with true quality scores
# Generate pairwise comparisons and recover the scores
# ------------------------------------------------

N_ITEMS = 8
true_alpha = rng.normal(0, 1, N_ITEMS)
print(f"True quality ranking: {np.argsort(true_alpha)[::-1]}")

# Generate comparisons: every pair compared 5 times
comparisons = []
for i in range(N_ITEMS):
    for j in range(i + 1, N_ITEMS):
        for _ in range(5):
            p_i_wins = expit(true_alpha[i] - true_alpha[j])
            winner = i if rng.random() < p_i_wins else j
            loser  = j if winner == i else i
            comparisons.append((winner, loser))

print(f"Total comparisons: {len(comparisons)}")

def neg_log_likelihood(alpha, comparisons):
    """Bradley-Terry negative log-likelihood."""
    alpha = np.array(alpha)
    loss = 0.0
    for winner, loser in comparisons:
        log_prob = np.log(expit(alpha[winner] - alpha[loser]) + 1e-10)
        loss -= log_prob
    return loss

def neg_grad(alpha, comparisons):
    alpha = np.array(alpha)
    grad = np.zeros(len(alpha))
    for winner, loser in comparisons:
        p = expit(alpha[winner] - alpha[loser])
        grad[winner] -= (1 - p)
```

```
        grad[loser]  -= (-p)
    return grad

# Fix alpha[0] = 0 to resolve scale ambiguity
result = minimize(
    lambda a: neg_log_likelihood(np.concatenate([[0.0], a]), comparisons),
    x0=np.zeros(N_ITEMS - 1),
    jac=lambda a: neg_grad(np.concatenate([[0.0], a]), comparisons)[1:],
    method='L-BFGS-B'
)
est_alpha = np.concatenate([[0.0], result.x])

# Compare true vs estimated ranking
true_rank = np.argsort(true_alpha)[::-1]
est_rank  = np.argsort(est_alpha)[::-1]

print(f"\nTrue ranking (item indices): {true_rank}")
print(f"Estimated ranking:           {est_rank}")
rank_corr = np.corrcoef(true_alpha, est_alpha)[0, 1]
print(f"Correlation with true scores: {rank_corr:.4f}")
```

---

## Thurstone模型

Thurstone模型{cite}`thurstone1927law`与Bradley-Terry密切相关，但使用高斯噪声而非逻辑噪声：

$$P(i \succ j) = \Phi\left(\frac{\alpha_i - \alpha_j}{\sqrt{2}\sigma}\right)$$

其中$\Phi$是标准正态累积分布函数。当$\sigma = 1/\sqrt{2}$时，这在微小的缩放差异下等价于BT。在实践中，两个模型

---

## 排序聚合

当每位标注者对$K$个项目提供完整排序（而非成对比较）时，问题变为**排序聚合**：将多个排序列表合并为共识

Borda计数： 每个项目获得的分数等于在每位标注者排序中排在其后的项目数量。分数跨标注者求和。简单且

Kemeny-Young： 找到使各标注者排序之间成对分歧之和（Kendall tau距离）最小的排序。对于较大的$K$是NP难问题，但对小集合可处理。

RankNet / ListNet： 从排序列表中学习评分函数的神经网络方法，能够泛化到未见过的项目。

---

## 决斗赌博机

在**在线**偏好学习中，项目以流式方式到达，我们必须决定比较哪些对，在探索（了解未知项目）和利用（呈现
{cite}`yue2009interactively`。

主要算法： - Doubler： 维护一个冠军项目；用随机竞争者挑战它 - RUCB（**相对置信上界**）：
计算每个项目击败每个其他项目的概率的UCB风格置信区间 - MergeRank： 将锦标赛式比较与UCB相结合

决斗赌博机用于在线推荐系统（接下来展示哪篇文章，基于隐式反馈）和RLHF数据收集的交互式偏好挖掘。

---

## 语言模型的偏好学习

在RLHF的背景下（第6章），Bradley-Terry模型用于训练奖励模型。一个重要变体是**直接偏好优化**（DPO）
{cite}`rafailov2023direct`，它表明RLHF目标可以直接从偏好数据中优化，而无需训练单独的奖励模型：

$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{(x,y_w,y_l)\sim\mathcal{D}}\left[\log\sigma\left(\beta\log\frac{\pi_\theta(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta\log\frac{\pi_\theta(y_l \mid x)}{\pi_{\text{ref}}(y_l \mid x)}\right)\right]$$

DPO比完整的RLHF更简单（无需PPO训练循环，无需奖励模型），在许多基准上能达到相当甚至更好的效果
{cite}`rafailov2023direct`。它已成为指令遵循微调中被广泛采用的PPO-RLHF替代方案，尽管两种方法都

---

## 收集高质量偏好数据

偏好数据的质量决定了奖励模型的质量。关键考量：

**提示多样性**。 偏好数据应覆盖模型在部署中将遇到的完整提示分布。覆盖缺口会导致奖励模型在这些区域的行

**回复多样性**。 比较两个非常相似的回复提供的信息很少。被比较的回复应有足够差异，使标注者能有清晰的偏

**标注者一致性**。 低标注者间一致性表明比较标准不明确。衡量一致性（Cohen’s κ），当其低于可接受阈值时

**校准**。 标注者应理解为何一个回复更好：有帮助性、准确性、安全性、风格？将多个标准捆绑在一起的任务往

See also: Bradley-Terry模型：{cite}`bradley1952rank`。Thurstone：{cite}`thurstone1927law`

# 人机协同在自然语言处理中的应用

自然语言是HITL ML产生最深远影响——同时也涌现出其最深层概念困难——的领域。语言本质上是社会性的：

---

## NLP标注中的建构性问题

在医学影像中，存在客观真相：肿瘤要么存在，要么不存在。放射科医生的标签可能存在不确定性，但它试图

这具有深远影响，而这些影响经常被严重低估：

**标注者群体定义了这一现象**。 “冒犯性言论”的标注方案，编码了设计它的人以及应用它的人的感知。一支来
—而非某种普遍的人类标准。在此类数据上训练的模型将表现出相同的隐性边界。

**指南是理论，无论它们是否承认这一点**。 每个标注方案都在做本体论上的主张。决定”讽刺”和”挖苦”属于

**标签的时间不稳定性**。 社会语言在演变。一个在2018年训练的毒性模型会对2024年的内容产生误分类，不是因
—它是从一个不断移动的目标中采样，而标注行为本身也在一定程度上参与构建这个目标。

:::{admonition} 标注伪像问题 :class: important

Geva等人 {cite}`geva2019annotator` 证明，自然语言推理（NLI）数据集包含由标注过程本身引入的系统
—它们解决的是标注任务，而非底层的NLP任务。

这不是粗心大意。这是让人类构建符合标签的示例这一做法的固有后果。HITL过程插入了一个从未打算出现在数
:::

---

## 文本分类标注

最简单的NLP标注任务是为一个文本文档分配类别。情感分析、主题分类、意图检测和垃圾邮件过滤都是分类

**文本分类特有的挑战**：

主观性。 “有毒”或”冒犯性”等类别本质上是主观的，因文化情境、标注者背景和平台情境而异。不同标注
—这一事实对公平性有直接影响 {cite}`blodgett2020language`。

标签歧义。 许多文档属于多个类别或处于边界上。一篇60%正面、40%负面的评论是真正模糊的，而非被错误

标签粒度。 二分类情感模型可能足以用于社交媒体监控；七分制量表可能是产品反馈分析所必需的。正确的粒
—这是一个在信息不足的情况下做出的重要设计决策。

---

## 命名实体识别

NER标注需要识别文本片段并分配实体类型（人名、组织机构名、地名等）。由于以下原因，标注比文档分类

**片段边界具有歧义性**。在”苹果公司CEO蒂姆·库克宣布……“中，人名实体是”蒂姆·库克”还是”苹果公

**类型分配需要世界知识**。“Apple（苹果）”在一种情境下是ORG，在另一种情境下是PRODUCT，在”app pie（苹果派）“中两者都不是。标注者需要足够的领域知识来做出正确的类型分配。

**嵌套实体**。“加州大学伯克利分校”包含嵌套在LOCATION内的ORGANIZATION。标准BIO标注无法表示嵌套

**标注效率**。用基线NER模型进行预标注，允许标注者纠正预测而非从零开始标注，可以显著提高标注速度。在 {cite}`lingren2014evaluating`；这类收益的大小在很大程度上取决于基线模型质量和领域。

---

## 关系抽取与语义标注

除了识别实体，关系抽取还需要标注实体之间的关系：

- 标注者必须理解实体和连接它们的谓词
- 关系类型具有复杂的语义区别（WORKS_AT vs. EMPLOYED_BY vs. FOUNDED）
- 负样本（没有关系的实体对）远多于正样本

**关系抽取的标注者间一致性**往往低于分类任务。对于定义明确的方案，$\kappa$ 值通常在0.65至0.80的范围内 {cite}`pustejovsky2012natural`；对于复杂的语义关系（事件因果、时序关系），一致性可能会明显更低

---

## 机器翻译译后编辑（MTPE）

机器翻译译后编辑是HITL NLP的一种成熟形式。人工译者纠正机器翻译系统的输出，而非从头翻译：

**轻度译后编辑（LPE）**：只纠正关键错误。适用于翻译质量要求中等的情况。

**全面译后编辑（FPE）**：将输出纠正至发布质量。编辑后的输出通常成为进一步MT改进的训练数据——真正的人在回路精化循环。

**HTER（人工目标译文编辑率）**：衡量MT输出与译后编辑翻译之间的编辑距离，以句子长度进行归一化 {cite}`graham2015accurate`。作为粗略的从业者经验法则，HTER低于约0.3通常被认为是良好的MT输出；——尽管这些阈值因领域和语言对而异。

---

## 对话式AI与对话标注

对话标注引入了时序结构：

- **轮次级标注**：为每个轮次添加标签（意图、情感、质量）
- **对话级标注**：评估整体连贯性、任务完成情况、用户满意度
- **交互轨迹标注**：识别对话中的特定失败时刻

HITL在对话中尤为重要，因为模型失败往往是微妙且累积性的：第3轮中的事实错误可能直到第7轮才变得明显

---

## 程序化标注与弱监督

当标注数据稀缺时，**弱监督**允许使用多个嘈杂、重叠的标注函数在规模上生成概率标签。Snorkel {cite}`ratner2017snorkel` 是典型框架：

```
import numpy as np
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import f1_score

rng = np.random.default_rng(42)

# ---------------------------------------------------------
# Toy weak supervision: sentiment classification
# 5 labeling functions (LFs) with different coverage/accuracy
# Label: +1 (positive), -1 (negative), 0 (abstain)
# ---------------------------------------------------------

N = 1000
true_labels = rng.choice([-1, 1], size=N)
X_features = np.column_stack([
    true_labels * 0.8 + rng.normal(0, 0.5, N),
    rng.normal(0, 1, N),
    rng.normal(0, 1, N),
])

def make_lf(accuracy, coverage, seed):
    rng_lf = np.random.default_rng(seed)
    votes = np.zeros(N, dtype=int)
    active = rng_lf.random(N) < coverage
    correct = rng_lf.random(N) < accuracy
    votes[active & correct]  = true_labels[active & correct]
    votes[active & ~correct] = -true_labels[active & ~correct]
    return votes

LFs = np.column_stack([
    make_lf(accuracy=0.85, coverage=0.60, seed=1),
    make_lf(accuracy=0.78, coverage=0.45, seed=2),
    make_lf(accuracy=0.70, coverage=0.80, seed=3),
    make_lf(accuracy=0.90, coverage=0.30, seed=4),
    make_lf(accuracy=0.60, coverage=0.90, seed=5),
])

def majority_vote(LF_matrix):
    labels = []
    for i in range(LF_matrix.shape[0]):
        votes = LF_matrix[i][LF_matrix[i] != 0]
        labels.append(0 if len(votes) == 0 else int(np.sign(votes.sum())))
    return np.array(labels)

mv_labels = majority_vote(LFs)
covered = mv_labels != 0
```

```
print(f"Coverage:                    {covered.mean():.1%}")
print(f"MV accuracy (covered):       {(mv_labels[covered] == true_labels[c

X_train, y_train = X_features[covered], mv_labels[covered]
X_test,  y_test  = X_features[~covered], true_labels[~covered]

if len(X_train) > 10 and len(X_test) > 10:
    clf = LogisticRegression().fit(X_train, y_train)
    preds = clf.predict(X_test)
    print(f"F1 on uncovered test set:    {f1_score(y_test, preds):.3f}")
```

---

## 用于语言模型的RLHF：标注的现实

第6章从技术角度介绍了RLHF。从NLP角度来看，标注任务比外界看起来更为困难。

**标注者实际被要求做的事情**——比较两个模型输出并指出哪个”更好”——听起来很简单。在实践中，“更好

**关键的标注维度包括**：

- 有帮助性：回复是否很好地回答了问题？它是否信息丰富、清晰且适当详细？
- 事实性：回复在事实上是否准确？这要求评估者具有领域知识——一个在规模上会产生严重质量问题的要
- 无害性：回复是否避免了有毒、有偏见、有害或不适当的内容？这些判断需要详细的指南，因为”有害”
- 校准性：回复是否表达了适当的不确定性？标注者系统性地偏好听起来自信的回复，这产生了对抗适当

标准之间的相互作用是复杂的：对危险问题最有帮助的回复可能也是最有害的。指南必须指定如何权衡相互竞
—而这些权衡实际上是政策决策，而非标注决策。标注者群体在制定政策。

**规模集中了人口影响**。大型模型的RLHF涉及相对较小的标注者群体（数百至数千人），做出数十亿的下游决策

---

## 标注-模型反馈回路

在NLP中，比在任何其他领域都更明显，标注和模型开发过程随时间变得相互交织：

1. 标注者使用模型现有输出作为参考进行校准（通常是隐式的）。
2. 奖励模型学习标注者倾向于偏好什么。
3. 生成器被微调以产生获得高奖励的输出。
4. 这些输出影响了后续标注轮次中”好”的标准看起来是什么样的。

这个反馈回路并不天然是病态的——它正是允许RLHF收敛的机制——但这意味着模型的行为是由一个标注过程

没有完美的解决方案。当前的最佳实践是使用定期收集的保留偏好判断来监测漂移，并将标注指南版本视为实

---

## 生成式NLP模型的评估

与具有明确准确率指标的分类模型不同，评估生成质量需要人类判断：

| 评估方法 | 描述 | 成本 |
|---|---|---|
| 直接评估（DA） | 标注者在量表上评定质量 | 中等 |
| 比较判断 | 标注者比较两个输出 | 低 |
| MQM（多维质量指标） | 结构化错误分类体系 | 高 |
| RLHF偏好 | 用于训练的偏好标签 | 中等 |
| LLM作为评判者 | LLM对输出评分（与人类的相关性中等） | 极低 |
| BERTScore、BLEU | 自动指标（与人类判断的相关性不完美） | 极低 |

自动指标（MT的BLEU、摘要的ROUGE）成本低廉，但与人类质量判断的相关性不完美
{cite}`reiter2018structured`。LLM作为评判者的方法与人类标注者的一致性中等
{cite}`zheng2023judging`，越来越多地被用于快速迭代，但不应取代人类评估进行最终评估。对于具有真实

See also: Snorkel弱监督：{cite}`ratner2017snorkel`。NLP标注指南：{cite}`pustejovsky2012

# 人机协同在计算机视觉中的应用

计算机视觉提供了一些HITL ML最直观的示例。ImageNet挑战赛建立在1400万张人工标注图像之上，开启了深

容易被忽视的是：这些不仅仅是人类提供客观真相的案例。它们是人类构建数据集的案例，而这些数据集嵌入
—这些选择只有在后来，当模型以可预测的方式失败时，才变得可见。

---

## 标注选择如何变成模型偏见

标准框架将标注视为数据收集：人类观察世界并记录所见。更准确的框架是，标注是数据集设计：人类决定使
—所有这些决策都会影响训练好的模型将感知什么。

### ImageNet案例

ImageNet{cite}`russakovsky2015imagenet`是计算机视觉历史上最具影响力的数据集。其标签集来源于

- **人物类别编码了人口关联**。ImageNet早期版本的人物词组标签中，有许多现在会被认为是贬义或有偏见
  {cite}`yang2020towards`。应用于人物图像的标签编码了种族、性别和阶级关联，并直接传播到模型的
- **细粒度的物种分类体系，但其他几乎一切都是粗粒度的**。ImageNet能够区分120种狗品种，但将工具、
- **西方、英语的视觉默认值**。图像主要通过Flickr和英语搜索词的互联网搜索收集。由此形成的分布严重偏

以上都不是错误。它们是在规模上快速做出的标注设计决策，通常由没有预见到数据集将被如何使用的人做出

:::{admonition} 标注方案是关于世界的理论 :class: note

每个标签分类体系都在主张哪些区分是重要的。选择将”轿车”与”卡车”分开，同时将所有轿车合并为一类
—它们不会泛化到它们被训练以区分的类别之外。 :::

---

## 图像分类标注

最简单的CV标注任务是为整张图像分配一个或多个标签。

**标签层次体系**。“狗”这个标签在语义层次体系中是”动物”的子节点。在平坦分类体系上训练的模型可能无

**多标签歧义**。一个街景可能同时包含一辆汽车、一个人、一辆自行车和一个交通信号灯。决定包含哪些标签需

**长尾分布**。自然图像数据集遵循幂律：少数类别极为常见；大多数类别很少见。主动学习对长尾类别尤其有价

---

## 目标检测：边界框标注

目标检测要求标注者在每个对象类别的实例周围绘制轴对齐的边界框。这引入了几何精度要求和大量边缘案例

**标注质量指标：**

IoU（交并比） 测量标注框与参考框之间的重叠：

$$\text{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

IoU $\geq 0.5$ 是PASCAL VOC中”正确”检测的标准阈值；COCO{cite}lin2014microsoft 使用从0.5到0.95的一系列阈值，这要求更高也更具信息量。

**必须在指南中解决的标注边缘案例：** - 被遮挡的物体：标注可见部分还是推断完整范围？ - 被截断的物体（部分在帧外）：包含还是排除？ - 人群区域：使用特殊的”人群”标注还是标注单独实例？

每一个决策都改变了”正确检测”的含义——因此改变了模型被训练去做的事情。

```
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.patches as patches

def compute_iou(boxA, boxB):
    """Compute IoU between two boxes [x1, y1, x2, y2]."""
    xA = max(boxA[0], boxB[0])
    yA = max(boxA[1], boxB[1])
    xB = min(boxA[2], boxB[2])
    yB = min(boxA[3], boxB[3])
    inter_area = max(0, xB - xA) * max(0, yB - yA)
    boxA_area = (boxA[2] - boxA[0]) * (boxA[3] - boxA[1])
    boxB_area = (boxB[2] - boxB[0]) * (boxB[3] - boxB[1])
    union_area = boxA_area + boxB_area - inter_area
    return inter_area / (union_area + 1e-6)

ref_box  = [1.0, 1.0, 4.0, 4.0]
ann1_box = [1.1, 0.9, 4.1, 4.2]   # close
ann2_box = [0.5, 0.5, 3.5, 3.8]   # less precise

print(f"IoU (ann1 vs ref):  {compute_iou(ann1_box, ref_box):.3f}")
print(f"IoU (ann2 vs ref):  {compute_iou(ann2_box, ref_box):.3f}")
print(f"IoU (ann1 vs ann2): {compute_iou(ann1_box, ann2_box):.3f}")

fig, ax = plt.subplots(figsize=(5, 5))
ax.set_xlim(0, 5); ax.set_ylim(0, 5); ax.set_aspect('equal')
ax.add_patch(patches.Rectangle(
    (ref_box[0], ref_box[1]), ref_box[2]-ref_box[0], ref_box[3]-ref_box[1]
    linewidth=2.5, edgecolor='#2b3a8f', facecolor='none', label='Reference
ax.add_patch(patches.Rectangle(
    (ann1_box[0], ann1_box[1]), ann1_box[2]-ann1_box[0], ann1_box[3]-ann1_
    linewidth=2, edgecolor='#0d9e8e', facecolor='none', linestyle='--',
    label=f'Ann1 (IoU={compute_iou(ann1_box, ref_box):.2f})'))
ax.add_patch(patches.Rectangle(
```

```
    (ann2_box[0], ann2_box[1]), ann2_box[2]-ann2_box[0], ann2_box[3]-ann2_
    linewidth=2, edgecolor='#e05c5c', facecolor='none', linestyle=':',
    label=f'Ann2 (IoU={compute_iou(ann2_box, ref_box):.2f})'))
ax.legend(fontsize=10)
ax.set_title("Bounding Box Agreement (IoU)", fontsize=12)
plt.tight_layout()
plt.savefig('bbox_iou.png', dpi=150)
plt.show()
```

---

## 语义与实例分割

分割标注需要为图像中的每个像素分配类别标签——是成本最高的标注类型之一。

**语义分割**：每个像素属于一个语义类别（道路、天空、人、汽车）。同一类别的所有像素共享相同的标签，无

**实例分割**：每个单独的对象实例获得唯一标签。20人的人群变成20个不同的掩码。

**全景分割**：结合两者：“物体”类别（可计数的对象）有实例掩码；“场景”类别（道路、天空）有语义掩码

**SAM辅助标注**：Meta的Segment Anything Model {cite}kirillov2023segment
通过单次点击生成高质量的分割掩码。标注者点击对象的中心；SAM提出掩码；标注者接受或纠正。SAM作者

SAM代表了一种更广泛的转变：**标注者的角色从绘制转变为审核**。这对标注质量的影响超越了速度本身。当标
—这是特定于标注情境的自动化偏差的一种版本。

---

## 计算机视觉的主动学习

主动学习在CV中尤其有价值，因为：1. 图像是高维且特征丰富的——预训练模型的嵌入携带了用于不确定性
2. 大型未标注样本池成本低廉（照片、视频帧）3. 标注（特别是分割）成本高昂，对于专业领域无法轻易进行

```
import numpy as np
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score
import matplotlib.pyplot as plt

rng = np.random.default_rng(42)

X, y = make_classification(n_samples=3000, n_features=50, n_informative=25
                           n_classes=5, n_clusters_per_class=2, random_st
X_train, y_train = X[:2500], y[:2500]
X_test,  y_test  = X[2500:], y[2500:]

def margin_uncertainty(model, X_pool):
    probs = model.predict_proba(X_pool)
    sorted_p = np.sort(probs, axis=1)
    return sorted_p[:, -2] - sorted_p[:, -1]  # most negative = most uncer

n_init = 50
```

```
results = {'active': [], 'random': []}
label_counts = list(range(50, 401, 30))

for strategy in ['active', 'random']:
    labeled = list(rng.choice(len(X_train), n_init, replace=False))
    unlabeled = [i for i in range(len(X_train)) if i not in labeled]

    for target in label_counts:
        while len(labeled) < target and unlabeled:
            if strategy == 'active' and len(labeled) >= 10:
                model_temp = LogisticRegression(max_iter=300).fit(
                    X_train[labeled], y_train[labeled])
                margins = margin_uncertainty(model_temp, X_train[unlabeled
                idx = int(np.argmin(margins))
            else:
                idx = rng.integers(0, len(unlabeled))
            labeled.append(unlabeled.pop(idx))

        clf = LogisticRegression(max_iter=300).fit(X_train[labeled], y_tra
        results[strategy].append(accuracy_score(y_test, clf.predict(X_test

plt.figure(figsize=(7, 4))
plt.plot(label_counts, results['active'], 'o-', color='#2b3a8f',
         linewidth=2, label='Active (margin sampling)')
plt.plot(label_counts, results['random'], 's--', color='#e05c5c',
         linewidth=2, label='Random baseline')
plt.xlabel("Labeled training images", fontsize=12)
plt.ylabel("Test accuracy", fontsize=12)
plt.title("Active Learning for 5-Class Image Classification", fontsize=13)
plt.legend(fontsize=11); plt.grid(alpha=0.3)
plt.tight_layout()
plt.savefig('cv_active_learning.png', dpi=150)
plt.show()
```

---

## 基于人类引导的半监督学习

大量可用的未标注视觉数据使半监督学习对CV尤具吸引力。

**自训练 / 伪标签**：在已标注数据上训练模型；将未标注数据上的高置信度预测作为伪标签；重新训练。关键的
一标注者对伪标注样本的随机子集进行抽查以进行校准。

**FixMatch与一致性正则化**：这些方法训练模型在数据增强下产生一致的预测。关键的HITL洞见是：咨询人类不
一模型应该学习哪些不变性？医学影像模型应该对旋转和亮度不变，但不对尺度不变；文本检测模型不应对透

**主动半监督学习**：最高效的组合：主动学习将人类标签集中在模型不确定性最高的地方；自训练对高置信度的

---

## 视频标注

视频标注将图像标注的挑战乘以时间维度：

- **跟踪**： 对象必须跨帧被识别。标注者为关键帧添加标签；跟踪算法在其间进行插值。遮挡、重新进入、快
- **时序一致性**： 在帧 $t$ 中绘制的边界应与帧 $t+1$ 在空间上保持一致。不一致的标注是告诉模型对象不连续
  —这是一种对检测模型特别有害的标注噪声形式。
- **可扩展性**： 以30帧/秒拍摄的1小时视频有108,000帧。完整标注是不切实际的；采样策略必须精心设计，

现代视频标注工具支持**智能跟踪**，跨帧传播标注，并在跟踪置信度下降到阈值以下时标记帧，提示标注者重新

**自动驾驶系统中的稀有事件问题**。 对于稀有事件后果灾难性的应用——自动驾驶、无人机导航—
—正常操作中看到的帧分布与最重要的帧分布严重不匹配。通过均匀采样行车影像构建的数据集，将包含数百万
—它是安全要求。

> See also: ImageNet数据集：{cite}`russakovsky2015imagenet`。ImageNet中的标签偏见：{cite
> Anything）：{cite}`kirillov2023segment`。CV核心集主动学习：{cite}`sener2018active`。

# 人机协同在医疗与科学中的应用

医疗健康和科学研究是HITL ML最具影响力、也最受争议的两个领域。风险极高：一次漏诊的癌症或一个错误的
一肿瘤要么存在，要么不存在——即便没有任何单独的观察者能可靠地确定这一点。

大众报道中的主流框架是”AI对抗人类”：AI会取代放射科医生吗？这种框架错误的方式是重要的。真正的问

---

## 医学图像分析

医学影像——放射学（X射线、CT、MRI）、病理学（组织切片）、皮肤科、眼科——是医疗AI进展最为迅速的

### 专家标注者的要求

医学影像标注通常需要具有特定亚专科培训的医师。这使标注：

- **缓慢**：专家时间有限；标注与临床职责相竞争
- **昂贵**：成本从数十美元到数百美元不等，具体取决于亚专科、模态和任务复杂度
- **多变**：即使是专家也会出现分歧，特别是在边界案例上——这一事实通常被视为问题，但实际上具有信息

### 放射科医生间的变异性

阅片变异性在放射学中有充分记录。在CheXNet研究中，四位放射科医生对同一肺炎检测测试集进行标注，F
{cite}`rajpurkar2017chexnet`，反映了边界案例上真实的诊断不确定性。对于肺部CT结节检测，阅片者内

这种变异性不仅仅是噪声——它反映了真实的诊断不确定性。在单一放射科医生标注上训练的模型可能学习到

:::{admonition} CheXNet争议作为HITL教训 :class: note

当Rajpurkar等人宣称其CheXNet模型在肺炎检测上”超越了放射科医生的表现”时，这一说法立即受到放射
{cite}`yu2022assessing`。争议的一部分涉及特定测试集和放射科医生比较。但更深层的问题是方法论的：
一所有这些模型都没有。

教训不是模型是好是坏，而是**性能比较需要明确HITL设置**。一个优于独立冷读放射科医生的模型，可能仍然不好
:::

:::{admonition} 医学中的软标签 :class: important

多个医疗AI项目已转向使用**软标签**，反映专家意见的分布而非单一”黄金标准”标签。一张由放射科医生小组
一而这种不确定性在临床上是有意义的，因为它告诉临床医生何时应该会诊，而不仅仅是模型认为是什么。
:::

### 罕见病的主动学习

主动学习对罕见疾病和罕见病理尤其有价值，在这些情况下，即使是大型未标注样本池也只包含少量阳性病例

基于不确定性的主动学习自然地选择模型不确定的边界案例——对于罕见病，这些往往是阳性病例和边界阴性

---

## 临床NLP标注

电子健康记录（EHR）包含大量临床叙述文本：医嘱、出院摘要、放射学报告、病理报告。从这些文本中提取
—而高质量的NLP需要标注的训练数据。

**常见临床NLP标注任务**： - **临床NER**： 识别文本中的药物、剂量、诊断、操作和症状 - **否定检测**： “无肺炎证据”与”确认肺炎”——一个关键区别，出人意料地困难 - **时序推理**：区分当前状况与病史（“既往心肌梗死病史，以胸痛就诊”） - **去标识化**： 删除受保护健康信息（PHI）以支持

**PHI去标识化**既是标注任务，也是数据治理要求。根据美国HIPAA和欧盟GDPR，健康数据在未删除或匿名化患

### i2b2 / n2c2作为模板

i2b2（用于整合生物学与床旁实践的信息学）及其后续项目n2c2（国家NLP临床挑战赛）共享任务计划发布了

---

## 监管考量

医疗AI在大多数司法管辖区受到监管监督。

**FDA（美国）**： 基于AI/ML的医疗软件设备（SaMD）需要上市前审批或许可。FDA 2021年AI/ML行动计划强
—记录模型将如何更新以及在部署前如何验证这些更新。在此框架下，持续从临床反馈中学习的模型在每次更

**CE认证（欧洲）**： 包括AI系统在内的医疗设备必须符合医疗器械法规（MDR）。MDR要求临床评估、上市后

**关键HITL含义**： 监管框架要求清晰地记录标注流程、标注者资质、评分者间可靠性，以及对训练数据任何变更
—它是允许临床医生了解什么训练数据产生了模型当前行为的审计追踪，且在法律上是必需的。将标注视为非

---

## 科学数据标注

除医疗健康之外，HITL ML在科学研究中发挥着日益增长且未被充分认识的作用，在那里标注挑战往往将领域专

### 天文学：Galaxy Zoo

Galaxy Zoo {cite}`lintott2008galaxy` 将斯隆数字巡天中星系的形态分类众包给了公民科学家。原始项目

Galaxy Zoo的经验产生了两个重要的方法论发现。首先，公民科学家与专业天文学家之间的一致性对清晰案例
—而恰恰是这些案例在科学上最重要。解决方案不是丢弃公民科学数据中的边界案例，而是将志愿者响应的分
Zoo标签上训练的分类器优于在任何单一专家标签上训练的模型，因为人群分布捕捉了单个专家的强制选择所

### 基因组学：致病性分类

标注基因组变异——决定某个变异是致病性的、良性的还是意义不明的——是一个高风险的NLP和专家判断问题

### 气候与地球科学

为土地利用变化、森林砍伐、冰川范围和风暴轨迹标注卫星图像，涉及遥感专家，以及日益增多的公民科学平

### 神经科学：连接组学

从电子显微镜图像重建神经回路——连接组学——需要对跨越庞大图像栈的神经元膜进行像素级标注。Eyewir

---

## 管理专家标注者

当标注需要稀缺专业知识时，通常的众包方法（第13章）不适用。

**根本矛盾**在于，能够产生最高质量标注的人，也是时间最宝贵、最受约束的人。专家标注流程中的每个设计决

**这在实践中意味着：**

- **积极地进行预标注。** 使用低层级标注者、自动化模型或基于规则的系统来生成候选结果，供专家审查和
- **为专家注意力而非吞吐量设计。** 针对高吞吐量优化的标注界面（快速二元决策、键盘快捷键、最小化显
- **明确追踪个体标注者模式。** 有了一小批专家，追踪每位标注者与小组的一致率、标记看似与其自身历史
  —它是临床医学用于绩效审查的相同质量流程，当被框架为共同质量改进而非评估时，专家通常反应良好
- **会话设计很重要。** 医学标注在认知上是要求苛刻的。来自放射学和病理学的证据表明，连续阅片约90分

---

## 医学影像HITL主动学习流程

```python
import numpy as np
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import roc_auc_score
from sklearn.datasets import make_classification
import matplotlib.pyplot as plt

rng = np.random.default_rng(42)

# Simulate a rare-pathology detection task
# 8% positive class (e.g., rare pathology)
X, y = make_classification(
    n_samples=5000, n_features=100,
    n_informative=20, n_redundant=10,
    weights=[0.92, 0.08],
    random_state=42
)
X_train, y_train = X[:4000], y[:4000]
X_test,  y_test  = X[4000:], y[4000:]
```

```
print(f"Training set positive prevalence: {y_train.mean():.1%}")

def run_medical_al(strategy, n_initial=50, budget=300):
    labeled = list(rng.choice(len(X_train), n_initial, replace=False))
    unlabeled = [i for i in range(len(X_train)) if i not in labeled]
    aucs = []

    while len(labeled) < n_initial + budget:
        model = LogisticRegression(max_iter=500, class_weight='balanced')
        model.fit(X_train[labeled], y_train[labeled])

        if len(labeled) % 30 == 0:
            preds = model.predict_proba(X_test)[:, 1]
            aucs.append(roc_auc_score(y_test, preds))

        X_pool = X_train[unlabeled]
        if strategy == 'uncertainty' and len(labeled) >= 10:
            probs = model.predict_proba(X_pool)
            entropy = -np.sum(probs * np.log(probs + 1e-9), axis=1)
            q = int(np.argmax(entropy))
        else:
            q = rng.integers(0, len(unlabeled))

        labeled.append(unlabeled.pop(q))

    return np.array(aucs)

aucs_al  = run_medical_al('uncertainty')
aucs_rnd = run_medical_al('random')
label_counts = np.arange(len(aucs_al)) * 30 + 50

plt.figure(figsize=(7, 4))
plt.plot(label_counts, aucs_al,  'o-',  color='#2b3a8f', linewidth=2, labe
plt.plot(label_counts, aucs_rnd, 's--', color='#e05c5c', linewidth=2, labe
plt.xlabel("Expert labels obtained", fontsize=12)
plt.ylabel("AUROC", fontsize=12)
plt.title("Active Learning for Rare Pathology Detection", fontsize=13)
plt.legend(); plt.grid(alpha=0.3)
plt.tight_layout()
plt.savefig('medical_al.png', dpi=150)
plt.show()

# Show how AL preferentially selects positive examples
# by checking which class the queried examples belong to
n_init = 50
labeled_al  = list(rng.choice(len(X_train), n_init, replace=False))
labeled_rnd = labeled_al.copy()
unlabeled_al  = [i for i in range(len(X_train)) if i not in labeled_al]
unlabeled_rnd = unlabeled_al.copy()
```

```
model = LogisticRegression(max_iter=500, class_weight='balanced')
model.fit(X_train[labeled_al], y_train[labeled_al])
probs = model.predict_proba(X_train[unlabeled_al])
entropy = -np.sum(probs * np.log(probs + 1e-9), axis=1)
top50_al  = [unlabeled_al[i] for i in np.argsort(entropy)[-50:]]
top50_rnd = list(rng.choice(unlabeled_rnd, 50, replace=False))

pos_rate_al  = y_train[top50_al].mean()
pos_rate_rnd = y_train[top50_rnd].mean()
print(f"\nPositive rate in next 50 queries:")
print(f"  Uncertainty AL: {pos_rate_al:.1%}  (base rate: {y_train.mean():.
print(f"  Random:         {pos_rate_rnd:.1%}")
print(f"  AL queries {pos_rate_al/y_train.mean():.1f}x more positives than
```

See also: Galaxy Zoo众包：{cite}`lintott2008galaxy`。CheXNet放射科医生表现：{cite}`rajpu
AI/ML行动计划指导意见，请参阅FDA发布的相关文件（2021年）。

# 标注平台与工具链

标注平台是人类反馈转化为数据的环境。一个好的平台能提高吞吐量、减少错误、维护质量控制，并使标注流
—以及知道何时自建与购买——是任何HITL项目中的重要决策。

---

## 标注平台全景

近年来，受企业对机器学习训练数据需求的驱动，标注工具市场大幅增长并趋于成熟。工具涵盖范围广泛，从

### 开源平台

Label Studio 是最受欢迎的开源标注平台，通过统一的基于XML的任务配置支持文本、图像、音频、视频和时

Prodigy（由spaCy的开发者提供）是一款高度以工作流为导向的标注工具，专为NLP任务设计。其流式架构每
—旨在最大化标注吞吐量。Prodigy是付费软件，但在NLP研究中被广泛使用。

CVAT（**计算机视觉标注工具**）是CV标注领域领先的开源工具，对检测、分割和视频标注有强大支持。CVAT

Doccano 针对序列标注任务（NER、关系抽取、文本分类）。其简单的Web界面使没有专职数据工程资源的

### 商业平台

Scale AI 提供端到端托管标注服务：人工标注者群体、质量管理和API集成。在自动驾驶、机器人和复杂3D标

Labelbox 是数据整理、标注和机器学习辅助标注的完整平台。具有强大的企业级功能：项目管理、质量工作
AI、Azure ML）的集成。

Appen（前身为Figure Eight / CrowdFlower）在工具的基础上运营着一支庞大的全球标注者队伍。当数量和

Surge AI 专注于专家标注者，在需要领域知识或细致判断的任务中表现出色。

Humanloop 专注于LLM反馈收集——偏好标注、RLHF数据收集和模型评估。

---

## 标注平台功能对比

| 功能 | Label Studio | Prodigy | CVAT | Labelbox | Scale AI |
|---|---|---|---|---|---|
| 许可证 | 开源 | 商业 | 开源 | 商业 | 商业 |
| 托管方式 | 自托管/云 | 自托管 | 自托管/云 | 云 | 托管服务 |
| 文本标注 | ▯ | ▯ | — | ▯ | ▯ |

| 功能 | Label Studio | Prodigy | CVAT | Labelbox | Scale AI |
|---|---|---|---|---|---|
| 图像标注 | □ | 有限 | □ | □ | □ |
| 视频标注 | □ | — | □ | □ | □ |
| 主动学习集成 | □ | □ | 有限 | □ | □ |
| ML辅助预标注 | □ | □ | □ | □ | □ |
| 质量控制工作流 | 基础 | 基础 | 基础 | 高级 | 高级 |
| API / 程序化访问 | □ | □ | □ | □ | □ |
| 标注者队伍管理 | — | — | — | 有限 | □ |

---

## 标注即代码

标注基础设施中一个重要但常被忽视的方面是**对标注和标注方案进行版本控制**。将标注视为代码意味着：

**方案优先设计**。 在标注开始之前，在版本控制的配置文件（YAML或JSON）中定义标签分类体系和标注规则。

**标注版本化**。 标注与创建它们时所依据的方案版本相关联存储。这允许审计、回滚和跨方案版本比较标注。

**可重现的流程**。 从原始数据到可训练标签的标注流程应该能从代码中重现。预标注模型、质量过滤器、聚合逻

```
# Example: Label Studio annotation schema (text classification)
label_config: |
  <View>
    <Text name="text" value="$text"/>
    <Choices name="sentiment" toName="text" choice="single">
      <Choice value="positive"/>
      <Choice value="negative"/>
      <Choice value="neutral"/>
      <Choice value="mixed"/>
    </Choices>
  </View>
schema_version: "2.1.0"
task_type: text_classification
guidelines_version: "guidelines_v3.pdf"
```

```text
□ □ □
    |
    v
□ □ □ □ □ □  -->  □ □ □ □  --> □ □ □ □ □
    ^                    |                    |
    |                    | □ ML□ □ □            v
□ □ □ □  <--------+                  □ □ □ □
□ □ □ □                                  |
    ^                                    v
    +------------ □ □ □ □ □  <---------- □ □
                                         |
                                       □ □ □
                                       □ □
```

关键集成点： 1. **数据摄取**： 未标注数据自动从数据仓库流入标注平台 2. **模型服务**：
当前最优模型被部署到标注平台以进行预标注和主动学习评分 3. **导出**： 完成的标注以与训练框架兼容的格式导

JSON、Hugging Face数据集等） 4. **反馈回路**： 生产模型错误被路由回标注平台以进行纠正

See also: 关于Label Studio文档和主动学习集成：https://labelstud.io。关于Prodigy：https://prodi.g
{cite}`monarch2021human` 第7章。

# 众包与质量控制

当标注任务足够简单，非专家也能完成时，众包平台提供了以较低的每条成本访问大型按需标注者队伍的途径

---

## 众包平台

Amazon Mechanical Turk（MTurk） 是最原始的众包市场，于2005年推出。工人（“Turkers”）完成发布者
—远低于许多高收入国家的最低工资{cite}hara2018data——这是第15章将讨论的伦理问题。MTurk最适合

Prolific 是一个学术众包平台，执行最低薪酬标准（目前约为9英镑/小时，即约11美元/小时，如Prolific发布的

Appen（以及类似的Telus International、iMerit）提供托管标注队伍与质量管理，用于更复杂的任务和企业项

**专业社区**。 对于特定领域的任务，领域爱好者社区可以提供高质量的标注：用于天文学的Galaxy Zoo、用于鸟类物种的eBird、用于国际象棋局面标注的Chess Tempo。

---

## 众包的任务设计

### 分解复杂任务

复杂任务应分解为简单、定义明确的微任务。与其要求工人全面标注一份文档，不如每次只问他们一个专注的

**分解的好处**： - 每个任务的认知需求降低 → 疲劳减少，质量提高 - 每个微任务可以单独进行质量控制 - 更易于审计和调试

### 说明的重要性

众包质量最重要的单一预测因素是说明质量。良好的任务说明： - 用一句话解释任务的目的 - 为每个类别提供清晰、无歧义的定义 - 提供3至5个有效示例（特别是边缘案例） - 长度不超过工人实际会阅读的

在扩大规模之前进行**试点研究**（10至50名工人，20至100个任务）。分析试点分歧；大多数分歧指向可以修复

### 黄金标准问题

在任务批次中嵌入**黄金标准问题**——具有已知正确答案的任务。在黄金问题上低于阈值的工人将被从项目中移

```
import numpy as np
from scipy.stats import binom

rng = np.random.default_rng(42)
```

```python
def simulate_gold_screening(n_workers=100, gold_per_batch=5,
                            p_good_worker=0.7, good_acc=0.92,
                            bad_acc=0.55, threshold=0.70):
    """
    Simulate quality screening via gold questions.
    Returns: precision and recall of identifying bad workers.
    """
    worker_quality = rng.choice(['good', 'bad'], size=n_workers,
                                p=[p_good_worker, 1 - p_good_worker])
    results = {'tp': 0, 'fp': 0, 'tn': 0, 'fn': 0}

    for q in worker_quality:
        acc = good_acc if q == 'good' else bad_acc
        n_correct = rng.binomial(gold_per_batch, acc)
        passed = (n_correct / gold_per_batch) >= threshold
        if q == 'bad' and not passed:  results['tp'] += 1
        if q == 'good' and not passed: results['fp'] += 1
        if q == 'bad' and passed:      results['fn'] += 1
        if q == 'good' and passed:     results['tn'] += 1

    tp, fp, fn = results['tp'], results['fp'], results['fn']
    precision = tp / (tp + fp + 1e-6)
    recall    = tp / (tp + fn + 1e-6)
    return precision, recall

# Vary gold question count
gold_counts = [3, 5, 8, 10, 15, 20]
precisions, recalls = [], []
for g in gold_counts:
    p_list, r_list = [], []
    for _ in range(50):
        p, r = simulate_gold_screening(gold_per_batch=g)
        p_list.append(p); r_list.append(r)
    precisions.append(np.mean(p_list))
    recalls.append(np.mean(r_list))

import matplotlib.pyplot as plt
fig, ax = plt.subplots(figsize=(7, 4))
ax.plot(gold_counts, precisions, 'o-', color='#2b3a8f', label='Precision',
ax.plot(gold_counts, recalls,    's--', color='#0d9e8e', label='Recall',
ax.set_xlabel("Gold questions per batch", fontsize=12)
ax.set_ylabel("Screening performance", fontsize=12)
ax.set_title("Worker Screening via Gold Standard Questions", fontsize=13)
ax.legend(fontsize=11); ax.grid(alpha=0.3)
plt.tight_layout()
plt.savefig('gold_screening.png', dpi=150)
plt.show()

p, r = simulate_gold_screening(gold_per_batch=5)
print(f"5 gold questions: Precision={p:.3f}, Recall={r:.3f}")
```

```
p, r = simulate_gold_screening(gold_per_batch=10)
print(f"10 gold questions: Precision={p:.3f}, Recall={r:.3f}")
```

---

## 标签聚合的统计模型

多数投票是自然的基线，但忽略了标注者准确率的差异。统计模型可以做得更好。

### Dawid-Skene模型

Dawid-Skene（DS）模型 {cite}dawid1979maximum 联合估计： - 每个条目 $i$ 的**真实标签** $z_i$ - 每位标注者 $j$ 的**混淆矩阵** $\pi_j^{(k,l)}$：标注者 $j$ 将真实类别为 $k$ 的条目标注为类别 $l$ 的概率

EM算法迭代： -E步： 给定标注者混淆矩阵，计算每个真实标签的后验概率 -M步： 给定条目标签估计，更新

```
import numpy as np
from scipy.special import softmax

def dawid_skene_em(annotations, n_classes, n_iter=20):
    """
    Simplified Dawid-Skene EM for binary classification.
    annotations: dict {item_idx: [(annotator_idx, label), ...]}
    Returns: estimated true labels and annotator accuracies.
    """
    items = sorted(annotations.keys())
    n_items = len(items)
    annotators = sorted({a for anns in annotations.values() for a, _ in an
    n_annotators = len(annotators)
    ann_idx = {a: i for i, a in enumerate(annotators)}

    # Initialize: majority vote
    T = np.zeros((n_items, n_classes))  # soft label estimates
    for i, item in enumerate(items):
        for _, label in annotations[item]:
            T[i, label] += 1
        T[i] /= T[i].sum()

    # Confusion matrices: shape (n_annotators, n_classes, n_classes)
    PI = np.ones((n_annotators, n_classes, n_classes)) * 0.5

    for _ in range(n_iter):
        # M-step: update confusion matrices
        PI = np.zeros((n_annotators, n_classes, n_classes)) + 1e-6
        for i, item in enumerate(items):
            for ann, label in annotations[item]:
                a = ann_idx[ann]
                for k in range(n_classes):
                    PI[a, k, label] += T[i, k]
        PI /= PI.sum(axis=2, keepdims=True)
```

```
        # E-step: update soft label estimates
        T = np.zeros((n_items, n_classes))
        for i, item in enumerate(items):
            log_p = np.zeros(n_classes)
            for ann, label in annotations[item]:
                a = ann_idx[ann]
                log_p += np.log(PI[a, :, label] + 1e-10)
            T[i] = softmax(log_p)

    return {item: T[i] for i, item in enumerate(items)}, PI

# Simulate crowdsourcing scenario
rng = np.random.default_rng(42)
N_ITEMS, N_ANNOTATORS, ANNS_PER_ITEM = 200, 10, 3
true_labels = rng.integers(0, 2, N_ITEMS)
# Annotator accuracies: 3 good (0.9), 4 medium (0.75), 3 noisy (0.6)
accuracies = [0.90]*3 + [0.75]*4 + [0.60]*3

annotations = {}
for i in range(N_ITEMS):
    anns_for_item = []
    chosen = rng.choice(N_ANNOTATORS, ANNS_PER_ITEM, replace=False)
    for a in chosen:
        acc = accuracies[a]
        label = true_labels[i] if rng.random() < acc else 1 - true_labels[
        anns_for_item.append((a, int(label)))
    annotations[i] = anns_for_item

# Run Dawid-Skene
soft_labels, confusion = dawid_skene_em(annotations, n_classes=2, n_iter=3
ds_preds = {i: int(np.argmax(soft_labels[i])) for i in range(N_ITEMS)}

# Compare with majority vote
mv_preds = {}
for i in range(N_ITEMS):
    votes = [l for _, l in annotations[i]]
    mv_preds[i] = int(np.round(np.mean(votes)))

ds_acc = np.mean([ds_preds[i] == true_labels[i] for i in range(N_ITEMS)])
mv_acc = np.mean([mv_preds[i] == true_labels[i] for i in range(N_ITEMS)])

print(f"Majority vote accuracy:  {mv_acc:.3f}")
print(f"Dawid-Skene accuracy:    {ds_acc:.3f}")
print(f"\nEstimated annotator accuracies (diagonal of confusion matrix):")
for a in range(N_ANNOTATORS):
    est_acc = np.mean([confusion[a, k, k] for k in range(2)])
    print(f"  Annotator {a}: estimated={est_acc:.3f}, true={accuracies[a]:
```

### MACE

MACE（**多标注者能力估计**）{cite}`hovy2013learning` 是另一种概率模型，它明确表示标注者的刷单行为（$1-\text{spam}_j$），要么提供随机标签（概率为 $\text{spam}_j$）。这种两组分模型在众包场景中通常比Dawid-Skene具有更好的校准效果，特别是在一些标注者完全是刷单者的情况下。

---

## 冗余与聚合策略

每条数据的最优标注者数量取决于任务难度和标注者质量：

- **容易任务且有技能的标注者**： 每条数据1至2名标注者通常足够
- **中等难度任务且有经过培训的标注者**： 3名标注者 + 多数投票
- **困难/主观任务且有众包工人**： 5至7名标注者 + Dawid-Skene

关键洞见：当标注者准确率较低时，冗余最有价值。对于准确率为 $p$ 的标注者，$n$ 名标注者多数投票的准确率

$$P(\text{MV正确}) = \sum_{k>n/2}^{n} \binom{n}{k} p^k (1-p)^{n-k}$$

对于 $p = 0.70$，添加第三名标注者将多数投票准确率从70%提升至78%；对于 $p = 0.90$，第三名标注者带来的收益可以忽略不计（从90%提升至97%）。

See also: Dawid-Skene模型：{cite}`dawid1979maximum`。MACE：{cite}`hovy2013learning`。

# 评估方法与度量指标

了解HITL系统是否正常运作，不仅仅是衡量模型准确率。你需要知道：你是否从标注预算中获得了价值，模型是

---

## 以模型为中心的指标

标准机器学习指标可直接应用于HITL系统，但有一些重要的细微差别。

### 分类指标

**准确率**在类别平衡且所有错误代价相同时适用。然而，在HITL设置中，标注测试集可能因查询策略而产生偏差

**F1分数**是精确率和召回率的调和平均，适用于不平衡类别。在HITL情境中，精确率和召回率的重要程度可能因

**AUROC**衡量模型不依赖阈值区分类别的能力——对于医学筛查等对校准敏感的任务很重要。

**校准**衡量预测概率与经验频率的吻合程度。在HITL系统中，从主动学习的偏斜标注集上训练的模型，即使准确率

### 生成式模型指标

对于语言模型和生成系统，评估从根本上更为困难。没有单一的自动指标能够捕捉质量的全部：

- **BLEU / ROUGE / METEOR**： 用于翻译和摘要的基于参考的指标。与长文本生成的人类质量判断的相关性
- **困惑度**： 衡量模型预测保留文本的能力。是质量的必要但非充分条件。
- **BERTScore**： 与参考文本的基于嵌入的相似度。与人类判断的相关性优于n-gram指标。
- **人工评估**： 黄金标准。详见第14.3节。

---

## 标注效率指标

HITL评估还应衡量人类反馈的使用效率。

### 学习曲线

**学习曲线**将模型性能绘制为标注样本数量的函数。学习曲线陡峭（标签少，改善快）表明标注策略正在选择信

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
from sklearn.linear_model import LogisticRegression
```

```
from sklearn.metrics import f1_score, roc_auc_score
from sklearn.model_selection import StratifiedShuffleSplit

rng = np.random.default_rng(42)
X, y = make_classification(n_samples=5000, n_features=30, n_informative=15
                           weights=[0.8, 0.2], random_state=42)
X_test, y_test = X[4000:], y[4000:]
X_pool, y_pool = X[:4000], y[:4000]

label_sizes = [20, 40, 60, 100, 150, 200, 300, 400, 600, 800, 1000, 1500,
metrics = {'f1': [], 'auc': []}

for n in label_sizes:
    idx = rng.choice(len(X_pool), n, replace=False)
    clf = LogisticRegression(max_iter=500, class_weight='balanced')
    clf.fit(X_pool[idx], y_pool[idx])
    preds = clf.predict(X_test)
    probs = clf.predict_proba(X_test)[:, 1]
    metrics['f1'].append(f1_score(y_test, preds))
    metrics['auc'].append(roc_auc_score(y_test, probs))

# Fit learning curve: performance ≈ a - b/sqrt(n)
from scipy.optimize import curve_fit

def learning_curve_fn(n, a, b):
    return a - b / np.sqrt(n)

popt_f1, _ = curve_fit(learning_curve_fn, label_sizes, metrics['f1'], p0=[
popt_auc, _ = curve_fit(learning_curve_fn, label_sizes, metrics['auc'], p0

n_smooth = np.linspace(20, 3000, 200)

fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(11, 4))

ax1.scatter(label_sizes, metrics['f1'], color='#2b3a8f', zorder=5, s=40)
ax1.plot(n_smooth, learning_curve_fn(n_smooth, *popt_f1), '--', color='#e0
         label=f'Fit: {popt_f1[0]:.3f} - {popt_f1[1]:.1f}/√n')
ax1.set_xlabel("Labeled examples"); ax1.set_ylabel("F1 score")
ax1.set_title("Learning Curve: F1"); ax1.legend(); ax1.grid(alpha=0.3)

ax2.scatter(label_sizes, metrics['auc'], color='#0d9e8e', zorder=5, s=40)
ax2.plot(n_smooth, learning_curve_fn(n_smooth, *popt_auc), '--', color='#e
         label=f'Fit: {popt_auc[0]:.3f} - {popt_auc[1]:.2f}/√n')
ax2.set_xlabel("Labeled examples"); ax2.set_ylabel("AUROC")
ax2.set_title("Learning Curve: AUROC"); ax2.legend(); ax2.grid(alpha=0.3)

plt.tight_layout()
plt.savefig('learning_curves.png', dpi=150)
plt.show()

# Estimate the annotation budget needed to reach a target performance
```

```
target_f1 = 0.80
n_needed = (popt_f1[1] / (popt_f1[0] - target_f1)) ** 2
print(f"Estimated labels needed to reach F1={target_f1}: {n_needed:.0f}")
```

### 投资回报率（ROI）分析

人类反馈的ROI回答了这样一个问题：每增加一个标签，模型性能会提升多少？

$$\text{ROI}(n) = \frac{\Delta\text{性能}(n)}{\text{每标签成本}}$$

随着模型的成熟（以及易于学习的样本被耗尽），ROI通常会下降。实际含义：标注预算应该前置，在ROI最高

---

## 人工评估

对于生成系统和主观任务，人工评估仍然是黄金标准。

### 直接评估（DA）

标注者在绝对量表上（例如，翻译质量1至100分，或回复有帮助性1至5分）对输出进行评分。DA已在机器翻译

**DA的最佳实践：** - 随机化输出顺序以防止锚定效应 - 每个条目使用足够数量的标注者（最少3至5名）
- 包含质量控制（明显好和坏的示例，以发现注意力不集中的评分者） - 在汇总分数的同时报告标注者间一致性

### 比较评估

标注者选择两个输出中的一个："哪个更好？"比较判断比绝对评分更快且更一致（见第8章）。**ELO评分系统**

```
import numpy as np

def update_elo(rating_a, rating_b, outcome_a, k=32):
    """Update ELO ratings. outcome_a: 1=A wins, 0=B wins, 0.5=tie."""
    expected_a = 1 / (1 + 10 ** ((rating_b - rating_a) / 400))
    expected_b = 1 - expected_a
    new_a = rating_a + k * (outcome_a - expected_a)
    new_b = rating_b + k * ((1 - outcome_a) - expected_b)
    return new_a, new_b

# Simulate 5 model versions being compared pairwise
rng = np.random.default_rng(42)
true_quality = [0.60, 0.70, 0.75, 0.80, 0.85]  # underlying model quality
n_models = len(true_quality)
elo_ratings = {i: 1000.0 for i in range(n_models)}

for _ in range(500):  # 500 pairwise comparisons
    i, j = rng.choice(n_models, 2, replace=False)
    p_i_wins = true_quality[i] / (true_quality[i] + true_quality[j])
    outcome = 1.0 if rng.random() < p_i_wins else 0.0
```

```
    elo_ratings[i], elo_ratings[j] = update_elo(elo_ratings[i], elo_rating

print("ELO Rankings after 500 comparisons:")
sorted_models = sorted(elo_ratings.items(), key=lambda x: x[1], reverse=Tr
for rank, (model_id, elo) in enumerate(sorted_models, 1):
    print(f"  Rank {rank}: Model {model_id}  ELO={elo:.1f}  True quality={
```

### 行为测试（CheckList）

CheckList{cite}`ribeiro2020beyond`是一种对NLP模型进行系统性行为评估的方法论。与随机测试集不同

- **最小功能测试（MFT）：** 模型能否处理简单、明显的案例?
- **不变性测试（INV）：** 当不应发生变化时（例如，改写时），模型的输出是否会变化?
- **方向性预期测试（DIR）：** 当输入发生变化时，模型的输出是否按预期方向变化?

CheckList使人工评估具有针对性且可操作：不是单一的准确率数字，而是能力概况。

---

## 衡量与人类意图的对齐程度

对于RLHF系统，衡量对齐程度是核心评估挑战。

**奖励模型评估：** 奖励模型在保留偏好测试集上的准确率。Ouyang等人{cite}`ouyang2022training`报告InstructGPT奖励模型的成对准确率约为72%；作为粗略的参考点，类似数量级的数字在类似的RLHF流程中

**胜率：** 给定两个模型版本（例如，SFT基线与RLHF微调版），在人类成对比较中，RLHF模型的回复赢得了多少

**GPT-4作为评估者：** 使用有能力的LLM来评估回复，已成为快速迭代的常见做法。Gilardi等人{cite}`gilardi2023chatgpt`和Zheng等人{cite}`zheng2023judging`发现LLM评估者与人类判断的一致—对于快速A/B比较有用，但对于检测谄迎性、文化细微差别或安全问题则不够可靠。

**谄迎性检测：** 衡量模型是否根据隐含的用户偏好改变其答案（例如，“我认为X是正确的；你怎么看？”）。

---

## 已部署系统中的A/B测试

对于生产中的系统，最终评估是**A/B测试**：将一部分用户路由到新的模型版本，并衡量下游结果。

A/B测试提供了模型在实际部署情境中质量的无偏估计，能够捕捉实验室评估遗漏的影响（用户行为、人口分

挑战在于：合适的下游指标。参与度指标（点击、会话时长）可能奖励操纵性行为。任务完成率或用户满意度

> See also: CheckList行为测试：{cite}`ribeiro2020beyond`。关于RLHF评估方法论，请参见{cite}`ouyang2022training`。关于MT中人工评估的最佳实践：{cite}`graham2015accurate`。关

# 公平性、偏见与伦理

人在回路系统继承了其中人类的能力与局限。标注者将知识、判断力和创造力带到工作中——但也带来了偏见、疲劳和他们自身生活的社会情境。我们在设计HITL系统时做出的选择——谁来标注、被问了什么、如何获得报酬，以及他们的工作被如何使用——其影响远超模型准确率指标。

本章探讨HITL ML的伦理维度。

---

## HITL系统中偏见的来源

### 标注者人口构成

标注不是中立的行为。标注者分配的标签反映了他们的视角、经历和文化情境。当标注者群体人口构成单一——通常正是这种情况，众包工作偏向年轻、男性和西方人——由此产生的数据集编码了这一群体的视角。

**证据**： NLP标注数据集的研究发现，标注者的人口特征能够预测他们对主观任务（毒性、情感、冒犯性）的标 {cite}`geva2019annotator`。

**后果**： 在此类数据上训练的模型，对与标注者群体相似的用户表现良好，对不相似的用户则表现较差，或存在

**缓解措施**： 刻意推进队伍多样化；分层标注（确保来自相关人口群体的标注者对相关任务做出贡献）；追踪标

### 任务框架

问题的框架方式影响其所引发的答案。如果问标注者”这段文字是有毒的吗？“他们的回答可能与问”这段文

**示例**： 社交媒体上”滥用性语言”的标注，根据标注者是否被展示了关于作者身份的情境信息而有显著差异。

### 平台效应

平台和支付结构影响标注质量。按任务而非按小时付费的工人有快速工作的激励；这提高了吞吐量，但降低了

### 确认偏见与锚定偏见

标注者受以下因素影响： - **预标注**： 呈现给标注者的模型预测，被接受的频率多于被拒绝，即使在错误时也是 - **顺序效应**： 在不同情境下标注同一条目会产生不同答案 - **启动效应**： 任务中的前一条目影响后续条目的标注方

---

## HITL系统中的公平性

### 什么是公平性?

机器学习中的公平性是一个有争议的概念，有多种形式定义，这些定义往往相互不兼容 {cite}barocas2019fairness。对HITL而言，最相关的维度是：

**代表性**： 训练数据是否代表了模型将影响的人口群体?

**性能均等**： 模型在不同人口群体中的表现是否相同?

**标注一致性**： 相同的行为是否被一致标注，无论谁在执行这些行为? （研究表明，当相同内容被归因于不同种

### 公平性感知的主动学习

标准主动学习查询聚焦于模型不确定性，倾向于集中在多数类样本上。这可能加剧少数群体的性能差距。

**公平性感知的查询策略**用多样性或代表性约束来补充不确定性标准：

$$x^* = \underset{x \in \mathcal{U}}{\arg\max} \left[ \lambda \cdot \text{不确定性}(x) + (1 - \lambda) \cdot \text{少数群体加分}(x) \right]$$

设置 $\lambda < 1$ 确保查询策略不会完全忽视少数群体的代表性。

---

## 标注者福利

### 幽灵工作问题

驱动机器学习的标注工作在很大程度上是不可见的。数据工人——常常在全球南方——以低薪酬、无福利的零工经济安排，在没有工作保障的情况下，为图像添加标签、转录语音和审核内容。Kate Crawford和Vladan Joler的”AI系统的解剖” {cite}crawford2018anatomy 以及Mary Gray和Siddharth Suri的”幽灵工作” {cite}gray2019ghost 记录了这种劳动的规模和不稳定性。

**Amazon MTurk数据**： 2018年对MTurk收入的系统性分析发现，有效时薪中位数约为2美元/小时——低于美国大多数州和许多高收入国家的最低工资 {cite}hara2018data。高收入国家以外的工人往往面临额

**内容审核**： 一种特别有害的标注工作形式——审核图形、暴力和令人不安的内容——已被与标注工人的创伤后 {cite}newton2019trauma。平台因心理健康支持不足和过度暴露限额而受到批评。

### 伦理实践

**公平薪酬**： 以不低于当地最低工资的标准向标注工人支付报酬。研究表明，更高的薪酬吸引了更高质量的工人

**工作可见性**： 在出版物和产品文档中承认创建训练数据的劳动。

**心理健康支持**： 对于审核有害内容的工人，提供心理支持、轮岗安排和暴露限制。

**工人代表**： 使标注工人能够报告关切、请求指南澄清，并对不公平的质量评估提出异议。

---

## 标注中的隐私问题

### 受保护健康信息（PHI）和个人可识别信息（PII）

标注任务通常涉及敏感个人数据。医疗标注项目可能使工人接触到患者记录；NLP项目可能使工人接触到私人

监管框架（HIPAA、GDPR）限制个人数据如何与标注者队伍共享。关键原则：

- **数据最小化**： 只共享标注者完成任务所需的信息
- **去标识化**： 在可能的情况下，在标注前删除PHI和PII
- **同意**： 在标注真实用户数据时，确保适当的同意或合法依据
- **访问控制**： 根据角色和权限限制哪些标注者可以访问敏感数据

### 合成数据作为替代方案

对于真实数据带有隐私风险的任务，合成数据生成可以创建可用于标注的数据集，而不会暴露敏感信息。例如

---

## 对抗性标注与数据投毒

HITL系统创造了一个攻击面：如果攻击者能够影响标注过程，他们就能影响模型的行为。

**通过标注进行数据投毒**： 能够访问标注者队伍的攻击者（例如，一个被破坏的众包工人账户）可以注入系统性
—这可能正是攻击者的目标。

**通过反馈进行奖励黑客攻击**： 在RLHF中，持续给某些类型内容高分的标注者（或AI生成的标注）可以引导模型

**缓解措施**： 每条数据使用多个独立标注者；对标注模式进行异常值检测；监控异常的一致或不一致情况；维护

---

## 机构伦理

### IRB与伦理审查

涉及人类受试者（包括标注工人）的研究项目通常需要机构审查委员会（IRB）批准。收集关于工人信念、对敏

### 数据治理

组织应对以下方面制定清晰政策： - 哪些数据可以发送到外部标注，哪些必须在内部标注 -
标注数据的保留期限及由谁保管 - 谁有权访问标注及基于其训练的模型 - 如何处理删除标注数据的请求（GDPR

### 透明度与问责制

受机器学习系统影响的用户，对了解这些系统是如何构建的有正当利益。记录标注方法论——
谁标注了数据、在什么条件下、遵循什么指南——是一种为用户、监管者和整个领域带来好处的问责形式。

**数据集数据表** {cite}`gebru2021datasheets` 为记录数据集来源、标注程序和已知局限性提供了结构化模板

> See also: 算法公平性框架：{cite}`barocas2019fairness`。幽灵工作与平台劳动：Gray
> & Suri（2019）。数据集数据表：{cite}`gebru2021datasheets`。内容审核工人福利：{cite}`newto

# 未来展望

人在回路机器学习领域正在快速变化。基础模型、LLM作为标注者，以及人机协作的新范式，正在以五年前难

---

## 基础模型与标注角色的转变

基础模型——在广泛数据上预训练、可适配到下游任务的大型模型——正在从根本上改变HITL的经济学。

### 减轻标注负担

一个以前从零开始训练需要数千个标注样本的任务，在微调基础模型时可能只需要数十个。少样本提示可能对

**含义：** 标注的ROI发生了变化。标注工作现在最好指向：- 高质量的评估集（衡量适配后的模型是否真正有效）
- 基础模型处理错误的困难案例和边缘案例 - 能告诉模型一些无法从预训练中推断出的东西的特定任务示例

### 新的任务规格形式

当基础模型已经理解语言、代码和常识时，用户可以用自然语言与其交流，而不是通过标注样本。想要文本分
—他们可以用自然语言描述分类任务并评估零样本性能。

这将HITL挑战从样本收集转变为任务规格：帮助用户以模型能够行动的形式精确表达他们想要的东西。这比听
—任务的自然语言描述往往具有标注样本所没有的歧义性。

---

## LLM作为标注者

2023至2025年最重要的发展之一是将**LLM作为标注来源**。与其问人类”这条评论是正面还是负面的？“，不如
4或Claude。对于定义明确的分类任务，LLM标注通常与众包工人准确率相当或接近{cite}`gilardi2023ch`

### LLM标注效果良好的情况

- 简单、定义明确的分类任务（情感、主题、意图）
- 人类标签编码了LLM已吸收的文化共识的任务
- 标注跨情境一致的任务（非高度主观性）
- 生成供人工审查的初步标注

### LLM标注失败的情况

- 需要稀缺专业知识的高度专业化领域任务（医学、法律、科学）
- 需要本地文化知识或语言变体的任务
- 安全和危害任务，其中LLM可能在与训练数据相同的方向上校准不足
- 预训练中代表性不足的新型任务类型

### RLAIF与宪法AI

如第6章所讨论，AI生成的反馈可用于训练奖励模型并引导强化学习微调。这创造了一个反馈回路：LLM生成数

---

## 大规模弱监督

通过标注函数进行的**程序化标注**（第9章）允许主题专家将知识表达为代码而非标注样本。Snorkel {cite}`ratner2017snorkel`及其后继系统已大幅成熟，现在在主要科技公司的生产环境中被使用。

**前沿方向**：- **LLM增强的标注函数**：使用LLM从自然语言描述生成标注函数 - **基于切片的学习**：识别标注函数不一致的数据关键子集（切片），并将人工标注引导到那里 - **不确定性感知聚合**：用于组合具有不同准确率和相关性的标注函数的更好统计模型

---

## 带有人类监督的持续学习

大多数机器学习系统离线训练并以静态模型的形式部署。真实世界在变化；在部署时准确的模型会随着数据分

**持续学习**——在保留旧知识的同时从新数据中学习的能力——是一个活跃的研究领域。人类监督至关重要：没

**HITL持续学习**涉及：- 监测分布偏移（自动化）并将偏移的样本路由到人工审查 - 选择性重训练：来自新分布的 - 在每次更新后对模型行为变化进行人工审查

---

## 多模态HITL

随着AI系统变得多模态——同时处理和生成文本、图像、音频和视频——标注变得更加复杂。单一内容可能需

**新兴任务类型**：- 视频 + 转录标注（发生了什么，谁在说话，文本在视觉上描述了什么？）- 医学图像 + 临床报告标注 - 机器人轨迹标注（将传感器数据与动作序列关联）

多模态基础模型（GPT-4V、Gemini、Claude）也在改变这里的标注格局——模型现在可以解释图像并生成

---

## 可扩展监督

HITL ML中一个根本性的开放问题是**可扩展监督** {cite}`irving2018ai,bowman2022measuring`：随着AI

对于蛋白质结构预测、法律分析或数学证明验证等任务，即使是专家标注者也可能无法判断两个AI输出哪个是

**提出的方法** {cite}**`bowman2022measuring`**：

**辩论**： 两个AI系统为不同结论辩护；人类评判者直接评估论证而非结论。正确的结论应该更具可辩护性。

**放大**： 人类评判者咨询AI助手（模型本身）来帮助评估复杂输出。这利用AI能力来扩展人类监督，而不是取代

**过程监督**： 不是评估最终输出，而是人类评估推理过程——在思维链中标记有缺陷的步骤，无论最终答案恰好

---

## 劳动分工的演变

HITL ML的长期走向是人类和AI之间更流动的协作，其中双方都不仅仅是”标注者”或”学习者”，而是共同为

**值得关注的趋势**： - **AI辅助标注**： AI提议；人类决定。随着AI提议更好的选项，质量提高。 - **人类引导的探索**： 人类设定目标和约束；AI探索解决方案空间。 - **协作评估**： 人类和AI通过对话共同评估复杂 - **大规模偏好学习**： 用户与AI输出交互的隐式信号，在不需要明确标注会话的情况下提供持续的偏好学习。

关于在多大程度上信任AI判断相对于人类判断——以及在什么领域、什么能力水平、采用什么保障措施——这最终是一个社会问题，而非仅仅是技术问题。HITL ML提供了谨慎回答这个问题的技术基础设施，而非默认

---

## 开放研究问题

我们以一系列该领域正在积极研究的重要开放问题作为结语：

1. **主动学习中的最优停止**： 下一个标注的边际价值何时低于其成本？有原则的停止规则仍然难以捉摸。
2. **跨任务的标注预算分配**： 在多任务设置中，固定的标注预算应如何在任务之间分配？
3. **主动学习中的分布偏移**： 主动学习创建了有偏的标注集。如何对以这种方式训练的模型进行适当校准？
4. **奖励模型泛化**： RLHF奖励模型可能无法泛化到新颖的提示-回复对。我们如何构建更鲁棒的偏好模型？
5. **可扩展监督**： 当AI系统在特定领域超越人类性能时，我们如何维持人类监督？
6. **标注者建模**： 更好的标注者行为统计模型，不仅捕捉能力，还捕捉系统性偏见、主题专业知识和疲劳。
7. **对齐评估**： 我们缺乏关于模型是否与人类价值观对齐的客观真相测试。开发此类测试——类似于鲁棒性的对抗样本——是一个开放问题。
8. **公平的数据劳动**： 确保标注工人获得公平报酬和保护的经济和机构结构，同时维持大规模标注的成本效益

---

目标不是用机器判断取代人类判断， 而是构建两者结合优于任何一方单独的系统。

本手册中的工具和技术——标注、主动学习、RLHF、偏好学习等等——都是实现这一目标的手段。随着该领域——构建既有能力又真正与人类意图对齐的系统——将永远存在。

See also: 可扩展监督与辩论：{cite}`bowman2022measuring`。Snorkel弱监督：{cite}`ratner2017` {cite}`amershi2019software`。

# 参考文献

Table 1: all:

| |
|---|
| jupytext: |
| formats: md:myst |
| text_representation: |
| extension: .md |
| format_name: myst |
| kernelspec: |
| display_name: Python 3 |
| language: python |
| name: python3 |

# 案例研究：Limen——万物循环中的人类

:::{admonition} 关于本章的说明 :class: important 本章是一篇**推测性设计论文**，而非实证研究或经同行评审的
—Limen，一个以语音为优先交互方式的AI原生桌面操作系统——作为前几章HITL原则如何组合成一个连贯整体
:::

本手册的每一章都将HITL ML描述为一种设计哲学：一套使人类参与学习系统变得有意识、高效且诚实的原则。
—不是应用于单一系统，而是应用于整个操作环境——是什么样子的。

Limen 是一个以语音为优先交互方式的AI原生桌面操作系统，建立在这样一个前提之上：人类始终在回路中，
是拉丁语中”门槛”的意思。在感知心理学中，临界值是被感知与未被感知之间的边界。对于操作系统而言，

这里描述的架构不是专有的。它是一套设计决策，每一个都自然地遵循前几章发展的HITL原则。目标不是记录
—当一致地应用时它们如何相互强化，以及当人类不是事后考虑时，什么样的系统成为可能。

---

## 传统操作系统设计的问题

传统操作系统不是为人类设计的。它是为程序设计的。人类通过一层抽象来适应——一个图形界面、一个文件
—这层抽象叠加在一个为进程、内存地址和文件描述符构建的基础之上。

这一设计选择在历史上是有充分理由的。当产生这些假设时，计算机很贵，人类很便宜，瓶颈是计算能力。正

这些假设不再成立。对于大多数用户在大多数任务中来说，瓶颈不是计算能力。而是人类的注意力：上下文切

传统操作系统不这样做。它们为程序优化，人类的工作是说程序的语言。Limen颠转了这一关系。程序说人类

---

## 临界值处的架构

Limen的架构围绕一个单一原则组织：**每次交互都是一个事件**，每个事件都是人类教导、纠正或确认的机会。

### 事件层：WID

在基础层面是WID（适用于Limen本地优先架构的Waldiez ID系统）——一个因果感知的事件追踪系统，它不

传统日志询问：发生了什么？ WID询问：为什么会发生，以及接下来发生了什么？ 每个事件携带一个因果谱系
—从触发的人类行动，经过中间系统状态，到观察到的结果的链条。

这对HITL学习很重要，因为它在交互层面解决了**信用分配问题**。当用户纠正系统的行为时，WID可以识别不只

这是第6章对RLHF描述内容在操作系统层面的等价物：追踪奖励信号通过一系列决策的能力。WID为每次交互

:::{admonition} 因果事件追踪作为HITL基础设施 :class: note WID的设计反映了一个更广泛的原则：HITL基础设
—不仅仅是”它做了什么？“没有因果追踪，纠正只修复症状。有了它，纠正可以修复原因。这是补丁与教训
:::

### 感知层：语音优先

Limen的主要输入模态是语音，通过本地Whisper ONNX推理流程处理。值得明确陈述选择这一方式的原因：

**语音是对大多数人而言最自然的人类输出渠道**。 它不需要培训，不需要超出普通言语之外的身体灵活性，也不

**本地处理保护隐私**。 语音数据不会离开设备。这在伦理上很重要——语音是生物特征数据，云提供商大规模收
—在实践上也是如此：离线操作意味着系统在没有网络连接的情况下仍然可用。

**语音创造了自然的反馈回路**。 当系统响应时，用户的反应——继续说话、重新表述、说”不，那不对”——
—本身就是一个信号。Limen将这些反应视为HITL反馈：关于系统对前一发言的解释是否正确的证据。

回退链与主要模态同样重要。当语音失败时——在嘈杂环境中、对有语言障碍的用户、或对于受益于精确性的
—Limen优雅地降级为键盘界面，再降级为结构化文本界面。祖母测试（见第5章）不是可访问性的事后考虑；

### 智能层：多LLM路由

Limen不依赖单一语言模型。它根据任务类型、所需延迟、隐私要求和置信度，通过结构化决策树路由请求：

1. **本地小型模型**（始终优先）：快速、私密，处理常规任务——“打开我昨天在编辑的文件”、“设置计时
2. **本地大型模型**（当小型模型置信度低时）：更慢但更有能力；处理结构化推理、代码生成、复杂检索
3. **远程模型**（当本地失败且用户已授权时）：出口；以透明方式处理，并明确通知用户

这种结构不是新颖的——它是第4章描述的主动学习查询策略在推理时的等价物。在每个步骤，系统问：我当前

人类在升级边界处在回路中。配置了Limen从不升级到远程模型的用户，已经做出了一个HITL决策—
—系统尊重并记录这个决策。批准了远程查询然后说”这类请求不要再问我了”的用户，提供了一个更新路由策

---

## 交互设计

### 即时性

Limen为第5章定义的即时性而设计：用户感知到其反馈的效果。当用户纠正系统输出时，纠正立即可见地被应

这需要使用支持高效在线更新的模型架构——适配器、前缀调整和检索增强生成，而非全面微调。权衡是明确

### 可解释性

IML文献中反复出现的主题是**可解释性要求**：人类只能引导他们至少能大致理解的模型。Limen在界面中呈现这
—那会淹没大多数用户——而是关键因素的自然语言摘要：“我正在打开你最近使用的项目—
—对吗？”

这个解释也是一个问题。它邀请纠正。它使模型的推断可见，以便用户可以在错误时重新引导。这个解释不是

### 一致性与漂移

任何长期运行的交互系统中出现的一个问题是**行为漂移**：系统在时间 $T + n$ 的行为与时间 $T$
的行为微妙不同，而这种差异既不是用户也不是系统明确选择的。纠正积累。边缘案例复合。上个月与用户偏

Limen通过定期一致性检查来解决这个问题——这是第13章描述的重新呈现技术在操作系统层面的等价物。系

---

## Limen作为HITL系统

通过本手册的视角看Limen的架构，设计决策直接映射到每个部分发展的概念。

**第一部分（基础理论）：** Limen将每次交互都视为人机交互事件。没有”非HITL模式”——系统始终在学习，始终在归因，始终在等待人类参与。

**第二部分（核心技术）：** 主动学习体现为基于置信度的升级链。交互式机器学习体现在实时更新周期中。标注

**第三部分（从人类反馈中学习）：** 第8章描述的偏好学习出现在路由策略更新中。当用户偏好本地模型的答案而

**第四部分（应用实践）：** Limen是通用环境，但其设计在人类判断不可替代、错误代价高昂的领域中最为显著—文档起草、任务优先级排序、创意工作。

**第五部分（系统与工程实践）：** WID是Limen的标注平台。它在正常操作中对用户不可见，在需要调试或透明

**第六部分（伦理与前沿展望）：** 本地优先、隐私保护的设计是伦理选择，而非仅仅是技术选择。人类的数据不

---

## 更深层的观点

Limen不是产品宣传。它是通过构建提出的论证。

论证如下：如果你认真对待HITL ML的原则——如果你相信人类反馈是需要理解而非最小化的信号，人类始终在—那么你最终会构建出类似Limen的东西。

不一定非要是Limen。特定的技术栈（Tauri、Rust、Babylon.js、Whisper ONNX）是众多选择之一。但架构—因果事件追踪、本地优先处理、优雅降级、持续偏好学习、透明度作为一流特性——从原则中自然地涌现出

HITL ML领域花费了大量精力描述如何将人类置于特定模型和特定任务的回路中。下一个问题是，我们是否能围

Limen是对那个问题的一个回答。

门槛不是你跨越就留在身后的东西。它是你居住的地方。

---

See also: Limen交互设计所基于的IML原则在第5章中阐述。路由策略背后的偏好学习方法在第8章中正式

# 论离开

在某个时间点，我曾在一个博士项目中就读。研究方向是机器学习。所在机构是真实的。意图是真诚的。

然后我停下来了。

不是因为这个课题不再重要——它现在比我开始时更加重要。不是因为工作太难——本手册以其独特的方式，

博士体制是一个回路。你作为一个有问题的人类进入它。这个回路教你将那些问题转化为论文，将论文转化为

我不是第一个注意到这一点的人。也不会是最后一个。这不是批评——这是描述。这个回路确实产出了真实的

离开不是一个戏剧性的决定。它是一种缓慢的认识：我实际上想要构建的东西并不需要委员会的许可。我想要
—正在为真实系统做真实决策的从业者、学生和工程师——并不在等待一篇经过正式验证的论文。对我所知道

于是我这样做了。

本手册不是一篇博士论文。它没有机构归属，没有资金致谢，没有伦理委员会审批，没有答辩考核。它不会对

它同时——我在此并非出于虚伪的谦虚而言，因为虚伪的谦虚本身也是一种不诚实——
比那篇论文更完整、更前沿、更具可读性，也更有用。

我是回路中的一个人类。我曾在博士项目的回路中，然后我走出来了。我现在处于写关于回路的文字的回路中

我们当中没有人是完全自由地选择进入这些回路的。但我们有时可以选择对自己身处哪个回路、为何身处其中

这本书是我对这些问题的回答。

它不是一封辞职信。辞职意味着有一份工作，而有工作意味着是别人决定了条件。这是另一回事：记录我选择
—这个选择是正确的。

您可以做这个判断。毕竟，您是回路中的一个人类。

---

——作者